

Comparação entre o método dos Mínimos Quadrados e Maximização da Correntropia do Erro aplicados ao Controle Adaptativo

Allan de Medeiros Martins
Pedro Yochinori Gushiken

Universidade Federal do Rio Grande do Norte

06 de dezembro de 2016

Sumário

- 1 Introdução
- 2 Conceitos
 - Parametrização
 - Estimação dos Parâmetros da Planta usando LSE
 - Estimação dos Parâmetros da Planta usando critério de maximização da Correntropia
 - Controle por Posicionamento de Polos
- 3 Simulações
 - APPC
- 4 Conclusão

Contextualização

1 Controle por Posicionamento de Polos

Contextualização

- 1 Controle por Posicionamento de Polos
- 2 Estimação, Caso Indireto

Contextualização

- 1 Controle por Posicionamento de Polos
- 2 Estimação, Caso Indireto
- 3 Correntropia e Controle

Descrições

Seja a planta controlável e observável descrita por sua função de transferência:

$$G_p(s) = \frac{N_p(s)}{D_p(s)} = \frac{b_0 + b_1s + \dots + b_{n-1}s^{n-1}}{a_0 + a_1s + \dots + a_ns^n}$$

Onde apenas os sinais $u(t) \in R^1$ e $y(t) \in R^1$ estão disponíveis para medição.

Uma parametrização alternativa da planta é da seguinte forma:

$$\theta^* = [b_{n-1}, b_{n-2}, \dots, b_1, b_0, a_{n-1}, a_{n-2}, \dots, a_1, a_0]^T$$

$$Y = [u^{(n-1)}, u^{(n-2)}, \dots, u, -y^{(n-1)}, -y^{(n-2)}, -y]$$

$$y = \theta^{*T} Y$$

Seja um polinômio $\Lambda(s)$ cujas raízes tem todas parte real negativa:

$$\Lambda(s) = s^n + \lambda_{n-1}s^{n-1} + \dots + \lambda_0$$

E um vetor $\alpha_{n-1}(s)$:

$$\alpha_{n-1} = [s^{(n-1)}, s^{(n-2)}, \dots, s^0]^T$$

Desejamos estimar os $2n$ parâmetros da planta, mas dispomos de apenas 2 sinais. De tal forma que criamos um regressor a partir de $u(t)$ e $y(t)$ e de um filtro estável com polinômio $\Lambda(s)$ no denominador:

$$\phi_1 = \frac{\alpha_{n-1}(s)}{\Lambda(s)}u$$

$$\phi_2 = -\frac{\alpha_{n-1}(s)}{\Lambda(s)}y$$

E criamos um regressor $\phi(t)$ concatenando $\phi_1(t)$ e $\phi_2(t)$.

Passando $y(t)$ pelo filtro com $\Lambda(s)$ no denominador criamos um novo sinal $z(t)$:

$$z = \frac{s^n y}{\Lambda(s)}$$

É válida a seguinte parametrização de $z(t)$:

$$z = \theta^{*T} \phi$$

Caracterizamos então uma estimativa de $z(t)$ da seguinte forma:

$$\hat{z} = \theta^T \phi$$

E o erro normalizado entre estes sinais:

$$\epsilon = \frac{z - \hat{z}}{m^2}$$

Onde $m = 1 + n_s^2$ tal que $\phi/m \in \mathcal{L}_\infty$. [escolhas comum: $n_s^2 = \phi^T \phi$]

Para o algoritmo "Least Square Error"(LSE) recursivo com fator de esquecimento, escolhemos a seguinte função de custo com fator de esquecimento:

$$J(\theta) = \frac{1}{2} \int_0^t e^{-\beta(t-\tau)} \frac{[z(\tau) - \theta^T(t)\phi(\tau)]^2}{m^2(\tau)} d\tau + \frac{1}{2} e^{-\beta t} (\theta - \theta_0)^T Q_0 (\theta - \theta_0)$$

Esta função de custo leva ao gradiente:

$$\nabla J(\theta) = e^{-\beta t} Q_0(\theta(t) - \theta_0) - \int_0^t e^{-\beta(t-\tau)} \frac{[z(\tau) - \theta^T(t)\phi(\tau)]}{m^2(\tau)} \phi(\tau) d\tau$$

Que leva à seguinte implementação de uma lei de atualização para as estimativas θ :

$$\begin{aligned}\dot{P} &= \beta P - P \frac{\phi \phi^T}{m^2} P \\ \dot{\theta} &= P \epsilon \phi\end{aligned}$$

Seja um estimador da correntropia entre as variáveis aleatórias Z e $\hat{Z}$ avaliado a partir de uma única amostra:

$$\hat{V}(Z, \hat{Z}) = \frac{1}{\sqrt{2\pi}\sigma} e^{-(z_i - \hat{z}_i)^2 / 2\sigma^2}$$

Escolhemos este estimador como função de custo:

$$\hat{V}(Z, \hat{Z}) = J(\theta)$$

E esperamos que $\hat{V}(Z, \hat{Z})$ tenha um comportamento similar ao valor esperado $V(Z, \hat{Z}) = \mathbf{E}(k_\sigma(Z - \hat{Z}))$ que é a correntropia exata. Este raciocínio é similar ao aplicado em alguns algoritmos de gradiente estocástico.

Somos então levados ao gradiente:

$$\nabla J(\theta) = \epsilon \phi \frac{1}{\sqrt{2\pi}\sigma^3} e^{-\frac{\epsilon^2}{2\sigma^2}}$$

E uma escolha possível para a lei de atualização dos parâmetros θ é:

$$\dot{\theta} = \Gamma \nabla J(\theta)$$

Com $\Gamma \in \mathcal{R}^{2n \times 2n}$, $\Gamma = \Gamma^T > 0$.

Assim, fazendo uso do conceito de correntropia somos levados ao estimador:

$$\dot{\theta} = \Gamma \epsilon \phi \frac{1}{\sqrt{2\pi}\sigma^3} e^{-\frac{\epsilon^2}{2\sigma^2}}$$

E podemos estimar os parâmetros da planta em tempo real fazendo uso do conceito de correntropia.

Seja um controlador usando o princípio do modelo interno, tal que $Q_m(s)$ cancele os termos instáveis dos sinais de referência e perturbação:

$$C(s) = \frac{P(s)}{L(s)Q_m(s)}$$

E lembrando que:

$$G_p(s) = \frac{N_p(s)}{D_p(s)}$$

Descrições, Cont.

Em realimentação unitária, o polinômio no denominador da função de transferência em malha fechada é:

$$L(s)Q_m(s)D_p(s) + N_p(s)P(s) = A^*(s)$$

Ou seja, resolvendo para $L(s)$ e $P(s)$ podemos obter um polinômio desejado $A^*(s)$ em malha fechada, desde que conheçamos $D_p(s)$ e $N_p(s)$.

No controle adaptativo substituímos os parâmetros da planta contidos em $D_p(s)$ e $N_p(s)$ desconhecidos por suas estimativas.

Equações, Cont.

De tal forma que a seguinte lei de controle é gerada:

$$u_p = (\Lambda - \hat{L}Q_m)\frac{1}{\Lambda}u_p - \hat{P}\frac{1}{\Lambda}(y_p - r)$$

Onde r é uma referência qualquer escolhida.




Figura: Comportamento do controlador Adaptativo por Posicionamento de Polos (APPC) em um ambiente sem ruído com estimador por Maximização da Correntropia do Erro




Figura: Comportamento do controlador Adaptativo por Posicionamento de Polos (APPC) em um ambiente sem ruído com estimador por Minimização do Erro Quadrado com Fator de Esquecimento




Figura: APPC-MCC em ambiente com ruído gaussiano




Figura: APPC-LSE em ambiente com ruído gaussiano




Figura: APPC-MCC em ambiente com ruído uniforme




Figura: APPC-LSE em ambiente com ruído uniforme




Figura: APPC-MCC em ambiente com ruído impulsivo, falha do controlador, instabilidade




Figura: APPC-LSE em ambiente com ruído impulsivo

Conclusão

A Maximização da Correntropia do erro como critério de estimação de parâmetros discutida para este artigo apresenta:

- 1 Desempenho comparável ao LSE quando aplicada ao controle
- 2 Capacidade de rejeição do ruído impulsivo
- 3 Compatibilidade com estratégias de Controle Indireto

Em trabalhos futuros trataremos de uma fundamentação matemática mais robusta e condições suficientes de convergência das estimativas para o algoritmo proposto.
Muito obrigado!

 BOTTOU, L. *Large-Scale Machine Learning with Stochastic Gradient Descent*. Heidelberg: Physica-Verlag HD, 2010. 177–186 p. ISBN 978-3-7908-2604-3.

 CHEN, B. et al. *System Parameter Identification: Information Criteria and Algorithms*. 1st. ed. Amsterdam, The Netherlands, The Netherlands: Elsevier Science Publishers B. V., 2013. ISBN 012404574X, 9780124045743.

 CHEN, C.-T. *Linear System Theory and Design*. [S.l.]: Oxford University Press, 1999.

 IOANNOU, P. A.; SUN, J. *Robust Adaptive Control*. [S.l.]: Pearson Education, Inc., 1996.

 KRSTIC, I. K. M.; KOKOTOVIC, P. *Nonlinear and Adaptive Control Design*. [S.l.]: Wiley, 1995.

 LIU, W.; POKHAREL, P. P.; PRINCIPE, J. C. Correntropy: Properties and applications in non-gaussian signal processing. *IEEE Transactions on Signal Processing*, v. 55, n. 11, p. 5286–5298, Nov 2007. ISSN 1053-587X.

 OGATA, K. *Modern Control Engineering*. [S.l.]: Pearson Education, Inc., 2010.

 PRINCIPE, J. C. *Information Theoretic Learning: Renyi's Entropy and Kernel Perspectives*. 1st. ed. [S.l.]: Springer Publishing Company, Incorporated, 2010. ISBN 1441915699, 9781441915696.

 TAO, G. *Adaptive Control Design and Analysis*. [S.l.]: Wiley, 2003.