

Lista de Exercícios 3 - 2018.1

Docente: Prof. Dr. Adrião.

Disciplina: Redes Neurais Artificiais.

Discentes: Isaac Dantas Isidório & Pedro Gushiken.

21 de junho de 2018

Sumário

1	Lista 3 - Redes Neurais Artificiais	1
1.1	Questão 01	1
1.1.1	a. Simulação com predição de um passo	2
1.1.2	b. Simulação com predição de dois passos	2
1.1.3	c. Simulação com predição de três passos	2
1.2	Questão 2	3
1.2.1	Rede neural competitiva	3
1.2.2	Rede SOM	3
1.3	Questão 3	8
1.3.1	Método de compressão de imagens em rede SOM	8
1.3.2	Rede Neural-Gas Aplicada à Reconstrução de Superfícies	9
1.4	Questão 4	17
1.4.1	Rede Neural Competitiva	17
1.4.2	Rede SOM	20
1.5	Questão 5	24
1.6	Questão 06	30
1.6.1	Algoritmo K-Means:	30
1.6.2	a.	32
1.6.3	b.	33
1.7	Questão 7	34
1.8	Questão 8	36
1.9	Questão 9	37
1.10	Questão 10	37
1.10.1	Big Data aplicado ao setor comercial	37
1.10.2	Ministério da Justiça - Brasil	38
1.10.3	Maplink	38
1.10.4	UPS	38
1.10.5	NOAA	39
1.10.6	Nike	39
1.10.7	Danone	39
1.10.8	J.P. Morgan	39
1.10.9	Rolls Royce	40
1.10.10	American Express	40
1.10.11	Under Armor	40
1.10.12	Pinterest	41
1.11	Minority Report da vida real: China utiliza Big Data para prever crimes	41

1.11.1	Prevenindo crimes com uma plataforma de Big Data	41
1.11.2	Como funciona	41
1.12	Big Data Analytics faz gol também no futebol	42
1.12.1	De frente para o gol	42
1.12.2	De olho no torcedor	42
1.12.3	É correr para o abraço	43

Lista de Figuras

1.1	Rede NARX.	1
1.2	Erro de predição (<i>delay</i> =1).	2
1.3	Erro de predição (<i>delay</i> =2).	2
1.4	Erro de predição (<i>delay</i> =3).	2
1.5	Respostas dos neurônios para a rede competitiva, Q02.	3
1.6	Matriz U, rede SOM, Q02	4
1.7	Vogal a, rede SOM, Q02	5
1.8	Vogal e, rede SOM, Q02	5
1.9	Vogal i, rede SOM, Q02	6
1.10	Vogal o, rede SOM, Q02	7
1.11	Vogal u, rede SOM, Q02	8
1.12	Reconstrução da imagem Lena utilizando um algoritmo de compressão baseado em rede SOM, para 2 taxas de compressão distintas, e comparada ao algoritmo de compressão JPEG	10
1.13	Relação PSNR para os dois algoritmos de compressão comparados no artigo	11
1.14	Adaptação de neurônios w a uma amostra de dados x tirada da nuvem de pontos.	12
1.15	Uma reconstrução grosseira do coelho de Stanford antes (à esquerda) e depois (à direita) fechando os furos na superfície.	15
1.16	Reconstrução do modelo do urso polar usando: (a) Neural Gas e (b) Growing Neural Gas.	16
1.17	Comparação de diferentes níveis de ruído, da esquerda para a direita 2%, 4%, 6%, 8% e 10% (modelo do oito, do inglês <i>eigth model</i>).	17
1.18	Respostas dos neurônios para a rede competitiva, Dados de treinamento pertencentes à espiral 1, Q04.	18
1.19	Respostas dos neurônios para a rede competitiva, Dados de treinamento pertencentes à espiral 2, Q04.	18
1.20	Respostas dos neurônios para a rede competitiva, Dados de validação pertencentes à espiral 1, Q04.	19
1.21	Respostas dos neurônios para a rede competitiva, Dados de validação pertencentes à espiral 2, Q04.	19
1.22	Respostas dos neurônios para a rede SOM, Dados de treinamento pertencentes à espiral 1, Q04.	20
1.23	Respostas dos neurônios para a rede SOM, Dados de treinamento pertencentes à espiral 2, Q04.	21

1.24	Respostas dos neurônios para a rede SOM, Dados de validação pertencentes à espiral 1, Q04.	21
1.25	Respostas dos neurônios para a rede SOM, Dados de validação pertencentes à espiral 2, Q04.	22
1.26	Posição dos pesos para a rede SOM, Q04.	22
1.27	Matriz U rede SOM, Q04.	23
1.28	Planos de entrada para a rede SOM, Q04.	23
1.29	Respostas dos neurônios para a rede SOM, Dados de treinamento pertencentes à classe 1, Q05.	24
1.30	Respostas dos neurônios para a rede SOM, Dados de treinamento pertencentes à classe 2, Q05.	25
1.31	Respostas dos neurônios para a rede SOM, Dados de validação pertencentes à classe 3, Q05.	25
1.32	Respostas dos neurônios para a rede SOM, Dados de validação pertencentes à classe 4, Q05.	26
1.33	Matriz U rede SOM, Q05.	27
1.34	Matriz U rede SOM, recorte, Q05.	28
1.35	Planos de entrada para a rede SOM, Q05.	29
1.36	Configuração inicial (letra a).	32
1.37	Configuração final (letra a).	32
1.38	Configuração inicial (letra b).	33
1.39	Configuração final (letra b).	33
1.40	Matriz U rede SOM, Q07.	34
1.41	Matriz U rede SOM, recorte, Q07.	35
1.42	Planos de entrada para a rede SOM, Q07.	35
1.43	Respostas dos neurônios, Q08.	36

Capítulo 1

Lista 3 - Redes Neurais Artificiais

1.1 Questão 01

A rede utilizada possui um neurônio na camada de entrada, uma camada oculta com dois neurônios e um neurônio na camada de saída.

Inicialmente, a rede realiza o processo de treinamento (70% das amostras), teste (15% amostras) e validação (15% amostras) sem a realimentação de saída.

Posteriormente, a saída realimenta à rede e a predição é realizada. Segue abaixo, na Figura 1.1, a estrutura final da rede NARX.




Figura 1.1: Rede NARX.

Para a predição da série temporal dada, foi utilizada a *toolbox* de redes neurais do *Matlab*.

Os gráficos referentes a cada predição, para um passo, dois passos e três passos, podem ser visualizados, respectivamente, nas Figuras 1.2, 1.3 e 1.4.

É observado que o erro médio de predição aumenta com o aumento do horizonte de predição. Assim, a rede NARX erra menos quando se deseja prever um valor futuro a um passo à frente, em comparação com a predição de um valor futuro a dois passos à frente e assim por diante.

1.1.1 a. Simulação com predição de um passo




Figura 1.2: Erro de predição ($delay=1$).

1.1.2 b. Simulação com predição de dois passos




Figura 1.3: Erro de predição ($delay=2$).

1.1.3 c. Simulação com predição de três passos




Figura 1.4: Erro de predição ($delay=3$).

1.2 Questão 2

1.2.1 Rede neural competitiva

Fizemos uso da database do MNIST, retirada da internet. Cada imagem consiste de 28x28 pixels, havendo 4800 imagens de treinamento para cada vogal, que transformamos em vetores de entrada de 784x1 com valores de amplitude limitados ao intervalo entre 0 e 1. Treinamos uma rede competitiva com 10 neurônios na camada de saída para fazer o reconhecimento dos clusters através de treinamento não supervisionado. Como a database disponibiliza os rótulos, para testar o desempenho da rede separamos as entradas para cada vogal e alimentamos a rede, de forma a observar seu comportamento. Obtivemos os resultados da Figura 1.5, para 500 épocas de treinamento, onde os gráficos representa o número de neurônios que foi ativado, e cada gráfico corresponde a uma vogal.




Figura 1.5: Respostas dos neurônios para a rede competitiva, Q02.

Vemos que a rede competitiva é capaz de distinguir que há classes distintas, porém, devido aos fatores de variância dos dados (especialmente a vogal "a"), e de que cada grupo de dados rotulados representa 2 casos distintos (a vogal maiúscula ou minúscula), as classes não possuem uma separação clara. Vemos, no entanto, que o neurônio 9 só é ativado quando uma vogal "i" é colocada na entrada da rede, a probabilidade de que a vogal seja "o" para uma ativação do neurônio 3 é alta, e o mesmo pode ser dito para a vogal "a" e o neurônio 5. De modo geral a rede competitiva nos permitiu observar que a variância dos dados é maior para vogais "a" e "e", e menor para as demais vogais. Este resultado é esperado, pois a grafia cursiva das vogais "i", "o" e "u" é mais propensa a ser similar entre duas pessoas distintas, já que suas formas (e portanto features a serem reconhecidas) são mais simples.

1.2.2 Rede SOM

Fizemos experimentos com várias configurações de dimensão para a rede SOM, desde um número pequenos de neurônios (5x5), até um número grande (40x40). Observamos que o projetista da rede deve encontrar um meio termo entre a granularidade

obtida na representação dos dados, o número de neurônios que acaba "morto", isto é, nunca é ativado, e finalmente considerar o tempo de treinamento da rede. Por fim, optamos por uma topologia de rede SOM 7x7 hexagonal, que treinamos por 20000 iterações, usando as opções padrão de algoritmos de treinamento do toolbox de redes neurais do MATLAB. Da mesma forma como foi feito com a rede competitiva, aproveitamos a disponibilidade das labels na database para alimentar a entrada da rede com cada grupo de vogais, para enxergar a organização dos dados. Obtivemos os resultados das Figuras 1.6, 1.7, 1.8, 1.9, 1.10 e 1.11.




Figura 1.6: Matriz U, rede SOM, Q02

Ao preservar a topologia, a rede SOM exhibe uma separação mais clara entre os dados. Podemos observar algumas características marcantes nos mapas de neurônios ativados para cada uma das vogais. Para as vogais "a" e "e" é interessante notar que há uma variância maior dos dados, em comparação com as outras vogais, e, de fato, a probabilidade de uma vogal destes tipos ser classificada erroneamente num cluster pertencente à outra vogal é maior. Quanto às vogais "i" e "o", seus clusters de neurônios representantes são concentrados em regiões bem delineadas, com poucas amostras sendo colocadas em regiões pertencentes à outras vogais. Finalmente, a letra "u" tem um neurônio que concentra impressionantes 2400 amostras, indicando que uma das grafias da letra "u" é realmente distinta, no sentido de que é de baixa variância, ou seja, foi escrita de um jeito aproximadamente igual em todas as amostras, no entanto, a outra grafia da letra "u" sofre de uma variância maior, necessitando de mais neurônios para representar aquela região da topologia dos dados. Vemos aqui a efetividade da rede SOM na visualização quando comparada com a rede competitiva, pois fomos capazes




Figura 1.7: Vogal a, rede SOM, Q02




Figura 1.8: Vogal e, rede SOM, Q02




Figura 1.9: Vogal i, rede SOM, Q02

de observar as características dos dados de forma mais detalhada.




Figura 1.10: Vogal o, rede SOM, Q02




Figura 1.11: Vogal u, rede SOM, Q02

1.3 Questão 3

1.3.1 Método de compressão de imagens em rede SOM

Encontramos o artigo da referência [5], escolhendo fazer um breve resumo dos resultados encontrados naquele trabalho. Fazemos a observação de que o trabalho citado possui uma patente associada, de número 7469065, que pode ser acessada no site do escritório de patentes dos EUA.

Resumo do artigo

No contexto do processamento de imagens, esquemas de compressão são utilizados para reduzir a taxa de transmissão para imagens paradas ou fixas, procurando manter a qualidade visual. Um dos métodos comuns de atingir este objetivo é através da quantização vetorial, onde cada vetor no espaço de entrada é aproximado para um dos vetores de um dicionário, de acordo com alguma métrica escolhida, normalmente de proximidade. O algoritmo do mapa auto organizável de Kohonen pode ser utilizado para este fim, isto é, como um dicionário, tendo a importante propriedade de preservação da topologia dos dados. De fato, uma rede SOM bidimensional pode ser utilizada de forma que os pesos de seus neurônios individuais formem "palavras", que servem para reconstruir a "mensagem" original, isto é, a imagem.

São propostos os seguintes passos para realizar a tarefa de compressão:

- 1 Pré-processamento da imagem em blocos, buscando obter componentes de cada bloco no domínio da frequência, agrupando-os por similaridade e buscando atenuar os componentes de alta frequência, sob a suposição de que componentes de alta frequência não contribuem para a qualidade visual da imagem.
- 2 Treinamento de uma rede SOM, as entradas da rede são os blocos de componentes frequenciais da imagem produzidos no passo 1. Os pesos neuronais obtidos formam um "livro código", que é utilizado para quantização vetorial.
- 3 Supondo que a imagem possui propriedades espaciais típicas, podemos supor que na maioria dos casos, a maior parte das regiões de uma imagem é suave, e portanto uma codificação diferencial levará a códigos pequenos, em um certo sentido. Sendo isto verdade, um codificador entrópico com tamanho de palavra variável pode ser utilizado. Assim as palavras produzidas por este codificador serão menores, quanto menor for a diferença entre as regiões adjacentes avaliadas.

Resultados obtidos

O artigo citado utilizou "Lena" como imagem de teste, que é uma imagem bastante utilizada em testes de desempenho de algoritmos de compressão e reconstrução de imagens, para avaliar os resultados, as métricas utilizadas foram a relação sinal ruído de pico (um valor maior em dB indica maior ruído de pico), e a taxa de compressão atingida. Retiramos os resultados, que podemos visualizar nas Figuras 1.12 e 1.13.

1.3.2 Rede Neural-Gas Aplicada à Reconstrução de Superfícies

Introdução

A tarefa de reconstruir uma superfície a partir de uma nuvem de pontos não estruturada de amostras de dados ainda é um assunto de pesquisas recentes no campo da computação gráfica. Embora excelentes resultados possam ser alcançados com algoritmos existentes, em certos casos alguns desafios permanecem.

A disponibilidade de digitalizações de alta resolução resulta em conjuntos de dados muito grandes com milhões de pontos amostrados. Muitos algoritmos não conseguem lidar com essa quantidade de dados de entrada e eles dependem muito de pré-processamento e refinamento das amostras. Outros métodos usam um pós-processamento dispendioso como simplificação para gerar uma malha triangular viável.

A capacidade de lidar com dados de entrada ruidosos é outro tópico de grande importância, uma vez que dados gerados (por exemplo, a partir de uma varredura a laser) estão sujeitos a ruído e, com maior resolução, mesmo pequenos distúrbios tornam-se evidentes na superfície do objeto. Este assunto é frequentemente tratado da mesma forma, pela aplicação de algoritmos de pré ou pós-processamento para suavizar a superfície.

Objetos de gênero superior (ou seja, *handles*) são um obstáculo adicional para muitos métodos existentes. Frequentemente isso é contornado por recursos especiais de controle para anexar ou mesclar algumas partes da reconstrução a fim de obter um resultado de gênero maior que zero, mas os algoritmos geralmente dependem de heurísticas e a convergência para a topologia correta não é comprovada.




Fig. 9. (a) Lena image compressed by the proposed method, compression rate = 25.22, PSNR= 24.7dB. (b) Lena image compressed by the JPEG algorithm, compression rate = 25.04, PSNR = 25.3dB. (c) Lena image compressed by the proposed method, compression rate = 38, PSNR = 24dB. (d) Lena image compressed by the JPEG algorithm, compression rate = 38.55, PSNR = 22.46dB.

Figura 1.12: Reconstrução da imagem Lena utilizando um algoritmo de compressão baseado em rede SOM, para 2 taxas de compressão distintas, e comparada ao algoritmo de compressão JPEG




Fig. 8. Comparison of PSNR for the proposed lossy compression scheme and the JPEG algorithm.

Figura 1.13: Relação PSNR para os dois algoritmos de compressão comparados no artigo

Aqui, utiliza-se o algoritmo Neural-Gas (NG) para o problema de reconstrução de superfícies. Essa abordagem está alinhada com a abordagem neural introduzida por Ivriissimtzis et al. que é baseado em **estruturas celulares** em crescimento e dá resultados notáveis na reconstrução da superfície. Devido ao erro de tolerância inerente e a adaptação on-line de sistemas neurais, seu método também pode lidar com conjuntos de dados grandes e ruidosos, mas não possui quaisquer garantias matemáticas que converge. Em vez disso, o algoritmo NG que usamos adapta seu gráfico de vizinhança automaticamente à topologia da dada variedade de dados, de tal forma que garantias teóricas muito fortes são válidas.

Adapta-se o NG à reconstrução de superfícies 3D usando a nuvem de pontos como entrada de treinamento. Esta abordagem faz com que o algoritmo seja independente do tamanho dos dados de entrada e capaz de lidar com conjuntos de dados muito grandes e ruidosos, que são implicitamente reduzidos e suavizados pelo algoritmo. A principal força deste método é a capacidade inerente de reconstruir objetos de gênero superior sem a necessidade de executar operações especiais para criar *handles*. A capacidade do algoritmo NG para formar uma quantização vetorial do espaço de dados e para construir uma triangulação completa de Delaunay pode ser comprovado matematicamente.

O algoritmo Neural-Gas adaptado pode ser resumido da seguinte forma:

1. Comece com um número inicial de neurônios (vértices), distribuídos aleatoriamente na caixa delimitadora da nuvem de pontos.
2. Escolha aleatoriamente uma amostra de dados do conjunto de dados de entrada.

3. Mova os neurônios em direção à amostra selecionada, conforme mostrado na Figura 1.
4. Estabeleça uma conexão (borda) entre o neurônio mais próximo e o neurônio mais próximo.
5. Remova as conexões que não foram atualizadas por algum tempo.
6. Repita os passos 2 a 5 até que a condição de terminação seja cumprida.
7. Gerar faces das bordas do gráfico de vizinhança construído.




Figura 1.14: Adaptação de neurônios w a uma amostra de dados x tirada da nuvem de pontos.

Algoritmos

O NG baseia-se no princípio básico relacionado com a capacidade das redes neurais de se adaptar a diferentes ambientes. Uma rede neural é composta de neurônios que são ajustados a dados de entrada por meio de algoritmos de aprendizado. Os métodos baseados em protótipos constituem uma família popular de redes neurais para aprendizado não supervisionado, como dado na configuração proposta. Os neurônios representam posições prototípicas do espaço de dados e são treinados de acordo com os dados fornecidos usando o aprendizado de Hebb, ou seja, os neurônios são movidos para os pontos de dados.

Os algoritmos neurais são métodos aproximados, isto é, calculam inerentemente uma média estatística sobre o ruído contido no espaço de dados. Assim, os neurônios estão localizados em posições típicas que representam o coletor de dados e são colocados entre as amostras de entrada. Essa abordagem tem várias consequências: primeiro, o algoritmo executa uma redução implícita de dados a partir dos dados de entrada. O número de vértices gerados, consequentemente a precisão do modelo resultante, pode ser controlado explicitamente pelos parâmetros do algoritmo. Em segundo lugar, essa abordagem possui habilidades de suavização inerentes, o que leva a uma robustez muito alta da forma gerada em relação aos dados de entrada com ruído. Terceiro, o tempo de execução do algoritmo depende da complexidade da variedade e da qualidade da aproximação, em vez do número de dados de treinamento: em outras palavras,

o tempo de cálculo depende apenas do número de neurônios, que por sua vez corresponde ao número de vértices na malha triangular reconstruída, mas não do número de pontos na dada nuvem de pontos. Portanto, essa abordagem é bem adequada para gerar uma aproximação muito rápida dos dados da amostra, o que pode ser aprimorado usando conjuntos de parâmetros diferentes ou métodos de pós-processamento para refinamentos finais.

Neural Gas (NG)

O algoritmo do NG é um método de quantização vetorial matematicamente bem fundamentado e muito robusto. Primeiramente proposto por Martinetz e Schulten, este modelo é um quantizador ideal para aproximar e reduzir grandes conjuntos de dados com um número fixo de neurônios.

Gerando Vértices: O NG pode ser derivado como um método de gradiente descendente estocástico de uma função de custo que aumenta o erro de quantização padrão pela cooperação de vizinhança. Em geral, assumimos que os dados se originam de um espaço vetorial $\mathcal{R}^d$ (com $d = 3$ para reconstrução de superfícies) e que um número N de neurônios $\mathbf{w}_i \in \mathcal{R}^d$ deve ser adaptado de acordo com os dados fornecidos. Uma rede NG representa os dados por meio de uma função *winner-takes-all* (em português, "o vencedor leva tudo"): Um dado de entrada $\mathbf{x}_i \in \mathcal{R}^d$ é mapeado para o neurônio que está mais próximo, de acordo com a norma Euclidiana. Assumindo um coletor de dados contínuo de acordo com a distribuição P , o NG otimiza a função custo:

$$E \sim \sum_i \int e^{\frac{-rk(\mathbf{w}_i, \mathbf{x})}{\sigma^2}} \cdot \|\mathbf{w}_i - \mathbf{x}\|^2 P(\mathbf{x}) d\mathbf{x} \quad (1.1)$$

onde

$$rk(\mathbf{w}_i, \mathbf{x}) = \# \{ \mathbf{w}_j : \|\mathbf{w}_j - \mathbf{x}\|^2 \leq \|\mathbf{w}_i - \mathbf{x}\|^2 \} \quad (1.2)$$

denota o posto de neurônio $\mathbf{w}_i$ medido de acordo com a distância de $\mathbf{x}$ e $\sigma > 0$ controla o grau de cooperação na vizinhança. Obviamente, para $\sigma \rightarrow 0$ isto resulta na quantização padrão, isto é, os 3 neurônios estão dispostos dentro da nuvem de dados de tal maneira que a distância média dos pontos de dados do seu neurônio mais próximo é minimizada. Para $\sigma > 0$, a vizinhança também é levada em conta, dando assim um método de quantização muito robusto e suave.

O NG é derivado da função custo por meio do gradiente descendente estocástica. Isso significa que os neurônios são inicializados aleatoriamente. Um vetor aleatório $\mathbf{x}$ é desenhado de acordo com P e todos os neurônios são movidos para $\mathbf{x}$ de acordo com a classificação do seu posto

$$\mathbf{w}_i \rightarrow \mathbf{w}_i + \eta \cdot e^{\frac{-rk(\mathbf{w}_i, \mathbf{x})}{\sigma^2}} \cdot \|\mathbf{w}_i - \mathbf{x}\|^2 P(\mathbf{x} - \mathbf{w}_i). \quad (1.3)$$

Construindo Fronteiras: Ao contrário do SOM ou do crescimento de estruturas celulares, o NG usa uma estrutura de vizinhança que é determinada de acordo com o dado múltiplo. Este fato pode ser usado para construir uma topologia ótima dos neurônios durante o treinamento. Suponha que dois neurônios sejam vizinhos, se e somente se, eles possuírem campos receptivos próximos na variedade de dados. Esta definição induz uma triangulação de Delaunay válida do coletor de dados. Martinetz

também propõe uma regra de aprendizagem competitiva de Hebb para aprender essa topologia: Inicialmente, a força da conexão C_{ij} entre todos os neurônios w_i e w_j são definidas como 0. Cada etapa de treinamento seleciona iterativamente os pontos de dados x dos dados de entrada e encontra os dois neurônios w_i e w_j que estão mais próximos de x . Então, se $C_{ij} = 0$, a força de conexão C_{ij} é ajustada para 1, ou seja, esses dois neurônios são conectados.

A abordagem cognitiva competitiva fornece uma triangulação de Delaunay válida do colector de dados, se os dados de treinamento são densos no colector, isto é, para cada ponto x no colector, o triângulo abarcado por x e o seu primeiro e segundo vencedores encontram-se completamente no colector de dados. Obviamente, essa propriedade depende da taxa de amostragem do distribuidor de dados. Como esperado, podem ocorrer problemas para regiões com alta curvatura, amostragem esparsa e neurônios esparsos dentro dessas regiões.

A aprendizagem cognitiva competitiva (ou hebbiana) da conectividade após o treinamento pode ser substituída por uma aprendizagem on-line cognitiva competitiva durante o treinamento: Inicialmente, todas as forças de conexão C_{ij} dos neurônios w_i e w_j são definidas como 0. Em cada etapa de treinamento, esse valor vai para 1, se e somente se, w_i e w_j são os dois neurônios mais próximos em relação ao ponto de dados considerado x . Além disso, cada valor C_{ij} é diminuído por um fator pequeno em cada passo para permitir o esquecimento de conexões falsas iniciais.

Detectando Faces: Após o treinamento, o NG fornece um conjunto de vértices e conexões que constituem uma triangulação de Delaunay do distribuidor de dados, mas nenhuma estrutura de superfície explícita é fornecida. Para construir uma triangulação final da superfície do objeto, propomos um algoritmo de pós-processamento: Começando com qualquer aresta determinada, todos os pares de arestas adjacentes são inspecionados em uma maneira de busca em amplitude até que um vizinho comum seja encontrado. Obviamente, para uma superfície fechada, essas três bordas formam um triângulo, e as arestas de contorno são adicionadas a um conjunto de arestas de contorno. A próxima borda inicial é selecionada deste conjunto até que uma superfície fechada tenha sido construída.

Em aplicações práticas, a triangulação NG pode ter defeitos devido ao fato de que a regra competitiva de Hebb ainda não convergiu ou os dados não são densos. Assim, a malha é geralmente composta de uma multiplicidade de triângulos e alguns polígonos maiores. Esses polígonos resultam de regiões amostradas de forma esparsa no conjunto de dados ou de uma extremidade pré-convergente do algoritmo. É possível detectar e reconstruir buracos no objeto de forma correta e triangular esses polígonos para obter uma superfície fechada, como mostrado na Figura 1.15. Isso é feito expandindo a profundidade da árvore de busca de detecção de triângulos unicamente para polígonos de ordem superior até um dado máximo.




Figura 1.15: Uma reconstrução grosseira do coelho de **Stanford** antes (à esquerda) e depois (à direita) fechando os furos na superfície.

Outras Melhorias: Uma grande desvantagem da abordagem NG é a limitação de uma quantidade inicial de neurônios. Um pequeno número de neurônios leva a uma reconstrução muito rápida, mas grosseira da superfície, sem detalhes significativos, enquanto um grande número de neurônios dificulta uma convergência rápida e pode resultar em vértices desconectados na parte interior do objeto. Isso pode ser evitado por duas extensões simples.

Primeiro, em vez de adaptar todos os neurônios, apenas um número fixo de n unidades mais próximas é alterado em uma única etapa de treinamento. Isso aproxima o comportamento do algoritmo em etapas de treinamento posteriores quando o intervalo da vizinhança σ é pequeno. Valores de n entre 10 e 50 provaram ser uma boa escolha nos experimentos. Na prática, isso reduz o esforço de executar uma iteração de aprendizado que é dominada pela classificação de N neurônios ($O(N \log N)$) a uma complexidade de $O(n \log N)$ com n fixo sob a suposição de que uma estrutura espacial eficiente é usada. O comportamento do algoritmo só é afetado por esta simplificação no início, quando o raio de adaptação exponencialmente decrescente σ ainda é grande e pode levar a vértices desconectados.

Este efeito é compensado, no entanto, pela segunda melhoria introduzida para acelerar a fase inicial da exploração, mantendo uma grande quantidade de vértices na reconstrução final. O algoritmo começa com um pequeno número de neurônios que se adaptam à forma geral do modelo em poucas etapas de treinamento. Após um certo número de iterações, cada neurônio é duplicado. Assim, os vértices recém-criados são colocados na superfície, portanto, eles estão conectados. As iterações subsequentes separam os neurônios duplicados se a taxa de aprendizado η na equação 1.3 é escolhida apropriadamente. Observe que esse procedimento pode ser repetido até que a granularidade desejada da superfície seja atingida.

Growing Neural Gas (GNG)

Para comparação, também foi adaptado o algoritmo Growing Neural Gas (GNG). Este método introduz uma estratégia crescente para aumentar continuamente o número de neurônios durante o processo de adaptação, criando novas unidades nas regiões com o maior déficit. Para detectar essas regiões, um valor de erro é calculado para cada

neurônio, dependendo da distância média até a próxima amostra de dados. Novas unidades são criadas para dividir a borda que conecta esse neurônio ao maior valor de erro e aquele com o maior valor de erro em sua vizinhança. Além da estratégia crescente, o GNG difere do GN das seguintes formas: A configuração inicial do Growing Neural Gas é uma rede muito pequena de duas unidades conectadas. Em cada etapa de adaptação, a conectividade dos neurônios é considerada para adaptar somente as unidades que estão conectadas ao neurônio de melhor ajuste à amostra de dados. Além disso, os parâmetros de adaptação são mantidos constantes para permitir que o algoritmo processe o tempo que desejar sem convergência prematura. A adaptação de um neurônio é calculada da seguinte forma:

$$\mathbf{w}_i \leftarrow \mathbf{w}_i + \eta \cdot (\mathbf{x} - \mathbf{w}_i). \quad (1.4)$$

Outras Melhorias: No algoritmo GNG original, o número de etapas de adaptação entre a criação de novos neurônios é mantido constante. Com essa abordagem, é provável que, em iterações posteriores, um neurônio recém-criado não seja escolhido como a unidade mais próxima de uma amostra de dados até que o próximo neurônio seja criado. Isso leva a um número crescente de vértices com apenas dois vizinhos e, portanto, contradiz a criação de uma malha triangular. Portanto, usamos um número de amostras de dados dependendo da quantidade real de neurônios antes que uma nova unidade seja criada.

Experimentos e Conclusão: Aqui, são apresentados dois algoritmos neurais para a reconstrução da superfície 3D. Como foi mostrado, ambos trabalham independentemente do tamanho da nuvem de pontos e possuem alta robustez em relação aos dados de entrada com ruído. Além disso, as habilidades inerentes de reconstruir formas de gêneros superiores foram demonstradas.

Os métodos propostos são adequados para uma geração muito rápida da forma aproximada e da topologia do modelo. Usando um pequeno número de vértices, até mesmo grandes conjuntos de dados podem ser aproximados em poucos segundos.




Figura 1.16: Reconstrução do modelo do urso polar usando: (a) Neural Gas e (b) Growing Neural Gas.




Figura 1.17: Comparação de diferentes níveis de ruído, da esquerda para a direita 2%, 4%, 6%, 8% e 10% (modelo do oito, do inglês *eigth model*).

1.4 Questão 4

Temos duas espirais distintas, onde as coordenadas dos pontos da espiral 1 são dadas por x_1 e y_1 , e as coordenadas da espiral 2 são dadas por x_2 e y_2 , como a seguir:

$$\begin{aligned} x_1 &= \frac{\theta}{4} \cos \theta \\ y_1 &= \frac{\theta}{4} \sin \theta \\ x_2 &= (0.8 + \frac{\theta}{4}) \cos \theta \\ y_2 &= (0.8 + \frac{\theta}{4}) \sin \theta \end{aligned} \tag{1.5}$$

Para cada uma destas espirais, geramos um grupo de 51 amostras, espaçadas de intervalos regulares do parâmetro θ , de 0 até 20 radianos. Os dados de validação foram gerados numa grade quadrada de -5 até 5 nos dois eixos, como na lista anterior a esta.

1.4.1 Rede Neural Competitiva

Para a rede neural competitiva, escolhemos uma topologia de rede de 10 neurônios na camada de saída. A expectativa que tivemos é de que, como os dados não pertencem a categorias linearmente separáveis, a rede não seja capaz de encontrar distinções relevantes entre os dois grupos de amostras. Como no caso da questão 2 (pois a mesma questão foi feita na lista 2 para treinamento supervisionado), temos os rótulos de cada classe a nossa disposição, e portanto podemos separar os dados de cada classe para testar como nossa rede responde. Obtivemos os resultados das Figuras 1.18, 1.19, 1.20 e 1.21.

Pelas visualizações obtidas, concluímos que não foi possível para a rede competitiva separar os dados de forma expressiva, como esperávamos. Isto é, cada um dos 10 neurônios da rede foi ativado um número expressivo de vezes para cada uma das duas




Figura 1.18: Respostas dos neurônios para a rede competitiva, Dados de treinamento pertencentes à espiral 1, Q04.




Figura 1.19: Respostas dos neurônios para a rede competitiva, Dados de treinamento pertencentes à espiral 2, Q04.




Figura 1.20: Respostas dos neurônios para a rede competitiva, Dados de validação pertencentes à espiral 1, Q04.




Figura 1.21: Respostas dos neurônios para a rede competitiva, Dados de validação pertencentes à espiral 2, Q04.




Figura 1.22: Respostas dos neurônios para a rede SOM, Dados de treinamento pertencentes à espiral 1, Q04.

classes de dados, indicando que a rede não obteve sucesso na separação, nem mesmo dos dados de treinamento.

1.4.2 Rede SOM

Treinamos a rede SOM por 500 épocas, para uma topologia hexagonal 10x10. A expectativa é de que, como a topologia dos dados é preservada, possamos observar algum padrão. Novamente, utilizamos os rótulos disponíveis para alimentar a entrada da rede, tanto com os dados de treinamento quanto com os de validação, para observar a resposta da rede. Obtivemos os resultados das Figuras 1.22, 1.23, 1.24, 1.25, 1.26, 1.27 e 1.28.

Para os dados de treinamento, fica evidente que há uma ordenação dos neurônios que preserva o formato das espirais. Isto é, de modo geral o algoritmo SOM tem como um de seus critérios buscar assinalar um número similar de ativações para cada neurônio, preservando a topologia dos dados, o que permite à rede SOM representar clusters com regiões de separação não lineares. E, de fato, para um dado pertencente a classe 1, apenas neurônios de um grupo distinto são ativados, e o mesmo é verdadeiro para um dado pertencente à classe 2. Já para os dados de validação, observamos que os dados mais próximos da origem tendem a ativar neurônios que correspondem às suas respectivas classes, e ainda podemos visualizar a estrutura da espiral nas respostas dos neurônios. No entanto, a medida que nos afastamos da origem, esta "classificação" se




Figura 1.23: Respostas dos neurônios para a rede SOM, Dados de treinamento pertencentes à espiral 2, Q04.




Figura 1.24: Respostas dos neurônios para a rede SOM, Dados de validação pertencentes à espiral 1, Q04.




Figura 1.25: Respostas dos neurônios para a rede SOM, Dados de validação pertencentes à espiral 2, Q04.




Figura 1.26: Posição dos pesos para a rede SOM, Q04.




Figura 1.27: Matriz U rede SOM, Q04.




Figura 1.28: Planos de entrada para a rede SOM, Q04.




Figura 1.29: Respostas dos neurônios para a rede SOM, Dados de treinamento pertencentes à classe 1, Q05.

torna cada vez mais imprecisa, em parte porque os dados de treinamento possuem uma granularidade maior quanto mais longe estivermos da origem, e em parte porque esta clusterização dos dados fica limitada pelo tamanho da rede em conjunto com o alcance de varredura que usamos na variável θ , em outras palavras, é provável que um dado de entrada muito distante da origem seja classificado sempre como sendo pertencente à espiral 1 por exemplo, independente de seu pertencimento ou não a esta classe. Isto também pode ser visualizado na posição dos pesos dos neurônios, que reproduz a topologia das espirais.

1.5 Questão 5

Geramos 4 nuvens de pontos, conforme especificado na questão. Escolhemos gerar 1000 pontos para cada nuvem, treinamos uma rede SOM 10x10 com topologia hexagonal, durante 1000 épocas. Novamente, a estratégia de visualização escolhida foi a de alimentar a rede com os dados de cada nuvem, além disso, geramos a matriz U e recortamos as divisões entre os dados, e geramos os planos de entrada para a rede. Obtivemos os resultados das Figuras 1.29, 1.30, 1.31, 1.32, 1.33, 1.34 e 1.35.

Podemos observar que, de fato, há agrupamentos distintos de neurônios que respondem à cada uma das classes, que nos gera uma visualização em 2 dimensões do espaço de dados de 8 dimensões, como mencionado na questão. Também é possível vi-




Figura 1.30: Respostas dos neurônios para a rede SOM, Dados de treinamento pertencentes à classe 2, Q05.




Figura 1.31: Respostas dos neurônios para a rede SOM, Dados de validação pertencentes à classe 3, Q05.




Figura 1.32: Respostas dos neurônios para a rede SOM, Dados de validação pertencentes à classe 4, Q05.




Figura 1.33: Matriz U rede SOM, Q05.




Figura 1.34: Matriz U rede SOM, recorte, Q05.




Figura 1.35: Planos de entrada para a rede SOM, Q05.

sualizar pela matriz U de distâncias entre os neurônios a divisão entre os grupos, como cores mais escuras correspondem a distâncias maiores, traçamos a divisão aproximada entre os neurônios das classes. Notamos que a visualização dos clusters através da matriz U é menos clara, pois o algoritmo implementado no toolbox do MATLAB utiliza uma regra de treinamento que favorece a ativação e atualização dos neurônios menos ativados através do aumento do bias destes neurônios, por uma questão de buscar tornar a maioria dos neurônios da rede úteis. No entanto, traçamos as divisões entre as classes observando os tons mais escuros de vermelho na matriz. Adicionalmente, os planos de entrada para cada uma das 8 componentes foi traçado, e nele podemos observar claramente o peso assinalado a cada uma das componentes. Em especial, destacamos os planos de entrada 1, 3 e 8, onde as regiões mais claras correspondem a pesos maiores.

1.6 Questão 06

1.6.1 Algoritmo K-Means:

```
%% Amostras:
x1 = [-7.82 -6.68 4.36 6.72 -8.64 -6.87 4.47 6.73 -7.71 -6.91 6.18...
6.72 -6.25 -6.94 8.09 6.81 -5.19 -6.38 4.08 6.27]';
x2 = [4.58 3.16 -2.19 0.88 3.06 0.57 -2.62 -2.01 2.34 -0.49 2.81...
-0.93 -0.26 -1.22 0.20 0.17 4.24 -1.74 1.30 0.93]';
x3 = [-3.97 2.71 2.09 2.80 3.50 -5.45 5.76 4.18 -6.33 -5.68 5.82...
-4.04 0.56 1.13 2.25 -4.15 4.04 1.43 5.33 -2.78]';

X = [x1 x2 x3];

%% Número de clusters do Algoritmo K-Means
K = 3;

%% Questão 6a
disp('Questão 6a')
centroids1 = [0 1 -1; 0 1 0; 0 1 2];

figure(1)
plot3(X(:,1),X(:,2),X(:,3),'o','MarkerSize',5);
grid on;
hold on;
plot3(centroids1(1,1),centroids1(1,2),centroids1(1,3),'r*','MarkerSize',7);
hold on;
plot3(centroids1(2,1),centroids1(2,2),centroids1(2,3),'k*','MarkerSize',7);
hold on;
plot3(centroids1(3,1),centroids1(3,2),centroids1(3,3),'g*','MarkerSize',7);
legend('Amostras','Centroide 1','Centroide 2','Centroide 3');
xlabel('x1');
ylabel('x2');
```

```

xlabel('x3');

[idxa, Ca, somada, dA] = kmeans(X, K, 'Start', centroids1, 'Display', 'iter');

for i=1:K
centroids1 = Ca;
end

figure(2)
plot3(X(:,1),X(:,2),X(:,3),'o','MarkerSize',5);
grid on;
hold on;
plot3(centroids1(1,1),centroids1(1,2),centroids1(1,3),'r*','MarkerSize',7);
hold on;
plot3(centroids1(2,1),centroids1(2,2),centroids1(2,3),'k*','MarkerSize',7);
hold on;
plot3(centroids1(3,1),centroids1(3,2),centroids1(3,3),'g*','MarkerSize',7);
legend('Amostras','Centroide 1','Centroide 2','Centroide 3');
xlabel('x1');
ylabel('x2');
zlabel('x3');

%% Questão 6b
disp('Questão 6b')
centroids = [-0.1 0 -0.1; 0 -0.1 -0.1; 0.1 0.1 0.1];

figure(3)
plot3(X(:,1),X(:,2),X(:,3),'o','MarkerSize',5);
grid on;
hold on;
hold on;
plot3(centroids(1,1),centroids(1,2),centroids(1,3),'r*','MarkerSize',7);
hold on;
plot3(centroids(2,1),centroids(2,2),centroids(2,3),'k*','MarkerSize',7);
hold on;
plot3(centroids(3,1),centroids(3,2),centroids(3,3),'g*','MarkerSize',7);
legend('Amostras','Centroide 1','Centroide 2','Centroide 3');
xlabel('x1');
ylabel('x2');
zlabel('x3');

[idxb, Cb, somadb, dB] = kmeans(X, K, 'Start', centroids, 'Display', 'iter');

for i=1:K
centroids = Cb;
end

```

```

figure(4)
plot3(X(:,1),X(:,2),X(:,3),'o','MarkerSize',5);
grid on;
hold on;
plot3(centroids(1,1),centroids(1,2),centroids(1,3),'r*','MarkerSize',7);
hold on;
plot3(centroids(2,1),centroids(2,2),centroids(2,3),'k*','MarkerSize',7);
hold on;
plot3(centroids(3,1),centroids(3,2),centroids(3,3),'g*','MarkerSize',7);
legend('Amostras','Centroide 1','Centroide 2','Centroide 3');
xlabel('x1');
ylabel('x2');
zlabel('x3');

```

1.6.2 a.




Figura 1.36: Configuração inicial (letra a).




Figura 1.37: Configuração final (letra a).

1.6.3 b.




Figura 1.38: Configuração inicial (letra b).




Figura 1.39: Configuração final (letra b).

Abaixo, seguem os resultados obtidos pela aplicação do algoritmo K-means, a partir dos centroides definidos nos itens **a** e **b**, respectivamente.

Item	Iterações	$\sum_{\text{dist}}$	Centroide 1	Centroide 2	Centroide 3
a	4	266.734	3	10	7
b	2	266.734	10	3	7

Tabela 1.1: Resultados do algoritmo K-means.

No item **a**, o algoritmo convergiu em 4 iterações, ao passo que no item **b**, o k-means converge mais rapidamente, em apenas 2 iterações.

No item **a**, o algoritmo associou 3 elementos ao centroide 1, 10 elementos ao centroide 2 e 7 elementos ao centroide 3.

No item **b**, o algoritmo associou 10 elementos ao centroide 1, 3 elementos ao centroide 2 e 7 elementos ao centroide 3.




Figura 1.40: Matriz U rede SOM, Q07.

A terceira coluna da tabela 1.1 representa a soma das distâncias dos elementos associados a cada cluster¹. Em ambos os itens, **a** e **b**, quando o algoritmo converge, o valor encontrado é 266.734.

As posições finais dos centroides 1 e 2 são permutadas, do item **a** para o item **b**. Como pode ser visualizado nas figuras acima, o centroide em vermelho vai para a posição do centroide em preto, se compararmos as Figuras 1.37 e 1.39. Isso releva a sensibilidade do algoritmo K-means em relação à inicialização de seus centroides.

1.7 Questão 7

Treinamos uma rede SOM com topologia 10x10, por 10000 épocas, obtendo os resultados das Figuras 1.40, 1.42 e 1.41.

Vemos que há uma separação distinta entre 5 clusters de países. Os clusters são:

- Reino Unido, Canadá, Austrália, Estados Unidos, Japão, Cingapura, França e Uruguai.
- Argentina, Brasil, Egito, China

¹Os elementos são associados a cada cluster, suas distâncias são computadas em relação ao seu respectivo cluster e as distâncias são somadas.




Figura 1.41: Matriz U rede SOM, recorte, Q07.




Figura 1.42: Planos de entrada para a rede SOM, Q07.




Figura 1.43: Respostas dos neurônios, Q08.

- Cuba
- Colômbia, Paraguai e Senegal
- Nigéria, Serra Leoa, Angola, Etiópia, Moçambique

Pelos planos de entrada, vemos que as características que foram fornecidas para o treinamento da rede são similares em sua correlação com a classificação, isto é, indicadores maiores tendem a ativar neurônios do cluster 1 (de países de primeiro mundo). Recortamos a matriz U com linhas para facilitar a visualização dos clusters.

1.8 Questão 8

Usamos o algoritmo k-means com 5 neurônios, durante 500 épocas de treinamento, obtendo o resultado de classificação da Figura 1.43.

Apenas 4 dos 5 neurônios que utilizamos respondem às entradas, sendo que, utilizando um processo de quantização vetorial para determinar o centróide mais próximo de cada uma das amostras, os clusters classificados são:

- Reino Unido, Canadá, Austrália, Estados Unidos, Japão, França, Cingapura, Argentina, Uruguai e Brasil.
- Cuba, Egito e China.
- Colômbia, Nigéria, Senegal, Serra leoa, Angola, Etiópia e Moçambique
- Paraguai
- Vazio

1.9 Questão 9

Média: 67.7792, 22.1083, 10.1958, 2.8333

Mediana: 67.45, 22.9, 10.15, 2.85

Máximos: 83.7, 32.8, 17.6, 4.4

Mínimos: 55.9, 10.5, 5.8, 0.9

Variância: 68.2226, 39.8878, 9.5961, 0.6858

Matriz de covariância:

$$\text{cov}X = \begin{bmatrix} 68,22 & -48,91 & -18,37 & 1,79 \\ -48,91 & 39,88 & 8,52 & -1,81 \\ -18,37 & 8,52 & 9,59 & -0,01 \\ 1,79 & -1,81 & -0,01 & 0,68 \end{bmatrix} \quad (1.6)$$

Matriz de autovetores:

$$V_x = \begin{bmatrix} 0,79 & -0,23 & 0,03 & 0,57 \\ -0,58 & -0,57 & -0,03 & 0,57 \\ -0,20 & 0,78 & 0,083 & 0,58 \\ 0,02 & 0,076 & -1,00 & 0,05 \end{bmatrix} \quad (1.7)$$

A equação das componentes principais é dada por:

$$\begin{aligned} Y_1 &= 0.79X_1 - 0.23X_2 + 0.03X_3 + 0.57X_4 \\ Y_2 &= -0.58X_1 - 0.57X_2 - 0.03X_3 + 0.57X_4 \\ Y_3 &= -0.20X_1 + 0.78X_2 + 0.083X_3 + 0.58X_4 \\ Y_4 &= 0.02X_1 + 0.076X_2 - 1.00X_3 + 0.05X_4 \end{aligned} \quad (1.8)$$

Autovalores da matriz de covariância 109, 8.76, 0.58 e 0.05. Percentagem de variância dos dados explicada pelos componentes principais: 92%, 7.4%, 0.5%, 0.1%.

e) Não conseguimos implementar o algoritmo GHA.

1.10 Questão 10

1.10.1 Big Data aplicado ao setor comercial

Até algumas décadas atrás, a simples contratação de uma empresa de pesquisas de mercado era suficiente para desvendar o **comportamento do consumidor**. Um estudo analítico profundo poderia dar sinais sobre o futuro da economia e o seu setor de atuação.

Mas esse universo empresarial estático ficou para trás. O dinamismo da troca de informações das mídias sociais, a formação de um novo consumidor, exigente, antenado e conectado 24 horas à web, além da “inundação” de novos entrantes em todos os segmentos, ampliando a concorrência e confundindo o seu target, fizeram com que a compreensão plena do mercado só pudesse ser alcançada por meio do

trabalho aprofundado com centenas de variáveis internas e externas, a serem coletadas e processadas por poderosos softwares.

Estamos falando de **Big Data**, que permite às empresas mapearem e compreenderem plenamente seus consumidores, otimizarem seus processos de negócios ou enxergarem antes da concorrência uma **eventual mudança de tendência**.

A importância do trabalho com Big Data é tão grande que companhias de todos os segmentos já o fazem (inclusive brasileiras), gerando grandes resultados em seus negócios. É o que você verá neste artigo, com **11 casos de sucesso com Big Data** de companhias e instituições que investiram na coleta e análise de grandes volumes de dados.

1.10.2 Ministério da Justiça - Brasil

O Ministério da Justiça possui um data warehouse (banco de dados) com mais de 1 bilhão de registros, além de um poderoso supercomputador da IBM, chamado Watson, capaz de coletar, agrupar e processar petabytes de dados em frações de segundos. O objetivo do Ministério com o uso de Big Data é identificar indícios de ações ilícitas, sobretudo ligadas à **lavagem de dinheiro**.

1.10.3 Maplink

A Maplink, empresa especializada na digitalização de mapas, passou a utilizar, nos últimos anos, um software de rastreamento por satélite, cruzando centenas de milhares de dados oriundos de mais de 400 mil automóveis em São Paulo – tudo em tempo real.

Esse trabalho de tecnologia avançada possibilitou à empresa fazer um diagnóstico preciso do trânsito da cidade, indicando todos os pontos de lentidão, as razões e possíveis alternativas.

Por exemplo, enquanto em um dado momento a Maplink revelava que a cidade tem mais de 400 km de ruas congestionadas, a Companhia de Engenharia de Tráfego (CET) apontava, erroneamente, menos da metade dessa quilometragem.

1.10.4 UPS

Empresa norte-americana de transporte e logística, a UPS tinha o desafio de otimizar o seu cronograma de rotas, tornando-as mais eficientes e menos dispendiosas possíveis. Era necessário então fazer um estudo matemático e milimétrico, cruzando todas as rotas de todos os seus veículos, e avaliando também velocidade, pressão, tempo gasto em cada entrega, RPM e por aí vai.

Evidentemente, a imensidão de variáveis tornava impossível à mente humana chegar a resultados sólidos. Entretanto, a instalação de sensores em todos os veículos da empresa permitiu que ela chegasse a uma solução para suas rotas. Após um extenso período de testes, resultados práticos foram alcançados: quase 5 milhões de litros de gasolina economizados anualmente, redução de manutenção e maior rapidez nas entregas dos produtos.

1.10.5 NOAA

A National Oceanic and Atmospheric Administration (NOAA), organização pertencente ao governo dos EUA, recolhe cerca de 30 petabytes de dados diariamente por meio de satélites, da instalação de sensores em vias e de outros recursos.

O resultado do investimento foi o aumento da eficiência e exatidão das previsões de mudanças atmosféricas, previsões de tempestades e tornados com muito mais antecedência e a possibilidade de vender todas as informações preditivas geradas para outras empresas, tanto do setor público quanto do privado (setor agrícola, por exemplo).

1.10.6 Nike

A maior fabricante de materiais esportivos do planeta fechou uma parceria com uma empresa especialista em tecnologia, no intuito de desenvolver um software que fosse usado por **praticantes de running**, informando a eles frequência de batimentos cardíacos, velocidade, quantidade de passos dados, distância percorrida e muitos outros dados.

O “pulo do gato”, neste caso, foi integrar esse app com as redes sociais, estimulando amigos e fãs de corrida a compartilharem suas informações, propiciando uma certa “competição” entre os atletas.

O estímulo a esse comportamento multiplicou exponencialmente a quantidade de dados gerados diariamente, os quais são usados pela Nike para compreender seu público, melhorar seus produtos ou desenvolver novos modelos de tênis e roupas esportivas.

1.10.7 Danone

A Danone norte-americana tinha a necessidade de melhorar sua cadeia logística na distribuição de um certo tipo de iogurte (o ‘Grego’, no caso). Como o produto perecia com rapidez, ele precisava ser produzido e entregue ao varejo em sincronia quase matemática.

Isso se tornou possível apenas com o cruzamento de informações de rotas, tempo de entrega e prazo de validade.

1.10.8 J.P. Morgan

O dinamismo extremo do mercado financeiro resulta na produção diária de milhões de dados, índices e indicadores, os quais devem ser combinados no intuito de formar direcionamentos mais sólidos do que poderá ocorrer no próximo minuto.

O banco norte-americano J.P. Morgan trabalha há anos com estudos de algoritmos complexos, conceitos de redes neurais e cruzamento de dados por meio de sistemas de **Big Data Analytics** para prever tendências e entender quando comprar ou vender ações.

1.10.9 Rolls Royce

Quando se fala em Rolls-Royce, muitas características da marca logo vêm à mente das pessoas: tradição, elegância, status. Contudo, é principalmente pela inovação tecnológica que a empresa automobilística inglesa, subsidiária da BMW, tem se destacado ultimamente.

A Rolls-Royce vem implementando soluções de Big Data para otimizar seus processos de manutenção. Os motores e sistemas de propulsão dos veículos da companhia têm centenas de sensores embutidos, que registram todos os detalhes de funcionamento das máquinas e enviam, aos engenheiros da marca (espalhados pelos centros de serviço da empresa ao redor do mundo), dados em tempo real sobre quaisquer mudanças de desempenho delas.

A equipe de engenheiros cruza e analisa estes dados, possibilitando tomadas de decisão rápidas e assertivas para evitar e/ou resolver qualquer problema de funcionamento dos carros.

Segundo a Rolls-Royce, a adoção de tecnologias de Big Data para diagnosticar falhas, corrigi-las e evitá-las de ocorrerem novamente diminuiu significativamente os custos de manutenção de seus veículos.

1.10.10 American Express

A American Express, empresa norte-americana de serviços financeiros, passou a investir em Big Data ao perceber que os insights gerados pelas **ferramentas tradicionais de BI** não estavam sendo suficientes para diminuir as taxas de cancelamento de seus clientes.

A companhia desenvolveu sofisticados modelos preditivos para analisar históricos de transações dos usuários de seus cartões de crédito, além de 115 variáveis, para prever potenciais churns (evasão de clientes). Após a implementação de uma solução de Big Data em seus processos, a American Express acredita ser capaz, por exemplo, de identificar 24 % de seus clientes australianos que pretendem encerrar suas contas dentro dos próximos quatro meses.

1.10.11 Under Armor

Já falamos em um tópico anterior sobre como a Nike tem utilizado Big Data em seus negócios. E justamente uma de suas rivais de mercado, a Under Armour, também tem implementado a análise e coleta de dados em suas estratégias para desbancar a eterna líder do fornecimento de materiais esportivos.

A marca investiu, recentemente, 710 milhões de dólares na compra de três criadoras de aplicativos de ginástica, a fim de ter acesso aos dados dos mais de 120 milhões de usuários combinados destes apps.

De posse destes gigantescos volumes de informação, e em parceria com uma empresa de wearables (tecnologias vestíveis), a Under Armour planeja fornecer, a atletas e praticantes regulares de esportes que desejam melhorar suas performances, um conjunto completo de expertises, atividades e rastreamento nutricional.

O objetivo da ação? Ajudar seus usuários a evoluírem, claro. Porém, ainda mais importante: segundo a Under Armour, quanto mais incentivadas e animadas estas

pessoas ficam, mais inclinadas a comprarem novos equipamentos de esporte da marca elas se tornam.

1.10.12 Pinterest

O Pinterest, rede social de compartilhamento de imagens, chegou recentemente a mais de 150 milhões de usuários ativos mensais. Um de seus trunfos para o sucesso é a utilização de Big Data e machine learning (aprendizado de máquina) para personalizar ao máximo a experiência de seus usuários.

A equipe técnica do Pinterest vem refinando o sistema de recomendação da rede ano após ano. Para alcançar este objetivo, seus cientistas de dados têm implementado inteligência artificial, um sistema de ranking mais rápido e conteúdo localizado.

1.11 Minority Report da vida real: China utiliza Big Data para prever crimes

1.11.1 Prevenindo crimes com uma plataforma de Big Data

Na China, as autoridades responsáveis pelo combate à criminalidade estão começando a se utilizar de um recurso que antes só poderia ser visto em filmes de ficção científica: ações pré-crime.

O governo local designou um dos maiores prestadores de serviço ao estado na área de segurança, a China Electronics Technology Group, para conduzir o processo de desenvolvimento de um software para coletar dados sobre trabalho, hobbies, consumo, entre outros tipos de comportamento de cidadãos comuns. O objetivo desse software é detectar a possibilidade da ocorrência de crimes — especialmente terrorismo — antes que eles aconteçam.

O programa também se utiliza de uma preexistente e vasta rede de informantes do governo, designados para monitorar a vizinhança, alertando sobre aspectos diversos, desde violações às políticas locais de planejamento familiar até comportamentos suspeitos.

Isto é utilizado em conjunto com uma nova legislação que entrou em vigor neste ano, regulamentando as ações de espionagem do estado. Esta lei concede às autoridades o direito de acessar contas bancárias, sistemas de telecomunicação e a rede nacional de vigilância chamada Skynet.

Não é de espantar que, com tantos poderes para saber detalhes pessoais dos cidadãos, o programa já seja objeto de vários questionamentos e polêmicas em torno que questões sobre privacidade.

1.11.2 Como funciona

Na prática, a plataforma mantém um constante monitoramento da população, identificando padrões de comportamento que, quando alterados, podem ser considerados indicativos de atividades suspeitas.

Assim, por exemplo, se um cidadão começa a receber repentinamente quantias muito elevadas de dinheiro em sua conta bancária ou se, mesmo não tendo parentes morando fora do país, começa a fazer ou receber muitas ligações do exterior, esta pessoa pode ser classificada como suspeita e passar a ser objeto de investigações ou monitoramento individualizado.

Quando enquadrados dessa maneira, os cidadãos podem ter suas contas bancárias bloqueadas e as empresas de telecomunicações são obrigadas a conceder ao governo acesso irrestrito ao seu histórico e informações pessoais.

O sistema vem sendo comparado com a história relatada no filme **Minority Report**, uma trama de ficção científica que se desenrola em torno de um sistema que detecta crimes com 4 dias de antecedência. Será possível algum dia nós possamos chegar a este cenário? E mais do que isso, será possível que este objetivo seja atingido mantendo o respeito à privacidade dos cidadãos?

1.12 Big Data Analytics faz gol também no futebol

Foi-se o tempo em que uma partida de futebol exigia apenas elementos simples: 22 em campo, estádio lotado e paixão pelo time. Hoje o esporte movimenta uma indústria que precisa estar de braços dados com a tecnologia.

Já mostramos por aqui que esporte e Big Data Analytics têm tudo a ver. Faz parte das estratégias dos grandes times obter insights, conhecer a concorrência, ter uma visão geral sobre a equipe e alinhar a performance dos atletas com objetivos do clube.

o futebol tomou a posse de bola da análise de dados e não ficou de fora da tendência que amplia os horizontes e permite que os técnicos e seus cartolas enxerguem o gramado de um lugar estratégico.

1.12.1 De frente para o gol

Desculpe-nos, mas temos que falar do amargo 7x1 da Copa do Mundo. Dia de tristeza para nós e exaltação para a Alemanha, a goleada em cima do Brasil traumatizou a nossa torcida e destacou o melhor time do mundial. Mas a vitória era de se esperar, convenhamos. Além da disciplina e preparo físico dos atletas, a Alemanha tinha um elemento surpresa em sua escalação: Big Data Analytics.

Com este reforço foi possível avaliar as situações de jogo, treinar jogadas específicas para cada partida, medir a posse de bola do time e dos adversários, quem mais deu passes e até mesmo quem tinha mais chances de fazer gol.

A clássica tendência de analisar as estatísticas de cada jogo ganhou o apoio de softwares de última geração e analistas em campo, que mediram desempenho de cada jogador, cruzaram dados de partidas similares e analisaram a vantagem competitiva deste ou daquele atleta.

1.12.2 De olho no torcedor

É da arquibancada que ouvimos os gritos da torcida que ama seu time. A cada jogo, ela está lá, vestindo a camisa e promovendo a grande festa que é o futebol brasileiro.

Mas, o que pensam verdadeiramente os torcedores? O que mais se fala nas redes sociais sobre o clássico imperdível do fim de semana? A imagem de um time perante a imprensa e as ferramentas de interação social devem importar aos times de futebol. Afinal, são nesses espaços que estão os entusiastas e também os maiores críticos dos times e seus jogadores.

A análise de dados, então, se torna um aliado de peso capaz de ajudar mesmo fora de campo. A Hekima, por exemplo, coletou um volume gigantesco de informações sobre o embate entre Corinthians e Grêmio no Campeonato Brasileiro de 2014. Foram 95.030 posts e 45.252 usuários monitorados entre 18h30 e 22h30 no dia da partida.

A partir do monitoramento foi possível avaliar qual era a expectativa do torcedor para a Copa Libertadores da América, medir qual jogador estava em alta com a torcida (na época, Paolo Guerrero) e qual a avaliação do programa de sócio-torcedor do time. A diretoria e a arbitragem também não escaparam das menções das redes sociais e blogs avaliados pelo monitor, que rastreou até mesmo as confusões na arquibancada.

Com tantas informações a seu dispor, as diretorias, empresas administradoras dos estádios e até a CBF têm subsídios para tomada de decisões acertadas no que se refere ao esporte.

1.12.3 É correr para o abraço

Medição da frequência cardíaca do jogador, GPS para acompanhar suas movimentações nos treinos, hábitos alimentares, estatísticas de gol, quantidade de likes no Facebook. O céu é o limite para a quantidade de dados passíveis de coleta e de análise.

E, tudo junto, misturado e cruzado, pode render o que mais interessa ao futebol: gols. O monitoramento de redes sociais em conjunto com soluções de Big Data Analytics são o passe certo que faltava para esportistas e times alcançarem a sua melhor performance.

Referências Bibliográficas

Links:

- [1] <http://www.bigdatabusiness.com.br/aprenda-mais-sobre-big-data-vendo-esses-7-cases-de-sucesso/>.
- [2] <http://www.bigdatabusiness.com.br/minority-report-da-vida-real-china-utiliza-big-data-para-prever-crimes/>.
- [3] <http://www.bigdatabusiness.com.br/big-data-analytics-faz-gol-tambem-no-futebol/>.

Livros e Artigos Científicos:

- [4] MELATO, Markus; HAMMER, Barbara; HORMANN, Kai. Neural gas for surface reconstruction. **Clausthal-Zellerfeld: Clausthal University of Technology, Department of Informatics**, 2007.
- [5] C. Amerijckx, M. Verleysen, P. Thissen and J. D. Legat, "Image compression by self-organized Kohonen map," in IEEE Transactions on Neural Networks, vol. 9, no. 3, pp. 503-507, May 1998.