

Lista de Exercícios 3 - 2018.1

Docente: Prof. Dr. Adrião.

Disciplina: Redes Neurais Artificiais.

Discentes: Isaac Dantas Isidório & Pedro Gushiken.

19 de junho de 2018

Sumário

1	Lista 3 - Redes Neurais Artificiais	1
1.1	Questão 01	1
1.1.1	Algoritmo da rede NARX:	1
1.1.2	a. Simulação com predição de um passo	3
1.1.3	b. Simulação com predição de dois passos	3
1.1.4	c. Simulação com predição de três passos	4
1.1.5	d. Comentários gerais	5
1.2	Questão 2	5
1.2.1	Rede neural competitiva	5
1.2.2	Rede SOM	5
1.3	Questão 3	6
1.4	Questão 4	6
1.4.1	Rede SOM	6
1.5	Questão 5	6
1.6	Questão 06	8
1.6.1	Algoritmo K-Means:	8
1.6.2	a.	23
1.6.3	b.	24
1.7	Questão 7	25
1.8	Questão 8	25
1.9	Questão 9	27
1.10	Questão 10	27
1.10.1	Big Data aplicado ao setor comercial	27
1.10.2	Ministério da Justiça - Brasil	29
1.10.3	Maplink	29
1.10.4	UPS	30
1.10.5	NOAA	30
1.10.6	Nike	30
1.10.7	Danone	30
1.10.8	J.P. Morgan	31
1.10.9	Rolls Royce	31
1.10.10	American Express	31
1.10.11	Under Armor	32
1.10.12	Pinterest	32
1.11	Minority Report da vida real: China utiliza Big Data para prever crimes	32
1.11.1	Prevenindo crimes com uma plataforma de Big Data	32

1.11.2	Como funciona	33
1.12	Big Data Analytics faz gol também no futebol	33
1.12.1	De frente para o gol	33
1.12.2	De olho no torcedor	34
1.12.3	É correr para o abraço	34

Lista de Figuras

1.1	Rede NARX.	1
1.2	Saída real x saída predita ($delay=1$).	3
1.3	Erro de predição ($delay=1$).	3
1.4	Saída real x saída predita ($delay=2$).	3
1.5	Erro de predição ($delay=2$).	4
1.6	Saída real x saída predita ($delay=3$).	4
1.7	Erro de predição ($delay=3$).	4
1.8	Respostas dos neurônios para a rede competitiva, Q02.	5
1.9	Matriz U, rede SOM, Q02	6
1.10	Vogal a, rede SOM, Q02	7
1.11	Vogal e, rede SOM, Q02	7
1.12	Vogal i, rede SOM, Q02	8
1.13	Vogal o, rede SOM, Q02	9
1.14	Vogal u, rede SOM, Q02	10
1.15	Respostas dos neurônios para a rede competitiva, Dados de treinamento pertencentes à espiral 1, Q04.	10
1.16	Respostas dos neurônios para a rede competitiva, Dados de treinamento pertencentes à espiral 2, Q04.	11
1.17	Respostas dos neurônios para a rede competitiva, Dados de validação pertencentes à espiral 1, Q04.	11
1.18	Respostas dos neurônios para a rede competitiva, Dados de validação pertencentes à espiral 2, Q04.	12
1.19	Respostas dos neurônios para a rede SOM, Dados de treinamento per- tencentes à espiral 1, Q04.	12
1.20	Respostas dos neurônios para a rede SOM, Dados de treinamento per- tencentes à espiral 2, Q04.	13
1.21	Respostas dos neurônios para a rede SOM, Dados de validação pertencen- tes à espiral 1, Q04.	13
1.22	Respostas dos neurônios para a rede SOM, Dados de validação pertencen- tes à espiral 2, Q04.	14
1.23	Posição dos pesos para a rede SOM, Q04.	14
1.24	Matriz U rede SOM, Q04.	15
1.25	Planos de entrada para a rede SOM, Q04.	15
1.26	Respostas dos neurônios para a rede SOM, Dados de treinamento per- tencentes à classe 1, Q05.	16

1.27	Respostas dos neurônios para a rede SOM, Dados de treinamento pertencentes à classe 2, Q05.	16
1.28	Respostas dos neurônios para a rede SOM, Dados de validação pertencentes à classe 3, Q05.	17
1.29	Respostas dos neurônios para a rede SOM, Dados de validação pertencentes à classe 4, Q05.	18
1.30	Matriz U rede SOM, Q05.	19
1.31	Matriz U rede SOM, recorte, Q05.	20
1.32	Planos de entrada para a rede SOM, Q05.	21
1.33	Configuração inicial (letra a).	23
1.34	Configuração final (letra a).	23
1.35	Configuração inicial (letra b).	24
1.36	Configuração final (letra b).	24
1.37	Matriz U rede SOM, Q07.	25
1.38	Matriz U rede SOM, recorte, Q07.	26
1.39	Planos de entrada para a rede SOM, Q07.	26
1.40	Respostas dos neurônios, Q08.	27
1.41	Matriz de covariância, Q09.	28
1.42	Matriz de autovetores, ordenados de maior para menor autovalor associado, Q09.	28
1.43	Componentes principais, Q09.	29

Capítulo 1

Lista 3 - Redes Neurais Artificiais

1.1 Questão 01

A rede utilizada possui duas camadas ocultas, sendo a primeira com 3 neurônios e a segunda com 1 neurônio.

Inicialmente, a rede realiza o processo de treinamento, teste e validação sem a realimentação de saída.

Posteriormente, a saída realimenta à rede e a predição é realizada. Segue abaixo, na Figura 1.1, a estrutura final da rede NARX.




Figura 1.1: Rede NARX.

1.1.1 Algoritmo da rede NARX:

```
% Inicialização dos parâmetros
t = linspace(0, 20*pi, 1000);
u = cos(t + sin(t).^2);
x = log(1 + u);
u = con2seq(u);
x = con2seq(x);
```

```
% Delay:
%delay = 1;
```

```

%delay = 2;
delay = 3;

% Arquitetura da rede:
net = narxnet(1:delay, 1:delay, [3 1]);

%% Treinamento da rede (malha aberta)
[Xs, Xi, Ai, Ts] = preparets(net, u, {}, x);
net = train(net, Xs, Ts, Xi);

yp = sim(net,Xs,Xi);

%% Erros de treinamento:
erro_treinamento = cell2mat(yp)-cell2mat(Ts);
figure(1)
plot(erro_treinamento);

%% Realimentação
% Rede Narx em malha fechada:
net_mf = closeloop(net);
view(net_mf);




x1 = x(500:1000);
u1 = u(500:1000);
[X_mf, Xi_mf, A_mf, T_mf] = preparets(net_mf, u1, {}, x1);
yp1 = net_mf(X_mf, Xi_mf, A_mf);
TS = size(T_mf,2);


%% Gráfico da saída da rede Narx:
figure(2)
plot(1:TS,cell2mat(T_mf),'b',1:TS,cell2mat(yp1),'r')
legend('Saída Real','Saída Predita')
figure(3)
erro_predicao = cell2mat(T_mf)-cell2mat(yp1);
plot(1:TS,erro_predicao,'k')
legend('Erro de Predição')

```



Seguem abaixo, os gráficos referentes a comparação entre as saídas da função $x(n)$ e sua predição, um para predição de um passo, dois passos e três passos, Figuras 1.2, 1.4 e 1.6.

Os gráficos referentes ao erro associado a cada predição, para um passo, dois passos e três passos, podem ser visualizados, respectivamente, nas Figuras 1.3, 1.5 e 1.6.

1.1.2 a. Simulação com predição de um passoFigura 1.2: Saída real x saída predita ($delay=1$).Figura 1.3: Erro de predição ($delay=1$).**1.1.3 b. Simulação com predição de dois passos**Figura 1.4: Saída real x saída predita ($delay=2$).

Figura 1.5: Erro de predição ($\text{delay}=2$).

1.1.4 c. Simulação com predição de três passos

Figura 1.6: Saída real $\times$ saída predita ($\text{delay}=3$).Figura 1.7: Erro de predição ($\text{delay}=3$).




Figura 1.8: Respostas dos neurônios para a rede competitiva, Q02.

1.1.5 d. Comentários gerais

É observado que o erro de predição diminui, de maneira geral, com o aumento do passo de predição. Dessa forma, a série temporal pode ser melhor aproximada de acordo com a quantidade de termos de atraso conhecidos.

1.2 Questão 2

Fizemos uso da database do MNIST, retirada da internet. Cada imagem consiste de 28x28 pixels, que transformamos em um vetor de entrada de 784x1 com valores limitados ao intervalo entre 0 e 1. Treinamos uma rede competitiva e da rede SOM para fazer o reconhecimento dos clusters através de treinamento não supervisionado, obtivemos os seguintes resultados:

1.2.1 Rede neural competitiva

Vemos que a rede competitiva é capaz de distinguir que há classes distintas, porém, devido aos fatores de variância dos dados (especialmente a vogal a), e de que cada grupo de dados rotulados representa 2 casos distintos (a vogal maiúscula ou minúscula), podemos ver que a separação não é tão clara quanto gostaríamos.

1.2.2 Rede SOM

Treinamos uma rede SOM 7x7 por 20000 iterações, usando as opções padrão de algoritmos do toolbox de redes neurais do MATLAB, obtendo os seguintes resultados:

Ao preservar a topologia dos dados, a rede SOM exibe uma separação mais clara entre os dados. Novamente, como no caso da rede competitiva, observamos que a separação para a vogal "a" é menos clara, no entanto, as fronteiras de decisão são um pouco mais claras.




Figura 1.9: Matriz U, rede SOM, Q02

1.3 Questão 3

1.4 Questão 4

Repetimos a questão das espirais da lista 2, obtendo os resultados das Figuras 8 até 11.

Pela visualização obtida, concluímos que não foi possível para a rede competitiva separar os dados de forma expressiva.

1.4.1 Rede SOM

Treinamos a rede SOM por 500 épocas, para uma topologia hexagonal 10x10, obtendo os resultados das Figuras 12 até 18.

1.5 Questão 5

Geramos 4 nuvens de pontos, conforme especificado na questão. Escolhemos gerar 1000 pontos para cada nuvem, obtendo os resultados das Figuras 19 até 25, para uma rede SOM 10x10:




Figura 1.10: Vogal a, rede SOM, Q02




Figura 1.11: Vogal e, rede SOM, Q02




Figura 1.12: Vogal i, rede SOM, Q02

1.6 Questão 06

1.6.1 Algoritmo K-Means:

%% Amostras:

```
x1 = [-7.82 -6.68 4.36 6.72 -8.64 -6.87 4.47 6.73 -7.71 -6.91 6.18...
6.72 -6.25 -6.94 8.09 6.81 -5.19 -6.38 4.08 6.27]';
x2 = [4.58 3.16 -2.19 0.88 3.06 0.57 -2.62 -2.01 2.34 -0.49 2.81...
-0.93 -0.26 -1.22 0.20 0.17 4.24 -1.74 1.30 0.93]';
x3 = [-3.97 2.71 2.09 2.80 3.50 -5.45 5.76 4.18 -6.33 -5.68 5.82...
-4.04 0.56 1.13 2.25 -4.15 4.04 1.43 5.33 -2.78]';
```

```
X = [x1 x2 x3];
```

%% Número de clusters do Algoritmo K-Means

```
K = 3;
```

%% Questão 6a

```
disp('Questão 6a')
```

```
centroids = [0 1 -1; 0 1 0; 0 1 2];
```

```
figure(1)
```




Figura 1.13: Vogal o, rede SOM, Q02




Figura 1.14: Vogal u, rede SOM, Q02




Figura 1.15: Respostas dos neurônios para a rede competitiva, Dados de treinamento pertencentes à espiral 1, Q04.




Figura 1.16: Respostas dos neurônios para a rede competitiva, Dados de treinamento pertencentes à espiral 2, Q04.




Figura 1.17: Respostas dos neurônios para a rede competitiva, Dados de validação pertencentes à espiral 1, Q04.




Figura 1.18: Respostas dos neurônios para a rede competitiva, Dados de validação pertencentes à espiral 2, Q04.




Figura 1.19: Respostas dos neurônios para a rede SOM, Dados de treinamento pertencentes à espiral 1, Q04.




Figura 1.20: Respostas dos neurônios para a rede SOM, Dados de treinamento pertencentes à espiral 2, Q04.




Figura 1.21: Respostas dos neurônios para a rede SOM, Dados de validação pertencentes à espiral 1, Q04.




Figura 1.22: Respostas dos neurônios para a rede SOM, Dados de validação pertencentes à espiral 2, Q04.




Figura 1.23: Posição dos pesos para a rede SOM, Q04.




Figura 1.24: Matriz U rede SOM, Q04.




Figura 1.25: Planos de entrada para a rede SOM, Q04.




Figura 1.26: Respostas dos neurônios para a rede SOM, Dados de treinamento pertencentes à classe 1, Q05.




Figura 1.27: Respostas dos neurônios para a rede SOM, Dados de treinamento pertencentes à classe 2, Q05.




Figura 1.28: Respostas dos neurônios para a rede SOM, Dados de validação pertencentes à classe 3, Q05.




Figura 1.29: Respostas dos neurônios para a rede SOM, Dados de validação pertencentes à classe 4, Q05.




Figura 1.30: Matriz U rede SOM, Q05.




Figura 1.31: Matriz U rede SOM, recorte, Q05.




Figura 1.32: Planos de entrada para a rede SOM, Q05.

```

plot3(X(:,1),X(:,2),X(:,3),'o','MarkerSize',5);
grid on;
hold on;
plot3(centroids(1,:),centroids(2,:),centroids(3:),'k*','MarkerSize',7);
legend('Amostras','Centróides');
xlabel('x1');
ylabel('x2');
zlabel('x3');

[idxa, Ca, somada, dA] = kmeans(X, K, 'Start', centroids, 'Display', 'iter');

for i=1:K
centroids(i,:) = Ca(:,i);
end

figure(2)
plot3(X(:,1),X(:,2),X(:,3),'o','MarkerSize',5);
grid on;
hold on;
plot3(centroids(1,:),centroids(2,:),centroids(3:),'k*','MarkerSize',7);
legend('Amostras','Centróides');
xlabel('x1');
ylabel('x2');
zlabel('x3');

%% Questão 6b
disp('Questão 6b')
centroids = [-0.1 0 -0.1;0 -0.1 -0.1; 0.1 0.1 0.1];

figure(3)
plot3(X(:,1),X(:,2),X(:,3),'o','MarkerSize',5);
grid on;
hold on;
plot3(centroids(1,:),centroids(2,:),centroids(3:),'k*','MarkerSize',7);
legend('Amostras','Centróides');
xlabel('x1');
ylabel('x2');
zlabel('x3');

[idxb, Cb, somadb, dB] = kmeans(X, K, 'Start', centroids, 'Display', 'iter');

for i=1:K
centroids(i,:) = Cb(:,i);
end

figure(4)

```

```

plot3(X(:,1),X(:,2),X(:,3),'o','MarkerSize',5);
grid on;
hold on;
plot3(centroids(1,:),centroids(2,:),centroids(3,:),'k*','MarkerSize',7);
legend('Amostras','Centróides');
xlabel('x1');
ylabel('x2');
zlabel('x3');

```

1.6.2 a.




Figura 1.33: Configuração inicial (letra a).




Figura 1.34: Configuração final (letra a).

1.6.3 b.




Figura 1.35: Configuração inicial (letra b).




Figura 1.36: Configuração final (letra b).

Abaixo, seguem os resultados obtidos pela aplicação do algoritmo K-means, a partir dos centroides definidos nos itens **a** e **b**, respectivamente.

Item	Iterações	$\sum_{\text{dist}}$	Centroide 1	Centroide 2	Centroide 3
a	4	266.734	3	10	7
b	2	266.734	10	3	7

Tabela 1.1: Resultados do algoritmo K-means.

No item **a**, o algoritmo convergiu em 4 iterações, ao passo que no item **b**, o k-means converge mais rapidamente, em apenas 2 iterações.

No item **a**, o algoritmo associou 3 elementos ao centroide 1, 10 elementos ao centroide 2 e 7 elementos ao centroide 3.

No item **b**, o algoritmo associou 10 elementos ao centroide 1, 3 elementos ao centroide 2 e 7 elementos ao centroide 3.




Figura 1.37: Matriz U rede SOM, Q07.

A terceira coluna da tabela 1.1 representa a soma das distâncias dos elementos associados a cada cluster¹. Em ambos os itens, **a** e **b**, quando o algoritmo converge, o valor encontrado é 266.734.

1.7 Questão 7

Treinamos a rede SOM, obtendo os resultados das Figuras 26 a 28. Vemos que há uma separação distinta entre 5 clusters de países.

1.8 Questão 8

Usamos o algoritmo k-means com 10 neurônios, durante 500 épocas de treinamento, obtendo o resultado de classificação da Figura 29.

Apenas 5 dos 10 neurônios que utilizamos respondem às entradas, um resultado condizente com o obtido para a questão 7.

¹Os elementos são associados a cada cluster, suas distâncias são computadas em relação ao seu respectivo cluster e as distâncias são somadas.




Figura 1.38: Matriz U rede SOM, recorte, Q07.




Figura 1.39: Planos de entrada para a rede SOM, Q07.




Figura 1.40: Respostas dos neurônios, Q08.

1.9 Questão 9

Média: 67.7792, 22.1083, 10.1958, 2.8333
 Mediana: 67.45, 22.9, 10.15, 2.85
 Máximos: 83.7, 32.8, 17.6, 4.4
 Mínimos: 55.9, 10.5, 5.8, 0.9
 Variância: 68.2226, 39.8878, 9.5961, 0.6858

Autovalores da matriz de covariância ordenados, com precisão de 1e-10: 20864,377.7,39.3,0,0,0,0
 Variância dos componentes principais: 109%, 8.77%, 0.58%, 0.05%. Percentagem de variância dos dados explicada pelos componentes principais: 92%, 7.4%, 0.5%, 0.1%.

1.10 Questão 10

1.10.1 Big Data aplicado ao setor comercial

Até algumas décadas atrás, a simples contratação de uma empresa de pesquisas de mercado era suficiente para desvendar o **comportamento do consumidor**. Um estudo analítico profundo poderia dar sinais sobre o futuro da economia e o seu setor de atuação.


Mas esse universo empresarial estático ficou para trás. O dinamismo da troca de informações das mídias sociais, a formação de um novo consumidor, exigente, antenado e conectado 24 horas à web, além da “inundação” de novos entrantes em todos os segmentos, ampliando a concorrência e confundindo o seu target, fizeram com que a compreensão plena do mercado só pudesse ser alcançada por meio do trabalho aprofundado com centenas de variáveis internas e externas, a serem coletadas e processadas por poderosos softwares.

Estamos falando de **Big Data**, que permite às empresas mapearem e compreenderem plenamente seus consumidores, otimizarem seus processos de negócios ou enxergarem antes da concorrência uma **eventual mudança de tendência**.

covX																								
24x24 double																								
	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20	21	22	23	24
1	1320	1284	1069	905	1100	1034	899	1127	1396	1052	860	1022	1157	905	910	1208	1325	1125	789	780	909	852	1255	816
2	1284	1252	1047	887	1079	1011	884	1101	1356	1033	847	1002	1128	892	897	1178	1289	1099	780	773	895	840	1223	805
3	1069	1047	887	746	918	850	755	925	1122	885	729	850	940	771	775	986	1068	923	675	677	770	725	1023	692
4	905	887	746	651	772	726	646	784	950	740	616	720	810	649	649	836	908	786	575	566	648	613	865	590
5	1100	1079	918	772	952	878	785	955	1151	920	760	881	968	804	808	1016	1097	953	705	709	802	756	1054	722
6	1034	1011	850	726	878	821	726	891	1087	842	696	816	914	733	736	952	1036	891	644	639	733	691	987	662
7	899	884	755	646	785	726	654	785	938	758	631	728	800	668	669	834	897	785	590	591	665	629	864	602
8	1127	1101	925	784	955	891	785	970	1187	917	754	886	992	795	799	1036	1129	969	696	692	796	749	1076	716
9	1396	1356	1122	950	1151	1087	938	1187	1481	1097	895	1071	1223	939	945	1275	1405	1185	818	804	945	885	1325	848
10	1052	1033	885	740	920	842	758	917	1097	892	737	850	923	782	786	974	1047	914	685	694	779	734	1010	700
11	860	847	729	616	760	696	631	754	895	737	613	703	761	651	653	799	856	753	573	580	647	612	828	584
12	1022	1002	850	720	881	816	728	886	1071	850	703	817	902	743	746	944	1021	885	652	653	742	699	979	668
13	1157	1128	940	810	968	914	800	992	1223	923	761	902	1026	800	802	1062	1164	993	703	689	802	755	1102	726
14	905	892	771	649	804	733	668	795	939	782	651	743	800	692	694	842	899	794	609	619	687	649	872	619
15	910	897	775	649	808	736	669	799	945	786	653	746	802	694	697	846	904	797	609	621	690	651	877	620
16	1208	1178	986	836	1016	952	834	1036	1275	974	799	944	1062	842	846	1109	1212	1035	736	729	844	793	1151	759
17	1325	1289	1068	908	1097	1036	897	1129	1405	1047	856	1021	1164	899	904	1212	1333	1128	784	771	903	847	1259	812
18	1125	1099	923	786	953	891	785	969	1185	914	753	885	993	794	797	1035	1128	968	696	690	795	748	1074	717
19	789	780	675	575	705	644	590	696	818	685	573	652	703	609	609	736	784	696	538	545	604	572	762	547
20	780	773	677	566	709	639	591	692	804	694	580	653	689	619	621	729	771	690	545	560	613	580	756	552
21	909	895	770	648	802	733	665	796	945	779	647	742	802	687	690	844	903	795	604	613	683	645	875	616
22	852	840	725	613	756	691	629	749	885	734	612	699	755	649	651	793	847	748	572	580	645	610	821	583
23	1255	1223	1023	865	1054	987	864	1076	1325	1010	828	979	1102	872	877	1151	1259	1074	762	756	875	821	1196	786
24	816	805	692	590	722	662	602	716	848	700	584	668	726	619	620	759	812	717	547	552	616	583	786	557

Figura 1.41: Matriz de covariância, Q09.

covX																								
eigenvalues																								
eigenvectors																								
24x24 double																								
	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20	21	22	23	24
1	0.2492	-0.2465	-0.1481	-0.0709	-0.0554	0.1485	-0.2148	0.3415	-0.1472	0.0547	0.2303	0.1390	0.4198	-0.0238	-0.2079	0.2161	-0.2278	0.0754	0.1476	0.1402	-0.3136	-0.0436	-0.3011	0.0935
2	0.2439	-0.1693	-0.0843	-0.0630	-0.0640	0.1009	0.2190	-0.1095	-0.1970	0.0224	0.0760	-0.2414	0.2252	-0.1833	0.0975	0.0161	-0.0382	-0.0177	0.1378	0.1215	-0.0921	-0.1830	0.7345	-0.1102
3	0.2060	0.0275	-0.1658	-0.0065	-0.0718	-0.2347	0.3275	0.1971	-0.3096	0.2727	0.0784	-0.2671	-0.2514	-0.1181	0.3774	-0.2399	0.0763	0.0932	0.1729	-0.0953	-0.1364	-0.0666	-0.3452	0.0487
4	0.1746	-0.0037	0.6117	0.1934	0.0728	-0.1281	-0.0923	0.4260	0.0880	-0.2880	-0.0903	-0.1544	-0.0678	-0.1193	0.1716	0.1807	-0.1182	0.0504	0.1483	-0.0581	0.1246	-0.1921	0.0739	0.2070
5	0.2131	0.0975	-0.1583	0.0871	0.1771	0.3312	0.3303	0.1325	-0.1117	-0.0898	-0.0742	-0.1446	-0.0355	0.2341	-0.3264	-0.1613	-0.1899	-0.2102	-0.1248	-0.2127	0.1743	0.0884	0.0406	0.4778
6	0.1981	-0.0491	0.1761	0.0190	-0.1329	-0.2624	0.0261	-0.0131	-0.1494	-0.3196	0.0275	-0.0147	0.0082	0.3344	-0.1399	-0.3860	0.1841	-0.0255	-0.2567	0.5528	-0.1602	-0.0284	-0.0297	0.0162
7	0.1757	0.1384	0.2589	0.0721	-0.0959	0.2452	0.1872	0.1480	0.1790	0.4850	0	-0.0130	0.2702	-0.0880	-0.1598	-0.0484	0.3412	0.1003	-0.2614	0.0934	0.2790	-0.2292	-0.1136	-0.1690
8	0.2154	-0.0758	-0.0438	-0.0257	0.0089	0.1800	0.4508	-0.0624	0.1756	-0.2441	0.0239	0.3467	-0.0534	-0.0308	0.1855	0.1943	0.1111	0.0866	0.3393	0.3226	0.2611	0.3085	-0.1226	-0.0330
9	0.2617	-0.3701	-0.1646	-0.1555	-0.1341	-0.4852	0.0364	0.0421	0.3199	-0.0534	0.0285	0.1348	0.1153	0.0575	-0.1497	-0.0427	0.2301	-0.2527	0.0594	-0.3903	0.1856	-0.1133	0.0330	0.0280
10	0.2051	0.1747	-0.2932	0.0277	0.0616	0.1867	-0.2767	0.1738	0.3883	0.1538	-0.2043	0.0987	-0.2582	0.2846	0.1759	-0.0245	0.2174	0.0337	0.1751	0.1508	-0.2549	-0.2379	0.1975	0.1668
11	0.1692	0.2070	0.0191	0.0626	-0.0757	-0.0244	-0.2668	0.0713	-0.1554	0.1371	0.4372	-0.0408	0.1105	0.3890	0.3729	0.1604	0.0326	-0.2821	-0.0834	-0.0416	0.2739	0.3118	0.1121	-0.0603
12	0.1977	0.0622	-0.0217	0.0017	-0.0904	0.2255	-0.3880	0.0344	-0.2070	-0.1494	0.0548	0.3291	-0.0753	-0.3549	-0.0013	-0.5672	0.0275	0.0737	0.1291	-0.1353	0.2614	0.0194	0.0583	-0.0520
13	0.2197	-0.1843	0.4019	0.0100	-0.1570	0.3193	0.0542	-0.2823	0.2211	0.0678	-0.0533	-0.0268	-0.0235	0.1335	0.1391	-0.2086	-0.1837	-0.2917	0.0821	-0.2334	-0.3942	0.1163	-0.1468	-0.1951
14	0.1786	0.2609	-0.0595	-0.0038	-0.1828	-0.2693	0.1078	0.0936	-0.0265	0.1977	-0.3150	0.3313	-0.0770	0.0254	-0.0254	0.0343	-0.6182	-0.1463	-0.0888	0.1325	0.1061	-0.1047	0.0680	-0.2389
15	0.1794	0.2525	-0.1764	-0.0438	-0.2283	0.1856	-0.0232	0.0229	-0.1406	-0.4033	-0.0710	-0.1286	-0.1737	-0.2248	-0.0591	0.3572	0.2343	-0.3556	-0.1909	-0.0704	-0.0959	-0.2019	-0.1731	-0.2550
16	0.2297	-0.1464	-0.0456	0.0107	0.0160	0.0348	-0.1253	-0.5572	-0.0199	-0.0071	0.0630	0.0275	-0.0048	-0.0097	0.2680	0.1382	-0.1735	0.1511	-0.2494	0.0583	0.2125	-0.4215	-0.2007	0.3436
17	0.2493	-0.3113	-0.0267	-0.1307	-0.2095	0.0486	-0.2689	-0.0130	-0.0147	0.1479	-0.2603	-0.4074	-0.3346	0.0339	-0.2261	0.1476	-0.0531	0.2479	-0.0206	0.1033	0.2346	0.3479	-0.0029	-0.1056
18	0.2151	-0.0791	0.0964	0.0697	0.0553	-0.0649	0.0577	0.0404	-0.2133	0.0839	-0.1914	0.3943	-0.0495	-0.1148	0.1170	0.1956	0.2154	0.2093	-0.4515	-0.2305	-0.3143	0.3163	0.1894	0.1640
19	0.1566	0.2562	0.2005	0.1659	0.0561	-0.1830	-0.0932	-0.3720	-0.3238	0.2070	-0.1417	0.0754	0.0263	0.0480	-0.3429	0.1704	0.2288	-0.1148	0.4971	-0.0062	-0.0438	-0.0059	-0.0304	0.1406
20	0.1563	0.3620	-0.1359	0.0324	-0.1312	-0.0768	-0.0045	-0.1031	0.1104	-0.2786	-0.2647	-0.2093	0.4925	0.1669	0.1113	-0.0738	-0.0288	0.4469	0.0582	-0.2527	-0.0286	0.1216	-0.0707	-0.1043
21	0.1785	0.2187	-0.0885	0.1045	-0.1190	-0.1963	-0.1021	-0.1085	0.3782	0.0760	0.0853	-0.2117	0.1183	-0.1626	-0.0122	-0.0853	0.0698	-0.2360	-0.1152	0.2466	-0.1201	0.3403	-0.0743	0.2366
22	0.1681	0.2334	0.0517	0.0669	-0.0893	-0.0723	0.1149	-0.0819	-0.0285	-0.0520	0.6083	0.0410	-0.3488	0.0572	-0.3255	0.0641	-0.1315	0.3750	-0.0172	-0.1579	-0.1460	-0.0543	0.1128	-0.0950
23	0.2368	-0.1637	-0.0313	0.3787	0.7056	-0.0562	-0.0163	-0.0204	-0.0287	-0.0480	-0.0182	-0.0488	-0.0180	0.0510	-0.0284	-0.0250	-0.0236	0.0061	-0.0581	-0.0209	0.0273	-0.0472	-0.0809	-0.4765
24	0.1608	0.2064	0.1891	-0.8363	0.4367	-0.0211	-0.0227	-0.0060	-0.0288	0.0013	0.0089	-0.0153	-0.0064	0.0146	0.0012	-0.0059	-0.0017	0.0108	-0.0200	-0.0077	-0.0124	-0.0112	-0.0227	-0.0432



	1	2	3	4
1	0.7884	-0.2292	-0.0281	0.5702
2	-0.5828	-0.5707	0.0290	0.5778
3	-0.1957	0.7849	-0.0833	0.5820
4	0.0229	0.0758	0.9957	0.0479

Figura 1.43: Componentes principais, Q09.

A importância do trabalho com Big Data é tão grande que companhias de todos os segmentos já o fazem (inclusive brasileiras), gerando grandes resultados em seus negócios. É o que você verá neste artigo, com **11 casos de sucesso com Big Data** de companhias e instituições que investiram na coleta e análise de grandes volumes de dados.

1.10.2 Ministério da Justiça - Brasil

O Ministério da Justiça possui um data warehouse (banco de dados) com mais de 1 bilhão de registros, além de um poderoso supercomputador da IBM, chamado Watson, capaz de coletar, agrupar e processar petabytes de dados em frações de segundos. O objetivo do Ministério com o uso de Big Data é identificar indícios de ações ilícitas, sobretudo ligadas à **lavagem de dinheiro**.

1.10.3 Maplink

A Maplink, empresa especializada na digitalização de mapas, passou a utilizar, nos últimos anos, um software de rastreamento por satélite, cruzando centenas de milhares de dados oriundos de mais de 400 mil automóveis em São Paulo – tudo em tempo real.

Esse trabalho de tecnologia avançada possibilitou à empresa fazer um diagnóstico preciso do trânsito da cidade, indicando todos os pontos de lentidão, as razões e possíveis alternativas.

Por exemplo, enquanto em um dado momento a Maplink revelava que a cidade tem mais de 400 km de ruas congestionadas, a Companhia de Engenharia de Tráfego (CET) apontava, erroneamente, menos da metade dessa quilometragem.

1.10.4 UPS

Empresa norte-americana de transporte e logística, a UPS tinha o desafio de otimizar o seu cronograma de rotas, tornando-as mais eficientes e menos dispendiosas possíveis. Era necessário então fazer um estudo matemático e milimétrico, cruzando todas as rotas de todos os seus veículos, e avaliando também velocidade, pressão, tempo gasto em cada entrega, RPM e por aí vai.

Evidentemente, a imensidão de variáveis tornava impossível à mente humana chegar a resultados sólidos. Entretanto, a instalação de sensores em todos os veículos da empresa permitiu que ela chegasse a uma solução para suas rotas. Após um extenso período de testes, resultados práticos foram alcançados: quase 5 milhões de litros de gasolina economizados anualmente, redução de manutenção e maior rapidez nas entregas dos produtos.

1.10.5 NOAA

A National Oceanic and Atmospheric Administration (NOAA), organização pertencente ao governo dos EUA, recolhe cerca de 30 petabytes de dados diariamente por meio de satélites, da instalação de sensores em vias e de outros recursos.

O resultado do investimento foi o aumento da eficiência e exatidão das previsões de mudanças atmosféricas, previsões de tempestades e tornados com muito mais antecedência e a possibilidade de vender todas as informações preditivas geradas para outras empresas, tanto do setor público quanto do privado (setor agrícola, por exemplo).

1.10.6 Nike

A maior fabricante de materiais esportivos do planeta fechou uma parceria com uma empresa especialista em tecnologia, no intuito de desenvolver um software que fosse usado por **praticantes de running**, informando a eles frequência de batimentos cardíacos, velocidade, quantidade de passos dados, distância percorrida e muitos outros dados.

O “pulo do gato”, neste caso, foi integrar esse app com as redes sociais, estimulando amigos e fãs de corrida a compartilharem suas informações, propiciando uma certa “competição” entre os atletas.

O estímulo a esse comportamento multiplicou exponencialmente a quantidade de dados gerados diariamente, os quais são usados pela Nike para compreender seu público, melhorar seus produtos ou desenvolver novos modelos de tênis e roupas esportivas.

1.10.7 Danone

A Danone norte-americana tinha a necessidade de melhorar sua cadeia logística na distribuição de um certo tipo de iogurte (o ‘Grego’, no caso). Como o produto perecia com rapidez, ele precisava ser produzido e entregue ao varejo em sincronia quase matemática.

Isso se tornou possível apenas com o cruzamento de informações de rotas, tempo de entrega e prazo de validade.

1.10.8 J.P. Morgan

O dinamismo extremo do mercado financeiro resulta na produção diária de milhões de dados, índices e indicadores, os quais devem ser combinados no intuito de formar direcionamentos mais sólidos do que poderá ocorrer no próximo minuto.

O banco norte-americano J.P. Morgan trabalha há anos com estudos de algoritmos complexos, conceitos de redes neurais e cruzamento de dados por meio de sistemas de **Big Data Analytics** para prever tendências e entender quando comprar ou vender ações.

1.10.9 Rolls Royce

Quando se fala em Rolls-Royce, muitas características da marca logo vêm à mente das pessoas: tradição, elegância, status. Contudo, é principalmente pela inovação tecnológica que a empresa automobilística inglesa, subsidiária da BMW, tem se destacado ultimamente.

A Rolls-Royce vem implementando soluções de Big Data para otimizar seus processos de manutenção. Os motores e sistemas de propulsão dos veículos da companhia têm centenas de sensores embutidos, que registram todos os detalhes de funcionamento das máquinas e enviam, aos engenheiros da marca (espalhados pelos centros de serviço da empresa ao redor do mundo), dados em tempo real sobre quaisquer mudanças de desempenho delas.

A equipe de engenheiros cruza e analisa estes dados, possibilitando tomadas de decisão rápidas e assertivas para evitar e/ou resolver qualquer problema de funcionamento dos carros.

Segundo a Rolls-Royce, a adoção de tecnologias de Big Data para diagnosticar falhas, corrigi-las e evitá-las de ocorrerem novamente diminuiu significativamente os custos de manutenção de seus veículos.

1.10.10 American Express

A American Express, empresa norte-americana de serviços financeiros, passou a investir em Big Data ao perceber que os insights gerados pelas **ferramentas tradicionais de BI** não estavam sendo suficientes para diminuir as taxas de cancelamento de seus clientes.

A companhia desenvolveu sofisticados modelos preditivos para analisar históricos de transações dos usuários de seus cartões de crédito, além de 115 variáveis, para prever potenciais churns (evasão de clientes). Após a implementação de uma solução de Big Data em seus processos, a American Express acredita ser capaz, por exemplo, de identificar 24 % de seus clientes australianos que pretendem encerrar suas contas dentro dos próximos quatro meses.

1.10.11 Under Armor

Já falamos em um tópico anterior sobre como a Nike tem utilizado Big Data em seus negócios. E justamente uma de suas rivais de mercado, a Under Armour, também tem implementado a análise e coleta de dados em suas estratégias para desbancar a eterna líder do fornecimento de materiais esportivos.

A marca investiu, recentemente, 710 milhões de dólares na compra de três criadoras de aplicativos de ginástica, a fim de ter acesso aos dados dos mais de 120 milhões de usuários combinados destes apps.

De posse destes gigantescos volumes de informação, e em parceria com uma empresa de wearables (tecnologias vestíveis), a Under Armour planeja fornecer, a atletas e praticantes regulares de esportes que desejam melhorar suas performances, um conjunto completo de expertises, atividades e rastreamento nutricional.

O objetivo da ação? Ajudar seus usuários a evoluírem, claro. Porém, ainda mais importante: segundo a Under Armour, quanto mais incentivadas e animadas estas pessoas ficam, mais inclinadas a comprarem novos equipamentos de esporte da marca elas se tornam.

1.10.12 Pinterest

O Pinterest, rede social de compartilhamento de imagens, chegou recentemente a mais de 150 milhões de usuários ativos mensais. Um de seus trunfos para o sucesso é a utilização de Big Data e machine learning (aprendizado de máquina) para personalizar ao máximo a experiência de seus usuários.

A equipe técnica do Pinterest vem refinando o sistema de recomendação da rede ano após ano. Para alcançar este objetivo, seus cientistas de dados têm implementado inteligência artificial, um sistema de ranking mais rápido e conteúdo localizado.

1.11 Minority Report da vida real: China utiliza Big Data para prever crimes

1.11.1 Prevenindo crimes com uma plataforma de Big Data

Na China, as autoridades responsáveis pelo combate à criminalidade estão começando a se utilizar de um recurso que antes só poderia ser visto em filmes de ficção científica: ações pré-crime.

O governo local designou um dos maiores prestadores de serviço ao estado na área de segurança, a China Electronics Technology Group, para conduzir o processo de desenvolvimento de um software para coletar dados sobre trabalho, hobbies, consumo, entre outros tipos de comportamento de cidadãos comuns. O objetivo desse software é detectar a possibilidade da ocorrência de crimes — especialmente terrorismo — antes que eles aconteçam.

O programa também se utiliza de uma preexistente e vasta rede de informantes do governo, designados para monitorar a vizinhança, alertando sobre aspectos diversos, desde violações às políticas locais de planejamento familiar até comportamentos suspeitos.

Isto é utilizado em conjunto com uma nova legislação que entrou em vigor neste ano, regulamentando as ações de espionagem do estado. Esta lei concede às autoridades o direito de acessar contas bancárias, sistemas de telecomunicação e a rede nacional de vigilância chamada Skynet.

Não é de espantar que, com tantos poderes para saber detalhes pessoais dos cidadãos, o programa já seja objeto de vários questionamentos e polêmicas em torno que questões sobre privacidade.

1.11.2 Como funciona

Na prática, a plataforma mantém um constante monitoramento da população, identificando padrões de comportamento que, quando alterados, podem ser considerados indicativos de atividades suspeitas.

Assim, por exemplo, se um cidadão começa a receber repentinamente quantias muito elevadas de dinheiro em sua conta bancária ou se, mesmo não tendo parentes morando fora do país, começa a fazer ou receber muitas ligações do exterior, esta pessoa pode ser classificada como suspeita e passar a ser objeto de investigações ou monitoramento individualizado.

Quando enquadrados dessa maneira, os cidadãos podem ter suas contas bancárias bloqueadas e as empresas de telecomunicações são obrigadas a conceder ao governo acesso irrestrito ao seu histórico e informações pessoais.

O sistema vem sendo comparado com a história relatada no filme **Minority Report**, uma trama de ficção científica que se desenrola em torno de um sistema que detecta crimes com 4 dias de antecedência. Será possível algum dia nós possamos chegar a este cenário? E mais do que isso, será possível que este objetivo seja atingido mantendo o respeito à privacidade dos cidadãos?

1.12 Big Data Analytics faz gol também no futebol

Foi-se o tempo em que uma partida de futebol exigia apenas elementos simples: 22 em campo, estádio lotado e paixão pelo time. Hoje o esporte movimenta uma indústria que precisa estar de braços dados com a tecnologia.

Já mostramos por aqui que esporte e Big Data Analytics têm tudo a ver. Faz parte das estratégias dos grandes times obter insights, conhecer a concorrência, ter uma visão geral sobre a equipe e alinhar a performance dos atletas com objetivos do clube.

O futebol tomou a posse de bola da análise de dados e não ficou de fora da tendência que amplia os horizontes e permite que os técnicos e seus cartolas enxerguem o gramado de um lugar estratégico.

1.12.1 De frente para o gol

Desculpe-nos, mas temos que falar do amargo 7x1 da Copa do Mundo. Dia de tristeza para nós e exaltação para a Alemanha, a goleada em cima do Brasil traumatizou a nossa torcida e destacou o melhor time do mundial. Mas a vitória era de se esperar,

convenhamos. Além da disciplina e preparo físico dos atletas, a Alemanha tinha um elemento surpresa em sua escalação: Big Data Analytics.

Com este reforço foi possível avaliar as situações de jogo, treinar jogadas específicas para cada partida, medir a posse de bola do time e dos adversários, quem mais deu passes e até mesmo quem tinha mais chances de fazer gol.

A clássica tendência de analisar as estatísticas de cada jogo ganhou o apoio de softwares de última geração e analistas em campo, que mediram desempenho de cada jogador, cruzaram dados de partidas similares e analisaram a vantagem competitiva deste ou daquele atleta.

1.12.2 De olho no torcedor

É da arquibancada que ouvimos os gritos da torcida que ama seu time. A cada jogo, ela está lá, vestindo a camisa e promovendo a grande festa que é o futebol brasileiro.

Mas, o que pensam verdadeiramente os torcedores? O que mais se fala nas redes sociais sobre o clássico imperdível do fim de semana? A imagem de um time perante a imprensa e as ferramentas de interação social devem importar aos times de futebol. Afinal, são nesses espaços que estão os entusiastas e também os maiores críticos dos times e seus jogadores.

A análise de dados, então, se torna um aliado de peso capaz de ajudar mesmo fora de campo. A Hekima, por exemplo, coletou um volume gigantesco de informações sobre o embate entre Corinthians e Grêmio no Campeonato Brasileiro de 2014. Foram 95.030 posts e 45.252 usuários monitorados entre 18h30 e 22h30 no dia da partida.

A partir do monitoramento foi possível avaliar qual era a expectativa do torcedor para a Copa Libertadores da América, medir qual jogador estava em alta com a torcida (na época, Paolo Guerrero) e qual a avaliação do programa de sócio-torcedor do time. A diretoria e a arbitragem também não escaparam das menções das redes sociais e blogs avaliados pelo monitor, que rastreou até mesmo as confusões na arquibancada.

Com tantas informações a seu dispor, as diretorias, empresas administradoras dos estádios e até a CBF têm subsídios para tomada de decisões acertadas no que se refere ao esporte.

1.12.3 É correr para o abraço

Medição da frequência cardíaca do jogador, GPS para acompanhar suas movimentações nos treinos, hábitos alimentares, estatísticas de gol, quantidade de likes no Facebook. O céu é o limite para a quantidade de dados passíveis de coleta e de análise.

E, tudo junto, misturado e cruzado, pode render o que mais interessa ao futebol: gols. O monitoramento de redes sociais em conjunto com soluções de Big Data Analytics são o passe certo que faltava para esportistas e times alcançarem a sua melhor performance.

Referências Bibliográficas

Links:

- [1] *<http://www.bigdatabusiness.com.br/aprenda-mais-sobre-big-data-vendo-esses-7-cases-de-sucesso/>.*
- [2] *<http://www.bigdatabusiness.com.br/minority-report-da-vida-real-china-utiliza-big-data-para-prever-crimes/>.*
- [3] *<http://www.bigdatabusiness.com.br/big-data-analytics-faz-gol-tambem-no-futebol/>.*

Livros: