

Adaptação de Segundo Nível como Técnica de Estimação de Parâmetros e sua Aplicação ao Controle Adaptativo por Modelo de Referência

Orientador: Aldayr Dantas de Araújo

Aluno: Pedro Yochinori Gushiken

Universidade Federal do Rio Grande do Norte

31 de Janeiro de 2018

Sumário

- 1 Introdução
- 2 Identificação, ordem n , $n^*=1$
- 3 Controle, ordem n , $n^*=1$
- 4 Conclusões e Perspectivas

Controle automático

- Variáveis de entrada
- Variáveis de saída
- Projeto de um controlador

Controle adaptativo

- Incerteza paramétrica
- Estimação de parâmetros
- Princípio de equivalência à certeza
- Controlador não-linear
- Estabilidade
- Robustez
- Desempenho

Controle adaptativo indireto

- Modelo de identificação
- Estimação dos parâmetros da planta
- Cálculo dos parâmetros do controlador

Controle adaptativo indireto, cont.




Figura: Controlador adaptativo indireto

Leis de ajuste de parâmetros no controle adaptativo

- Leis integrais
- Leis chaveadas

Controle adaptativo com estrutura variável

- Leis de ajuste chaveadas
- Boas características de transitório
- Sinal de controle chaveado
- Intensidade do sinal de controle é proporcional à incerteza

Controle adaptativo com leis integrais

- Aprendizado
- Desempenho durante o transitório depende da incerteza
- Sinal de controle suave e de baixa intensidade

Propriedades de um conjunto de modelos de identificação

- Fecho convexo
- Combinação convexa
- Modelo virtual

Adaptação de segundo nível

- Estimação dos parâmetros da planta por leis integrais, nível 1
- Estimação dos coeficientes da combinação convexa por leis integrais, nível 2
- Utilização da combinação convexa como estimativa dos parâmetros da planta
- Controle adaptativo na estratégia indireta

Adaptação de segundo nível, cont.




Figura: Controlador adaptativo indireto de segundo nível

Descrição do problema

Considere-se a planta de ordem n , grau relativo unitário, LIT descrita por:

$$\Sigma_p : G_p(s) = \frac{y(s)}{u(s)} = \frac{N_p(s)}{D_p(s)}$$

em que:

$$\begin{aligned} N_p(s) &= b_1 s^{n-1} + b_2 s^{n-2} + \dots + b_{n-1} s + b_n \\ D_p(s) &= s^n + a_1 s^{n-1} + a_2 s^{n-2} + \dots + a_{n-1} s + a_n \end{aligned} \quad (1)$$

A região de incerteza para os coeficientes dos polinômios $N_p(s)$ e $D_p(s)$ é conhecida. Queremos identificar os valores dos coeficientes dos polinômios $N_p(s)$ e $D_p(s)$, considerando $u(t)$ PE, uniformemente limitado e contínuo por partes.

Modelo de identificação por regressão linear, cont.

Assim, definimos os seguintes sinais, com $\Lambda(s)$ mônico e Hurwitz:

$$\begin{aligned} z(s) &\triangleq \frac{s^n}{\Lambda(s)} y(s) \\ \phi_1(s) &\triangleq \left[\frac{-s^{n-1}y(s)}{\Lambda(s)} \quad \dots \quad \frac{-y(s)}{\Lambda(s)} \right]^T \\ \phi_2(s) &\triangleq \left[\frac{s^{n-1}u(s)}{\Lambda(s)} \quad \dots \quad \frac{u(s)}{\Lambda(s)} \right]^T \\ \phi(s) &\triangleq \left[\frac{-s^{n-1}y(s)}{\Lambda(s)} \quad \dots \quad \frac{-y(s)}{\Lambda(s)} \quad \frac{s^{n-1}u(s)}{\Lambda(s)} \quad \dots \quad \frac{u(s)}{\Lambda(s)} \right]^T = \begin{bmatrix} \phi_1^T & \phi_2^T \end{bmatrix}^T \\ \theta_p^* &\triangleq \begin{bmatrix} a_1 & \dots & a_n & b_1 & \dots & b_n \end{bmatrix}^T \end{aligned} \tag{2}$$

Modelo de identificação por regressão linear, cont. 2

O vetor regressor ϕ pode ser gerado através de filtros de $y(t)$ e $u(t)$:

$$\begin{aligned}\dot{\phi}_1 &= \Lambda_c \phi_1 - l y \\ \dot{\phi}_2 &= \Lambda_c \phi_2 + l u\end{aligned}\tag{3}$$

em que Λ_c e l são escolhidos de acordo com $\Lambda(s)$.

Modelo de identificação por regressão linear, cont. 3

O sinal z pode ser representado como uma combinação linear dos parâmetros da planta e do vetor regressor ϕ :

$$z(s) = \theta_p^{*T} \phi \quad (4)$$

e pode ser gerado por:

$$z(t) = \frac{s^n y}{\Lambda(s)} = y - \lambda_1 \frac{s^{n-1} y(s)}{\Lambda(s)} - \dots - \lambda_n \frac{y(s)}{\Lambda(s)} = y + \lambda_f^T \phi_1 \quad (5)$$

onde $\lambda_f^T = [\lambda_1 \quad \lambda_2 \quad \dots \quad \lambda_{n-1} \quad \lambda_n]$.

Modelo de identificação por regressão linear, cont. 4

Criamos um modelo de identificação para o sinal z :

$$\Sigma_{1,f} : \hat{z}_{1,f} = \hat{\theta}_{1,f}^T \phi \quad (6)$$

Definimos o erro de identificação:

$$e_{1,f} \triangleq \hat{z}_1 - z \quad (7)$$

Definimos também o seguinte sinal:

$$m^2 = 1 + n_s^2 \quad (8)$$

com $n_s = \phi^T \phi$.

Modelo de identificação por regressão linear, cont. 5

Construímos o erro de identificação normalizado:

$$\epsilon_{1,f} = \frac{e_{1,f}}{m^2} \quad (9)$$

As estimativas dos parâmetros da planta podem, então, ser atualizadas pela lei integral:

$$\hat{\theta}_{1,f} = -\Gamma \epsilon_{1,f} \phi \quad (10)$$

onde Γ é uma matriz simétrica e definida positiva.

Adaptação de segundo nível

A partir da parametrização que acabamos de apresentar, consideremos os $i = 1, \dots, N$, com $N \geq 2n + 1$, modelos:

$$\Sigma_{i,f} : \hat{z}_{i,f} = \hat{\theta}_{i,f}^T \phi \quad (11)$$

onde os parâmetros iniciais dos modelos formam um fecho convexo que contém a região de incerteza para os parâmetros da planta.

Definimos os $i = 1, \dots, N$ erros de identificação normalizados:

$$\epsilon_{i,f} = \frac{e_{i,f}}{m^2} \quad (12)$$

Adaptação de segundo nível, cont.

Definimos os erros paramétricos dos N modelos, com $i = 1, \dots, N$:

$$\tilde{\theta}_{i,f} = \hat{\theta}_{i,f} - \theta_p^* \quad (13)$$

As N estimativas do vetor de parâmetros da planta podem ser atualizadas pelas leis integrais:

$$\dot{\hat{\theta}}_{i,f} = -\Gamma \epsilon_{i,f} \phi \quad (14)$$

Adaptação de segundo nível, cont. 2

Considere-se um modelo virtual, com parâmetros formados por combinação convexa:

$$\begin{aligned}\Sigma_{v,f} : \hat{z}_{v,f} &= \theta_{v,f}^T \phi \\ \hat{\theta}_{v,f} &= \sum_{i=1}^N \hat{\theta}_{i,f} \beta_{i,f} \\ \sum_{i=1}^N \beta_{i,f} &= 1 \\ 0 &\leq \beta_{i,f} \leq 1\end{aligned}\tag{15}$$

Adaptação de segundo nível, cont. 3

Definimos os erros para o modelo virtual:

$$\begin{aligned}e_{v,f} &\triangleq \hat{z}_{v,f} - z \\ \epsilon_{v,f} &\triangleq \frac{e_{v,f}}{m^2}\end{aligned}\tag{16}$$

Ao analisar o modelo virtual chegamos às seguintes equações, para

$$e_{v,f}(0) = \sum_{i=1}^N e_{i,f}(0)\beta_{i,f}:$$

$$\begin{aligned}e_{v,f} &= \sum_{i=1}^N e_{i,f}\beta_{i,f} \\ \dot{\theta}_{v,f} &= -\Gamma \epsilon_{v,f} \phi\end{aligned}\tag{17}$$

Adaptação de segundo nível, cont. 4

Considere-se agora o seguinte modelo virtual em particular:

$$\begin{aligned}\Sigma_{\alpha,f} : \hat{z}_{\alpha,f} &= \theta_p^{*T} \phi \\ \theta_p^* &= \sum_{i=1}^N \hat{\theta}_{i,f} \alpha_{i,f}^* \\ \sum_{i=1}^N \alpha_{i,f}^* &= 1 \\ 0 \leq \alpha_{i,f}^* &\leq 1\end{aligned}\tag{18}$$

Adaptação de segundo nível, cont. 5

O erro de identificação para este modelo virtual tende a 0 exponencialmente, assim como o erro de identificação normalizado.

Ao analisar a dinâmica do erro de identificação para o modelo virtual e as leis de ajuste para seus parâmetros chegamos à seguinte equação, para

$$e_{\alpha f}(0) = \sum_{i=1}^N e_{if}(0) \alpha_{if}^*:$$

$$\lim_{t \rightarrow \infty} e_{\alpha f} = \lim_{t \rightarrow \infty} \sum_{i=1}^N e_{if} \alpha_{if}^* = 0 \quad (19)$$

Adaptação de segundo nível, cont. 6

Definimos os seguintes vetores:

$$\begin{aligned}\bar{E}_f &\triangleq \begin{bmatrix} \epsilon_{1,f} & \dots & \epsilon_{N-1,f} & \epsilon_{N,f} \end{bmatrix} \\ \bar{\alpha}_f^* &\triangleq \begin{bmatrix} \alpha_{1,f}^* & \dots & \alpha_{N-1,f}^* & \alpha_{N,f}^* \end{bmatrix}^T \\ E_f &\triangleq \begin{bmatrix} \epsilon_{1,f} - \epsilon_{N,f} & \epsilon_{2,f} - \epsilon_{N,f} & \dots & \epsilon_{N-1,f} - \epsilon_{N,f} \end{bmatrix} \\ \alpha_f^* &\triangleq \begin{bmatrix} \alpha_{1,f}^* & \alpha_{2,f}^* & \dots & \alpha_{N-1,f}^* \end{bmatrix}^T \\ \bar{\alpha}_f &\triangleq \begin{bmatrix} \alpha_{1,f} & \dots & \alpha_{N-1,f} & \alpha_{N,f} \end{bmatrix}^T \\ \alpha_f &\triangleq \begin{bmatrix} \alpha_{1,f} & \alpha_{2,f} & \dots & \alpha_{N-1,f} \end{bmatrix}^T\end{aligned}\tag{20}$$

Adaptação de segundo nível, cont. 7

Assim, podemos estimar $\bar{\alpha}_f^*$ através das seguintes equações:

$$\begin{aligned}\dot{\alpha}_f &= -E_f^T E_f \alpha_f - E_f^T \epsilon_{N,f} \\ \bar{\alpha}_f &= \left[\alpha_f^T \quad 1 - \mathbf{1}^T \alpha_f \right]^T\end{aligned}\tag{21}$$

A estimativa de segundo nível dos parâmetros da planta é então dada por:

$$\hat{\theta}_{n2,f} = \text{proj}_{S_{\theta,f}}(\alpha_{1,f} \hat{\theta}_{1,f} + \alpha_{2,f} \hat{\theta}_{2,f} + \dots + \alpha_{N,f} \hat{\theta}_{N,f})\tag{22}$$

onde $\text{proj}_{S_{\theta,f}}(.)$ é o operador de projeção retangular dentro da região de incerteza para os parâmetros da planta.

Adaptação de segundo nível, cont. 8

Definimos os erros paramétricos:

$$\begin{aligned}\tilde{\bar{\alpha}}_f &\triangleq \bar{\alpha}_f - \bar{\alpha}_f^* \\ \tilde{\alpha}_f &\triangleq \alpha_f - \alpha_f^*\end{aligned}\tag{23}$$

Usamos uma candidata a função de Lyapunov:

$$V(\tilde{\alpha}_f) = \frac{1}{2} \tilde{\alpha}_f^T \tilde{\alpha}_f\tag{24}$$

A função V não pode crescer a partir de algum instante, isto nos permite concluir que os sinais relevantes são uniformemente limitados.

Adicionalmente, como os parâmetros dos modelos tendem aos valores corretos, as estimativas de segundo nível também o fazem.

Adaptação de segundo nível com fator de esquecimento

Definimos as seguintes variáveis:

$$\begin{aligned} M_f &\triangleq \int_0^t e^{-\sigma(t-\tau)} E_f^T(\tau) E_f(\tau) d\tau \\ v_f &\triangleq \int_0^t e^{-\sigma(t-\tau)} E_f^T(\tau) \epsilon_{N,f}(\tau) d\tau \end{aligned} \quad (25)$$

onde $\sigma > 0$ é chamado fator de esquecimento.

E estimamos α_f^* a partir da equação:

$$\dot{\alpha}_f = -M_f \alpha_f - E_f^T E_f \alpha_f - v_f - E_f^T \epsilon_{N,f} \quad (26)$$

Adaptação de segundo nível com fator de esquecimento, cont.

Utilizando a mesma candidata a função de Lyapunov:

$$V(\tilde{\alpha}_f) = \frac{1}{2} \tilde{\alpha}_f^T \tilde{\alpha}_f \quad (27)$$

Novamente, V não pode crescer a partir de algum instante, o que nos permite concluir que os sinais relevantes são uniformemente limitados. Intuímos que esta modificação pode melhorar o processo de estimação dos coeficientes.

Resultados de simulação

Considere-se a planta LIT, de ordem 2 e grau relativo 1:

$$G_p(s) = \frac{N_p(s)}{D_p(s)} = \frac{b_1s + b_2}{s^2 + a_1s + a_2} = \frac{2s + 0}{s^2 + 4s + 3}$$

onde deseja-se identificar os parâmetros $b_1 = 2, b_2 = 0, a_1 = 4, a_2 = 3$. A região de incerteza é conhecida:

$$a_1 \in [3 \quad 8]$$

$$a_2 \in [1 \quad 6]$$

$$b_1 \in [-1 \quad 7]$$

$$b_2 \in [-3 \quad 3]$$

Resultados de simulação, cont.

Usamos o valor de $\hat{\theta}_{1,f}^T(0) = \begin{bmatrix} 3 & 1 & -1 & -3 \end{bmatrix}$ nas simulações. A matriz de ganhos adaptativos foi escolhida $\Gamma = 100I$. O ganho adaptativo de segundo nível foi escolhido $\gamma_{n2,f} = 10$. [VARIÁVEIS DE INICIALIZAÇÃO DETALHADAS](#).

Resultados de simulação, cont. 2




Figura:

Comportamento das estimativas do coeficiente a_1 do polinômio $D_p(s)$. A estimativa de primeiro nível converge mais rapidamente para uma vizinhança do valor correto.

Resultados de simulação, cont. 3




Figura:

Comportamento das estimativas do coeficiente a_2 do polinômio $D_p(s)$. A adaptação de segundo nível, nos dois modos usados, tende ao valor correto mais rapidamente.

Resultados de simulação, cont. 4




Figura:
Comportamento das estimativas do coeficiente b_1 do polinômio $N_p(s)$. A adaptação de segundo nível se mostra mais rápida.

Resultados de simulação, cont. 5




Figura:

Comportamento das estimativas do coeficiente b_2 do polinômio $N_p(s)$. A adaptação de segundo nível com fator de esquecimento rápida e suavemente atinge o valor correto.

Descrição do problema

Considere-se a planta LIT, de ordem n e grau relativo 1, descrita pela função de transferência:

$$\Sigma_{p,SISO} : G_p(s) = \frac{y(s)}{u(s)} = \frac{N_p(s)}{D_p(s)} = k_p \frac{Z_p(s)}{D_p(s)}$$

As seguintes hipóteses são verdadeiras:

- **P1** $Z_p(s)$ é mônico, Hurwitz e de grau $n - 1$
- **P2** O grau n de $D_p(s)$ é conhecido.
- **P3** O sinal de $b_1 = k_p$ é conhecido.
- **P4** $N_p(s)$ e $D_p(s)$ são coprimos

Descrição do problema, cont.

Considere-se o seguinte modelo de referência:

$$\Sigma_m : W_m(s) = \frac{y_m(s)}{r(s)} = k_m \frac{Z_m(s)}{D_m(s)}$$

que cumpre as seguintes condições:

- **M1** $Z_m(s)$ e $D_m(s)$ são Hurwitz e coprimos
- **M2** O grau de $D_m(s)$ é n
- **M3** O grau relativo de $W_m(s)$ é 1.

Descrição do problema, cont. 2

O polinômio $N_p(s)$ do numerador da função de transferência pode ser colocado em forma mônica, com $k_p = b_1$:

$$\begin{aligned} N_p(s) &= b_1 s^{n-1} + b_2 s^{n-2} + \dots + b_{n-1} s + b_n = k_p Z_p(s) \\ Z_p(s) &= s^{n-1} + \frac{b_2}{k_p} s^{n-2} + \dots + \frac{b_{n-1}}{k_p} s + \frac{b_n}{k_p} \end{aligned} \quad (28)$$

onde os coeficientes dos polinômios pertencem a uma região de incerteza conhecida.

Descrição do problema, cont. 3

Os polinômios $N_m(s)$ e $Z_m(s)$ são da forma:

$$\begin{aligned} Z_m(s) &= s^{n-1} + b_{m,2}s^{n-2} + \dots + b_{m,n-1}s + b_{m,n} \\ D_m(s) &= s^n + a_{m,1}s^{n-1} + a_{m,2}s^{n-2} + \dots + a_{m,n-1}s + a_{m,n} \end{aligned} \quad (29)$$

Queremos projetar um controlador que produza um sinal $u(t)$ na entrada da planta tal que a saída $y(t)$ rastreie a saída $y_m(t)$ do modelo de referência alimentado pelo sinal $r(t)$.

Equações de matching

Considera-se a seguinte lei de controle por realimentação:

$$u^* = \theta_1^{*T} \frac{\psi(s)}{\Lambda_w(s)} u + \theta_2^{*T} \frac{\psi(s)}{\Lambda_w(s)} y + \theta_3^* y + c_0^* r = \theta^{*T} w \quad (30)$$

onde:

$$\begin{aligned} w &\triangleq \left[\frac{\psi^T(s)}{\Lambda_w(s)} u \quad \frac{\psi^T(s)}{\Lambda_w(s)} y \quad y \quad r \right]^T \\ \psi(s) &\triangleq \left[s^{n-2} \quad s^{n-3} \quad \dots \quad s \quad 1 \right]^T \\ \theta^* &\triangleq \left[\theta_1^{*T} \quad \theta_2^{*T} \quad \theta_3^* \quad c_0^* \right]^T \end{aligned} \quad (31)$$

Equações de matching, cont.

Definimos os seguintes parâmetros:

$$\begin{aligned}\vec{a}_p &\triangleq \begin{bmatrix} a_2 & a_3 & \dots & a_n \end{bmatrix}^T \\ \vec{a}_m &\triangleq \begin{bmatrix} a_{m,2} & a_{m,3} & \dots & a_{m,n} \end{bmatrix}^T \\ \vec{b}_p &\triangleq \begin{bmatrix} \frac{b_2}{k_p} & \frac{b_3}{k_p} & \dots & \frac{b_n}{k_p} \end{bmatrix}^T \\ \vec{b}_m &\triangleq \begin{bmatrix} b_{m,2} & b_{m,3} & \dots & b_{m,n} \end{bmatrix}^T\end{aligned}\tag{32}$$

Equações de matching, cont. 2

Os parâmetros do controlador que cumprem o objetivo de controle são:

$$\begin{aligned}c_0^* &= \frac{k_m}{k_p} \\ \theta_1^* &= \vec{b}_m - \vec{b}_p \\ \theta_2^* &= \frac{\vec{d}_p - \vec{d}_m - (a_1 - a_{m,1})\vec{b}_m}{k_p} \\ \theta_3^* &= \frac{a_1 - a_{m,1}}{k_p}\end{aligned}\tag{33}$$

As equações 33 são chamadas equações de matching.

Controle adaptativo por modelo de referência indireto

Substituímos os parâmetros verdadeiros da planta pelas estimativas:

$$\begin{aligned}c_0 &= \frac{k_m}{\hat{k}_p} \\ \theta_1 &= \vec{b}_m - \hat{\vec{b}}_p \\ \theta_2 &= \frac{\hat{\vec{a}}_p - \vec{a}_m - (\hat{a}_1 - a_{m,1})\vec{b}_m}{\hat{k}_p} \\ \theta_3 &= \frac{\hat{a}_1 - a_{m,1}}{\hat{k}_p} \\ u &= \theta^T w\end{aligned}\tag{34}$$

Controle por modelo de referência e estrutura variável

Considere-se o erro de saída:

$$e_o = y - y_m \quad (35)$$

Pode-se escolher os parâmetros do controlador a cada instante como:

$$\begin{aligned} \theta_{1,i} &= -\bar{\theta}_{1,i} \text{sign}(c_0^* e_o w_{1,i}) \\ \theta_{2,i} &= -\bar{\theta}_{2,i} \text{sign}(c_0^* e_o w_{2,i}) \\ \theta_3 &= -\bar{\theta}_3 \text{sign}(c_0^* e_o y) \\ c_0 &= -\bar{c}_0 \text{sign}(c_0^* e_o r) \end{aligned} \quad (36)$$

onde escolhem-se $\bar{\theta}_{1,i} > |\theta_{1,i}^*|$ e $\bar{\theta}_{2,i} > |\theta_{2,i}^*|$, $\bar{\theta}_3 > |\theta_3^*|$ e $\bar{c}_0 > |c_0^*|$, com $i = 1, \dots, n-1$ pois conhecemos a região de incerteza para os parâmetros da planta.

Controle por modelo de referência e estrutura variável, cont.

Utiliza-se a seguinte candidata a função de Lyapunov:

$$V(e_o) = \frac{e^T P e}{2} \quad (37)$$

onde e é o vetor de erro entre o estado aumentado da planta e o estado aumentado do modelo de referência, como pode ser visto a partir da página 78 da dissertação. A função V decresce, o que permite concluir que os sinais relevantes são uniformemente limitados e o erro de saída tende a 0.

Resultados de simulação

Considere-se a planta de ordem n:

$$G_p(s) = \frac{N_p(s)}{D_p(s)} = \frac{b_1 s + b_2}{s^2 + a_1 s + a_2} = \frac{2s + 1}{s^2 - 3s - 4}$$

onde:

$$a_1 \in [-8 \quad -3]$$

$$a_2 \in [-6 \quad -1.5]$$

$$b_1 \in [1 \quad 7]$$

$$b_2 \in [0.5 \quad 1.5]$$

Resultados de simulação, cont.

Considere-se o modelo de referência:

$$W_m(s) = \frac{N_m(s)}{D_m(s)} = 1 \frac{s + 4}{s^2 + 4s + 4}$$

Queremos projetar um controlador que produza um sinal $u(t)$ tal que a saída da planta rastreie a saída do modelo de referência.

Resultados de simulação, cont.

Usamos o valor de $\hat{\theta}_{1,f}^T(0) = [-8 \quad -6 \quad 1 \quad 0.5]$ nas simulações. A matriz de ganhos adaptativos foi escolhida $\Gamma = 100I$. O ganho adaptativo de segundo nível foi escolhido $\gamma_{n2,f} = 10$ para a adaptação de segundo nível com fator de esquecimento e $\gamma'_{n2,f} = 3$ para a adaptação de segundo nível convencional. **VARIÁVEIS DE INICIALIZAÇÃO DETALHADAS**.

Resultados de simulação, cont. 2




Figura: Erro de saída da planta para os controladores com leis integrais. A adaptação de segundo nível faz com que o erro se aproxime de zero rapidamente.

Resultados de simulação, cont. 3




Figura: Sinal de controle gerado pelos controladores com leis de ajuste integrais. O sinal é suave.

Resultados de simulação, cont. 5




Figura: Sinal de controle gerado pelo controlador por modelo de referência e estrutura variável. O sinal exhibe chattering e alta amplitude.

Conclusões

A partir dos resultados de simulação observados, concluímos que:

- A adaptação de segundo nível é mais rápida que o método do gradiente normalizado, nos casos estudados.
- A aplicação da adaptação de segundo nível ao controle adaptativo indireto leva a um controlador com melhor desempenho, nos casos estudados.
- O transitório com adaptação de segundo nível é mais lento que o atingido pelo controle adaptativo com estrutura variável, em contrapartida o sinal de controle é suave e de menor intensidade.

Contribuições

Fizemos, neste trabalho, as seguintes contribuições:

- Adaptação de segundo nível baseada em modelos de identificação por regressão linear, de forma a aplicar o conceito à plantas SISO de ordem maior que 1.
- Adaptação de segundo nível com fator de esquecimento, intuindo que, ao acumular informações do transitório, é possível melhorar a convergência das estimativas.

Perspectivas

Entre as perspectivas futuras estão:

- Prova de estabilidade do controlador adaptativo indireto baseado na adaptação de segundo nível para a planta de ordem n e grau relativo qualquer.
- Adaptação de segundo nível para o caso MIMO.
- Adaptação de segundo nível aplicada ao APPC.
- Adaptação de segundo nível aplicada ao IDMARC.
- O uso da adaptação de segundo nível em conjunto com chaveamento entre múltiplos modelos de identificação, por meio da avaliação de funções de custo.

Inicialização de variáveis, identificação, ordem n

[VOLTAR](#)

Os parâmetros dos modelos de identificação foram inicializados nos seguintes valores:

$$\hat{\theta}_{1,f}^T(0) = \begin{bmatrix} 3 & 1 & -1 & -3 \end{bmatrix}$$

$$\hat{\theta}_{2,f}^T(0) = \begin{bmatrix} 28 & 1 & -1 & -3 \end{bmatrix}$$

$$\hat{\theta}_{3,f}^T(0) = \begin{bmatrix} 3 & 26 & -1 & -3 \end{bmatrix}$$

$$\hat{\theta}_{4,f}^T(0) = \begin{bmatrix} 3 & 1 & 39 & -3 \end{bmatrix}$$

$$\hat{\theta}_{5,f}^T(0) = \begin{bmatrix} 3 & 1 & -1 & 27 \end{bmatrix}$$

Inicialização de variáveis, identificação, ordem n, cont.

$$\Lambda(s) = s^2 + 6s + 9$$

$$\Lambda_c = \begin{bmatrix} -6 & -9 \\ 1 & 0 \end{bmatrix}$$

$$l = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$$

$$\Gamma = 100I$$

$$x_p(0) = \begin{bmatrix} 0.2 \\ 0.4 \end{bmatrix}$$

$$\phi_1(0) = \phi_2(0) = 0$$

Inicialização de variáveis, identificação, ordem n, cont. 2

$$u(t) = 1 + \sin(t) + \sin(1.7t) + \sin(3t)$$

$$\alpha_{1,f}(0) = 1$$

$$\alpha_i(0) = 0, \quad i \neq 1$$

$$\gamma_{n2,f} = 10$$

$$\sigma = 0.2$$

Inicialização de variáveis, controle, ordem n

[VOLTAR](#)

Para inicializar os modelos, usamos os seguintes valores:

$$\hat{\theta}_{1,f}^T(0) = [-8 \quad -6 \quad 1 \quad 0.5]$$

$$\hat{\theta}_{2,f}^T(0) = [29.5 \quad -6 \quad 1 \quad 0.5]$$

$$\hat{\theta}_{3,f}^T(0) = [-8 \quad 16.5 \quad 1 \quad 0.5]$$

$$\hat{\theta}_{4,f}^T(0) = [-8 \quad -6 \quad 31 \quad 0.5]$$

$$\hat{\theta}_{5,f}^T(0) = [-8 \quad -6 \quad 1 \quad 5.5]$$

Inicialização de variáveis, controle, ordem n, cont.

$$\Lambda(s) = s^2 + 6s + 9$$

$$\Lambda_c = \begin{bmatrix} -6 & -9 \\ 1 & 0 \end{bmatrix}$$

$$l = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$$

$$\Gamma = 100I$$

$$x_p(0) = \begin{bmatrix} 0.2 \\ 0.4 \end{bmatrix}$$

$$\phi_1(0) = \phi_2(0) = 0$$

Inicialização de variáveis, controle, ordem n, cont. 2

$$r(t) = 1 + \sin(t) + \sin(1.7t) + \sin(3t)$$

$$\alpha_{1,f}(0) = 1$$

$$\alpha_i(0) = 0, \quad i \neq 1$$

$$\gamma_{n2,f} = 10$$

$$\gamma'_{n2,f} = 3$$

$$\sigma = 6$$

Inicialização de variáveis, controle, ordem n, cont. 3

$$\Lambda_w(s) = s + 4$$

$$c_0 = \frac{k_m}{\hat{k}_p} = \frac{1}{\hat{b}_1}$$

$$\theta_1 = 4 - \frac{\hat{b}_2}{\hat{b}_1}$$

$$\theta_2 = \frac{-4\hat{a}_1 + \hat{a}_2 + 12}{\hat{b}_1}$$

$$\theta_3 = \frac{\hat{a}_1 - 4}{\hat{b}_1}$$

$$\theta = [\theta_1 \quad \theta_2 \quad \theta_3 \quad c_0]^T$$

Descrição do problema

Considere-se a planta de ordem 1, linear e invariante no tempo, descrita pela função de transferência:

$$\Sigma_p : G(s) = \frac{y(s)}{u(s)} = \frac{k_p}{s + a_p}$$

onde os parâmetros a_p e k_p são desconhecidos, mas pertencem a intervalos conhecidos.

Gostaríamos de identificar os valores dos parâmetros a_p e k_p , considerando que um sinal apropriado $u(t)$, persistentemente excitante, uniformemente limitado e contínuo por partes é aplicado à entrada.

Modelo de identificação por regressão linear, cont.

Assim, definimos os seguintes sinais:

$$\Lambda(s) = s + \lambda$$

$$z(s) \triangleq \frac{s}{\Lambda(s)} y(s)$$

$$\phi_1(s) \triangleq \frac{-y(s)}{\Lambda(s)} \quad (38)$$

$$\phi_2(s) \triangleq \frac{u(s)}{\Lambda(s)}$$

$$\phi(s) \triangleq \begin{bmatrix} \frac{-y(s)}{\Lambda(s)} & \frac{u(s)}{\Lambda(s)} \end{bmatrix}^T = \begin{bmatrix} \phi_1 & \phi_2 \end{bmatrix}^T$$

Modelo de identificação por regressão linear, cont. 2

O sinal z tem a seguinte parametrização:

$$z(s) = \begin{bmatrix} a_p & k_p \end{bmatrix} \phi \quad (39)$$

O sinal z pode ser gerado por:

$$z = \frac{sy}{\Lambda(s)} = y - \frac{\lambda y}{\Lambda(s)} = y + \lambda \phi_1 \quad (40)$$

Modelo de identificação por regressão linear, cont. 3

Criamos um modelo de identificação para o sinal z :

$$\Sigma_{1,f} : \hat{z}_1 = \begin{bmatrix} \hat{a}_{1,f} & \hat{k}_{1,f} \end{bmatrix} \phi \quad (41)$$

Definimos o erro de identificação:

$$e_{1,f} \triangleq \hat{z}_1 - z \quad (42)$$

E, a partir do erro de identificação e dos sinais de entrada e saída, podemos estimar os parâmetros da planta:

$$\begin{aligned} \dot{\hat{a}}_{1,f} &= e_{1,f}y \\ \dot{\hat{k}}_{1,f} &= -e_{1,f}u \end{aligned} \quad (43)$$

Para este tipo de modelo de identificação, os sinais relevantes são uniformemente

Adaptação de segundo nível

A partir da parametrização que acabamos de apresentar, consideremos os $i = 1, \dots, N$, com $N \geq 3$, modelos:

$$\Sigma_{i,f} : \hat{z}_{i,f} = \begin{bmatrix} \hat{a}_{i,f} & \hat{k}_{i,f} \end{bmatrix} \phi \quad (44)$$

onde os parâmetros iniciais dos modelos formam um fecho convexo que contém a região de incerteza para os parâmetros da planta.

Definimos os $i = 1, \dots, N$ erros de identificação em relação ao sinal filtrado da planta $z(t)$:

$$e_{i,f} \triangleq \hat{z}_{i,f} - z \quad (45)$$

Adaptação de segundo nível, cont.

Definimos os erros paramétricos dos N modelos, com $i = 1, \dots, N$:

$$\begin{aligned}\tilde{a}_{i,f} &\triangleq \hat{a}_{i,f} - a_p \\ \tilde{k}_{i,f} &\triangleq \hat{k}_{i,f} - k_p\end{aligned}\tag{46}$$

As $2N$ estimativas dos parâmetros da planta podem ser atualizadas pelas leis integrais:

$$\begin{aligned}\dot{\hat{a}}_{i,f} &= e_{i,f}y \\ \dot{\hat{k}}_{i,f} &= -e_{i,f}u\end{aligned}\tag{47}$$

Adaptação de segundo nível, cont. 2

Considere-se um modelo virtual, com parâmetros formados por combinação convexa:

$$\begin{aligned}
 \Sigma_{v,f} : \hat{z}_{v,f} &= [\hat{a}_{v,f} \hat{k}_{v,f}] \phi \\
 \hat{a}_{v,f} &= \sum_{i=1}^N \hat{a}_{i,f} \beta_{i,f} \\
 \hat{k}_{v,f} &= \sum_{i=1}^N \hat{k}_{i,f} \beta_{i,f} \\
 \sum_{i=1}^N \beta_{i,f} &= 1 \\
 0 &\leq \beta_{i,f} \leq 1
 \end{aligned} \tag{48}$$

Adaptação de segundo nível, cont. 3

Definimos o erro de identificação para o modelo virtual:

$$e_{v,f} \triangleq \hat{z}_{v,f} - z \quad (49)$$

Ao analisar a dinâmica do erro de identificação para o modelo virtual e as leis de ajuste para seus parâmetros chegamos às seguintes equações, para

$$e_{v,f}(0) = \sum_{i=1}^N e_{i,f}(0)\beta_{i,f}:$$

$$e_{v,f} = \sum_{i=1}^N e_{i,f}\beta_{i,f} \quad (50)$$

$$\dot{\hat{a}}_{v,f} = e_{v,f}y$$

$$\dot{\hat{k}}_{v,f} = -e_{v,f}u$$

Adaptação de segundo nível, cont. 4

Considere-se o seguinte modelo virtual em particular:

$$\begin{aligned}\Sigma_{\alpha,f} : \hat{z}_{\alpha,f} &= \begin{bmatrix} a_p & k_p \end{bmatrix} \phi \\ a_p &= \sum_{i=1}^N \hat{a}_{i,f} \alpha_{i,f}^* \\ k_p &= \sum_{i=1}^N \hat{k}_{i,f} \alpha_{i,f}^* \\ \sum_{i=1}^N \alpha_{i,f}^* &= 1 \\ 0 \leq \alpha_{i,f}^* &\leq 1\end{aligned}\tag{51}$$

Adaptação de segundo nível, cont. 5

Definimos os seguintes vetores:

$$\begin{aligned}
 \bar{E}_f &\triangleq \begin{bmatrix} e_{1,f} & \dots & e_{N-1,f} & e_{N,f} \end{bmatrix} \\
 \bar{\alpha}_f^* &\triangleq \begin{bmatrix} \alpha_{1,f}^* & \dots & \alpha_{N-1,f}^* & \alpha_{N,f}^* \end{bmatrix}^T \\
 E_f &\triangleq \begin{bmatrix} e_{1,f} - e_{N,f} & e_{2,f} - e_{N,f} & \dots & e_{N-1,f} - e_{N,f} \end{bmatrix} \\
 \alpha_f^* &\triangleq \begin{bmatrix} \alpha_{1,f}^* & \alpha_{2,f}^* & \dots & \alpha_{N-1,f}^* \end{bmatrix}^T \\
 \bar{\alpha}_f &\triangleq \begin{bmatrix} \alpha_{1,f} & \dots & \alpha_{N-1,f} & \alpha_{N,f} \end{bmatrix}^T \\
 \alpha_f &\triangleq \begin{bmatrix} \alpha_{1,f} & \alpha_{2,f} & \dots & \alpha_{N-1,f} \end{bmatrix}^T
 \end{aligned} \tag{52}$$

Adaptação de segundo nível, cont. 6

Assim, podemos estimar $\bar{\alpha}_f^*$ através das seguintes equações:

$$\begin{aligned}\dot{\alpha}_f &= -E_f^T E_f \alpha_f - E_f^T e_{N,f} \\ \bar{\alpha}_f &= \left[\alpha_f^T \quad 1 - \mathbf{1}^T \alpha_f \right]^T\end{aligned}\tag{53}$$

A estimativa de segundo nível dos parâmetros da planta é então dada por:

$$\begin{aligned}\hat{a}_{n2,f} &= \alpha_{1,f} \hat{a}_{1,f} + \alpha_{2,f} \hat{a}_{2,f} + \dots + \alpha_{N,f} \hat{a}_{N,f} \\ \hat{k}_{n2,f} &= \alpha_{1,f} \hat{k}_{1,f} + \alpha_{2,f} \hat{k}_{2,f} + \dots + \alpha_{N,f} \hat{k}_{N,f}\end{aligned}\tag{54}$$

Adaptação de segundo nível, cont. 7

Definimos os erros paramétricos:

$$\begin{aligned}\tilde{\bar{\alpha}}_f &\triangleq \bar{\alpha}_f - \bar{\alpha}_f^* \\ \tilde{\alpha}_f &\triangleq \alpha_f - \alpha_f^*\end{aligned}\tag{55}$$

Usamos uma candidata a função de Lyapunov:

$$V(\tilde{\alpha}_f) = \frac{1}{2} \tilde{\alpha}_f^T \tilde{\alpha}_f \tag{56}$$

Derivamos ao longo das trajetórias de V , obtendo que V não pode crescer a partir de algum instante, que nos permite concluir que os sinais relevantes são uniformemente limitados.

Adicionalmente, como os parâmetros dos modelos tendem aos valores corretos, as estimativas de segundo nível também o fazem.

Adaptação de segundo nível modificada

Seguindo a intuição de que há algum benefício em acumular informações de instantes anteriores, definimos as seguintes variáveis:

$$M_f \triangleq \int_0^t E_f^T(\tau) E_f(\tau) d\tau$$

$$v_f \triangleq \int_0^t E_f^T(\tau) e_{N,f}(\tau) d\tau$$

E passamos a estimar α_f^* a partir da equação:

$$\dot{\alpha}_f = -M_f \alpha_f - E_f^T E_f \alpha_f - v_f - E_f^T e_{N,f} \quad (58)$$

Adaptação de segundo nível modificada, cont.

Assumindo condições iniciais nulas, e utilizando a mesma candidata a função de Lyapunov:

$$V(\tilde{\alpha}_f) = \frac{1}{2} \tilde{\alpha}_f^T \tilde{\alpha}_f \quad (59)$$

Derivando ao longo das trajetórias de V obtemos que V deve decrescer a partir de algum instante, que nos permite concluir que os sinais relevantes são uniformemente limitados e que os coeficientes $\alpha_{i,f}$ tendem aos valores $\alpha_{i,f}^*$, mesmo que $u(t)$ não seja persistentemente excitante.

Resultados de simulação

Considere-se a planta de ordem 1:

$$\Sigma_p : G(s) = \frac{3}{s + 1.5}$$

onde $a_p \in [0.5 \quad 4]$, e $k_p \in [1 \quad 6]$.

Utilizamos $u(t) = \sin(t)$ que é PE de ordem 1. As estimativas de um dos modelos de primeiro nível são inicializadas em $\hat{a}(0) = 0.5$ e $\hat{k}(0) = 6$ e os coeficientes da combinação convexa são escolhidos tal que $\hat{a}_{n2,f}(0) = 0.5$ e $\hat{k}_{n2,f}(0) = 6$.

TABELA COM VARIÁVEIS DE INICIALIZAÇÃO

Resultados de simulação, cont. 2




Figura: Estimativa do parâmetro $k_p = 3$ para a planta Σ_p , 20 segundos de simulação, as estimativas de segundo nível tendem ao valor correto mais rapidamente.

Resultados de simulação, cont. 3




Figura:

Estimativas do parâmetro $a_p = 1.5$ para a planta Σ_p , 36 segundos de simulação, apesar de $u(t) = 1$ não ser PE, as estimativas de segundo nível atingem os valores corretos

Resultados de simulação, cont. 4




Figura:

Estimativas do parâmetro $k_p = 3$ para a planta Σ_p , 36 segundos de simulação, apesar de $u(t) = 1$ não ser PE, as estimativas de segundo nível atingem os valores corretos

Descrição do problema

Considere-se a planta LIT, de ordem 1 e grau relativo 1, descrita pela função de transferência:

$$\Sigma_p : G_p(s) = \frac{y(s)}{u(s)} = \frac{k_p}{s + a_p}$$

As seguintes hipóteses são verdadeiras:

- **P1** A ordem da planta e seu grau relativo são conhecidos
- **P2** O sinal de k_p é conhecido.

Descrição do problema, cont.

Considere-se o seguinte modelo de referência:

$$\Sigma_m : W_m(s) = \frac{y_m(s)}{r(s)} = \frac{k_m}{s + a_m}$$

que cumpre as seguintes condições:

- **M1** A ordem do modelo e seu grau relativo são iguais aos da planta.
- **M2** $s + a_m$ é Hurwitz, isto é, $a_m > 0$.

Queremos projetar um controlador que produza um sinal $u(t)$ na entrada da planta tal que a saída $y(t)$ rastreie a saída $y_m(t)$ do modelo de referência alimentado pelo sinal $r(t)$.

Equações de matching

Considera-se a seguinte lei de controle por realimentação:

$$u^* = k_1^* y + k_2^* r \quad (60)$$

Os parâmetros k_1^* e k_2^* que cumprem o objetivo de controle são:

$$\begin{aligned} k_1^* &= \frac{a_p - a_m}{k_p} \\ k_2^* &= \frac{k_m}{k_p} \end{aligned} \quad (61)$$

As equações 61 são chamadas equações de matching.

Controle adaptativo por modelo de referência indireto

Utilizando as equações de matching e o princípio de equivalência à certeza, substituímos os parâmetros da planta, que são desconhecidos, pelas estimativas que obtemos através dos métodos de estimação discutidos anteriormente:

$$\begin{aligned}k_1 &= \frac{\hat{a}_p - a_m}{\hat{k}_p} \\k_2 &= \frac{k_m}{\hat{k}_p}\end{aligned}\tag{62}$$

$$u = k_1 y + k_2 r$$

Controle por modelo de referência e estrutura variável

Considere-se o erro de saída:

$$e_o = y - y_m \quad (63)$$

Pode-se escolher k_1 e k_2 a cada instante como:

$$\begin{aligned} k_1 &= -\bar{k}_1 \text{sign}(k_p e_o y) \\ k_2 &= -\bar{k}_2 \text{sign}(k_p e_o r) \end{aligned} \quad (64)$$

onde escolhem-se $\bar{k}_1 > |k_1^*|$ e $\bar{k}_2 > |k_2^*|$, pois conhecemos a região de incerteza para os parâmetros da planta.

Controle por modelo de referência e estrutura variável, cont.

Utiliza-se a seguinte candidata a função de Lyapunov:

$$V(e_o) = \frac{e_o^2}{2} \quad (65)$$

Derivando ao longo de suas trajetórias temos que $\dot{V}$ é definida negativa, o que permite concluir que V decresce, os sinais relevantes são uniformemente limitados e o erro de saída tende a 0.

Resultados de simulação

Considere-se a planta de ordem 1:

$$\Sigma_p : G(s) = \frac{3}{s + 1.5}$$

onde $a_p \in [0.5 \quad 4]$, e $k_p \in [1 \quad 6]$.

Considere-se também o modelo de referência:

$$\Sigma_m : W_m(s) = \frac{5}{s + 5}$$

Queremos projetar um controlador $u(t)$ tal que a saída da planta rastreie a saída do modelo de referência.

Resultados de simulação, cont.

Utilizamos $r(t) = 1$. As estimativas de um dos modelos de primeiro nível são inicializadas em $\hat{a}(0) = 0.5$ e $\hat{k}(0) = 6$ e os coeficientes da combinação convexa são escolhidos tal que $\hat{a}_{n2,f}(0) = 0.5$ e $\hat{k}_{n2,f}(0) = 6$. **TABELA COM VARIÁVEIS DE INICIALIZAÇÃO**.
Para o controle com estrutura chaveada calculamos os parâmetros $\bar{k}_1 = 4.5$ e $\bar{k}_2 = 5$.

Resultados de simulação, cont. 2




Figura: Saída da planta Σ_p de ordem 1, 12 segundos de simulação, $r(t)=1$, a planta rastreia o modelo de referência. A adaptação de segundo nível mostra bom desempenho.

Resultados de simulação, cont. 4




Figura: Sinal de controle aplicado à planta de ordem 1, 12 segundos de simulação, $r(t) = 1$, os sinais de controle gerados são suaves e de baixa amplitude.

Resultados de simulação, cont. 5




Figura: Sinal de controle chaveado aplicado à planta de ordem 1, 12 segundos de simulação, $r(t) = 1$, observa-se chattering e alta amplitude do sinal.

Inicialização de variáveis, identificação, ordem 1

VOLTAR

N=3	N=4	N=8
$\hat{a}_{1,f}(0) = 0.5, \hat{k}_{1,f}(0) = 1$	$\hat{a}_{1,f}(0) = 0.5, \hat{k}_{1,f}(0) = 1$	$\hat{a}_{1,f}(0) = 0.5, \hat{k}_{1,f}(0) = 1$
$\hat{a}_{2,f}(0) = 0.5, \hat{k}_{2,f}(0) = 11$	$\hat{a}_{2,f}(0) = 4, \hat{k}_{1,f}(0) = 1$	$\hat{a}_{2,f}(0) = 2, \hat{k}_{2,f}(0) = 1$
$\hat{a}_{3,f}(0) = 7, \hat{k}_{3,f}(0) = 1$	$\hat{a}_{3,f}(0) = 4, \hat{k}_{3,f}(0) = 6$	$\hat{a}_{3,f}(0) = 4, \hat{k}_{3,f}(0) = 1$
$\alpha_{1,f}(0) = 0.5, \alpha_{2,f}(0) = 0.5$	$\hat{a}_{4,f}(0) = 0.5, \hat{k}_{4,f}(0) = 6$	$\hat{a}_{4,f}(0) = 4, \hat{k}_{4,f}(0) = 3$
	$\alpha_{4,f}(0) = 1$	$\hat{a}_{5,f}(0) = 4, \hat{k}_{5,f}(0) = 6$
Parâmetros Comuns		$\hat{a}_{6,f}(0) = 2.5, \hat{k}_{6,f}(0) = 6$
$\lambda = 4$	$\Lambda(s) = s + 4$	$\hat{a}_{7,f}(0) = 0.5, \hat{k}_{7,f}(0) = 4$
$u(t) = \text{sen}(t)$	$h = 0.001$	$\hat{a}_{8,f}(0) = 0.5, \hat{k}_{8,f}(0) = 6$
$\phi_1(0) = \phi_2(0) = 0$	$y(0) = 0.2$	$\alpha_{8,f}(0) = 1$

Inicialização de variáveis, controle, ordem 1

VOLTAR

N=3	Primeiro Nível	VS
$\hat{a}_{1,f}(0) = 0.5, \hat{k}_{1,f}(0) = 1$	$\hat{a}_{1,f} = 0.5, \hat{k}_{1,f} = 6$	$\bar{k}_1 = 4.5, \bar{k}_2 = 5$
$\hat{a}_{2,f}(0) = 0.5, \hat{k}_{2,f}(0) = 11$		$h = 0.0001$
$\hat{a}_{3,f}(0) = 7, \hat{k}_{3,f}(0) = 1$		
$\alpha_{1,f}(0) = 0.5, \alpha_{2,f}(0) = 0.5$		
Parâmetros Comuns		
$\lambda = 4$	$\phi_1(0) = \phi_2(0) = 0$	$y(0) = 0.2$
$h = 0.001$		$r(t) = 1$