

Nomenclatura

N	Número de Modelos de Identificação usados na Adaptação de Segundo Nível
$\vec{1}$	Vetor Linha de tamanho apropriado (determinado pelo contexto da equação em que está sendo aplicado) cujos elementos são todos 1
$\mathbf{0}$	Matriz de tamanho apropriado (determinado pelo contexto da equação em que está sendo aplicada) cujos elementos são todos 0
s	Variável complexa no domínio da frequência
Σ_p	Planta de ordem 1
$G(s)$	Função de Transferência da planta de ordem 1
y	Sinal de Saída da Planta de Ordem 1
$\Lambda(s)$	Polinômio mônico, de Grau 1 com raiz negativa
z	Sinal de Saída da Planta de Ordem 1 Filtrado por uma função de transferência própria $\frac{s}{\Lambda(s)}$
ϕ_1	Componente do vetor regressor ϕ gerado a partir de uma filtragem do sinal y por uma função de transferência própria $\frac{1}{\Lambda(s)}$
ϕ_2	Componente do vetor regressor ϕ gerado a partir de uma filtragem do sinal u por uma função de transferência própria $\frac{1}{\Lambda(s)}$
ϕ	Vetor Coluna formado pelos elementos ϕ_1 na primeira linha e ϕ_2 na segunda linha, e chamado vetor regressor
k_p	Coefficiente do polinômio do numerador da planta de ordem 1
k_p^+	Limitante superior da região de incerteza para o coeficiente k_p da planta de ordem 1

k_p^-	Limitante inferior da região de incerteza para o coeficiente k_p da planta de ordem 1
a_p	Coeficiente do polinômio mônico do denominador da planta de ordem 1
a_p^+	Limitante superior da região de incerteza para o coeficiente a_p da planta de ordem 1
a_p^-	Limitante inferior da região de incerteza para o coeficiente a_p da planta de ordem 1
$\Sigma_{1,p}$	Modelo de identificação paralelo 1 da planta de ordem 1
$G_{1,p}(s)$	Função de Transferência do Modelo de identificação Paralelo 1 da planta de ordem 1
$\hat{y}_{1,p}$	Estimativa do Sinal de Saída da Planta de Ordem 1 usando o Modelo de Identificação Paralelo 1
$e_{1,p}$	Erro de identificação gerado pela diferença entre o sinal de saída do Modelo de identificação Paralelo 1 e o sinal de saída da planta de ordem 1
$\hat{k}_{1,p}$	Estimativa do coeficiente do polinômio do numerador da planta de ordem 1 usando o Modelo de Identificação Paralelo 1
$\tilde{k}_{1,p}$	Erro paramétrico devido a diferença entre a estimativa $\hat{k}_{1,p}$ e o valor correto k_p
$\dot{\hat{k}}_{1,p}$	Lei Adaptativa para Atualização da Estimativa $\hat{k}_{1,p}$
$\hat{a}_{1,p}$	Estimativa do coeficiente do polinômio mônico do denominador da planta de ordem 1 usando o Modelo de Identificação Paralelo 1
$\tilde{a}_{1,p}$	Erro paramétrico devido a diferença entre a estimativa $\hat{a}_{1,p}$ e o valor correto a_p
$\dot{\hat{a}}_{1,p}$	Lei Adaptativa para Atualização da Estimativa $\hat{a}_{1,p}$
$\Sigma_{1,sp}$	Modelo de identificação série-paralelo 1 da planta de ordem 1
$\Sigma_{i,sp}$	i-ésimo Modelo de identificação Série-Paralelo da planta de ordem 1, com $i = 1, \dots, N$
$\Sigma_{v,sp}$	Modelo de identificação Virtual da planta de ordem 1 cujas estimativas dos parâmetros são formadas pela combinação convexa das estimativas de Modelos de Identificação Série Paralelos

$\hat{y}_{1,sp}$	Estimativa do Sinal de Saída da Planta de Ordem 1 usando o Modelo de Identificação Série-Paralelo 1
$\hat{y}_{i,sp}$	Estimativa do Sinal de Saída da Planta de Ordem 1 usando o i-ésimo Modelo de Identificação Série-Paralelo, com $i = 1, \dots, N$
$\hat{y}_{v,sp}$	Estimativa do Sinal de Saída da Planta de Ordem 1 usando o Modelo Virtual
$e_{1,sp}$	Erro de identificação gerado pela diferença entre o sinal de saída do Modelo de identificação Série-Paralelo 1 e o sinal de saída da planta de ordem 1
$e_{i,sp}$	Erro de identificação gerado pela diferença entre o sinal de saída do i-ésimo Modelo de identificação Série-Paralelo, com $i = 1, \dots, N$, e o sinal de saída da planta de ordem 1
$e_{N,sp}$	Erro de identificação gerado pela diferença entre o sinal de saída do Modelo de identificação Série-Paralelo N e o sinal de saída da planta de ordem 1
$e_{v,sp}$	Erro de identificação gerado pela diferença entre o sinal de saída do Modelo Virtual e o sinal de saída da planta de ordem 1
$\bar{E}_{sp}$	Vetor linha formado pelos Erros de identificação $e_{i,sp}$, com $i = 1, \dots, N$, em suas colunas
E_{sp}	Vetor linha formado pela diferença entre os Erros de identificação $e_{i,sp}$, com $i = 1, \dots, N - 1$, e o erro $e_{N,sp}$ em suas colunas
$\hat{k}_{1,sp}$	Estimativa do coeficiente do polinômio do numerador da planta de ordem 1 usando o Modelo de Identificação Série-Paralelo 1
$\tilde{k}_{1,sp}$	Erro paramétrico devido a diferença entre a estimativa $\hat{k}_{1,sp}$ e o valor correto k_p
$\dot{\hat{k}}_{1,sp}$	Lei Adaptativa para Atualização da Estimativa $\hat{k}_{1,sp}$
$\hat{k}_{i,sp}$	Estimativa do coeficiente do polinômio do numerador da planta de ordem 1 usando o i-ésimo Modelo de Identificação Série-Paralelo, com $i = 1, \dots, N$
$\hat{k}_{v,sp}$	Estimativa do coeficiente do polinômio do numerador da planta de ordem 1 usando o Modelo Virtual

$\tilde{k}_{i,sp}$	Erro paramétrico devido a diferença entre a estimativa $\hat{k}_{i,sp}$ e o valor correto k_p
$\tilde{k}_{v,sp}$	Erro paramétrico devido a diferença entre a estimativa $\hat{k}_{v,sp}$ e o valor correto k_p
$\dot{\hat{k}}_{i,sp}$	Lei Adaptativa para Atualização da Estimativa $\hat{k}_{i,sp}$
$\dot{\hat{k}}_{v,sp}$	Lei Adaptativa para Atualização da Estimativa $\hat{k}_{v,sp}$
$\hat{a}_{1,sp}$	Estimativa do coeficiente do polinômio mônico do denominador da planta de ordem 1 usando o Modelo de Identificação Série-Paralelo 1
$\hat{a}_{i,sp}$	Estimativa do coeficiente do polinômio mônico do denominador da planta de ordem 1 usando o i-ésimo Modelo de Identificação Série-Paralelo, com $i = 1, \dots, N$
$\hat{a}_{v,sp}$	Estimativa do coeficiente do polinômio mônico do denominador da planta de ordem 1 a partir de uma combinação convexa de coeficientes β_i dos parâmetros dos modelos de identificação série-paralelos
$\tilde{a}_{1,sp}$	Erro paramétrico devido a diferença entre a estimativa $\hat{a}_{1,sp}$ e o valor correto a_p
$\tilde{a}_{i,sp}$	Erro paramétrico devido a diferença entre a estimativa $\hat{a}_{i,sp}$ e o valor correto a_p , com $i = 1, \dots, N$
$\tilde{a}_{v,sp}$	Erro paramétrico devido a diferença entre a estimativa $\hat{a}_{v,sp}$ e o valor correto a_p
$\dot{\hat{a}}_{1,sp}$	Lei Adaptativa para Atualização da Estimativa $\hat{a}_{1,sp}$
$\dot{\hat{a}}_{i,sp}$	Lei Adaptativa para Atualização da Estimativa $\hat{a}_{i,sp}$, com $i = 1, \dots, N$
$\dot{\hat{a}}_{v,sp}$	Lei Adaptativa para Atualização da Estimativa $\hat{a}_{v,sp}$
$\alpha_{i,sp}^*$	Coeficientes da combinação convexa que quando aplicados às estimativas $\hat{k}_{i,sp}$ e $\hat{a}_{i,sp}$, com $i = 1, \dots, N$, formam k_p e a_p respectivamente
$\alpha_{i,sp}$	Coeficientes da combinação convexa que são aplicados às estimativas $\hat{k}_{i,sp}$ e $\hat{a}_{i,sp}$, com $i = 1, \dots, N$, para formar uma estimativa de segundo nível dos parâmetros k_p e a_p

$\beta_{i,sp}$	Coeficientes de uma combinação convexa que são aplicados às estimativas $\hat{k}_{i,sp}$ e $\hat{a}_{i,sp}$, com $i = 1, \dots, N$ para formar estimativas virtuais $\hat{a}_{v,sp}$ e $\hat{k}_{v,sp}$ dos parâmetros
α_{sp}^*	Vetor Coluna formado pelos Coeficientes $\alpha_{i,sp}^*$ em suas linhas, com $i = 1, \dots, N - 1$
$\bar{\alpha}_{sp}^*$	Vetor Coluna formado pelos Coeficientes $\alpha_{i,sp}^*$ em suas linhas, com $i = 1, \dots, N$
α_{sp}	Vetor Coluna formado pelos Coeficientes $\alpha_{i,sp}$ em suas linhas, com $i = 1, \dots, N - 1$
$\bar{\alpha}_{sp}$	Vetor Coluna formado pelos Coeficientes $\alpha_{i,sp}$ em suas linhas, com $i = 1, \dots, N$
$\bar{\Theta}_{sp}$	Matriz formada pelos coeficientes $a_{i,sp}$ na primeira linha e $k_{i,sp}$ na segunda linha, com $i = 1, \dots, N$
$\dot{\alpha}_{sp}$	Lei Adaptativa para Atualização do Vetor α_{sp}
$\hat{a}_{n2,sp}$	Estimativa de Segundo Nível do parâmetro a_p da planta usando como base Modelos de Identificação Série-Paralelo
$\hat{k}_{n2,sp}$	Estimativa de Segundo Nível do parâmetro k_p da planta usando como base Modelos de Identificação Série-Paralelo
$\Sigma_{1,f}$	Modelo de identificação por Regressão Linear 1 da planta de ordem 1
$\Sigma_{i,f}$	i-ésimo Modelo de identificação por Regressão Linear de ordem 1, com $i = 1, \dots, N$
$\Sigma_{v,f}$	Modelo de identificação Virtual da planta de ordem 1 cujas estimativas dos parâmetros são formadas pela combinação convexa das estimativas de Modelos de Identificação por Regressão Linear
$\hat{z}_{1,f}$	Estimativa do Sinal Filtrado de Saída da Planta de Ordem 1 usando o Modelo de Identificação por Regressão Linear 1
$\hat{z}_{i,f}$	Estimativa do Sinal Filtrado de Saída da Planta de Ordem 1 usando o i-ésimo Modelo de Identificação por Regressão Linear, com $i = 1, \dots, N$
$\hat{z}_{v,f}$	Estimativa do Sinal Filtrado de Saída da Planta de Ordem 1 usando o Modelo Virtual

$e_{1,f}$	Erro de identificação gerado pela diferença entre o sinal de saída do Modelo de identificação por Regressão Linear 1 e o Sinal de Saída da Planta de ordem 1 Filtrado
$e_{i,f}$	Erro de identificação gerado pela diferença entre o sinal de saída do i-ésimo Modelo de identificação por Regressão Linear, com $i = 1, \dots, N$, e o Sinal de Saída da Planta de ordem 1 Filtrado
$e_{N,f}$	Erro de identificação gerado pela diferença entre o sinal de saída do Modelo de identificação por Regressão Linear N e o Sinal de Saída da Planta de ordem 1 Filtrado
$e_{v,f}$	Erro de identificação gerado pela diferença entre o sinal de saída do Modelo Virtual e o Sinal de Saída da Planta de ordem 1 Filtrado
$\tilde{E}_f$	Vetor linha formado pelos Erros de identificação $e_{i,f}$, com $i = 1, \dots, N$, em suas colunas
E_f	Vetor linha formado pela diferença entre os Erros de identificação $e_{i,f}$, com $i = 1, \dots, N - 1$, e o erro $e_{N,f}$ em suas colunas
$\hat{k}_{1,f}$	Estimativa do coeficiente do polinômio do numerador da planta de ordem 1 usando o Modelo de Identificação por Regressão Linear 1
$\tilde{k}_{1,f}$	Erro paramétrico devido a diferença entre a estimativa $\hat{k}_{1,f}$ e o valor correto k_p
$\hat{k}_{1,f}$	Lei Adaptativa para Atualização da Estimativa $\hat{k}_{1,f}$
$\hat{k}_{i,f}$	Estimativa do coeficiente do polinômio do numerador da planta de ordem 1 usando o i-ésimo Modelo de Identificação por Regressão Linear, com $i = 1, \dots, N$
$\hat{k}_{v,f}$	Estimativa do coeficiente do polinômio do numerador da planta de ordem 1 usando o Modelo Virtual
$\tilde{k}_{i,f}$	Erro paramétrico devido a diferença entre a estimativa $\hat{k}_{i,f}$ e o valor correto k_p
$\tilde{k}_{v,f}$	Erro paramétrico devido a diferença entre a estimativa $\hat{k}_{v,f}$ e o valor correto k_p
$\hat{k}_{v,f}$	Lei Adaptativa para Atualização da Estimativa $\hat{k}_{v,f}$
$\hat{k}_{i,f}$	Lei Adaptativa para Atualização da Estimativa $\hat{k}_{i,f}$

$\hat{a}_{1,f}$	Estimativa do coeficiente do polinômio mônico do denominador da planta de ordem 1 usando o Modelo de Identificação por Regressão Linear 1
$\hat{a}_{i,f}$	Estimativa do coeficiente do polinômio mônico do denominador da planta de ordem 1 usando o i -ésimo Modelo de Identificação por Regressão Linear, com $i = 1, \dots, N$
$\hat{a}_{v,f}$	Estimativa do coeficiente do polinômio mônico do denominador da planta de ordem 1 a partir de uma combinação convexa de coeficientes β_i dos parâmetros dos modelos de identificação por regressão linear
$\tilde{a}_{1,f}$	Erro paramétrico devido a diferença entre a estimativa $\hat{a}_{1,f}$ e o valor correto a_p
$\tilde{a}_{i,f}$	Erro paramétrico devido a diferença entre a estimativa $\hat{a}_{i,f}$ e o valor correto a_p
$\tilde{a}_{v,f}$	Erro paramétrico devido a diferença entre a estimativa $\hat{a}_{v,f}$ e o valor correto a_p
$\dot{\hat{a}}_{1,f}$	Lei Adaptativa para Atualização da Estimativa $\hat{a}_{1,f}$
$\dot{\hat{a}}_{i,f}$	Lei Adaptativa para Atualização da Estimativa $\hat{a}_{i,f}$, com $i = 1, \dots, N$
$\dot{\hat{a}}_{v,f}$	Lei Adaptativa para Atualização da Estimativa $\hat{a}_{v,f}$
$\alpha_{i,f}^*$	Coefficientes da combinação convexa que quando aplicados às estimativas $\hat{k}_{i,f}$ e $\hat{a}_{i,f}$, com $i = 1, \dots, N$, formam k_p e a_p respectivamente
$\alpha_{i,f}$	Coefficientes da combinação convexa que são aplicados às estimativas $\hat{k}_{i,f}$ e $\hat{a}_{i,f}$, com $i = 1, \dots, N$, para formar uma estimativa de segundo nível dos parâmetros k_p e a_p
$\beta_{i,f}$	Coefficientes de uma combinação convexa que são aplicados às estimativas $\hat{k}_{i,f}$ e $\hat{a}_{i,f}$, com $i = 1, \dots, N$ para formar estimativas virtuais $\hat{a}_{v,f}$ e $\hat{k}_{v,f}$ dos parâmetros
α_f^*	Vetor Coluna formado pelos Coeficientes $\alpha_{i,f}^*$ em suas linhas, com $i = 1, \dots, N - 1$
$\bar{\alpha}_f^*$	Vetor Coluna formado pelos Coeficientes $\alpha_{i,f}^*$ em suas linhas, com $i = 1, \dots, N$
$\bar{\Theta}_f$	Matriz formada pelos coeficientes $a_{i,f}$ na primeira linha e $k_{i,f}$ na segunda linha, com $i = 1, \dots, N$

α_f	Vetor Coluna formado pelos Coeficientes $\alpha_{i,f}$ em suas linhas, com $i = 1, \dots, N - 1$
$\bar{\alpha}_f$	Vetor Coluna formado pelos Coeficientes $\alpha_{i,f}$ em suas linhas, com $i = 1, \dots, N$
$\dot{\alpha}_f$	Lei Adaptativa para Atualização do Vetor α_f
$\hat{a}_{n2,f}$	Estimativa de Segundo Nível do parâmetro a_p da planta usando como base Modelos de Identificação por Regressão Linear
$\hat{k}_{n2,f}$	Estimativa de Segundo Nível do parâmetro k_p da planta usando como base Modelos de Identificação por Regressão Linear

Capítulo 1

Estimação de Parâmetros, Ordem 1

Ao modelar um sistema dinâmico como um sistema linear descrito por uma função de transferência ou por uma equação diferencial em espaço de estado é comum lidar com incertezas nos coeficientes dos polinômios do numerador e denominador desta função ou nos elementos das matrizes (A, B, C, D) do espaço de estado, as chamadas incertezas paramétricas. As incertezas paramétricas têm vários fatores. Entre eles a falta de conhecimento completo sobre componentes físicos, cujos valores tipicamente se encontram dentro de uma certa tolerância como resistores, capacitores, amortecedores e indutores. Aproximações na modelagem como por exemplo sistemas cujo comportamento possui não-linearidades. Variações dos parâmetros devido ao desgaste ou envelhecimento como por exemplo o óleo de um motor de automóvel cuja viscosidade aumenta com o tempo ou uma engrenagem cujos dentes se desgastam com o uso. E mesmo devido a falhas de componentes como um transformador danificado por sobretensão na linha de transmissão.

Uma forma de atacar as incertezas paramétricas de modo a melhorar o conhecimento sobre a dinâmica atual do sistema é através da estimação dos parâmetros em tempo real. Um conhecimento mais preciso dos parâmetros pode permitir decisões melhores acerca de qual ação de controle tomar. Através de um modelo de estimação do sistema estudado, gera-se a diferença entre o sinal(ou sinais) de saída do sistema e o sinal(ou sinais) de saída do modelo de estimação, o chamado erro de identificação. Este erro pode ser empregado para gerar leis integrais para atualizar as estimativas. A atualização das estimativas faz com que as estimativas estejam mais próximas dos valores corretos do que as estimativas iniciais quando o sistema atinge o regime permanente. Além disso o erro de identificação tende a um valor nulo. Quando um sistema linear é sujeito a um sinal de entrada com a característica de persistência de excitação existe garantia de convergência das estimativas dos parâmetros para seus valores corretos [1, 2, 3]. O modelo de es-

timação se torna portanto um modelo de identificação pois eventualmente seus parâmetros serão idênticos aos parâmetros do sistema linear e não apenas estimativas próximas. Um exemplo de sinal persistentemente excitante é um sinal senoidal contendo pelo menos uma frequência para uma planta de ordem 1.

Neste capítulo faremos um passo-a-passo, de diferentes modelos de identificação que podem ser usados para estimar os parâmetros da função de transferência de uma planta de ordem 1 e grau relativo 1. Apresentamos primeiramente o caso mais simples por motivos didáticos, para que o leitor possa se familiarizar com as técnicas e conceitos discutidos, da forma como é feito na literatura como por exemplo em [4, 5, 6]. Usaremos sinais de controle com persistência de excitação de ordem 1 para atingir o objetivo de identificação dos parâmetros. Começamos descrevendo os modelos cujas estimativas dos parâmetros são atualizadas por leis integrais: o Modelo Paralelo, o Modelo Série-Paralelo e o Modelo por Regressão Linear. Os dois últimos sendo chamados Modelos de Identificação de Primeiro Nível. Estas descrições servem como uma introdução para que se possa discutir a técnica de estimação chamada Adaptação de Segundo Nível. A Adaptação de Segundo Nível foi introduzida por Han e Narendra em [7], com base em propriedades mostradas em [8], e discutida em [9, 10, 11], com resultados estendidos para o caso SISO em [12]. Na Adaptação de Segundo Nível os coeficientes de uma combinação linear convexa das estimativas dos parâmetros da planta vindas de múltiplos modelos de identificação de primeiro nível são atualizados por leis integrais como uma segunda camada de adaptação. Isto traz uma vantagem em termos de rapidez de convergência dos parâmetros, como foi extensivamente demonstrado nos trabalhos citados acima e se deve ao fato de que a informação proveniente dos múltiplos modelos estar sendo combinada. Após a descrição de cada um dos modelos e técnicas de identificação fazemos estudos de simulação usando cada uma destas técnicas discutindo seus resultados. Também colocamos os algoritmos utilizados no final do capítulo.

1.1 Modelos de Identificação Convencionais

1.1.1 Modelo de Identificação Paralelo

Considere a planta estável e invariante no tempo:

$$\Sigma_p : G(s) = \frac{y(s)}{u(s)} = \frac{k_p}{s + a_p} \quad (1.1)$$

em que $k_p \in [k_p^+ \quad k_p^-]$, $k_p^+ > 0$ e $k_p^- > 0$ ou $k_p^+ < 0$ e $k_p^- < 0$ e $a_p \in [a_p^+ \quad a_p^-]$,

$a_p^+ > 0$ e $a_p^- > 0$ e os limitantes $k_p^+, k_p^-, a_p^+, a_p^-$ são conhecidos, y é o sinal de saída da planta e u é o sinal de entrada. E o modelo de identificação:

$$\Sigma_{1,p} : G_{1,p}(s) = \frac{\hat{y}_{1,p}(s)}{u(s)} = \frac{\hat{k}_{1,p}}{s + \hat{a}_{1,p}} \quad (1.2)$$

em que $\hat{y}_{1,p}(s)$ é o sinal de saída do modelo de identificação. Podemos escrever na forma de equações diferenciais:

$$\begin{aligned} \Sigma_p : \dot{y} &= -a_p y + k_p u \\ \Sigma_{1,p} : \dot{\hat{y}}_{1,p} &= -\hat{a}_{1,p} \hat{y}_{1,p} + \hat{k}_{1,p} u \end{aligned} \quad (1.3)$$

e definimos então o erro de identificação:

$$e_{1,p} \triangleq \hat{y}_{1,p} - y \quad (1.4)$$

e obtemos sua dinâmica:

$$\dot{e}_{1,p} = \dot{\hat{y}}_{1,p} - \dot{y} = -\hat{a}_{1,p} \hat{y}_{1,p} + \hat{k}_{1,p} u - (-a_p y + k_p u)$$

definimos os erros paramétricos:

$$\begin{aligned} \tilde{a}_{1,p} &\triangleq \hat{a}_{1,p} - a_p \\ \tilde{k}_{1,p} &\triangleq \hat{k}_{1,p} - k_p \end{aligned} \quad (1.5)$$

e a dinâmica do erro de identificação $e_{1,p}$ pode ser escrita como:

$$\dot{e}_{1,p} = -a_p e_{1,p} - \tilde{a}_{1,p} \hat{y}_{1,p} + \tilde{k}_{1,p} u \quad (1.6)$$

então usamos a seguinte função definida positiva como uma candidata a função de Lyapunov:

$$V(e_{1,p}, \tilde{k}_{1,p}, \tilde{a}_{1,p}) = \frac{1}{2}(e_{1,p}^2 + \tilde{k}_{1,p}^2 + \tilde{a}_{1,p}^2) \quad (1.7)$$

e derivando ao longo das trajetórias obtemos:

$$\dot{V} = e_{1,p} \dot{e}_{1,p} + \tilde{k}_{1,p} \dot{\tilde{k}}_{1,p} + \tilde{a}_{1,p} \dot{\tilde{a}}_{1,p}$$

substituindo $\dot{e}_{1,p}$ por 1.6 obtemos:

$$\dot{V} = -a_p e_{1,p}^2 - \tilde{a}_{1,p} e_{1,p} \hat{y}_{1,p} + \tilde{k}_{1,p} e_{1,p} u + \tilde{k}_{1,p} \dot{\tilde{k}}_{1,p} + \tilde{a}_{1,p} \dot{\tilde{a}}_{1,p} \quad (1.8)$$

e como a planta é invariante no tempo temos:

$$\begin{aligned}\tilde{a}_{1,p} &= \hat{a}_{1,p} - a_p \rightarrow \dot{\tilde{a}}_{1,p} = \dot{\hat{a}}_{1,p} - \cancel{\dot{a}_p}^0 = \dot{\hat{a}}_{1,p} \\ \tilde{k}_{1,p} &= \hat{k}_{1,p} - k_p \rightarrow \dot{\tilde{k}}_{1,p} = \dot{\hat{k}}_{1,p} - \cancel{\dot{k}_p}^0 = \dot{\hat{k}}_{1,p}\end{aligned}$$

e portanto podemos escolher leis adaptativas para atualizar as estimativas $\hat{k}_{1,p}$ e $\hat{a}_{1,p}$ para cancelar os termos de sinal indefinido em $\dot{V}$. Se escolhermos:

$$\begin{aligned}\dot{\hat{a}}_{1,p} &= e_{1,p} \hat{y}_{1,p} \\ \dot{\hat{k}}_{1,p} &= -e_{1,p} u\end{aligned}\tag{1.9}$$

teremos então que:

$$\dot{V}(e_{1,p}, \tilde{k}_{1,p}, \tilde{a}_{1,p}) = -a_p e_{1,p}^2\tag{1.10}$$

$\dot{V}$ é semi-definida negativa e portanto V não pode crescer, o que implica em:

$$\begin{aligned}e_{1,p} &\in \mathcal{L}_\infty \\ \tilde{a}_{1,p} &\in \mathcal{L}_\infty \rightarrow \hat{a}_{1,p} \in \mathcal{L}_\infty \\ \tilde{k}_{1,p} &\in \mathcal{L}_\infty \rightarrow \hat{k}_{1,p} \in \mathcal{L}_\infty\end{aligned}$$

o sinal de controle u é escolhido tal que:

$$u \in \mathcal{L}_\infty$$

e como a planta é estável temos que:

$$y \in \mathcal{L}_\infty$$

como $e_{1,p} = \hat{y}_{1,p} - y \in \mathcal{L}_\infty$ e $y \in \mathcal{L}_\infty$, temos que:

$$\begin{aligned}\hat{y}_{1,p} &\in \mathcal{L}_\infty \\ \dot{e}_{1,p} &\in \mathcal{L}_\infty\end{aligned}$$

e finalmente, usando 1.10:

$$\begin{aligned}e_{1,p}^2 &= -\frac{1}{a_p} \dot{V} \\ \int_0^\infty e_{1,p}^2 &= -\frac{1}{a_p} \int_0^\infty \dot{V} \\ \int_0^\infty e_{1,p}^2 &= -\frac{1}{a_p} (V(\infty) - V(0))\end{aligned}$$

portanto:

$$e_{1,p} \in \mathcal{L}_2$$

usando o lema de Barbalat, como $e_{1,p}$ é uniformemente limitado, tem norma $\mathcal{L}_2$ limitada e sua derivada é uniformemente limitada temos que:

$$\lim_{t \rightarrow \infty} e_{1,p} = 0$$

adicionalmente, quando o sinal de controle u for persistentemente excitante, teremos que $e_{1,p} = 0$ para todo tempo $t > t_0$ sse $\tilde{a}_{1,p} = 0$ e $\tilde{k}_{1,p} = 0$ e as estimativas $\hat{a}_{1,p}$ e $\hat{k}_{1,p}$ tendem aos valores corretos a_p e k_p respectivamente, para $t \rightarrow \infty$. É importante notar que usando o modelo paralelo o valor de $\dot{V}$ depende de a_p que é um parâmetro da planta. Portanto a velocidade de convergência de $e_{1,p}$ para 0 depende de uma característica da planta.

1.1.2 Modelo de Identificação Série-Paralelo

Seja, novamente, a planta estável como em 1.1:

$$\Sigma_p : G(s) = \frac{y(s)}{u(s)} = \frac{k_p}{s + a_p}$$

colocando na forma de equação diferencial podemos escrever:

$$\begin{aligned} \dot{y} &= -a_p y + k_p u = -a_p y + a_m y - a_m y + k_p u \\ \dot{y} + a_m y &= -a_p y + a_m y + k_p u \end{aligned}$$

então, um Modelo de Identificação pode ser criado a partir da equação acima, substituindo y por uma estimativa de y no lado esquerdo da equação:

$$\Sigma_{1,p} : \dot{\hat{y}}_{1,p} + a_m \hat{y}_{1,p} = -\hat{a}_{1,p} y + a_m y + \hat{k}_{1,p} u$$

tal que:

$$\Sigma_{1,p} : \dot{\hat{y}}_{1,p} = -a_m \hat{y}_{1,p} - \hat{a}_{1,p} y + a_m y + \hat{k}_{1,p} u \quad (1.11)$$

definimos o erro de identificação:

$$e_{1,p} \triangleq \hat{y}_{1,p} - y \quad (1.12)$$

e sua dinâmica é da forma:

$$\dot{e}_{1,p} = \dot{\hat{y}}_{1,p} - \dot{y} = -a_m \hat{y}_{1,p} - \hat{a}_{1,p} y + a_m y + \hat{k}_{1,p} u + a_p y - k_p u$$

definimos os erros paramétricos:

$$\begin{aligned}\tilde{a}_{1,sp} &\triangleq \hat{a}_{1,sp} - a_p \\ \tilde{k}_{1,sp} &\triangleq \hat{k}_{1,sp} - k_p\end{aligned}\quad (1.13)$$

e escrevemos $\dot{e}_{1,sp}$ da seguinte forma:

$$\dot{e}_{1,sp} = -a_m e_{1,sp} - \tilde{a}_{1,sp} y + \tilde{k}_{1,sp} u \quad (1.14)$$

então, a partir de uma candidata a função de Lyapunov definida positiva da forma:

$$V(e_{1,sp}, \tilde{a}_{1,sp}, \tilde{k}_{1,sp}) = \frac{1}{2}(e_{1,sp}^2 + \tilde{a}_{1,sp}^2 + \tilde{k}_{1,sp}^2) \quad (1.15)$$

derivamos ao longo das trajetórias:

$$\begin{aligned}\dot{V} &= e_{1,sp} \dot{e}_{1,sp} + \tilde{a}_{1,sp} \dot{\tilde{a}}_{1,sp} + \tilde{k}_{1,sp} \dot{\tilde{k}}_{1,sp} \\ &= -a_m e_{1,sp}^2 - \tilde{a}_{1,sp} e_{1,sp} y + \tilde{k}_{1,sp} e_{1,sp} u + \tilde{a}_{1,sp} \dot{\tilde{a}}_{1,sp} + \tilde{k}_{1,sp} \dot{\tilde{k}}_{1,sp}\end{aligned}$$

e como a planta é invariante no tempo:

$$\begin{aligned}\tilde{a}_{1,sp} &= \hat{a}_{1,sp} - a_p \rightarrow \dot{\tilde{a}}_{1,sp} = \dot{\hat{a}}_{1,sp} - \overset{0}{\dot{a}_p} = \dot{\hat{a}}_{1,sp} \\ \tilde{k}_{1,sp} &= \hat{k}_{1,sp} - k_p \rightarrow \dot{\tilde{k}}_{1,sp} = \dot{\hat{k}}_{1,sp} - \overset{0}{\dot{k}_p} = \dot{\hat{k}}_{1,sp}\end{aligned}$$

podemos então escolher leis integrais para atualizar $\hat{a}_{1,sp}$ e $\hat{k}_{1,sp}$ tal que os termos de sinal indefinido em $\dot{V}$ sejam anulados:

$$\begin{aligned}\dot{\hat{a}}_{1,sp} &= e_{1,sp} y \\ \dot{\hat{k}}_{1,sp} &= -e_{1,sp} u\end{aligned}\quad (1.16)$$

e temos:

$$\dot{V}(e_{1,sp}, \tilde{a}_{1,sp}, \tilde{k}_{1,sp}) = -a_m e_{1,sp}^2 \quad (1.17)$$

$\dot{V}$ é semi-definida negativa e portanto V não pode crescer, o que implica em:

$$\begin{aligned}e_{1,sp} &\in \mathcal{L}_\infty \\ \tilde{a}_{1,sp} &\in \mathcal{L}_\infty \rightarrow \hat{a}_{1,sp} \in \mathcal{L}_\infty \\ \tilde{k}_{1,sp} &\in \mathcal{L}_\infty \rightarrow \hat{k}_{1,sp} \in \mathcal{L}_\infty\end{aligned}$$

o sinal de controle u é escolhido tal que:

$$u \in \mathcal{L}_\infty$$

e como a planta é estável temos que:

$$\begin{aligned} y &\in \mathcal{L}_\infty \\ \dot{e}_{1,sp} &\in \mathcal{L}_\infty \end{aligned}$$

como $e_{1,sp} = \hat{y}_{1,sp} - y \in \mathcal{L}_\infty$ e $y \in \mathcal{L}_\infty$, temos que:

$$\hat{y}_{1,sp} \in \mathcal{L}_\infty$$

e finalmente, manipulando a equação para $\dot{V}$:

$$\begin{aligned} e_{1,sp}^2 &= -\frac{1}{a_m} \dot{V} \\ \int_0^\infty e_{1,sp}^2 &= -\frac{1}{a_m} \int_0^\infty \dot{V} \\ \int_0^\infty e_{1,sp}^2 &= -\frac{1}{a_m} (V(\infty) - V(0)) \end{aligned}$$

portanto:

$$e_{1,sp} \in \mathcal{L}_2$$

usando o lema de Barbalat, como $e_{1,sp}$ é uniformemente limitado, tem norma $\mathcal{L}_2$ limitada e sua derivada é uniformemente limitada temos que:

$$\lim_{t \rightarrow \infty} e_{1,sp} = 0$$

adicionalmente, quando o sinal de controle u for persistentemente excitante, teremos que $e_{1,sp} = 0$ para todo tempo $t > t_0$ sse $\tilde{a}_{1,sp} = 0$ e $\tilde{k}_{1,sp} = 0$ e as estimativas $\hat{a}_{1,sp}$ e $\hat{k}_{1,sp}$ tendem aos valores corretos a_p e k_p respectivamente, para $t \rightarrow \infty$. É importante notar que usando o modelo série-paralelo o valor de $\dot{V}$ depende de a_m que é um parâmetro de projeto do estimador. Portanto a velocidade de convergência de $e_{1,sp}$ para 0 depende de um parâmetro de projeto.

1.1.3 Modelo de Identificação por Regressão Linear

Novamente, seja a planta estável:

$$\Sigma_p : G(s) = \frac{y(s)}{u(s)} = \frac{k_p}{s + a_p}$$

manipulando a função de transferência podemos escrever, no domínio da frequência:

$$sy(s) = -a_p y(s) + k_p u(s) \quad (1.18)$$

e definindo o seguinte polinômio:

$$\Lambda(s) \triangleq s + \lambda \quad (1.19)$$

com $\lambda > 0$, escalar, escrevemos:

$$\frac{s}{\Lambda(s)} y(s) = -a_p \frac{1}{\Lambda(s)} y(s) + k_p \frac{1}{\Lambda(s)} u(s) \quad (1.20)$$

definimos:

$$\begin{aligned} z(s) &\triangleq \frac{s}{\Lambda(s)} y(s) \\ \phi(s) &\triangleq \begin{bmatrix} \frac{-y(s)}{\Lambda(s)} & \frac{u(s)}{\Lambda(s)} \end{bmatrix}^T \end{aligned} \quad (1.21)$$

para gerar ϕ filtramos $y(t)$ e $u(t)$:

$$\begin{aligned} \dot{\phi}_1 &= -\lambda \phi_1 + y \\ \dot{\phi}_2 &= -\lambda \phi_2 + u \\ \phi &= [\phi_1 \quad \phi_2]^T \end{aligned} \quad (1.22)$$

e temos:

$$z(s) = [a_p \quad k_p] \phi \quad (1.23)$$

z pode ser gerado da seguinte forma:

$$z = y - \lambda \phi_1 \quad (1.24)$$

podemos criar um modelo de identificação a partir de uma combinação linear dos sinais componentes do vetor ϕ como:

$$\Sigma_{1,f} : \hat{z}_1 = [\hat{a}_{1,f} \quad \hat{k}_{1,f}] \phi \quad (1.25)$$

e definir um erro de identificação:

$$e_{1,f} \triangleq \hat{z}_1 - z \quad (1.26)$$

o sinal filtrado da saída da planta e seu modelo de identificação podem ser representados pelas equações diferenciais:

$$\begin{aligned}\dot{z} &= -\lambda z - a_p y + k_p u \\ \dot{\hat{z}}_1 &= -\lambda \hat{z}_1 - \hat{a}_{1,f} y + \hat{k}_{1,f} u - \hat{a}_{1,f} \phi_1 + \hat{k}_{1,f} \phi_2\end{aligned}\quad (1.27)$$

e a dinâmica de $e_{1,f}$ é dada por:

$$\dot{e}_{1,f} = -\lambda \hat{z}_1 - \hat{a}_{1,f} y + \hat{k}_{1,f} u + \lambda z + a_p y - k_p u - \hat{a}_{1,f} \phi_1 + \hat{k}_{1,f} \phi_2$$

definimos os erros paramétricos:

$$\begin{aligned}\tilde{a}_{1,f} &\triangleq \hat{a}_{1,f} - a_p \\ \tilde{k}_{1,f} &\triangleq \hat{k}_{1,f} - k_p\end{aligned}\quad (1.28)$$

tal que:

$$\dot{e}_{1,f} = -\lambda e_{1,f} - \tilde{a}_{1,f} y + \tilde{k}_{1,f} u - \hat{a}_{1,f} \phi_1 + \hat{k}_{1,f} \phi_2 \quad (1.29)$$

então, a partir de uma candidata a função de Lyapunov definida positiva da forma:

$$V(e_{1,f}, \tilde{a}_{1,f}, \tilde{k}_{1,f}) = \frac{1}{2}(e_{1,f}^2 + \tilde{a}_{1,f}^2 + \tilde{k}_{1,f}^2) \quad (1.30)$$

derivamos ao longo das trajetórias:

$$\begin{aligned}\dot{V} &= e_{1,f} \dot{e}_{1,f} + \tilde{a}_{1,f} \dot{\tilde{a}}_{1,f} + \tilde{k}_{1,f} \dot{\tilde{k}}_{1,f} \\ &= -\lambda e_{1,f}^2 - \tilde{a}_{1,f} e_{1,f} y + \tilde{k}_{1,f} e_{1,f} u + \tilde{a}_{1,f} \dot{\tilde{a}}_{1,f} + \tilde{k}_{1,f} \dot{\tilde{k}}_{1,f} - \hat{a}_{1,f} e_{1,f} \phi_1 + \hat{k}_{1,f} e_{1,f} \phi_2\end{aligned}$$

e como a planta é invariante no tempo:

$$\begin{aligned}\tilde{a}_{1,f} &= \hat{a}_{1,f} - a_p \rightarrow \dot{\tilde{a}}_{1,f} = \dot{\hat{a}}_{1,f} - \overset{0}{\cancel{\dot{a}_p}} = \dot{\hat{a}}_{1,f} \\ \tilde{k}_{1,f} &= \hat{k}_{1,f} - k_p \rightarrow \dot{\tilde{k}}_{1,f} = \dot{\hat{k}}_{1,f} - \overset{0}{\cancel{\dot{k}_p}} = \dot{\hat{k}}_{1,f}\end{aligned}$$

podemos então escolher leis integrais para atualizar $\hat{a}_{1,f}$ e $\hat{k}_{1,f}$ da seguinte forma:

$$\begin{aligned}\dot{\hat{a}}_{1,f} &= e_{1,f} y \\ \dot{\hat{k}}_{1,f} &= -e_{1,f} u\end{aligned}\quad (1.31)$$

e temos:

$$\dot{V}(e_{1,f}, \tilde{a}_{1,f}, \tilde{k}_{1,f}) = -(\lambda + y\phi_1 + u\phi_2)e_{1,f}^2 \quad (1.32)$$

a região de incerteza que contém os parâmetros da planta é conhecida, assim como o sinal dos parâmetros, desta forma, para uma frequência de sinal de entrada qualquer, sabemos que o módulo da função de transferência da planta cumpre a seguinte restrição:

$$|G(jw)| \leq \left| \frac{k_p^+}{jw + a_p^-} \right| \quad (1.33)$$

portanto podemos garantir a seguinte condição:

$$\lambda > y\phi_1 + u\phi_2 \quad (1.34)$$

pois basta garantir que λ é maior que a maior cota superior dos módulos dos sinais $y\phi_1$ e $u\phi_2$. As funções de transferência para ϕ_1 e ϕ_2 representam filtros passa-baixa de primeira ordem. O maior ganho de amplitude que um filtro passa-baixa pode impor a um sinal é quando a frequência do sinal é nula. Podemos escrever:

$$\begin{aligned} \sup(|y|) &\leq \sup(|u|) \left| \frac{k_p^+}{jw + a_p^-} \right| \\ \sup(|\phi_1|) &\leq \frac{\sup(|u|)}{\lambda} \left| \frac{k_p^+}{jw + a_p^-} \right| \\ \sup(|\phi_2|) &\leq \frac{\sup(|u|)}{\lambda} \end{aligned}$$

então, temos que a escolha de λ que cumpre:

$$\lambda > \sup(|u|) \sqrt{\left| \frac{k_p^+}{jw + a_p^-} \right|} + 1 \quad (1.35)$$

é suficiente para garantir que $\dot{V}$ seja semi-definida negativa e que portanto V não possa crescer, o que implica em:

$$\begin{aligned} e_{1,f} &\in \mathcal{L}_\infty \\ \tilde{a}_{1,f} &\in \mathcal{L}_\infty \rightarrow \hat{a}_{1,f} \in \mathcal{L}_\infty \\ \tilde{k}_{1,f} &\in \mathcal{L}_\infty \rightarrow \hat{k}_{1,f} \in \mathcal{L}_\infty \end{aligned}$$

o sinal de controle u deve ser escolhido tal que:

$$u \in \mathcal{L}_\infty$$

e como a planta é estável temos que:

$$y \in \mathcal{L}_\infty \rightarrow z \in \mathcal{L}_\infty$$

$$\dot{e}_{1,f} \in \mathcal{L}_\infty$$

como $e_{1,f} = \hat{z}_1 - z \in \mathcal{L}_\infty$ e $z \in \mathcal{L}_\infty$, temos que:

$$\hat{z}_1 \in \mathcal{L}_\infty$$

e finalmente, manipulando a equação para $\dot{V}$:

$$e_{1,f}^2 = -\frac{1}{\lambda + y\phi_1 + u\phi_2} \dot{V}$$

$$\int_0^\infty e_{1,f}^2 \leq -\frac{1}{\lambda - \sup(|y\phi_1|) - \sup(|u\phi_2|)} \int_0^\infty \dot{V}$$

$$\int_0^\infty e_{1,f}^2 \leq -\frac{1}{\lambda - \sup(|y\phi_1|) - \sup(|u\phi_2|)} (V(\infty) - V(0))$$

portanto:

$$e_{1,f} \in \mathcal{L}_2$$

usando o lema de Barbalat, como $e_{1,f}$ é uniformemente limitado, tem norma $\mathcal{L}_2$ limitada e sua derivada é uniformemente limitada temos que:

$$\lim_{t \rightarrow \infty} e_{1,f} = 0$$

adicionalmente, quando o sinal de controle u for persistentemente excitante, teremos que $e_{1,f} = 0$ para todo tempo $t > t_0$ sse $\tilde{a}_{1,f} = 0$ e $\tilde{k}_{1,f} = 0$ e as estimativas $\hat{a}_{1,f}$ e $\hat{k}_{1,f}$ tendem aos valores corretos a_p e k_p respectivamente, para $t \rightarrow \infty$. É importante notar que usando este modelo de identificação o valor de $\dot{V}$ depende de λ que é um parâmetro de projeto do estimador. Portanto a velocidade de convergência de $e_{1,f}$ para 0 depende de um parâmetro de projeto. $\hat{z}_1$ é gerado a partir de uma combinação linear dos componentes do vetor ϕ com os parâmetros $\hat{a}_{1,f}$ e $\hat{k}_{1,f}$. Para mais informações acerca dos Modelos de Identificação discutidos até agora, referimos o leitor a [5, 4, 6].

1.2 Estimação de Parâmetros de Segundo Nível

1.2.1 N Modelos de Identificação Série-Paralelo

Seja a planta estável:

$$\Sigma_p : \dot{y} = -a_p y + k_p u$$

e sejam os $i = 1, \dots, N$ modelos de identificação, com $N \geq 3$:

$$\Sigma_{i,sp} : \dot{\hat{y}}_{i,sp} = -a_m \hat{y}_{i,sp} - \hat{a}_{i,sp} y + a_m y + \hat{k}_{i,sp} u \quad (1.36)$$

definimos os $i = 1, \dots, N$ erros de identificação:

$$e_{i,sp} \triangleq \hat{y}_{i,sp} - y \quad (1.37)$$

e suas dinâmicas são representadas pelas $i = 1, \dots, N$ equações diferenciais:

$$\dot{e}_{i,sp} = -a_m e_{i,sp} - \hat{a}_{i,sp} y + a_p y + \hat{k}_{i,sp} u - k_p u$$

então, definimos os erros paramétricos dos N modelos, com $i = 1, \dots, N$:

$$\begin{aligned} \tilde{a}_{i,sp} &= \hat{a}_{i,sp} - a_p \\ \tilde{k}_{i,sp} &= \hat{k}_{i,sp} - k_p \end{aligned} \quad (1.38)$$

e as equações diferenciais podem ser escritas como:

$$\dot{e}_{i,sp} = -a_m e_{i,sp} - \tilde{a}_{i,sp} y + \tilde{k}_{i,sp} u \quad (1.39)$$

com $i = 1, \dots, N$ e como já foi visto anteriormente, as $2N$ estimativas dos parâmetros da planta podem ser atualizadas pelas leis integrais:

$$\begin{aligned} \dot{\hat{a}}_{i,sp} &= e_{i,sp} y \\ \dot{\hat{k}}_{i,sp} &= -e_{i,sp} u \end{aligned} \quad (1.40)$$

os vetores de parâmetros $[\hat{a}_{i,sp} \ \hat{k}_{i,sp}]$, $i = 1, \dots, N$, formam um fecho convexo no espaço de parâmetros. Cada um dos pontos no interior ou fronteira deste fecho convexo pode ser representado por uma combinação convexa:

$$\begin{aligned} \hat{a}_{v,sp} &= \sum_{i=1}^N \hat{a}_{i,sp} \beta_{i,sp} \\ \hat{k}_{v,sp} &= \sum_{i=1}^N \hat{k}_{i,sp} \beta_{i,sp} \\ \sum_{i=1}^N \beta_{i,sp} &= 1 \\ 0 &\leq \beta_{i,sp} \leq 1 \end{aligned} \quad (1.41)$$

se criarmos então um **MODELO DE IDENTIFICAÇÃO VIRTUAL** a partir de alguma destas combinações convexas:

$$\Sigma_{v,sp} : \dot{\hat{y}}_{v,sp} = -a_m \hat{y}_{v,sp} - \hat{a}_{v,sp} y + a_m y + \hat{k}_{v,sp} u \quad (1.42)$$

e definirmos o erro de identificação para o modelo virtual:

$$e_{v,sp} \triangleq \hat{y}_{v,sp} - y \quad (1.43)$$

e definindo os erros paramétricos:

$$\begin{aligned} \tilde{a}_{v,sp} &\triangleq \hat{a}_{v,sp} - a_p \\ \tilde{k}_{v,sp} &\triangleq \hat{k}_{v,sp} - k_p \end{aligned} \quad (1.44)$$

sua dinâmica e expressão no tempo são idênticas às dos modelos de primeiro nível:

$$\begin{aligned} \dot{e}_{v,sp} &= -a_m e_{v,sp} - \tilde{a}_{v,sp} y + \tilde{k}_{v,sp} u \\ e_{v,sp}(t) &= e_{v,sp}(0) e^{-a_m t} + \int_0^t e^{-a_m(t-\tau)} (-\tilde{a}_{v,sp}(\tau) y(\tau) + \tilde{k}_{v,sp}(\tau) u(\tau)) d\tau \end{aligned} \quad (1.45)$$

pode-se manipular as expressões dos erros paramétricos:

$$\begin{aligned} \tilde{a}_{v,sp} &= \sum_{i=1}^N \hat{a}_{i,sp} \beta_{i,sp} - a_p = \sum_{i=1}^N \hat{a}_{i,sp} \beta_{i,sp} - \sum_{i=1}^N a_p \beta_{i,sp} = \sum_{i=1}^N \tilde{a}_{i,sp} \beta_{i,sp} \\ \tilde{k}_{v,sp} &= \sum_{i=1}^N \hat{k}_{i,sp} \beta_{i,sp} - k_p = \sum_{i=1}^N \hat{k}_{i,sp} \beta_{i,sp} - \sum_{i=1}^N k_p \beta_{i,sp} = \sum_{i=1}^N \tilde{k}_{i,sp} \beta_{i,sp} \end{aligned} \quad (1.46)$$

segue que as leis adaptativas que governam o ajuste de $k_{v,sp}$ e $a_{v,sp}$ são da forma:

$$\begin{aligned} \dot{\hat{a}}_{v,sp} &= \sum_{i=1}^N \dot{\hat{a}}_{i,sp} \beta_{i,sp} \\ \dot{\hat{k}}_{v,sp} &= \sum_{i=1}^N \dot{\hat{k}}_{i,sp} \beta_{i,sp} \end{aligned} \quad (1.47)$$

substituindo as expressões relevantes obtemos:

$$\begin{aligned} \dot{\hat{a}}_{v,sp} &= y \sum_{i=1}^N e_{i,sp} \beta_{i,sp} \\ \dot{\hat{k}}_{v,sp} &= -u \sum_{i=1}^N e_{i,sp} \beta_{i,sp} \end{aligned} \quad (1.48)$$

assumindo que $y(0)$ é conhecido então é possível escolher $\hat{y}_{i,sp}(0) = \hat{y}_{v,sp}(0) = y(0)$ e ter que $e_{i,sp}(0) = e_{v,sp}(0) = 0$, com $i = 1, \dots, N$. Usando as expressões dos erros obtemos:

$$\begin{aligned}
 \hat{a}_{v,sp} &= y \int_0^t e^{-a_m(t-\tau)} \left(- \left(\sum_{i=1}^N \tilde{a}_{i,sp}(\tau) \beta_{i,sp} \right) y(\tau) + \left(\sum_{i=1}^N \tilde{k}_{i,sp}(\tau) \beta_{i,sp} \right) u(\tau) \right) d\tau \\
 &= y \int_0^t e^{-a_m(t-\tau)} \left(-\tilde{a}_{v,sp}(\tau) y(\tau) + \tilde{k}_{v,sp}(\tau) u(\tau) \right) d\tau \\
 \hat{k}_{v,sp} &= u \int_0^t e^{-a_m(t-\tau)} \left(- \left(\sum_{i=1}^N \tilde{a}_{i,sp}(\tau) \beta_{i,sp} \right) y(\tau) + \left(\sum_{i=1}^N \tilde{k}_{i,sp}(\tau) \beta_{i,sp} \right) u(\tau) \right) d\tau \\
 &= u \int_0^t e^{-a_m(t-\tau)} \left(-\tilde{a}_{v,sp}(\tau) y(\tau) + \tilde{k}_{v,sp}(\tau) u(\tau) \right) d\tau
 \end{aligned} \tag{1.49}$$

As expressões acima então se reduzem a:

$$\begin{aligned}
 \hat{a}_{v,sp} &= e_{v,sp} y \\
 \hat{k}_{v,sp} &= -e_{v,sp} u
 \end{aligned} \tag{1.50}$$

também é importante notar que obtivemos o seguinte resultado:

$$e_{v,sp} = \sum_{i=1}^N \beta_{i,sp} e_{i,sp} \tag{1.51}$$

as leis adaptativas obtidas acima têm forma idêntica àquelas usadas nos modelos de primeiro nível $\Sigma_{i,sp}, i = 1, \dots, N$. **Cada um dos pontos no interior do fecho convexo corresponde a um modelo virtual.** Conforme os modelos de primeiro nível têm seus parâmetros ajustados adaptativamente os modelos virtuais também tem seus parâmetros ajustados por leis idênticas. Assim, **uma combinação convexa de coeficientes constantes dos parâmetros de modelos de primeiro nível se comporta da mesma forma que um modelo de primeiro nível cujos parâmetros fossem inicializados nos mesmos valores.** Assumindo, então, que os parâmetros verdadeiros da planta a_p e k_p pertencem inicialmente ao fecho convexo, podem ser representados por uma combinação convexa de coeficientes $\alpha_{i,sp}^*$, $i = 1, \dots, N$, dos parâmetros dos modelos de primeiro nível:

$$\begin{aligned}
a_p &= \sum_{i=1}^N \hat{a}_{i,sp} \alpha_{i,sp}^* \\
k_p &= \sum_{i=1}^N \hat{k}_{i,sp} \alpha_{i,sp}^* \\
\sum_{i=1}^N \alpha_{i,sp}^* &= 1 \\
0 &\leq \alpha_{i,sp}^* \leq 1
\end{aligned} \tag{1.52}$$

e definimos o modelo virtual:

$$\Sigma_{\alpha,sp} : \dot{\hat{y}}_{\alpha,sp} = -a_m \hat{y}_{\alpha,sp} - a_p y + a_m y + k_p u \tag{1.53}$$

com erro de identificação:

$$e_{\alpha,sp} \triangleq \hat{y}_{\alpha,sp} - y \tag{1.54}$$

cujas dinâmica é simplesmente:

$$\dot{e}_{\alpha,sp} = -a_m e_{\alpha,sp} \tag{1.55}$$

e como vimos as estimativas acima são atualizadas da mesma forma que seriam para um modelo de primeiro nível inicializado nos valores corretos. Podemos verificar pelas equações acima que um modelo inicializado nos valores corretos com erro de identificação inicialmente nulo tem erro de identificação idênticamente nulo. Suas estimativas são idênticamente os valores corretos. Temos então que:

$$e_{\alpha,sp} \equiv 0 \tag{1.56}$$

e portanto se os parâmetros verdadeiros da planta pertencem inicialmente ao fecho convexo formado pelos parâmetros dos modelos de primeiro nível, devem fazê-lo para todo o tempo t.

Como vimos, se os parâmetros da planta pertencem ao fecho convexo formado pelos parâmetros dos modelos de primeiro nível, existe pelo menos uma combinação convexa de coeficientes $\alpha_{i,sp}^*, i = 1, \dots, N$, que caracteriza a planta para todo o tempo t, e portanto os coeficientes podem servir como uma alternativa de parametrização para a planta. Então, como uma segunda camada de estimação, ou **segundo nível de adaptação**, podemos estimar os coeficientes da combinação linear convexa. Pelas equações anteriores, temos que pode-se escrever $e_{\alpha,sp}$ como a combinação convexa dos erros dos modelos de primeiro nível:

$$e_{\alpha,sp} = \sum_{i=1}^N e_{i,sp} \alpha_{i,sp}^*$$

e definindo:

$$\bar{E}_{sp} = [e_{1,sp} \quad e_{2,sp} \quad \dots \quad e_{N,sp}] \quad (1.57)$$

e:

$$\alpha_{sp}^* = [\alpha_{1,sp}^* \quad \alpha_{2,sp}^* \quad \dots \quad \alpha_{N,sp}^*] \quad (1.58)$$

podemos escrever em forma matricial:

$$\bar{E}_{sp} \bar{\alpha}_{sp}^* = \sum_{i=1}^N e_{i,sp} \alpha_{i,sp}^* = 0 \quad (1.59)$$

pela combinação convexa temos que:

$$\sum_{i=1}^N \alpha_{i,sp}^* = 1$$

então o parâmetro $\alpha_{N,sp}^*$ pode ser expresso por:

$$\alpha_{N,sp}^* = 1 - \sum_{i=1}^{N-1} \alpha_{i,sp}^* \quad (1.60)$$

e explicitando o último termo do somatório em $\bar{E}_{sp} \bar{\alpha}_{sp}^*$:

$$\bar{E}_{sp} \bar{\alpha}_{sp}^* = \sum_{i=1}^{N-1} e_{i,sp} \alpha_{i,sp}^* + e_{N,sp} \alpha_{N,sp}^*$$

e então substituímos $\alpha_{N,sp}^*$ pela expressão obtida acima:

$$\bar{E}_{sp} \bar{\alpha}_{sp}^* = \sum_{i=1}^{N-1} e_{i,sp} \alpha_{i,sp}^* + e_{N,sp} (1 - \sum_{i=1}^{N-1} \alpha_{i,sp}^*) = 0$$

que reorganizado fica da seguinte forma:

$$\sum_{i=1}^{N-1} (e_{i,sp} - e_{N,sp}) \alpha_{i,sp}^* = -e_{N,sp} \quad (1.61)$$

e definimos:

$$E_{sp} \triangleq [e_{1,sp} - e_{N,sp} \quad e_{2,sp} - e_{N,sp} \quad \dots \quad e_{N-1,sp} - e_{N,sp}] \quad (1.62)$$

e:

$$\alpha_{sp}^* \triangleq [\alpha_{1,sp}^* \quad \alpha_{2,sp}^* \quad \dots \quad \alpha_{N-1,sp}^*] \quad (1.63)$$

com estas variáveis definidas, reescrevemos a equação 1.61 como:

$$E_{sp}\alpha_{sp}^* = -e_{N,sp} \quad (1.64)$$

e substituindo o vetor α_{sp}^* por uma estimativa α_{sp} , como anteriormente, pode-se obter uma equação diferencial para estimar α_{sp}^* :

$$\dot{\alpha}_{sp} = -E_{sp}^T E_{sp} \alpha_{sp} - E_{sp}^T e_{N,sp} \quad (1.65)$$

e a estimativa $\bar{\alpha}_{sp}$ de α_{sp}^* fica da forma:

$$\bar{\alpha}_{sp}^T = [\alpha_{sp}^T \quad 1 - \bar{\mathbf{1}}\alpha_{sp}] \quad (1.66)$$

onde $\bar{\mathbf{1}}$ é o vetor linha $[1 \quad 1 \quad \dots \quad 1]$ de tamanho apropriado. Definimos, então, o erro paramétrico para a estimativa $\bar{\alpha}_{sp}$ e para α_{sp} :

$$\begin{aligned} \tilde{\bar{\alpha}}_{sp} &\triangleq \bar{\alpha}_{sp} - \alpha_{sp}^* \\ \tilde{\alpha}_{sp} &\triangleq \alpha_{sp} - \alpha_{sp}^* \end{aligned} \quad (1.67)$$

e como pelo menos uma solução de $\bar{\alpha}_{sp}^*$ é invariante no tempo, escrevemos:

$$\begin{aligned} \dot{\tilde{\bar{\alpha}}}_{sp} &= \dot{\bar{\alpha}}_{sp} - \cancel{\dot{\alpha}_{sp}^*}^0 = \dot{\bar{\alpha}}_{sp} \\ \dot{\tilde{\alpha}}_{sp} &= \dot{\alpha}_{sp} - \cancel{\dot{\alpha}_{sp}^*}^0 = \dot{\alpha}_{sp} \end{aligned} \quad (1.68)$$

tal que, substituindo $\dot{\alpha}_{sp}$ por $\dot{\tilde{\alpha}}_{sp}$ e α_{sp} por $\tilde{\alpha}_{sp} + \alpha_{sp}^*$ em 1.65 e cancelando os termos equivalentes devido a 1.64, temos:

$$\dot{\tilde{\bar{\alpha}}}_{sp} = -E_{sp}^T E_{sp} \tilde{\alpha}_{sp} \quad (1.69)$$

a partir de uma candidata a função de Lyapunov definida positiva:

$$V(\tilde{\bar{\alpha}}_{sp}) = \frac{1}{2} \tilde{\bar{\alpha}}_{sp}^T \tilde{\bar{\alpha}}_{sp} \quad (1.70)$$

derivando ao longo das trajetórias teremos:

$$\dot{V} = \tilde{\bar{\alpha}}_{sp}^T \dot{\tilde{\bar{\alpha}}}_{sp}$$

e explicitando $\tilde{\bar{\alpha}}_{sp}$ e $\dot{\tilde{\bar{\alpha}}}_{sp}$:

$$\dot{V} = \begin{bmatrix} \tilde{\alpha}_{sp}^T & \mathbf{1} \tilde{\alpha}_{sp} \end{bmatrix} \begin{bmatrix} \dot{\alpha}_{sp}^T \\ \mathbf{1} \dot{\alpha}_{sp} \end{bmatrix}$$

ao substituírmos $\dot{\alpha}_{sp}$ por 1.69, obtemos:

$$\dot{V} = -\tilde{\alpha}_{sp}^T E_{sp}^T E_{sp} \tilde{\alpha}_{sp} + \mathbf{1} \tilde{\alpha}_{sp} \mathbf{1} E_{sp}^T E_{sp} \tilde{\alpha}_{sp}$$

que reorganizado, tendo em mente que neste caso $\mathbf{1} \mathbf{1}^T = N - 1$, pode ser expresso por:

$$\dot{V} = -N \tilde{\alpha}_{sp}^T E_{sp}^T E_{sp} \tilde{\alpha}_{sp} \quad (1.71)$$

nesta expressão de $\dot{V}$ fica expressa uma característica importante da Adaptação de Segundo Nível, isto é, a velocidade com que a função de energia V decresce está relacionada com o número de modelos escolhidos, de forma que quanto mais modelos de identificação de primeiro nível forem usados, mais rápida será a convergência dos parâmetros. Ademais, $\dot{V}$ é semi-definida negativa (pois temos uma forma quadrática de sinal negativo com uma matriz semi-definida positiva) e portanto V não pode crescer, temos então que:

$$\tilde{\alpha}_{sp} \in \mathcal{L}_\infty \rightarrow \tilde{\alpha}_{sp} \in \mathcal{L}_\infty$$

e que:

$$\tilde{\alpha}_{sp} \in \mathcal{L}_\infty \rightarrow \tilde{\alpha}_{sp} \in \mathcal{L}_\infty$$

$$\tilde{\alpha}_{sp} \in \mathcal{L}_\infty \rightarrow \alpha_{sp} \in \mathcal{L}_\infty$$

e como:

$$E_{sp}, \alpha_{sp} \in \mathcal{L}_\infty \rightarrow \dot{\alpha}_{sp}, \ddot{\alpha}_{sp} \in \mathcal{L}_\infty$$

quando o sinal de controle u for persistentemente excitante teremos que E_{sp} só será o vetor nulo a partir de algum instante qualquer se as estimativas dos parâmetros forem equivalentes aos parâmetros corretos a_p e k_p , o que indica que uma combinação convexa destes parâmetros também tenderá para os valores corretos. As estimativas dos parâmetros a_p e k_p da planta, $\hat{a}_{n2,sp}$ e $\hat{k}_{n2,sp}$ são entregues pela combinação convexa de coeficientes $\alpha_{i,sp}, i = 1, \dots, N$ dos parâmetros $\hat{a}_{i,sp}$ e $\hat{k}_{i,sp}$, $i = 1, \dots, N$:

$$\begin{aligned} \hat{a}_{n2,sp} &= \alpha_{1,sp} \hat{a}_{1,sp} + \alpha_{2,sp} \hat{a}_{2,sp} + \dots + \alpha_{N,sp} \hat{a}_{N,sp} \\ \hat{k}_{n2,sp} &= \alpha_{1,sp} \hat{k}_{1,sp} + \alpha_{2,sp} \hat{k}_{2,sp} + \dots + \alpha_{N,sp} \hat{k}_{N,sp} \end{aligned} \quad (1.72)$$

Adaptação de Segundo Nível Modificada

Como foi demonstrado, é possível estimar $\alpha_{i,sp}^*$, $i = 1, \dots, N$ através das equações 1.65 e 1.66. No entanto, como $E_{sp}^T E_{sp}$ é uma matriz de posto 1 ou 0, não podemos concluir mais nada sem a presença de um sinal com persistência de excitação pois $\lambda_{\min}(E_{sp}^T E_{sp}) \equiv 0$. Como forma de melhorar este resultado, fazemos o seguinte raciocínio:

$$\begin{aligned}
 E_{sp}^T E_{sp} \alpha_{sp}^* &= -E_{sp}^T e_{N,sp} \\
 \int_0^t E_{sp}^T(\tau) E_{sp}(\tau) \alpha_{sp}^* d\tau &= - \int_0^t E_{sp}^T(\tau) e_{N,sp}(\tau) d\tau \\
 \int_0^t E_{sp}^T(\tau) E_{sp}(\tau) d\tau \alpha_{sp}^* &= - \int_0^t E_{sp}^T(\tau) e_{N,sp}(\tau) d\tau \\
 0 &= - \int_0^t E_{sp}^T(\tau) E_{sp}(\tau) d\tau \alpha_{sp}^* - \int_0^t E_{sp}^T(\tau) e_{N,sp}(\tau) d\tau \\
 0 &= - \int_0^t E_{sp}^T(\tau) E_{sp}(\tau) d\tau \alpha_{sp}^* - E_{sp}^T E_{sp} \alpha_{sp}^* - \int_0^t E_{sp}^T(\tau) e_{N,sp}(\tau) d\tau - E_{sp}^T e_{N,sp}
 \end{aligned}$$

como os erros de identificação $e_{i,sp}, i = 1, \dots, N$, são limitados e tendem a 0 a medida que o tempo t tende a infinito, as integrais são limitadas e tendem a valores constantes. Substituindo α_{sp}^* por sua estimativa temos a seguinte equação:

$$\hat{\alpha}_{sp} = - \int_0^t E_{sp}^T(\tau) E_{sp}(\tau) d\tau \hat{\alpha}_{sp} - E_{sp}^T E_{sp} \hat{\alpha}_{sp} - \int_0^t E_{sp}^T(\tau) e_{N,sp}(\tau) d\tau - E_{sp}^T e_{N,sp}$$

e por facilidade de notação, usamos variáveis para as integrais:

$$\begin{aligned}
 M_{sp} &= \int_0^t E_{sp}^T(\tau) E_{sp}(\tau) d\tau \\
 v_{sp} &= \int_0^t E_{sp}^T(\tau) e_{N,sp}(\tau) d\tau
 \end{aligned} \tag{1.73}$$

e escrevemos:

$$\hat{\alpha}_{sp} = -M_{sp} \hat{\alpha}_{sp} - E_{sp}^T E_{sp} \hat{\alpha}_{sp} - v_{sp} - E_{sp}^T e_{N,sp} \tag{1.74}$$

então usamos uma candidata a função de Lyapunov definida positiva:

$$V(\tilde{\alpha}_{sp}) = \frac{1}{2} \tilde{\alpha}_{sp}^T \tilde{\alpha}_{sp} \quad (1.75)$$

que resulta em:

$$\dot{V} = -N \tilde{\alpha}_{sp}^T (E_{sp}^T E_{sp} + M_{sp}) \tilde{\alpha}_{sp} \quad (1.76)$$

para cada instante de tempo existe um autovetor ligado ao espaço nulo da matriz $E_{sp}^T E_{sp}$. Então para um vetor arbitrário $w_q \in \mathbb{R}^{N-1}$ constante:

$$w_q^T \left(\int_0^\infty E_{sp}^T(\tau) E_{sp}(\tau) d\tau \right) w_q > 0$$

pois assumimos que não existe um vetor w_q , constante e não-nulo, que seja equivalente a um múltiplo escalar do autovetor associado ao espaço nulo da matriz $E_{sp}^T E_{sp}$ (pois assumimos que a direção deste autovetor está mudando ao longo do tempo), o que tornará $w_q^T E_{sp}^T E_{sp} w_q$ positivo durante algum intervalo de tempo, qualquer que seja w_q . Portanto a matriz M_{sp} converge para uma matriz simétrica com valores de seus elementos constantes, definida positiva e de posto cheio. Temos então, para um intervalo finito entre 0 e $t_0 > 0$ escolhido tal que $\lambda_{\min}(E_{sp}^T E_{sp} + M_{sp}) > 0$ a partir de t_0 , que:

$$\int_0^{t_0} \|\tilde{\alpha}_{sp}\|^2 d\tau < K$$

onde K é um escalar finito, pois $\tilde{\alpha}_{sp}$ é uniformemente limitado. E temos pela desigualdade de Rayleigh que:

$$\begin{aligned} \lambda_{\min}(E_{sp}^T E_{sp} + M_{sp}) \|\tilde{\alpha}_{sp}\|^2 & \leq \\ & \tilde{\alpha}_{sp}^T (E_{sp}^T E_{sp} + M_{sp}) \tilde{\alpha}_{sp} \\ & \leq \\ \lambda_{\max}(E_{sp}^T E_{sp} + M_{sp}) \|\tilde{\alpha}_{sp}\|^2 \end{aligned}$$

e usando a equação obtida para $\dot{V}$ temos que:

$$\|\tilde{\alpha}_{sp}\|^2 \leq \frac{-\dot{V}}{N \lambda_{\min}(E_{sp}^T E_{sp} + M_{sp})}$$

substituímos λ_{min} que varia com o tempo por um valor $\lambda_{min,inf}$ constante, a menor cota inferior do conjunto de autovalores mínimos da matriz $E_{sp}^T E_{sp} + M_{sp}$ a partir do instante t_0 e integrando temos:

$$\int_0^\infty \|\tilde{\alpha}_{sp}(\tau)\|^2 d\tau \leq \int_0^{t_0} \|\tilde{\alpha}_{sp}(\tau)\|^2 d\tau + \frac{-1}{N\lambda_{min,inf}(E_{sp}^T E_{sp} + M_{sp})} (V(\infty) - V(t_0))$$

como o lado direito desta equação é um valor limitado seu lado esquerdo também é limitado e temos que:

$$\tilde{\alpha}_{sp} \in \mathcal{L}_2$$

e finalmente, pelo lema de Barbalat, temos que a o vetor $\tilde{\alpha}_{sp}$ é uniformemente limitado, sua norma $\mathcal{L}_2$ é uniformemente limitada e sua derivada é uniformemente limitada:

$$\lim_{t \rightarrow \infty} \tilde{\alpha}_{sp} = \mathbf{0}$$

temos então que:

$$\lim_{t \rightarrow \infty} \tilde{\alpha}_{sp} = \mathbf{0} \rightarrow \lim_{t \rightarrow \infty} \tilde{\alpha}_{N,sp} = 0$$

e portanto, com a modificação proposta, existe garantia de convergência dos coeficientes $\hat{\alpha}_{i,sp}$, $i = 1, \dots, N$, para seus valores corretos, sem que se necessite impor sobre a planta um sinal de controle com a característica de persistência de excitação. Outra forma de calcular os coeficientes corretos é monitorando o posto de M_{sp} e resolvendo o sistema de equações $M_{sp}\alpha_{sp}^{*T} = -v_{sp}$ para α_{sp}^* quando for verificado que M_{sp} é de posto cheio e suficientemente distante de ser uma matriz singular, para evitar erro numérico. No entanto, é importante ressaltar que esta melhora na convergência dos parâmetros implica numa perda em outro aspecto importante, isto é, caso a planta tenha seus parâmetros variando lentamente no tempo, as informações acumuladas nos elementos da matriz M_{sp} e do vetor v_{sp} deixarão gradualmente de ser válidas na atualização ou cálculo dos coeficientes, fazendo com que os coeficientes acabem convergindo para valores distintos dos corretos, o que é algo que não acontece sem a modificação já que a Adaptação de Segundo Nível para o Modelo Série-Paralelo usa apenas as informações disponíveis em tempo presente.

1.2.2 N Modelos de Identificação por Regressão Linear

Novamente, seja a planta estável:

$$\Sigma_p : \dot{y} = -a_p y + k_p u$$

temos, isolando o termo $sy(s)$ à esquerda:

$$sy(s) = -a_p y(s) + k_p u(s)$$

lembrando que definimos o seguinte polinômio:

$$\Lambda(s) \triangleq s + \lambda$$

com $\lambda > 0$, escalar, e escrevemos:

$$\frac{s}{\Lambda(s)} y(s) = -a_p \frac{1}{\Lambda(s)} y(s) + k_p \frac{1}{\Lambda(s)} u(s)$$

e definimos anteriormente:

$$z(s) \triangleq \frac{s}{\Lambda(s)} y(s)$$

$$\phi(s) \triangleq \begin{bmatrix} \frac{-y(s)}{\Lambda(s)} & \frac{u(s)}{\Lambda(s)} \end{bmatrix}^T$$

e representamos o sinal de saída filtrado da planta como:

$$z(s) = \begin{bmatrix} a_p & k_p \end{bmatrix} \phi$$

e os $i = 1, \dots, N$ modelos de identificação deste sinal:

$$\Sigma_{i,f} : \hat{z}_{i,f} = \begin{bmatrix} \hat{a}_{i,f} & \hat{k}_{i,f} \end{bmatrix} \phi \quad (1.77)$$

e definimos os $i = 1, \dots, N$ erros de identificação deste sinal:

$$e_{i,f} \triangleq \hat{z}_{i,f} - z \quad (1.78)$$

e suas dinâmicas são representadas pelas $i = 1, \dots, N$ equações diferenciais:

$$\dot{e}_{i,f} = -(\lambda + y\phi_1 + u\phi_2)e_{i,f} - \hat{a}_{i,f}y + a_p y + \hat{k}_{i,f}u - k_p u$$

então, definimos os erros paramétricos dos N modelos, com $i = 1, \dots, N$:

$$\begin{aligned} \tilde{a}_{i,f} &= \hat{a}_{i,f} - a_p \\ \tilde{k}_{i,f} &= \hat{k}_{i,f} - k_p \end{aligned} \quad (1.79)$$

e as equações diferenciais podem ser escritas como:

$$\dot{e}_{i,f} = -(\lambda + y\phi_1 + u\phi_2)e_{i,f} - \tilde{a}_{i,f}y + \tilde{k}_{i,f}u \quad (1.80)$$

com $i = 1, \dots, N$ e como já foi visto anteriormente, as $2N$ estimativas dos parâmetros da planta podem ser atualizadas pelas leis integrais:

$$\begin{aligned}\dot{\hat{a}}_{i,f} &= e_{i,f}y \\ \dot{\hat{k}}_{i,f} &= -e_{i,f}u\end{aligned}\tag{1.81}$$

com $i = 1, \dots, N$. Faremos agora um detalhamento do raciocínio referente à introdução de uma segunda camada de estimação, ou **Adaptação de Segundo Nível**, como na seção anterior. Os vetores de parâmetros $[\hat{a}_{i,f} \ \hat{k}_{i,f}]$, $i = 1, \dots, N$ formam um fecho convexo no espaço de parâmetros. Cada um dos pontos no interior ou fronteira deste fecho convexo pode ser representado por uma combinação convexa:

$$\begin{aligned}\hat{a}_{v,f} &= \sum_{i=1}^N \hat{a}_{i,f} \beta_{i,f} \\ \hat{k}_{v,f} &= \sum_{i=1}^N \hat{k}_{i,f} \beta_{i,f} \\ \sum_{i=1}^N \beta_{i,f} &= 1 \\ 0 &\leq \beta_{i,f} \leq 1\end{aligned}\tag{1.82}$$

se criarmos então um **MODELO DE IDENTIFICAÇÃO VIRTUAL** a partir de alguma destas combinações convexas:

$$\Sigma_{v,f} : \hat{z}_{v,f} = [\hat{a}_{v,f} \ \hat{k}_{v,f}] \phi\tag{1.83}$$

e definirmos o erro de identificação para o modelo virtual:

$$e_{v,f} \triangleq \hat{z}_{v,f} - z\tag{1.84}$$

e definindo os erros paramétricos:

$$\begin{aligned}\tilde{a}_{v,f} &= \hat{a}_{v,f} - a_p \\ \tilde{k}_{v,f} &= \hat{k}_{v,f} - k_p\end{aligned}\tag{1.85}$$

sua dinâmica será idêntica às dos modelos de primeiro nível:

$$\dot{e}_{v,f} = -(\lambda + y\phi_1 + u\phi_2)e_{v,f} - \tilde{a}_{v,f}y + \tilde{k}_{v,f}u\tag{1.86}$$

podemos manipular as expressões dos erros paramétricos:

$$\begin{aligned}\tilde{a}_{v,f} &= \sum_{i=1}^N \hat{a}_{i,f} \beta_{i,f} - a_p = \sum_{i=1}^N \hat{a}_{i,f} \beta_{i,f} - \sum_{i=1}^N a_p \beta_{i,f} = \sum_{i=1}^N \tilde{a}_{i,f} \beta_{i,f} \\ \tilde{k}_{v,f} &= \sum_{i=1}^N \hat{k}_{i,f} \beta_{i,f} - k_p = \sum_{i=1}^N \hat{k}_{i,f} \beta_{i,f} - \sum_{i=1}^N k_p \beta_{i,f} = \sum_{i=1}^N \tilde{k}_{i,f} \beta_{i,f}\end{aligned}\quad (1.87)$$

segue que as leis adaptativas que governam o ajuste de $k_{v,f}$ e $a_{v,f}$ são da forma:

$$\begin{aligned}\dot{\hat{a}}_{v,f} &= \sum_{i=1}^N \dot{\hat{a}}_{i,f} \beta_{i,f} \\ \dot{\hat{k}}_{v,f} &= \sum_{i=1}^N \dot{\hat{k}}_{i,f} \beta_{i,f}\end{aligned}\quad (1.88)$$

no entanto, ao contrário do caso do modelo série-paralelo, não dispomos de uma expressão no tempo para os erros de identificação. Podemos no entanto utilizar as expressões anteriores:

$$\sum_{i=1}^N \dot{e}_{i,f} \beta_{i,f} = -(\lambda + y\phi_1 + u\phi_2) \sum_{i=1}^N e_{i,f} \beta_{i,f} - \tilde{a}_{v,f} y + \tilde{k}_{v,f} u \quad (1.89)$$

ou seja, a dinâmica da combinação convexa $\sum_{i=1}^N e_{i,f} \beta_{i,f}$ é exatamente igual à dinâmica do erro de identificação do modelo virtual $e_{v,f}$. A combinação convexa dos erros de identificação tende exponencialmente para o valor do erro de identificação do modelo virtual. Se estipularmos que $e_{v,f}(0) = \sum_{i=1}^N e_{i,f}(0) \beta_{i,f}$ então os dois se tornam equivalentes. Feitas estas considerações, teremos então que as expressões das leis adaptativas se reduzem a:

$$\begin{aligned}\dot{\hat{a}}_{v,f} &= e_{v,f} y \\ \dot{\hat{k}}_{v,f} &= -e_{v,f} u\end{aligned}\quad (1.90)$$

e novamente, as leis adaptativas obtidas acima têm forma idêntica àquelas usadas nos modelos de primeiro nível $\Sigma_{i,f}$, $i = 1, \dots, N$. **Cada um dos pontos no interior do fecho convexo corresponde a um modelo virtual.** Conforme os modelos de primeiro nível têm seus parâmetros ajustados adaptativamente os modelos virtuais também tem seus parâmetros ajustados por leis idênticas. Nestas condições, **uma combinação convexa de coeficientes constantes dos parâmetros de modelos de primeiro nível se comporta como se fosse os parâmetros de um modelo de primeiro nível inicializados nos mesmos valores.** Assumindo, então,

que os parâmetros verdadeiros da planta a_p e k_p pertencem inicialmente ao fecho convexo, podem ser representados por uma combinação convexa de coeficientes $\alpha_{i,f}^*, i = 1, \dots, N$ dos parâmetros dos modelos de primeiro nível:

$$\begin{aligned} a_p &= \sum_{i=1}^N \hat{a}_{i,f} \alpha_{i,f}^* \\ k_p &= \sum_{i=1}^N \hat{k}_{i,f} \alpha_{i,f}^* \\ \sum_{i=1}^N \alpha_{i,f}^* &= 1 \\ 0 &\leq \alpha_{i,f}^* \leq 1 \end{aligned} \quad (1.91)$$

e definimos o modelo virtual:

$$\Sigma_{\alpha,f} : \hat{z}_{\alpha,f} = [a_p \quad k_p] \phi \quad (1.92)$$

com erro de identificação:

$$e_{\alpha,f} \triangleq \hat{z}_{\alpha,f} - z \quad (1.93)$$

cuja dinâmica é:

$$\dot{e}_{\alpha,f} = -(\lambda + y\phi_1 + u\phi_2)e_{\alpha,f} \quad (1.94)$$

que nos dá o seguinte resultado:

$$\lim_{t \rightarrow \infty} e_{\alpha,f} = \lim_{t \rightarrow \infty} \sum_{i=1}^N e_{i,f} \alpha_{i,f}^* = 0 \quad (1.95)$$

desta forma, os parâmetros da planta podem deixar de pertencer ao fecho convexo devido ao efeito das condições iniciais. No entanto este resultado indica que os parâmetros da planta voltam a pertencer ao fecho convexo. Se a combinação convexa dos erros de identificação não-nulos se torna constante e nula a partir de um certo instante então a combinação convexa dos erros paramétricos também se torna constante e nula. Desta forma os coeficientes $\alpha_{i,f}^*, i = 1, \dots, N$ servem como alternativas de parametrização para a planta. Assim, como uma segunda camada de estimação, ou **segundo nível de adaptação**, podemos estimar os coeficientes da combinação linear. Consideramos, portanto, que a equação $\sum_{i=1}^N e_{i,f} \alpha_{i,f}^* = 0$ é uma ferramenta adequada de estimação. Definimos:

$$\bar{E}_f = [e_{1,f} \quad \dots \quad e_{N-1,f} \quad e_{N,f}] \quad (1.96)$$

e:

$$\bar{\alpha}_f^* = [\alpha_{1,f}^* \quad \dots \quad \alpha_{N-1,f}^*] \quad (1.97)$$

tal que temos em forma matricial:

$$\bar{E}_f \bar{\alpha}_f^* = \sum_{i=1}^N e_{i,f} \alpha_{i,f}^* = 0 \quad (1.98)$$

pela combinação convexa temos que:

$$\sum_{i=1}^N \alpha_{i,f} = 1$$

então o parâmetro $\alpha_{N,f}^*$ pode ser expresso por:

$$\alpha_{N,f} = 1 - \sum_{i=1}^{N-1} \alpha_{i,f}^*$$

e explicitando o último termo do somatório em $\bar{E}_f \bar{\alpha}_f^*$:

$$\bar{E}_f \bar{\alpha}_f^* = \sum_{i=1}^{N-1} e_{i,f} \alpha_{i,f}^* + e_{N,f} \alpha_{N,f}^*$$

e então substituímos $\alpha_{N,f}$ por sua expressão:

$$\bar{E}_f \bar{\alpha}_f^* = \sum_{i=1}^{N-1} e_{i,f} \alpha_{i,f}^* + e_{N,f} (1 - \sum_{i=1}^{N-1} \alpha_{i,f}^*) = 0$$

que reorganizado fica da seguinte forma:

$$\sum_{i=1}^{N-1} (e_{i,f} - e_{N,f}) \alpha_{i,f}^* = -e_{N,f} \quad (1.99)$$

e definimos:

$$E_f = [e_{1,f} - e_{N,f} \quad e_{2,f} - e_{N,f} \quad \dots \quad e_{N-1,f} - e_{N,f}] \quad (1.100)$$

e:

$$\alpha_f^* = [\alpha_{1,f}^* \quad \alpha_{2,f}^* \quad \dots \quad \alpha_{N-1,f}^*] \quad (1.101)$$

com estas variáveis definidas, reescrevemos a equação como:

$$E_f \alpha_f^* = -e_{N,f} \quad (1.102)$$

e substituindo o vetor α_f^* por uma estimativa α_f , como anteriormente, pode-se obter uma equação diferencial para estimar α_f^* :

$$\dot{\alpha}_f = -E_f^T E_f \alpha_f - E_f^T e_{N,f} \quad (1.103)$$

e a estimativa $\bar{\alpha}_f$ de $\bar{\alpha}_f^*$ fica da forma:

$$\bar{\alpha}_f^T = \begin{bmatrix} \alpha_f^T & 1 - \vec{1}\alpha_f \end{bmatrix} \quad (1.104)$$

onde $\vec{1}$ é o vetor linha $[1 \ 1 \ \dots \ 1]$ de tamanho apropriado. Definimos, então, o erro paramétrico para a estimativa $\bar{\alpha}_f$ e para α_f :

$$\begin{aligned} \tilde{\alpha}_f &\triangleq \bar{\alpha}_f - \bar{\alpha}_f^* \\ \tilde{\alpha}_f &\triangleq \alpha_f - \alpha_f^* \end{aligned} \quad (1.105)$$

e como assumimos $\bar{\alpha}_f^*$ invariante no tempo, escrevemos:

$$\begin{aligned} \dot{\tilde{\alpha}}_f &= \dot{\alpha}_f - \cancel{\dot{\alpha}_f^*}^0 = \dot{\alpha}_f \\ \dot{\tilde{\alpha}}_f &= \dot{\alpha}_f - \cancel{\dot{\alpha}_f^*}^0 = \dot{\alpha}_f \end{aligned} \quad (1.106)$$

tal que, substituindo $\dot{\alpha}_f$ por $\dot{\tilde{\alpha}}_f$ e α_f por $\tilde{\alpha}_f + \alpha_f^*$ em 1.103 e cancelando os termos equivalentes devido a 1.102, temos:

$$\dot{\tilde{\alpha}}_f = -E_f^T E_f \tilde{\alpha}_f - E_f^T e_{\alpha,f} \quad (1.107)$$

e a partir de uma candidata a função de Lyapunov definida positiva:

$$V(\tilde{\alpha}_f) = \frac{1}{2} \tilde{\alpha}_f^T \tilde{\alpha}_f \quad (1.108)$$

derivando ao longo das trajetórias teremos:

$$\dot{V} = \tilde{\alpha}_f^T \dot{\tilde{\alpha}}_f$$

e explicitando $\tilde{\alpha}_f$ e $\dot{\tilde{\alpha}}_f$:

$$\dot{V} = \begin{bmatrix} \tilde{\alpha}_f^T & \vec{1}\tilde{\alpha}_f \end{bmatrix} \begin{bmatrix} \dot{\tilde{\alpha}}_f^T \\ \vec{1}\dot{\tilde{\alpha}}_f \end{bmatrix}$$

ao substituírmos $\dot{\tilde{\alpha}}_f$ por 1.107 e reorganizarmos, obtemos:

$$\dot{V} = -N\tilde{\alpha}_f^T E_f^T E_f \tilde{\alpha}_f - N\tilde{\alpha}_f^T E_f^T e_{\alpha,f} \quad (1.109)$$

e pode-se sempre escolher λ tal que o termo de sinal indefinido $-N\tilde{\alpha}_f^T E_f^T e_{\alpha,f}$ tenda para 0 mais rapidamente que o termo de sinal definido. Nesta expressão de $\dot{V}$ fica expresso novamente que a rapidez de convergência dos parâmetros depende do número de modelos N . V não pode crescer a partir de um certo instante, temos então que:

$$\tilde{\alpha}_f \in \mathcal{L}_\infty \rightarrow \tilde{\alpha}_f \in \mathcal{L}_\infty$$

e que:

$$\tilde{\alpha}_f \in \mathcal{L}_\infty \rightarrow \bar{\alpha}_f \in \mathcal{L}_\infty$$

$$\tilde{\alpha}_f \in \mathcal{L}_\infty \rightarrow \alpha_f \in \mathcal{L}_\infty$$

e como:

$$E_f, \alpha_f \in \mathcal{L}_\infty \rightarrow \dot{\alpha}_f, \dot{\alpha}_f \in \mathcal{L}_\infty$$

quando o sinal de controle u for persistentemente excitante teremos que E_f só será o vetor nulo a partir de algum instante quando as estimativas dos parâmetros forem equivalentes aos parâmetros corretos a_p e k_p , o que indica que uma combinação convexa destes parâmetros também tenderá para os valores corretos. As estimativas dos parâmetros a_p e k_p da planta, $\hat{a}_{n2,f}$ e $\hat{k}_{n2,f}$ são entregues pela combinação convexa de coeficientes $\alpha_{i,f}, i = 1, \dots, N$ dos parâmetros $\hat{a}_{i,f}$ e $\hat{k}_{i,f}, i = 1, \dots, N$:

$$\begin{aligned} \hat{a}_{n2,f} &= \alpha_{1,f} \hat{a}_{1,f} + \alpha_{2,f} \hat{a}_{2,f} + \dots + \alpha_{N,f} \hat{a}_{N,f} \\ \hat{k}_{n2,f} &= \alpha_{1,f} \hat{k}_{1,f} + \alpha_{2,f} \hat{k}_{2,f} + \dots + \alpha_{N,f} \hat{k}_{N,f} \end{aligned} \quad (1.110)$$

Adaptação de Segundo Nível Modificada

Como foi demonstrado, é possível estimar $\alpha_{i,sp}^*, i = 1, \dots, N$ através das equações 1.103 e 1.104. No entanto, como $E_f^T E_f$ é uma matriz de posto 1 ou 0, não podemos concluir mais nada sem a presença de um sinal com persistência de excitação pois $\lambda_{\min}(E_f^T E_f) \equiv 0$. Assumindo condições iniciais nulas, fazemos o seguinte raciocínio:

$$\begin{aligned}
E_f^T E_f \alpha_f^* &= -E_f^T e_{N,f} \\
\int_0^t E_f^T(\tau) E_f(\tau) \alpha_f^* d\tau &= -\int_0^t E_f^T(\tau) e_{N,f}(\tau) d\tau \\
\int_0^t E_f^T(\tau) E_f(\tau) d\tau \alpha_f^* &= -\int_0^t E_f^T(\tau) e_{N,f}(\tau) d\tau \\
0 &= -\int_0^t E_f^T(\tau) E_f(\tau) d\tau \alpha_f^* - \int_0^t E_f^T(\tau) e_{N,f}(\tau) d\tau \\
0 &= -\int_0^t E_f^T(\tau) E_f(\tau) d\tau \alpha_f^* - E_f^T E_f \alpha_f^* - \int_0^t E_f^T(\tau) e_{N,f}(\tau) d\tau - E_f^T e_{N,f}
\end{aligned}$$

como os erros de identificação $e_{i,f}, i = 1, \dots, N$, são limitados e tendem a 0 a medida que o tempo t tende a infinito, as integrais são limitadas e tendem a valores constantes. Substituindo α_f^* por sua estimativa temos a seguinte equação:

$$\dot{\alpha}_f = -\int_0^t E_f^T(\tau) E_f(\tau) d\tau \alpha_f - E_f^T E_f \alpha_f - \int_0^t E_f^T(\tau) e_{N,f}(\tau) d\tau - E_f^T e_{N,f}$$

e por facilidade de notação, usamos variáveis para as integrais:

$$\begin{aligned}
M_f &= \int_0^t E_f^T(\tau) E_f(\tau) d\tau \\
v_f &= \int_0^t E_f^T(\tau) e_{N,f}(\tau) d\tau
\end{aligned} \tag{1.111}$$

e escrevemos:

$$\dot{\alpha}_f = -M_f \alpha_f - E_f^T E_f \alpha_f - v_f - E_f^T e_{N,f} \tag{1.112}$$

então usamos uma candidata a função de Lyapunov definida positiva:

$$V(\tilde{\alpha}_f) = \frac{1}{2} \tilde{\alpha}_f^T \tilde{\alpha}_f \tag{1.113}$$

que resulta em:

$$\dot{V} = -N \tilde{\alpha}_f^T (E_f^T E_f + M_f) \tilde{\alpha}_f \tag{1.114}$$

para cada instante de tempo existe um autovetor ligado ao espaço nulo da matriz $E_f^T E_f$. Então para um vetor arbitrário $w_q \in R^{N-1}$ constante:

$$w_q^T \left(\int_0^\infty E_f^T(\tau) E_f(\tau) d\tau \right) w_q > 0$$

pois assumimos que não existe um vetor w_q , constante e não-nulo, que seja equivalente a um múltiplo escalar do autovetor associado ao espaço nulo da matriz $E_f^T E_f$ (pois assumimos que a direção deste autovetor está mudando ao longo do tempo), o que tornará $w_q^T E_{sp}^T E_{sp} w_q$ positivo durante algum intervalo de tempo, qualquer que seja w_q . Portanto a matriz M_f converge para uma matriz simétrica com valores de seus elementos constantes, definida positiva e de posto cheio. Temos então, para um intervalo finito entre 0 e $t_0 > 0$ escolhido tal que $\lambda_{\min}(E_f^T E_f + M_f) > 0$ a partir de t_0 , que:

$$\int_0^{t_0} \|\tilde{\alpha}_f\|^2 d\tau < K$$

onde K é um escalar finito, pois $\tilde{\alpha}_f$ é uniformemente limitado. E temos pela desigualdade de Rayleigh que:

$$\begin{aligned} \lambda_{\min}(E_f^T E_f + M_f) \|\tilde{\alpha}_f\|^2 &\leq \\ &\tilde{\alpha}_f^T (E_f^T E_f + M_f) \tilde{\alpha}_f \\ &\leq \\ \lambda_{\max}(E_f^T E_f + M_f) \|\tilde{\alpha}_f\|^2 \end{aligned}$$

e usando a equação obtida para $\dot{V}$ temos que:

$$\|\tilde{\alpha}_f\|^2 \leq \frac{-\dot{V}}{N\lambda_{\min}(E_f^T E_f + M_f)}$$

substituímos $\lambda_{\min}$ que varia com o tempo por um valor $\lambda_{\min,inf}$ constante, a menor cota inferior do conjunto de autovalores mínimos da matriz $E_f^T E_f + M_f$ a partir do instante t_0 e integrando temos:

$$\int_0^\infty \|\tilde{\alpha}_f(\tau)\|^2 d\tau \leq \int_0^{t_0} \|\tilde{\alpha}_f(\tau)\|^2 d\tau + \frac{-1}{N\lambda_{\min,inf}(E_f^T E_f + M_f)} (V(\infty) - V(t_0))$$

como o lado direito desta equação é um valor limitado seu lado esquerdo também é limitado e temos que:

$$\tilde{\alpha}_f \in \mathcal{L}_2$$

e finalmente, pelo lema de Barbalat, temos que a o vetor $\tilde{\alpha}_f$ é uniformemente limitado, sua norma $\mathcal{L}_2$ é uniformemente limitada e sua derivada é uniformemente limitada:

$$\lim_{t \rightarrow \infty} \tilde{\alpha}_f = \mathbf{0}$$

temos então que:

$$\lim_{t \rightarrow \infty} \tilde{\alpha}_f = \mathbf{0} \rightarrow \lim_{t \rightarrow \infty} \tilde{\alpha}_{N,f} = 0$$

e portanto, com a modificação proposta, existe garantia de convergência dos coeficientes $\hat{\alpha}_{i,f}$, $i = 1, \dots, N$, para seus valores corretos, sem que se necessite impor sobre a planta um sinal de controle com a característica de persistência de excitação. Outra forma de calcular os coeficientes corretos é monitorando o posto de M_f e resolvendo o sistema de equações $M_f \alpha_f^{*T} = -v_f$ para α_f^* quando for verificado que M_f é de posto cheio e suficientemente distante de ser uma matriz singular, para evitar erro numérico. No entanto, é importante ressaltar que esta melhora na convergência dos parâmetros implica numa perda em outro aspecto importante, isto é, caso a planta tenha seus parâmetros variando lentamente no tempo, as informações acumuladas nos elementos da matriz M_f e do vetor v_f deixarão gradualmente de ser válidas na atualização ou cálculo dos coeficientes, fazendo com que os coeficientes acabem convergindo para valores distintos dos corretos, o que é algo que não acontece sem a modificação já que a Adaptação de Segundo Nível para o Modelo por Regressão Linear usa apenas as informações disponíveis em tempo presente.

1.3 Resumo dos Algoritmos e Estudos de Simulação

Apresentamos o Modelo de Identificação Paralelo, Modelo de Identificação Série-Paralelo e o Modelo de Identificação por Regressão Linear neste primeiro capítulo. Discutimos algumas de suas propriedades para a planta estável de ordem 1 e grau relativo 1. Mostramos que o erro de identificação tende a 0 para estes modelos. Mencionamos que as estimativas tendem aos valores corretos na presença de um sinal de entrada com a característica de persistência de excitação. Provamos, para os Modelos de Primeiro Nível que existem coeficientes constantes de uma combinação convexa das estimativas dos parâmetros de 3 ou mais Modelos

que produzem a_p e k_p . Demonstramos como uma **segunda camada de adaptação**, ou uma **adaptação em dois níveis** pode-se atualizar estimativas destes coeficientes para calcular uma estimativa de segundo nível de a_p e k_p . Finalmente, para cada um dos Modelos de Identificação de Primeiro Nível, discutimos uma modificação na lei adaptativa da Adaptação de Segundo Nível tal que não seja necessária a imposição de um sinal de controle com característica de persistência de excitação à planta para que seja garantida a convergência dos parâmetros para seus valores corretos.

1.3.1 Resumo dos Algoritmos

Caso o leitor deseje consultar rapidamente, listamos os algoritmos de identificação de primeiro e segundo nível de forma compacta:

Série-Paralelo	Regressão Linear
$\Sigma_p : \dot{y} = -a_p y + k_p u$	$\Sigma_p : \dot{y} = -a_p y + k_p u$
$\Sigma_{1,sp} : \dot{\hat{y}}_{1,sp} = -a_m \hat{y}_{1,sp} - \hat{a}_{1,sp} y + a_m y + \hat{k}_{1,sp} u$	$z = y - \lambda \phi_1$
$e_{1,sp} = \hat{y}_{1,sp} - y$	$\dot{\phi}_1 = -\lambda \phi_1 + y$
$\hat{a}_{1,sp} = e_{1,sp} y$	$\dot{\phi}_2 = -\lambda \phi_2 + u$
$\hat{k}_{1,sp} = -e_{1,sp} u$	$\phi^T = [\phi_1 \quad \phi_2]$
	$\Sigma_{1,f} : \hat{z}_{1,f} = [-\hat{a}_{1,f} \quad \hat{k}_{1,f}] \phi$
	$e_{1,f} = \hat{z}_{1,f} - z$
	$\hat{a}_{1,f} = e_{1,f} y$
	$\hat{k}_{1,f} = -e_{1,f} u$

Segundo Nível Série-Paralelo	Segundo Nível Série-Paralelo Modificado
$\Sigma_p : \dot{y} = -a_p y + k_p u$ $\Sigma_{i,sp} : \dot{\hat{y}}_{i,sp} = -a_m \hat{y}_{i,sp} - \hat{a}_{i,sp} y + a_m y + \hat{k}_{i,sp} u$ $e_{i,sp} = \hat{y}_{i,sp} - y$ $\dot{\hat{a}}_{i,sp} = e_{i,sp} y$ $\dot{\hat{k}}_{i,sp} = -e_{i,sp} u$ $E_{sp} = [e_{1,sp} - e_{N,sp} \quad \dots \quad e_{N-1,sp} - e_{N,sp}]$ $\dot{\alpha}_{sp} = -E_{sp}^T E_{sp} \alpha_{sp} - E_{sp}^T e_{N,sp}$ $\bar{\Theta}_{sp} = \begin{bmatrix} \hat{a}_{1,sp} & \dots & \hat{a}_{N,sp} \\ \hat{k}_{1,sp} & \dots & \hat{k}_{N,sp} \end{bmatrix}$ $\bar{\alpha}_{sp}^T = \begin{bmatrix} \alpha_{sp}^T & 1 - \vec{1} \alpha_{sp} \end{bmatrix}$ $\begin{bmatrix} \hat{a}_{n2,sp} \\ \hat{k}_{n2,sp} \end{bmatrix} = \bar{\Theta}_{sp} \bar{\alpha}_{sp}$	$\Sigma_p : \dot{y} = -a_p y + k_p u$ $\Sigma_{i,sp} : \dot{\hat{y}}_{i,sp} = -a_m \hat{y}_{i,sp} - \hat{a}_{i,sp} y + a_m y + \hat{k}_{i,sp} u$ $e_{i,sp} = \hat{y}_{i,sp} - y$ $\dot{\hat{a}}_{i,sp} = e_{i,sp} y$ $\dot{\hat{k}}_{i,sp} = -e_{i,sp} u$ $E_{sp} = [e_{1,sp} - e_{N,sp} \quad \dots \quad e_{N-1,sp} - e_{N,sp}]$ $M_{sp}(0) = \mathbf{0}$ $v_{sp}(0) = \mathbf{0}$ $\dot{M}_{sp} = E_{sp}^T E_{sp}$ $\dot{v}_{sp} = E_{sp}^T e_{N,sp}$ $\dot{\alpha}_{sp} = -(E_{sp}^T E_{sp} + M_{sp}) \alpha_{sp} - E_{sp}^T e_{N,sp} - v_{sp}$ $\bar{\Theta}_{sp} = \begin{bmatrix} \hat{a}_{1,sp} & \dots & \hat{a}_{N,sp} \\ \hat{k}_{1,sp} & \dots & \hat{k}_{N,sp} \end{bmatrix}$ $\bar{\alpha}_{sp}^T = \begin{bmatrix} \alpha_{sp}^T & 1 - \vec{1} \alpha_{sp} \end{bmatrix}$ $\begin{bmatrix} \hat{a}_{n2,sp} \\ \hat{k}_{n2,sp} \end{bmatrix} = \bar{\Theta}_{sp} \bar{\alpha}_{sp}$

Segundo Nível Regressão Linear	Segundo Nível Regressão Linear Modificado
$\Sigma_p : \dot{y} = -a_p y + k_p u$ $z = y - \lambda \phi_1$ $\dot{\phi}_1 = -\lambda \phi_1 + y$ $\dot{\phi}_2 = -\lambda \phi_2 + u$ $\phi^T = [\phi_1 \ \phi_2]$ $\Sigma_{i,f} : \hat{z}_{i,f} = [-\hat{a}_{i,f} \ \hat{k}_{i,f}] \phi$ $e_{i,f} = \hat{z}_{i,f} - z$ $\hat{a}_{i,f} = e_{i,f} y$ $\hat{k}_{i,f} = -e_{i,f} u$ $E_f = [e_{1,f} - e_{N,f} \ \dots \ e_{N-1,f} - e_{N,f}]$ $\dot{\alpha}_f = -E_f^T E_f \alpha_f - E_f^T e_{N,f}$ $\bar{\Theta}_f = \begin{bmatrix} \hat{a}_{1,f} & \dots & \hat{a}_{N,f} \\ \hat{k}_{1,f} & \dots & \hat{k}_{N,f} \end{bmatrix}$ $\bar{\alpha}_f^T = [\alpha_f^T \ 1 - \vec{1} \alpha_f]$ $\begin{bmatrix} \hat{a}_{n2,f} \\ \hat{k}_{n2,f} \end{bmatrix} = \bar{\Theta}_f \bar{\alpha}_f$	$\Sigma_p : \dot{y} = -a_p y + k_p u$ $z = y - \lambda \phi_1$ $\dot{\phi}_1 = -\lambda \phi_1 + y$ $\dot{\phi}_2 = -\lambda \phi_2 + u$ $\phi^T = [\phi_1 \ \phi_2]$ $\Sigma_{i,f} : \hat{z}_{i,f} = [-\hat{a}_{i,f} \ \hat{k}_{i,f}] \phi$ $e_{i,f} = \hat{z}_{i,f} - z$ $\hat{a}_{i,f} = e_{i,f} y$ $\hat{k}_{i,f} = -e_{i,f} u$ $E_f = [e_{1,f} - e_{N,f} \ \dots \ e_{N-1,f} - e_{N,f}]$ $M_f(0) = \mathbf{0}$ $v_f(0) = \mathbf{0}$ $\dot{M}_f = E_f^T E_f$ $\dot{v}_f = E_f^T e_{N,f}$ $\dot{\alpha}_f = -(E_f^T E_f + M_f) \alpha_f - E_f^T e_{N,f} - v_f$ $\bar{\Theta}_f = \begin{bmatrix} \hat{a}_{1,f} & \dots & \hat{a}_{N,f} \\ \hat{k}_{1,f} & \dots & \hat{k}_{N,f} \end{bmatrix}$ $\bar{\alpha}_f^T = [\alpha_f^T \ 1 - \vec{1} \alpha_f]$ $\begin{bmatrix} \hat{a}_{n2,f} \\ \hat{k}_{n2,f} \end{bmatrix} = \bar{\Theta}_f \bar{\alpha}_f$

1.3.2 Estudos de Simulação

Considere a Planta de Ordem 1 a seguir:

$$G(s) = \frac{3}{s + 1.5}$$

onde os parâmetros $k_p = 3$ e $a_p = 1.5$ pertencem a uma região de incerteza delimitada por $a_p^+ = 4$, $a_p^- = 0.5$, $k_p^+ = 6$, $k_p^- = 1$. Desejamos identificar os parâmetros desta planta em tempo real. Sua saída $y(t)$ e sua entrada $u(t)$ estão disponíveis para medição. Vamos usar os modelos de identificação estudados neste capítulo: o Modelo de Identificação Paralelo, Modelo Série-Paralelo, Modelo por Regressão Linear e diversas implementações do conceito de Adaptação de Segundo Nível, fazendo uso de conjuntos de Modelos de Primeiro Nível. Na Adaptação de Segundo Nível estimativas de Primeiro Nível são combinadas linearmente por um

conjunto de coeficientes que também estão, por sua vez, sendo atualizados para formar uma estimativa de Segundo Nível. Usaremos o número mínimo de modelos para caso de ordem 1 e grau relativo 1, $N = 3$. Depois, usando o Modelo de Identificação por Regressão Linear, mostramos resultados com $N = 4$ e $N = 8$ modelos. Finalmente, apresentamos e discutimos os resultados de simulações para $N = 3$ modelos com a modificação na lei adaptativa proposta no final da subseção 1.2.1 para Modelos de Identificação Série-Paralelo e no final da subseção 1.2.2 para o Modelo de Identificação por Regressão Linear.

Em todas as simulações utilizamos o sinal de entrada $u(t) = \sin(t)$ que é persistentemente excitante de ordem 1. Da mesma forma consideramos a condição inicial $y(0) = 0.2$ em todas as simulações a seguir. Inicializamos os parâmetros dos Modelos de Primeiro Nível em $\hat{a}(0) = 0.5$ e $\hat{k}(0) = 6$ e os α_i dos modelos de segundo nível tal que $\hat{a}(0) = 0.5$ e $\hat{k}(0) = 6$. Usamos integração por passo fixo de 10^{-3} segundos.

Modelo Paralelo




Figura 1.1: Erro de Identificação usando o Modelo Paralelo para a planta Σ_p , 110 segundos de simulação

Modelo Série-Paralelo

Escolhemos o parâmetro $a_m = 4$.




Figura 1.2: Erro de Identificação usando o Modelo Série-Paralelo para a planta Σ_p , 110 segundos de simulação

Modelo por Regressão Linear

Escolhemos o parâmetro $\lambda = 4$.

OBS, ERRATA: $\lambda > \sqrt{\left| \frac{6}{j1/2\pi + 0.5} \right|} + 1$, resulta em $\lambda > 11.44$, porém na prática usamos um valor muito menor. De fato, usando os parâmetros verdadeiros da planta na equação obtemos $\lambda > 2.27$. Portanto o λ escolhido, apesar de não respeitar a restrição, é mesmo assim suficiente para fazer com que $\dot{V} \leq 0$.




Figura 1.3: Erro de Identificação usando o Modelo por Regressão Linear para a planta Σ_p , 110 segundos de simulação

então verificamos para o Modelo Paralelo que o erro de identificação tende a 0 com $t \approx 90$ segundos na Figura 1.1. Como $u(t)$ é PE de ordem 1 isto indica que a partir de $t \approx 90$ segundos os parâmetros convergiram para os valores corretos. O mesmo aconteceu para o Modelo Série-Paralelo com $t = 110$ segundos na Figura 1.2. Da mesma forma, para o Modelo por Regressão Linear o erro de identificação está tendendo a 0 com $t = 110$ segundos na Figura 1.3, indicando convergência dos parâmetros. Em todos os 3 casos os Modelos de Identificação Convencionais foram capazes de identificar os parâmetros da planta. Porém somente foram capazes de fazê-lo após um intervalo de tempo longo em relação a dinâmica da planta.

Segundo Nível, Série-Paralelo, 3 Modelos

Consideramos que $y(0) = 0.2$, inicializamos os parâmetros do Modelo em $\hat{a}_{1,sp}(0) = 0.5$ e $\hat{k}_{1,sp}(0) = 1$, $\hat{a}_{2,sp}(0) = 0.5$ e $\hat{k}_{2,sp}(0) = 11$, $\hat{a}_{3,sp}(0) = 7$ e $\hat{k}_{3,sp}(0) = 1$, e os coeficientes da combinação convexa em $\alpha_{1,sp}(0) = 0.5$, $\alpha_{2,sp}(0) = 0.5$ e $\alpha_{3,sp}(0) = 0$. Desta forma $\hat{a}_{n2,sp}(0) = 0.5$ e $\hat{k}_{n2,sp}(0) = 6$, como mencionamos anteriormente. Escolhemos o parâmetro $a_m = 4$.

Segundo Nível, Filtragem, 3 Modelos

Inicializamos os parâmetros dos Modelos em $\hat{a}_{1,f}(0) = 0.5$ e $\hat{k}_{1,f}(0) = 1$, $\hat{a}_{2,f}(0) = 0.5$ e $\hat{k}_{2,f}(0) = 11$, $\hat{a}_{3,f}(0) = 7$ e $\hat{k}_{3,f}(0) = 1$, e os coeficientes da combinação convexa em $\alpha_{1,f}(0) = 0.5$, $\alpha_{2,f}(0) = 0.5$ e $\alpha_{3,f}(0) = 0$. Escolhemos o parâmetro $\lambda = 4$, além disso escolhemos $\phi_1(0) = \phi_2(0) = 0$.

Segundo Nível, Filtragem, 4 Modelos

Inicializamos os parâmetros dos Modelos nos vértices da região de incerteza em $\hat{a}_{1,f}(0) = 0.5$ e $\hat{k}_{1,f}(0) = 1$, $\hat{a}_{2,f}(0) = 4$ e $\hat{k}_{2,f}(0) = 1$, $\hat{a}_{3,f}(0) = 4$ e $\hat{k}_{3,f}(0) = 6$, $\hat{a}_{4,f}(0) = 0.5$ e $\hat{k}_{4,f}(0) = 6$, e os coeficientes da combinação convexa em $\alpha_{1,f}(0) = 0$, $\alpha_{2,f}(0) = 0$ e $\alpha_{3,f}(0) = 0$ e $\alpha_{4,f}(0) = 1$. Escolhemos o parâmetro $\lambda = 4$, além disso escolhemos $\phi_1(0) = \phi_2(0) = 0$.

Segundo Nível, Filtragem, 8 Modelos

Consideramos que $y(0) = 0.2$, inicializamos os parâmetros dos Modelos em $\hat{a}_{1,f}(0) = 0.5$ e $\hat{k}_{1,f}(0) = 1$, $\hat{a}_{2,f}(0) = 2$ e $\hat{k}_{2,f}(0) = 1$, $\hat{a}_{3,f}(0) = 4$ e $\hat{k}_{3,f}(0) = 1$, $\hat{a}_{4,f}(0) = 4$ e $\hat{k}_{4,f}(0) = 3$, $\hat{a}_{5,f}(0) = 4$ e $\hat{k}_{5,f}(0) = 6$, $\hat{a}_{6,f}(0) = 2.5$ e $\hat{k}_{6,f}(0) = 6$, $\hat{a}_{7,f}(0) = 0.5$ e $\hat{k}_{7,f}(0) = 4$, $\hat{a}_{8,f}(0) = 0.5$ e $\hat{k}_{8,f}(0) = 6$, ao longo do perímetro da região de incerteza, e os coeficientes da combinação

convexa em $\alpha_{i,f},(0) = 0, i \neq 8$ e $\alpha_{8,f},(0) = 1$. Escolhemos o parâmetro $\lambda = 4$, além disso escolhemos $\phi_1(0) = \phi_2(0) = 0$.

De forma a facilitar a comparação entre os diferentes Modelos de Identificação plotamos as estimativas dos parâmetros da planta de cada modelo nos mesmos 2 gráficos. Escolhemos omitir as estimativas dos Modelos que não iniciam em $\hat{a} = 0.5$ e $\hat{k} = 6$. Entendemos que estes modelos não contribuem com informações relevantes para a discussão.




Figura 1.4: Estimativa do parâmetro $a_p = 3$ para a planta Σ_p para os Modelos de Identificação estudados, Adaptação de Segundo Nível com $N = 3, N = 4$ e $N = 8$ Modelos de Primeiro Nível por Regressão Linear e $N = 3$ Modelos de Primeiro Nível Série-Paralelos, 20 segundos de simulação




Figura 1.5: Estimativa do parâmetro $k_p = 1.5$ para a planta Σ_p para os Modelos de Identificação estudados, Adaptação de Segundo Nível com $N = 3, N = 4$ e $N = 8$ Modelos de Primeiro Nível por Regressão Linear e $N = 3$ Modelos de Primeiro Nível Série-Paralelos , 20 segundos de simulação

e os resultados se encontram nas Figuras 1.4 e 1.5. Vemos que a Adaptação de Segundo Nível é mais rápida que os Modelos de Identificação Convencionais em todos os casos. O uso do Modelo Série-Paralelo ou Modelo por Regressão Linear leva a resultados quase idênticos, como pode ser visto nas Figuras para o caso em que usamos $N = 3$ modelos. A velocidade de convergência aumenta quando usamos mais modelos, mas não de uma forma linear. Tanto no caso em que $N = 4$ quanto $N = 8$ observamos um sobressinal menor nas estimativas em relação aos valores corretos e uma convergência mais rápida. No entanto é importante notar que dobramos o número de modelos em relação ao caso em que $N = 4$ e obtivemos uma convergência apenas um pouco mais rápida. Isto sugere que a velocidade de convergência dos parâmetros está sujeita a uma lei de rendimentos decrescentes, no que se refere ao número de modelos.

Segundo Nível Modificado, Série-Paralelo, 3 Modelos

Consideramos que $y(0) = 0.2$, inicializamos os parâmetros do Modelo em $\hat{a}_{1,sp}(0) = 0.5$ e $\hat{k}_{1,sp}(0) = 1, \hat{a}_{2,sp}(0) = 0.5$ e $\hat{k}_{2,sp}(0) = 11, \hat{a}_{3,sp}(0) = 7$ e $\hat{k}_{3,sp}(0) = 1$, e os coeficientes da combinação convexa em $\alpha_{1,sp}(0) = 0.5, \alpha_{2,sp}(0) = 0.5$ e $\alpha_{3,sp}(0) = 0$. O sinal de entrada foi escolhido como $u(t) = 1$ que **não é PE de ordem 1** e o parâmetro $a_m = 4$.




Figura 1.6: Erros de Identificação usando 3 Modelos Série-Paralelos para a planta Σ_p , 36 segundos de simulação




Figura 1.7: Estimativas do parâmetro $a_p = 3$ para a planta Σ_p para 3 Modelos por Série-Paralelos e a estimativa de Segundo Nível Modificada, 36 segundos de simulação




Figura 1.8: Estimativas do parâmetro $k_p = 1.5$ para a planta Σ_p para 3 Modelos por Série-Paralelos e a estimativa de Segundo Nível Modificada, 36 segundos de simulação




Figura 1.9: Trajetória dos parâmetros $\hat{a}_{n2,sp}$ e $\hat{k}_{n2,sp}$ da Adaptação de Segundo Nível no espaço de parâmetros usando 3 Modelos Série-Paralelos para a planta Σ_p , 30 segundos de simulação

Verificamos que as amplitudes dos erros de identificação vão para 0 com $t = 5$ segundos na Figura 1.6 e as estimativas de primeiro nível se aproximam dos valores corretos nas Figuras 1.7 e 1.8 e depois param em sua vizinhança, enquanto que as estimativas de segundo nível em $t = 20$ alcançam os valores corretos. O trajeto no espaço de parâmetros pode ser visto na Figura 1.9. Após o regime permanente as estimativas se mantêm no segmento da reta de inclinação igual ao ganho em regime permanente da planta e que passa pelo ponto que contém os parâmetros

corretos. Portanto a Adaptação de Segundo Nível Modificada com 3 Modelos de Primeiro Nível Série-Paralelo de uma Planta sujeita a um degrau unitário é adequada para a tarefa de identificação dos parâmetros. O processo de identificação continua a ser mais lento do que a dinâmica da planta e a convergência dos parâmetros se dá de fato após $t = 20$ segundos, porém dispensamos a exigência de um sinal PE de ordem 1.

Segundo Nível Modificado, Filtragem, 3 Modelos

Consideramos que $y(0) = 0$, inicializamos os parâmetros dos Modelos em $\hat{a}_{1,f}(0) = 0.5$ e $\hat{k}_{1,f}(0) = 1, \hat{a}_{2,f}(0) = 0.5$ e $\hat{k}_{2,f}(0) = 11, \hat{a}_{3,f}(0) = 7$ e $\hat{k}_{3,f}(0) = 1$, e os coeficientes da combinação convexa em $\alpha_{1,f}(0) = 0.5, \alpha_{2,f}(0) = 0.5$ e $\alpha_{3,f}(0) = 0$ e usamos o Método de Integração de Euler com passo fixo de 10^{-3} segundos e tempo de simulação de 36 segundos. O sinal de entrada foi escolhido como $u(t) = 1$ que **não é PE de ordem 1** e o parâmetro $\lambda = 4$, além disso escolhemos $\phi_1(0) = \phi_2(0) = 0$.




Figura 1.10: Erros de Identificação usando 3 Modelos por Regressão Linear para a planta Σ_p




Figura 1.11: Estimativas do parâmetro $a_p = 1.5$ para a planta Σ_p para 3 Modelos por Regressão Linear e a estimativa de Segundo Nível Modificada, 36 segundos de simulação




Figura 1.12: Estimativas do parâmetro $k_p = 1.5$ para a planta Σ_p para 3 Modelos por Regressão Linear e a estimativa de Segundo Nível Modificada, 36 segundos de simulação




Figura 1.13: Trajetória dos parâmetros $\hat{a}_{n2,f}$ e $\hat{k}_{n2,f}$ da Adaptação de Segundo Nível Modificada no espaço de parâmetros usando 3 Modelos por Regressão Linear para a planta Σ_p , aos 30 segundos de simulação

Verificamos que os erros de identificação rapidamente vão para 0 com $t \approx 5$ segundos na Figura 1.10 e as estimativas de primeiro nível ficaram mais próximas dos valores corretos nas Figuras 1.11 e 1.12. De fato as estimativas em regime permanente para um sinal de entrada do tipo degrau unitário sempre se localizam sobre a reta de inclinação igual ao ganho em regime permanente da planta e que passa pelo ponto que contém os parâmetros corretos. Isto acontece pois o degrau carrega apenas uma informação (a amplitude). A senoide carrega duas informações (amplitude e fase), de forma que uma senoide pode ser usada para identificar dois parâmetros. As estimativas de segundo nível em $t = 25$ segundos alcançam os valores corretos. Este resultado e o anterior são interessantes, e damos a eles a seguinte interpretação: **as informações sobre os parâmetros da planta se encontram disponíveis durante o transitório. O transitório é o período de tempo em que todos os modos estão excitados. Armazenar as informações acerca do transitório da planta nos permite identificá-la univocamente.** O trajeto no espaço de parâmetros pode ser visto na Figura 1.13 e tem uma característica quase inteiramente linear, como no caso anterior. Portanto a Adaptação de Segundo Nível Modificada com 3 Modelos de Primeiro Nível por Regressão Linear de uma Planta Invariante no Tempo sujeita a um sinal que provoca excitação de seus modos durante um intervalo de tempo finito é adequada para a tarefa de Identificação de Parâmetros. O processo de identificação continua a ser mais lento do que a dinâmica da planta pois a convergência dos parâmetros se dá de fato após $t = 25$ segundos. No entanto não foi necessária a imposição de um sinal com persistência de excitação.

1.4 Conclusão

Neste capítulo apresentamos uma introdução a alguns Modelos de Identificação Convencionais usados na identificação dos parâmetros em tempo real de uma Planta Linear Invariante no Tempo. Mostramos como alguns destes Modelos podem servir como base para identificação através do conceito de Adaptação de Segundo Nível. Na Adaptação de Segundo Nível os coeficientes de uma combinação linear de múltiplos modelos são atualizados por uma lei integral e as estimativas são entregues por esta mesma combinação. O Modelo Série-Paralelo servirá como base para o caso em que o vetor de estado da planta de grau n e grau relativo unitário é acessível. O Modelo por Regressão Linear servirá como base para o caso em que apenas a entrada e a saída da planta de grau n e grau relativo unitário estão disponíveis para medição. Disponibilizamos os algoritmos em forma compacta em um resumo para que o leitor possa testar o conceito por si mesmo em simulação. Neste capítulo escolhemos um caso simples, uma planta de grau 1 com grau relativo unitário e estável e portanto com apenas dois parâmetros a serem estimados e com sinais limitados a priori. Desta forma esperamos que as características da Adaptação de Segundo Nível tenham ficado evidenciadas mais facilmente. Foram feitos estudos de simulação extensivos, nos quais avaliamos que a Adaptação de Segundo Nível dispõe de propriedades promissoras de velocidade de convergência em relação aos Modelos de Identificação Convencionais. Mostramos também que existe a possibilidade de identificar os parâmetros corretos na presença de um sinal de entrada sem persistência de excitação.

Referências Bibliográficas

- [1] S. Boyd and S. S. Sastry, “Necessary and sufficient conditions for parameter convergence in adaptive control,” *Automatica*, vol. 22, no. 6, pp. 629–639, 1986.
- [2] K. S. NARENDRA and A. M. ANNASWAMY, “Persistent excitation in adaptive systems,” *International Journal of Control*, vol. 45, no. 1, pp. 127–160, 1987.
- [3] R. Bitmead, “Persistence of excitation conditions and the convergence of adaptive schemes,” *IEEE Transactions on Information Theory*, vol. 30, pp. 183–191, Mar 1984.
- [4] K. S. Narendra and A. M. Annaswamy, *Stable Adaptive Systems*. Prentice-Hall, 1989.
- [5] P. A. Ioannou and J. Sun, *Robust Adaptive Control*. Pearson Education, Inc., 1996.
- [6] G. Tao, *Adaptive Control Design and Analysis*. Wiley, 2003.
- [7] Z. Han and K. Narendra, “Second level adaptation using multiple models,” pp. 2350 – 2355, 08 2011.
- [8] Z. Han and K. S. Narendra, “Multiple adaptive models for control,” in *Decision and Control (CDC), 2010 49th IEEE Conference on*, pp. 60–65, Dec 2010.
- [9] Z. Han and K. S. Narendra, “New concepts in adaptive control using multiple models,” *IEEE Transactions on Automatic Control*, vol. 57, pp. 78–89, Jan 2012.
- [10] K. S. Narendra, Y. Wang, and W. Chen, “The rationale for second level adaptation,” in *The 16th Yale Workshop on Adaptive and Learning Systems*, Yale University, 2012.

- [11] K. S. Narendra, Y. Wang, and W. Chen, “Stability, robustness, and performance issues in second level adaptation,” in *American Control Conference (ACC), 2014*, pp. 2377–2382, June 2014.
- [12] K. S. Narendra, Y. Wang, and W. Chen, “Extension of second level adaptation using multiple models to siso systems,” in *2015 American Control Conference (ACC)*, pp. 171–176, July 2015.