

Nomenclatura

A_p	Matriz A da representação em espaço de estado para a Planta MIMO de ordem n e grau relativo 1
$\Sigma_{p,MIMO}$	Planta MIMO de ordem n e grau relativo 1
N	Número de Modelos de Identificação usados na Adaptação de Segundo Nível
n	Grau da Planta
p	Número de entradas da Planta MIMO
$\vec{1}$	Vetor Linha de tamanho apropriado (determinado pelo contexto da equação em que está sendo aplicado) cujos elementos são todos 1
$\mathbf{0}$	Matriz de tamanho apropriado (determinado pelo contexto da equação em que está sendo aplicada) cujos elementos são todos 0
s	Variável complexa no domínio da frequência
a_{ij}	Elementos da matriz $A_p, i = 1, \dots, n, j = 1, \dots, n$
a_{ij}^+	Limitantes superiores para os elementos $a_{ij}, i = 1, \dots, n, j = 1, \dots, n$
$S_{\theta,a}$	Região de incerteza do espaço de parâmetros a_{ij} da matriz A_p delimitada pelo politopo convexo cujos vértices são todas as combinações de a_{ij}^+ ou a_{ij}^- .
$S_{\theta,b}$	Região de incerteza do espaço de parâmetros b_{ij} da matriz B_p delimitada pelo politopo convexo cujos vértices são todas as combinações de b_{ij}^+ ou b_{ij}^- .
a_{ij}^-	Limitantes inferiores para os elementos $a_{ij}, i = 1, \dots, n, j = 1, \dots, n$
B_p	Matriz B da representação em espaço de estado para a Planta MIMO de ordem n e grau relativo 1

b_{ij}	Elementos da matriz $B_p, i = 1, \dots, n, j = 1, \dots, p$
b_{ij}^+	Limitantes superiores para os elementos $b_{ij}, i = 1, \dots, n, j = 1, \dots, p$
b_{ij}^-	Limitantes inferiores para os elementos $b_{ij}, i = 1, \dots, n, j = 1, \dots, p$
x_p	Vetor de estado da planta MIMO ou SISO.
$\dot{x}_p$	Primeira derivada em relação ao tempo do vetor de estado da planta MIMO ou SISO.
u	Vetor formado pelas p entradas no caso da Planta MIMO. No caso da Planta SISO sinal de entrada escalar.
$G_p(s)$	Função de Transferência da planta de ordem n e grau relativo 1
$\Sigma_{p,SISO}$	Planta SISO de ordem n e grau relativo 1
$N_p(s)$	Polinômio do Numerador da Função de Transferência $G_p(s)$
b_i	Coefficientes do polinômio do numerador da planta SISO de ordem n e grau relativo 1, com $i = 1, \dots, n$, associados às variáveis complexas s^{n-i} do polinômio
b_i^+	Limitante superior da região de incerteza para os coeficientes b_i da planta SISO de ordem n e grau relativo 1, com $i = 1, \dots, n$
b_i^-	Limitante inferior da região de incerteza para o coeficiente b_i da planta SISO de ordem n e grau relativo 1, com $i = 1, \dots, n$
$D_p(s)$	Polinômio do Denominador da Função de Transferência $G_p(s)$
a_i	Coefficientes do polinômio mônico do denominador da planta SISO de ordem n e grau relativo 1, com $i = 1, \dots, n$, associados às variáveis complexas s^{n-i} do polinômio
a_i^+	Limitante superior da região de incerteza para os coeficientes a_i da planta SISO de ordem n e grau relativo 1, com $i = 1, \dots, n$
a_i^-	Limitante inferior da região de incerteza para os coeficientes a_i da planta SISO de ordem n e grau relativo 1, com $i = 1, \dots, n$
y_p	Sinal de Saída da planta de ordem n e grau relativo 1
$\Lambda(s)$	Polinômio mônico, de Grau n com raízes negativas

z	Sinal de Saída planta de ordem n e grau relativo 1 filtrado por uma função de transferência $\frac{s^n}{\Lambda(s)}$
ϕ_1	Vetor gerado a partir de filtrações do sinal y por funções de transferência próprias $\frac{s^i}{\Lambda(s)}$, com $i = n - 1, \dots, 1$, usado para construir o vetor regressor ϕ
ϕ_2	Vetor gerado a partir de filtrações do sinal u por funções de transferência próprias $\frac{s^i}{\Lambda(s)}$, com $i = n - 1, \dots, 1$, usado para construir o vetor regressor ϕ
ϕ	Vetor Coluna formado pelos elementos de $-\phi_1$ e ϕ_2 , e chamado vetor regressor
$\Sigma_{1,sp}$	Modelo de identificação série-paralelo 1 da planta MIMO de ordem n
A_m	Matriz com autovalores no semi plano esquerdo aberto, critério do projetista
P	Variável simétrica da equação de Lyapunov $A_m^T P + P A_m = -Q$ em A_m e Q , usada nas leis adaptativas para o Modelo de Identificação Série Paralelo da Planta MIMO
Q	Matriz definida positiva e simétrica, critério do projetista
$\Sigma_{i,sp}$	i -ésimo Modelo de identificação Série-Paralelo planta MIMO de ordem n , com $i = 1, \dots, N$
$\Sigma_{1,f}$	Modelo de identificação por Regressão Linear 1 planta SISO de ordem n e grau relativo 1
$\Sigma_{i,f}$	i -ésimo Modelo de identificação por Regressão Linear planta SISO de ordem n e grau relativo 1, com $i = 1, \dots, N$
$\hat{x}_{1,sp}$	Estimativa do Vetor de Estado da Planta MIMO de ordem n e grau relativo 1 usando o Modelo de Identificação Série-Paralelo 1
$\hat{x}_{i,sp}$	Estimativa do Vetor de Estado da Planta MIMO de ordem n e grau relativo 1 usando o i -ésimo Modelo de Identificação Série-Paralelo com $i = 1, \dots, N$
$e_{1,sp}$	Erro de identificação gerado pela diferença entre o vetor de estado do Modelo de identificação Série-Paralelo 1 e o vetor de estado da planta MIMO
$e_{i,sp}$	Erro de identificação gerado pela diferença entre o vetor de estado do i -ésimo Modelo de identificação Série-Paralelo, com $i = 1, \dots, N$, e o vetor de estado da planta MIMO

$e_{N,sp}$	Erro de identificação gerado pela diferença entre o vetor de estado do Modelo de identificação Série-Paralelo N e o vetor de estado da planta MIMO
$\bar{E}_{sp}$	Matriz formada pelos Erros de identificação $e_{i,sp}$, com $i = 1, \dots, N$, em suas colunas
E_{sp}	Matriz formada pela diferença entre os Erros de identificação $e_{i,sp}$, com $i = 1, \dots, N-1$, e o erro $e_{N,sp}$ em suas colunas
$\hat{B}_{1,sp}$	Estimativa da Matriz B_p da planta MIMO usando o Modelo de Identificação Série-Paralelo 1
$\hat{B}_{i,sp}$	Estimativa da Matriz B_p da planta MIMO usando o i-ésimo Modelo de Identificação Série-Paralelo, com $i = 1, \dots, N$
$\hat{A}_{1,sp}$	Estimativa da Matriz A_p da planta MIMO usando o Modelo de Identificação Série-Paralelo 1
$\hat{A}_{i,sp}$	Estimativa da Matriz A_p da planta MIMO usando o i-ésimo Modelo de Identificação Série-Paralelo, com $i = 1, \dots, N$
$\tilde{A}_{1,sp}$	Erro paramétrico devido a diferença entre a estimativa $\hat{A}_{1,sp}$ e o valor correto A_p
$\tilde{A}_{i,sp}$	Erro paramétrico devido a diferença entre a estimativa $\hat{A}_{i,sp}$ e o valor correto A_p , com $i = 1, \dots, N$
$\dot{\hat{A}}_{1,sp}$	Lei Adaptativa para Atualização da Estimativa $\hat{A}_{1,sp}$
$\dot{\hat{A}}_{i,sp}$	Lei Adaptativa para Atualização da Estimativa $\hat{A}_{i,sp}$, com $i = 1, \dots, N$
$\dot{\hat{B}}_{1,sp}$	Lei Adaptativa para Atualização da Estimativa $\hat{B}_{1,sp}$
$\dot{\hat{B}}_{i,sp}$	Lei Adaptativa para Atualização da Estimativa $\hat{B}_{i,sp}$, com $i = 1, \dots, N$
$\alpha_{i,sp}^*$	Coefficientes da combinação convexa que quando aplicados às estimativas $\hat{B}_{i,sp}$ e $\hat{A}_{i,sp}$, com $i = 1, \dots, N$, formam B_p e A_p respectivamente
$\alpha_{i,sp}$	Coefficientes da combinação convexa que são aplicados às estimativas $\hat{k}_{B,sp}$ e $\hat{A}_{i,sp}$, com $i = 1, \dots, N$, para formar uma estimativa de segundo nível dos parâmetros B_p e A_p
α_{sp}^*	Vetor Coluna formado pelos Coeficientes $\alpha_{i,sp}^*$ em suas linhas, com $i = 1, \dots, N-1$

$\bar{\alpha}_{sp}^*$	Vetor Coluna formado pelos Coeficientes $\alpha_{i,sp}^*$ em suas linhas, com $i = 1, \dots, N$
α_{sp}	Vetor Coluna formado pelos Coeficientes $\alpha_{i,sp}$ em suas linhas, com $i = 1, \dots, N - 1$
$\bar{\alpha}_{sp}$	Vetor Coluna formado pelos Coeficientes $\alpha_{i,sp}$ em suas linhas, com $i = 1, \dots, N$
$\dot{\alpha}_{sp}$	Lei Adaptativa para Atualização do Vetor α_{sp}
$\bar{\Theta}_{sp}$	Matriz formada por $vec(\hat{A}_{i,sp})$ em suas primeiras n linhas e por $vec(\hat{k}_{i,sp})$ em suas n linhas seguintes, com $i = 1, \dots, N$
$\hat{A}_{n2,sp}$	Estimativa de Segundo Nível da matriz A_p da planta MIMO usando como base Modelos de Identificação Série-Paralelo
$\hat{B}_{n2,sp}$	Estimativa de Segundo Nível da matriz B_p da planta MIMO usando como base Modelos de Identificação Série-Paralelo
$\hat{z}_{1,f}$	Estimativa do Sinal Filtrado de Saída da Planta de Ordem n e grau relativo 1 usando o Modelo de Identificação por Regressão Linear 1
$\hat{z}_{i,f}$	Estimativa do Sinal Filtrado de Saída da Planta de Ordem n e grau relativo 1 usando o i-ésimo Modelo de Identificação por Regressão Linear, com $i = 1, \dots, N$
$e_{1,f}$	Erro de identificação gerado pela diferença entre o sinal de saída filtrado do Modelo de identificação por Regressão Linear da Planta 1 e o Sinal de Saída da Planta de ordem n e grau relativo 1 Filtrado
$e_{i,f}$	Erro de identificação gerado pela diferença entre o sinal de saída do i-ésimo Modelo de identificação por Regressão Linear, com $i = 1, \dots, N$, e o Sinal de Saída da Planta de ordem n e grau relativo 1 Filtrado
$e_{N,f}$	Erro de identificação gerado pela diferença entre o sinal de saída do Modelo de identificação por Regressão Linear N e o Sinal de Saída da Planta de ordem n e grau relativo 1 Filtrado
$\bar{E}_f$	Vetor linha formado pelos Erros de identificação $e_{i,f}$, com $i = 1, \dots, N$, em suas colunas
E_f	Vetor linha formado pela diferença entre os Erros de identificação $e_{i,f}$, com $i = 1, \dots, N - 1$, e o erro $e_{N,f}$ em suas colunas

$\hat{\theta}_{1,f}$	Estimativa do vetor de parâmetros θ_p^* da planta de ordem n e grau relativo 1 usando o Modelo de Identificação por Regressão Linear da Planta 1
$\hat{\theta}_{i,f}$	Estimativa do vetor de parâmetros θ_p^* da planta de ordem n e grau relativo 1 usando o i -ésimo Modelo de Identificação por Regressão Linear da Planta, com $i = 1, \dots, N$
$\tilde{\theta}_{1,f}$	Erro paramétrico devido a diferença entre a estimativa $\hat{\theta}_{1,f}$ e o valor correto θ_p^*
$\tilde{\theta}_{i,f}$	Erro paramétrico devido a diferença entre a estimativa $\hat{\theta}_{i,f}$ e o valor correto θ_p^*
$\dot{\hat{\theta}}_{1,f}$	Lei Adaptativa para Atualização da Estimativa $\hat{\theta}_{1,f}$
$\dot{\hat{\theta}}_{i,f}$	Lei Adaptativa para Atualização da Estimativa $\hat{\theta}_{i,f}$, com $i = 1, \dots, N$
$\alpha_{i,f}^*$	Coefficientes da combinação convexa que quando aplicados às estimativas $\hat{\theta}_{i,f}$, com $i = 1, \dots, N$, formam θ_p^*
$\alpha_{i,f}$	Coefficientes da combinação convexa que são aplicados às estimativas $\hat{\theta}_{i,f}$, com $i = 1, \dots, N$, para formar uma estimativa de segundo nível do vetor de parâmetros θ_p^*
α_f^*	Vetor Coluna formado pelos Coeficientes $\alpha_{i,f}^*$ em suas linhas, com $i = 1, \dots, N - 1$
$\bar{\alpha}_f^*$	Vetor Coluna formado pelos Coeficientes $\alpha_{i,f}^*$ em suas linhas, com $i = 1, \dots, N$
α_f	Vetor Coluna formado pelos Coeficientes $\alpha_{i,f}$ em suas linhas, com $i = 1, \dots, N - 1$
$\bar{\alpha}_f$	Vetor Coluna formado pelos Coeficientes $\alpha_{i,f}$ em suas linhas, com $i = 1, \dots, N$
$\dot{\alpha}_f$	Lei Adaptativa para Atualização do Vetor α_f
$\bar{\Theta}_f$	Matriz formada pelos coeficientes $\hat{\theta}_{i,f}$ em suas colunas, com $i = 1, \dots, N$
$\hat{\theta}_{n2,f}$	Estimativa de Segundo Nível do parâmetro θ_p^* da planta SISO usando como base Modelos de Identificação por Regressão Linear

Capítulo 2

Estimação de Parâmetros, Ordem n

Continuamos então a estender resultados que obtivemos para plantas lineares invariantes no tempo de ordem 1 e grau relativo 1 para plantas lineares de ordem n e grau relativo 1. Apresentaremos o Modelo de Identificação Série-Paralelo aplicado a uma Planta Linear Controlável e Observável, Invariante no Tempo, com Múltiplas Entradas e Múltiplas Saídas (MIMO). Discutiremos também o caso do Modelo de Identificação por Regressão Linear aplicado à Planta quando apenas a entrada $u(t)$ e a saída $y(t)$ estão disponíveis para medição (SISO).

Em [1, 2, 3] entre as hipóteses colocadas na modelagem do sistema estão a de que o vetor b do espaço de estado da planta é conhecido, e que as matrizes se encontram em forma companheira. Buscamos então o conceito de Adaptação de Segundo Nível para uma planta mais geral, assumindo apenas a hipótese de que os parâmetros da planta pertencem inicialmente ao fecho convexo formado pelos parâmetros dos Modelos de Primeiro Nível e que o vetor de estado da planta está acessível para medição. Isto nos levou naturalmente à Adaptação de Segundo Nível baseada em Modelos de Identificação Série-Paralelos aplicada ao caso MIMO, que detalharemos neste capítulo.

Além disto, em [4] uma extensão da Adaptação de Segundo Nível para o caso SISO foi apresentada, ainda baseada em Modelos de Primeiro Nível Série-Paralelos, onde a estabilidade dos modelos de identificação é garantida por uma matriz A_m escolhida pelo projetista. Isto faz com que a escolha das estimativas iniciais dos modelos precise cumprir duas condições simultâneas: A de formar um fecho convexo que contenha a região de incerteza dos parâmetros da planta e de que os Modelos de Identificação sejam estáveis. A escolha de parâmetros iniciais dos Modelos de Identificação Série-Paralelos para o número mínimo de modelos de identificação não é um problema trivial, especialmente a medida que a ordem da planta aumenta, como Narendra menciona em [5]. Com isto em mente

apresentamos o conceito de Adaptação de Segundo Nível baseada em Modelos de Identificação por Regressão Linear. Ao utilizar Modelos de Identificação por Regressão Linear, a estabilidade dos modelos independe da localização dos parâmetros escolhidos, desde que sejam limitados. Assim, é preciso cumprir apenas a condição de escolher as estimativas iniciais dos Modelos de Identificação tal que formem um fecho convexo que contenha a região de incerteza dos parâmetros da planta. Isto facilita bastante a escolha dos parâmetros iniciais, e nos permite propor um algoritmo simples para a escolha destes parâmetros no caso de uma planta intervalar, onde os limitantes inferiores e superiores para os coeficientes dos polinômios da função de transferência da planta são conhecidos.

Assim, para o caso MIMO e o caso SISO nos ocupamos de mostrar novamente que uma combinação convexa de coeficientes constantes das estimativas de Modelos de Primeiro Nível é equivalente a um Modelo de Primeiro Nível. Isto é estritamente verdadeiro quando os erros de identificação são inicialmente nulos. Mostramos também que mesmo que os erros não sejam inicialmente nulos, a combinação convexa dos erros de identificação tende a 0 exponencialmente dependendo de um parâmetro de projeto. Devido a esta propriedade é possível estimar os coeficientes da combinação convexa das estimativas dos Modelos de Primeiro Nível que produzem os parâmetros verdadeiros da planta. O resultado disto, como já vimos para a planta de ordem 1, é um ganho em rapidez de convergência das estimativas de segundo nível para seus valores corretos em relação às estimativas de primeiro nível. Ao obter uma convergência mais rápida dos parâmetros, a Adaptação de Segundo Nível pode ser usada para gerar um sinal de controle melhor no que tange a especificações como energia utilizada e overshoot, ao mesmo tempo que torna o transitório da planta mais rápido e mais suave como pode ser visto recentemente em [6].

Finalmente, apresentamos a Adaptação de Segundo Nível com Fator de Esquecimento para ambos os casos. Demonstramos por simulação que a coleta de informações através de uma integral de convolução ao longo do transitório resulta numa melhora do resultado da Adaptação de Segundo Nível em termos de suavidade das estimativas e rapidez de convergência.

2.1 Caso MIMO

2.1.1 Modelo de Identificação Série-Paralelo

Seja a planta linear invariante no tempo com múltiplas entradas e múltiplas saídas cujo vetor de estado está disponível para medição, descrita por:

$$\Sigma_{p,MIMO} : \dot{x}_p = A_p x_p + B_p u$$

em que $x_p \in R^n$, $u \in R^p$, $A_p \in R^{n \times n}$, $B_p \in R^{n \times p}$. Os limitantes superiores a_{ij}^+ , b_{ij}^+ e inferiores a_{ij}^- , b_{ij}^- dos elementos das matrizes A_p e B_p são conhecidos. Desta forma as combinações de limitantes a_{ij}^+ e a_{ij}^- formam um politopo convexo que delimita a região de incerteza $S_{\theta,a} \in R^{n^2}$ para os elementos de A_p . As combinações de limitantes b_{ij}^+ e b_{ij}^- formam um politopo convexo que delimita a região de incerteza $S_{\theta,b} \in R^{np}$ para os elementos de B_p . Portanto as regiões de incerteza $S_{\theta,a}$ e $S_{\theta,b}$ são conhecidas. Podemos escrever:

$$\begin{aligned} \dot{x}_p &= A_p x_p + B_p u = A_p x_p + A_m x_p - A_m x_p + B_p u \\ \dot{x}_p - A_m x_p &= A_p x_p - A_m x_p + B_p u \end{aligned}$$

em que A_m é uma matriz escolhida pelo projetista cujos autovalores estão contidos no semi-plano esquerdo do plano complexo. Um Modelo de Identificação pode ser criado a partir da equação acima, substituindo x_p por uma estimativa de x_p no lado esquerdo da equação:

$$\Sigma_{1,sp} : \dot{\hat{x}}_{1,sp} - A_m \hat{x}_{1,sp} = \hat{A}_{1,sp} x_p - A_m x_p + \hat{B}_{1,sp} u$$

tal que:

$$\Sigma_{1,sp} : \dot{\hat{x}}_{1,sp} = A_m \hat{x}_{1,sp} + \hat{A}_{1,sp} x_p - A_m x_p + \hat{B}_{1,sp} u \quad (2.1)$$

e definimos o erro de identificação:

$$e_{1,sp} \triangleq \hat{x}_{1,sp} - x_p \quad (2.2)$$

e sua dinâmica é da forma:

$$\dot{e}_{1,sp} = \dot{\hat{x}}_{1,sp} - \dot{x}_p = A_m \hat{x}_{1,sp} + \hat{A}_{1,sp} x_p - A_m x_p + \hat{B}_{1,sp} u - A_p x_p - B_p u$$

e definimos os erros paramétricos:

$$\begin{aligned} \tilde{A}_{1,sp} &\triangleq \hat{A}_{1,sp} - A_p \\ \tilde{B}_{1,sp} &\triangleq \hat{B}_{1,sp} - B_p \end{aligned} \quad (2.3)$$

e escrevemos $\dot{e}_{1,sp}$ da seguinte forma:

$$\dot{e}_{1,sp} = A_m e_{1,sp} + \tilde{A}_{1,sp} y + \tilde{B}_{1,sp} u \quad (2.4)$$

e então, a partir de uma candidata a função de Lyapunov definida positiva da forma:

$$V(e_{1,sp}, \tilde{A}_{1,sp}, \tilde{B}_{1,sp}) = \frac{1}{2} (e_{1,sp}^T P e_{1,sp} + tr(\tilde{A}_{1,sp}^T \tilde{A}_{1,sp}) + tr(\tilde{B}_{1,sp}^T \tilde{B}_{1,sp})) \quad (2.5)$$

em que $tr(\cdot)$ denota o traço da matriz e $P = P^T > 0$ cumpre a equação de Lyapunov:

$$A_m^T P + P A_m = -2Q \quad (2.6)$$

com $Q = Q^T > 0$, derivamos ao longo das trajetórias:

$$\begin{aligned} \dot{V} &= \frac{1}{2} (\dot{e}_{1,sp}^T P e_{1,sp} + e_{1,sp}^T P \dot{e}_{1,sp}) + tr(\tilde{A}_{1,sp}^T \dot{\tilde{A}}_{1,sp}) + tr(\tilde{B}_{1,sp}^T \dot{\tilde{B}}_{1,sp}) \\ &= \frac{1}{2} ((A_m e_{1,sp} + \tilde{A}_{1,sp} x_p + \tilde{B}_{1,sp} u)^T P e_{1,sp} + e_{1,sp}^T P (A_m e_{1,sp} + \tilde{A}_{1,sp} x_p + \tilde{B}_{1,sp} u)) + \\ &\quad + tr(\tilde{A}_{1,sp}^T \dot{\tilde{A}}_{1,sp}) + tr(\tilde{B}_{1,sp}^T \dot{\tilde{B}}_{1,sp}) \\ \dot{V} &= -e_{1,sp}^T Q e_{1,sp} + x_p^T \tilde{A}_{1,sp}^T P e_{1,sp} + u^T \tilde{B}_{1,sp}^T P e_{1,sp} + tr(\tilde{A}_{1,sp}^T \dot{\tilde{A}}_{1,sp}) + tr(\tilde{B}_{1,sp}^T \dot{\tilde{B}}_{1,sp}) \end{aligned}$$

e como a planta é invariante no tempo:

$$\begin{aligned} \tilde{A}_{1,sp} &= \hat{A}_{1,sp} - A_p \rightarrow \dot{\tilde{A}}_{1,sp} = \dot{\hat{A}}_{1,sp} - \overset{0}{\cancel{\dot{A}_p}} = \dot{\hat{A}}_{1,sp} \\ \tilde{B}_{1,sp} &= \hat{B}_{1,sp} - B_p \rightarrow \dot{\tilde{B}}_{1,sp} = \dot{\hat{B}}_{1,sp} - \overset{0}{\cancel{\dot{B}_p}} = \dot{\hat{B}}_{1,sp} \end{aligned}$$

e como $tr(v_1 v_2^T) = v_2^T v_1$ para dois vetores coluna v_1 e v_2 quaisquer, podemos então escolher leis integrais para atualizar $\hat{A}_{1,sp}$ e $\hat{B}_{1,sp}$ tal que os termos de sinal indefinido em $\dot{V}$ sejam anulados:

$$\begin{aligned} \dot{\hat{A}}_{1,sp} &= -P e_{1,sp} x_p^T \\ \dot{\hat{B}}_{1,sp} &= -P e_{1,sp} u^T \end{aligned} \quad (2.7)$$

temos que $tr(\tilde{A}_{1,sp}^T P e_{1,sp} x_p^T) = x_p^T \tilde{A}_{1,sp}^T P e_{1,sp}$ e $tr(\tilde{B}_{1,sp}^T P e_{1,sp} u^T) = u^T \tilde{B}_{1,sp}^T P e_{1,sp}$, fazendo com que:

$$\dot{V} = -e_{1,sp}^T Q e_{1,sp} \leq 0 \quad (2.8)$$

$\dot{V}$ é semi-definida negativa e portanto V não pode crescer, o que implica em:

$$\begin{aligned} e_{1,sp} &\in \mathcal{L}_\infty \\ \tilde{A}_{1,sp} &\in \mathcal{L}_\infty \rightarrow \hat{A}_{1,sp} \in \mathcal{L}_\infty \\ \tilde{B}_{1,sp} &\in \mathcal{L}_\infty \rightarrow \hat{B}_{1,sp} \in \mathcal{L}_\infty \end{aligned}$$

o sinal de controle u é escolhido tal que seus componentes sejam uniformemente limitados e o comportamento do sistema seja estável, no sentido de garantir que os componentes do vetor de estado x_p sejam uniformemente limitados:

$$\begin{aligned} x_p &\in \mathcal{L}_\infty \\ \dot{e}_{1,sp} &\in \mathcal{L}_\infty \end{aligned}$$

como $e_{1,sp} = \hat{x}_{1,sp} - x_p \in \mathcal{L}_\infty$ e $x_p \in \mathcal{L}_\infty$, temos que:

$$\hat{x}_{1,sp} \in \mathcal{L}_\infty$$

e finalmente, usando a desigualdade de Rayleigh:

$$\lambda_{\min}(Q) \|e_{1,sp}\|^2 \leq e_{1,sp}^T Q e_{1,sp} \leq \lambda_{\max}(Q) \|e_{1,sp}\|^2 \quad (2.9)$$

manipulando a equação para $\dot{V}$:

$$\begin{aligned} \|e_{1,sp}\|^2 &\leq -\frac{1}{\lambda_{\min}(Q)} \dot{V} \\ \int_0^\infty \|e_{1,sp}\|^2 &\leq -\frac{1}{\lambda_{\min}(Q)} \int_0^\infty \dot{V} \\ \int_0^\infty \|e_{1,sp}\|^2 &\leq -\frac{1}{\lambda_{\min}(Q)} (V(\infty) - V(0)) \end{aligned}$$

portanto:

$$e_{1,sp} \in \mathcal{L}_2$$

usando o lema de Barbalat, como $e_{1,sp}$ é uniformemente limitado, tem norma $\mathcal{L}_2$ uniformemente limitada e sua derivada é uniformemente limitada:

$$\lim_{t \rightarrow \infty} e_{1,sp} = \mathbf{0}$$

adicionalmente, quando o sinal de controle u for persistentemente excitante, teremos que $e_{1,sp} = \mathbf{0}$ para todo tempo $t > t_0$ sse $\tilde{A}_{1,sp} = \mathbf{0}$ e $\tilde{B}_{1,sp} = \mathbf{0}$ e os elementos das estimativas $\hat{A}_{1,sp}$ e $\hat{B}_{1,sp}$ tendem aos valores dos elementos de A_p e B_p respectivamente, para $t \rightarrow \infty$. É importante notar que usando o modelo série-paralelo o

valor de $\dot{V}$ depende de A_m que é um parâmetro de projeto do estimador. Portanto a velocidade de convergência de $e_{1,sp}$ para $\mathbf{0}$ depende de um parâmetro de projeto. Para mais informações acerca deste modelo, referimos o leitor a [7].

2.2 Caso SISO

2.2.1 Modelo de Identificação por Regressão Linear

Seja a planta linear invariante no tempo descrita pela seguinte função de transferência:

$$\Sigma_{p,SISO} : G_p(s) = \frac{y(s)}{u(s)} = \frac{N_p(s)}{D_p(s)}$$

em que:

$$\begin{aligned} N_p(s) &= b_1 s^{n-1} + b_2 s^{n-2} + \dots + b_{n-1} s + b_n \\ D_p(s) &= s^n + a_1 s^{n-1} + a_2 s^{n-2} + \dots + a_{n-1} s + a_n \end{aligned} \quad (2.10)$$

em que os limitantes superiores $b_1^+, \dots, b_n^+, a_1^+, a_n^+$ e inferiores $b_1^-, \dots, b_n^-, a_1^-, a_n^-$ dos coeficientes $b_1, \dots, b_n, a_1, \dots, a_n$ são conhecidos. Desta forma as combinações de limitantes $b_1^+, \dots, b_n^+, a_1^+, a_n^+$ e $b_1^-, \dots, b_n^-, a_1^-, a_n^-$ representam vértices de um politopo convexo que delimita a região de incerteza $S_{\theta,f} \in R^{2n}$ dos coeficientes $b_1, \dots, b_n, a_1, \dots, a_n$. A região de incerteza $S_{\theta,f}$ é conhecida. Manipulando a função de transferência podemos escrever, no domínio da frequência

$$s^n y(s) = -a_1 s^{n-1} y(s) - \dots - a_n y(s) + b_1 s^{n-1} u(s) + \dots + b_n u(s) \quad (2.11)$$

e definindo o seguinte polinômio com raízes negativas:

$$\Lambda(s) \triangleq s^n + \lambda_1 s^{n-1} + \lambda_2 s^{n-2} + \dots + \lambda_{n-1} s + \lambda_n \quad (2.12)$$

escrevemos:

$$\frac{s^n}{\Lambda(s)} y(s) = -a_1 \frac{s^{n-1}}{\Lambda(s)} y(s) - \dots - a_n \frac{1}{\Lambda(s)} y(s) + b_1 \frac{s^{n-1}}{\Lambda(s)} u(s) + \dots + b_n \frac{1}{\Lambda(s)} u(s)$$

e definimos:

$$\begin{aligned} z(s) &\triangleq \frac{s^n}{\Lambda(s)} y(s) \\ \phi(s) &\triangleq \left[\frac{-s^{n-1} y(s)}{\Lambda(s)} \quad \dots \quad \frac{-y(s)}{\Lambda(s)} \quad \frac{s^{n-1} u(s)}{\Lambda(s)} \quad \dots \quad \frac{u(s)}{\Lambda(s)} \right]^T \\ \theta_p^* &\triangleq [a_1 \quad \dots \quad a_n \quad b_1 \quad \dots \quad b_n]^T \end{aligned} \quad (2.13)$$

e temos a seguinte parametrização para a planta:

$$z(s) = \theta_p^{*T} \phi \quad (2.14)$$

e o vetor regressor ϕ pode ser gerado através de filtros de $y(t)$ e $u(t)$:

$$\begin{aligned} \dot{\phi}_1 &= \Lambda_c \phi_1 + l y \\ \dot{\phi}_2 &= \Lambda_c \phi_2 + l u \\ \phi &= [-\phi_1 \quad \phi_2]^T \end{aligned} \quad (2.15)$$

em que Λ_c e l são escolhidos de acordo com 2.12 e 2.13. Podemos criar um modelo de identificação a partir de uma combinação linear dos sinais componentes do vetor ϕ como:

$$\Sigma_{1,f} : \hat{z}_{1,f} = \hat{\theta}_{1,f}^T \phi \quad (2.16)$$

e definir um erro de identificação:

$$e_{1,f} \triangleq \hat{z}_{1,f} - z \quad (2.17)$$

então o erro de identificação normalizado pode ser construído:

$$\epsilon_{1,f} = \frac{e_{1,f}}{m^2} \quad (2.18)$$

onde $m^2 = 1 + n_s^2$ e n_s é chamado de sinal normalizador, escolhido tal que:

$$\frac{\phi}{m} \in \mathcal{L}_\infty$$

e uma escolha típica é $n_s = \phi^T \phi$. Definimos então o erro paramétrico:

$$\tilde{\theta}_{1,f} \triangleq \hat{\theta}_{1,f} - \theta_p^* \quad (2.19)$$

assim podemos expressar o erro de identificação normalizado:

$$\epsilon_{1,f} = \frac{\tilde{\theta}_{1,f}^T \phi}{m^2} \quad (2.20)$$

seja então a função de custo:

$$J(\theta_{1,f}) = \frac{\epsilon_{1,f}^2 m^2}{2} = \frac{(\theta_{1,f}^T \phi - z)^2}{2m^2} \quad (2.21)$$

gostaríamos de minimizar a função de custo em relação ao vetor $\theta_{1,f}$. Como $\frac{\phi}{m}$ é uniformemente limitado $J(\theta_{1,f})$ é convexa em $\theta_{1,f}$. Aplicando o método do gradiente a trajetória que minimiza $J(\theta_{1,f})$ é dada por:

$$\dot{\theta}_{1,f} = -\Gamma \nabla J(\theta_{1,f}) \quad (2.22)$$

onde $\Gamma = \Gamma^T > 0$ é uma matriz chamada matriz de ganhos adaptativos. Temos então que:

$$\nabla J(\theta_{1,f}) = \frac{(\theta_{1,f}^T \phi - z)\phi}{m^2} = \varepsilon_{1,f} \phi \quad (2.23)$$

que resulta na lei adaptativa:

$$\dot{\theta}_{1,f} = -\Gamma \varepsilon_{1,f} \phi \quad (2.24)$$

e como a planta é invariante no tempo θ_p^* é constante:

$$\dot{\tilde{\theta}}_{1,f} = -\Gamma \varepsilon_{1,f} \phi \quad (2.25)$$

escolhendo a candidata a função de Lyapunov:

$$V(\tilde{\theta}_{1,f}) = \frac{\tilde{\theta}_{1,f}^T \Gamma^{-1} \tilde{\theta}_{1,f}}{2} \quad (2.26)$$

temos que:

$$\dot{V} = \tilde{\theta}_{1,f}^T \phi \varepsilon_{1,f} = -\varepsilon_{1,f}^2 m^2 \leq 0 \quad (2.27)$$

$\tilde{\theta}_{1,f}$ é uniformemente limitado, que implica em $\varepsilon_{1,f}, \varepsilon_{1,f} m$ uniformemente limitados. Como no capítulo 1, este resultado implica que $\varepsilon_{1,f} m \in \mathcal{L}_2$. Apesar de não garantir diretamente que $e_{1,f}$ tende para 0, se tivermos que $\frac{\phi}{m}, \frac{\dot{m}}{m} \in \mathcal{L}_\infty$ é possível demonstrar que $\frac{d(\varepsilon_{1,f} m)}{dt} \in \mathcal{L}_\infty$ e aplicar o Lema de Barbalat. Para mais detalhes acerca deste Modelo de Identificação, referimos o leitor a [8].

2.3 Estimação de Parâmetros de Segundo Nível

2.3.1 Caso MIMO

N Modelos de Identificação Série-Paralelo

Seja, novamente, a planta linear invariante no tempo com múltiplas entradas e múltiplas saídas:

$$\Sigma_{p,MIMO} : \dot{x}_p = A_p x_p + B_p u$$

em que $x_p \in R^n$, $u \in R^p$, $A_p \in R^{n \times n}$, $B \in R^{n \times p}$. Os limitantes superiores a_{ij}^+ , b_{ij}^+ e inferiores a_{ij}^- , b_{ij}^- dos elementos das matrizes A_p e B_p são conhecidos. Desta forma as combinações de limitantes a_{ij}^+ e a_{ij}^- formam um politopo convexo que delimita região de incerteza $S_{\theta,a} \in R^{n^2}$ para os elementos de A_p . As combinações de limitantes b_{ij}^+ e b_{ij}^- formam um politopo convexo que delimita a região de incerteza $S_{\theta,b} \in R^{np}$ para os elementos de B_p . As regiões de incerteza $S_{\theta,a}$ e $S_{\theta,b}$ são conhecidas. Sejam os $N \geq n^2 + np + 1$ modelos de identificação:

$$\Sigma_{i,sp} : \dot{\hat{x}}_{i,sp} = A_m \hat{x}_{i,sp} + (\hat{A}_{i,sp} - A_m)x_p + \hat{B}_{i,sp}u \quad (2.28)$$

com $i = 1, \dots, N$, e os N erros de identificação:

$$e_{i,sp} = x_{i,sp} - x_p \quad (2.29)$$

definindo os N erros paramétricos:

$$\begin{aligned} \tilde{A}_{i,sp} &= \hat{A}_{i,sp} - A_p \\ \tilde{B}_{i,sp} &= \hat{B}_{i,sp} - B_p \end{aligned} \quad (2.30)$$

suas dinâmicas são representadas por:

$$\dot{e}_{i,sp} = A_m e_{i,sp} + \tilde{A}_{i,sp} x_p + \tilde{B}_{i,sp} u \quad (2.31)$$

e, como vimos anteriormente, as N matrizes estimativas podem ser atualizadas por:

$$\begin{aligned} \dot{\hat{A}}_{i,sp} &= -P e_{i,sp} x_p^T \\ \dot{\hat{B}}_{i,sp} &= -P e_{i,sp} u^T \end{aligned} \quad (2.32)$$

os elementos das matrizes $\hat{A}_{i,sp}$ e $\hat{B}_{i,sp}$, $i = 1, \dots, N$, formam um fecho convexo no espaço de parâmetros. Cada um dos pontos no interior ou fronteira deste fecho

convexo pode ser representado por uma combinação convexa:

$$\begin{aligned}\hat{A}_{v,sp} &= \sum_{i=1}^N \hat{A}_{i,sp} \beta_{i,sp} \\ \hat{B}_{v,sp} &= \sum_{i=1}^N \hat{B}_{i,sp} \beta_{i,sp} \\ \sum_{i=1}^N \beta_{i,sp} &= 1 \\ 0 &\leq \beta_{i,sp} \leq 1\end{aligned}\tag{2.33}$$

se criarmos então um **MODELO DE IDENTIFICAÇÃO VIRTUAL** a partir de alguma destas combinações convexas:

$$\Sigma_{v,sp} : \dot{\hat{x}}_{v,sp} = A_m \hat{x}_{v,sp} + (\hat{A}_{v,sp} - A_m)x_p + \hat{B}_{v,sp}u\tag{2.34}$$

e definirmos o erro de identificação para o modelo virtual:

$$e_{v,sp} \triangleq \hat{x}_{v,sp} - x_p\tag{2.35}$$

e definindo os erros paramétricos:

$$\begin{aligned}\tilde{A}_{v,sp} &\triangleq \hat{A}_{v,sp} - A_p \\ \tilde{B}_{v,sp} &\triangleq \hat{B}_{v,sp} - B_p\end{aligned}\tag{2.36}$$

sua dinâmica é idêntica às dos modelos de primeiro nível:

$$\dot{e}_{v,sp} = A_m e_{v,sp} + \tilde{A}_{v,sp}x_p + \tilde{B}_{v,sp}u\tag{2.37}$$

pode-se manipular as expressões dos erros paramétricos:

$$\begin{aligned}\tilde{A}_{v,sp} &= \sum_{i=1}^N \hat{A}_{i,sp} \beta_{i,sp} - A_p = \sum_{i=1}^N \hat{A}_{i,sp} \beta_{i,sp} - \sum_{i=1}^N A_p \beta_{i,sp} = \sum_{i=1}^N \tilde{A}_{i,sp} \beta_{i,sp} \\ \tilde{B}_{v,sp} &= \sum_{i=1}^N \hat{B}_{i,sp} \beta_{i,sp} - B_p = \sum_{i=1}^N \hat{B}_{i,sp} \beta_{i,sp} - \sum_{i=1}^N B_p \beta_{i,sp} = \sum_{i=1}^N \tilde{B}_{i,sp} \beta_{i,sp}\end{aligned}\tag{2.38}$$

segue que as leis adaptativas que governam o ajuste de $A_{v,sp}$ e $B_{v,sp}$ são da forma:

$$\begin{aligned}\dot{\hat{A}}_{v,sp} &= \sum_{i=1}^N \dot{\hat{A}}_{i,sp} \beta_{i,sp} \\ \dot{\hat{B}}_{v,sp} &= \sum_{i=1}^N \dot{\hat{B}}_{i,sp} \beta_{i,sp}\end{aligned}\tag{2.39}$$

substituindo as expressões relevantes obtemos:

$$\begin{aligned}\hat{A}_{v,sp} &= -P \sum_{i=1}^N e_{i,sp} \beta_{i,sp} x_p^T \\ \hat{B}_{v,sp} &= -P \sum_{i=1}^N e_{i,sp} \beta_{i,sp} u^T\end{aligned}\tag{2.40}$$

assumindo que $x_p(0)$ é conhecido então é possível escolher $\hat{x}_{i,sp}(0) = \hat{x}_{v,sp}(0) = y(0)$ e ter que $e_{i,sp}(0) = e_{v,sp}(0) = \mathbf{0}$, com $i = 1, \dots, N$. Usando as expressões dos erros obtemos:

$$\begin{aligned}\sum_{i=1}^N \beta_{i,sp} \dot{e}_{i,sp} &= \sum_{i=1}^N \beta_{i,sp} A_m e_{i,sp} + \sum_{i=1}^N \beta_{i,sp} \tilde{A}_{i,sp} x_p + \sum_{i=1}^N \beta_{i,sp} \tilde{B}_{i,sp} u \\ \sum_{i=1}^N \beta_{i,sp} \dot{e}_{i,sp} &= A_m \sum_{i=1}^N \beta_{i,sp} e_{i,sp} + \tilde{A}_{v,sp} x_p + \tilde{B}_{v,sp} u\end{aligned}$$

e como $\sum_{i=1}^N \beta_{i,sp} e_{i,sp}(0) = e_{v,sp}(0) = \mathbf{0}$ temos que:

$$\sum_{i=1}^N \beta_{i,sp} e_{i,sp} \equiv e_{v,sp}\tag{2.41}$$

as expressões acima então se reduzem a:

$$\begin{aligned}\dot{\hat{A}}_{v,sp} &= -P e_{v,sp} x_p^T \\ \dot{\hat{B}}_{v,sp} &= -P e_{v,sp} u^T\end{aligned}\tag{2.42}$$

as leis adaptativas obtidas acima têm forma idêntica às aquelas usadas nos modelos de primeiro nível $\Sigma_{i,sp}, i = 1, \dots, N$. **Cada um dos pontos no interior do fecho convexo corresponde a um modelo virtual.** Conforme os modelos de primeiro nível têm seus parâmetros ajustados adaptativamente os modelos virtuais também tem seus parâmetros ajustados por leis idênticas. Assim, **uma combinação convexa de coeficientes constantes dos parâmetros de modelos de primeiro nível se comporta da mesma forma que um modelo de primeiro nível cujos parâmetros fossem inicializados nos mesmos valores.** Assumindo, então, que os elementos das matrizes corretas A_p e B_p pertencem inicialmente ao fecho convexo, podem ser representados por uma combinação convexa de coeficientes $\alpha_{i,sp}^*$, $i = 1, \dots, N$, dos parâmetros dos modelos de primeiro nível:

$$\begin{aligned}
A_p &= \sum_{i=1}^N \hat{A}_{i,sp} \alpha_{i,sp}^* \\
B_p &= \sum_{i=1}^N \hat{B}_{i,sp} \alpha_{i,sp}^* \\
\sum_{i=1}^N \alpha_{i,sp}^* &= 1 \\
0 &\leq \alpha_{i,sp}^* \leq 1
\end{aligned} \tag{2.43}$$

e definimos o modelo virtual:

$$\Sigma_{\alpha,sp} : \dot{\hat{x}}_{\alpha,sp} = A_m \hat{x}_{\alpha,sp} + (A_p - A_m)x_p + B_p u \tag{2.44}$$

com erro de identificação:

$$e_{\alpha,sp} \triangleq \hat{x}_{\alpha,sp} - x_p \tag{2.45}$$

cujas dinâmica é simplesmente:

$$\dot{e}_{\alpha,sp} = A_m e_{\alpha,sp} \tag{2.46}$$

e como vimos as estimativas acima são atualizadas da mesma forma que seriam para um modelo de primeiro nível inicializado nos valores corretos. Podemos verificar pelas equações acima que um modelo inicializado nos valores corretos com erro de identificação inicialmente nulo tem erro de identificação identicamente nulo. Suas estimativas são identicamente os valores corretos. Temos então que:

$$e_{\alpha,sp} \equiv 0 \tag{2.47}$$

e portanto se os parâmetros verdadeiros da planta pertencem inicialmente ao fecho convexo formado pelos parâmetros dos modelos de primeiro nível, devem fazê-lo para todo o tempo t .

Como vimos, se os parâmetros da planta pertencem ao fecho convexo formado pelos parâmetros dos modelos de primeiro nível, existe pelo menos uma combinação convexa de coeficientes $\alpha_{i,sp}^*, i = 1, \dots, N$, que caracteriza a planta para todo o tempo t , e portanto os coeficientes podem servir como uma alternativa de parametrização para a planta. Então, como uma segunda camada de estimação, ou **segundo nível de adaptação**, podemos estimar os coeficientes da combinação linear convexa. Assim, podemos estimar os coeficientes $\alpha_{i,sp}^*$ por:

$$e_{\alpha,sp} = \sum_{i=1}^N e_{i,sp} \alpha_{i,sp}^* = \mathbf{0}$$

e definindo:

$$\bar{E}_{sp} = [e_{1,sp} \quad e_{2,sp} \quad \dots \quad e_{N,sp}] \quad (2.48)$$

e:

$$\alpha_{sp}^* = [\alpha_{1,sp}^* \quad \alpha_{2,sp}^* \quad \dots \quad \alpha_{N,sp}^*] \quad (2.49)$$

podemos escrever em forma matricial:

$$\bar{E}_{sp} \bar{\alpha}_{sp}^* = \sum_{i=1}^N e_{i,sp} \alpha_{i,sp}^* = 0 \quad (2.50)$$

e definindo:

$$E_{sp} \triangleq [e_{1,sp} - e_{N,sp} \quad e_{2,sp} - e_{N,sp} \quad \dots \quad e_{N-1,sp} - e_{N,sp}] \quad (2.51)$$

e:

$$\alpha_{sp}^* \triangleq [\alpha_{1,sp}^* \quad \alpha_{2,sp}^* \quad \dots \quad \alpha_{N-1,sp}^*] \quad (2.52)$$

com estas variáveis definidas podemos escrever:

$$E_{sp} \alpha_{sp}^* = -e_{N,sp} \quad (2.53)$$

e substituindo o vetor α_{sp}^* por uma estimativa α_{sp} , como anteriormente, pode-se obter uma equação diferencial para estimar α_{sp}^* :

$$\dot{\alpha}_{sp} = -\gamma_{n2,sp} E_{sp}^T E_{sp} \alpha_{sp} - \gamma_{n2,sp} E_{sp}^T e_{N,sp} \quad (2.54)$$

em que $\gamma_{n2,sp} > 0$ é chamado ganho adaptativo de segundo nível e a estimativa $\bar{\alpha}_{sp}$ de $\bar{\alpha}_{sp}^*$ fica da forma:

$$\bar{\alpha}_{sp}^T = [\alpha_{sp}^T \quad 1 - \vec{\mathbf{1}} \alpha_{sp}] \quad (2.55)$$

onde $\vec{\mathbf{1}}$ é o vetor linha $[1 \quad 1 \quad \dots \quad 1]$ de tamanho apropriado. Definimos, então, o erro paramétrico para a estimativa $\bar{\alpha}_{sp}$ e para α_{sp} :

$$\begin{aligned} \tilde{\alpha}_{sp} &\triangleq \bar{\alpha}_{sp} - \bar{\alpha}_{sp}^* \\ \tilde{\alpha}_{sp} &\triangleq \alpha_{sp} - \alpha_{sp}^* \end{aligned} \quad (2.56)$$

e como $\tilde{\alpha}_{sp}^*$ é invariante no tempo, escrevemos:

$$\begin{aligned}\dot{\tilde{\alpha}}_{sp} &= \dot{\alpha}_{sp} - \dot{\tilde{\alpha}}_{sp}^* = \dot{\alpha}_{sp} \\ \dot{\tilde{\alpha}}_{sp} &= \dot{\alpha}_{sp} - \dot{\tilde{\alpha}}_{sp}^* = \dot{\alpha}_{sp}\end{aligned}\quad (2.57)$$

tal que, substituindo $\dot{\alpha}_{sp}$ por $\dot{\tilde{\alpha}}_{sp}$ e α_{sp} por $\tilde{\alpha}_{sp} + \alpha_{sp}^*$ em 2.54 e cancelando os termos equivalentes devido a 2.53, temos:

$$\dot{\tilde{\alpha}}_{sp} = -\gamma_{n2,sp} E_{sp}^T E_{sp} \tilde{\alpha}_{sp} \quad (2.58)$$

a partir de uma candidata a função de Lyapunov definida positiva:

$$V(\tilde{\alpha}_{sp}) = \frac{1}{2\gamma_{n2,sp}} \tilde{\alpha}_{sp}^T \tilde{\alpha}_{sp} \quad (2.59)$$

derivando ao longo das trajetórias teremos:

$$\dot{V} = -N \tilde{\alpha}_{sp}^T E_{sp}^T E_{sp} \tilde{\alpha}_{sp} \quad (2.60)$$

nesta expressão de $\dot{V}$ fica expressa uma característica importante da Adaptação de Segundo Nível, isto é, a velocidade com que a função de energia V decresce está relacionada com o número de modelos escolhidos, de forma que quanto mais modelos de identificação de primeiro nível forem usados, mais rápida será a convergência dos parâmetros. $\dot{V}$ é semi-definida negativa e portanto V não pode crescer, temos então que:

$$\tilde{\alpha}_{sp} \in \mathcal{L}_\infty \rightarrow \tilde{\alpha}_{sp} \in \mathcal{L}_\infty$$

e que:

$$\tilde{\alpha}_{sp} \in \mathcal{L}_\infty \rightarrow \tilde{\alpha}_{sp} \in \mathcal{L}_\infty$$

$$\tilde{\alpha}_{sp} \in \mathcal{L}_\infty \rightarrow \alpha_{sp} \in \mathcal{L}_\infty$$

e como:

$$E_{sp}, \alpha_{sp} \in \mathcal{L}_\infty \rightarrow \dot{\alpha}_{sp}, \dot{\tilde{\alpha}}_{sp} \in \mathcal{L}_\infty$$

quando o sinal de controle u for persistentemente excitante teremos que E_{sp} só será a matriz nula a partir de algum instante qualquer se as estimativas dos parâmetros forem equivalentes aos parâmetros corretos A_p e B_p , o que indica que uma combinação convexa destes parâmetros também tenderá para os valores corretos. As estimativas dos parâmetros A_p e B_p da planta, $\hat{A}_{n2,sp}$ e $\hat{B}_{n2,sp}$ são entregues

pela combinação convexa de coeficientes $\alpha_{i,sp}, i = 1, \dots, N$ dos parâmetros $\hat{A}_{i,sp}$ e $\hat{B}_{i,sp}, i = 1, \dots, N$:

$$\begin{aligned}\hat{A}_{n2,sp} &= \text{proj}_{S_{\theta,a}}(\alpha_{1,sp}\hat{A}_{1,sp} + \alpha_{2,sp}\hat{A}_{2,sp} + \dots + \alpha_{N,sp}\hat{A}_{N,sp}) \\ \hat{B}_{n2,sp} &= \text{proj}_{S_{\theta,b}}(\alpha_{1,sp}\hat{B}_{1,sp} + \alpha_{2,sp}\hat{B}_{2,sp} + \dots + \alpha_{N,sp}\hat{B}_{N,sp})\end{aligned}\quad (2.61)$$

em que $\text{proj}_{S_{\theta,a}}(\cdot)$ é o operador de projeção retangular dentro da região de incerteza $S_{\theta,a}$ e $\text{proj}_{S_{\theta,b}}(\cdot)$ é o operador de projeção retangular dentro da região de incerteza $S_{\theta,b}$.

Adaptação de Segundo Nível com Fator de Esquecimento

No capítulo 1 vimos que é possível acumular informações sobre os erros de identificação dos modelos de primeiro nível de forma a melhorar a convergência das estimativas dos parâmetros para seus valores corretos. No entanto, estipulamos que era adequado integrar desde o instante inicial pois consideramos a planta invariante no tempo. Na prática o uso de métodos de identificação em tempo real se dá quando os parâmetros da planta variam lentamente ou não há tempo hábil para usar métodos de identificação por batelada. Neste caso, integrar desde o instante inicial como fizemos no capítulo 1 não é adequado. Se os parâmetros da planta variam lentamente então acumular informações recentes melhora os resultados de convergência das estimativas dos parâmetros para seus valores corretos. No entanto, acumular informações mais antigas pode produzir piora dos resultados. Assim, se quisermos acumular informações, devemos buscar algum critério de descarte de informações. Então, chegamos ao seguinte raciocínio:

$$\begin{aligned}E_{sp}^T E_{sp} \alpha_{sp}^* &= -E_{sp}^T e_{N,sp} \\ \int_0^t e^{-\sigma(t-\tau)} E_{sp}^T(\tau) E_{sp}(\tau) \alpha_{sp}^* d\tau &= - \int_0^t e^{-\sigma(t-\tau)} E_{sp}^T(\tau) e_{N,sp}(\tau) d\tau \\ \int_0^t e^{-\sigma(t-\tau)} E_{sp}^T(\tau) E_{sp}(\tau) d\tau \alpha_{sp}^* &= - \int_0^t e^{-\sigma(t-\tau)} E_{sp}^T(\tau) e_{N,sp}(\tau) d\tau \\ 0 &= - \int_0^t e^{-\sigma(t-\tau)} E_{sp}^T(\tau) E_{sp}(\tau) d\tau \alpha_{sp}^* - \int_0^t e^{-\sigma(t-\tau)} E_{sp}^T(\tau) e_{N,sp}(\tau) d\tau \\ 0 &= - \int_0^t e^{-\sigma(t-\tau)} E_{sp}^T(\tau) E_{sp}(\tau) d\tau \alpha_{sp}^* - E_{sp}^T E_{sp} \alpha_{sp}^* - \int_0^t e^{-\sigma(t-\tau)} E_{sp}^T(\tau) e_{N,sp}(\tau) d\tau - E_{sp}^T e_{N,sp}\end{aligned}$$

onde $\sigma > 0$ é chamado fator de esquecimento. Como os erros de identificação são uniformemente limitados e tendem a 0 a medida que o tempo t tende a infinito, as integrais são limitadas e tendem a valores nulos. Substituindo α_{sp}^* por sua estimativas e introduzindo o ganho adaptativo temos a seguinte equação:

$$\begin{aligned} \dot{\alpha}_{sp} = \gamma_{n2,sp} & \left(- \int_0^t e^{-\sigma(t-\tau)} E_{sp}^T(\tau) E_{sp}(\tau) d\tau \alpha_{sp} - E_{sp}^T E_{sp} \alpha_{sp} \right. \\ & \left. - \int_0^t e^{-\sigma(t-\tau)} E_{sp}^T(\tau) e_{N,sp}(\tau) d\tau - E_{sp}^T e_{N,sp} \right) \end{aligned}$$

por facilidade de notação, usamos variáveis para as integrais:

$$\begin{aligned} M_{sp} &= \int_0^t e^{-\sigma(t-\tau)} E_{sp}^T(\tau) E_{sp}(\tau) d\tau \\ v_{sp} &= \int_0^t e^{-\sigma(t-\tau)} E_{sp}^T(\tau) e_{N,sp}(\tau) d\tau \end{aligned} \quad (2.62)$$

que podem ser geradas diretamente estipulando $M_{sp}(0) = \mathbf{0}$ e $v_{sp}(0) = \mathbf{0}$ pelas equações diferenciais:

$$\begin{aligned} \dot{M}_{sp} &= -\sigma M_{sp} + E_{sp}^T E_{sp} \\ \dot{v}_{sp} &= -\sigma v_{sp} + E_{sp}^T e_{N,sp} \end{aligned} \quad (2.63)$$

e escrevemos:

$$\dot{\alpha}_{sp} = \gamma_{n2,sp} (-M_{sp} \alpha_{sp} - E_{sp}^T E_{sp} \alpha_{sp} - v_{sp} - E_{sp}^T e_{N,sp}) \quad (2.64)$$

usamos então uma candidata a função de Lyapunov definida positiva:

$$V = \frac{1}{2\gamma_{n2,sp}} \tilde{\alpha}_{sp}^T \tilde{\alpha}_{sp} \quad (2.65)$$

que resulta em:

$$\dot{V} = -N \tilde{\alpha}_{sp}^T (E_{sp}^T E_{sp} + M_{sp}) \tilde{\alpha}_{sp} \quad (2.66)$$

com a modificação proposta, a convergência de α_{sp} para α_{sp}^* passa a depender de informações presentes e passadas. Se a razão entre o autovalor máximo e o autovalor mínimo de quaisquer das matrizes $E_{sp}^T E_{sp}$, M_{sp} ou $E_{sp}^T E_{sp} + M_{sp}$ for adequada pode-se também calcular α_{sp}^* diretamente por inversão de matrizes.

2.3.2 Caso SISO

N Modelos de Identificação por Regressão Linear

Novamente, seja a planta:

$$\Sigma_{p,SISO} : G_p(s) = \frac{y(s)}{u(s)} = \frac{N_p(s)}{D_p(s)}$$

em que:

$$\begin{aligned} N_p(s) &= b_1 s^{n-1} + b_2 s^{n-2} + \dots + b_{n-1} s + b_n \\ D_p(s) &= s^n + a_1 s^{n-1} + a_2 s^{n-2} + \dots + a_{n-1} s + a_n \end{aligned} \quad (2.67)$$

em que os limitantes superiores $b_1^+, \dots, b_n^+, a_1^+, a_n^+$ e inferiores $b_1^-, \dots, b_n^-, a_1^-, a_n^-$ dos coeficientes $b_1, \dots, b_n, a_1, \dots, a_n$ são conhecidos. Desta forma as combinações de limitantes $b_1^+, \dots, b_n^+, a_1^+, a_n^+$ e $b_1^-, \dots, b_n^-, a_1^-, a_n^-$ representam vértices de um politopo convexo que delimita a região de incerteza $S_{\theta,f} \in R^{2n}$ dos coeficientes $b_1, \dots, b_n, a_1, \dots, a_n$. A região de incerteza $S_{\theta,f}$ é conhecida. E como definimos anteriormente:

$$\begin{aligned} z(s) &\triangleq \frac{s^n}{\Lambda(s)} y(s) \\ \phi(s) &\triangleq \left[\frac{-s^{n-1}y(s)}{\Lambda(s)} \quad \dots \quad \frac{-y(s)}{\Lambda(s)} \quad \frac{s^{n-1}u(s)}{\Lambda(s)} \quad \dots \quad \frac{u(s)}{\Lambda(s)} \right]^T \\ \theta_p^* &\triangleq [a_1 \quad \dots \quad a_n \quad b_1 \quad \dots \quad b_n]^T \end{aligned}$$

e o vetor regressor ϕ é gerado pela seguinte equação:

$$\begin{aligned} \dot{\phi}_1 &= \Lambda_c \phi_1 + l y \\ \dot{\phi}_2 &= \Lambda_c \phi_2 + l u \\ \phi &= [-\phi_1 \quad \phi_2]^T \end{aligned} \quad (2.68)$$

em que Λ_c e l são escolhidos de acordo com 2.12 e 2.13. Temos a seguinte parametrização:

$$z(s) = \theta_p^{*T} \phi$$

e os $i = 1, \dots, N$ modelos de identificação deste sinal:

$$\Sigma_{i,f} : \hat{z}_{i,f} = \hat{\theta}_{i,f}^T \phi \quad (2.69)$$

e os $i = 1, \dots, N$ erros paramétricos:

$$\tilde{\theta}_{i,f} = \hat{\theta}_{i,f} - \theta_p^* \quad (2.70)$$

definimos os $i = 1, \dots, N$ erros de identificação deste sinal:

$$e_{i,f} \triangleq \hat{z}_{i,f} - z \quad (2.71)$$

os erros de identificação normalizados são da forma:

$$\varepsilon_{i,f} = \frac{e_{i,f}}{m^2} \quad (2.72)$$

onde $m^2 = 1 + n_s^2$ e n_s escolhido tal que:

$$\frac{\phi}{m} \in \mathcal{L}_\infty$$

e temos que:

$$\varepsilon_{i,f} = \frac{\tilde{\theta}_{i,f} \phi}{m^2} \quad (2.73)$$

e os vetores de parâmetros $\hat{\theta}_{i,f}$, $i = 1, \dots, N$, são adaptados de acordo com o método do gradiente:

$$\dot{\hat{\theta}}_{i,f} = -\Gamma \varepsilon_{i,f} \phi \quad (2.74)$$

a partir desta lei adaptativa obtemos uma expressão para as dinâmicas $\dot{e}_{i,f}$:

$$\dot{e}_{i,f} = \dot{\tilde{\theta}}_{i,f}^T \phi + \tilde{\theta}_{i,f}^T \dot{\phi} = -\frac{1}{m^2} e_{i,f} \phi^T \Gamma \phi + \tilde{\theta}_{i,f}^T \dot{\phi} \quad (2.75)$$

os vetores de parâmetros $\hat{\theta}_{i,f}$, $i = 1, \dots, N$ formam um fecho convexo no espaço de parâmetros. Cada um dos pontos no interior ou fronteira deste fecho convexo pode ser representado por uma combinação convexa:

$$\begin{aligned} \hat{\theta}_{v,f} &= \sum_{i=1}^N \hat{\theta}_{i,f} \beta_{i,f} \\ \sum_{i=1}^N \beta_{i,f} &= 1 \\ 0 &\leq \beta_{i,f} \leq 1 \end{aligned} \quad (2.76)$$

se criarmos então um **MODELO DE IDENTIFICAÇÃO VIRTUAL** a partir de alguma destas combinações convexas:

$$\Sigma_{v,f} : \hat{z}_{v,f} = \theta_{v,f}^T \phi \quad (2.77)$$

e definirmos o erro de identificação para o modelo virtual:

$$e_{v,f} \triangleq \hat{z}_{v,f} - z \quad (2.78)$$

e definindo o erro paramétrico:

$$\tilde{\theta}_{v,f} = \hat{\theta}_{v,f} - \theta_p^* \quad (2.79)$$

a dinâmica do erro de identificação $e_{v,f}$ é:

$$\dot{e}_{v,f} = \dot{\tilde{\theta}}_{v,f}^T \phi + \tilde{\theta}_{v,f}^T \dot{\phi} \quad (2.80)$$

podemos manipular as expressões dos erros paramétricos:

$$\tilde{\theta}_{v,f} = \sum_{i=1}^N \hat{\theta}_{i,f} \beta_{i,f} - \theta_p^* = \sum_{i=1}^N \hat{\theta}_{i,f} \beta_{i,f} - \sum_{i=1}^N \theta_p^* \beta_{i,f} = \sum_{i=1}^N \tilde{\theta}_{i,f} \beta_{i,f} \quad (2.81)$$

segue que a lei adaptativa que governa o ajuste de $\hat{\theta}_{v,f}$ é da forma:

$$\dot{\hat{\theta}}_{v,f} = \sum_{i=1}^N \dot{\hat{\theta}}_{i,f} \beta_{i,f} = -\Gamma \sum_{i=1}^N \varepsilon_{i,f} \beta_{i,f} \phi \quad (2.82)$$

e temos que:

$$\dot{e}_{v,f} = -\frac{1}{m^2} \sum_{i=1}^N e_{i,f} \beta_{i,f} \phi^T \Gamma \phi + \sum_{i=1}^N \tilde{\theta}_{i,f}^T \beta_{i,f} \dot{\phi} \quad (2.83)$$

no entanto, ao contrário do caso do modelo série-paralelo, não dispomos de uma expressão no tempo para os erros de identificação. Podemos no entanto utilizar as expressões das dinâmicas dos erros de identificação $\dot{e}_{i,f}$, temos que a combinação

convexa $\sum_{i=1}^N \dot{e}_{i,f} \beta_{i,f}$ é da forma:

$$\sum_{i=1}^N \dot{e}_{i,f} \beta_{i,f} = \sum_{i=1}^N \dot{\tilde{\theta}}_{i,f}^T \beta_{i,f} \phi + \sum_{i=1}^N \tilde{\theta}_{i,f}^T \beta_{i,f} \dot{\phi} = \dot{e}_{v,f} \quad (2.84)$$

ou seja, a dinâmica $\frac{d}{dt}(\sum_{i=1}^N e_{i,f} \beta_{i,f})$ da combinação convexa $\sum_{i=1}^N e_{i,f} \beta_{i,f}$ é exatamente igual à dinâmica do erro de identificação do modelo virtual $e_{v,f}$. A combinação convexa dos erros de identificação tende exponencialmente para o valor do erro de identificação do modelo virtual. Se estipularmos que $e_{v,f}(0) =$

$\sum_{i=1}^N e_{i,f}(0)\beta_{i,f}$ então os dois se tornam equivalentes. Assim $\varepsilon_{v,f}$ se torna equivalente a $\sum_{i=1}^N \varepsilon_{i,f}\beta_{i,f}$. Feitas estas considerações, teremos então que a expressão da lei adaptativa para o modelo virtual se reduz a:

$$\dot{\hat{\theta}}_{v,f} = -\Gamma \varepsilon_{v,f} \phi \quad (2.85)$$

e novamente, a lei adaptativa obtida acima tem forma idêntica àquela usada nos modelos de primeiro nível $\Sigma_{i,f}$, $i = 1, \dots, N$. **Cada um dos pontos no interior do fecho convexo corresponde a um modelo virtual.** Conforme os modelos de primeiro nível têm seus parâmetros ajustados adaptativamente os modelos virtuais também tem seus parâmetros ajustados por leis idênticas. Nestas condições, **uma combinação convexa de coeficientes constantes dos parâmetros de modelos de primeiro nível se comporta como se fosse os parâmetros de um modelo de primeiro nível inicializados nos mesmos valores.** Assumindo, então, que os parâmetros verdadeiros da planta contidos no vetor θ_p^* pertencem inicialmente ao fecho convexo, podem ser representados por uma combinação convexa de coeficientes $\alpha_{i,f}^*, i = 1, \dots, N$ dos parâmetros dos modelos de primeiro nível:

$$\begin{aligned} \theta_p^* &= \sum_{i=1}^N \hat{\theta}_{i,f} \alpha_{i,f}^* \\ \sum_{i=1}^N \alpha_{i,f}^* &= 1 \\ 0 &\leq \alpha_{i,f}^* \leq 1 \end{aligned} \quad (2.86)$$

e definimos o modelo virtual:

$$\Sigma_{\alpha,f} : \hat{z}_{\alpha,f} = \theta_p^{*T} \phi \quad (2.87)$$

com erro de identificação:

$$e_{\alpha,f} \triangleq \hat{z}_{\alpha,f} - z \quad (2.88)$$

cujas dinâmica é:

$$\dot{e}_{\alpha,f} = -\frac{1}{m^2} e_{\alpha,f} \phi^T \Gamma \phi \quad (2.89)$$

que nos dá o seguinte resultado, caso $\lim_{t \rightarrow \infty} \phi \neq \mathbf{0}$:

$$\lim_{t \rightarrow \infty} e_{\alpha,f} = \lim_{t \rightarrow \infty} \sum_{i=1}^N e_{i,f} \alpha_{i,f}^* = 0 \quad (2.90)$$

desta forma, os parâmetros da planta podem deixar de pertencer ao fecho convexo devido ao efeito das condições iniciais. No entanto este resultado indica que os parâmetros da planta voltam a pertencer ao fecho convexo. Se a combinação convexa dos erros de identificação não-nulos se torna constante e nula a partir de um certo instante então a combinação convexa dos erros paramétricos também se torna constante e nula. Desta forma os coeficientes $\alpha_{i,f}^*, i = 1, \dots, N$ servem como alternativas de parametrização para a planta. Assim, como uma segunda camada de estimação, ou **segundo nível de adaptação**, podemos estimar os coeficientes da combinação linear. Consideramos, portanto, que a equação $\sum_{i=1}^N e_{i,f} \alpha_{i,f}^* = 0$ é uma ferramenta adequada de estimação. Definimos:

$$\bar{E}_f = [\varepsilon_{1,f} \quad \dots \quad \varepsilon_{N-1,f} \quad \varepsilon_{N,f}] \quad (2.91)$$

e:

$$\bar{\alpha}_f^* = [\alpha_{1,f}^* \quad \dots \quad \alpha_{N-1,f}^*] \quad (2.92)$$

tal que temos em forma matricial:

$$\bar{E}_f \bar{\alpha}_f^* = \sum_{i=1}^N \varepsilon_{i,f} \alpha_{i,f}^* = 0 \quad (2.93)$$

pela combinação convexa temos que:

$$\sum_{i=1}^N \alpha_{i,f} = 1$$

então o parâmetro $\alpha_{N,f}^*$ pode ser expresso por:

$$\alpha_{N,f} = 1 - \sum_{i=1}^{N-1} \alpha_{i,f}^*$$

e explicitando o último termo do somatório em $\bar{E}_f \bar{\alpha}_f^*$:

$$\bar{E}_f \bar{\alpha}_f^* = \sum_{i=1}^{N-1} e_{i,f} \alpha_{i,f}^* + \varepsilon_{N,f} \alpha_{N,f}^*$$

e então substituímos $\alpha_{N,f}$ por sua expressão:

$$\bar{E}_f \bar{\alpha}_f^* = \sum_{i=1}^{N-1} \varepsilon_{i,f} \alpha_{i,f}^* + \varepsilon_{N,f} (1 - \sum_{i=1}^{N-1} \alpha_{i,f}^*) = 0$$

que reorganizado fica da seguinte forma:

$$\sum_{i=1}^{N-1} (\epsilon_{i,f} - \epsilon_{N,f}) \alpha_{i,f}^* = -\epsilon_{N,f} \quad (2.94)$$

e definimos:

$$E_f = [\epsilon_{1,f} - \epsilon_{N,f} \quad \epsilon_{2,f} - \epsilon_{N,f} \quad \dots \quad \epsilon_{N-1,f} - \epsilon_{N,f}] \quad (2.95)$$

e:

$$\alpha_f^* = [\alpha_{1,f}^* \quad \alpha_{2,f}^* \quad \dots \quad \alpha_{N-1,f}^*] \quad (2.96)$$

com estas variáveis definidas, reescrevemos a equação como:

$$E_f \alpha_f^* = -\epsilon_{N,f} \quad (2.97)$$

e substituindo o vetor α_f^* por uma estimativa α_f , como anteriormente, pode-se obter uma equação diferencial para estimar α_f^* :

$$\dot{\alpha}_f = -\gamma_{n2,f} E_f^T E_f \alpha_f - \gamma_{n2,f} E_f^T \epsilon_{N,f} \quad (2.98)$$

onde $\gamma_{n2,f} > 0$ e a estimativa $\tilde{\alpha}_f$ de $\bar{\alpha}_f^*$ fica da forma:

$$\tilde{\alpha}_f^T = [\alpha_f^T \quad 1 - \vec{1} \alpha_f] \quad (2.99)$$

onde $\vec{1}$ é o vetor linha $[1 \quad 1 \quad \dots \quad 1]$ de tamanho apropriado. Definimos, então, o erro paramétrico para a estimativa $\tilde{\alpha}_f$ e para α_f :

$$\begin{aligned} \tilde{\tilde{\alpha}}_f &\triangleq \tilde{\alpha}_f - \alpha_f^* \\ \tilde{\alpha}_f &\triangleq \alpha_f - \alpha_f^* \end{aligned} \quad (2.100)$$

e como assumimos $\bar{\alpha}_f^*$ invariante no tempo, escrevemos:

$$\begin{aligned} \dot{\tilde{\tilde{\alpha}}}_f &= \dot{\tilde{\alpha}}_f - \cancel{\dot{\alpha}_f^*}^0 = \dot{\tilde{\alpha}}_f \\ \dot{\tilde{\alpha}}_f &= \dot{\alpha}_f - \cancel{\dot{\alpha}_f^*}^0 = \dot{\alpha}_f \end{aligned} \quad (2.101)$$

tal que, substituindo $\dot{\alpha}_f$ por $\dot{\tilde{\alpha}}_f$ e α_f por $\tilde{\alpha}_f + \alpha_f^*$ em 2.98 e cancelando os termos equivalentes devido a 2.97, temos:

$$\dot{\tilde{\alpha}}_f = -\gamma_{n2,f} E_f^T E_f \tilde{\alpha}_f - \gamma_{n2,f} E_f^T e_{\alpha,f} \frac{1}{m^2} \quad (2.102)$$

onde o termo $-\gamma_{n2,f} E_f^T e_{\alpha,f} \frac{1}{m^2}$ aparece devido às condições iniciais. E a partir de uma candidata a função de Lyapunov definida positiva:

$$V(\tilde{\alpha}_f) = \frac{1}{2\gamma_{n2,f}} \tilde{\alpha}_f^T \tilde{\alpha}_f \quad (2.103)$$

derivando ao longo das trajetórias teremos:

$$\dot{V} = \tilde{\alpha}_f^T \dot{\tilde{\alpha}}_f$$

e explicitando $\tilde{\alpha}_f$ e $\dot{\tilde{\alpha}}_f$:

$$\dot{V} = \begin{bmatrix} \tilde{\alpha}_f^T & \mathbf{1} \tilde{\alpha}_f \end{bmatrix} \begin{bmatrix} \dot{\tilde{\alpha}}_f^T \\ \mathbf{1} \dot{\tilde{\alpha}}_f \end{bmatrix}$$

ao substituírmos $\dot{\tilde{\alpha}}_f$ por 2.102 e reorganizarmos, obtemos:

$$\dot{V} = -N \tilde{\alpha}_f^T E_f^T E_f \tilde{\alpha}_f - N \tilde{\alpha}_f^T E_f^T e_{\alpha,f} \frac{1}{m^2} \quad (2.104)$$

e pode-se sempre escolher $\Lambda(s)$ tal que o termo de sinal indefinido $-N \tilde{\alpha}_f^T E_f^T E_f \tilde{\alpha}_f$ tenda para 0 mais rapidamente que o termo de sinal definido. Nesta expressão de $\dot{V}$ fica expresso novamente que a rapidez de convergência dos parâmetros depende do número de modelos N . V não pode crescer a partir de um certo instante, temos então que:

$$\tilde{\alpha}_f \in \mathcal{L}_\infty \rightarrow \tilde{\alpha}_f \in \mathcal{L}_\infty$$

e que:

$$\tilde{\alpha}_f \in \mathcal{L}_\infty \rightarrow \tilde{\alpha}_f \in \mathcal{L}_\infty$$

$$\tilde{\alpha}_f \in \mathcal{L}_\infty \rightarrow \alpha_f \in \mathcal{L}_\infty$$

e como:

$$E_f, \alpha_f \in \mathcal{L}_\infty \rightarrow \dot{\alpha}_f, \dot{\tilde{\alpha}}_f \in \mathcal{L}_\infty$$

quando o sinal de controle u for persistentemente excitante teremos que E_f só será o vetor nulo a partir de algum instante quando as estimativas forem equivalentes ao vetor de parâmetros corretos θ_p^* , o que indica que uma combinação convexa destes parâmetros também tenderá para os valores corretos. A estimativa do vetor de parâmetros θ_p^* da planta, $\hat{\theta}_{n2,f}$ é entregue pela combinação convexa de coeficientes $\alpha_{i,f}, i = 1, \dots, N$ dos parâmetros $\hat{\theta}_{i,f}, i = 1, \dots, N$:

$$\hat{\theta}_{n2,f} = \text{proj}_{S_{\theta,f}}(\alpha_{1,f} \hat{\theta}_{1,f} + \alpha_{2,f} \hat{\theta}_{2,f} + \dots + \alpha_{N,f} \hat{\theta}_{N,f}) \quad (2.105)$$

em que $proj_{S_{\theta,f}}(\cdot)$ é o operador de projeção retangular dentro da região de incerteza $S_{\theta,f}$.

Comentário acerca da escolha dos parâmetros iniciais

Diferentemente dos Modelos de Identificação Série-Paralelos, as saídas $z_{i,f}(t)$ dos Modelos de Identificação por Regressão Linear são limitadas independentemente do valor dos parâmetros iniciais escolhidos, desde que sejam limitados, devido ao fato de que utilizamos o erro de identificação normalizado para atualizar os valores dos parâmetros e os sinais $z_{i,f}(t)$ serem gerados por regressão linear. Isto permite, por exemplo, a escolha de modelos com grandes diferenças de valores entre seus parâmetros iniciais ou que representam plantas instáveis sem maiores preocupações. Comparado com Modelos Série-Paralelos, a escolha de parâmetros iniciais muito discrepantes pode gerar problemas de atenuação excessiva dos erros de identificação $e_{i,sp}$ ao escolher uma matriz A_m que seja simultaneamente capaz de estabilizar modelos de identificação com parâmetros iniciais muito grandes e parâmetros iniciais muito pequenos em módulo. Para ilustrar, considere a seguinte planta instável de ordem 1:

$$\Sigma_p : G(s) = \frac{b}{s+a} = \frac{20}{s-50}$$

vamos assumir que o sinal $u(t)$ é tal que a saída $y(t)$ da planta é limitada. Sabemos que $b \in [19 \ 21]$ e $a \in [-1 \ -1000]$. Podemos escolher os seguintes 4 pares de estimativas iniciais dos parâmetros da planta, tal que a região de incerteza dos parâmetros esteja contida no fecho convexo: $b_1 = 19, a_1 = -1, b_2 = 19, a_2 = -1000, b_3 = 21, a_3 = -1, b_4 = 21, a_4 = -1000$. Se os modelos forem do tipo Série-Paralelo, será necessário escolher um parâmetro $a_m > 1000$ de forma a tornar os modelos 2 e 4 estáveis. No entanto, neste caso teremos $|a_m| \gg |a_1|$ e $|a_m| \gg |a_3|$, o que fará com que os erros $e_{1,sp}$ e $e_{3,sp}$ sejam praticamente nulos, tornando a adaptação dos modelos 1 e 3 extremamente lenta. No entanto, se forem usados Modelos por Regressão Linear, a escolha de um polinômio com raiz que seja, em módulo, comparativamente pequena aos limitantes superiores, como por exemplo $\Lambda(s) = s + 1$, não tornará os modelos 2 e 4 instáveis.

Adaptação de Segundo Nível com Fator de Esquecimento

No capítulo 1 vimos que é possível acumular informações sobre os erros de identificação dos modelos de primeiro nível de forma a melhorar a convergência das estimativas dos parâmetros para seus valores corretos. No entanto, estipulamos que era adequado integrar desde o instante inicial pois consideramos a planta invariante no tempo. Na prática o uso de métodos de identificação em tempo real

se dá quando os parâmetros da planta variam lentamente ou não há tempo hábil para usar métodos de identificação por batelada. Neste caso, integrar desde o instante inicial como fizemos no capítulo 1 não é adequado. Se os parâmetros da planta variam lentamente então acumular informações recentes melhora os resultados de convergência das estimativas dos parâmetros para seus valores corretos. No entanto, acumular informações mais antigas pode produzir piora dos resultados. Assim, se quisermos acumular informações, devemos buscar um critério de descarte de informações. Como anteriormente no caso MIMO, chegamos ao seguinte raciocínio:

$$\begin{aligned}
E_f^T E_f \alpha_f^* &= -E_f^T \varepsilon_{N,f} \\
\int_0^t e^{-\sigma(t-\tau)} E_f^T(\tau) E_f(\tau) \alpha_f^* d\tau &= -\int_0^t e^{-\sigma(t-\tau)} E_f^T(\tau) \varepsilon_{N,f}(\tau) d\tau \\
\int_0^t e^{-\sigma(t-\tau)} E_f^T(\tau) E_f(\tau) d\tau \alpha_f^* &= -\int_0^t e^{-\sigma(t-\tau)} E_f^T(\tau) \varepsilon_{N,f}(\tau) d\tau \\
0 &= -\int_0^t e^{-\sigma(t-\tau)} E_f^T(\tau) E_f(\tau) d\tau \alpha_f^* - \int_0^t e^{-\sigma(t-\tau)} E_f^T(\tau) \varepsilon_{N,f}(\tau) d\tau \\
0 &= -\int_0^t e^{-\sigma(t-\tau)} E_f^T(\tau) E_f(\tau) d\tau \alpha_f^* - E_f^T E_f \alpha_f^* - \int_0^t e^{-\sigma(t-\tau)} E_f^T(\tau) \varepsilon_{N,f}(\tau) d\tau - E_f^T \varepsilon_{N,f}
\end{aligned}$$

onde $\sigma > 0$ é chamado fator de esquecimento. Como os erros de identificação são uniformemente limitados e tendem a 0 a medida que o tempo t tende a infinito, as integrais são limitadas e tendem a valores nulos. Substituindo α_f^* por sua estimativas e introduzindo o ganho adaptativo temos a seguinte equação:

$$\dot{\alpha}_f = \gamma_{n2,f} \left(-\int_0^t e^{-\sigma(t-\tau)} E_f^T(\tau) E_f(\tau) d\tau \alpha_f - E_f^T E_f \alpha_f - \int_0^t e^{-\sigma(t-\tau)} E_f^T(\tau) \varepsilon_{N,f}(\tau) d\tau - E_f^T \varepsilon_{N,f} \right)$$

por facilidade de notação, usamos variáveis para as integrais:

$$\begin{aligned}
M_f &= \int_0^t e^{-\sigma(t-\tau)} E_f^T(\tau) E_f(\tau) d\tau \\
v_f &= \int_0^t e^{-\sigma(t-\tau)} E_f^T(\tau) \varepsilon_{N,f}(\tau) d\tau
\end{aligned} \tag{2.106}$$

que podem ser geradas diretamente estipulando $M_f(0) = \mathbf{0}$ e $v_f(0) = \mathbf{0}$ pelas equações diferenciais:

$$\begin{aligned}\dot{M}_f &= -\sigma M_f + E_f^T E_f \\ \dot{v}_f &= -\sigma v_f + E_f^T \epsilon_{N,f}\end{aligned}\tag{2.107}$$

e escrevemos:

$$\dot{\alpha}_f = \gamma_{n2,f}(-M_f \alpha_f - E_f^T E_f \alpha_f - v_f - E_f^T \epsilon_{N,f})\tag{2.108}$$

usamos então uma candidata a função de Lyapunov definida positiva:

$$V = \frac{1}{2\gamma_{n2,f}} \tilde{\alpha}_f^T \tilde{\alpha}_f\tag{2.109}$$

que resulta em:

$$\dot{V} = -N \tilde{\alpha}_f^T (E_f^T E_f + M_f) \tilde{\alpha}_f - N \tilde{\alpha}_f^T E_f^T e_{\alpha,f} \frac{1}{m^2} - N \tilde{\alpha}_f^T M_f \alpha_f^*\tag{2.110}$$

temos que $N \tilde{\alpha}_f^T M_f \alpha_f^* = N \int_0^t e^{-\sigma(t-\tau)} E_f^T(\tau) e_{\alpha}(\tau) d\tau$. Novamente, sempre é possível escolher $\Lambda(s)$ tal que os termos de sinal indefinido $-N \tilde{\alpha}_f^T E_f^T e_{\alpha,f} - N \tilde{\alpha}_f^T M_f \alpha_f^*$ tendam para 0 mais rapidamente que o termo de sinal definido $-N \tilde{\alpha}_f^T (E_f^T E_f + M_f) \tilde{\alpha}_f$. Dizemos isto pois os termos de sinal indefinido dependem das condições iniciais, que estão embutidas no escalar $e_{\alpha,f}$, que decai exponencialmente. Com a modificação proposta a convergência de α_f para α_f^* passa a depender de informações presentes e passadas. Outra forma de calcular os coeficientes corretos é monitorando os autovalores de M_f . Se a razão entre o autovalor máximo e o autovalor mínimo da matriz M_f for adequada pode-se calcular α_f^* diretamente por inversão de matrizes resolvendo o sistema de equações $M_f \alpha_f^* = -v_f$ para α_f^* .

2.4 Resumo dos Algoritmos e Estudos de Simulação

Apresentamos o Modelo de Identificação Série-Paralelo para a planta MIMO e o Modelo de Identificação por Regressão Linear para a planta SISO neste segundo capítulo. Discutimos algumas de suas propriedades para a planta estável de ordem n e grau relativo 1. Mostramos que o erro de identificação tende a $\mathbf{0}$ para estes modelos. Mencionamos que as estimativas tendem aos valores corretos na presença de um sinal de entrada com a característica de persistência de excitação. Provamos, para os Modelos de Primeiro Nível que existem coeficientes constantes

de uma combinação convexa das estimativas dos parâmetros de N ou mais Modelos que produzem os parâmetros da planta. Demonstramos como uma **segunda camada de adaptação**, ou uma **adaptação em dois níveis** pode-se atualizar estimativas destes coeficientes para calcular uma estimativa de segundo nível dos parâmetros da planta.

2.4.1 Resumo dos Algoritmos

Caso o leitor deseje consultar rapidamente, listamos os algoritmos de identificação de primeiro e segundo nível de forma compacta. A operação $\text{vec}(M)$ toma como argumento uma matriz $M \in R^{n \times m}$ e retorna um vetor coluna $m \in R^{nm \times 1}$, formado pelas colunas de M empilhadas. A adaptação destes algoritmos para uma linguagem de programação qualquer é razoavelmente simples. Seguem os algoritmos:

Série-Paralelo	Regressão Linear
$\Sigma_p : \dot{x}_p = A_p x_p + B_p u$	$\Sigma_p : \dot{x}_p = A_p x_p + b_p u$
$\Sigma_{1,sp} : \dot{\hat{x}}_{1,sp} = A_m \hat{x}_{1,sp} + \hat{A}_{1,sp} x_p - A_m x_p + \hat{B}_{1,sp} u$	$y_p = h_p^T x_p$
$e_{1,sp} = \hat{x}_{1,sp} - x_p$	$z = \frac{s^n y}{\Lambda(s)}$
$\dot{\hat{A}}_{1,sp} = -P e_{1,sp} x_p^T$	$\dot{\phi}_1 = \Lambda_c \phi_1 + l y_p$
$\dot{\hat{B}}_{1,sp} = -P e_{1,sp} u^T$	$\dot{\phi}_2 = \Lambda_c \phi_2 + l u$
	$\phi^T = [\phi_1 \quad \phi_2]$
	$\Sigma_{1,f} : \hat{z}_{1,f} = \hat{\theta}_{1,f} \phi$
	$e_{1,f} = \hat{z}_{1,f} - z$
	$n_s^2 = \phi^T \phi$
	$Q = Q^T > 0$
	$m^2 = 1 + n_s^2$
	$\epsilon_{1,f} = \frac{e_{1,f}}{m^2}$
	$\Gamma = \Gamma^T > 0$
	$\dot{\hat{\theta}}_{1,f} = -\Gamma \epsilon_{1,f} \phi$

Segundo Nível Série-Paralelo	Segundo Nível Série-Paralelo Modificado
$\Sigma_p : \dot{x}_p = A_p x_p + B_p u$ $\Sigma_{i,sp} : \dot{\hat{x}}_{i,sp} = A_m \hat{x}_{i,sp} + \hat{A}_{i,sp} x_p - A_m x_p + \hat{B}_{i,sp} u$ $e_{i,sp} = \hat{x}_{i,sp} - x_p$ $\dot{\hat{A}}_{i,sp} = -P e_{i,sp} x_p^T$ $\dot{\hat{B}}_{i,sp} = -P e_{i,sp} u^T$ $E_{sp} = [e_{1,sp} - e_{N,sp} \quad \dots \quad e_{N-1,sp} - e_{N,sp}]$ $\dot{\alpha}_{sp} = -E_{sp}^T E_{sp} \alpha_{sp} - E_{sp}^T e_{N,sp}$ $\bar{\Theta}_{sp} = \begin{bmatrix} \text{vec}(\hat{A}_{1,sp}) & \dots & \text{vec}(\hat{A}_{N,sp}) \\ \text{vec}(\hat{B}_{1,sp}) & \dots & \text{vec}(\hat{B}_{N,sp}) \end{bmatrix}$ $\bar{\alpha}_{sp}^T = [\alpha_{sp}^T \quad 1 - \bar{\mathbf{1}} \alpha_{sp}]$ $\begin{bmatrix} \text{vec}(\hat{A}_{n2,sp}) \\ \text{vec}(\hat{B}_{n2,sp}) \end{bmatrix} = \bar{\Theta}_{sp} \bar{\alpha}_{sp}$	$\Sigma_p : \dot{x}_p = A_p x_p + B_p u$ $\Sigma_{i,sp} : \dot{\hat{x}}_{i,sp} = A_m \hat{x}_{i,sp} + \hat{A}_{i,sp} x_p - A_m x_p + \hat{B}_{i,sp} u$ $e_{i,sp} = \hat{x}_{i,sp} - x_p$ $\dot{\hat{A}}_{i,sp} = -P e_{i,sp} x_p^T$ $\dot{\hat{B}}_{i,sp} = -P e_{i,sp} u^T$ $E_{sp} = [e_{1,sp} - e_{N,sp} \quad \dots \quad e_{N-1,sp} - e_{N,sp}]$ $M_{sp}(0) = \mathbf{0}$ $v_{sp}(0) = \mathbf{0}$ $\dot{M}_{sp} = -\sigma M_{sp} + E_{sp}^T E_{sp}$ $\dot{v}_{sp} = -\sigma v_{sp} + E_{sp}^T e_{N,sp}$ $\dot{\alpha}_{sp} = -(E_{sp}^T E_{sp} + M_{sp}) \alpha_{sp} - E_{sp}^T e_{N,sp} - v_{sp}$ $\bar{\Theta}_{sp} = \begin{bmatrix} \text{vec}(\hat{A}_{1,sp}) & \dots & \text{vec}(\hat{A}_{N,sp}) \\ \text{vec}(\hat{B}_{1,sp}) & \dots & \text{vec}(\hat{B}_{N,sp}) \end{bmatrix}$ $\bar{\alpha}_{sp}^T = [\alpha_{sp}^T \quad 1 - \bar{\mathbf{1}} \alpha_{sp}]$ $\begin{bmatrix} \text{vec}(\hat{A}_{n2,sp}) \\ \text{vec}(\hat{B}_{n2,sp}) \end{bmatrix} = \bar{\Theta}_{sp} \bar{\alpha}_{sp}$

Segundo Nível Regressão Linear	Segundo Nível Regressão Linear Modificado
$\Sigma_p : \dot{x}_p = A_p x_p + b_p u$ $y_p = h_p^T x_p$ $z = \frac{s^n y}{\Lambda(s)}$ $\dot{\phi}_1 = \Lambda_c \phi_1 + l y_p$ $\dot{\phi}_2 = \Lambda_c \phi_2 + l u$ $\phi^T = [-\phi_1 \quad \phi_2]$ $\Sigma_{i,f} : \hat{z}_{i,f} = \hat{\theta}_{i,f} \phi$ $e_{i,f} = \hat{z}_{i,f} - z$ $n_s^2 = \phi^T \phi$ $Q = Q^T > 0$ $m^2 = 1 + n_s^2$ $\epsilon_{i,f} = \frac{e_{i,f}}{m^2}$ $\Gamma = \Gamma^T > 0$ $\dot{\hat{\theta}}_{i,f} = -\Gamma \epsilon_{i,f} \phi$ $E_f = [\epsilon_{1,f} - \epsilon_{N,f} \quad \dots \quad \epsilon_{N-1,f} - \epsilon_{N,f}]$ $\dot{M}_f = -\sigma M_f + E_f^T E_f$ $\dot{v}_f = -\sigma v_f + E_f^T \epsilon_{N,f}$ $\dot{\alpha}_f = -(E_f^T E_f + M_f) \alpha_f - E_f^T \epsilon_{N,f} - v_f$ $\bar{\alpha}_f^T = [\alpha_f^T \quad 1 - \vec{1} \alpha_f]$ $\hat{\theta}_{n2,f} = \bar{\Theta}_f \bar{\alpha}_f$	$\Sigma_p : \dot{x}_p = A_p x_p + b_p u$ $y_p = h_p^T x_p$ $z = \frac{s^n y}{\Lambda(s)}$ $\dot{\phi}_1 = \Lambda_c \phi_1 + l y_p$ $\dot{\phi}_2 = \Lambda_c \phi_2 + l u$ $\phi^T = [-\phi_1 \quad \phi_2]$ $\Sigma_{i,f} : \hat{z}_{i,f} = \hat{\theta}_{i,f} \phi$ $e_{i,f} = \hat{z}_{i,f} - z$ $n_s^2 = \phi^T \phi$ $Q = Q^T > 0$ $m^2 = 1 + n_s^2$ $\epsilon_{i,f} = \frac{e_{i,f}}{m^2}$ $\Gamma = \Gamma^T > 0$ $\dot{\hat{\theta}}_{i,f} = -\Gamma \epsilon_{i,f} \phi$ $E_f = [\epsilon_{1,f} - \epsilon_{N,f} \quad \dots \quad \epsilon_{N-1,f} - \epsilon_{N,f}]$ $M_f(0) = \mathbf{0}$ $v_f(0) = \mathbf{0}$ $\dot{M}_f = -\sigma M_f + E_f^T E_f$ $\dot{v}_f = -\sigma v_f + E_f^T \epsilon_{N,f}$ $\dot{\alpha}_f = -(E_f^T E_f + M_f) \alpha_f - E_f^T \epsilon_{N,f} - v_f$ $\bar{\alpha}_f^T = [\alpha_f^T \quad 1 - \vec{1} \alpha_f]$ $\hat{\theta}_{n2,f} = \bar{\Theta}_f \bar{\alpha}_f$

2.4.2 Estudos de Simulação

Caso MIMO

Considere a Planta a seguir:

$$\dot{x}_p = A_p x_p + b_p u = \begin{bmatrix} -1 & -2 \\ 0 & -3 \end{bmatrix} x_p + \begin{bmatrix} 2 \\ 3 \end{bmatrix} u$$

onde os elementos das matrizes A_p e do vetor b_p pertencem a uma região de

incerteza conhecida:

$$a_{11} \in [-3 \quad -0.5]$$

$$a_{12} \in [-4 \quad -1]$$

$$a_{21} \in [-1 \quad 1]$$

$$a_{22} \in [-4 \quad -2]$$

$$b_1 \in [1 \quad 5]$$

$$b_2 \in [2 \quad 6]$$

e desejamos identificar os parâmetros desta planta em tempo real, assumindo que o vetor de estado x_p e a entrada u estão disponíveis para medição. Usamos o Modelo Série-Paralelo e a Adaptação de Segundo Nível com e sem Fator de Esquecimento. Lembramos que a Adaptação de Segundo Nível consiste na combinação convexa das estimativas de um conjunto de Modelos de Primeiro Nível. Os coeficientes da combinação convexa também estão sendo atualizados. Através desta adaptação em duas camadas se forma uma estimativa de Segundo Nível. Usaremos o número mínimo de modelos para este caso, $N = 7$. Para facilitar a comparação entre os resultados plotamos os gráficos das estimativas para cada caso na mesma figura. Omitimos informações consideradas de pouca relevância como por exemplo os gráficos dos Modelos de Identificação de Primeiro Nível cujas estimativas iniciais não coincidem com as estimativas iniciais de Segundo Nível. Para inicializar as simulações, usamos os seguintes valores:

$$A_m = \begin{bmatrix} -10 & 0 \\ 0 & -20 \end{bmatrix}$$

$$Q = \begin{bmatrix} -200 & 0 \\ 0 & -200 \end{bmatrix} \rightarrow P = \begin{bmatrix} 20 & 0 \\ 0 & 10 \end{bmatrix}$$

$$x_p(0) = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

$$u(t) = 1 + \sin(t) + \sin(1.7t) + \sin(3t)$$

$$\alpha_{1,sp}(0) = 1$$

$$\alpha_i(0) = 0, \quad i \neq 1$$

$$\gamma_{n2,sp} = 50$$

$$\sigma = 0.2$$

note-se que $u(t)$ foi escolhido PE de ordem 3 pois temos 6 parâmetros para estimar. Escolhemos estimativas iniciais para a matriz A_p :

$$\begin{aligned}
\hat{A}_{1,sp}(0) &= \begin{bmatrix} -3 & -4 \\ -1 & -3 \end{bmatrix} \\
\hat{A}_{2,sp}(0) &= \begin{bmatrix} 14.5 & -4 \\ -1 & -3 \end{bmatrix} \\
\hat{A}_{3,sp}(0) &= \begin{bmatrix} -3 & 17 \\ -1 & -3 \end{bmatrix} \\
\hat{A}_{4,sp}(0) &= \begin{bmatrix} -3 & -4 \\ 13 & -3 \end{bmatrix} \\
\hat{A}_{5,sp}(0) &= \begin{bmatrix} -3 & -4 \\ -1 & 10 \end{bmatrix} \\
\hat{A}_{6,sp}(0) &= \begin{bmatrix} -3 & -4 \\ -1 & -3 \end{bmatrix} \\
\hat{A}_{7,sp}(0) &= \begin{bmatrix} -3 & -4 \\ -1 & -3 \end{bmatrix}
\end{aligned}$$

e para o vetor b_p :

$$\begin{aligned}
\hat{b}_{1,sp}(0) &= \begin{bmatrix} 1 \\ 2 \end{bmatrix} \\
\hat{b}_{2,sp}(0) &= \begin{bmatrix} 1 \\ 2 \end{bmatrix} \\
\hat{b}_{3,sp}(0) &= \begin{bmatrix} 1 \\ 2 \end{bmatrix} \\
\hat{b}_{4,sp}(0) &= \begin{bmatrix} 1 \\ 2 \end{bmatrix} \\
\hat{b}_{5,sp}(0) &= \begin{bmatrix} 1 \\ 2 \end{bmatrix} \\
\hat{b}_{6,sp}(0) &= \begin{bmatrix} 29 \\ 2 \end{bmatrix} \\
\hat{b}_{7,sp}(0) &= \begin{bmatrix} 1 \\ 30 \end{bmatrix}
\end{aligned}$$

e obtivemos os seguintes resultados:




Figura 2.1: Comportamento das estimativas do elemento a_{11} da matriz A_p para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.




Figura 2.2: Comportamento das estimativas do elemento a_{12} da matriz A_p para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.




Figura 2.3: Comportamento das estimativas do elemento a_{21} da matriz A_p para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.




Figura 2.4: Comportamento das estimativas do elemento a_{22} da matriz A_p para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.




Figura 2.5: Comportamento das estimativas do elemento b_1 do vetor b_p para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.




Figura 2.6: Comportamento das estimativas do elemento b_2 do vetor b_p para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.




Figura 2.7: Primeiro elemento do vetor erro de Identificação do Modelo de Primeiro Nível com estimativa inicial $\hat{A}_{1,sp}(0)$ e $b_{1,sp}(0)$




Figura 2.8: Segundo elemento do vetor erro de Identificação do Modelo de Primeiro Nível com estimativa inicial $\hat{A}_{1,sp}(0)$ e $b_{1,sp}(0)$

verificamos que, de fato, ambos os elementos do vetor erro de identificação para o Modelo de Primeiro Nível inicializado em $\hat{A}_{1,sp}(0)$ e $\hat{b}_{1,sp}(0)$ estão se aproximando de 0 com $t = 20$ segundos nas Figuras 2.7 e 2.8. As estimativas de Primeiro Nível inicializadas em $\hat{A}_{1,sp}(0)$ e $\hat{b}_{1,sp}(0)$ estão se aproximando dos valores corretos. As estimativas de Segundo Nível sem Fator de Esquecimento atingem os valores corretos em $t \approx 10$ segundos. As estimativas de Segundo Nível com Fator

de Esquecimento atingem os valores corretos em $t \approx 6$ segundos. Podemos ver o comportamento das estimativas nas Figuras 2.1 a 2.6. Vemos portanto que as estimativas de Primeiro Nível são mais lentas e mais oscilatórias que ambos os conjuntos de estimativas de Segundo Nível na sua convergência para os valores corretos. Com a introdução de um Fator de Esquecimento na Adaptação de Segundo Nível temos como resultado uma convergência mais rápida e mais suave dos parâmetros para seus valores corretos em relação a Adaptação de Segundo Nível sem Fator de Esquecimento. Quaisquer dos Modelos de Identificação sujeitos a um sinal PE são adequados para a tarefa de identificação dos parâmetros. No entanto, há claramente um resultado em particular que é melhor em relação a rapidez e suavidade de convergência dos parâmetros para seus valores corretos. Este resultado é obtido através do acúmulo de informações através de uma operação de integração que detalhamos anteriormente neste capítulo.

Caso SISO

Após estas simulações, consideramos que apenas a saída da planta $y_p = [1 \ 0] x_p$ e $u(t)$ estão disponíveis para medição. Desta forma estamos identificando a planta em termos de sua função de transferência:

$$G_p(s) = \frac{N_p(s)}{D_p(s)} = \frac{b_1 s + b_2}{s^2 + a_1 s + a_2} = \frac{2s + 0}{s^2 + 4s + 3}$$

desejamos então identificar os coeficientes dos polinômios do numerador e denominador da função de transferência da planta $N_p(s)$ e $D_p(s)$. A região de incerteza para estes parâmetros é considerada conhecida:

$$\begin{aligned} a_1 &\in [3 \ 8] \\ a_2 &\in [1 \ 6] \\ b_1 &\in [-1 \ 7] \\ b_2 &\in [-3 \ 3] \end{aligned}$$

faremos uso do Modelo de Identificação por Regressão Linear, da Adaptação de Segundo Nível usando o número mínimo de modelos $N = 5$ com e sem Fator de Esquecimento. Para inicializar as simulações, usamos os seguintes valores:

$$\begin{aligned}
\Lambda(s) &= s^2 + 6s + 9 \\
\Lambda_c &= \begin{bmatrix} -6 & -9 \\ 1 & 0 \end{bmatrix} \\
l &= \begin{bmatrix} 1 \\ 0 \end{bmatrix} \\
\Gamma &= \begin{bmatrix} 100 & 0 & 0 & 0 \\ 0 & 100 & 0 & 0 \\ 0 & 0 & 100 & 0 \\ 0 & 0 & 0 & 100 \end{bmatrix} \\
x_p(0) &= \begin{bmatrix} 0.2 \\ 0.4 \end{bmatrix} \\
\phi_1(0) &= \phi_2(0) = 0 \\
u(t) &= 1 + \sin(t) + \sin(1.7t) + \sin(3t) \\
\alpha_{1,f}(0) &= 1 \\
\alpha_i(0) &= 0, \quad i \neq 1 \\
\gamma_{n2,f} &= 10 \\
\sigma &= 0.2
\end{aligned}$$

e escolhemos as estimativas iniciais para o vetor θ_p :

$$\begin{aligned}
\hat{\theta}_{1,f}^T(0) &= [3 \quad 1 \quad -1 \quad -3] \\
\hat{\theta}_{2,f}^T(0) &= [28 \quad 1 \quad -1 \quad -3] \\
\hat{\theta}_{3,f}^T(0) &= [3 \quad 26 \quad -1 \quad -3] \\
\hat{\theta}_{4,f}^T(0) &= [3 \quad 1 \quad 39 \quad -3] \\
\hat{\theta}_{5,f}^T(0) &= [3 \quad 1 \quad -1 \quad 27]
\end{aligned}$$

e como na simulação anterior nós omitimos informações consideradas de pouca relevância. Obtivemos os seguintes resultados:




Figura 2.9: Comportamento das estimativas do coeficiente a_1 do polinômio $D_p(s)$ para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.




Figura 2.10: Comportamento das estimativas do coeficiente a_2 do polinômio $D_p(s)$ para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.




Figura 2.11: Comportamento das estimativas do coeficiente b_1 do polinômio $N_p(s)$ para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.




Figura 2.12: Comportamento das estimativas do coeficiente b_2 do polinômio $N_p(s)$ para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.




Figura 2.13: Erro de Identificação não normalizado do Modelo de Primeiro Nível com estimativa inicial $\hat{\theta}_{1,f}(0)$

como $\dot{\phi}$ é uniformemente limitado temos que o erro de identificação não normalizado deve tender a 0 quando o $t \rightarrow \infty$. Isto de fato se confirma e pode ser visualizado na Figura 2.13. As estimativas de Primeiro Nível inicializadas em $\hat{\theta}_{1,f}(0)$ estão se aproximando dos valores corretos. As estimativas de Segundo Nível sem Fator de Esquecimento atingem os valores corretos em $t \approx 15$ segundos. As estimativas de Segundo Nível com Fator de Esquecimento atingem os valores corretos em $t \approx 6$ segundos. Podemos ver o comportamento das estimativas nas Figuras 2.9 a 2.12. Vemos portanto que as estimativas de Primeiro Nível são mais lentas que ambos os conjuntos de estimativas de Segundo Nível na sua convergência para os valores corretos, como no caso anterior. No entanto devido a escolha de um valor alto de ganho para a Adaptação de Segundo Nível sem Fator de Esquecimento, vemos que 3 das estimativas exibem mudanças abruptas. Com a introdução de um Fator de Esquecimento na Adaptação de Segundo Nível temos como resultado uma convergência mais rápida e mais suave dos parâmetros para seus valores corretos em relação a Adaptação de Segundo Nível sem Fator de Esquecimento, como no caso anterior. O efeito das condições iniciais $x_p^T(0) = [0.2 \ 0.4]$ decai exponencialmente e não afeta a convergência dos parâmetros significativamente. Quaisquer dos Modelos de Identificação sujeitos a um sinal PE são adequados para a tarefa de identificação dos parâmetros. No entanto a Adaptação de Segundo Nível com Fator de Esquecimento, para os valores de parâmetros escolhidos, se mostra uma ferramenta de identificação mais efetiva em comparação com a Adaptação de Segundo Nível sem Fator de Esquecimento. Interpretamos esta melhora de resultado da seguinte forma: $E_f^T E_f$ é obrigatoriamente de posto 1 ou 0. M_f obtida através da integral de convolução não tem restrição quanto a seu

posto. Isto implica que M_f armazena informações mais precisas em relação aos coeficientes verdadeiros $\alpha_{i,f}^*$.

2.5 Conclusão

Neste capítulo apresentamos alguns Modelos de Identificação Convencionais que podem ser usados na identificação dos parâmetros em tempo real de uma Planta Linear Invariante no Tempo. Mostramos como estes Modelos podem servir como base para identificação através do conceito de Adaptação de Segundo Nível. Na Adaptação de Segundo Nível os coeficientes de uma combinação linear de múltiplos modelos são atualizados por uma lei integral e as estimativas são entregues por esta mesma combinação. O Modelo Série-Paralelo serve como base para o caso em que o vetor de estado da planta de grau n e as p entradas são acessíveis. O Modelo por Regressão Linear serve como base para o caso em que apenas a entrada e a saída da planta de grau n e grau relativo unitário estão disponíveis para medição. Disponibilizamos os algoritmos em forma compacta em um resumo para que o leitor possa testar o conceito por si mesmo em simulação. Neste capítulo tratamos apenas do problema da identificação dos parâmetros da planta, assumindo portanto que os sinais são limitados a priori. Desta forma escolhemos uma planta estável e um sinal de controle uniformemente limitado e PE.

Foram feitos estudos de simulação extensivos, nos quais avaliamos a Adaptação de Segundo Nível com e sem Fator de Esquecimento em relação ao Modelo Série-Paralelo para o caso MIMO e o Modelo por Regressão Linear para o caso SISO. Terminamos aqui nosso estudo da Adaptação de Segundo Nível como ferramenta de identificação de parâmetros. Tendo estudado as propriedades da Adaptação de Segundo Nível, passaremos a seguir no capítulo 3 ao problema do Controle. Desta forma, serão dispensadas as premissas de que a planta é estável e de que o sinal de controle é uniformemente limitado a priori. Assim, passaremos a nos ocupar de 2 tarefas simultâneas: A estimação dos parâmetros da planta e a escolha de uma lei de controle que faça uso destas estimativas. A lei de controle escolhida deve produzir um sinal de controle uniformemente limitado que faça com que o sinal ou sinais de saída da planta sejam uniformemente limitados e cumpram o objetivo de rastreamento de um Modelo de Referência escolhido pelo projetista.

Referências Bibliográficas

- [1] Z. Han and K. S. Narendra, “New concepts in adaptive control using multiple models,” *IEEE Transactions on Automatic Control*, vol. 57, pp. 78–89, Jan 2012.
- [2] K. S. Narendra, Y. Wang, and W. Chen, “The rationale for second level adaptation,” in *The 16th Yale Workshop on Adaptive and Learning Systems*, Yale University, 2012.
- [3] K. S. Narendra, Y. Wang, and W. Chen, “Stability, robustness, and performance issues in second level adaptation,” in *American Control Conference (ACC), 2014*, pp. 2377–2382, June 2014.
- [4] K. S. Narendra, Y. Wang, and W. Chen, “Extension of second level adaptation using multiple models to siso systems,” in *2015 American Control Conference (ACC)*, pp. 171–176, July 2015.
- [5] K. Narendra, “Chapter two - hierarchical adaptive control of rapidly time-varying systems using multiple models,” in *Control of Complex Systems* (K. G. Vamvoudakis and S. Jagannathan, eds.), pp. 33 – 66, Butterworth-Heinemann, 2016.
- [6] V. K. Pandey, I. Kar, and C. Mahanta, “Controller design for a 3-dof helicopter using multiple models with second level adaptation,” in *2017 Indian Control Conference (ICC)*, pp. 99–104, Jan 2017.
- [7] K. S. Narendra and A. M. Annaswamy, *Stable Adaptive Systems*. Prentice-Hall, 1989.
- [8] P. A. Ioannou and J. Sun, *Robust Adaptive Control*. Pearson Education, Inc., 1996.