

Nomenclatura

N	Número de Modelos de Identificação usados na Adaptação de Segundo Nível
n	Grau da Planta
$\vec{1}$	Vetor Linha de tamanho apropriado (determinado pelo contexto da equação em que está sendo aplicado) cujos elementos são todos 1
$\mathbf{0}$	Matriz de tamanho apropriado (determinado pelo contexto da equação em que está sendo aplicada) cujos elementos são todos 0
s	Variável complexa no domínio da frequência
u	Sinal de entrada da planta
$G_p(s)$	Função de Transferência da planta de ordem n e grau relativo 1
$\Sigma_{p,SISO}$	Planta SISO de ordem n e grau relativo 1
$N_p(s)$	Polinômio do Numerador da Função de Transferência $G_p(s)$
b_i	Coeficientes do polinômio do numerador da planta SISO de ordem n e grau relativo 1, com $i = 1, \dots, n$, associados às variáveis complexas s^{n-i} do polinômio
b_i^+	Limitante superior da região de incerteza para os coeficientes b_i da planta SISO de ordem n e grau relativo 1, com $i = 1, \dots, n$
b_i^-	Limitante inferior da região de incerteza para o coeficiente b_i da planta SISO de ordem n e grau relativo 1, com $i = 1, \dots, n$
$D_p(s)$	Polinômio do Denominador da Função de Transferência $G_p(s)$
a_i	Coeficientes do polinômio mônico do denominador da planta SISO de ordem n e grau relativo 1, com $i = 1, \dots, n$, associados às variáveis complexas s^{n-i} do polinômio

a_i^+	Limitante superior da região de incerteza para os coeficientes a_i da planta SISO de ordem n e grau relativo 1, com $i = 1, \dots, n$
a_i^-	Limitante inferior da região de incerteza para os coeficientes a_i da planta SISO de ordem n e grau relativo 1, com $i = 1, \dots, n$
y_p	Sinal de Saída da planta de ordem n e grau relativo 1
$\Lambda(s)$	Polinômio mônico, de Grau n com raízes negativas
z	Sinal de Saída planta de ordem n e grau relativo 1 filtrado por uma função de transferência $\frac{s^n}{\Lambda(s)}$
ϕ_1	Vetor gerado a partir de filtragens do sinal y por funções de transferência próprias $\frac{s^i}{\Lambda(s)}$, com $i = n - 1, \dots, 1$, usado para construir o vetor regressor ϕ
ϕ_2	Vetor gerado a partir de filtragens do sinal u por funções de transferência próprias $\frac{s^i}{\Lambda(s)}$, com $i = n - 1, \dots, 1$, usado para construir o vetor regressor ϕ
ϕ	Vetor Coluna formado pelos elementos de $-\phi_1$ e ϕ_2 , e chamado vetor regressor
$\Sigma_{1,f}$	Modelo de identificação por Regressão Linear 1 planta SISO de ordem n e grau relativo 1
$\Sigma_{i,f}$	i -ésimo Modelo de identificação por Regressão Linear planta SISO de ordem n e grau relativo 1, com $i = 1, \dots, N$
$\hat{z}_{1,f}$	Estimativa do Sinal Filtrado de Saída da Planta de Ordem n e grau relativo 1 usando o Modelo de Identificação por Regressão Linear 1
$\hat{z}_{i,f}$	Estimativa do Sinal Filtrado de Saída da Planta de Ordem n e grau relativo 1 usando o i -ésimo Modelo de Identificação por Regressão Linear, com $i = 1, \dots, N$
$e_{1,f}$	Erro de identificação gerado pela diferença entre o sinal de saída filtrado do Modelo de identificação por Regressão Linear da Planta 1 e o Sinal de Saída da Planta de ordem n e grau relativo 1 Filtrado
$\varepsilon_{1,f}$	Erro de identificação $e_{1,f}$ normalizado
$e_{i,f}$	Erro de identificação gerado pela diferença entre o sinal de saída do i -ésimo Modelo de identificação por Regressão Linear, com $i = 1, \dots, N$, e o Sinal de Saída da Planta de ordem n e grau relativo 1 Filtrado

$\varepsilon_{i,f}$	Erro de identificação $e_{i,f}$ normalizado
$e_{N,f}$	Erro de identificação gerado pela diferença entre o sinal de saída do Modelo de identificação por Regressão Linear N e o Sinal de Saída da Planta de ordem n e grau relativo 1 Filtrado
$\varepsilon_{N,f}$	Erro de identificação $e_{N,f}$ normalizado
$\bar{E}_f$	Vetor linha formado pelos Erros de identificação $\varepsilon_{i,f}$, com $i = 1, \dots, N$, em suas colunas
E_f	Vetor linha formado pela diferença entre os Erros de identificação $\varepsilon_{i,f}$, com $i = 1, \dots, N - 1$, e o erro $\varepsilon_{N,f}$ em suas colunas
$\hat{\theta}_{1,f}$	Estimativa do vetor de parâmetros θ_p^* da planta de ordem n e grau relativo 1 usando o Modelo de Identificação por Regressão Linear da Planta 1
$\hat{\theta}_{i,f}$	Estimativa do vetor de parâmetros θ_p^* da planta de ordem n e grau relativo 1 usando o i-ésimo Modelo de Identificação por Regressão Linear da Planta, com $i = 1, \dots, N$
$\tilde{\theta}_{1,f}$	Erro paramétrico devido a diferença entre a estimativa $\hat{\theta}_{1,f}$ e o valor correto θ_p^*
$\tilde{\theta}_{i,f}$	Erro paramétrico devido a diferença entre a estimativa $\hat{\theta}_{i,f}$ e o valor correto θ_p^*
$\hat{\hat{\theta}}_{1,f}$	Lei Adaptativa para Atualização da Estimativa $\hat{\theta}_{1,f}$
$\hat{\hat{\theta}}_{i,f}$	Lei Adaptativa para Atualização da Estimativa $\hat{\theta}_{i,f}$, com $i = 1, \dots, N$
$\alpha_{i,f}^*$	Coeficientes da combinação convexa que quando aplicados às estimativas $\hat{\theta}_{i,f}$, com $i = 1, \dots, N$, formam θ_p^*
$\alpha_{i,f}$	Coeficientes da combinação convexa que são aplicados às estimativas $\hat{\theta}_{i,f}$, com $i = 1, \dots, N$, para formar uma estimativa de segundo nível do vetor de parâmetros θ_p^*
α_f^*	Vetor Coluna formado pelos Coeficientes $\alpha_{i,f}^*$ em suas linhas, com $i = 1, \dots, N - 1$
$\bar{\alpha}_f^*$	Vetor Coluna formado pelos Coeficientes $\alpha_{i,f}^*$ em suas linhas, com $i = 1, \dots, N$

α_f	Vetor Coluna formado pelos Coeficientes $\alpha_{i,f}$ em suas linhas, com $i = 1, \dots, N-1$
$\bar{\alpha}_f$	Vetor Coluna formado pelos Coeficientes $\alpha_{i,f}$ em suas linhas, com $i = 1, \dots, N$
$\dot{\alpha}_f$	Lei Adaptativa para Atualização do Vetor α_f
$\bar{\Theta}_f$	Matriz formada pelos coeficientes $\hat{\theta}_{i,f}$ em suas colunas, com $i = 1, \dots, N$
$\hat{\theta}_{n2,f}$	Estimativa de Segundo Nível do parâmetro θ_p^* da planta SISO usando como base Modelos de Identificação por Regressão Linear

Capítulo 3

Controle Adaptativo Indireto

Finalmente, passamos a tratar do problema do controle de uma planta linear invariante no tempo. Fazemos um breve resumo dos resultados que obtivemos no capítulo anterior para o caso SISO com o Modelo de Identificação por Regressão Linear e a Adaptação de Segundo Nível baseada em múltiplos Modelos de Identificação por Regressão Linear. Após este resumo, detalhamos como são calculados os parâmetros do controlador a partir das estimativas dos parâmetros da planta. Provamos que a Adaptação de Segundo Nível possui as mesmas propriedades que o Método do Gradiente quando utilizada no Controle por Modelo de Referência Indireto para a planta de grau n e grau relativo 1 quando o Modelo de Referência escolhido tem grau n e grau relativo 1.

3.1 Planta de Ordem n e Grau Relativo Unitário

3.1.1 Controle Adaptativo por Modelo de Referência Indireto

Estimador por Método do Gradiente

Seja a planta linear invariante no tempo descrita pela seguinte função de transferência:

$$\Sigma_{p,SISO} : G_p(s) = \frac{y(s)}{u(s)} = \frac{N_p(s)}{D_p(s)}$$

em que:

$$\begin{aligned} N_p(s) &= b_1 s^{n-1} + b_2 s^{n-2} + \dots + b_{n-1} s + b_n \\ D_p(s) &= s^n + a_1 s^{n-1} + a_2 s^{n-2} + \dots + a_{n-1} s + a_n \end{aligned} \quad (3.1)$$

em que os limitantes superiores $b_1^+, \dots, b_n^+, a_1^+, a_n^+$ e inferiores $b_1^-, \dots, b_n^-, a_1^-, \dots, a_n^-$ dos coeficientes $b_1, \dots, b_n, a_1, \dots, a_n$ são conhecidos. Desta forma as combinações

de limitantes $b_1^+, \dots, b_n^+, a_1^+, a_n^+$ e $b_1^-, \dots, b_n^-, a_1^-, a_n^-$ representam vértices de um politopo convexo que delimita a região de incerteza $S_{\theta,f} \in R^{2n}$ dos coeficientes $b_1, \dots, b_n, a_1, \dots, a_n$. A região de incerteza $S_{\theta,f}$ é conhecida. Definimos anteriormente, no capítulo 2:

$$\begin{aligned} z(s) &\triangleq \frac{s^n}{\Lambda(s)} y(s) \\ \phi(s) &\triangleq \left[\frac{-s^{n-1}y(s)}{\Lambda(s)} \quad \dots \quad \frac{-y(s)}{\Lambda(s)} \quad \frac{s^{n-1}u(s)}{\Lambda(s)} \quad \dots \quad \frac{u(s)}{\Lambda(s)} \right]^T \\ \theta_p^* &\triangleq [a_1 \quad \dots \quad a_n \quad b_1 \quad \dots \quad b_n]^T \end{aligned} \quad (3.2)$$

e temos a seguinte parametrização para a planta:

$$z(s) = \theta_p^{*T} \phi \quad (3.3)$$

e o vetor regressor ϕ pode ser gerado através de filtros de $y(t)$ e $u(t)$:

$$\begin{aligned} \dot{\phi}_1 &= \Lambda_c \phi_1 + l y \\ \dot{\phi}_2 &= \Lambda_c \phi_2 + l u \\ \phi &= [-\phi_1 \quad \phi_2]^T \end{aligned} \quad (3.4)$$

e uma estimativa da saída z é gerada pelo modelo de identificação:

$$\Sigma_{1,f} : \hat{z}_{1,f} = \hat{\theta}_{1,f}^T \phi \quad (3.5)$$

e geramos o erro de identificação:

$$e_{1,f} \triangleq \hat{z}_{1,f} - z \quad (3.6)$$

então o erro de identificação normalizado pode ser construído:

$$\epsilon_{1,f} = \frac{e_{1,f}}{m^2} \quad (3.7)$$

onde $m^2 = 1 + n_s^2$ e n_s é chamado de sinal normalizador, escolhido tal que $\frac{\phi}{m} \in \mathcal{L}_\infty$

$$\dot{\hat{\theta}}_{1,f} = -\Gamma \epsilon_{1,f} \phi \quad (3.8)$$

IMRAC com Método do Gradiente

assumindo que os polinômios $N_p(s)$ e $D_p(s)$ são coprimos, queremos fazer uso das estimativas obtidas para encontrar um sinal $u(t)$ que faça com que a saída da planta rastreie a saída de um Modelo de Referência:

$$\Sigma_m : W_m(s) = \frac{y_m(s)}{r(s)} = k_m \frac{N_m(s)}{D_m(s)}$$

alimentado com uma referência $r(t)$ escolhida pelo projetista em que:

$$\begin{aligned} N_m(s) &= s^{n-1} + b_{m,2}s^{n-2} + \dots + b_{m,n-1}s + b_{m,n} \\ D_m(s) &= s^n + a_{m,1}s^{n-1} + a_{m,2}s^{n-2} + \dots + a_{m,n-1}s + a_{m,n} \end{aligned} \quad (3.9)$$

e $N_m(s)$ e $D_m(s)$ são também escolhidos pelo projetista. De acordo com [Ioannou e Sun, 1996] a seguinte lei de controle é adequada para esta tarefa:

$$u = \theta_1^T \frac{\Psi(s)}{\Lambda_w(s)} u + \theta_2^T \frac{\Psi(s)}{\Lambda_w(s)} y + \theta_3 y + c_0 r = \theta^T w \quad (3.10)$$

onde $w = \left[\frac{\Psi^T(s)}{\Lambda_w(s)} u \quad \frac{\Psi^T(s)}{\Lambda_w(s)} y \quad y \quad r \right]^T$, $\Psi(s)^T = [s^{n-2} \quad s^{n-3} \quad \dots \quad s \quad 1]$ e $\theta = [\theta_1^T \quad \theta_2^T \quad \theta_3 \quad c_0]$.

Note-se que mudamos um pouco a notação, por exemplo usando $\Psi(s)$ ao invés de $\alpha(s)$ para evitar ambiguidade com os coeficientes da combinação convexa da adaptação de segundo nível. O vetor regressor de controle w pode ser gerado por:

$$\begin{aligned} \dot{w}_1 &= F w_1 + g u \\ \dot{w}_2 &= F w_2 + g y \\ w &= [w_1 \quad w_2 \quad y \quad r]^T \end{aligned} \quad (3.11)$$

onde F e g são escolhidos de acordo com $\Lambda_w(s)$. Colocamos o polinômio $N_p(s)$ da planta na seguinte forma:

$$N_p(s) = k_p(s^{n-1} + \frac{b_2}{k_p}s^{n-2} + \dots + \frac{b_{n-1}}{k_p}s + \frac{b_n}{k_p}) = k_p Z_p(s) \quad (3.12)$$

onde $k_p = b_1$ e o vetor de parâmetros θ do controlador pode ser calculado através de um mapeamento $\theta(t) = f(\theta_p(t))$. Este mapeamento é obtido usando as equações de "matching". No caso da planta de grau relativo unitário com modelo de referência de mesmo grau e grau relativo, caso os parâmetros da planta fossem conhecidos teríamos:

$$\begin{aligned} c_0^* &= \frac{k_m}{k_p} \\ \theta_1^{*T} \Psi(s) &= \Lambda_w(s) - Z_p(s) \\ \theta_2^{*T} \Psi(s) + \theta_3^* \Lambda_w(s) &= \frac{D_p(s) - \Lambda_0(s) D_m(s)}{k_p} \end{aligned} \quad (3.13)$$

onde $\Lambda_w(s) = \Lambda_0(s)N_m(s)$ é escolhido pelo projetista. Como estivemos estimando os coeficientes de $D_p(s)$ e $N_p(s)$ temos então estimativas $\hat{D}_p(s)$ e $\hat{N}_p(s)$ que podemos usar no cálculo dos parâmetros do controlador. Usando estas estimativas podemos resolver a equação polinomial acima para cada instante de tempo t para obter os parâmetros do controlador:

$$\begin{aligned} c_0 &= \frac{k_m}{\hat{k}_p} \\ \theta_1^T \psi(s) &= \Lambda_w(s) - \frac{1}{\hat{k}_p} \hat{N}_p(s) \\ \theta_2^T \psi(s) + \theta_3 \Lambda_w(s) &= \frac{\hat{D}_p(s) - \Lambda_0(s)D_m(s)}{\hat{k}_p} \end{aligned} \quad (3.14)$$

desde que $\hat{k}_p \neq 0$. E os polinômios $\hat{D}_p(s)$ e $\hat{N}_p(s)$ são obtidos substituindo as estimativas dos coeficientes de $D_p(s)$ e $N_p(s)$:

$$\begin{aligned} \hat{k}_p &= \hat{b}_1 \\ \hat{D}_p(s) &= s^n + \hat{a}_1 s^{n-1} + \hat{a}_2 s^{n-2} + \dots + \hat{a}_n \\ \hat{N}_p(s) &= \hat{b}_1 s^{n-1} + \hat{b}_2 s^{n-2} + \dots + \hat{b}_n \end{aligned} \quad (3.15)$$

e a estimativa $\hat{k}_p = \hat{b}_1$ deve ser restringida de atingir um valor nulo por projeção. Este esquema adaptativo garante, segundo [Ioannou e Sun, 1996, pp. 424-428], que todos os sinais envolvidos no sistema são uniformemente limitados e que o erro de saída $e_1 = y - y_m$ converge para 0 a medida que $t \rightarrow \infty$. Esta afirmação é verdadeira se a estimativa $\theta_p \in \mathcal{L}_\infty$, $\frac{1}{\hat{k}_p} \in \mathcal{L}_\infty$ e sua derivada $\dot{\theta}_p \in \mathcal{L}_2$, o que se verifica para o Método do Gradiente.

Estimador por Adaptação de Segundo Nível

Novamente, seja a planta:

$$\Sigma_{p,SISO} : G_p(s) = \frac{y(s)}{u(s)} = \frac{N_p(s)}{D_p(s)}$$

em que:

$$\begin{aligned} N_p(s) &= b_1 s^{n-1} + b_2 s^{n-2} + \dots + b_{n-1} s + b_n \\ D_p(s) &= s^n + a_1 s^{n-1} + a_2 s^{n-2} + \dots + a_{n-1} s + a_n \end{aligned} \quad (3.16)$$

em que os limitantes superiores $b_1^+, \dots, b_n^+, a_1^+, a_n^+$ e inferiores $b_1^-, \dots, b_n^-, a_1^-, a_n^-$ dos coeficientes $b_1, \dots, b_n, a_1, \dots, a_n$ são conhecidos. Desta forma as combinações de limitantes $b_1^+, \dots, b_n^+, a_1^+, a_n^+$ e $b_1^-, \dots, b_n^-, a_1^-, a_n^-$ representam vértices de um

politopo convexo que delimita a região de incerteza $S_{\theta,f} \in R^{2n}$ dos coeficientes $b_1, \dots, b_n, a_1, \dots, a_n$. A região de incerteza $S_{\theta,f}$ é conhecida. E como definimos anteriormente:

$$\begin{aligned} z(s) &\triangleq \frac{s^n}{\Lambda(s)} y(s) \\ \phi(s) &\triangleq \left[\frac{-s^{n-1}y(s)}{\Lambda(s)} \quad \dots \quad \frac{-y(s)}{\Lambda(s)} \quad \frac{s^{n-1}u(s)}{\Lambda(s)} \quad \dots \quad \frac{u(s)}{\Lambda(s)} \right]^T \\ \theta_p^* &\triangleq [a_1 \quad \dots \quad a_n \quad b_1 \quad \dots \quad b_n]^T \end{aligned}$$

e o vetor regressor ϕ é gerado pela seguinte equação:

$$\begin{aligned} \dot{\phi}_1 &= \Lambda_c \phi_1 + l y \\ \dot{\phi}_2 &= \Lambda_c \phi_2 + l u \\ \phi &= [-\phi_1 \quad \phi_2]^T \end{aligned} \tag{3.17}$$

e temos a seguinte parametrização:

$$z(s) = \theta_p^{*T} \phi$$

e os $i = 1, \dots, N$ modelos de identificação deste sinal:

$$\Sigma_{i,f} : \hat{z}_{i,f} = \hat{\theta}_{i,f}^T \phi \tag{3.18}$$

e os $i = 1, \dots, N$ erros paramétricos:

$$\tilde{\theta}_{i,f} = \hat{\theta}_{i,f} - \theta_p^* \tag{3.19}$$

definimos os $i = 1, \dots, N$ erros de identificação deste sinal:

$$e_{i,f} \triangleq \hat{z}_{i,f} - z \tag{3.20}$$

os erros de identificação normalizados são da forma:

$$\epsilon_{i,f} = \frac{e_{i,f}}{m^2} \tag{3.21}$$

e os vetores de parâmetros $\hat{\theta}_{i,f}$, $i = 1, \dots, N$, são adaptados de acordo com o método do gradiente:

$$\dot{\hat{\theta}}_{i,f} = -\Gamma \epsilon_{i,f} \phi \tag{3.22}$$

e uma estimativa α_f pode ser atualizada por:

$$\dot{\alpha}_f = -\gamma_{n2,f} E_f^T E_f \alpha_f - \gamma_{n2,f} E_f^T \epsilon_{N,f} \tag{3.23}$$

onde $\gamma_{n2,f} > 0$ e a estimativa $\bar{\alpha}_f$ fica da forma:

$$\bar{\alpha}_f^T = \begin{bmatrix} \alpha_f^T & 1 - \vec{1}\alpha_f \end{bmatrix} \quad (3.24)$$

onde $\vec{1}$ é o vetor linha $[1 \ 1 \ \dots \ 1]$ de tamanho apropriado. Assim pode-se gerar uma estimativa de segundo nível dos parâmetros da planta através dos coeficientes $\alpha_{i,f}$, que são os componentes do vetor $\bar{\alpha}_f$:

$$\hat{\theta}_{n2,f} = \text{proj}_{S_{\theta,f}}(\alpha_{1,f}\hat{\theta}_{1,f} + \alpha_{2,f}\hat{\theta}_{2,f} + \dots + \alpha_{N,f}\hat{\theta}_{N,f}) \quad (3.25)$$

em que $\text{proj}_{S_{\theta,f}}(\cdot)$ é o operador de projeção retangular dentro da região de incerteza $S_{\theta,f}$.

3.1.2 IMRAC com Adaptação de Segundo Nível

assumindo que os polinômios $N_p(s)$ e $D_p(s)$ são coprimos, queremos fazer uso das estimativas obtidas para encontrar um sinal $u(t)$ que faça com que a saída da planta rastreie a saída de um Modelo de Referência:

$$\Sigma_m : W_m(s) = \frac{y_m(s)}{r(s)} = k_m \frac{N_m(s)}{D_m(s)}$$

alimentado com uma referência $r(t)$ escolhida pelo projetista em que:

$$\begin{aligned} N_m(s) &= s^{n-1} + b_{m,2}s^{n-2} + \dots + b_{m,n-1}s + b_{m,n} \\ D_m(s) &= s^n + a_{m,1}s^{n-1} + a_{m,2}s^{n-2} + \dots + a_{m,n-1}s + a_{m,n} \end{aligned} \quad (3.26)$$

e $N_m(s)$ e $D_m(s)$ são também escolhidos pelo projetista. De acordo com [Ioannou e Sun, 1996] a seguinte lei de controle é adequada para esta tarefa:

$$u = \theta_1^T \frac{\Psi(s)}{\Lambda_w(s)} u + \theta_2^T \frac{\Psi(s)}{\Lambda_w(s)} y + \theta_3 y + c_0 r = \theta^T w \quad (3.27)$$

onde $w = \left[\frac{\Psi^T(s)}{\Lambda_w(s)} u \ \frac{\Psi^T(s)}{\Lambda_w(s)} y \ y \ r \right]^T$, $\Psi(s)^T = [s^{n-2} \ s^{n-3} \ \dots \ s \ 1]$ e $\theta = [\theta_1^T \ \theta_2^T \ \theta_3 \ c_0]$.

Note-se que mudamos um pouco a notação, por exemplo usando $\Psi(s)$ ao invés de $\alpha(s)$ para evitar ambiguidade com os coeficientes da combinação convexa da adaptação de segundo nível. O vetor regressor de controle w pode ser gerado por:

$$\begin{aligned} \dot{w}_1 &= F w_1 + g u \\ \dot{w}_2 &= F w_2 + g y \\ w &= [w_1 \ w_2 \ y \ r]^T \end{aligned} \quad (3.28)$$

onde F e g são escolhidos de acordo com $\Lambda_w(s)$. Colocamos o polinômio $N_p(s)$ da planta na seguinte forma:

$$N_p(s) = k_p(s^{n-1} + \frac{b_2}{k_p}s^{n-2} + \dots + \frac{b_{n-1}}{k_p}s + \frac{b_n}{k_p}) = k_p Z_p(s) \quad (3.29)$$

onde $k_p = b_1$ e o vetor de parâmetros θ do controlador pode ser calculado através de um mapeamento $\theta(t) = f(\theta_p(t))$. Este mapeamento é obtido usando as equações de "matching". No caso da planta de grau relativo unitário com modelo de referência de mesmo grau e grau relativo, caso os parâmetros da planta fossem conhecidos teríamos:

$$\begin{aligned} c_0^* &= \frac{k_m}{k_p} \\ \theta_1^{*T} \psi(s) &= \Lambda_w(s) - Z_p(s) \\ \theta_2^{*T} \psi(s) + \theta_3^* \Lambda_w(s) &= \frac{D_p(s) - \Lambda_0(s)D_m(s)}{k_p} \end{aligned} \quad (3.30)$$

onde $\Lambda_w(s) = \Lambda_0(s)N_m(s)$ é escolhido pelo projetista. Como estivemos estimando os coeficientes de $D_p(s)$ e $N_p(s)$ temos então estimativas $\hat{D}_p(s)$ e $\hat{N}_p(s)$ que podemos usar no cálculo dos parâmetros do controlador. Usando estas estimativas podemos resolver a equação polinomial acima para cada instante de tempo t para obter os parâmetros do controlador:

$$\begin{aligned} c_0 &= \frac{k_m}{\hat{k}_p} \\ \theta_1^T \psi(s) &= \Lambda_w(s) - \frac{1}{\hat{k}_p} \hat{N}_p(s) \\ \theta_2^T \psi(s) + \theta_3 \Lambda_w(s) &= \frac{\hat{D}_p(s) - \Lambda_0(s)D_m(s)}{\hat{k}_p} \end{aligned} \quad (3.31)$$

desde que $\hat{k}_p \neq 0$. E os polinômios $\hat{D}_p(s)$ e $\hat{N}_p(s)$ são obtidos substituindo as estimativas dos coeficientes de $D_p(s)$ e $N_p(s)$:

$$\begin{aligned} \hat{k}_p &= \hat{b}_1 \\ \hat{D}_p(s) &= s^n + \hat{a}_1 s^{n-1} + \hat{a}_2 s^{n-2} + \dots + \hat{a}_n \\ \hat{N}_p(s) &= \hat{b}_1 s^{n-1} + \hat{b}_2 s^{n-2} + \dots + \hat{b}_n \end{aligned} \quad (3.32)$$

e a estimativa $\hat{k}_p = \hat{b}_1$ deve ser restringida de atingir ou se aproximar de um valor nulo por projeção. Este esquema adaptativo garante, segundo [Ioannou e Sun, 1996, pp. 424-428], que todos os sinais envolvidos no sistema são uniformemente limitados e que o erro de saída $e_1 = y - y_m$ converge para 0 a medida que $t \rightarrow \infty$.

Esta afirmação é verdadeira se a estimativa $\theta_p \in \mathcal{L}_\infty$, $\frac{1}{\hat{k}_p} \in \mathcal{L}_\infty$ e sua derivada $\dot{\theta}_p \in \mathcal{L}_2$. Portanto devemos analisar a existência destas normas de θ_p para a adaptação de segundo nível:

$$\hat{\theta}_{n2,f} = \alpha_{1,f}\hat{\theta}_{1,f} + \alpha_{2,f}\hat{\theta}_{2,f} + \dots + \alpha_{N,f}\hat{\theta}_{N,f}$$

omitimos o operador de projeção. Como determinamos anteriormente que $\alpha_{i,f} \in \mathcal{L}_\infty$, $i = 1, \dots, N$ e $\theta_{i,f} \in \mathcal{L}_\infty$, $i = 1, \dots, N$ claramente $\hat{\theta}_{n2,f} = \hat{\theta}_p \in \mathcal{L}_\infty$. Assumimos que a região de incerteza e que o sinal de $\hat{k}_p = \hat{b}_1$ são conhecidos, portanto a condição de que $\frac{1}{\hat{k}_p} \in \mathcal{L}_\infty$ pode ser incorporada na projeção retangular. Finalmente, temos que:

$$\dot{\theta}_{n2,f} = \sum_{i=1}^N \dot{\theta}_{i,f} \alpha_{i,f} + \sum_{i=1}^N \theta_{i,f} \dot{\alpha}_{i,f} \quad (3.33)$$

e temos que $\dot{\theta}_{i,f} = -\Gamma \epsilon_{i,f} \phi$ pertence ao $\mathcal{L}_2$ pois $\frac{\phi}{m} \in \mathcal{L}_\infty$ e $\epsilon_{i,f} m \in \mathcal{L}_2 \cap \mathcal{L}_\infty$ implicam que existe um limite superior para a norma $|\dot{\theta}_{i,f}|_2$:

$$\left(\int_0^\infty |\dot{\theta}_{i,f}(\tau)|^2 d\tau \right)^{\frac{1}{2}} \leq \sup\left(\frac{\phi}{m}\right) \|\Gamma\| \|\epsilon_{i,f} m\|_2 \quad (3.34)$$

e como $\dot{\theta}_{i,f} \in \mathcal{L}_2 \cap \mathcal{L}_\infty$ e $\alpha_{i,f} \in \mathcal{L}_\infty$, pelo mesmo raciocínio temos que:

$$\left| \sum_{i=1}^N \dot{\theta}_{i,f} \alpha_{i,f} \right|_2 \leq \sum_{i=1}^N \sup(\alpha_{i,f}) |\dot{\theta}_{i,f}|_2 \quad (3.35)$$

portanto $\sum_{i=1}^N \dot{\theta}_{i,f} \alpha_{i,f} \in \mathcal{L}_2 \cap \mathcal{L}_\infty$. Como $\dot{\alpha}_f$ é da forma:

$$\dot{\alpha}_f = -E_f^T E_f \alpha_f - E_f^T \epsilon_{N,f} \quad (3.36)$$

e como as colunas de E_f pertencem ao $\mathcal{L}_2$ e os coeficientes $\alpha_{i,f}$ são limitados podemos escrever:

$$|\dot{\alpha}_f|_2 \leq \sup(\|E_f\|) \left[\sum_{i=1}^{N-1} \|\epsilon_{i,f} - \epsilon_{N,f}\|_2 \sup(\alpha_{i,f}) + \|\epsilon_{N,f}\|_2 \right] \quad (3.37)$$

portanto $\dot{\alpha}_f \in \mathcal{L}_2 \cap \mathcal{L}_\infty$, que implica em $\alpha_{i,f} \in \mathcal{L}_2 \cap \mathcal{L}_\infty$, $i = 1, \dots, N$, e como $\theta_{i,f} \in \mathcal{L}_\infty$ temos que $\sum_{i=1}^N \theta_{i,f} \dot{\alpha}_{i,f} \in \mathcal{L}_2 \cap \mathcal{L}_\infty$. Portanto $\dot{\theta}_{n2,f} = \dot{\theta}_p \in \mathcal{L}_2 \cap \mathcal{L}_\infty$ e as

mesmas condições para a norma de $\hat{\theta}_p$ e sua derivada que são verdadeiras para o Método do Gradiente também o são para a Adaptação de Segundo Nível. O IMRAC fazendo uso da adaptação de segundo nível mantém as mesmas propriedades de estabilidade e convergência do erro de saída que o IMRAC fazendo uso do método do gradiente para estimar os parâmetros da planta.

3.2 Resumo dos Algoritmos e Estudos de Simulação

Neste capítulo apresentamos a lei de controle usada para que a planta rastreie um Modelo de Referência. É gerado um vetor regressor de controle w a partir de filtros da entrada e saída da planta. Uma combinação linear dos componentes deste regressor com os parâmetros do controlador gera o sinal de controle a ser introduzido na planta. Os parâmetros do controlador são calculados a partir dos parâmetros estimados da planta por um mapeamento baseado em equações de matching, como se os parâmetros da planta fossem conhecidos. Mostramos que as estimativas de segundo nível têm as mesmas propriedades de norma $\mathcal{L}_p$ das estimativas produzidas pelo Método do Gradiente. Desta forma, a mesma prova matemática de que o Método do Gradiente é adequado como estimador de parâmetros no Controle Adaptativo Indireto por Modelo de Referência [Ioannou e Sun, 1996, pp. 424-428] pode ser utilizada para provar o mesmo quanto a Adaptação de Segundo Nível. Assim, tanto para a Adaptação de Segundo Nível quanto para o Método do Gradiente o erro de saída tende a 0 e a planta segue o modelo de referência. As estimativas dos parâmetros da planta tendem aos valores corretos na presença de um sinal de entrada com a característica de persistência de excitação. Na ausência de um sinal PE apenas o erro de saída tende a 0 e o sinal de controle tende a u^* .

3.2.1 Resumo dos Algoritmos

Caso o leitor deseje consultar rapidamente, listamos os algoritmos usados neste capítulo para o Controle Adaptativo por Modelo de Referência Indireto de uma planta de grau n e grau relativo 1 e modelo de referência de grau n e grau relativo 1:

Caso Ideal, Planta Conhecida	Regressão Linear
$\Sigma_p : \dot{x}_p = A_p x_p + b_p u$	$\Sigma_p : \dot{x}_p = A_p x_p + b_p u$
$y_p = h_p^T x_p$	$y_p = h_p^T x_p$
$\dot{x}_m = A_m x_m + b_m r$	$z = \frac{s^n y}{\Lambda(s)}$
$y_m = h_m^T x_m$	$\dot{\phi}_1 = \Lambda_c \phi_1 + l y_p$
$c_0 = \frac{k_m}{\hat{k}_p}$	$\dot{\phi}_2 = \Lambda_c \phi_2 + l u$
$\theta_1^T \psi(s) = \Lambda_w(s) - \frac{1}{k_p} N_p(s)$	$\phi^T = [\phi_1 \quad \phi_2]$
$\theta_2^T \psi(s) + \theta_3 \Lambda_w(s) = \frac{D_p(s) - \Lambda_0(s) D_m(s)}{k_p}$	$\Sigma_{1,f} : \hat{z}_{1,f} = \hat{\theta}_{1,f} \phi$
$\theta = [\theta_1 \quad \theta_2 \quad \theta_3 \quad c_0]^T$	$e_{1,f} = \hat{z}_{1,f} - z$
$\dot{w}_1 = F w_1 + g u$	$n_s^2 = \phi^T \phi$
$\dot{w}_2 = F w_2 + g y$	$Q = Q^T > 0$
$w = [w_1 \quad w_2 \quad y \quad r]^T$	$m^2 = 1 + n_s^2$
$u = \theta^T w$	$\varepsilon_{1,f} = \frac{e_{1,f}}{m^2}$
	$\Gamma = \Gamma^T > 0$
	$\dot{\hat{\theta}}_{1,f} = -\Gamma \varepsilon_{1,f} \phi$
	$\dot{x}_m = A_m x_m + b_m r$
	$y_m = h_m^T x_m$
	$c_0 = \frac{k_m}{\hat{k}_p}$
	$\theta_1^T \psi(s) = \Lambda_w(s) - \frac{1}{\hat{k}_p} \hat{N}_p(s)$
	$\theta_2^T \psi(s) + \theta_3 \Lambda_w(s) = \frac{\hat{D}_p(s) - \Lambda_0(s) D_m(s)}{\hat{k}_p}$
	$\theta = [\theta_1 \quad \theta_2 \quad \theta_3 \quad c_0]^T$
	$\dot{w}_1 = F w_1 + g u$
	$\dot{w}_2 = F w_2 + g y$
	$w = [w_1 \quad w_2 \quad y \quad r]^T$
	$u = \theta^T w$

Segundo Nível Regressão Linear	Segundo Nível Regressão Linear Modificado
$\Sigma_p : \dot{x}_p = A_p x_p + b_p u$ $y_p = h_p^T x_p$ $z = \frac{s^n y}{\Lambda(s)}$ $\dot{\phi}_1 = \Lambda_c \phi_1 + l y_p$ $\dot{\phi}_2 = \Lambda_c \phi_2 + l u$ $\phi^T = [-\phi_1 \quad \phi_2]$ $\Sigma_{i,f} : \hat{z}_{i,f} = \hat{\theta}_{i,f} \phi$ $e_{i,f} = \hat{z}_{i,f} - z$ $n_s^2 = \phi^T \phi$ $Q = Q^T > 0$ $m^2 = 1 + n_s^2$ $\epsilon_{i,f} = \frac{e_{i,f}}{m^2}$ $\Gamma = \Gamma^T > 0$ $\dot{\hat{\theta}}_{i,f} = -\Gamma \epsilon_{i,f} \phi$ $E_f = [e_{1,f} - e_{N,f} \quad \dots \quad e_{N-1,f} - e_{N,f}]$ $M_f(0) = \mathbf{0}$ $v_f(0) = \mathbf{0}$ $\dot{M}_f = -\sigma M_f + E_f^T E_f$ $\dot{v}_f = -\sigma v_f + E_f^T e_{N,f}$ $\dot{\alpha}_f = -(E_f^T E_f + M_f) \alpha_f - E_f^T e_{N,f} - v_f$ $\bar{\Theta}_f = [\hat{\theta}_{1,f} \quad \dots \quad \hat{\theta}_{N,f}]$ $\bar{\alpha}_f^T = [\alpha_f^T \quad 1 - \bar{\mathbf{1}} \alpha_f]$ $\hat{\theta}_{n2,f} = \bar{\Theta}_f \bar{\alpha}_f$ $\dot{x}_m = A_m x_m + b_m r$ $y_m = h_m^T x_m$ $c_0 = \frac{k_m}{\hat{k}_p}$ $\theta_1^T \Psi(s) = \Lambda_w(s) - \frac{1}{\hat{k}_p} \hat{N}_p(s)$ $\theta_2^T \Psi(s) + \theta_3 \Lambda_w(s) = \frac{\hat{D}_p(s) - \Lambda_0(s) D_m(s)}{\hat{k}_p}$ $\theta = [\theta_1 \quad \theta_2 \quad \theta_3 \quad c_0]^T$ $\dot{w}_1 = F w_1 + g u$ $\dot{w}_2 = F w_2 + g y$ $w = [w_1 \quad w_2 \quad y \quad r]^T$ $u = \theta^T w$	$\Sigma_p : \dot{x}_p = A_p x_p + b_p u$ $y_p = h_p^T x_p$ $z = \frac{s^n y}{\Lambda(s)}$ $\dot{\phi}_1 = \Lambda_c \phi_1 + l y_p$ $\dot{\phi}_2 = \Lambda_c \phi_2 + l u$ $\phi^T = [-\phi_1 \quad \phi_2]$ $\Sigma_{i,f} : \hat{z}_{i,f} = \hat{\theta}_{i,f} \phi$ $e_{i,f} = \hat{z}_{i,f} - z$ $n_s^2 = \phi^T \phi$ $Q = Q^T > 0$ $m^2 = 1 + n_s^2$ $\epsilon_{i,f} = \frac{e_{i,f}}{m^2}$ $\Gamma = \Gamma^T > 0$ $\dot{\hat{\theta}}_{i,f} = -\Gamma \epsilon_{i,f} \phi$ $E_f = [e_{1,f} - e_{N,f} \quad \dots \quad e_{N-1,f} - e_{N,f}]$ $M_f(0) = \mathbf{0}$ $v_f(0) = \mathbf{0}$ $\dot{M}_f = -\sigma M_f + E_f^T E_f$ $\dot{v}_f = -\sigma v_f + E_f^T e_{N,f}$ $\dot{\alpha}_f = -(E_f^T E_f + M_f) \alpha_f - E_f^T e_{N,f} - v_f$ $\bar{\Theta}_f = [\hat{\theta}_{1,f} \quad \dots \quad \hat{\theta}_{N,f}]$ $\bar{\alpha}_f^T = [\alpha_f^T \quad 1 - \bar{\mathbf{1}} \alpha_f]$ $\hat{\theta}_{n2,f} = \bar{\Theta}_f \bar{\alpha}_f$ $\dot{x}_m = A_m x_m + b_m r$ $y_m = h_m^T x_m$ $c_0 = \frac{k_m}{\hat{k}_p}$ $\theta_1^T \Psi(s) = \Lambda_w(s) - \frac{1}{\hat{k}_p} \hat{N}_p(s)$ $\theta_2^T \Psi(s) + \theta_3 \Lambda_w(s) = \frac{\hat{D}_p(s) - \Lambda_0(s) D_m(s)}{\hat{k}_p}$ $\theta = [\theta_1 \quad \theta_2 \quad \theta_3 \quad c_0]^T$ $\dot{w}_1 = F w_1 + g u$ $\dot{w}_2 = F w_2 + g y$ $w = [w_1 \quad w_2 \quad y \quad r]^T$ $u = \theta^T w$

3.2.2 Estudos de Simulação

Considere a planta a seguir:

$$G_p(s) = \frac{N_p(s)}{D_p(s)} = \frac{b_1s + b_2}{s^2 + a_1s + a_2} = \frac{2s + 1}{s^2 - 3s - 4}$$

desejamos estimar os coeficientes dos polinômios do numerador e denominador da função de transferência da planta $N_p(s)$ e $D_p(s)$. A região de incerteza para estes parâmetros é considerada conhecida:

$$\begin{aligned} a_1 &\in [-8 \quad -3] \\ a_2 &\in [-6 \quad -1.5] \\ b_1 &\in [-1 \quad 7] \\ b_2 &\in [0.5 \quad 1.5] \end{aligned}$$

faremos uso do Modelo de Identificação por Regressão Linear, da Adaptação de Segundo Nível usando o número mínimo de modelos $N = 5$ com e sem Fator de Esquecimento. Para inicializar as simulações, usamos os seguintes valores:

$$\begin{aligned} \Lambda(s) &= s^2 + 7s + 12 \\ \Lambda_c &= \begin{bmatrix} -6 & -9 \\ 1 & 0 \end{bmatrix} \\ l &= \begin{bmatrix} 1 \\ 0 \end{bmatrix} \\ \Gamma &= \begin{bmatrix} 100 & 0 & 0 & 0 \\ 0 & 100 & 0 & 0 \\ 0 & 0 & 100 & 0 \\ 0 & 0 & 0 & 100 \end{bmatrix} \\ x_p(0) &= \begin{bmatrix} 0.2 \\ 0.4 \end{bmatrix} \\ \phi_1(0) &= \phi_2(0) = 0 \\ r(t) &= 1 + \sin(t) + \sin(1.7t) + \sin(3t) \\ \alpha_{1,f}(0) &= 1 \\ \alpha_i(0) &= 0, \quad i \neq 1 \\ \gamma_{n2,f} &= 10 \\ \gamma'_{n2,f} &= 3 \\ \sigma &= 6 \end{aligned}$$

usamos o valor $\gamma'_{n2,f} = 3$ na simulação para a Adaptação de Segundo Nível Sem

fator de esquecimento e $\gamma_{n2,f} = 10$ para Adaptação de Segundo Nível com Fator de Esquecimento. Escolhemos as estimativas iniciais para o vetor θ_p :

$$\begin{aligned}\hat{\theta}_{1,f}^T(0) &= [-8 \quad -6 \quad 1 \quad 0.5] \\ \hat{\theta}_{2,f}^T(0) &= [29.5 \quad -6 \quad 1 \quad 0.5] \\ \hat{\theta}_{3,f}^T(0) &= [-8 \quad 16.5 \quad 1 \quad 0.5] \\ \hat{\theta}_{4,f}^T(0) &= [-8 \quad -6 \quad 31 \quad 0.5] \\ \hat{\theta}_{5,f}^T(0) &= [-8 \quad -6 \quad 1 \quad 5.5]\end{aligned}$$

e adicionalmente, desejamos que a saída da planta rastreie a saída y_m de um modelo de referência estável escolhido pelo projetista:

$$W_m(s) = \frac{N_m(s)}{D_m(s)} = 1 \frac{s+4}{s^2+4s+4}$$

para tanto calculamos os parâmetros do controlador a partir das estimativas dos parâmetros da planta, resolvendo as equações polinomiais. Geramos um vetor regressor de controle gerado por filtragem do sinal de saída e do sinal de entrada da planta. A partir do vetor de parâmetros do controlador e do regressor de controle geramos uma lei de controle:

$$\begin{aligned}\Lambda_w(s) &= s+4 \\ c_0 &= \frac{k_m}{\hat{k}_p} = \frac{1}{\hat{b}_1} \\ \theta_1 &= s+4 - s - \frac{\hat{b}_2}{\hat{b}_1} = 4 - \frac{\hat{b}_2}{\hat{b}_1} \\ \theta_2^T + \theta_3(s+4) &= \frac{\hat{D}_p(s) - D_m(s)}{\hat{k}_p} \\ \theta_2 &= \frac{-4\hat{a}_1 + \hat{a}_2 + 12}{\hat{b}_1} \\ \theta_3 &= \frac{\hat{a}_1 - 4}{\hat{b}_1} \\ \theta &= [\theta_1 \quad \theta_2 \quad \theta_3 \quad c_0]^T \\ \dot{w}_1 &= -4w_1 + u \\ \dot{w}_2 &= -4w_2 + y \\ w &= [w_1 \quad w_2 \quad y \quad r]^T \\ u &= \theta^T w\end{aligned}$$

omitimos informações consideradas de pouca relevância. Obtivemos os seguintes resultados:




Figura 3.1: Comportamento das estimativas do coeficiente a_1 do polinômio $D_p(s)$ para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.




Figura 3.2: Comportamento das estimativas do coeficiente a_2 do polinômio $D_p(s)$ para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.




Figura 3.3: Comportamento das estimativas do coeficiente b_1 do polinômio $N_p(s)$ para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.




Figura 3.4: Comportamento das estimativas do coeficiente b_2 do polinômio $N_p(s)$ para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.




Figura 3.5: Erro de saída da planta para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.




Figura 3.6: Sinal de Controle gerado pelo controlador com base nas estimativas do Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.

tanto o Modelo de Identificação por Regressão Linear quanto a Adaptação de Segundo Nível mantém o comportamento do sistema estável e, com os parâmetros do controlador calculados a partir de suas estimativas, fazem com que a saída da planta tenda para a saída do modelo de referência. Isto pode ser visualizado na Figura 3.5, com o erro de saída tendendo para 0 em todos os 3 casos. As estimativas

de Primeiro Nível inicializadas em $\hat{\theta}_{1,f}(0)$ se dirigem lentamente em direção aos valores corretos. As estimativas de Segundo Nível sem Fator de Esquecimento não atingem os valores corretos mas também estão se aproximando, mais rapidamente que o Modelo de Primeiro Nível. As estimativas de Segundo Nível com Fator de Esquecimento são as que mais se aproximam dos valores corretos. Podemos ver o comportamento das estimativas nas Figuras 3.1 a 3.4. Vemos novamente que as estimativas de Primeiro Nível são mais lentas que ambos os conjuntos de estimativas de Segundo Nível na sua convergência para os valores corretos, como no capítulo anterior. Apesar de não exibir convergência dos parâmetros para o tempo de simulação escolhido, a Adaptação de Segundo Nível sem Fator de Esquecimento exibe convergência do sinal de controle para o sinal de controle que seria gerado caso os parâmetros da planta fossem conhecidos. Com a introdução de um Fator de Esquecimento na Adaptação de Segundo Nível temos como resultado uma convergência mais rápida e mais suave dos parâmetros para seus valores corretos em relação a Adaptação de Segundo Nível sem Fator de Esquecimento, como no capítulo anterior. O efeito das condições iniciais $x_p^T(0) = [0.2 \ 0.4]$ afeta o erro de saída e a Adaptação de Segundo Nível com Fator de Esquecimento se mostra mais sensível, exibindo um pico no sinal de controle no começo da simulação. A seguir, fizemos uma simulação com uma referência $r(t) = 1$, que não é PE para este sistema:




Figura 3.7: Comportamento das estimativas do coeficiente a_1 do polinômio $D_p(s)$ para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.




Figura 3.8: Comportamento das estimativas do coeficiente a_2 do polinômio $D_p(s)$ para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.




Figura 3.9: Comportamento das estimativas do coeficiente b_1 do polinômio $N_p(s)$ para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.




Figura 3.10: Comportamento das estimativas do coeficiente b_2 do polinômio $N_p(s)$ para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.




Figura 3.11: Erro de saída da planta para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.




Figura 3.12: Sinal de Controle gerado pelo controlador com base nas estimativas do Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.

vemos que, na ausência de um sinal PE as estimativas dos parâmetros acabam por se manter em valores que não são os corretos. Isto pode ser visto nas Figuras 3.7 a 3.10. A Adaptação de Segundo Nível sem Fator de Esquecimento converge ligeiramente mais rápido que os outros dois casos mas exibe mais overshoot que a Adaptação de Segundo Nível com Fator de Esquecimento. O Modelo de Identificação por Regressão Linear exibe uma resposta mais lenta e mais oscilatória que ambos os tipos de Adaptação de Segundo Nível. Apesar de as estimativas dos parâmetros não atingirem os valores corretos, todos os 3 modelos são capazes de fazer com que a saída da planta siga a saída do modelo de referência e produzir um sinal de controle em regime permanente que é igual ao sinal de controle do controlador ideal, como pode ser visto nas Figuras 3.11 e 3.12. No entanto, como não houve convergência dos parâmetros para seus valores corretos, uma mudança qualquer no sinal de referência da planta certamente causará um novo transitório de adaptação das estimativas dos parâmetros.

3.3 Conclusão

Neste capítulo apresentamos brevemente o problema do Controle Adaptativo por Modelo de Referência Indireto para o caso da planta SISO de grau n e grau relativo 1, onde os parâmetros do controlador são calculados a partir de um mapeamento obtido pelas equações de "matching". Mostramos que a Adaptação de Segundo Nível pode substituir o Método do Gradiente na entrega das estimativas

dos parâmetros da planta, sem perda das propriedades de estabilidade do sistema. Na Adaptação de Segundo Nível os coeficientes de uma combinação linear de múltiplos modelos são atualizados por uma lei integral e as estimativas são entregues por esta mesma combinação. Disponibilizamos os algoritmos em forma compacta em um resumo para que o leitor possa testar o conceito por si mesmo em simulação. Dispensamos a hipótese que assumimos para os capítulos 1 e 2 de que a planta seja estável e adotamos uma lei de controle capaz de estabilizar a saída da planta.

Foram feitos estudos de simulação com uma planta instável, nos quais avaliamos a Adaptação de Segundo Nível com e sem Fator de Esquecimento em relação ao Modelo por Regressão Linear para o caso SISO. Terminamos aqui os temas que gostaríamos de abordar para esta dissertação. A Adaptação de Segundo Nível com e sem Fator de Esquecimento é uma nova ferramenta de identificação dos parâmetros de uma planta linear. Devido ao uso das informações de múltiplos modelos de identificação em conjunto, as estimativas dos parâmetros exibem uma convergência mais rápida na Adaptação de Segundo Nível quando comparada com modelos de identificação convencionais. Nesta dissertação de mestrado nossas contribuições foram as seguintes:

- 1 Explicitar o conceito de Adaptação de Segundo Nível para identificação dos parâmetros de uma planta de grau n e grau relativo 1 tendo como base o Método do Gradiente Normalizado para o caso SISO, discutindo suas propriedades.
- 2 Explicitar o conceito de Adaptação de Segundo Nível para identificação dos parâmetros de uma planta linear tendo como base o Modelo Série-Paralelo para o caso MIMO, discutindo suas propriedades.
- 3 A introdução de um Fator de Esquecimento na lei adaptativa da Adaptação de Segundo Nível, de forma a acumular informações passadas e melhorar as propriedades de convergência das estimativas dos parâmetros da planta para seus valores corretos.
- 4 Analisar as normas $\mathcal{L}_p$ do vetor $\hat{\theta}_p$ de estimativas dos parâmetros da planta SISO de grau n e grau relativo 1 para a Adaptação de Segundo Nível tendo como base o Método do Gradiente, o que permite concluir que a Adaptação de Segundo Nível é uma ferramenta de estimação adequada em termos de estabilidade para se usar em conjunto com o Controle Adaptativo por Modelo de Referência Indireto neste caso.

finalmente, esperamos que esta dissertação sirva como um guia de uso da Adaptação de Segundo Nível e como ponto de partida para novos trabalhos.