



UNIVERSIDADE FEDERAL DO RIO GRANDE DO NORTE
CENTRO DE TECNOLOGIA
PROGRAMA DE PÓS-GRADUAÇÃO EM ENGENHARIA ELÉTRICA E
DE COMPUTAÇÃO



Adaptação de Segundo Nível como Técnica de Estimação de Parâmetros e sua Aplicação ao Controle Adaptativo por Modelo de Referência

Pedro Yochinori Gushiken

Orientador: Prof. Dr. Aldayr Dantas de Araújo

Dissertação de Mestrado apresentada ao
Programa de Pós-Graduação em Engenharia
Elétrica e de Computação da UFRN (área de
concentração: Engenharia de Computação)
como parte dos requisitos para obtenção do
título de Mestre em Ciências.

Número de ordem PPgEEC: M000
Natal, RN, janeiro de 2018

Resumo

O controle adaptativo é usado quando há incertezas paramétricas no sistema a ser controlado. Há duas estratégias distintas: A direta e a indireta. No controle adaptativo direto os parâmetros do controlador são estimados em tempo real. No controle adaptativo indireto os parâmetros da planta são estimados em tempo real através de um modelo de identificação e estas estimativas são utilizadas para calcular os parâmetros do controlador. Modelos de identificação tais como os modelos paralelo, série-paralelo e por regressão linear podem ser usados. Há vários métodos de estimação para atualizar os parâmetros de um modelo de identificação que são aplicáveis ao controle adaptativo indireto tais como o método dos mínimos quadrados e o método do gradiente normalizado.

Neste contexto, recentemente um novo método de estimação de parâmetros foi proposto, conhecido como adaptação de segundo nível. Na adaptação de segundo nível as estimativas dos parâmetros da planta são entregues por combinações convexas dos parâmetros de múltiplos modelos de identificação. Os coeficientes destas combinações convexas são por sua vez estimados, como um segundo nível de adaptação.

Neste trabalho mostramos a adaptação de segundo nível para o caso de uma planta de ordem 1, para o caso de uma planta de ordem n onde apenas a entrada e a saída da planta estão disponíveis para medição (**SISO**) e para o caso de uma planta de ordem n e vetor de estado disponível para medição. Propomos uma modificação na lei adaptativa da adaptação de segundo nível. Em todos os casos verificamos por simulação que as estimativas entregues pela adaptação de segundo nível convergem muito mais rapidamente para os valores corretos que as estimativas entregues por modelos de identificação individuais e que a modificação proposta aumenta a velocidade e suaviza a convergência das estimativas. Finalmente, aplicamos a adaptação de segundo nível com base em modelos de identificação por regressão linear atualizados pelo método do gradiente normalizado ao problema do controle adaptativo por modelo de referência (**MRAC**) de uma planta **SISO** de grau n e grau relativo unitário. Demonstramos a estabilidade dos sinais do sistema em malha fechada. Resultados de simulação mostram que o sinal de controle gerado com adaptação de segundo nível produz melhores resultados de rastreamento do modelo de referência comparada aos modelos de identificação individuais.

Palavras-chave: Estimação de Parâmetros, Controle Adaptativo por Modelo de Referência, Adaptação de Segundo Nível, Controle Adaptativo Múltiplos Modelos.

Abstract

Adaptive control is used when there is parametric uncertainty in the controlled system. There are two distinct strategies: Direct and indirect. Direct adaptive control estimates the controller parameters in real time. In indirect adaptive control the plant parameters are estimated in real time through an identification model and these estimates are used to calculate the controller parameters. There are several identification models that can be used such as parallel, series-parallel and linear regression models. There are several parameter estimation methods that can be used to update these models that are suitable to be used in conjunction with indirect adaptive control such as the least squares method and normalized gradient method.

In this context, a new method for parameter estimation based on multiple identification models was recently proposed, known as second-level adaptation. In second level adaptation the estimates of the plant parameters are delivered by convex combinations of the estimates from multiple identification models. The coefficients for these convex combinations are also estimated, as a second level of adaptation.

In this dissertation we demonstrate the concept of second level adaptation as a parameter estimation method for the case of a plant of degree unity, the case of a plant of degree n with single input and output available for measurement (**SISO**) and the case of a plant of degree n whose state vector is available for measurement. We propose a modified form of the adaptive law for second level adaptation. In all cases simulation studies show that the estimates reach their true values faster with second level adaptation compared to individual identification models and that the proposed modification is even faster and also smoother in this regard. Finally, we apply second level adaptation based on linear regression identification models updated through the normalized gradient method to the problem of model reference adaptive control(**MRAC**) of a degree n **SISO** plant with relative degree one. The closed-loop stability of the system is demonstrated. Simulation results show that the control signal generated with second level adaptation yields better results of model reference tracking compared to individual identification models.

Keywords: Parameter Estimation, Model Reference Adaptive Control, Second Level Adaptation, Multiple Model Adaptive Control.

Sumário

Sumário	i
Lista de Figuras	iii
Lista de Tabelas	vii
Lista de Símbolos e Abreviaturas	ix
1 Introdução	1
1.1 Sistemas Lineares	1
1.2 Sistemas de Controle	1
1.3 Controle Clássico	3
1.4 Controle Adaptativo	4
1.5 Controle Adaptativo Direto e Indireto	4
1.6 Modelos de Identificação	6
1.7 Controle Adaptativo por Modelo de Referência	8
1.8 Controle Adaptativo baseado em Múltiplos Modelos de Identificação . . .	9
1.9 Modelos Virtuais por Combinação Convexa	9
1.10 Adaptação de Segundo Nível	10
1.11 Estrutura do Trabalho	11
2 Estimação de Parâmetros, Ordem 1	13
2.1 Modelos de Identificação Convencionais	14
2.1.1 Modelo de Identificação Paralelo	14
2.1.2 Modelo de Identificação Série-Paralelo	17
2.1.3 Modelo de Identificação por Regressão Linear	19
2.2 Estimação de Parâmetros de Segundo Nível	22
2.2.1 N Modelos de Identificação Série-Paralelo	22
2.2.2 N Modelos de Identificação por Regressão Linear	32
2.3 Resumo dos Algoritmos e Estudos de Simulação	41
2.3.1 Resumo dos Algoritmos	41
2.3.2 Estudos de Simulação	43
2.4 Conclusão	53

3	Estimação de Parâmetros, Ordem n	55
3.1	Planta com Vetor de Estado Acessível	56
3.1.1	Modelo de Identificação Série-Paralelo	56
3.2	Caso SISO	59
3.2.1	Modelo de Identificação por Regressão Linear	59
3.3	Estimação de Parâmetros de Segundo Nível	62
3.3.1	Planta com Vetor de Estado Acessível	62
3.3.2	Caso SISO	69
3.4	Resumo dos Algoritmos e Estudos de Simulação	78
3.4.1	Resumo dos Algoritmos	78
3.4.2	Estudos de Simulação	81
3.5	Conclusão	93
4	Controle Adaptativo Indireto	95
4.1	Planta de Ordem n e Grau Relativo Unitário	95
4.1.1	Controle por Modelo de Referência	95
4.1.2	Controle Adaptativo por Modelo de Referência Indireto	97
4.1.3	IMRAC com Adaptação de Segundo Nível	101
4.2	Resumo dos Algoritmos e Estudos de Simulação	103
4.2.1	Resumo dos Algoritmos	103
4.2.2	Estudos de Simulação	106
4.3	Conclusão	114
5	Conclusão	117
	Referências Bibliográficas	120

Lista de Figuras

1.1	Sistema de Controle em Malha Aberta	2
1.2	Sistema de Controle em Malha Fechada	3
1.3	Controlador Adaptativo Direto	5
1.4	Controlador Adaptativo Indireto	6
1.5	Modelo de Identificação Paralelo	7
1.6	Modelo de Identificação Série-Paralelo	7
1.7	Modelo de Identificação por Regressão Linear	8
1.8	Controlador Adaptativo Indireto de Segundo Nível	11
2.1	Erro de Identificação usando o Modelo Paralelo para a planta Σ_p , 110 segundos de simulação	44
2.2	Erro de Identificação usando o Modelo Série-Paralelo para a planta Σ_p , 110 segundos de simulação	45
2.3	Erro de Identificação usando o Modelo por Regressão Linear para a planta Σ_p , 110 segundos de simulação	45
2.4	Estimativa do parâmetro $a_p = 3$ para a planta Σ_p para os Modelos de Identificação estudados, Adaptação de Segundo Nível com $N = 3, N = 4$ e $N = 8$ Modelos de Primeiro Nível por Regressão Linear e $N = 3$ Modelos de Primeiro Nível Série-Paralelos, 20 segundos de simulação	47
2.5	Estimativa do parâmetro $k_p = 1.5$ para a planta Σ_p para os Modelos de Identificação estudados, Adaptação de Segundo Nível com $N = 3, N = 4$ e $N = 8$ Modelos de Primeiro Nível por Regressão Linear e $N = 3$ Modelos de Primeiro Nível Série-Paralelos, 20 segundos de simulação	47
2.6	Erros de Identificação usando 3 Modelos Série-Paralelos para a planta Σ_p , 36 segundos de simulação	48
2.7	Estimativas do parâmetro $a_p = 3$ para a planta Σ_p para 3 Modelos por Série-Paralelos e a estimativa de Segundo Nível Modificada, 36 segundos de simulação	49
2.8	Estimativas do parâmetro $k_p = 1.5$ para a planta Σ_p para 3 Modelos por Série-Paralelos e a estimativa de Segundo Nível Modificada, 36 segundos de simulação	49
2.9	Trajetória dos parâmetros $\hat{a}_{n2,sp}$ e $\hat{k}_{n2,sp}$ da Adaptação de Segundo Nível no espaço de parâmetros usando 3 Modelos Série-Paralelos para a planta Σ_p , 30 segundos de simulação	50
2.10	Erros de Identificação usando 3 Modelos por Regressão Linear para a planta Σ_p	51

2.11	Estimativas do parâmetro $a_p = 1.5$ para a planta Σ_p para 3 Modelos por Regressão Linear e a estimativa de Segundo Nível Modificada, 36 segundos de simulação	51
2.12	Estimativas do parâmetro $k_p = 1.5$ para a planta Σ_p para 3 Modelos por Regressão Linear e a estimativa de Segundo Nível Modificada, 36 segundos de simulação	52
2.13	Trajetória dos parâmetros $\hat{a}_{n2,f}$ e $\hat{k}_{n2,f}$ da Adaptação de Segundo Nível Modificada no espaço de parâmetros usando 3 Modelos por Regressão Linear para a planta Σ_p , aos 30 segundos de simulação	52
3.1	Comportamento das estimativas do elemento a_{11} da matriz A_p para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento. .	84
3.2	Comportamento das estimativas do elemento a_{12} da matriz A_p para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento. .	84
3.3	Comportamento das estimativas do elemento a_{21} da matriz A_p para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento. .	85
3.4	Comportamento das estimativas do elemento a_{22} da matriz A_p para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento. .	85
3.5	Comportamento das estimativas do elemento b_1 do vetor b_p para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento. .	86
3.6	Comportamento das estimativas do elemento b_2 do vetor b_p para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento. .	86
3.7	Primeiro elemento do vetor erro de Identificação do Modelo de Primeiro Nível com estimativa inicial $\hat{A}_{1,sp}(0)$ e $b_{1,sp}(0)$	87
3.8	Segundo elemento do vetor erro de Identificação do Modelo de Primeiro Nível com estimativa inicial $\hat{A}_{1,sp}(0)$ e $b_{1,sp}(0)$	87
3.9	Comportamento das estimativas do coeficiente a_1 do polinômio $D_p(s)$ para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.	90
3.10	Comportamento das estimativas do coeficiente a_2 do polinômio $D_p(s)$ para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.	90
3.11	Comportamento das estimativas do coeficiente b_1 do polinômio $N_p(s)$ para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.	91

3.12	Comportamento das estimativas do coeficiente b_2 do polinômio $N_p(s)$ para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.	91
3.13	Erro de Identificação não normalizado do Modelo de Primeiro Nível com estimativa inicial $\hat{\theta}_{1,f}(0)$	92
4.1	Comportamento das estimativas do coeficiente a_1 do polinômio $D_p(s)$ para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.	108
4.2	Comportamento das estimativas do coeficiente a_2 do polinômio $D_p(s)$ para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.	108
4.3	Comportamento das estimativas do coeficiente b_1 do polinômio $N_p(s)$ para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.	109
4.4	Comportamento das estimativas do coeficiente b_2 do polinômio $N_p(s)$ para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.	109
4.5	Erro de saída da planta para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.	110
4.6	Sinal de Controle gerado pelo controlador com base nas estimativas do Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.	110
4.7	Comportamento das estimativas do coeficiente a_1 do polinômio $D_p(s)$ para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.	111
4.8	Comportamento das estimativas do coeficiente a_2 do polinômio $D_p(s)$ para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.	112
4.9	Comportamento das estimativas do coeficiente b_1 do polinômio $N_p(s)$ para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.	112
4.10	Comportamento das estimativas do coeficiente b_2 do polinômio $N_p(s)$ para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.	113

4.11	Erro de saída da planta para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.	113
4.12	Sinal de Controle gerado pelo controlador com base nas estimativas do Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.	114

Lista de Tabelas

2.1	Algoritmos dos Modelos de Identificação de Primeiro Nível para uma Planta de Grau 1 e Grau Relativo Unitário	42
2.2	Algoritmos da Adaptação de Segundo Nível baseada em Modelos de Identificação Série-Paralelos para uma Planta de Grau 1 e Grau relativo unitário	42
2.3	Algoritmos da Adaptação de Segundo Nível baseada em Modelos de Identificação por Regressão Linear para uma Planta de Grau 1 e Grau relativo unitário	43
3.1	Algoritmos dos Modelos de Primeiro Nível para uma Planta de Grau n	79
3.2	Algoritmos da Adaptação de Segundo Nível baseado em Modelos de Identificação Série-Paralelos para uma Planta de Grau n com vetor de estado acessível	80
3.3	Algoritmos da Adaptação de Segundo Nível baseada em Modelos de Identificação por Regressão Linear para uma Planta SISO de Grau n	81
4.1	Algoritmos de Controle por Modelo de Referência, Caso Ideal com Planta Conhecida e Controle Adaptativo baseado em Modelo de Identificação por Regressão Linear	104
4.2	Algoritmos de Controle Adaptativo por Modelo de Referência Indireto baseados em Adaptação de Segundo Nível a partir de Modelos de Identificação por Regressão Linear	105

Lista de Símbolos e Abreviaturas

$(.)^T$	Operador de transposição de uma matriz ou vetor
N	Número de modelos de identificação usados na Adaptação de Segundo Nível
$(\dot{\cdot})$	Derivada de uma variável em relação ao tempo
$(\hat{\cdot})$	Estimativa de uma variável
$\inf(\cdot)$	Ínfimo de uma variável, maior cota inferior do conjunto de valores daquela variável
$\int_{(\cdot)}^{(\cdot)}(\cdot)$	Operador de integração
λ_{max}	Autovalor máximo de uma matriz
λ_{min}	Autovalor mínimo de uma matriz
$\sum_{(\cdot)}^{(\cdot)}(\cdot)$	Operador de somatório
$\sup(\cdot)$	Supremo de uma variável, menor cota superior do conjunto de valores daquela variável
$\mathbf{0}$	Matriz de tamanho apropriado (determinado pelo contexto da equação em que está sendo aplicada) cujos elementos são todos 0
$(\tilde{\cdot})$	Erro paramétrico, refere-se a diferença entre uma estimativa e o valor que está sendo estimado
$\vec{\mathbf{1}}$	Vetor linha de tamanho apropriado (determinado pelo contexto da equação em que está sendo aplicado) cujos elementos são todos 1
n	Grau da Planta
n^*	Grau da relativo da planta, neste trabalho assumimos sempre que $n^* = 1$
s	Variável complexa no domínio da frequência
Σ_p	Planta

$\Sigma_{1,f}$	Modelo de identificação por Regressão Linear 1 da planta
$\Sigma_{1,p}$	Modelo de identificação paralelo 1 da planta
$\Sigma_{1,sp}$	Modelo de identificação série-paralelo 1 da planta
$\Sigma_{i,f}$	i-ésimo Modelo de identificação por Regressão Linear, com $i = 1, \dots, N$
$\Sigma_{i,sp}$	i-ésimo Modelo de identificação Série-Paralelo da planta, com $i = 1, \dots, N$
$\Sigma_{p,SISO}$	Planta SISO de ordem n e grau relativo 1
$\Sigma_{v,f}$	Modelo de identificação Virtual da planta cujas estimativas dos parâmetros são formadas pela combinação convexa das estimativas de Modelos de Identificação por Regressão Linear
$\Sigma_{v,sp}$	Modelo de identificação Virtual da planta cujas estimativas dos parâmetros são formadas pela combinação convexa das estimativas de Modelos de Identificação Série Paralelos
$D_m(s)$	Polinômio do denominador da função de transferência $W_m(s)$
$D_p(s)$	Polinômio do denominador da função de transferência $G_p(s)$
$G(s)$	Função de transferência da planta
$G_c(s)$	Função de transferência entre o sinal de referência e a saída da planta
$G_{1,p}(s)$	Função de transferência do Modelo de identificação Paralelo 1 da planta
$N_p(s)$	Polinômio do numerador da função de transferência $G_p(s)$
$W_m(s)$	Função de transferência do modelo de referência
$Z_m(s)$	Polinômio mônico do numerador da função de transferência $W_m(s)$
$Z_p(s)$	Polinômio mônico do numerador da função de transferência $G_p(s)$, igual a $N_p(s)$ dividido pelo ganho de alta frequência $b_1 = k_p$
$\Lambda(s)$	Polinômio mônico, Hurwitz, de grau n
$\dot{x}_p$	Primeira derivada em relação ao tempo do vetor de estado da planta.
$\hat{x}_{1,sp}$	Estimativa do Vetor de Estado da Planta de ordem n e grau relativo 1 usando o Modelo de Identificação Série-Paralelo 1
$\hat{x}_{i,sp}$	Estimativa do Vetor de Estado da Planta de ordem n e grau relativo 1 usando o i-ésimo Modelo de Identificação Série-Paralelo com $i = 1, \dots, N$
$\hat{y}_{1,p}$	Estimativa do Sinal de Saída da Planta usando o Modelo de Identificação Paralelo 1

$\hat{y}_{1,sp}$	Estimativa do Sinal de Saída da Planta usando o Modelo de Identificação Série-Paralelo 1
$\hat{y}_{i,sp}$	Estimativa do Sinal de Saída da Planta usando o i -ésimo Modelo de Identificação Série-Paralelo, com $i = 1, \dots, N$
$\hat{y}_{v,sp}$	Estimativa do Sinal de Saída da Planta usando o Modelo Virtual
$\hat{z}_{1,f}$	Estimativa do Sinal Filtrado de Saída da Planta usando o Modelo de Identificação por Regressão Linear 1
$\hat{z}_{i,f}$	Estimativa do Sinal Filtrado de Saída da Planta usando o i -ésimo Modelo de Identificação por Regressão Linear, com $i = 1, \dots, N$
$\hat{z}_{v,f}$	Estimativa do Sinal Filtrado de Saída da Planta usando o Modelo Virtual
ϕ	Vetor Coluna formado pelos elementos ϕ_1 na primeira linha e ϕ_2 na segunda linha, e chamado vetor regressor
ϕ_1	Vetor gerado a partir de filtragens do sinal y por funções de transferência próprias $\frac{s^i}{\Lambda(s)}$, com $i = n - 1, \dots, 1$, usado para construir o vetor regressor ϕ
ϕ_2	Vetor gerado a partir de filtragens do sinal u por funções de transferência próprias $\frac{s^i}{\Lambda(s)}$, com $i = n - 1, \dots, 1$, usado para construir o vetor regressor ϕ
u	Sinal de entrada escalar.
x_p	Vetor de estado da planta.
y ou y_p	Sinal de Saída da Planta
z	Sinal de Saída da Planta filtrado por uma função de transferência própria $\frac{s^n}{\Lambda(s)}$
E_f	Vetor linha formado pela diferença entre os Erros de identificação $e_{i,f}$, com $i = 1, \dots, N - 1$, e o erro $e_{N,f}$ em suas colunas
E_{sp}	Matriz formada pela diferença entre os Erros de identificação $e_{i,sp}$, com $i = 1, \dots, N - 1$, e o erro $e_{N,sp}$ em suas colunas
$\bar{E}_f$	Vetor linha formado pelos erros de identificação $e_{i,f}$, com $i = 1, \dots, N$, em suas colunas
$\bar{E}_{sp}$	Matriz formada pelos Erros de identificação $e_{i,sp}$, com $i = 1, \dots, N$, em suas colunas
$e_{1,f}$	Erro de identificação gerado pela diferença entre o sinal de saída do Modelo de identificação por Regressão Linear 1 e o sinal de saída da planta filtrado

$e_{1,p}$	Erro de identificação gerado pela diferença entre o sinal de saída do Modelo de identificação Paralelo 1 e o sinal de saída da planta no caso da planta de ordem 1
$e_{1,sp}$	Erro de identificação gerado pela diferença entre o sinal de saída do Modelo de identificação Série-Paralelo 1 e o sinal de saída da planta no caso da planta de ordem 1 ou erro de identificação gerado pela diferença entre o vetor de estado do Modelo de identificação Série-Paralelo 1 e o vetor de estado da planta no caso da planta de ordem n
$e_{N,f}$	Erro de identificação gerado pela diferença entre o sinal de saída do Modelo de identificação por Regressão Linear N e o sinal de saída da planta filtrado
$e_{N,sp}$	Erro de identificação gerado pela diferença entre o sinal de saída do Modelo de identificação Série-Paralelo N e o sinal de saída da planta no caso da planta de ordem 1 ou erro de identificação gerado pela diferença entre o vetor de estado do modelo de identificação série-paralelo N e o vetor de estado da planta no caso da planta de ordem n
$e_{i,f}$	Erro de identificação gerado pela diferença entre o sinal de saída do i-ésimo Modelo de identificação por Regressão Linear, com $i = 1, \dots, N$, e o sinal de saída da planta filtrado
$e_{i,sp}$	Erro de identificação gerado pela diferença entre o sinal de saída do i-ésimo Modelo de identificação Série-Paralelo, com $i = 1, \dots, N$, e o sinal de saída da planta no caso da planta de ordem 1 ou erro de identificação gerado pela diferença entre o vetor de estado do i-ésimo Modelo de identificação Série-Paralelo, com $i = 1, \dots, N$, e o vetor de estado da planta no caso da planta de ordem n
$e_{v,f}$	Erro de identificação gerado pela diferença entre o sinal de saída do modelo virtual e o sinal de saída da planta filtrado
$e_{v,sp}$	Erro de identificação gerado pela diferença entre o sinal de saída do modelo virtual e o sinal de saída da planta no caso da planta de ordem 1 ou erro de identificação gerado pela diferença entre o vetor de estado do modelo virtual e o vetor de estado da planta no caso da planta ordem n
A_m	Matriz com autovalores no semi plano esquerdo aberto, critério do projetista
A_p	Matriz A da representação em espaço de estado para a Planta de ordem n e grau relativo 1
P	Variável simétrica da equação de Lyapunov $A_m^T P + P A_m = -Q$ em A_m e Q , usada nas leis adaptativas para o Modelo de Identificação Série Paralelo da Planta
Q	Matriz definida positiva e simétrica, critério do projetista
$S_{\theta,a}$	Região de incerteza do espaço de parâmetros a_{ij} da matriz A_p delimitada pelo polítopo convexo cujos vértices são todas as combinações de a_{ij}^+ ou a_{ij}^- .

$S_{\theta,b}$	Região de incerteza do espaço de parâmetros b_{ij} da matriz b_p delimitada pelo polítopo convexo cujos vértices são todas as combinações de b_{ij}^+ ou b_{ij}^- .
$\hat{A}_{1,sp}$	Lei adaptativa para atualização da estimativa $\hat{A}_{1,sp}$
$\hat{A}_{i,sp}$	Lei adaptativa para atualização da estimativa $\hat{A}_{i,sp}$, com $i = 1, \dots, N$
$\hat{\theta}_{1,f}$	Lei adaptativa para atualização da estimativa $\hat{\theta}_{1,f}$
$\hat{\theta}_{i,f}$	Lei adaptativa para atualização da estimativa $\hat{\theta}_{i,f}$, com $i = 1, \dots, N$
$\hat{a}_{1,f}$	Lei adaptativa para atualização da estimativa $\hat{a}_{1,f}$
$\hat{a}_{1,p}$	Lei adaptativa para atualização da estimativa $\hat{a}_{1,p}$
$\hat{a}_{1,sp}$	Lei adaptativa para atualização da estimativa $\hat{a}_{1,sp}$
$\hat{a}_{i,f}$	Lei adaptativa para atualização da estimativa $\hat{a}_{i,f}$, com $i = 1, \dots, N$
$\hat{a}_{i,sp}$	Lei adaptativa para atualização da estimativa $\hat{a}_{i,sp}$, com $i = 1, \dots, N$
$\hat{a}_{v,f}$	Lei adaptativa para atualização da estimativa $\hat{a}_{v,f}$
$\hat{a}_{v,sp}$	Lei adaptativa para atualização da estimativa $\hat{a}_{v,sp}$
$\hat{b}_{1,sp}$	Lei adaptativa para atualização da estimativa $\hat{b}_{1,sp}$
$\hat{b}_{i,sp}$	Lei adaptativa para atualização da estimativa $\hat{b}_{i,sp}$, com $i = 1, \dots, N$
$\hat{k}_{1,f}$	Lei adaptativa para atualização da Estimativa $\hat{k}_{1,f}$
$\hat{k}_{1,p}$	Lei adaptativa para atualização da estimativa $\hat{k}_{1,p}$
$\hat{k}_{1,sp}$	Lei adaptativa para atualização da estimativa $\hat{k}_{1,sp}$
$\hat{k}_{i,f}$	Lei adaptativa para atualização da Estimativa $\hat{k}_{i,f}$
$\hat{k}_{i,sp}$	Lei adaptativa para atualização da Estimativa $\hat{k}_{i,sp}$
$\hat{k}_{v,f}$	Lei adaptativa para atualização da Estimativa $\hat{k}_{v,f}$
$\hat{k}_{v,sp}$	Lei adaptativa para atualização da Estimativa $\hat{k}_{v,sp}$
$\hat{A}_{1,sp}$	Estimativa da Matriz A_p da planta usando o Modelo de Identificação Série-Paralelo 1
$\hat{A}_{i,sp}$	Estimativa da Matriz A_p da planta usando o i-ésimo Modelo de Identificação Série-Paralelo, com $i = 1, \dots, N$

$\hat{\theta}_{1,f}$	Estimativa do vetor de parâmetros θ_p^* da planta de ordem n e grau relativo 1 usando o Modelo de Identificação por Regressão Linear da Planta 1
$\hat{\theta}_{i,f}$	Estimativa do vetor de parâmetros θ_p^* da planta de ordem n e grau relativo 1 usando o i -ésimo Modelo de Identificação por Regressão Linear da Planta, com $i = 1, \dots, N$
$\hat{a}_{1,f}$	Estimativa do coeficiente do polinômio mônico do denominador da planta de ordem 1 usando o Modelo de Identificação por Regressão Linear 1
$\hat{a}_{1,p}$	Estimativa do coeficiente do polinômio mônico do denominador da planta de ordem 1 usando o Modelo de Identificação Paralelo 1
$\hat{a}_{1,sp}$	Estimativa do coeficiente do polinômio mônico do denominador da planta de ordem 1 usando o Modelo de Identificação Série-Paralelo 1
$\hat{a}_{i,f}$	Estimativa do coeficiente do polinômio mônico do denominador da planta de ordem 1 usando o i -ésimo Modelo de Identificação por Regressão Linear, com $i = 1, \dots, N$
$\hat{a}_{i,sp}$	Estimativa do coeficiente do polinômio mônico do denominador da planta de ordem 1 usando o i -ésimo Modelo de Identificação Série-Paralelo, com $i = 1, \dots, N$
$\hat{a}_{v,f}$	Estimativa do coeficiente do polinômio mônico do denominador da planta de ordem 1 a partir de uma combinação convexa de coeficientes β_i dos parâmetros dos modelos de identificação por regressão linear
$\hat{a}_{v,sp}$	Estimativa do coeficiente do polinômio mônico do denominador da planta de ordem 1 a partir de uma combinação convexa de coeficientes β_i dos parâmetros dos modelos de identificação série-paralelos
$\hat{b}_{1,sp}$	Estimativa do vetor b_p da planta usando o Modelo de Identificação Série-Paralelo 1
$\hat{b}_{i,sp}$	Estimativa do vetor b_p da planta usando o i -ésimo Modelo de Identificação Série-Paralelo, com $i = 1, \dots, N$
$\hat{k}_{1,f}$	Estimativa do coeficiente do polinômio do numerador da planta de ordem 1 usando o Modelo de Identificação por Regressão Linear 1
$\hat{k}_{1,p}$	Estimativa do coeficiente do polinômio do numerador da planta de ordem 1 usando o Modelo de Identificação Paralelo 1
$\hat{k}_{1,sp}$	Estimativa do coeficiente do polinômio do numerador da planta de ordem 1 usando o Modelo de Identificação Série-Paralelo 1
$\hat{k}_{i,f}$	Estimativa do coeficiente do polinômio do numerador da planta de ordem 1 usando o i -ésimo Modelo de Identificação por Regressão Linear, com $i = 1, \dots, N$

$\hat{k}_{i,sp}$	Estimativa do coeficiente do polinômio do numerador da planta de ordem 1 usando o i-ésimo Modelo de Identificação Série-Paralelo, com $i = 1, \dots, N$
$\hat{k}_{v,f}$	Estimativa do coeficiente do polinômio do numerador da planta de ordem 1 usando o Modelo Virtual
$\hat{k}_{v,sp}$	Estimativa do coeficiente do polinômio do numerador da planta de ordem 1 usando o Modelo Virtual
$\tilde{A}_{1,sp}$	Erro paramétrico devido a diferença entre a estimativa $\hat{A}_{1,sp}$ e o valor correto A_p
$\tilde{A}_{i,sp}$	Erro paramétrico devido a diferença entre a estimativa $\hat{A}_{i,sp}$ e o valor correto A_p , com $i = 1, \dots, N$
$\tilde{\theta}_{1,f}$	Erro paramétrico devido a diferença entre a estimativa $\hat{\theta}_{1,f}$ e o valor correto θ_p^*
$\tilde{\theta}_{i,f}$	Erro paramétrico devido a diferença entre a estimativa $\hat{\theta}_{i,f}$ e o valor correto θ_p^*
$\tilde{a}_{1,f}$	Erro paramétrico devido a diferença entre a estimativa $\hat{a}_{1,f}$ e o valor correto a_p
$\tilde{a}_{1,p}$	Erro paramétrico devido a diferença entre a estimativa $\hat{a}_{1,p}$ e o valor correto a_p
$\tilde{a}_{1,sp}$	Erro paramétrico devido a diferença entre a estimativa $\hat{a}_{1,sp}$ e o valor correto a_p
$\tilde{a}_{i,f}$	Erro paramétrico devido a diferença entre a estimativa $\hat{a}_{i,f}$ e o valor correto a_p
$\tilde{a}_{i,sp}$	Erro paramétrico devido a diferença entre a estimativa $\hat{a}_{i,sp}$ e o valor correto a_p , com $i = 1, \dots, N$
$\tilde{a}_{v,f}$	Erro paramétrico devido a diferença entre a estimativa $\hat{a}_{v,f}$ e o valor correto a_p
$\tilde{a}_{v,sp}$	Erro paramétrico devido a diferença entre a estimativa $\hat{a}_{v,sp}$ e o valor correto a_p
$\tilde{k}_{1,f}$	Erro paramétrico devido a diferença entre a estimativa $\hat{k}_{1,f}$ e o valor correto k_p
$\tilde{k}_{1,p}$	Erro paramétrico devido a diferença entre a estimativa $\hat{k}_{1,p}$ e o valor correto k_p
$\tilde{k}_{1,sp}$	Erro paramétrico devido a diferença entre a estimativa $\hat{k}_{1,sp}$ e o valor correto k_p
$\tilde{k}_{i,f}$	Erro paramétrico devido a diferença entre a estimativa $\hat{k}_{i,f}$ e o valor correto k_p
$\tilde{k}_{i,sp}$	Erro paramétrico devido a diferença entre a estimativa $\hat{k}_{i,sp}$ e o valor correto k_p
$\tilde{k}_{v,f}$	Erro paramétrico devido a diferença entre a estimativa $\hat{k}_{v,f}$ e o valor correto k_p
$\tilde{k}_{v,sp}$	Erro paramétrico devido a diferença entre a estimativa $\hat{k}_{v,sp}$ e o valor correto k_p
a_i	Coeficientes do polinômio mônico do denominador da planta SISO de ordem n e grau relativo 1, com $i = 1, \dots, n$, associados às variáveis complexas s^{n-i} do polinômio

a_i^+	Limitante superior da região de incerteza para os coeficientes a_i da planta SISO de ordem n e grau relativo 1, com $i = 1, \dots, n$
a_i^-	Limitante inferior da região de incerteza para os coeficientes a_i da planta SISO de ordem n e grau relativo 1, com $i = 1, \dots, n$
a_p	Coefficiente do polinômio mônico do denominador da planta de ordem 1
a_p^+	Limitante superior da região de incerteza para o coeficiente a_p da planta de ordem 1
a_p^-	Limitante inferior da região de incerteza para o coeficiente a_p da planta de ordem 1
a_{ij}	Elementos da matriz $A_p, i = 1, \dots, n, j = 1, \dots, n$
a_{ij}^+	Limitantes superiores para os elementos $a_{ij}, i = 1, \dots, n, j = 1, \dots, n$
a_{ij}^-	Limitantes inferiores para os elementos $a_{ij}, i = 1, \dots, n, j = 1, \dots, n$
b_i	Coefficientes do polinômio do numerador da planta SISO de ordem n e grau relativo 1, com $i = 1, \dots, n$, associados às variáveis complexas s^{n-i} do polinômio
b_i^+	Limitante superior da região de incerteza para os coeficientes b_i da planta SISO de ordem n e grau relativo 1, com $i = 1, \dots, n$
b_i^-	Limitante inferior da região de incerteza para o coeficiente b_i da planta SISO de ordem n e grau relativo 1, com $i = 1, \dots, n$
b_p	vetor b da representação em espaço de estado para a Planta de ordem n e grau relativo 1
b_{ij}	Elementos do vetor $b_p, i = 1, \dots, n, j = 1, \dots, p$
b_{ij}^+	Limitantes superiores para os elementos $b_{ij}, i = 1, \dots, n$
b_{ij}^-	Limitantes inferiores para os elementos $b_{ij}, i = 1, \dots, n$
k_p	Coefficiente do polinômio do numerador da planta de ordem 1
k_p^+	Limitante superior da região de incerteza para o coeficiente k_p da planta de ordem 1
k_p^-	Limitante inferior da região de incerteza para o coeficiente k_p da planta de ordem 1
α_f	Vetor coluna formado pelos coeficientes $\alpha_{i,f}$ em suas linhas, com $i = 1, \dots, N-1$
α_f^*	Vetor coluna formado pelos coeficientes $\alpha_{i,f}^*$ em suas linhas, com $i = 1, \dots, N-1$

$\alpha_{i,f}$	Coeficientes da combinação convexa que são aplicados às estimativas $\hat{k}_{i,f}$ e $\hat{a}_{i,f}$, com $i = 1, \dots, N$, para formar uma estimativa de segundo nível dos parâmetros k_p e a_p ou coeficientes da combinação convexa que são aplicados às estimativas $\hat{\theta}_{i,f}$, com $i = 1, \dots, N$, para formar uma estimativa de segundo nível do vetor de parâmetros θ_p^* no caso da planta SISO de ordem n
$\alpha_{i,f}^*$	Coeficientes da combinação convexa que quando aplicados às estimativas $\hat{k}_{i,f}$ e $\hat{a}_{i,f}$, com $i = 1, \dots, N$, formam k_p e a_p respectivamente no caso da planta de ordem 1 ou coeficientes da combinação convexa que quando aplicados às estimativas $\hat{\theta}_{i,f}$, com $i = 1, \dots, N$, formam θ_p^* no caso da planta SISO de ordem n
$\alpha_{i,sp}$	Coeficientes da combinação convexa que são aplicados às estimativas $\hat{k}_{i,sp}$ e $\hat{a}_{i,sp}$, com $i = 1, \dots, N$, para formar uma estimativa de segundo nível dos parâmetros k_p e a_p ou coeficientes da combinação convexa que são aplicados às estimativas $\hat{B}_{i,sp}$ e $\hat{A}_{i,sp}$, com $i = 1, \dots, N$, para formar uma estimativa de segundo nível dos parâmetros B_p e A_p no caso da planta de ordem n
$\alpha_{i,sp}^*$	Coeficientes da combinação convexa que quando aplicados às estimativas $\hat{k}_{i,sp}$ e $\hat{a}_{i,sp}$, com $i = 1, \dots, N$, formam k_p e a_p respectivamente no caso da planta de ordem 1 ou coeficientes da combinação convexa que quando aplicados às estimativas $\hat{B}_{i,sp}$ e $\hat{A}_{i,sp}$, com $i = 1, \dots, N$, formam B_p e A_p respectivamente no caso da planta de ordem n
α_{sp}	Vetor coluna formado pelos coeficientes $\alpha_{i,sp}$ em suas linhas, com $i = 1, \dots, N - 1$
α_{sp}^*	Vetor coluna formado pelos coeficientes $\alpha_{i,sp}^*$ em suas linhas, com $i = 1, \dots, N - 1$
$\bar{\alpha}_f$	Vetor coluna formado pelos coeficientes $\alpha_{i,f}$ em suas linhas, com $i = 1, \dots, N$
$\bar{\alpha}_f^*$	Vetor coluna formado pelos coeficientes $\alpha_{i,f}^*$ em suas linhas, com $i = 1, \dots, N$
$\bar{\alpha}_{sp}$	Vetor coluna formado pelos coeficientes $\alpha_{i,sp}$ em suas linhas, com $i = 1, \dots, N$
$\bar{\alpha}_{sp}^*$	Vetor coluna formado pelos coeficientes $\alpha_{i,sp}^*$ em suas linhas, com $i = 1, \dots, N$
$\beta_{i,f}$	Coeficientes de uma combinação convexa que são aplicados às estimativas $\hat{k}_{i,f}$ e $\hat{a}_{i,f}$, com $i = 1, \dots, N$ para formar estimativas virtuais $\hat{a}_{v,f}$ e $\hat{k}_{v,f}$ dos parâmetros ou coeficientes da combinação convexa que são aplicados às estimativas $\hat{\theta}_{i,f}$, com $i = 1, \dots, N$, para formar uma estimativa virtual do vetor de parâmetros θ_p^* no caso da planta SISO de ordem n
$\beta_{i,sp}$	Coeficientes de uma combinação convexa que são aplicados às estimativas $\hat{k}_{i,sp}$ e $\hat{a}_{i,sp}$, com $i = 1, \dots, N$ para formar estimativas virtuais $\hat{a}_{v,sp}$ e $\hat{k}_{v,sp}$ dos parâmetros ou coeficientes da combinação convexa que são aplicados às estimativas

	$\hat{B}_{i,sp}$ e $\hat{A}_{i,sp}$, com $i = 1, \dots, N$, para formar estimativas virtuais dos parâmetros B_p e A_p no caso da planta de ordem n
$\dot{\alpha}_f$	Lei adaptativa para atualização do vetor α_f
$\dot{\alpha}_{sp}$	Lei adaptativa para atualização do vetor α_{sp}
$\hat{A}_{n2,sp}$	Estimativa de segundo nível da matriz A_p da planta de ordem n usando como base modelos de identificação série-paralelo
$\hat{\theta}_{n2,f}$	Estimativa de Segundo Nível do parâmetro θ_p^* da planta SISO de ordem n usando como base Modelos de Identificação por Regressão Linear
$\hat{a}_{n2,f}$	Estimativa de segundo nível do parâmetro a_p da planta de ordem 1 usando como base modelos de identificação por regressão linear
$\hat{a}_{n2,sp}$	Estimativa de segundo nível do parâmetro a_p da planta de ordem 1 usando como base modelos de identificação série-paralelo
$\hat{b}_{n2,sp}$	Estimativa de segundo nível do vetor b_p da planta de ordem n usando como base modelos de identificação série-paralelo
$\hat{k}_{n2,f}$	Estimativa de segundo nível do parâmetro k_p da planta de ordem 1 usando como base modelos de identificação por regressão linear
$\hat{k}_{n2,sp}$	Estimativa de segundo nível do parâmetro k_p da planta de ordem 1 usando como base modelos de identificação série-paralelo
IMRAC	Indirect Model Reference Adaptive Control - Controle Adaptativo por Modelo de Referência Indireto
MMAC	Multiple Model Adaptive Control - Controle Adaptativo baseado em Múltiplos Modelos
MRAC	Model Reference Adaptive Control - Controle Adaptativo por Modelo de Referência
MRC	Model Reference Control - Controle por Modelo de Referência
PE	Persistently Exciting - Persistentemente Excitante
SISO	Single Input Single Output - Sistema com apenas uma variável de entrada e uma variável de saída

Capítulo 1

Introdução

1.1 Sistemas Lineares

Duas propriedades definem a linearidade de um sistema:

- Homogeneidade (ou escalamento): A entrada é proporcional à saída. Para um aumento (ou diminuição) no valor do sinal de entrada, há uma variação diretamente proporcional da variável de saída em regime permanente;
- Aditividade: Se a soma de 2 ou mais sinais atuam sobre a mesma entrada de um sistema linear, então o efeito total destes sinais sobre a saída pode ser determinado considerando cada um dos sinais independentemente e somando os resultados.

Um sistema linear obedece ao princípio da superposição ao exibir ambas as propriedades descritas acima. Os sistemas que não obedecem a estas propriedades são chamados sistemas não-lineares.

1.2 Sistemas de Controle

O controle automático representa uma forma de lidar com processos e sistemas. O controle automático visa fazer com que algum conjunto de variáveis de interesse do projetista se comporte dentro de certas especificações, através do ajuste automático de algum outro conjunto de variáveis. Variáveis de interesse podem ser das mais diversas como por exemplo medidas de fluxo sanguíneo em corações artificiais, medidas de tensão e corrente em motores de indução, medidas de posição e velocidade em drones, braços robóticos e esteiras e o nível de tanques e reservatórios. Assim, sua aplicação se dá em muitos campos, tais como nas ciências médicas, nas indústrias automotiva e aeroespacial e na fabricação de bens de consumo e componentes eletrônicos. A melhoria das técnicas de controle automático faz com que seja possível atingir desempenhos aceitáveis, em alguns casos ótimos, em uma classe cada vez maior de sistemas dinâmicos. Assim, o controle automático permite a substituição de mão de obra humana por máquinas na realização de tarefas repetitivas e também a realização de tarefas onde um operador humano não é capaz de responder em tempo hábil ou com a precisão e acurácia necessárias.

O controlador é um sistema projetado tal que, ao atuar em conjunto ao sistema dinâmico a ser controlado, o desempenho do sistema como um todo esteja dentro de certas especificações. Assim, mediante a aplicação de um ou mais sinais ao controlador, este deve produzir um ou mais sinais capazes de estimular a planta ou processo dinâmico tal que o conjunto de variáveis de interesse tenda cada uma para o valor desejado como valor final. Em geral, um sistema físico exibe dinâmica, isto é, o efeito de um estímulo sobre uma planta não aparece instantaneamente em cada variável de interesse. Um exemplo disto é que uma chaleira com água não ferve no instante que acendemos o fogão, devemos aguardar para que a temperatura da água(variável de interesse) chegue ao valor desejado. O intervalo de tempo entre o instante em que o sistema começa a receber o estímulo(calor) e o instante em que, na prática, todas as variáveis de interesse atingem seus valores finais e permanecem idênticos aos valores finais(ponto de fervura), é chamado de transitório. Quando todas as variáveis de interesse se aproximam dos valores iguais aos finais e neles permanecem, diz-se que o sistema se encontra em regime permanente. Um objetivo comum no projeto de controladores é o de atingir os valores desejados em regime permanente passando por um transitório que seja o mais rápido e menos oscilatório possível. De forma geral, os sistemas de controle podem ser classificados como:

- Sistema de Controle em Malha Aberta: No controle em malha aberta, o controlador é conectado em série com o processo a ser controlado. O controlador é alimentado com um conjunto de sinais de referência e produz um conjunto de sinais de controle tal que as saídas do processo tendam para as desejadas. Um sistema de controle em malha aberta se comporta da forma esperada somente se não ocorrer perturbação externa ou mudanças nos parâmetros do sistema. Se algum fator passa a atuar sobre o sistema suas saídas serão afetadas, mas os sinais de controle permanecem nos mesmos valores independente disto. Representamos um sistema de controle em malha aberta na Figura 1.1.
- Sistema de Controle em Malha Fechada: Um sistema de controle em malha fechada mede os valores de variáveis de interesse ou dos modos do sistema e compara estes valores com o comportamento desejado. Desta forma o controle em malha fechada busca corrigir os valores dos sinais de controle se algum fator passa a influir no sistema afetando as saídas ou modos internos. Representamos um sistema de controle em malha fechada na Figura 1.2.




Figura 1.1: Sistema de Controle em Malha Aberta




Figura 1.2: Sistema de Controle em Malha Fechada

1.3 Controle Clássico

Inicialmente a teoria de controle se desenvolveu no sentido de abordar o problema do controle de sistemas lineares devido ao fato de estes obedecerem ao princípio da superposição. A análise matemática destes sistemas se revelou mais amena. Assim, um arcabouço teórico foi desenvolvido em torno do controle linear de sistemas lineares. Um controlador linear tem seus parâmetros ajustados durante o projeto e constantes durante a operação. Há uma gama de métodos para o projeto de controladores lineares para este tipo de sistema tais como o lugar das raízes e os métodos por resposta frequencial. No entanto, é raro que um sistema físico obedeça estritamente ao princípio da superposição dentro de toda sua faixa de operação. De fato, a maioria absoluta dos sistemas físicos exhibe comportamento não-linear em algum grau. Para utilizar o arcabouço da teoria de controle de sistemas lineares, tipicamente o projetista se utiliza de modelos linearizados em torno do ponto de operação do sistema. No entanto, a medida que o sistema se afasta do ponto de operação o modelo linearizado deixa de ser válido e o controlador linear se torna incapaz de garantir as especificações sobre as variáveis de interesse, pois seus parâmetros são fixos e podem não ser adequados para lidar com o novo ponto de operação. De fato, sistemas lineares e não-lineares são qualitativamente diferentes e nem sempre é possível para um controlador linear lidar favoravelmente com não-linearidades. Diversos fenômenos que afetam sistemas não-lineares simplesmente não podem ocorrer em sistemas lineares. Um exemplo muito comum é a saturação: tipicamente a planta ou sistema de controle não pode produzir um sinal cujo módulo excede um determinado valor, devido à limitações físicas.

Além disto, o controle clássico aborda o projeto do controlador sob a hipótese de que os parâmetros que descrevem o sistema são constantes e conhecidos sem incertezas. Sistemas físicos tipicamente apresentam variação em seus parâmetros devido a desgaste, envelhecimento ou falhas. Além disso, normalmente os componentes de um sistema tem valores nominais que são obedecidos dentro de uma certa tolerância, como por exemplo resistores e capacitores. Na prática sempre há algum grau de incerteza acerca dos parâme-

tros do sistema. Finalmente, o controle clássico busca lidar com sistemas que dispõem de apenas uma variável de entrada e uma variável saída (Single Input Single Output - **SISO**). Muitos sistemas possuem um conjunto de mais de uma variável de saída ou de entrada, como é o caso de drones, que devem controlar elevação, velocidade, ângulos de rolagem, guinada e arfagem simultaneamente.

Assim, no sentido de superar estas limitações da teoria de controle clássica e abordar o projeto de controladores para sistemas cada vez mais complexos, a teoria de controle moderno desenvolve e apresenta técnicas de projeto de controladores não-lineares. Um exemplo de controlador não-linear é o controlador adaptativo.

1.4 Controle Adaptativo

No controle adaptativo, os parâmetros do controlador são ajustados de acordo com um mecanismo de estimação de parâmetros em tempo real. A partir de medidas de variáveis do sistema como por exemplo sinal de controle e sinal de saída ou modos internos do sistema é gerada uma lei de ajuste dos parâmetros. O processo de estimação executada concorrentemente com o controle torna o controlador um sistema não-linear. Devido a não-linearidade a análise dos sinais presentes no sistema em malha fechada se torna mais complexa. Este tipo de controle costuma apresentar bons resultados quando os parâmetros da planta são conhecidos com incertezas consideradas suficientemente pequenas e que variam mais lentamente do que o mecanismo de ajuste é capaz de ajustar os parâmetros do controlador. O motivo disto é que no controle adaptativo faz-se uso do princípio de equivalência à certeza. Assumimos que o processo de estimação faça com que o controlador busque se adaptar às circunstâncias de operação e tenda aos parâmetros que são adequados para aquelas condições de operação, atingindo um desempenho suficiente. Assim, o desempenho do controle adaptativo depende em parte da velocidade, precisão e acurácia com que os parâmetros do controlador podem ser estimados frente a cada situação específica. Na maior parte dos casos, quanto mais rápido, preciso e acurado é o processo de estimação de parâmetros, melhor o desempenho. O controle adaptativo tem duas estratégias principais, a direta e a indireta:

1.5 Controle Adaptativo Direto e Indireto

Como já mencionamos, um controlador adaptativo nada mais é do que um controlador cujos parâmetros são ajustados por um mecanismo de estimação. As duas estratégias principais são chamadas estratégia direta e indireta. Na estratégia direta os parâmetros do controlador são estimados. A planta é parametrizada em função dos parâmetros ideais do controlador, que são aqueles que seriam calculados por um projetista caso os parâmetros da planta fossem constantes e conhecidos sem incertezas. O erro da saída do sistema em relação ao comportamento desejado é avaliado e usado na lei de ajuste dos parâmetros do controlador. A vantagem do controle adaptativo direto é que a estrutura do controlador é

mais simples, em relação ao controle adaptativo indireto, o que facilita a implementação. Um exemplo de diagrama de blocos de um controlador adaptativo direto está na Figura 1.3.




Figura 1.3: Controlador Adaptativo Direto

Na abordagem indireta, um modelo de identificação do sistema é ajustado em tempo real de acordo com as informações provenientes da planta, tais como sinal de controle e saída ou modos internos. O objetivo do modelo de identificação é estimar os parâmetros da planta através de alguma lei de ajuste, tais como o método do gradiente ou método dos mínimos quadrados. Busca-se minimizar o erro de identificação entre a saída do modelo e a saída da planta. Considera-se que os parâmetros estimados da planta são os parâmetros verdadeiros e estes parâmetros são usados para realizar o cálculo dos parâmetros do controlador. O controle adaptativo indireto sofre a desvantagem de se tratar de uma estratégia mais complexa, no entanto é possível utilizar o conhecimento prévio sobre os parâmetros da planta mais facilmente para inicializar os parâmetros do modelo de identificação. Além disso há uma separação clara entre o processo de estimação dos parâmetros da planta e o ajuste dos parâmetros do controlador, que torna o entendimento da estratégia indireta mais intuitivo. Um exemplo de diagrama de blocos de um controlador adaptativo indireto está na Figura 1.4.




Figura 1.4: Controlador Adaptativo Indireto

1.6 Modelos de Identificação

Como vimos, o controle adaptativo indireto necessita ajustar os parâmetros de um modelo de identificação da planta em tempo real. Estes parâmetros são utilizados para calcular os parâmetros do controlador. Um modelo de identificação é um sistema virtual que buscamos tornar equivalente a alguma parametrização válida da planta. Para tanto assumimos conhecer a forma da função de transferência da planta ou a forma de sua representação em espaço de estados e usamos estas informações na criação do modelo de identificação.

O modelo de identificação mais intuitivo de um sistema linear é o modelo paralelo. No modelo paralelo criamos uma equação diferencial com a mesma estrutura da equação diferencial que representa o sistema linear que buscamos identificar e avaliamos a diferença entre a saída de nosso modelo de identificação e a saída do sistema para realizar o ajuste dos parâmetros do modelo de identificação. Apesar de sua simplicidade, a estabilidade do modelo paralelo depende dos parâmetros da planta, o que limita sua aplicação. Um diagrama de blocos do modelo de identificação paralelo se encontra disponível na Figura 1.5.




Figura 1.5: Modelo de Identificação Paralelo

Outra forma de modelo de identificação é o chamado modelo série-paralelo. Cria-se uma equação diferencial com estrutura similar à da planta, porém no modelo série-paralelo o modelo de identificação é alimentado com a saída da planta, ou equivalentemente com o erro de identificação. Isto permite atrelar a estabilidade deste modelo de identificação a um parâmetro de projeto A_m . Isto faz com que este tipo de modelo possa ser aplicado a qualquer tipo de planta, desde que o projetista tenha informações suficientes para escolher A_m de forma adequada e seja capaz de estabilizar o sistema através de uma ação de controle. Um diagrama de blocos do modelo de identificação série-paralelo se encontra disponível na Figura 1.6.




Figura 1.6: Modelo de Identificação Série-Paralelo

Além destes, há o modelo de identificação por regressão linear. Neste caso buscamos fazer com que o sinal de saída do modelo de identificação seja equivalente ao sinal de saída da planta filtrado por uma função de transferência específica. Esta filtragem é feita pois o sinal de saída da planta filtrado pode ser parametrizado como uma combinação linear dos componentes de um vetor, chamado vetor regressor. O vetor regressor pode também ser gerado por filtragem dos sinais de saída e entrada da planta. Os coeficientes da combinação linear são os coeficientes dos polinômios do numerador e denominador

da função de transferência da planta. Assim, no modelo de identificação por regressão linear estimamos diretamente os coeficientes dos polinômios da função de transferência da planta. A vantagem do modelo de identificação por regressão linear é similar à do modelo série-paralelo, desde que seja possível estabilizar o sistema através de uma ação de controle o modelo de identificação será estável. Um diagrama de blocos do modelo de identificação por regressão linear se encontra disponível na Figura 1.7.




Figura 1.7: Modelo de Identificação por Regressão Linear

1.7 Controle Adaptativo por Modelo de Referência

Como mencionamos, o controle busca garantir especificações sobre um conjunto de variáveis de interesse através do ajuste de outro conjunto de variáveis. Estas especificações podem ser traduzidas na forma de um modelo de referência, um sistema que se comporta da forma desejada em malha aberta ao ser alimentado por um sinal de referência. Assim, o objetivo do controle por modelo de referência é o de projetar um controlador que faça com que o sistema de controle da planta em malha fechada com o controlador tenha uma função de transferência em malha fechada equivalente à do modelo de referência em malha aberta. Assim, o modelo de referência especifica a trajetória que as variáveis de interesse devem seguir durante o transitório e os seus valores em regime permanente. Para tanto, o controlador é projetado para atingir a chamada condição de **matching**, onde os zeros da planta são cancelados por polos do controlador e substituídos pelos zeros do modelo de referência e os polos da função de transferência em malha fechada se tornam os polos da função de transferência do modelo de referência.

Devido ao cancelamento dos zeros da planta, o controle por modelo de referência (**MRC**) sofre da limitação de ser aplicável apenas à plantas de fase mínima, isto é, cujos zeros se encontram no semi plano esquerdo aberto do plano complexo. Isto ocorre pois, na prática, o cancelamento de raízes no semi-plano direito aberto está sempre sujeito a erro numérico, cujo resíduo leva à instabilidade.

Uma das estratégias de controle que pode ser empregada dentro do paradigma do controle adaptativo é o controle adaptativo por modelo de referência (**MRAC**). Usando as

equações obtidas a partir da condição de matching podemos estimar, direta ou indiretamente, os parâmetros do controlador.

1.8 Controle Adaptativo baseado em Múltiplos Modelos de Identificação

Como já dissemos, o controle adaptativo costuma apresentar bons resultados quando a incerteza é suficientemente pequena e o mecanismo de estimação é suficientemente rápido. O controle adaptativo baseado em múltiplos modelos busca lidar com incertezas maiores acerca dos parâmetros da planta. Nos anos 90 (Narendra & Balakrishnan 1994, Narendra et al. 1995, Narendra & Balakrishnan 1997), foram feitas propostas de controle adaptativo baseado em múltiplos modelos através do chaveamento entre modelos de identificação inicializados com parâmetros diferentes, com alguns modelos tendo parâmetros fixos e outros ajustados por leis integrais. Apesar de exibir bons resultados de simulação, esta técnica apresenta uma limitação pois se baseia na ideia de que os parâmetros de pelo menos um modelo devem estar localizados suficientemente próximos dos parâmetros da planta. Isto faz com que seja necessário utilizar um grande número de modelos para atingir uma boa performance, dependendo exponencialmente do grau da planta. Assim, plantas de maior grau necessitariam de uma quantidade proibitiva de modelos inicializados de tal forma a garantir que os parâmetros da planta estivessem em uma vizinhança pequena de algum deles.

Mais recentemente no entanto, em (Han & Narendra 2011), foi introduzido um novo conceito ao controle adaptativo baseado em múltiplos modelos de identificação conhecido como adaptação de segundo nível. Utilizando a informação combinada de cada um dos modelos é formada uma combinação dos parâmetros de múltiplos modelos de identificação, que é utilizada como estimativa dos parâmetros da planta. Ao invés de necessitar de um número de modelos que cresce exponencialmente com o grau da planta para garantir um bom desempenho, a adaptação de segundo nível necessita de um número que cresce linearmente.

1.9 Modelos Virtuais por Combinação Convexa

Em (Narendra & Han 2010) foi estabelecido, para um caso particular, que um modelo de identificação virtual cujos parâmetros são formados por uma combinação convexa dos parâmetros de múltiplos modelos de identificação se comporta, dentro de certas circunstâncias, identicamente a um modelo de identificação inicializado com os mesmos valores de parâmetros. Assim, uma combinação convexa dos parâmetros de múltiplos modelos de identificação pode ser utilizada como estimativa dos parâmetros da planta. De fato, se os parâmetros da planta pertencem ao interior ou fronteira de um fecho convexo formado pe-

los parâmetros dos modelos de identificação então os parâmetros da planta permanecerão na fronteira ou interior deste fecho convexo, independentemente do ajuste dos parâmetros dos modelos de identificação. Esta propriedade pode então ser explorada, pois além do ajuste dos parâmetros dos modelos de identificação podemos, concorrentemente, estimar os coeficientes da combinação convexa referente aos parâmetros verdadeiros da planta.

1.10 Adaptação de Segundo Nível

Assim, como um segundo nível de estimação, ou segunda camada de adaptação, busca-se estimar os coeficientes de uma combinação convexa de múltiplos modelos de identificação para que esta combinação convexa tenda aos valores verdadeiros dos parâmetros da planta. Ao mesmo tempo os parâmetros dos modelos de identificação também são ajustados. Passamos a chamar os modelos de identificação de modelos de primeiro nível. Devido à propriedade do fecho convexo discutida anteriormente é possível obter uma lei de ajuste para as estimativas dos coeficientes da combinação convexa, baseada nos erros de identificação dos modelos. Assim, a adaptação de segundo nível entrega as estimativas dos parâmetros da planta como combinações convexas variantes no tempo dos parâmetros de múltiplos modelos de identificação. A adaptação de segundo nível como método de estimação de parâmetros é muito mais rápida em atingir os parâmetros verdadeiros que os métodos de estimação convencionais. Isto se deve ao fato de que as informações provenientes de múltiplas fontes são utilizadas e combinadas.

Este trabalho tem como um de seus objetivos apresentar a adaptação de segundo nível, começando pela caracterização de modelos de identificação de primeiro nível e suas leis de ajuste, passando à investigação sobre a propriedade do fecho convexo para estes modelos de identificação e finalmente à aplicação do conceito de adaptação de segundo nível como método de estimação de parâmetros. Adicionalmente, realizamos uma modificação na lei integral de ajuste da adaptação de segundo nível e que chamamos adaptação de segundo nível com fator de esquecimento, que levou a uma convergência mais rápida e suave dos parâmetros para seus valores corretos em estudos de simulação.

Finalmente, neste trabalho, aplicamos o conceito de adaptação de segundo nível como técnica de estimação de parâmetros ao controlador adaptativo por modelo de referência indireto. Substituímos as estimativas dos parâmetros da planta que seriam obtidas pelo método do gradiente normalizado por combinações convexas dos parâmetros de múltiplos modelos de identificação por regressão linear baseados no método do gradiente normalizado. Um diagrama de blocos deste conceito está disponível na Figura 1.8.




Figura 1.8: Controlador Adaptativo Indireto de Segundo Nível

1.11 Estrutura do Trabalho

Este trabalho está organizado como segue:

O capítulo 1 contém esta introdução destinada a esclarecer o objetivo e tema deste trabalho.

O capítulo 2 contém o caso da adaptação de segundo nível como método de estimação de parâmetros aplicada a uma planta de grau 1 e grau relativo unitário. Primeiramente introduzimos cada um dos modelos de identificação utilizados, mostrando as leis de ajuste para seus parâmetros e demonstrando a estabilidade do processo de estimação para cada um deles. A seguir discutimos a propriedade do fecho convexo no caso do modelo série-paralelo e modelo por regressão linear e demonstramos como aplicar o conceito de adaptação de segundo nível. Demonstramos a estabilidade do estimador resultante. Disponibilizamos os algoritmos de forma compacta como um resumo no final do capítulo e realizamos a aplicação de cada um destes conceitos em estudos de simulação de forma que o leitor possa comparar os resultados.

O capítulo 3 contém o caso da adaptação de segundo nível como método de estimação de parâmetros para uma planta de grau n e grau relativo unitário. No caso **SISO** utilizamos o modelo por regressão linear. No caso em que o vetor de estado da planta está disponível para medição utilizamos o modelo série-paralelo. Novamente introduzimos cada um dos modelos de identificação utilizados, mostramos as leis de ajuste para seus parâmetros e demonstramos a estabilidade do processo de estimação para cada um dos modelos. Discutimos a propriedade do fecho convexo no caso do modelo série-paralelo e modelo por regressão linear e aplicamos o conceito de adaptação de segundo nível. Demonstramos a estabilidade do estimador resultante. Disponibilizamos os algoritmos de forma compacta como um resumo no final do capítulo e por fim, aplicamos cada um dos conceitos mostrados em estudos de simulação comparativos.

No capítulo 4 mostramos a condição de matching para um controlador por modelo de referência indireto (**IMRAC**) para uma planta de grau n e grau relativo unitário. A partir da condição de matching e das estimativas dos parâmetros da planta os parâmetros do controlador são calculados. A estabilidade do **IMRAC** com adaptação de segundo nível é demonstrada. Finalmente, estudos de simulação são realizados comparando o método do gradiente, adaptação de segundo nível e a adaptação de segundo nível com fator de esquecimento.

No capítulo 5 concluímos discutindo o que foi feito e perspectivas futuras.

Capítulo 2

Estimação de Parâmetros, Ordem 1

Ao modelar um sistema dinâmico como um sistema linear descrito por uma função de transferência ou por uma equação diferencial em espaço de estado é comum lidar com incertezas nos coeficientes dos polinômios do numerador e denominador desta função ou nos elementos das matrizes (A,B,C,D) do espaço de estado, as chamadas incertezas paramétricas. As incertezas paramétricas têm vários fatores. Entre eles a falta de conhecimento completo sobre componentes físicos, cujos valores tipicamente se encontram dentro de uma certa tolerância como resistores, capacitores, amortecedores e indutores. Aproximações na modelagem como por exemplo sistemas cujo comportamento possui não-linearidades. Variações dos parâmetros devido ao desgaste ou envelhecimento como por exemplo o óleo de um motor de automóvel cuja viscosidade aumenta com o tempo ou uma engrenagem cujos dentes se desgastam com o uso. E mesmo devido a falhas de componentes como um transformador danificado por sobretensão na linha de transmissão.

Uma forma de atacar as incertezas paramétricas de modo a melhorar o conhecimento sobre a dinâmica atual do sistema é através da estimação dos parâmetros em tempo real. Um conhecimento mais preciso dos parâmetros pode permitir decisões melhores acerca de qual ação de controle tomar. Através de um modelo de estimação do sistema estudado, gera-se a diferença entre o sinal(ou sinais) de saída do sistema e o sinal(ou sinais) de saída do modelo de estimação, o chamado erro de identificação. Este erro pode ser empregado para gerar leis integrais para atualizar as estimativas. A atualização das estimativas faz com que as estimativas estejam mais próximas dos valores corretos do que as estimativas iniciais quando o sistema atinge o regime permanente. Além disso o erro de identificação tende a um valor nulo. Quando um sistema linear é sujeito a um sinal de entrada com a característica de persistência de excitação existe garantia de convergência das estimativas dos parâmetros para seus valores corretos (Boyd & Sastry 1986, NARENDRA & ANNASWAMY 1987, Bitmead 1984). O modelo de estimação se torna portanto um modelo de identificação pois eventualmente seus parâmetros serão idênticos aos parâmetros do sistema linear e não apenas estimativas próximas. Um exemplo de sinal persistentemente excitante é um sinal senoidal contendo pelo menos uma frequência para uma planta de ordem 1.

Neste capítulo faremos um passo-a-passo, de diferentes modelos de identificação que

podem ser usados para estimar os parâmetros da função de transferência de uma planta de ordem 1 e grau relativo 1. Apresentamos primeiramente o caso mais simples por motivos didáticos, para que o leitor possa se familiarizar com as técnicas e conceitos discutidos, da forma como é feito na literatura como por exemplo em (Narendra & Annaswamy 1989, Ioannou & Sun 1996, Tao 2003). Usaremos sinais de controle com persistência de excitação de ordem 1 para atingir o objetivo de identificação dos parâmetros. Começamos descrevendo os modelos cujas estimativas dos parâmetros são atualizadas por leis integrais: o Modelo Paralelo, o Modelo Série-Paralelo e o Modelo por Regressão Linear. Os dois últimos sendo chamados Modelos de Identificação de Primeiro Nível. Estas descrições servem como uma introdução para que se possa discutir a técnica de estimação chamada Adaptação de Segundo Nível. A Adaptação de Segundo Nível foi introduzida por Han e Narendra em (Han & Narendra 2011), com base em propriedades mostradas em (Han & Narendra 2010), e discutida em (Han & Narendra 2012, Narendra et al. 2012, Narendra et al. 2014), com resultados estendidos para o caso SISO em (Narendra et al. 2015). Na Adaptação de Segundo Nível os coeficientes de uma combinação linear convexa das estimativas dos parâmetros da planta vindas de múltiplos modelos de identificação de primeiro nível são atualizados por leis integrais como uma segunda camada de adaptação. Isto traz uma vantagem em termos de rapidez de convergência dos parâmetros, como foi extensivamente demonstrado nos trabalhos citados acima e se deve ao fato de que a informação proveniente dos múltiplos modelos estar sendo combinada. Após a descrição de cada um dos modelos e técnicas de identificação fazemos estudos de simulação usando cada uma destas técnicas discutindo seus resultados. Também colocamos os algoritmos utilizados no final do capítulo.

2.1 Modelos de Identificação Convencionais

2.1.1 Modelo de Identificação Paralelo

Considere a planta estável e invariante no tempo:

$$\Sigma_p : G(s) = \frac{y(s)}{u(s)} = \frac{k_p}{s + a_p} \quad (2.1)$$

em que $k_p \in [k_p^+ \ k_p^-]$, $k_p^+ > 0$ e $k_p^- > 0$ ou $k_p^+ < 0$ e $k_p^- < 0$ e $a_p \in [a_p^+ \ a_p^-]$, $a_p^+ > 0$ e $a_p^- > 0$ e os limitantes $k_p^+, k_p^-, a_p^+, a_p^-$ são conhecidos, y é o sinal de saída da planta e u é o sinal de entrada. E o modelo de identificação:

$$\Sigma_{1,p} : G_{1,p}(s) = \frac{\hat{y}_{1,p}(s)}{u(s)} = \frac{\hat{k}_{1,p}}{s + \hat{a}_{1,p}} \quad (2.2)$$

em que $\hat{y}_{1,p}(s)$ é o sinal de saída do modelo de identificação. Podemos escrever na forma

de equações diferenciais:

$$\begin{aligned}\Sigma_p : \dot{y} &= -a_p y + k_p u \\ \Sigma_{1,p} : \dot{\hat{y}}_{1,p} &= -\hat{a}_{1,p} \hat{y}_{1,p} + \hat{k}_{1,p} u\end{aligned}\quad (2.3)$$

e definimos então o erro de identificação:

$$e_{1,p} \triangleq \hat{y}_{1,p} - y \quad (2.4)$$

e obtemos sua dinâmica:

$$\dot{e}_{1,p} = \dot{\hat{y}}_{1,p} - \dot{y} = -\hat{a}_{1,p} \hat{y}_{1,p} + \hat{k}_{1,p} u - (-a_p y + k_p u)$$

definimos os erros paramétricos:

$$\begin{aligned}\tilde{a}_{1,p} &\triangleq \hat{a}_{1,p} - a_p \\ \tilde{k}_{1,p} &\triangleq \hat{k}_{1,p} - k_p\end{aligned}\quad (2.5)$$

e a dinâmica do erro de identificação $e_{1,p}$ pode ser escrita como:

$$\dot{e}_{1,p} = -a_p e_{1,p} - \tilde{a}_{1,p} \hat{y}_{1,p} + \tilde{k}_{1,p} u \quad (2.6)$$

então usamos a seguinte função definida positiva como uma candidata a função de Lyapunov:

$$V(e_{1,p}, \tilde{k}_{1,p}, \tilde{a}_{1,p}) = \frac{1}{2}(e_{1,p}^2 + \tilde{k}_{1,p}^2 + \tilde{a}_{1,p}^2) \quad (2.7)$$

e derivando ao longo das trajetórias obtemos:

$$\dot{V} = e_{1,p} \dot{e}_{1,p} + \tilde{k}_{1,p} \dot{\tilde{k}}_{1,p} + \tilde{a}_{1,p} \dot{\tilde{a}}_{1,p}$$

substituindo $\dot{e}_{1,p}$ por 2.6 obtemos:

$$\dot{V} = -a_p e_{1,p}^2 - \tilde{a}_{1,p} e_{1,p} \hat{y}_{1,p} + \tilde{k}_{1,p} e_{1,p} u + \tilde{k}_{1,p} \dot{\tilde{k}}_{1,p} + \tilde{a}_{1,p} \dot{\tilde{a}}_{1,p} \quad (2.8)$$

e como a planta é invariante no tempo temos:

$$\begin{aligned}\tilde{a}_{1,p} &= \hat{a}_{1,p} - a_p \rightarrow \dot{\tilde{a}}_{1,p} = \dot{\hat{a}}_{1,p} - \overset{0}{\cancel{\dot{a}_p}} = \dot{\hat{a}}_{1,p} \\ \tilde{k}_{1,p} &= \hat{k}_{1,p} - k_p \rightarrow \dot{\tilde{k}}_{1,p} = \dot{\hat{k}}_{1,p} - \overset{0}{\cancel{\dot{k}_p}} = \dot{\hat{k}}_{1,p}\end{aligned}$$

e portanto podemos escolher leis adaptativas para atualizar as estimativas $\hat{k}_{1,p}$ e $\hat{a}_{1,p}$ para cancelar os termos de sinal indefinido em $\dot{V}$. Se escolhermos:

$$\begin{aligned}\dot{\hat{a}}_{1,p} &= e_{1,p} \hat{y}_{1,p} \\ \dot{\hat{k}}_{1,p} &= -e_{1,p} u\end{aligned}\quad (2.9)$$

teremos então que:

$$\dot{V}(e_{1,p}, \tilde{k}_{1,p}, \tilde{a}_{1,p}) = -a_p e_{1,p}^2 \quad (2.10)$$

$\dot{V}$ é semi-definida negativa e portanto V não pode crescer, o que implica em:

$$\begin{aligned} e_{1,p} &\in \mathcal{L}_\infty \\ \tilde{a}_{1,p} &\in \mathcal{L}_\infty \rightarrow \hat{a}_{1,p} \in \mathcal{L}_\infty \\ \tilde{k}_{1,p} &\in \mathcal{L}_\infty \rightarrow \hat{k}_{1,p} \in \mathcal{L}_\infty \end{aligned}$$

o sinal de controle u é escolhido tal que:

$$u \in \mathcal{L}_\infty$$

e como a planta é estável temos que:

$$y \in \mathcal{L}_\infty$$

como $e_{1,p} = \hat{y}_{1,p} - y \in \mathcal{L}_\infty$ e $y \in \mathcal{L}_\infty$, temos que:

$$\begin{aligned} \hat{y}_{1,p} &\in \mathcal{L}_\infty \\ \dot{e}_{1,p} &\in \mathcal{L}_\infty \end{aligned}$$

e finalmente, usando 2.10:

$$\begin{aligned} e_{1,p}^2 &= -\frac{1}{a_p} \dot{V} \\ \int_0^\infty e_{1,p}^2 &= -\frac{1}{a_p} \int_0^\infty \dot{V} \\ \int_0^\infty e_{1,p}^2 &= -\frac{1}{a_p} (V(\infty) - V(0)) \end{aligned}$$

portanto:

$$e_{1,p} \in \mathcal{L}_2$$

usando o lema de Barbalat, como $e_{1,p}$ é uniformemente limitado, tem norma $\mathcal{L}_2$ limitada e sua derivada é uniformemente limitada temos que:

$$\lim_{t \rightarrow \infty} e_{1,p} = 0$$

adicionalmente, quando o sinal de controle u for persistentemente excitante, teremos que $e_{1,p} = 0$ para todo tempo $t > t_0$ sse $\tilde{a}_{1,p} = 0$ e $\tilde{k}_{1,p} = 0$ e as estimativas $\hat{a}_{1,p}$ e $\hat{k}_{1,p}$ tendem aos valores corretos a_p e k_p respectivamente, para $t \rightarrow \infty$. É importante notar que usando o modelo paralelo o valor de $\dot{V}$ depende de a_p que é um parâmetro da planta. Portanto a velocidade de convergência de $e_{1,p}$ para 0 depende de uma característica da planta.

2.1.2 Modelo de Identificação Série-Paralelo

Seja, novamente, a planta estável como em 2.1:

$$\Sigma_p : G(s) = \frac{y(s)}{u(s)} = \frac{k_p}{s + a_p}$$

colocando na forma de equação diferencial podemos escrever:

$$\begin{aligned}\dot{y} &= -a_p y + k_p u = -a_p y + a_m y - a_m y + k_p u \\ \dot{y} + a_m y &= -a_p y + a_m y + k_p u\end{aligned}$$

então, um Modelo de Identificação pode ser criado a partir da equação acima, substituindo y por uma estimativa de y no lado esquerdo da equação:

$$\Sigma_{1,sp} : \dot{\hat{y}}_{1,sp} + a_m \hat{y}_{1,sp} = -\hat{a}_{1,sp} y + a_m y + \hat{k}_{1,sp} u$$

tal que:

$$\Sigma_{1,sp} : \dot{\hat{y}}_{1,sp} = -a_m \hat{y}_{1,sp} - \hat{a}_{1,sp} y + a_m y + \hat{k}_{1,sp} u \quad (2.11)$$

definimos o erro de identificação:

$$e_{1,sp} \triangleq \hat{y}_{1,sp} - y \quad (2.12)$$

e sua dinâmica é da forma:

$$\dot{e}_{1,sp} = \dot{\hat{y}}_{1,sp} - \dot{y} = -a_m \hat{y}_{1,sp} - \hat{a}_{1,sp} y + a_m y + \hat{k}_{1,sp} u + a_p y - k_p u$$

definimos os erros paramétricos:

$$\begin{aligned}\tilde{a}_{1,sp} &\triangleq \hat{a}_{1,sp} - a_p \\ \tilde{k}_{1,sp} &\triangleq \hat{k}_{1,sp} - k_p\end{aligned} \quad (2.13)$$

e escrevemos $\dot{e}_{1,sp}$ da seguinte forma:

$$\dot{e}_{1,sp} = -a_m e_{1,sp} - \tilde{a}_{1,sp} y + \tilde{k}_{1,sp} u \quad (2.14)$$

então, a partir de uma candidata a função de Lyapunov definida positiva da forma:

$$V(e_{1,sp}, \tilde{a}_{1,sp}, \tilde{k}_{1,sp}) = \frac{1}{2}(e_{1,sp}^2 + \tilde{a}_{1,sp}^2 + \tilde{k}_{1,sp}^2) \quad (2.15)$$

derivamos ao longo das trajetórias:

$$\begin{aligned}\dot{V} &= e_{1,sp} \dot{e}_{1,sp} + \tilde{a}_{1,sp} \dot{\tilde{a}}_{1,sp} + \tilde{k}_{1,sp} \dot{\tilde{k}}_{1,sp} \\ &= -a_m e_{1,sp}^2 - \tilde{a}_{1,sp} e_{1,sp} y + \tilde{k}_{1,sp} e_{1,sp} u + \tilde{a}_{1,sp} \dot{\tilde{a}}_{1,sp} + \tilde{k}_{1,sp} \dot{\tilde{k}}_{1,sp}\end{aligned}$$

e como a planta é invariante no tempo:

$$\begin{aligned}\tilde{a}_{1,sp} &= \hat{a}_{1,sp} - a_p \rightarrow \dot{\tilde{a}}_{1,sp} = \dot{\hat{a}}_{1,sp} - \overset{0}{\cancel{\dot{a}_p}} = \dot{\hat{a}}_{1,sp} \\ \tilde{k}_{1,sp} &= \hat{k}_{1,sp} - k_p \rightarrow \dot{\tilde{k}}_{1,sp} = \dot{\hat{k}}_{1,sp} - \overset{0}{\cancel{\dot{k}_p}} = \dot{\hat{k}}_{1,sp}\end{aligned}$$

podemos então escolher leis integrais para atualizar $\hat{a}_{1,sp}$ e $\hat{k}_{1,sp}$ tal que os termos de sinal indefinido em $\dot{V}$ sejam anulados:

$$\begin{aligned}\dot{\hat{a}}_{1,sp} &= e_{1,sp}y \\ \dot{\hat{k}}_{1,sp} &= -e_{1,sp}u\end{aligned}\tag{2.16}$$

e temos:

$$\dot{V}(e_{1,sp}, \tilde{a}_{1,sp}, \tilde{k}_{1,sp}) = -a_m e_{1,sp}^2\tag{2.17}$$

$\dot{V}$ é semi-definida negativa e portanto V não pode crescer, o que implica em:

$$\begin{aligned}e_{1,sp} &\in \mathcal{L}_\infty \\ \tilde{a}_{1,sp} &\in \mathcal{L}_\infty \rightarrow \hat{a}_{1,sp} \in \mathcal{L}_\infty \\ \tilde{k}_{1,sp} &\in \mathcal{L}_\infty \rightarrow \hat{k}_{1,sp} \in \mathcal{L}_\infty\end{aligned}$$

o sinal de controle u é escolhido tal que:

$$u \in \mathcal{L}_\infty$$

e como a planta é estável temos que:

$$\begin{aligned}y &\in \mathcal{L}_\infty \\ \dot{e}_{1,sp} &\in \mathcal{L}_\infty\end{aligned}$$

como $e_{1,sp} = \hat{y}_{1,sp} - y \in \mathcal{L}_\infty$ e $y \in \mathcal{L}_\infty$, temos que:

$$\hat{y}_{1,sp} \in \mathcal{L}_\infty$$

e finalmente, manipulando a equação para $\dot{V}$:

$$\begin{aligned}e_{1,sp}^2 &= -\frac{1}{a_m} \dot{V} \\ \int_0^\infty e_{1,sp}^2 &= -\frac{1}{a_m} \int_0^\infty \dot{V} \\ \int_0^\infty e_{1,sp}^2 &= -\frac{1}{a_m} (V(\infty) - V(0))\end{aligned}$$

portanto:

$$e_{1,sp} \in \mathcal{L}_2$$

usando o lema de Barbalat, como $e_{1,sp}$ é uniformemente limitado, tem norma $\mathcal{L}_2$ limitada e sua derivada é uniformemente limitada temos que:

$$\lim_{t \rightarrow \infty} e_{1,sp} = 0$$

adicionalmente, quando o sinal de controle u for persistentemente excitante, teremos que $e_{1,sp} = 0$ para todo tempo $t > t_0$ sse $\tilde{a}_{1,sp} = 0$ e $\tilde{k}_{1,sp} = 0$ e as estimativas $\hat{a}_{1,sp}$ e $\hat{k}_{1,sp}$ tendem aos valores corretos a_p e k_p respectivamente, para $t \rightarrow \infty$. É importante notar que usando o modelo série-paralelo o valor de $\dot{V}$ depende de a_m que é um parâmetro de projeto do estimador. Portanto a velocidade de convergência de $e_{1,sp}$ para 0 depende de um parâmetro de projeto.

2.1.3 Modelo de Identificação por Regressão Linear

Novamente, seja a planta estável:

$$\Sigma_p : G(s) = \frac{y(s)}{u(s)} = \frac{k_p}{s + a_p}$$

manipulando a função de transferência podemos escrever, no domínio da frequência:

$$sy(s) = -a_p y(s) + k_p u(s) \quad (2.18)$$

e definindo o seguinte polinômio:

$$\Lambda(s) \triangleq s + \lambda \quad (2.19)$$

com $\lambda > 0$, escalar, escrevemos:

$$\frac{s}{\Lambda(s)} y(s) = -a_p \frac{1}{\Lambda(s)} y(s) + k_p \frac{1}{\Lambda(s)} u(s) \quad (2.20)$$

definimos:

$$\begin{aligned} z(s) &\triangleq \frac{s}{\Lambda(s)} y(s) \\ \phi(s) &\triangleq \begin{bmatrix} \frac{-y(s)}{\Lambda(s)} & \frac{u(s)}{\Lambda(s)} \end{bmatrix}^T \end{aligned} \quad (2.21)$$

para gerar ϕ filtramos $y(t)$ e $u(t)$:

$$\begin{aligned} \dot{\phi}_1 &= -\lambda \phi_1 + y \\ \dot{\phi}_2 &= -\lambda \phi_2 + u \\ \phi &= [\phi_1 \quad \phi_2]^T \end{aligned} \quad (2.22)$$

e temos:

$$z(s) = [a_p \quad k_p] \phi \quad (2.23)$$

z pode ser gerado da seguinte forma:

$$z = y - \lambda \phi_1 \quad (2.24)$$

podemos criar um modelo de identificação a partir de uma combinação linear dos sinais componentes do vetor ϕ como:

$$\Sigma_{1,f} : \hat{z}_1 = [\hat{a}_{1,f} \quad \hat{k}_{1,f}] \phi \quad (2.25)$$

e definir um erro de identificação:

$$e_{1,f} \triangleq \hat{z}_1 - z \quad (2.26)$$

o sinal filtrado da saída da planta e seu modelo de identificação podem ser representados pelas equações diferenciais:

$$\begin{aligned} \dot{z} &= -\lambda z - a_p y + k_p u \\ \dot{\hat{z}}_1 &= -\lambda \hat{z}_1 - \hat{a}_{1,f} y + \hat{k}_{1,f} u - \hat{a}_{1,f} \phi_1 + \hat{k}_{1,f} \phi_2 \end{aligned} \quad (2.27)$$

e a dinâmica de $e_{1,f}$ é dada por:

$$\dot{e}_{1,f} = -\lambda \hat{z}_1 - \hat{a}_{1,f} y + \hat{k}_{1,f} u + \lambda z + a_p y - k_p u - \hat{a}_{1,f} \phi_1 + \hat{k}_{1,f} \phi_2$$

definimos os erros paramétricos:

$$\begin{aligned} \tilde{a}_{1,f} &\triangleq \hat{a}_{1,f} - a_p \\ \tilde{k}_{1,f} &\triangleq \hat{k}_{1,f} - k_p \end{aligned} \quad (2.28)$$

tal que:

$$\dot{e}_{1,f} = -\lambda e_{1,f} - \tilde{a}_{1,f} y + \tilde{k}_{1,f} u - \hat{a}_{1,f} \phi_1 + \hat{k}_{1,f} \phi_2 \quad (2.29)$$

então, a partir de uma candidata a função de Lyapunov definida positiva da forma:

$$V(e_{1,f}, \tilde{a}_{1,f}, \tilde{k}_{1,f}) = \frac{1}{2} (e_{1,f}^2 + \tilde{a}_{1,f}^2 + \tilde{k}_{1,f}^2) \quad (2.30)$$

derivamos ao longo das trajetórias:

$$\begin{aligned} \dot{V} &= e_{1,f} \dot{e}_{1,f} + \tilde{a}_{1,f} \dot{\tilde{a}}_{1,f} + \tilde{k}_{1,f} \dot{\tilde{k}}_{1,f} \\ &= -\lambda e_{1,f}^2 - \tilde{a}_{1,f} e_{1,f} y + \tilde{k}_{1,f} e_{1,f} u + \tilde{a}_{1,f} \dot{\tilde{a}}_{1,f} + \tilde{k}_{1,f} \dot{\tilde{k}}_{1,f} - \hat{a}_{1,f} e_{1,f} \phi_1 + \hat{k}_{1,f} e_{1,f} \phi_2 \end{aligned}$$

e como a planta é invariante no tempo:

$$\begin{aligned} \tilde{a}_{1,f} &= \hat{a}_{1,f} - a_p \rightarrow \dot{\tilde{a}}_{1,f} = \dot{\hat{a}}_{1,f} - \overset{0}{\dot{a}_p} = \dot{\hat{a}}_{1,f} \\ \tilde{k}_{1,f} &= \hat{k}_{1,f} - k_p \rightarrow \dot{\tilde{k}}_{1,f} = \dot{\hat{k}}_{1,f} - \overset{0}{\dot{k}_p} = \dot{\hat{k}}_{1,f} \end{aligned}$$

podemos então escolher leis integrais para atualizar $\hat{a}_{1,f}$ e $\hat{k}_{1,f}$ da seguinte forma:

$$\begin{aligned}\dot{\hat{a}}_{1,f} &= e_{1,f}y \\ \dot{\hat{k}}_{1,f} &= -e_{1,f}u\end{aligned}\tag{2.31}$$

e temos:

$$\dot{V}(e_{1,f}, \tilde{a}_{1,f}, \tilde{k}_{1,f}) = -(\lambda + y\phi_1 + u\phi_2)e_{1,f}^2\tag{2.32}$$

a região de incerteza que contém os parâmetros da planta é conhecida, assim como o sinal dos parâmetros, desta forma, para uma frequência de sinal de entrada qualquer, sabemos que o módulo da função de transferência da planta cumpre a seguinte restrição:

$$|G(jw)| \leq \left| \frac{k_p^+}{jw + a_p^-} \right|\tag{2.33}$$

portanto podemos garantir a seguinte condição:

$$\lambda > y\phi_1 + u\phi_2\tag{2.34}$$

pois basta garantir que λ é maior que a maior cota superior dos módulos dos sinais $y\phi_1$ e $u\phi_2$. As funções de transferência para ϕ_1 e ϕ_2 representam filtros passa-baixa de primeira ordem. O maior ganho de amplitude que um filtro passa-baixa pode impor a um sinal é quando a frequência do sinal é nula. Podemos escrever:

$$\begin{aligned}\sup(|y|) &\leq \sup(|u|) \left| \frac{k_p^+}{jw + a_p^-} \right| \\ \sup(|\phi_1|) &\leq \frac{\sup(|u|)}{\lambda} \left| \frac{k_p^+}{jw + a_p^-} \right| \\ \sup(|\phi_2|) &\leq \frac{\sup(|u|)}{\lambda}\end{aligned}$$

então, temos que a escolha de λ que cumpre:

$$\lambda > \sup(|u|) \sqrt{\left| \frac{k_p^+}{jw + a_p^-} \right|} + 1\tag{2.35}$$

é suficiente para garantir que $\dot{V}$ seja semi-definida negativa e que portanto V não possa crescer, o que implica em:

$$\begin{aligned}e_{1,f} &\in \mathcal{L}_\infty \\ \tilde{a}_{1,f} &\in \mathcal{L}_\infty \rightarrow \hat{a}_{1,f} \in \mathcal{L}_\infty \\ \tilde{k}_{1,f} &\in \mathcal{L}_\infty \rightarrow \hat{k}_{1,f} \in \mathcal{L}_\infty\end{aligned}$$

o sinal de controle u deve ser escolhido tal que:

$$u \in \mathcal{L}_\infty$$

e como a planta é estável temos que:

$$y \in \mathcal{L}_\infty \rightarrow z \in \mathcal{L}_\infty$$

$$\dot{e}_{1,f} \in \mathcal{L}_\infty$$

como $e_{1,f} = \hat{z}_1 - z \in \mathcal{L}_\infty$ e $z \in \mathcal{L}_\infty$, temos que:

$$\hat{z}_1 \in \mathcal{L}_\infty$$

e finalmente, manipulando a equação para $\dot{V}$:

$$e_{1,f}^2 = -\frac{1}{\lambda + y\phi_1 + u\phi_2} \dot{V}$$

$$\int_0^\infty e_{1,f}^2 \leq -\frac{1}{\lambda - \sup(|y\phi_1|) - \sup(|u\phi_2|)} \int_0^\infty \dot{V}$$

$$\int_0^\infty e_{1,f}^2 \leq -\frac{1}{\lambda - \sup(|y\phi_1|) - \sup(|u\phi_2|)} (V(\infty) - V(0))$$

portanto:

$$e_{1,f} \in \mathcal{L}_2$$

usando o lema de Barbalat, como $e_{1,f}$ é uniformemente limitado, tem norma $\mathcal{L}_2$ limitada e sua derivada é uniformemente limitada temos que:

$$\lim_{t \rightarrow \infty} e_{1,f} = 0$$

adicionalmente, quando o sinal de controle u for persistentemente excitante, teremos que $e_{1,f} = 0$ para todo tempo $t > t_0$ sse $\tilde{a}_{1,f} = 0$ e $\tilde{k}_{1,f} = 0$ e as estimativas $\hat{a}_{1,f}$ e $\hat{k}_{1,f}$ tendem aos valores corretos a_p e k_p respectivamente, para $t \rightarrow \infty$. É importante notar que usando este modelo de identificação o valor de $\dot{V}$ depende de λ que é um parâmetro de projeto do estimador. Portanto a velocidade de convergência de $e_{1,f}$ para 0 depende de um parâmetro de projeto. $\hat{z}_1$ é gerado a partir de uma combinação linear dos componentes do vetor ϕ com os parâmetros $\hat{a}_{1,f}$ e $\hat{k}_{1,f}$. Para mais informações acerca dos Modelos de Identificação discutidos até agora, referimos o leitor a (Ioannou & Sun 1996, Narendra & Annaswamy 1989, Tao 2003).

2.2 Estimação de Parâmetros de Segundo Nível

2.2.1 N Modelos de Identificação Série-Paralelo

Seja a planta estável:

$$\Sigma_p : \dot{y} = -a_p y + k_p u$$

e sejam os $i = 1, \dots, N$ modelos de identificação, com $N \geq 3$:

$$\Sigma_{i,sp} : \dot{\hat{y}}_{i,sp} = -a_m \hat{y}_{i,sp} - \hat{a}_{i,sp} y + a_m y + \hat{k}_{i,sp} u \quad (2.36)$$

definimos os $i = 1, \dots, N$ erros de identificação:

$$e_{i,sp} \triangleq \hat{y}_{i,sp} - y \quad (2.37)$$

e suas dinâmicas são representadas pelas $i = 1, \dots, N$ equações diferenciais:

$$\dot{e}_{i,sp} = -a_m e_{i,sp} - \hat{a}_{i,sp} y + a_p y + \hat{k}_{i,sp} u - k_p u$$

então, definimos os erros paramétricos dos N modelos, com $i = 1, \dots, N$:

$$\begin{aligned} \tilde{a}_{i,sp} &= \hat{a}_{i,sp} - a_p \\ \tilde{k}_{i,sp} &= \hat{k}_{i,sp} - k_p \end{aligned} \quad (2.38)$$

e as equações diferenciais podem ser escritas como:

$$\dot{e}_{i,sp} = -a_m e_{i,sp} - \tilde{a}_{i,sp} y + \tilde{k}_{i,sp} u \quad (2.39)$$

com $i = 1, \dots, N$ e como já foi visto anteriormente, as $2N$ estimativas dos parâmetros da planta podem ser atualizadas pelas leis integrais:

$$\begin{aligned} \dot{\hat{a}}_{i,sp} &= e_{i,sp} y \\ \dot{\hat{k}}_{i,sp} &= -e_{i,sp} u \end{aligned} \quad (2.40)$$

os vetores de parâmetros $[\hat{a}_{i,sp} \ \hat{k}_{i,sp}]$, $i = 1, \dots, N$, formam um fecho convexo no espaço de parâmetros. Cada um dos pontos no interior ou fronteira deste fecho convexo pode ser representado por uma combinação convexa:

$$\begin{aligned} \hat{a}_{v,sp} &= \sum_{i=1}^N \hat{a}_{i,sp} \beta_{i,sp} \\ \hat{k}_{v,sp} &= \sum_{i=1}^N \hat{k}_{i,sp} \beta_{i,sp} \\ \sum_{i=1}^N \beta_{i,sp} &= 1 \\ 0 &\leq \beta_{i,sp} \leq 1 \end{aligned} \quad (2.41)$$

se criarmos então um **MODELO DE IDENTIFICAÇÃO VIRTUAL** a partir de alguma destas combinações convexas:

$$\Sigma_{v,sp} : \dot{\hat{y}}_{v,sp} = -a_m \hat{y}_{v,sp} - \hat{a}_{v,sp} y + a_m y + \hat{k}_{v,sp} u \quad (2.42)$$

e definirmos o erro de identificação para o modelo virtual:

$$e_{v,sp} \triangleq \hat{y}_{v,sp} - y \quad (2.43)$$

e definindo os erros paramétricos:

$$\begin{aligned} \tilde{a}_{v,sp} &\triangleq \hat{a}_{v,sp} - a_p \\ \tilde{k}_{v,sp} &\triangleq \hat{k}_{v,sp} - k_p \end{aligned} \quad (2.44)$$

sua dinâmica e expressão no tempo são idênticas às dos modelos de primeiro nível:

$$\begin{aligned} \dot{e}_{v,sp} &= -a_m e_{v,sp} - \tilde{a}_{v,sp} y + \tilde{k}_{v,sp} u \\ e_{v,sp}(t) &= e_{v,sp}(0) e^{-a_m t} + \int_0^t e^{-a_m(t-\tau)} (-\tilde{a}_{v,sp}(\tau) y(\tau) + \tilde{k}_{v,sp}(\tau) u(\tau)) d\tau \end{aligned} \quad (2.45)$$

pode-se manipular as expressões dos erros paramétricos:

$$\begin{aligned} \tilde{a}_{v,sp} &= \sum_{i=1}^N \hat{a}_{i,sp} \beta_{i,sp} - a_p = \sum_{i=1}^N \hat{a}_{i,sp} \beta_{i,sp} - \sum_{i=1}^N a_p \beta_{i,sp} = \sum_{i=1}^N \tilde{a}_{i,sp} \beta_{i,sp} \\ \tilde{k}_{v,sp} &= \sum_{i=1}^N \hat{k}_{i,sp} \beta_{i,sp} - k_p = \sum_{i=1}^N \hat{k}_{i,sp} \beta_{i,sp} - \sum_{i=1}^N k_p \beta_{i,sp} = \sum_{i=1}^N \tilde{k}_{i,sp} \beta_{i,sp} \end{aligned} \quad (2.46)$$

segue que as leis adaptativas que governam o ajuste de $k_{v,sp}$ e $a_{v,sp}$ são da forma:

$$\begin{aligned} \dot{\hat{a}}_{v,sp} &= \sum_{i=1}^N \dot{\hat{a}}_{i,sp} \beta_{i,sp} \\ \dot{\hat{k}}_{v,sp} &= \sum_{i=1}^N \dot{\hat{k}}_{i,sp} \beta_{i,sp} \end{aligned} \quad (2.47)$$

substituindo as expressões relevantes obtemos:

$$\begin{aligned} \dot{\hat{a}}_{v,sp} &= y \sum_{i=1}^N e_{i,sp} \beta_{i,sp} \\ \dot{\hat{k}}_{v,sp} &= -u \sum_{i=1}^N e_{i,sp} \beta_{i,sp} \end{aligned} \quad (2.48)$$

assumindo que $y(0)$ é conhecido então é possível escolher $\hat{y}_{i,sp}(0) = \hat{y}_{v,sp}(0) = y(0)$ e ter

que $e_{i,sp}(0) = e_{v,sp}(0) = 0$, com $i = 1, \dots, N$. Usando as expressões dos erros obtemos:

$$\begin{aligned}
 \dot{\hat{a}}_{v,sp} &= y \int_0^t e^{-a_m(t-\tau)} \left(- \left(\sum_{i=1}^N \tilde{a}_{i,sp}(\tau) \beta_{i,sp} \right) y(\tau) + \left(\sum_{i=1}^N \tilde{k}_{i,sp}(\tau) \beta_{i,sp} \right) u(\tau) \right) d\tau \\
 &= y \int_0^t e^{-a_m(t-\tau)} \left(-\tilde{a}_{v,sp}(\tau) y(\tau) + \tilde{k}_{v,sp}(\tau) u(\tau) \right) d\tau \\
 \hat{k}_{v,sp} &= u \int_0^t e^{-a_m(t-\tau)} \left(- \left(\sum_{i=1}^N \tilde{a}_{i,sp}(\tau) \beta_{i,sp} \right) y(\tau) + \left(\sum_{i=1}^N \tilde{k}_{i,sp}(\tau) \beta_{i,sp} \right) u(\tau) \right) d\tau \\
 &= u \int_0^t e^{-a_m(t-\tau)} \left(-\tilde{a}_{v,sp}(\tau) y(\tau) + \tilde{k}_{v,sp}(\tau) u(\tau) \right) d\tau
 \end{aligned} \tag{2.49}$$

As expressões acima então se reduzem a:

$$\begin{aligned}
 \dot{\hat{a}}_{v,sp} &= e_{v,sp} y \\
 \dot{\hat{k}}_{v,sp} &= -e_{v,sp} u
 \end{aligned} \tag{2.50}$$

também é importante notar que obtivemos o seguinte resultado:

$$e_{v,sp} = \sum_{i=1}^N \beta_{i,sp} e_{i,sp} \tag{2.51}$$

as leis adaptativas obtidas acima têm forma idêntica àsquelas usadas nos modelos de primeiro nível $\Sigma_{i,sp}, i = 1, \dots, N$. **Cada um dos pontos no interior do fecho convexo corresponde a um modelo virtual.** Conforme os modelos de primeiro nível têm seus parâmetros ajustados adaptativamente os modelos virtuais também tem seus parâmetros ajustados por leis idênticas. Assim, **uma combinação convexa de coeficientes constantes dos parâmetros de modelos de primeiro nível se comporta da mesma forma que um modelo de primeiro nível cujos parâmetros fossem inicializados nos mesmos valores.** Assumindo, então, que os parâmetros verdadeiros da planta a_p e k_p pertencem inicialmente ao fecho convexo, podem ser representados por uma combinação convexa de coeficientes $\alpha_{i,sp}^*$, $i = 1, \dots, N$, dos parâmetros dos modelos de primeiro nível:

$$\begin{aligned}
a_p &= \sum_{i=1}^N \hat{a}_{i,sp} \alpha_{i,sp}^* \\
k_p &= \sum_{i=1}^N \hat{k}_{i,sp} \alpha_{i,sp}^* \\
\sum_{i=1}^N \alpha_{i,sp}^* &= 1 \\
0 &\leq \alpha_{i,sp}^* \leq 1
\end{aligned} \tag{2.52}$$

e definimos o modelo virtual:

$$\Sigma_{\alpha,sp} : \dot{\hat{y}}_{\alpha,sp} = -a_m \hat{y}_{\alpha,sp} - a_p y + a_m y + k_p u \tag{2.53}$$

com erro de identificação:

$$e_{\alpha,sp} \triangleq \hat{y}_{\alpha,sp} - y \tag{2.54}$$

cujas dinâmica é simplesmente:

$$\dot{e}_{\alpha,sp} = -a_m e_{\alpha,sp} \tag{2.55}$$

e como vimos as estimativas acima são atualizadas da mesma forma que seriam para um modelo de primeiro nível inicializado nos valores corretos. Podemos verificar pelas equações acima que um modelo inicializado nos valores corretos com erro de identificação inicialmente nulo tem erro de identificação identicamente nulo. Suas estimativas são identicamente os valores corretos. Temos então que:

$$e_{\alpha,sp} \equiv 0 \tag{2.56}$$

e portanto se os parâmetros verdadeiros da planta pertencem inicialmente ao fecho convexo formado pelos parâmetros dos modelos de primeiro nível, devem fazê-lo para todo o tempo t.

Como vimos, se os parâmetros da planta pertencem ao fecho convexo formado pelos parâmetros dos modelos de primeiro nível, existe pelo menos uma combinação convexa de coeficientes $\alpha_{i,sp}^*, i = 1, \dots, N$, que caracteriza a planta para todo o tempo t, e portanto os coeficientes podem servir como uma alternativa de parametrização para a planta. Então, como uma segunda camada de estimação, ou **segundo nível de adaptação**, podemos estimar os coeficientes da combinação linear convexa. Pelas equações anteriores, temos que pode-se escrever $e_{\alpha,sp}$ como a combinação convexa dos erros dos modelos de primeiro nível:

$$e_{\alpha,sp} = \sum_{i=1}^N e_{i,sp} \alpha_{i,sp}^*$$

e definindo:

$$\bar{E}_{sp} = [e_{1,sp} \ e_{2,sp} \ \dots \ e_{N,sp}] \quad (2.57)$$

e:

$$\alpha_{sp}^* = [\alpha_{1,sp}^* \ \alpha_{2,sp}^* \ \dots \ \alpha_{N,sp}^*] \quad (2.58)$$

podemos escrever em forma matricial:

$$\bar{E}_{sp} \bar{\alpha}_{sp}^* = \sum_{i=1}^N e_{i,sp} \alpha_{i,sp}^* = 0 \quad (2.59)$$

pela combinação convexa temos que:

$$\sum_{i=1}^N \alpha_{i,sp}^* = 1$$

então o parâmetro $\alpha_{N,sp}^*$ pode ser expresso por:

$$\alpha_{N,sp}^* = 1 - \sum_{i=1}^{N-1} \alpha_{i,sp}^* \quad (2.60)$$

e explicitando o último termo do somatório em $\bar{E}_{sp} \bar{\alpha}_{sp}^*$:

$$\bar{E}_{sp} \bar{\alpha}_{sp}^* = \sum_{i=1}^{N-1} e_{i,sp} \alpha_{i,sp}^* + e_{N,sp} \alpha_{N,sp}^*$$

e então substituímos $\alpha_{N,sp}^*$ pela expressão obtida acima:

$$\bar{E}_{sp} \bar{\alpha}_{sp}^* = \sum_{i=1}^{N-1} e_{i,sp} \alpha_{i,sp}^* + e_{N,sp} (1 - \sum_{i=1}^{N-1} \alpha_{i,sp}^*) = 0$$

que reorganizado fica da seguinte forma:

$$\sum_{i=1}^{N-1} (e_{i,sp} - e_{N,sp}) \alpha_{i,sp}^* = -e_{N,sp} \quad (2.61)$$

e definimos:

$$E_{sp} \triangleq [e_{1,sp} - e_{N,sp} \ e_{2,sp} - e_{N,sp} \ \dots \ e_{N-1,sp} - e_{N,sp}] \quad (2.62)$$

e:

$$\alpha_{sp}^* \triangleq [\alpha_{1,sp}^* \ \alpha_{2,sp}^* \ \dots \ \alpha_{N-1,sp}^*] \quad (2.63)$$

com estas variáveis definidas, reescrevemos a equação 2.61 como:

$$E_{sp} \alpha_{sp}^* = -e_{N,sp} \quad (2.64)$$

e substituindo o vetor α_{sp}^* por uma estimativa α_{sp} , como anteriormente, pode-se obter uma equação diferencial para estimar α_{sp}^* :

$$\dot{\alpha}_{sp} = -E_{sp}^T E_{sp} \alpha_{sp} - E_{sp}^T e_{N,sp} \quad (2.65)$$

e a estimativa $\bar{\alpha}_{sp}$ de $\bar{\alpha}_{sp}^*$ fica da forma:

$$\bar{\alpha}_{sp}^T = \begin{bmatrix} \alpha_{sp}^T & 1 - \vec{1}\alpha_{sp} \end{bmatrix} \quad (2.66)$$

onde $\vec{1}$ é o vetor linha $[1 \ 1 \ \dots \ 1]$ de tamanho apropriado. Definimos, então, o erro paramétrico para a estimativa $\bar{\alpha}_{sp}$ e para α_{sp} :

$$\begin{aligned} \tilde{\bar{\alpha}}_{sp} &\triangleq \bar{\alpha}_{sp} - \bar{\alpha}_{sp}^* \\ \tilde{\alpha}_{sp} &\triangleq \alpha_{sp} - \alpha_{sp}^* \end{aligned} \quad (2.67)$$

e como pelo menos uma solução de $\bar{\alpha}_{sp}^*$ é invariante no tempo, escrevemos:

$$\begin{aligned} \dot{\tilde{\bar{\alpha}}}_{sp} &= \dot{\bar{\alpha}}_{sp} - \cancel{\dot{\bar{\alpha}}_{sp}^*}^0 = \dot{\bar{\alpha}}_{sp} \\ \dot{\tilde{\alpha}}_{sp} &= \dot{\alpha}_{sp} - \cancel{\dot{\alpha}_{sp}^*}^0 = \dot{\alpha}_{sp} \end{aligned} \quad (2.68)$$

tal que, substituindo $\dot{\alpha}_{sp}$ por $\dot{\tilde{\alpha}}_{sp}$ e α_{sp} por $\tilde{\alpha}_{sp} + \alpha_{sp}^*$ em 3.54 e cancelando os termos equivalentes devido a 3.53, temos:

$$\dot{\tilde{\alpha}}_{sp} = -E_{sp}^T E_{sp} \tilde{\alpha}_{sp} \quad (2.69)$$

a partir de uma candidata a função de Lyapunov definida positiva:

$$V(\tilde{\alpha}_{sp}) = \frac{1}{2} \tilde{\alpha}_{sp}^T \tilde{\alpha}_{sp} \quad (2.70)$$

derivando ao longo das trajetórias teremos:

$$\dot{V} = \tilde{\alpha}_{sp}^T \dot{\tilde{\alpha}}_{sp}$$

e explicitando $\tilde{\alpha}_{sp}$ e $\dot{\tilde{\alpha}}_{sp}$:

$$\dot{V} = \begin{bmatrix} \tilde{\alpha}_{sp}^T & \vec{1}\tilde{\alpha}_{sp} \end{bmatrix} \begin{bmatrix} \dot{\tilde{\alpha}}_{sp}^T \\ \vec{1}\dot{\tilde{\alpha}}_{sp} \end{bmatrix}$$

ao substituirmos $\dot{\tilde{\alpha}}_{sp}$ por 3.58, obtemos:

$$\dot{V} = -\tilde{\alpha}_{sp}^T E_{sp}^T E_{sp} \tilde{\alpha}_{sp} + \vec{1}\tilde{\alpha}_{sp} \vec{1} E_{sp}^T E_{sp} \tilde{\alpha}_{sp}$$

que reorganizado, tendo em mente que neste caso $\vec{1}\vec{1}^T = N - 1$, pode ser expresso por:

$$\dot{V} = -N \tilde{\alpha}_{sp}^T E_{sp}^T E_{sp} \tilde{\alpha}_{sp} \quad (2.71)$$

nesta expressão de $\dot{V}$ fica expressa uma característica importante da Adaptação de Segundo Nível, isto é, a velocidade com que a função de energia V decresce está relacionada com o número de modelos escolhidos, de forma que quanto mais modelos de identificação de primeiro nível forem usados, mais rápida será a convergência dos parâmetros. Ademais, $\dot{V}$ é semi-definida negativa (pois temos uma forma quadrática de sinal negativo com uma matriz semi-definida positiva) e portanto V não pode crescer, temos então que:

$$\tilde{\tilde{\alpha}}_{sp} \in \mathcal{L}_\infty \rightarrow \tilde{\alpha}_{sp} \in \mathcal{L}_\infty$$

e que:

$$\tilde{\tilde{\alpha}}_{sp} \in \mathcal{L}_\infty \rightarrow \bar{\alpha}_{sp} \in \mathcal{L}_\infty$$

$$\tilde{\alpha}_{sp} \in \mathcal{L}_\infty \rightarrow \alpha_{sp} \in \mathcal{L}_\infty$$

e como:

$$E_{sp}, \alpha_{sp} \in \mathcal{L}_\infty \rightarrow \dot{\alpha}_{sp}, \dot{\tilde{\alpha}}_{sp} \in \mathcal{L}_\infty$$

quando o sinal de controle u for persistentemente excitante teremos que E_{sp} só será o vetor nulo a partir de algum instante qualquer se as estimativas dos parâmetros forem equivalentes aos parâmetros corretos a_p e k_p , o que indica que uma combinação convexa destes parâmetros também tenderá para os valores corretos. As estimativas dos parâmetros a_p e k_p da planta, $\hat{a}_{n2,sp}$ e $\hat{k}_{n2,sp}$ são entregues pela combinação convexa de coeficientes $\alpha_{i,sp}, i = 1, \dots, N$ dos parâmetros $\hat{a}_{i,sp}$ e $\hat{k}_{i,sp}, i = 1, \dots, N$:

$$\begin{aligned} \hat{a}_{n2,sp} &= \alpha_{1,sp} \hat{a}_{1,sp} + \alpha_{2,sp} \hat{a}_{2,sp} + \dots + \alpha_{N,sp} \hat{a}_{N,sp} \\ \hat{k}_{n2,sp} &= \alpha_{1,sp} \hat{k}_{1,sp} + \alpha_{2,sp} \hat{k}_{2,sp} + \dots + \alpha_{N,sp} \hat{k}_{N,sp} \end{aligned} \quad (2.72)$$

Adaptação de Segundo Nível Modificada

Como foi demonstrado, é possível estimar $\alpha_{i,sp}^*, i = 1, \dots, N$ através das equações 3.54 e 3.55. No entanto, como $E_{sp}^T E_{sp}$ é uma matriz de posto 1 ou 0, não podemos concluir mais nada sem a presença de um sinal com persistência de excitação pois $\lambda_{\min}(E_{sp}^T E_{sp}) \equiv 0$. Como forma de melhorar este resultado, fazemos o seguinte raciocínio:

$$\begin{aligned}
E_{sp}^T E_{sp} \alpha_{sp}^* &= -E_{sp}^T e_{N,sp} \\
\int_0^t E_{sp}^T(\tau) E_{sp}(\tau) \alpha_{sp}^* d\tau &= -\int_0^t E_{sp}^T(\tau) e_{N,sp}(\tau) d\tau \\
\int_0^t E_{sp}^T(\tau) E_{sp}(\tau) d\tau \alpha_{sp}^* &= -\int_0^t E_{sp}^T(\tau) e_{N,sp}(\tau) d\tau \\
0 &= -\int_0^t E_{sp}^T(\tau) E_{sp}(\tau) d\tau \alpha_{sp}^* - \int_0^t E_{sp}^T(\tau) e_{N,sp}(\tau) d\tau \\
0 &= -\int_0^t E_{sp}^T(\tau) E_{sp}(\tau) d\tau \alpha_{sp}^* - E_{sp}^T E_{sp} \alpha_{sp}^* - \int_0^t E_{sp}^T(\tau) e_{N,sp}(\tau) d\tau - E_{sp}^T e_{N,sp}
\end{aligned}$$

como os erros de identificação $e_{i,sp}, i = 1, \dots, N$, são limitados e tendem a 0 a medida que o tempo t tende a infinito, as integrais são limitadas e tendem a valores constantes. Substituindo α_{sp}^* por sua estimativa temos a seguinte equação:

$$\dot{\alpha}_{sp} = -\int_0^t E_{sp}^T(\tau) E_{sp}(\tau) d\tau \alpha_{sp} - E_{sp}^T E_{sp} \alpha_{sp} - \int_0^t E_{sp}^T(\tau) e_{N,sp}(\tau) d\tau - E_{sp}^T e_{N,sp}$$

e por facilidade de notação, usamos variáveis para as integrais:

$$\begin{aligned}
M_{sp} &= \int_0^t E_{sp}^T(\tau) E_{sp}(\tau) d\tau \\
v_{sp} &= \int_0^t E_{sp}^T(\tau) e_{N,sp}(\tau) d\tau
\end{aligned} \tag{2.73}$$

e escrevemos:

$$\dot{\alpha}_{sp} = -M_{sp} \alpha_{sp} - E_{sp}^T E_{sp} \alpha_{sp} - v_{sp} - E_{sp}^T e_{N,sp} \tag{2.74}$$

então usamos uma candidata a função de Lyapunov definida positiva:

$$V(\tilde{\alpha}_{sp}) = \frac{1}{2} \tilde{\alpha}_{sp}^T \tilde{\alpha}_{sp} \tag{2.75}$$

que resulta em:

$$\dot{V} = -N \tilde{\alpha}_{sp}^T (E_{sp}^T E_{sp} + M_{sp}) \tilde{\alpha}_{sp} \tag{2.76}$$

para cada instante de tempo existe um autovetor ligado ao espaço nulo da matriz $E_{sp}^T E_{sp}$.

Então para um vetor arbitrário $w_q \in R^{N-1}$ constante:

$$w_q^T \left(\int_0^\infty E_{sp}^T(\tau) E_{sp}(\tau) d\tau \right) w_q > 0$$

pois assumimos que não existe um vetor w_q , constante e não-nulo, que seja equivalente a um múltiplo escalar do autovetor associado ao espaço nulo da matriz $E_{sp}^T E_{sp}$ (pois assumimos que a direção deste autovetor está mudando ao longo do tempo), o que tornará $w_q^T E_{sp}^T E_{sp} w_q$ positivo durante algum intervalo de tempo, qualquer que seja w_q . Portanto a matriz M_{sp} converge para uma matriz simétrica com valores de seus elementos constantes, definida positiva e de posto cheio. Temos então, para um intervalo finito entre 0 e $t_0 > 0$ escolhido tal que $\lambda_{\min}(E_{sp}^T E_{sp} + M_{sp}) > 0$ a partir de t_0 , que:

$$\int_0^{t_0} \|\tilde{\alpha}_{sp}\|^2 d\tau < K$$

onde K é um escalar finito, pois $\tilde{\alpha}_{sp}$ é uniformemente limitado. E temos pela desigualdade de Rayleigh que:

$$\begin{aligned} \lambda_{\min}(E_{sp}^T E_{sp} + M_{sp}) \|\tilde{\alpha}_{sp}\|^2 &\leq \\ &\tilde{\alpha}_{sp}^T (E_{sp}^T E_{sp} + M_{sp}) \tilde{\alpha}_{sp} \\ &\leq \\ \lambda_{\max}(E_{sp}^T E_{sp} + M_{sp}) \|\tilde{\alpha}_{sp}\|^2 \end{aligned}$$

e usando a equação obtida para $\dot{V}$ temos que:

$$\|\tilde{\alpha}_{sp}\|^2 \leq \frac{-\dot{V}}{N\lambda_{\min}(E_{sp}^T E_{sp} + M_{sp})}$$

substituímos $\lambda_{\min}$ que varia com o tempo por um valor $\lambda_{\min,inf}$ constante, a menor cota inferior do conjunto de autovalores mínimos da matriz $E_{sp}^T E_{sp} + M_{sp}$ a partir do instante t_0 e integrando temos:

$$\int_0^\infty \|\tilde{\alpha}_{sp}(\tau)\|^2 d\tau \leq \int_0^{t_0} \|\tilde{\alpha}_{sp}(\tau)\|^2 d\tau + \frac{-1}{N\lambda_{\min,inf}(E_{sp}^T E_{sp} + M_{sp})} (V(\infty) - V(t_0))$$

como o lado direito desta equação é um valor limitado seu lado esquerdo também é limitado e temos que:

$$\tilde{\alpha}_{sp} \in \mathcal{L}_2$$

e finalmente, pelo lema de Barbalat, temos que a o vetor $\tilde{\alpha}_{sp}$ é uniformemente limitado,

sua norma $\mathcal{L}_2$ é uniformemente limitada e sua derivada é uniformemente limitada:

$$\lim_{t \rightarrow \infty} \tilde{\alpha}_{sp} = \mathbf{0}$$

temos então que:

$$\lim_{t \rightarrow \infty} \tilde{\alpha}_{sp} = \mathbf{0} \rightarrow \lim_{t \rightarrow \infty} \tilde{\alpha}_{N,sp} = 0$$

e portanto, com a modificação proposta, existe garantia de convergência dos coeficientes $\hat{\alpha}_{i,sp}$, $i = 1, \dots, N$, para seus valores corretos, sem que se necessite impor sobre a planta um sinal de controle com a característica de persistência de excitação. Outra forma de calcular os coeficientes corretos é monitorando o posto de M_{sp} e resolvendo o sistema de equações $M_{sp}\alpha_{sp}^{*T} = -v_{sp}$ para α_{sp}^* quando for verificado que M_{sp} é de posto cheio e suficientemente distante de ser uma matriz singular, para evitar erro numérico. No entanto, é importante ressaltar que esta melhora na convergência dos parâmetros implica numa perda em outro aspecto importante, isto é, caso a planta tenha seus parâmetros variando lentamente no tempo, as informações acumuladas nos elementos da matriz M_{sp} e do vetor v_{sp} deixarão gradualmente de ser válidas na atualização ou cálculo dos coeficientes, fazendo com que os coeficientes acabem convergindo para valores distintos dos corretos, o que é algo que não acontece sem a modificação já que a Adaptação de Segundo Nível para o Modelo Série-Paralelo usa apenas as informações disponíveis em tempo presente.

2.2.2 N Modelos de Identificação por Regressão Linear

Novamente, seja a planta estável:

$$\Sigma_p : \dot{y} = -a_p y + k_p u$$

temos, isolando o termo $sy(s)$ à esquerda:

$$sy(s) = -a_p y(s) + k_p u(s)$$

lembrando que definimos o seguinte polinômio:

$$\Lambda(s) \triangleq s + \lambda$$

com $\lambda > 0$, escalar, e escrevemos:

$$\frac{s}{\Lambda(s)}y(s) = -a_p \frac{1}{\Lambda(s)}y(s) + k_p \frac{1}{\Lambda(s)}u(s)$$

e definimos anteriormente:

$$z(s) \triangleq \frac{s}{\Lambda(s)}y(s)$$

$$\phi(s) \triangleq \begin{bmatrix} -y(s) & u(s) \end{bmatrix}^T \frac{1}{\Lambda(s)}$$

e representamos o sinal de saída filtrado da planta como:

$$z(s) = [a_p \quad k_p] \phi$$

e os $i = 1, \dots, N$ modelos de identificação deste sinal:

$$\Sigma_{i,f} : \hat{z}_{i,f} = [\hat{a}_{i,f} \quad \hat{k}_{i,f}] \phi \quad (2.77)$$

e definimos os $i = 1, \dots, N$ erros de identificação deste sinal:

$$e_{i,f} \triangleq \hat{z}_{i,f} - z \quad (2.78)$$

e suas dinâmicas são representadas pelas $i = 1, \dots, N$ equações diferenciais:

$$\dot{e}_{i,f} = -(\lambda + y\phi_1 + u\phi_2)e_{i,f} - \hat{a}_{i,f}y + a_p y + \hat{k}_{i,f}u - k_p u$$

então, definimos os erros paramétricos dos N modelos, com $i = 1, \dots, N$:

$$\begin{aligned} \tilde{a}_{i,f} &= \hat{a}_{i,f} - a_p \\ \tilde{k}_{i,f} &= \hat{k}_{i,f} - k_p \end{aligned} \quad (2.79)$$

e as equações diferenciais podem ser escritas como:

$$\dot{e}_{i,f} = -(\lambda + y\phi_1 + u\phi_2)e_{i,f} - \tilde{a}_{i,f}y + \tilde{k}_{i,f}u \quad (2.80)$$

com $i = 1, \dots, N$ e como já foi visto anteriormente, as $2N$ estimativas dos parâmetros da planta podem ser atualizadas pelas leis integrais:

$$\begin{aligned} \dot{\hat{a}}_{i,f} &= e_{i,f}y \\ \dot{\hat{k}}_{i,f} &= -e_{i,f}u \end{aligned} \quad (2.81)$$

com $i = 1, \dots, N$. Faremos agora um detalhamento do raciocínio referente à introdução de uma segunda camada de estimação, ou **Adaptação de Segundo Nível**, como na seção anterior. Os vetores de parâmetros $[\hat{a}_{i,f} \quad \hat{k}_{i,f}]$, $i = 1, \dots, N$ formam um fecho convexo no espaço de parâmetros. Cada um dos pontos no interior ou fronteira deste fecho convexo pode ser representado por uma combinação convexa:

$$\begin{aligned} \hat{a}_{v,f} &= \sum_{i=1}^N \hat{a}_{i,f} \beta_{i,f} \\ \hat{k}_{v,f} &= \sum_{i=1}^N \hat{k}_{i,f} \beta_{i,f} \\ \sum_{i=1}^N \beta_{i,f} &= 1 \\ 0 &\leq \beta_{i,f} \leq 1 \end{aligned} \quad (2.82)$$

se criarmos então um **MODELO DE IDENTIFICAÇÃO VIRTUAL** a partir de alguma

destas combinações convexas:

$$\Sigma_{v,f} : \hat{z}_{v,f} = [\hat{a}_{v,f} \quad \hat{k}_{v,f}] \phi \quad (2.83)$$

e definirmos o erro de identificação para o modelo virtual:

$$e_{v,f} \triangleq \hat{z}_{v,f} - z \quad (2.84)$$

e definindo os erros paramétricos:

$$\begin{aligned} \tilde{a}_{v,f} &= \hat{a}_{v,f} - a_p \\ \tilde{k}_{v,f} &= \hat{k}_{v,f} - k_p \end{aligned} \quad (2.85)$$

sua dinâmica será idêntica às dos modelos de primeiro nível:

$$\dot{e}_{v,f} = -(\lambda + y\phi_1 + u\phi_2)e_{v,f} - \tilde{a}_{v,f}y + \tilde{k}_{v,f}u \quad (2.86)$$

podemos manipular as expressões dos erros paramétricos:

$$\begin{aligned} \tilde{a}_{v,f} &= \sum_{i=1}^N \hat{a}_{i,f} \beta_{i,f} - a_p = \sum_{i=1}^N \hat{a}_{i,f} \beta_{i,f} - \sum_{i=1}^N a_p \beta_{i,f} = \sum_{i=1}^N \tilde{a}_{i,f} \beta_{i,f} \\ \tilde{k}_{v,f} &= \sum_{i=1}^N \hat{k}_{i,f} \beta_{i,f} - k_p = \sum_{i=1}^N \hat{k}_{i,f} \beta_{i,f} - \sum_{i=1}^N k_p \beta_{i,f} = \sum_{i=1}^N \tilde{k}_{i,f} \beta_{i,f} \end{aligned} \quad (2.87)$$

segue que as leis adaptativas que governam o ajuste de $k_{v,f}$ e $a_{v,f}$ são da forma:

$$\begin{aligned} \dot{\hat{a}}_{v,f} &= \sum_{i=1}^N \dot{\hat{a}}_{i,f} \beta_{i,f} \\ \dot{\hat{k}}_{v,f} &= \sum_{i=1}^N \dot{\hat{k}}_{i,f} \beta_{i,f} \end{aligned} \quad (2.88)$$

no entanto, ao contrário do caso do modelo série-paralelo, não dispomos de uma expressão no tempo para os erros de identificação. Podemos no entanto utilizar as expressões anteriores:

$$\sum_{i=1}^N \dot{e}_{i,f} \beta_{i,f} = -(\lambda + y\phi_1 + u\phi_2) \sum_{i=1}^N e_{i,f} \beta_{i,f} - \tilde{a}_{v,f}y + \tilde{k}_{v,f}u \quad (2.89)$$

ou seja, a dinâmica da combinação convexa $\sum_{i=1}^N e_{i,f} \beta_{i,f}$ é exatamente igual à dinâmica do erro de identificação do modelo virtual $e_{v,f}$. A combinação convexa dos erros de identificação tende exponencialmente para o valor do erro de identificação do modelo virtual.

Se estipularmos que $e_{v,f}(0) = \sum_{i=1}^N e_{i,f}(0) \beta_{i,f}$ então os dois se tornam equivalentes. Feitas

estas considerações, teremos então que as expressões das leis adaptativas se reduzem a:

$$\begin{aligned}\dot{\hat{a}}_{v,f} &= e_{v,f}y \\ \dot{\hat{k}}_{v,f} &= -e_{v,f}u\end{aligned}\tag{2.90}$$

e novamente, as leis adaptativas obtidas acima têm forma idêntica àsquelas usadas nos modelos de primeiro nível $\Sigma_{i,f}$, $i = 1, \dots, N$. **Cada um dos pontos no interior do fecho convexo corresponde a um modelo virtual.** Conforme os modelos de primeiro nível têm seus parâmetros ajustados adaptativamente os modelos virtuais também tem seus parâmetros ajustados por leis idênticas. Nestas condições, **uma combinação convexa de coeficientes constantes dos parâmetros de modelos de primeiro nível se comporta como se fosse os parâmetros de um modelo de primeiro nível inicializados nos mesmos valores.** Assumindo, então, que os parâmetros verdadeiros da planta a_p e k_p pertencem inicialmente ao fecho convexo, podem ser representados por uma combinação convexa de coeficientes $\alpha_{i,f}^*$, $i = 1, \dots, N$ dos parâmetros dos modelos de primeiro nível:

$$\begin{aligned}a_p &= \sum_{i=1}^N \hat{a}_{i,f} \alpha_{i,f}^* \\ k_p &= \sum_{i=1}^N \hat{k}_{i,f} \alpha_{i,f}^* \\ \sum_{i=1}^N \alpha_{i,f}^* &= 1 \\ 0 &\leq \alpha_{i,f}^* \leq 1\end{aligned}\tag{2.91}$$

e definimos o modelo virtual:

$$\Sigma_{\alpha,f} : \hat{z}_{\alpha,f} = [a_p \quad k_p] \phi\tag{2.92}$$

com erro de identificação:

$$e_{\alpha,f} \triangleq \hat{z}_{\alpha,f} - z\tag{2.93}$$

cujas dinâmica é:

$$\dot{e}_{\alpha,f} = -(\lambda + y\phi_1 + u\phi_2)e_{\alpha,f}\tag{2.94}$$

que nos dá o seguinte resultado:

$$\lim_{t \rightarrow \infty} e_{\alpha,f} = \lim_{t \rightarrow \infty} \sum_{i=1}^N e_{i,f} \alpha_{i,f}^* = 0\tag{2.95}$$

desta forma, os parâmetros da planta podem deixar de pertencer ao fecho convexo devido ao efeito das condições iniciais. No entanto este resultado indica que os parâmetros da planta voltam a pertencer ao fecho convexo. Se a combinação convexa dos erros de identificação não-nulos se torna constante e nula a partir de um certo instante então a combinação convexa dos erros paramétricos também se torna constante e nula. Desta

forma os coeficientes $\alpha_{i,f}^*, i = 1, \dots, N$ servem como alternativas de parametrização para a planta. Assim, como uma segunda camada de estimação, ou **segundo nível de adaptação**, podemos estimar os coeficientes da combinação linear. Consideramos, portanto, que a equação $\sum_{i=1}^N e_{i,f} \alpha_{i,f}^* = 0$ é uma ferramenta adequada de estimação. Definimos:

$$\bar{E}_f = [e_{1,f} \quad \dots \quad e_{N-1,f} \quad e_{N,f}] \quad (2.96)$$

e:

$$\bar{\alpha}_f^* = [\alpha_{1,f}^* \quad \dots \quad \alpha_{N-1,f}^*] \quad (2.97)$$

tal que temos em forma matricial:

$$\bar{E}_f \bar{\alpha}_f^* = \sum_{i=1}^N e_{i,f} \alpha_{i,f}^* = 0 \quad (2.98)$$

pela combinação convexa temos que:

$$\sum_{i=1}^N \alpha_{i,f} = 1$$

então o parâmetro $\alpha_{N,f}^*$ pode ser expresso por:

$$\alpha_{N,f} = 1 - \sum_{i=1}^{N-1} \alpha_{i,f}^*$$

e explicitando o último termo do somatório em $\bar{E}_f \bar{\alpha}_f^*$:

$$\bar{E}_f \bar{\alpha}_f^* = \sum_{i=1}^{N-1} e_{i,f} \alpha_{i,f}^* + e_{N,f} \alpha_{N,f}^*$$

e então substituímos $\alpha_{N,f}$ por sua expressão:

$$\bar{E}_f \bar{\alpha}_f^* = \sum_{i=1}^{N-1} e_{i,f} \alpha_{i,f}^* + e_{N,f} (1 - \sum_{i=1}^{N-1} \alpha_{i,f}^*) = 0$$

que reorganizado fica da seguinte forma:

$$\sum_{i=1}^{N-1} (e_{i,f} - e_{N,f}) \alpha_{i,f}^* = -e_{N,f} \quad (2.99)$$

e definimos:

$$E_f = [e_{1,f} - e_{N,f} \quad e_{2,f} - e_{N,f} \quad \dots \quad e_{N-1,f} - e_{N,f}] \quad (2.100)$$

e:

$$\alpha_f^* = [\alpha_{1,f}^* \quad \alpha_{2,f}^* \quad \dots \quad \alpha_{N-1,f}^*] \quad (2.101)$$

com estas variáveis definidas, reescrevemos a equação como:

$$E_f \alpha_f^* = -e_{N,f} \quad (2.102)$$

e substituindo o vetor α_f^* por uma estimativa α_f , como anteriormente, pode-se obter uma equação diferencial para estimar α_f^* :

$$\dot{\alpha}_f = -E_f^T E_f \alpha_f - E_f^T e_{N,f} \quad (2.103)$$

e a estimativa $\bar{\alpha}_f$ de $\bar{\alpha}_f^*$ fica da forma:

$$\bar{\alpha}_f^T = [\alpha_f^T \quad 1 - \mathbf{1} \alpha_f] \quad (2.104)$$

onde $\mathbf{1}$ é o vetor linha $[1 \quad 1 \quad \dots \quad 1]$ de tamanho apropriado. Definimos, então, o erro paramétrico para a estimativa $\bar{\alpha}_f$ e para α_f :

$$\begin{aligned} \tilde{\alpha}_f &\triangleq \bar{\alpha}_f - \bar{\alpha}_f^* \\ \tilde{\alpha}_f &\triangleq \alpha_f - \alpha_f^* \end{aligned} \quad (2.105)$$

e como assumimos $\bar{\alpha}_f^*$ invariante no tempo, escrevemos:

$$\begin{aligned} \dot{\tilde{\alpha}}_f &= \dot{\alpha}_f - \cancel{\dot{\bar{\alpha}}_f^*} = \dot{\alpha}_f \\ \dot{\tilde{\alpha}}_f &= \dot{\alpha}_f - \cancel{\dot{\alpha}_f^*} = \dot{\alpha}_f \end{aligned} \quad (2.106)$$

tal que, substituindo $\dot{\alpha}_f$ por $\dot{\tilde{\alpha}}_f$ e α_f por $\tilde{\alpha}_f + \alpha_f^*$ em 4.31 e cancelando os termos equivalentes devido a 3.97, temos:

$$\dot{\tilde{\alpha}}_f = -E_f^T E_f \tilde{\alpha}_f - E_f^T e_{\alpha,f} \quad (2.107)$$

e a partir de uma candidata a função de Lyapunov definida positiva:

$$V(\tilde{\alpha}_f) = \frac{1}{2} \tilde{\alpha}_f^T \tilde{\alpha}_f \quad (2.108)$$

derivando ao longo das trajetórias teremos:

$$\dot{V} = \tilde{\alpha}_f^T \dot{\tilde{\alpha}}_f$$

e explicitando $\tilde{\alpha}_f$ e $\dot{\tilde{\alpha}}_f$:

$$\dot{V} = [\tilde{\alpha}_f^T \quad \mathbf{1} \tilde{\alpha}_f] \begin{bmatrix} \dot{\tilde{\alpha}}_f^T \\ \mathbf{1} \dot{\tilde{\alpha}}_f \end{bmatrix}$$

ao substituírmos $\ddot{\alpha}_f$ por 3.102 e reorganizarmos, obtemos:

$$\dot{V} = -N\ddot{\alpha}_f^T E_f^T E_f \ddot{\alpha}_f - N\ddot{\alpha}_f^T E_f^T e_{\alpha,f} \quad (2.109)$$

e pode-se sempre escolher λ tal que o termo de sinal indefinido $-N\ddot{\alpha}_f^T E_f^T e_{\alpha,f}$ tenda para 0 mais rapidamente que o termo de sinal definido. Nesta expressão de $\dot{V}$ fica expresso novamente que a rapidez de convergência dos parâmetros depende do número de modelos N . V não pode crescer a partir de um certo instante, temos então que:

$$\ddot{\alpha}_f \in \mathcal{L}_\infty \rightarrow \ddot{\alpha}_f \in \mathcal{L}_\infty$$

e que:

$$\begin{aligned} \ddot{\alpha}_f \in \mathcal{L}_\infty &\rightarrow \ddot{\alpha}_f \in \mathcal{L}_\infty \\ \ddot{\alpha}_f \in \mathcal{L}_\infty &\rightarrow \ddot{\alpha}_f \in \mathcal{L}_\infty \end{aligned}$$

e como:

$$E_f, \alpha_f \in \mathcal{L}_\infty \rightarrow \dot{\alpha}_f, \ddot{\alpha}_f \in \mathcal{L}_\infty$$

quando o sinal de controle u for persistentemente excitante teremos que E_f só será o vetor nulo a partir de algum instante quando as estimativas dos parâmetros forem equivalentes aos parâmetros corretos a_p e k_p , o que indica que uma combinação convexa destes parâmetros também tenderá para os valores corretos. As estimativas dos parâmetros a_p e k_p da planta, $\hat{a}_{n2,f}$ e $\hat{k}_{n2,f}$ são entregues pela combinação convexa de coeficientes $\alpha_{i,f}, i = 1, \dots, N$ dos parâmetros $\hat{a}_{i,f}$ e $\hat{k}_{i,f}, i = 1, \dots, N$:

$$\begin{aligned} \hat{a}_{n2,f} &= \alpha_{1,f} \hat{a}_{1,f} + \alpha_{2,f} \hat{a}_{2,f} + \dots + \alpha_{N,f} \hat{a}_{N,f} \\ \hat{k}_{n2,f} &= \alpha_{1,f} \hat{k}_{1,f} + \alpha_{2,f} \hat{k}_{2,f} + \dots + \alpha_{N,f} \hat{k}_{N,f} \end{aligned} \quad (2.110)$$

Adaptação de Segundo Nível Modificada

Como foi demonstrado, é possível estimar $\alpha_{i,sp}^*, i = 1, \dots, N$ através das equações 4.31 e 4.32. No entanto, como $E_f^T E_f$ é uma matriz de posto 1 ou 0, não podemos concluir mais nada sem a presença de um sinal com persistência de excitação pois $\lambda_{\min}(E_f^T E_f) \equiv 0$. Assumindo condições iniciais nulas, fazemos o seguinte raciocínio:

$$\begin{aligned}
E_f^T E_f \alpha_f^* &= -E_f^T e_{N,f} \\
\int_0^t E_f^T(\tau) E_f(\tau) \alpha_f^* d\tau &= -\int_0^t E_f^T(\tau) e_{N,f}(\tau) d\tau \\
\int_0^t E_f^T(\tau) E_f(\tau) d\tau \alpha_f^* &= -\int_0^t E_f^T(\tau) e_{N,f}(\tau) d\tau \\
0 &= -\int_0^t E_f^T(\tau) E_f(\tau) d\tau \alpha_f^* - \int_0^t E_f^T(\tau) e_{N,f}(\tau) d\tau \\
0 &= -\int_0^t E_f^T(\tau) E_f(\tau) d\tau \alpha_f^* - E_f^T E_f \alpha_f^* - \int_0^t E_f^T(\tau) e_{N,f}(\tau) d\tau - E_f^T e_{N,f}
\end{aligned}$$

como os erros de identificação $e_{i,f}, i = 1, \dots, N$, são limitados e tendem a 0 a medida que o tempo t tende a infinito, as integrais são limitadas e tendem a valores constantes. Substituindo α_f^* por sua estimativa temos a seguinte equação:

$$\dot{\alpha}_f = -\int_0^t E_f^T(\tau) E_f(\tau) d\tau \alpha_f - E_f^T E_f \alpha_f - \int_0^t E_f^T(\tau) e_{N,f}(\tau) d\tau - E_f^T e_{N,f}$$

e por facilidade de notação, usamos variáveis para as integrais:

$$\begin{aligned}
M_f &= \int_0^t E_f^T(\tau) E_f(\tau) d\tau \\
v_f &= \int_0^t E_f^T(\tau) e_{N,f}(\tau) d\tau
\end{aligned} \tag{2.111}$$

e escrevemos:

$$\dot{\alpha}_f = -M_f \alpha_f - E_f^T E_f \alpha_f - v_f - E_f^T e_{N,f} \tag{2.112}$$

então usamos uma candidata a função de Lyapunov definida positiva:

$$V(\tilde{\alpha}_f) = \frac{1}{2} \tilde{\alpha}_f^T \tilde{\alpha}_f \tag{2.113}$$

que resulta em:

$$\dot{V} = -N \tilde{\alpha}_f^T (E_f^T E_f + M_f) \tilde{\alpha}_f \tag{2.114}$$

para cada instante de tempo existe um autovetor ligado ao espaço nulo da matriz $E_f^T E_f$. Então para um vetor arbitrário $w_q \in R^{N-1}$ constante:

$$w_q^T \left(\int_0^\infty E_f^T(\tau) E_f(\tau) d\tau \right) w_q > 0$$

pois assumimos que não existe um vetor w_q , constante e não-nulo, que seja equivalente a um múltiplo escalar do autovetor associado ao espaço nulo da matriz $E_f^T E_f$ (pois assumimos que a direção deste autovetor está mudando ao longo do tempo), o que tornará $w_q^T E_{sp}^T E_{sp} w_q$ positivo durante algum intervalo de tempo, qualquer que seja w_q . Portanto a matriz M_f converge para uma matriz simétrica com valores de seus elementos constantes, definida positiva e de posto cheio. Temos então, para um intervalo finito entre 0 e $t_0 > 0$ escolhido tal que $\lambda_{\min}(E_f^T E_f + M_f) > 0$ a partir de t_0 , que:

$$\int_0^{t_0} \|\tilde{\alpha}_f\|^2 d\tau < K$$

onde K é um escalar finito, pois $\tilde{\alpha}_f$ é uniformemente limitado. E temos pela desigualdade de Rayleigh que:

$$\begin{aligned} \lambda_{\min}(E_f^T E_f + M_f) \|\tilde{\alpha}_f\|^2 &\leq \\ &\tilde{\alpha}_f^T (E_f^T E_f + M_f) \tilde{\alpha}_f \\ &\leq \\ \lambda_{\max}(E_f^T E_f + M_f) \|\tilde{\alpha}_f\|^2 \end{aligned}$$

e usando a equação obtida para $\dot{V}$ temos que:

$$\|\tilde{\alpha}_f\|^2 \leq \frac{-\dot{V}}{N\lambda_{\min}(E_f^T E_f + M_f)}$$

substituímos $\lambda_{\min}$ que varia com o tempo por um valor $\lambda_{\min,inf}$ constante, a menor cota inferior do conjunto de autovalores mínimos da matriz $E_f^T E_f + M_f$ a partir do instante t_0 e integrando temos:

$$\int_0^\infty \|\tilde{\alpha}_f(\tau)\|^2 d\tau \leq \int_0^{t_0} \|\tilde{\alpha}_f(\tau)\|^2 d\tau + \frac{-1}{N\lambda_{\min,inf}(E_f^T E_f + M_f)} (V(\infty) - V(t_0))$$

como o lado direito desta equação é um valor limitado seu lado esquerdo também é limitado e temos que:

$$\tilde{\alpha}_f \in \mathcal{L}_2$$

e finalmente, pelo lema de Barbalat, temos que a o vetor $\tilde{\alpha}_f$ é uniformemente limitado, sua norma $\mathcal{L}_2$ é uniformemente limitada e sua derivada é uniformemente limitada:

$$\lim_{t \rightarrow \infty} \tilde{\alpha}_f = \mathbf{0}$$

temos então que:

$$\lim_{t \rightarrow \infty} \tilde{\alpha}_f = \mathbf{0} \rightarrow \lim_{t \rightarrow \infty} \tilde{\alpha}_{N,f} = 0$$

e portanto, com a modificação proposta, existe garantia de convergência dos coeficientes $\hat{\alpha}_{i,f}$, $i = 1, \dots, N$, para seus valores corretos, sem que se necessite impor sobre a planta um sinal de controle com a característica de persistência de excitação. Outra forma de calcular os coeficientes corretos é monitorando o posto de M_f e resolvendo o sistema de equações $M_f \alpha_f^{*T} = -v_f$ para α_f^* quando for verificado que M_f é de posto cheio e suficientemente distante de ser uma matriz singular, para evitar erro numérico. No entanto, é importante ressaltar que esta melhora na convergência dos parâmetros implica numa perda em outro aspecto importante, isto é, caso a planta tenha seus parâmetros variando lentamente no tempo, as informações acumuladas nos elementos da matriz M_f e do vetor v_f deixarão gradualmente de ser válidas na atualização ou cálculo dos coeficientes, fazendo com que os coeficientes acabem convergindo para valores distintos dos corretos, o que é algo que não acontece sem a modificação já que a Adaptação de Segundo Nível para o Modelo por Regressão Linear usa apenas as informações disponíveis em tempo presente.

2.3 Resumo dos Algoritmos e Estudos de Simulação

Apresentamos o Modelo de Identificação Paralelo, Modelo de Identificação Série-Paralelo e o Modelo de Identificação por Regressão Linear neste primeiro capítulo. Discutimos algumas de suas propriedades para a planta estável de ordem 1 e grau relativo 1. Mostramos que o erro de identificação tende a 0 para estes modelos. Mencionamos que as estimativas tendem aos valores corretos na presença de um sinal de entrada com a característica de persistência de excitação. Provamos, para os Modelos de Primeiro Nível que existem coeficientes constantes de uma combinação convexa das estimativas dos parâmetros de 3 ou mais Modelos que produzem a_p e k_p . Demonstramos como uma **segunda camada de adaptação**, ou uma **adaptação em dois níveis** pode-se atualizar estimativas destes coeficientes para calcular uma estimativa de segundo nível de a_p e k_p . Finalmente, para cada um dos Modelos de Identificação de Primeiro Nível, discutimos uma modificação na lei adaptativa da Adaptação de Segundo Nível tal que não seja necessária a imposição de um sinal de controle com característica de persistência de excitação à planta para que seja garantida a convergência dos parâmetros para seus valores corretos.

2.3.1 Resumo dos Algoritmos

Caso o leitor deseje consultar rapidamente, listamos os algoritmos de identificação de primeiro e segundo nível de forma compacta:

Tabela 2.1: Algoritmos dos Modelos de Identificação de Primeiro Nível para uma Planta de Grau 1 e Grau Relativo Unitário

Série-Paralelo	Regressão Linear
$\Sigma_p : \dot{y} = -a_p y + k_p u$	$\Sigma_p : \dot{y} = -a_p y + k_p u$
$\Sigma_{1,sp} : \hat{y}_{1,sp} = -a_m \hat{y}_{1,sp} - \hat{a}_{1,sp} y + a_m y + \hat{k}_{1,sp} u$	$z = y - \lambda \phi_1$
$e_{1,sp} = \hat{y}_{1,sp} - y$	$\dot{\phi}_1 = -\lambda \phi_1 + y$
$\hat{a}_{1,sp} = e_{1,sp} y$	$\dot{\phi}_2 = -\lambda \phi_2 + u$
$\hat{k}_{1,sp} = -e_{1,sp} u$	$\phi^T = [\phi_1 \quad \phi_2]$
	$\Sigma_{1,f} : \hat{z}_{1,f} = [-\hat{a}_{1,f} \quad \hat{k}_{1,f}] \phi$
	$e_{1,f} = \hat{z}_{1,f} - z$
	$\hat{a}_{1,f} = e_{1,f} y$
	$\hat{k}_{1,f} = -e_{1,f} u$

Tabela 2.2: Algoritmos da Adaptação de Segundo Nível baseada em Modelos de Identificação Série-Paralelos para uma Planta de Grau 1 e Grau relativo unitário

Segundo Nível Série-Paralelo	Segundo Nível Série-Paralelo Modificado
$\Sigma_p : \dot{y} = -a_p y + k_p u$	$\Sigma_p : \dot{y} = -a_p y + k_p u$
$\Sigma_{i,sp} : \hat{y}_{i,sp} = -a_m \hat{y}_{i,sp} - \hat{a}_{i,sp} y + a_m y + \hat{k}_{i,sp} u$	$\Sigma_{i,sp} : \hat{y}_{i,sp} = -a_m \hat{y}_{i,sp} - \hat{a}_{i,sp} y + a_m y + \hat{k}_{i,sp} u$
$e_{i,sp} = \hat{y}_{i,sp} - y$	$e_{i,sp} = \hat{y}_{i,sp} - y$
$\hat{a}_{i,sp} = e_{i,sp} y$	$\hat{a}_{i,sp} = e_{i,sp} y$
$\hat{k}_{i,sp} = -e_{i,sp} u$	$\hat{k}_{i,sp} = -e_{i,sp} u$
$E_{sp} = [e_{1,sp} - e_{N,sp} \quad \dots \quad e_{N-1,sp} - e_{N,sp}]$	$E_{sp} = [e_{1,sp} - e_{N,sp} \quad \dots \quad e_{N-1,sp} - e_{N,sp}]$
$\dot{\alpha}_{sp} = -E_{sp}^T E_{sp} \alpha_{sp} - E_{sp}^T e_{N,sp}$	$M_{sp}(0) = \mathbf{0}$
$\bar{\Theta}_{sp} = \begin{bmatrix} \hat{a}_{1,sp} & \dots & \hat{a}_{N,sp} \\ \hat{k}_{1,sp} & \dots & \hat{k}_{N,sp} \end{bmatrix}$	$v_{sp}(0) = \mathbf{0}$
$\bar{\alpha}_{sp}^T = [\alpha_{sp}^T \quad 1 - \vec{1} \alpha_{sp}]$	$\dot{M}_{sp} = E_{sp}^T E_{sp}$
$\begin{bmatrix} \hat{a}_{n2,sp} \\ \hat{k}_{n2,sp} \end{bmatrix} = \bar{\Theta}_{sp} \bar{\alpha}_{sp}$	$\dot{v}_{sp} = E_{sp}^T e_{N,sp}$
	$\dot{\alpha}_{sp} = -(E_{sp}^T E_{sp} + M_{sp}) \alpha_{sp} - E_{sp}^T e_{N,sp} - v_{sp}$
	$\bar{\Theta}_{sp} = \begin{bmatrix} \hat{a}_{1,sp} & \dots & \hat{a}_{N,sp} \\ \hat{k}_{1,sp} & \dots & \hat{k}_{N,sp} \end{bmatrix}$
	$\bar{\alpha}_{sp}^T = [\alpha_{sp}^T \quad 1 - \vec{1} \alpha_{sp}]$
	$\begin{bmatrix} \hat{a}_{n2,sp} \\ \hat{k}_{n2,sp} \end{bmatrix} = \bar{\Theta}_{sp} \bar{\alpha}_{sp}$

Tabela 2.3: Algoritmos da Adaptação de Segundo Nível baseada em Modelos de Identificação por Regressão Linear para uma Planta de Grau 1 e Grau relativo unitário

Segundo Nível Regressão Linear	Segundo Nível Regressão Linear Modificado
$\Sigma_p : \dot{y} = -a_p y + k_p u$ $z = y - \lambda \phi_1$ $\dot{\phi}_1 = -\lambda \phi_1 + y$ $\dot{\phi}_2 = -\lambda \phi_2 + u$ $\phi^T = [\phi_1 \quad \phi_2]$ $\Sigma_{i,f} : \hat{z}_{i,f} = [-\hat{a}_{i,f} \quad \hat{k}_{i,f}] \phi$ $e_{i,f} = \hat{z}_{i,f} - z$ $\hat{a}_{i,f} = e_{i,f} y$ $\hat{k}_{i,f} = -e_{i,f} u$ $E_f = [e_{1,f} - e_{N,f} \quad \dots \quad e_{N-1,f} - e_{N,f}]$ $\dot{\alpha}_f = -E_f^T E_f \alpha_f - E_f^T e_{N,f}$ $\bar{\Theta}_f = \begin{bmatrix} \hat{a}_{1,f} & \dots & \hat{a}_{N,f} \\ \hat{k}_{1,f} & \dots & \hat{k}_{N,f} \end{bmatrix}$ $\bar{\alpha}_f^T = [\alpha_f^T \quad 1 - \bar{\mathbf{1}} \alpha_f]$ $\begin{bmatrix} \hat{a}_{n2,f} \\ \hat{k}_{n2,f} \end{bmatrix} = \bar{\Theta}_f \bar{\alpha}_f$	$\Sigma_p : \dot{y} = -a_p y + k_p u$ $z = y - \lambda \phi_1$ $\dot{\phi}_1 = -\lambda \phi_1 + y$ $\dot{\phi}_2 = -\lambda \phi_2 + u$ $\phi^T = [\phi_1 \quad \phi_2]$ $\Sigma_{i,f} : \hat{z}_{i,f} = [-\hat{a}_{i,f} \quad \hat{k}_{i,f}] \phi$ $e_{i,f} = \hat{z}_{i,f} - z$ $\hat{a}_{i,f} = e_{i,f} y$ $\hat{k}_{i,f} = -e_{i,f} u$ $E_f = [e_{1,f} - e_{N,f} \quad \dots \quad e_{N-1,f} - e_{N,f}]$ $M_f(0) = \mathbf{0}$ $v_f(0) = \mathbf{0}$ $\dot{M}_f = E_f^T E_f$ $\dot{v}_f = E_f^T e_{N,f}$ $\dot{\alpha}_f = -(E_f^T E_f + M_f) \alpha_f - E_f^T e_{N,f} - v_f$ $\bar{\Theta}_f = \begin{bmatrix} \hat{a}_{1,f} & \dots & \hat{a}_{N,f} \\ \hat{k}_{1,f} & \dots & \hat{k}_{N,f} \end{bmatrix}$ $\bar{\alpha}_f^T = [\alpha_f^T \quad 1 - \bar{\mathbf{1}} \alpha_f]$ $\begin{bmatrix} \hat{a}_{n2,f} \\ \hat{k}_{n2,f} \end{bmatrix} = \bar{\Theta}_f \bar{\alpha}_f$

2.3.2 Estudos de Simulação

Considere a Planta de Ordem 1 a seguir:

$$G(s) = \frac{3}{s + 1.5}$$

onde os parâmetros $k_p = 3$ e $a_p = 1.5$ pertencem a uma região de incerteza delimitada por $a_p^+ = 4$, $a_p^- = 0.5$, $k_p^+ = 6$, $k_p^- = 1$. Desejamos identificar os parâmetros desta planta em tempo real. Sua saída $y(t)$ e sua entrada $u(t)$ estão disponíveis para medição. Vamos usar os modelos de identificação estudados neste capítulo: o Modelo de Identificação Paralelo, Modelo Série-Paralelo, Modelo por Regressão Linear e diversas implementações do conceito de Adaptação de Segundo Nível, fazendo uso de conjuntos de Modelos de Primeiro Nível. Na Adaptação de Segundo Nível estimativas de Primeiro Nível são combinadas linearmente por um conjunto de coeficientes que também estão, por sua vez, sendo atualizados para formar uma estimativa de Segundo Nível. Usaremos o número mínimo de

modelos para caso de ordem 1 e grau relativo 1, $N = 3$. Depois, usando o Modelo de Identificação por Regressão Linear, mostramos resultados com $N = 4$ e $N = 8$ modelos. Finalmente, apresentamos e discutimos os resultados de simulações para $N = 3$ modelos com a modificação na lei adaptativa proposta no final da subseção 1.2.1 para Modelos de Identificação Série-Paralelo e no final da subseção 1.2.2 para o Modelo de Identificação por Regressão Linear.

Em todas as simulações utilizamos o sinal de entrada $u(t) = \text{sen}(t)$ que é persistentemente excitante de ordem 1. Da mesma forma consideramos a condição inicial $y(0) = 0.2$ em todas as simulações a seguir. Inicializamos os parâmetros dos Modelos de Primeiro Nível em $\hat{a}(0) = 0.5$ e $\hat{k}(0) = 6$ e os α_i dos modelos de segundo nível tal que $\hat{a}(0) = 0.5$ e $\hat{k}(0) = 6$. Usamos integração por passo fixo de 10^{-3} segundos.

Modelo Paralelo




Figura 2.1: Erro de Identificação usando o Modelo Paralelo para a planta Σ_p , 110 segundos de simulação

Modelo Série-Paralelo

Escolhemos o parâmetro $a_m = 4$.




Figura 2.2: Erro de Identificação usando o Modelo Série-Paralelo para a planta Σ_p , 110 segundos de simulação

Modelo por Regressão Linear

Escolhemos o parâmetro $\lambda = 4$.

OBS, ERRATA: $\lambda > \sqrt{\left| \frac{6}{j1/2\pi + 0.5} \right|} + 1$, resulta em $\lambda > 11.44$, porém na prática usamos um valor muito menor. De fato, usando os parâmetros verdadeiros da planta na equação obtemos $\lambda > 2.27$. Portanto o λ escolhido, apesar de não respeitar a restrição, é mesmo assim suficiente para fazer com que $\dot{V} \leq 0$.




Figura 2.3: Erro de Identificação usando o Modelo por Regressão Linear para a planta Σ_p , 110 segundos de simulação

então verificamos para o Modelo Paralelo que o erro de identificação tende a 0 com $t \approx 90$ segundos na Figura 2.1. Como $u(t)$ é PE de ordem 1 isto indica que a partir de $t \approx 90$

segundos os parâmetros convergiram para os valores corretos. O mesmo aconteceu para o Modelo Série-Paralelo com $t = 110$ segundos na Figura 2.2. Da mesma forma, para o Modelo por Regressão Linear o erro de identificação está tendendo a 0 com $t = 110$ segundos na Figura 2.3, indicando convergência dos parâmetros. Em todos os 3 casos os Modelos de Identificação Convencionais foram capazes de identificar os parâmetros da planta. Porém somente foram capazes de fazê-lo após um intervalo de tempo longo em relação a dinâmica da planta.

Segundo Nível, Série-Paralelo, 3 Modelos

Consideramos que $y(0) = 0.2$, inicializamos os parâmetros do Modelo em $\hat{a}_{1,sp}(0) = 0.5$ e $\hat{k}_{1,sp}(0) = 1, \hat{a}_{2,sp}(0) = 0.5$ e $\hat{k}_{2,sp}(0) = 11, \hat{a}_{3,sp}(0) = 7$ e $\hat{k}_{3,sp}(0) = 1$, e os coeficientes da combinação convexa em $\alpha_{1,sp}(0) = 0.5, \alpha_{2,sp}(0) = 0.5$ e $\alpha_{3,sp}(0) = 0$. Desta forma $\hat{a}_{n2,sp}(0) = 0.5$ e $\hat{k}_{n2,sp}(0) = 6$, como mencionamos anteriormente. Escolhemos o parâmetro $a_m = 4$.

Segundo Nível, Filtragem, 3 Modelos

Inicializamos os parâmetros dos Modelos em $\hat{a}_{1,f}(0) = 0.5$ e $\hat{k}_{1,f}(0) = 1, \hat{a}_{2,f}(0) = 0.5$ e $\hat{k}_{2,f}(0) = 11, \hat{a}_{3,f}(0) = 7$ e $\hat{k}_{3,f}(0) = 1$, e os coeficientes da combinação convexa em $\alpha_{1,f}(0) = 0.5, \alpha_{2,f}(0) = 0.5$ e $\alpha_{3,f}(0) = 0$. Escolhemos o parâmetro $\lambda = 4$, além disso escolhemos $\phi_1(0) = \phi_2(0) = 0$.

Segundo Nível, Filtragem, 4 Modelos

Inicializamos os parâmetros dos Modelos nos vértices da região de incerteza em $\hat{a}_{1,f}(0) = 0.5$ e $\hat{k}_{1,f}(0) = 1, \hat{a}_{2,f}(0) = 4$ e $\hat{k}_{2,f}(0) = 1, \hat{a}_{3,f}(0) = 4$ e $\hat{k}_{3,f}(0) = 6, \hat{a}_{4,f}(0) = 0.5$ e $\hat{k}_{4,f}(0) = 6$, e os coeficientes da combinação convexa em $\alpha_{1,f}(0) = 0, \alpha_{2,f}(0) = 0$ e $\alpha_{3,f}(0) = 0$ e $\alpha_{4,f}(0) = 1$. Escolhemos o parâmetro $\lambda = 4$, além disso escolhemos $\phi_1(0) = \phi_2(0) = 0$.

Segundo Nível, Filtragem, 8 Modelos

Consideramos que $y(0) = 0.2$, inicializamos os parâmetros dos Modelos em $\hat{a}_{1,f}(0) = 0.5$ e $\hat{k}_{1,f}(0) = 1, \hat{a}_{2,f}(0) = 2$ e $\hat{k}_{2,f}(0) = 1, \hat{a}_{3,f}(0) = 4$ e $\hat{k}_{3,f}(0) = 1, \hat{a}_{4,f}(0) = 4$ e $\hat{k}_{4,f}(0) = 3, \hat{a}_{5,f}(0) = 4$ e $\hat{k}_{5,f}(0) = 6, \hat{a}_{6,f}(0) = 2.5$ e $\hat{k}_{6,f}(0) = 6, \hat{a}_{7,f}(0) = 0.5$ e $\hat{k}_{7,f}(0) = 4, \hat{a}_{8,f}(0) = 0.5$ e $\hat{k}_{8,f}(0) = 6$, ao longo do perímetro da região de incerteza, e os coeficientes da combinação convexa em $\alpha_{i,f}(0) = 0, i \neq 8$ e $\alpha_{8,f}(0) = 1$. Escolhemos o parâmetro $\lambda = 4$, além disso escolhemos $\phi_1(0) = \phi_2(0) = 0$.

De forma a facilitar a comparação entre os diferentes Modelos de Identificação plotamos as estimativas dos parâmetros da planta de cada modelo nos mesmos 2 gráficos. Escolhemos omitir as estimativas dos Modelos que não iniciam em $\hat{a} = 0.5$ e $\hat{k} = 6$. Entendemos que estes modelos não contribuem com informações relevantes para a discussão.




Figura 2.4: Estimativa do parâmetro $a_p = 3$ para a planta Σ_p para os Modelos de Identificação estudados, Adaptação de Segundo Nível com $N = 3, N = 4$ e $N = 8$ Modelos de Primeiro Nível por Regressão Linear e $N = 3$ Modelos de Primeiro Nível Série-Paralelos, 20 segundos de simulação




Figura 2.5: Estimativa do parâmetro $k_p = 1.5$ para a planta Σ_p para os Modelos de Identificação estudados, Adaptação de Segundo Nível com $N = 3, N = 4$ e $N = 8$ Modelos de Primeiro Nível por Regressão Linear e $N = 3$ Modelos de Primeiro Nível Série-Paralelos, 20 segundos de simulação

e os resultados se encontram nas Figuras 2.4 e 2.5. Vemos que a Adaptação de Segundo Nível é mais rápida que os Modelos de Identificação Convencionais em todos os casos. O uso do Modelo Série-Paralelo ou Modelo por Regressão Linear leva a resultados quase idênticos, como pode ser visto nas Figuras para o caso em que usamos $N = 3$ modelos.

A velocidade de convergência aumenta quando usamos mais modelos, mas não de uma forma linear. Tanto no caso em que $N = 4$ quanto $N = 8$ observamos um sobressinal menor nas estimativas em relação aos valores corretos e uma convergência mais rápida. No entanto é importante notar que dobramos o número de modelos em relação ao caso em que $N = 4$ e obtivemos uma convergência apenas um pouco mais rápida. Isto sugere que a velocidade de convergência dos parâmetros está sujeita a uma lei de rendimentos decrescentes, no que se refere ao número de modelos.

Segundo Nível Modificado, Série-Paralelo, 3 Modelos

Consideramos que $y(0) = 0.2$, inicializamos os parâmetros do Modelo em $\hat{a}_{1,sp}(0) = 0.5$ e $\hat{k}_{1,sp}(0) = 1$, $\hat{a}_{2,sp}(0) = 0.5$ e $\hat{k}_{2,sp}(0) = 11$, $\hat{a}_{3,sp}(0) = 7$ e $\hat{k}_{3,sp}(0) = 1$, e os coeficientes da combinação convexa em $\alpha_{1,sp}(0) = 0.5$, $\alpha_{2,sp}(0) = 0.5$ e $\alpha_{3,sp}(0) = 0$. O sinal de entrada foi escolhido como $u(t) = 1$ que **não é PE de ordem 1** e o parâmetro $a_m = 4$.




Figura 2.6: Erros de Identificação usando 3 Modelos Série-Paralelos para a planta Σ_p , 36 segundos de simulação




Figura 2.7: Estimativas do parâmetro $a_p = 3$ para a planta Σ_p para 3 Modelos por Série-Paralelos e a estimativa de Segundo Nível Modificada, 36 segundos de simulação




Figura 2.8: Estimativas do parâmetro $k_p = 1.5$ para a planta Σ_p para 3 Modelos por Série-Paralelos e a estimativa de Segundo Nível Modificada, 36 segundos de simulação




Figura 2.9: Trajetória dos parâmetros $\hat{a}_{n2,sp}$ e $\hat{k}_{n2,sp}$ da Adaptação de Segundo Nível no espaço de parâmetros usando 3 Modelos Série-Paralelos para a planta Σ_p , 30 segundos de simulação

Verificamos que as amplitudes dos erros de identificação vão para 0 com $t = 5$ segundos na Figura 2.6 e as estimativas de primeiro nível se aproximam dos valores corretos nas Figuras 2.7 e 2.8 e depois param em sua vizinhança, enquanto que as estimativas de segundo nível em $t = 20$ alcançam os valores corretos. O trajeto no espaço de parâmetros pode ser visto na Figura 2.9. Após o regime permanente as estimativas se mantêm no segmento da reta de inclinação igual ao ganho em regime permanente da planta e que passa pelo ponto que contém os parâmetros corretos. Portanto a Adaptação de Segundo Nível Modificada com 3 Modelos de Primeiro Nível Série-Paralelo de uma Planta sujeita a um degrau unitário é adequada para a tarefa de identificação dos parâmetros. O processo de identificação continua a ser mais lento do que a dinâmica da planta e a convergência dos parâmetros se dá de fato após $t = 20$ segundos, porém dispensamos a exigência de um sinal PE de ordem 1.

Segundo Nível Modificado, Filtragem, 3 Modelos

Consideramos que $y(0) = 0$, inicializamos os parâmetros dos Modelos em $\hat{a}_{1,f}(0) = 0.5$ e $\hat{k}_{1,f}(0) = 1$, $\hat{a}_{2,f}(0) = 0.5$ e $\hat{k}_{2,f}(0) = 11$, $\hat{a}_{3,f}(0) = 7$ e $\hat{k}_{3,f}(0) = 1$, e os coeficientes da combinação convexa em $\alpha_{1,f}(0) = 0.5$, $\alpha_{2,f}(0) = 0.5$ e $\alpha_{3,f}(0) = 0$ e usamos o Método de Integração de Euler com passo fixo de 10^{-3} segundos e tempo de simulação de 36 segundos. O sinal de entrada foi escolhido como $u(t) = 1$ que **não é PE de ordem 1** e o parâmetro $\lambda = 4$, além disso escolhemos $\phi_1(0) = \phi_2(0) = 0$.




Figura 2.10: Erros de Identificação usando 3 Modelos por Regressão Linear para a planta Σ_p




Figura 2.11: Estimativas do parâmetro $a_p = 1.5$ para a planta Σ_p para 3 Modelos por Regressão Linear e a estimativa de Segundo Nível Modificada, 36 segundos de simulação




Figura 2.12: Estimativas do parâmetro $k_p = 1.5$ para a planta Σ_p para 3 Modelos por Regressão Linear e a estimativa de Segundo Nível Modificada, 36 segundos de simulação




Figura 2.13: Trajetória dos parâmetros $\hat{a}_{n2,f}$ e $\hat{k}_{n2,f}$ da Adaptação de Segundo Nível Modificada no espaço de parâmetros usando 3 Modelos por Regressão Linear para a planta Σ_p , aos 30 segundos de simulação

Verificamos que os erros de identificação rapidamente vão para 0 com $t \approx 5$ segundos na Figura 2.10 e as estimativas de primeiro nível ficaram mais próximas dos valores corretos nas Figuras 2.11 e 2.12. De fato as estimativas em regime permanente para um sinal de entrada do tipo degrau unitário sempre se localizam sobre a reta de inclinação igual ao ganho em regime permanente da planta e que passa pelo ponto que contém os parâmetros corretos. Isto acontece pois o degrau carrega apenas uma informação (a amplitude). A senoide carrega duas informações (amplitude e fase), de forma que uma senoide pode ser usada para identificar dois parâmetros. As estimativas de segundo nível em $t = 25$ segundos alcançam os valores corretos. Este resultado e o anterior são interessantes, e damos a

eles a seguinte interpretação: **as informações sobre os parâmetros da planta se encontram disponíveis durante o transitório. O transitório é o período de tempo em que todos os modos estão excitados. Armazenar as informações acerca do transitório da planta nos permite identificá-la univocamente.** O trajeto no espaço de parâmetros pode ser visto na Figura 2.13 e tem uma característica quase inteiramente linear, como no caso anterior. Portanto a Adaptação de Segundo Nível Modificada com 3 Modelos de Primeiro Nível por Regressão Linear de uma Planta Invariante no Tempo sujeita a um sinal que provoca excitação de seus modos durante um intervalo de tempo finito é adequada para a tarefa de Identificação de Parâmetros. O processo de identificação continua a ser mais lento do que a dinâmica da planta pois a convergência dos parâmetros se dá de fato após $t = 25$ segundos. No entanto não foi necessária a imposição de um sinal com persistência de excitação.

2.4 Conclusão

Neste capítulo apresentamos uma introdução a alguns Modelos de Identificação Convencionais usados na identificação dos parâmetros em tempo real de uma Planta Linear Invariante no Tempo. Mostramos como alguns destes Modelos podem servir como base para identificação através do conceito de Adaptação de Segundo Nível. Na Adaptação de Segundo Nível os coeficientes de uma combinação linear de múltiplos modelos são atualizados por uma lei integral e as estimativas são entregues por esta mesma combinação. O Modelo Série-Paralelo servirá como base para o caso em que o vetor de estado da planta de grau n e grau relativo unitário é acessível. O Modelo por Regressão Linear servirá como base para o caso em que apenas a entrada e a saída da planta de grau n e grau relativo unitário estão disponíveis para medição. Disponibilizamos os algoritmos em forma compacta em um resumo para que o leitor possa testar o conceito por si mesmo em simulação. Neste capítulo escolhemos um caso simples, uma planta de grau 1 com grau relativo unitário e estável e portanto com apenas dois parâmetros a serem estimados e com sinais limitados a priori. Desta forma esperamos que as características da Adaptação de Segundo Nível tenham ficado evidenciadas mais facilmente. Foram feitos estudos de simulação extensivos, nos quais avaliamos que a Adaptação de Segundo Nível dispõe de propriedades promissoras de velocidade de convergência em relação aos Modelos de Identificação Convencionais. Mostramos também que existe a possibilidade de identificar os parâmetros corretos na presença de um sinal de entrada sem persistência de excitação.

Capítulo 3

Estimação de Parâmetros, Ordem n

Continuamos então a estender resultados que obtivemos para plantas lineares invariantes no tempo de ordem 1 e grau relativo 1 para plantas lineares de ordem n e grau relativo 1. Apresentaremos o Modelo de Identificação Série-Paralelo aplicado a uma planta com vetor de estado acessível. Discutiremos também o caso do Modelo de Identificação por Regressão Linear aplicado à Planta quando apenas a entrada $u(t)$ e a saída $y(t)$ estão disponíveis para medição (SISO).

Em (Han & Narendra 2012, Narendra et al. 2012, Narendra et al. 2014) entre as hipóteses colocadas na modelagem do sistema estão a de que o vetor b do espaço de estado da planta é conhecido, e que as matrizes se encontram em forma companheira. Buscamos então o conceito de Adaptação de Segundo Nível para uma planta mais geral, assumindo apenas a hipótese de que os parâmetros da planta pertencem inicialmente ao fecho convexo formado pelos parâmetros dos Modelos de Primeiro Nível e que o vetor de estado da planta está acessível para medição. Isto leva naturalmente à Adaptação de Segundo Nível baseada em Modelos de Identificação Série-Paralelos aplicada ao caso da planta com vetor de estado acessível, que detalharemos neste capítulo.

Além disto, em (Narendra et al. 2015) uma extensão da Adaptação de Segundo Nível para o caso SISO foi apresentada, ainda baseada em Modelos de Primeiro Nível Série-Paralelos, onde a estabilidade dos modelos de identificação é garantida por uma matriz A_m escolhida pelo projetista. Isto faz com que a escolha das estimativas iniciais dos modelos precise cumprir duas condições simultâneas: A de formar um fecho convexo que contenha a região de incerteza dos parâmetros da planta e de que os Modelos de Identificação sejam estáveis. A escolha de parâmetros iniciais dos Modelos de Identificação Série-Paralelos para o número mínimo de modelos de identificação não é um problema trivial, especialmente a medida que a ordem da planta aumenta, como Narendra menciona em (Narendra 2016). Com isto em mente apresentamos o conceito de Adaptação de Segundo Nível baseada em Modelos de Identificação por Regressão Linear. Ao utilizar Modelos de Identificação por Regressão Linear, a estabilidade dos modelos independe da localização dos parâmetros escolhidos, desde que sejam limitados. Assim, é preciso cumprir apenas a condição de escolher as estimativas iniciais dos Modelos de Identificação tal que formem um fecho convexo que contenha a região de incerteza dos parâmetros da

planta. Isto facilita a escolha dos parâmetros iniciais.

Assim, tanto para o caso com vetor de estado acessível quanto para o caso SISO nos ocupamos de mostrar novamente que uma combinação convexa de coeficientes constantes das estimativas de Modelos de Primeiro Nível é equivalente a um Modelo de Primeiro Nível. Isto é estritamente verdadeiro quando os erros de identificação são inicialmente nulos. Mostramos também que mesmo que os erros não sejam inicialmente nulos, a combinação convexa dos erros de identificação tende a 0 exponencialmente dependendo de um parâmetro de projeto. Devido a esta propriedade é possível estimar os coeficientes da combinação convexa das estimativas dos Modelos de Primeiro Nível que produzem os parâmetros verdadeiros da planta. O resultado disto, como já vimos para a planta de ordem 1, é um ganho em rapidez de convergência das estimativas de segundo nível para seus valores corretos em relação às estimativas de primeiro nível. Ao obter uma convergência mais rápida dos parâmetros, a Adaptação de Segundo Nível pode ser usada para gerar um sinal de controle melhor no que tange a especificações como energia utilizada e overshoot, ao mesmo tempo que torna o transitório da planta mais rápido e mais suave como pode ser visto recentemente em (Pandey et al. 2017).

Finalmente, apresentamos a Adaptação de Segundo Nível com Fator de Esquecimento para ambos os casos. Demonstramos por simulação que a coleta de informações através de uma integral de convolução ao longo do transitório resulta numa melhora do resultado da Adaptação de Segundo Nível em termos de suavidade das estimativas e rapidez de convergência.

3.1 Planta com Vetor de Estado Acessível

3.1.1 Modelo de Identificação Série-Paralelo

Seja a planta linear invariante no tempo com múltiplas entradas e múltiplas saídas cujo vetor de estado está disponível para medição, descrita por:

$$\Sigma_p : \dot{x}_p = A_p x_p + B_p u$$

em que $x_p \in R^n$, $u \in R^p$, $A_p \in R^{n \times n}$, $B_p \in R^{n \times p}$. Os limitantes superiores a_{ij}^+ , b_{ij}^+ e inferiores a_{ij}^- , b_{ij}^- dos elementos das matrizes A_p e B_p são conhecidos. Desta forma as combinações de limitantes a_{ij}^+ e a_{ij}^- formam um politopo convexo que delimita a região de incerteza $S_{\theta,a} \in R^{n^2}$ para os elementos de A_p . As combinações de limitantes b_{ij}^+ e b_{ij}^- formam um politopo convexo que delimita a região de incerteza $S_{\theta,b} \in R^{np}$ para os elementos de B_p . Portanto as regiões de incerteza $S_{\theta,a}$ e $S_{\theta,b}$ são conhecidas. Podemos escrever:

$$\begin{aligned} \dot{x}_p &= A_p x_p + B_p u = A_p x_p + A_m x_p - A_m x_p + B_p u \\ \dot{x}_p - A_m x_p &= A_p x_p - A_m x_p + B_p u \end{aligned}$$

em que A_m é uma matriz escolhida pelo projetista cujos autovalores estão contidos no semi-plano esquerdo do plano complexo. Um Modelo de Identificação pode ser criado a partir da equação acima, substituindo x_p por uma estimativa de x_p no lado esquerdo da equação:

$$\Sigma_{1,sp} : \dot{\hat{x}}_{1,sp} - A_m \hat{x}_{1,sp} = \hat{A}_{1,sp} x_p - A_m x_p + \hat{B}_{1,sp} u$$

tal que:

$$\Sigma_{1,sp} : \dot{\hat{x}}_{1,sp} = A_m \hat{x}_{1,sp} + \hat{A}_{1,sp} x_p - A_m x_p + \hat{B}_{1,sp} u \quad (3.1)$$

e definimos o erro de identificação:

$$e_{1,sp} \triangleq \hat{x}_{1,sp} - x_p \quad (3.2)$$

e sua dinâmica é da forma:

$$\dot{e}_{1,sp} = \dot{\hat{x}}_{1,sp} - \dot{x}_p = A_m \hat{x}_{1,sp} + \hat{A}_{1,sp} x_p - A_m x_p + \hat{B}_{1,sp} u - A_p x_p - B_p u$$

e definimos os erros paramétricos:

$$\begin{aligned} \tilde{A}_{1,sp} &\triangleq \hat{A}_{1,sp} - A_p \\ \tilde{B}_{1,sp} &\triangleq \hat{B}_{1,sp} - B_p \end{aligned} \quad (3.3)$$

e escrevemos $\dot{e}_{1,sp}$ da seguinte forma:

$$\dot{e}_{1,sp} = A_m e_{1,sp} + \tilde{A}_{1,sp} y + \tilde{B}_{1,sp} u \quad (3.4)$$

e então, a partir de uma candidata a função de Lyapunov definida positiva da forma:

$$V(e_{1,sp}, \tilde{A}_{1,sp}, \tilde{B}_{1,sp}) = \frac{1}{2} (e_{1,sp}^T P e_{1,sp} + tr(\tilde{A}_{1,sp}^T \tilde{A}_{1,sp}) + tr(\tilde{B}_{1,sp}^T \tilde{B}_{1,sp})) \quad (3.5)$$

em que $tr(\cdot)$ denota o traço da matriz e $P = P^T > 0$ cumpre a equação de Lyapunov:

$$A_m^T P + P A_m = -2Q \quad (3.6)$$

com $Q = Q^T > 0$, derivamos ao longo das trajetórias:

$$\begin{aligned} \dot{V} &= \frac{1}{2} (\dot{e}_{1,sp}^T P e_{1,sp} + e_{1,sp}^T P \dot{e}_{1,sp}) + tr(\tilde{A}_{1,sp}^T \dot{\tilde{A}}_{1,sp}) + tr(\tilde{B}_{1,sp}^T \dot{\tilde{B}}_{1,sp}) \\ &= \frac{1}{2} ((A_m e_{1,sp} + \tilde{A}_{1,sp} x_p + \tilde{B}_{1,sp} u)^T P e_{1,sp} + e_{1,sp}^T P (A_m e_{1,sp} + \tilde{A}_{1,sp} x_p + \tilde{B}_{1,sp} u)) + \\ &\quad + tr(\tilde{A}_{1,sp}^T \dot{\tilde{A}}_{1,sp}) + tr(\tilde{B}_{1,sp}^T \dot{\tilde{B}}_{1,sp}) \\ \dot{V} &= -e_{1,sp}^T Q e_{1,sp} + x^T \tilde{A}_{1,sp}^T P e_{1,sp} + u^T \tilde{B}_{1,sp}^T P e_{1,sp} + tr(\tilde{A}_{1,sp}^T \dot{\tilde{A}}_{1,sp}) + tr(\tilde{B}_{1,sp}^T \dot{\tilde{B}}_{1,sp}) \end{aligned}$$

e como a planta é invariante no tempo:

$$\begin{aligned}\tilde{A}_{1,sp} &= \hat{A}_{1,sp} - A_p \rightarrow \dot{\tilde{A}}_{1,sp} = \dot{\hat{A}}_{1,sp} - \cancel{\dot{A}_p}^0 = \dot{\hat{A}}_{1,sp} \\ \tilde{B}_{1,sp} &= \hat{B}_{1,sp} - B_p \rightarrow \dot{\tilde{B}}_{1,sp} = \dot{\hat{B}}_{1,sp} - \cancel{\dot{B}_p}^0 = \dot{\hat{B}}_{1,sp}\end{aligned}$$

e como $tr(v_1 v_2^T) = v_2^T v_1$ para dois vetores coluna v_1 e v_2 quaisquer, podemos então escolher leis integrais para atualizar $\hat{A}_{1,sp}$ e $\hat{B}_{1,sp}$ tal que os termos de sinal indefinido em $\dot{V}$ sejam anulados:

$$\begin{aligned}\dot{\hat{A}}_{1,sp} &= -Pe_{1,sp}x_p^T \\ \dot{\hat{B}}_{1,sp} &= -Pe_{1,sp}u^T\end{aligned}\tag{3.7}$$

temos que $tr(\tilde{A}_{1,sp}^T Pe_{1,sp}x_p^T) = x_p^T \tilde{A}_{1,sp}^T Pe_{1,sp}$ e $tr(\tilde{B}_{1,sp}^T Pe_{1,sp}u^T) = u^T \tilde{B}_{1,sp}^T Pe_{1,sp}$, fazendo com que:

$$\dot{V} = -e_{1,sp}^T Q e_{1,sp} \leq 0\tag{3.8}$$

$\dot{V}$ é semi-definida negativa e portanto V não pode crescer, o que implica em:

$$\begin{aligned}e_{1,sp} &\in \mathcal{L}_\infty \\ \tilde{A}_{1,sp} &\in \mathcal{L}_\infty \rightarrow \hat{A}_{1,sp} \in \mathcal{L}_\infty \\ \tilde{B}_{1,sp} &\in \mathcal{L}_\infty \rightarrow \hat{B}_{1,sp} \in \mathcal{L}_\infty\end{aligned}$$

o sinal de controle u é escolhido tal que seus componentes sejam uniformemente limitados e o comportamento do sistema seja estável, no sentido de garantir que os componentes do vetor de estado x_p sejam uniformemente limitados:

$$\begin{aligned}x_p &\in \mathcal{L}_\infty \\ \dot{e}_{1,sp} &\in \mathcal{L}_\infty\end{aligned}$$

como $e_{1,sp} = \hat{x}_{1,sp} - x_p \in \mathcal{L}_\infty$ e $x_p \in \mathcal{L}_\infty$, temos que:

$$\hat{x}_{1,sp} \in \mathcal{L}_\infty$$

e finalmente, usando a desigualdade de Rayleigh:

$$\lambda_{\min}(Q)||e_{1,sp}||^2 \leq e_{1,sp}^T Q e_{1,sp} \leq \lambda_{\max}(Q)||e_{1,sp}||^2\tag{3.9}$$

manipulando a equação para $\dot{V}$:

$$\begin{aligned}
||e_{1,sp}||^2 &\leq -\frac{1}{\lambda_{\min}(Q)} \dot{V} \\
\int_0^\infty ||e_{1,sp}||^2 &\leq -\frac{1}{\lambda_{\min}(Q)} \int_0^\infty \dot{V} \\
\int_0^\infty ||e_{1,sp}||^2 &\leq -\frac{1}{\lambda_{\min}(Q)} (V(\infty) - V(0))
\end{aligned}$$

portanto:

$$e_{1,sp} \in \mathcal{L}_2$$

usando o lema de Barbalat, como $e_{1,sp}$ é uniformemente limitado, tem norma $\mathcal{L}_2$ uniformemente limitada e sua derivada é uniformemente limitada:

$$\lim_{t \rightarrow \infty} e_{1,sp} = \mathbf{0}$$

adicionalmente, quando o sinal de controle u for persistentemente excitante, teremos que $e_{1,sp} = \mathbf{0}$ para todo tempo $t > t_0$ sse $\tilde{A}_{1,sp} = \mathbf{0}$ e $\tilde{B}_{1,sp} = \mathbf{0}$ e os elementos das estimativas $\hat{A}_{1,sp}$ e $\hat{B}_{1,sp}$ tendem aos valores dos elementos de A_p e B_p respectivamente, para $t \rightarrow \infty$. É importante notar que usando o modelo série-paralelo o valor de $\dot{V}$ depende de A_m que é um parâmetro de projeto do estimador. Portanto a velocidade de convergência de $e_{1,sp}$ para $\mathbf{0}$ depende de um parâmetro de projeto. Para mais informações acerca deste modelo, referimos o leitor a (Narendra & Annaswamy 1989).

3.2 Caso SISO

3.2.1 Modelo de Identificação por Regressão Linear

Seja a planta linear invariante no tempo descrita pela seguinte função de transferência:

$$\Sigma_{p,SISO} : G_p(s) = \frac{y(s)}{u(s)} = \frac{N_p(s)}{D_p(s)}$$

em que:

$$\begin{aligned}
N_p(s) &= b_1 s^{n-1} + b_2 s^{n-2} + \dots + b_{n-1} s + b_n \\
D_p(s) &= s^n + a_1 s^{n-1} + a_2 s^{n-2} + \dots + a_{n-1} s + a_n
\end{aligned} \tag{3.10}$$

em que os limitantes superiores $b_1^+, \dots, b_n^+, a_1^+, a_n^+$ e inferiores $b_1^-, \dots, b_n^-, a_1^-, a_n^-$ dos coeficientes $b_1, \dots, b_n, a_1, \dots, a_n$ são conhecidos. Desta forma as combinações de limitantes $b_1^+, \dots, b_n^+, a_1^+, a_n^+$ e $b_1^-, \dots, b_n^-, a_1^-, a_n^-$ representam vértices de um politopo convexo que delimita a região de incerteza $S_{\theta,f} \in \mathbb{R}^{2n}$ dos coeficientes $b_1, \dots, b_n, a_1, \dots, a_n$. A região de incerteza $S_{\theta,f}$ é conhecida. Manipulando a função de transferência podemos escrever, no

domínio da frequência

$$s^n y(s) = -a_1 s^{n-1} y(s) - \dots - a_n y(s) + b_1 s^{n-1} u(s) + \dots + b_n u(s) \quad (3.11)$$

e definindo o seguinte polinômio com raízes negativas:

$$\Lambda(s) \triangleq s^n + \lambda_1 s^{n-1} + \lambda_2 s^{n-2} + \dots + \lambda_{n-1} s + \lambda_n \quad (3.12)$$

escrevemos:

$$\frac{s^n}{\Lambda(s)} y(s) = -a_1 \frac{s^{n-1}}{\Lambda(s)} y(s) - \dots - a_n \frac{1}{\Lambda(s)} y(s) + b_1 \frac{s^{n-1}}{\Lambda(s)} u(s) + \dots + b_n \frac{1}{\Lambda(s)} u(s)$$

e definimos:

$$\begin{aligned} z(s) &\triangleq \frac{s^n}{\Lambda(s)} y(s) \\ \phi(s) &\triangleq \left[\frac{-s^{n-1} y(s)}{\Lambda(s)} \quad \dots \quad \frac{-y(s)}{\Lambda(s)} \quad \frac{s^{n-1} u(s)}{\Lambda(s)} \quad \dots \quad \frac{u(s)}{\Lambda(s)} \right]^T \\ \theta_p^* &\triangleq [a_1 \quad \dots \quad a_n \quad b_1 \quad \dots \quad b_n]^T \end{aligned} \quad (3.13)$$

e temos a seguinte parametrização para a planta:

$$z(s) = \theta_p^{*T} \phi \quad (3.14)$$

e o vetor regressor ϕ pode ser gerado através de filtros de $y(t)$ e $u(t)$:

$$\begin{aligned} \dot{\phi}_1 &= \Lambda_c \phi_1 + l y \\ \dot{\phi}_2 &= \Lambda_c \phi_2 + l u \\ \phi &= [-\phi_1 \quad \phi_2]^T \end{aligned} \quad (3.15)$$

em que Λ_c e l são escolhidos de acordo com 3.12 e 4.13. Podemos criar um modelo de identificação a partir de uma combinação linear dos sinais componentes do vetor ϕ como:

$$\Sigma_{1,f} : \hat{z}_{1,f} = \hat{\theta}_{1,f}^T \phi \quad (3.16)$$

e definir um erro de identificação:

$$e_{1,f} \triangleq \hat{z}_{1,f} - z \quad (3.17)$$

então o erro de identificação normalizado pode ser construído:

$$\epsilon_{1,f} = \frac{e_{1,f}}{m^2} \quad (3.18)$$

onde $m^2 = 1 + n_s^2$ e n_s é chamado de sinal normalizador, escolhido tal que:

$$\frac{\phi}{m} \in \mathcal{L}_\infty$$

e uma escolha típica é $n_s = \phi^T \phi$. Definimos então o erro paramétrico:

$$\tilde{\theta}_{1,f} \triangleq \hat{\theta}_{1,f} - \theta_p^* \quad (3.19)$$

assim podemos expressar o erro de identificação normalizado:

$$\varepsilon_{1,f} = \frac{\tilde{\theta}_{1,f} \phi}{m^2} \quad (3.20)$$

seja então a função de custo:

$$J(\theta_{1,f}) = \frac{\varepsilon_{1,f}^2 m^2}{2} = \frac{(\theta_{1,f}^T \phi - z)^2}{2m^2} \quad (3.21)$$

gostaríamos de minimizar a função de custo em relação ao vetor $\theta_{1,f}$. Como $\frac{\phi}{m}$ é uniformemente limitado $J(\theta_{1,f})$ é convexa em $\theta_{1,f}$. Aplicando o método do gradiente a trajetória que minimiza $J(\theta_{1,f})$ é dada por:

$$\dot{\theta}_{1,f} = -\Gamma \nabla J(\theta_{1,f}) \quad (3.22)$$

onde $\Gamma = \Gamma^T > 0$ é uma matriz chamada matriz de ganhos adaptativos. Temos então que:

$$\nabla J(\theta_{1,f}) = \frac{(\theta_{1,f}^T \phi - z)\phi}{m^2} = \varepsilon_{1,f} \phi \quad (3.23)$$

que resulta na lei adaptativa:

$$\dot{\theta}_{1,f} = -\Gamma \varepsilon_{1,f} \phi \quad (3.24)$$

e como a planta é invariante no tempo θ_p^* é constante:

$$\dot{\tilde{\theta}}_{1,f} = -\Gamma \varepsilon_{1,f} \phi \quad (3.25)$$

escolhendo a candidata a função de Lyapunov:

$$V(\tilde{\theta}_{1,f}) = \frac{\tilde{\theta}_{1,f}^T \Gamma^{-1} \tilde{\theta}_{1,f}}{2} \quad (3.26)$$

temos que:

$$\dot{V} = \tilde{\theta}_{1,f}^T \phi \varepsilon_{1,f} = -\varepsilon_{1,f}^2 m^2 \leq 0 \quad (3.27)$$

$\tilde{\theta}_{1,f}$ é uniformemente limitado, que implica em $\varepsilon_{1,f}, \varepsilon_{1,f} m$ uniformemente limitados. Como no capítulo 1, este resultado implica que $\varepsilon_{1,f} m \in \mathcal{L}_2$. Apesar de não garantir diretamente que $\varepsilon_{1,f}$ tende para 0, se tivermos que $\frac{\dot{\phi}}{m}, \frac{\dot{m}}{m} \in \mathcal{L}_\infty$ é possível demonstrar que $\frac{d(\varepsilon_{1,f} m)}{dt} \in \mathcal{L}_\infty$ e aplicar o Lema de Barbalat. Para mais detalhes acerca deste Modelo de Identificação, referimos o leitor a (Ioannou & Sun 1996).

3.3 Estimação de Parâmetros de Segundo Nível

3.3.1 Planta com Vetor de Estado Acessível

N Modelos de Identificação Série-Paralelo

Seja, novamente, a planta linear invariante no tempo com múltiplas entradas e múltiplas saídas:

$$\Sigma_p : \dot{x}_p = A_p x_p + b_p u$$

em que $x_p \in R^n$, $u \in R^p$, $A_p \in R^{n \times n}$, $b_p \in R^n$. Os limitantes superiores a_{ij}^+ , b_i^+ e inferiores a_{ij}^- , b_i^- dos elementos das matrizes A_p e b_p são conhecidos. Desta forma as combinações de limitantes a_{ij}^+ e a_{ij}^- formam um politopo convexo que delimita região de incerteza $S_{\theta,a} \in R^{n^2}$ para os elementos de A_p . As combinações de limitantes b_i^+ e b_i^- formam um politopo convexo que delimita a região de incerteza $S_{\theta,b} \in R^n$ para os elementos de b_p . As regiões de incerteza $S_{\theta,a}$ e $S_{\theta,b}$ são conhecidas. Sejam os $N \geq n^2 + n + 1$ modelos de identificação:

$$\Sigma_{i,sp} : \dot{\hat{x}}_{i,sp} = A_m \hat{x}_{i,sp} + (\hat{A}_{i,sp} - A_m) x_p + \hat{b}_{i,sp} u \quad (3.28)$$

com $i = 1, \dots, N$, e os N erros de identificação:

$$e_{i,sp} = x_{i,sp} - x_p \quad (3.29)$$

definindo os N erros paramétricos:

$$\begin{aligned} \tilde{A}_{i,sp} &= \hat{A}_{i,sp} - A_p \\ \tilde{b}_{i,sp} &= \hat{b}_{i,sp} - b_p \end{aligned} \quad (3.30)$$

suas dinâmicas são representadas por:

$$\dot{e}_{i,sp} = A_m e_{i,sp} + \tilde{A}_{i,sp} x_p + \tilde{b}_{i,sp} u \quad (3.31)$$

e, como vimos anteriormente, as N matrizes estimativas podem ser atualizadas por:

$$\begin{aligned} \dot{\hat{A}}_{i,sp} &= -P e_{i,sp} x_p^T \\ \dot{\hat{b}}_{i,sp} &= -P e_{i,sp} u \end{aligned} \quad (3.32)$$

os elementos das matrizes $\hat{A}_{i,sp}$ e $\hat{b}_{i,sp}$, $i = 1, \dots, N$, formam um fecho convexo no espaço de parâmetros. Cada um dos pontos no interior ou fronteira deste fecho convexo pode ser

representado por uma combinação convexa:

$$\begin{aligned}\hat{A}_{v,sp} &= \sum_{i=1}^N \hat{A}_{i,sp} \beta_{i,sp} \\ \hat{b}_{v,sp} &= \sum_{i=1}^N \hat{b}_{i,sp} \beta_{i,sp} \\ \sum_{i=1}^N \beta_{i,sp} &= 1 \\ 0 &\leq \beta_{i,sp} \leq 1\end{aligned}\tag{3.33}$$

se criarmos então um **MODELO DE IDENTIFICAÇÃO VIRTUAL** a partir de alguma destas combinações convexas:

$$\Sigma_{v,sp} : \hat{x}_{v,sp} = A_m \hat{x}_{v,sp} + (\hat{A}_{v,sp} - A_m)x_p + \hat{b}_{v,sp}u\tag{3.34}$$

e definirmos o erro de identificação para o modelo virtual:

$$e_{v,sp} \triangleq \hat{x}_{v,sp} - x_p\tag{3.35}$$

e definindo os erros paramétricos:

$$\begin{aligned}\tilde{A}_{v,sp} &\triangleq \hat{A}_{v,sp} - A_p \\ \tilde{b}_{v,sp} &\triangleq \hat{b}_{v,sp} - b_p\end{aligned}\tag{3.36}$$

sua dinâmica é idêntica às dos modelos de primeiro nível:

$$\dot{e}_{v,sp} = A_m e_{v,sp} + \tilde{A}_{v,sp} x_p + \tilde{b}_{v,sp} u\tag{3.37}$$

pode-se manipular as expressões dos erros paramétricos:

$$\begin{aligned}\tilde{A}_{v,sp} &= \sum_{i=1}^N \hat{A}_{i,sp} \beta_{i,sp} - A_p = \sum_{i=1}^N \hat{A}_{i,sp} \beta_{i,sp} - \sum_{i=1}^N A_p \beta_{i,sp} = \sum_{i=1}^N \tilde{A}_{i,sp} \beta_{i,sp} \\ \tilde{b}_{v,sp} &= \sum_{i=1}^N \hat{b}_{i,sp} \beta_{i,sp} - b_p = \sum_{i=1}^N \hat{b}_{i,sp} \beta_{i,sp} - \sum_{i=1}^N b_p \beta_{i,sp} = \sum_{i=1}^N \tilde{b}_{i,sp} \beta_{i,sp}\end{aligned}\tag{3.38}$$

segue que as leis adaptativas que governam o ajuste de $A_{v,sp}$ e $b_{v,sp}$ são da forma:

$$\begin{aligned}\dot{\hat{A}}_{v,sp} &= \sum_{i=1}^N \dot{\hat{A}}_{i,sp} \beta_{i,sp} \\ \dot{\hat{b}}_{v,sp} &= \sum_{i=1}^N \dot{\hat{b}}_{i,sp} \beta_{i,sp}\end{aligned}\tag{3.39}$$

substituindo as expressões relevantes obtemos:

$$\begin{aligned}\dot{\hat{A}}_{v,sp} &= -P \sum_{i=1}^N e_{i,sp} \beta_{i,sp} x_p^T \\ \dot{\hat{b}}_{v,sp} &= -P \sum_{i=1}^N e_{i,sp} \beta_{i,sp} u\end{aligned}\tag{3.40}$$

assumindo que $x_p(0)$ é conhecido então é possível escolher $\hat{x}_{i,sp}(0) = \hat{x}_{v,sp}(0) = y(0)$ e ter que $e_{i,sp}(0) = e_{v,sp}(0) = \mathbf{0}$, com $i = 1, \dots, N$. Usando as expressões dos erros obtemos:

$$\begin{aligned}\sum_{i=1}^N \beta_{i,sp} \dot{e}_{i,sp} &= \sum_{i=1}^N \beta_{i,sp} A_m e_{i,sp} + \sum_{i=1}^N \beta_{i,sp} \tilde{A}_{i,sp} x_p + \sum_{i=1}^N \beta_{i,sp} \tilde{b}_{i,sp} u \\ \sum_{i=1}^N \beta_{i,sp} \dot{e}_{i,sp} &= A_m \sum_{i=1}^N \beta_{i,sp} e_{i,sp} + \tilde{A}_{v,sp} x_p + \tilde{b}_{v,sp} u\end{aligned}$$

e como $\sum_{i=1}^N \beta_{i,sp} e_{i,sp}(0) = e_{v,sp}(0) = \mathbf{0}$ temos que:

$$\sum_{i=1}^N \beta_{i,sp} e_{i,sp} \equiv e_{v,sp}\tag{3.41}$$

as expressões acima então se reduzem a:

$$\begin{aligned}\dot{\hat{A}}_{v,sp} &= -P e_{v,sp} x_p^T \\ \dot{\hat{b}}_{v,sp} &= -P e_{v,sp} u\end{aligned}\tag{3.42}$$

as leis adaptativas obtidas acima têm forma idêntica àquelas usadas nos modelos de primeiro nível $\Sigma_{i,sp}, i = 1, \dots, N$. **Cada um dos pontos no interior do fecho convexo corresponde a um modelo virtual.** Conforme os modelos de primeiro nível têm seus parâmetros ajustados adaptativamente os modelos virtuais também tem seus parâmetros ajustados por leis idênticas. Assim, **uma combinação convexa de coeficientes constantes dos parâmetros de modelos de primeiro nível se comporta da mesma forma que um modelo de primeiro nível cujos parâmetros fossem inicializados nos mesmos valores.** Assumindo, então, que os elementos das matrizes corretas A_p e b_p pertencem inicialmente ao fecho convexo, podem ser representados por uma combinação convexa de coeficientes $\alpha_{i,sp}^*, i = 1, \dots, N$, dos parâmetros dos modelos de primeiro nível:

$$\begin{aligned}
A_p &= \sum_{i=1}^N \hat{A}_{i,sp} \alpha_{i,sp}^* \\
b_p &= \sum_{i=1}^N \hat{b}_{i,sp} \alpha_{i,sp}^* \\
\sum_{i=1}^N \alpha_{i,sp}^* &= 1 \\
0 &\leq \alpha_{i,sp}^* \leq 1
\end{aligned} \tag{3.43}$$

e definimos o modelo virtual:

$$\Sigma_{\alpha,sp} : \dot{\hat{x}}_{\alpha,sp} = A_m \hat{x}_{\alpha,sp} + (A_p - A_m)x_p + b_p u \tag{3.44}$$

com erro de identificação:

$$e_{\alpha,sp} \triangleq \hat{x}_{\alpha,sp} - x_p \tag{3.45}$$

cujas dinâmica é simplesmente:

$$\dot{e}_{\alpha,sp} = A_m e_{\alpha,sp} \tag{3.46}$$

e como vimos as estimativas acima são atualizadas da mesma forma que seriam para um modelo de primeiro nível inicializado nos valores corretos. Podemos verificar pelas equações acima que um modelo inicializado nos valores corretos com erro de identificação inicialmente nulo tem erro de identificação identicamente nulo. Suas estimativas são identicamente os valores corretos. Temos então que:

$$e_{\alpha,sp} \equiv \mathbf{0} \tag{3.47}$$

e portanto se os parâmetros verdadeiros da planta pertencem inicialmente ao fecho convexo formado pelos parâmetros dos modelos de primeiro nível, devem fazê-lo para todo o tempo t.

Como vimos, se os parâmetros da planta pertencem ao fecho convexo formado pelos parâmetros dos modelos de primeiro nível, existe pelo menos uma combinação convexa de coeficientes $\alpha_{i,sp}^*, i = 1, \dots, N$, que caracteriza a planta para todo o tempo t, e portanto os coeficientes podem servir como uma alternativa de parametrização para a planta. Então, como uma segunda camada de estimação, ou **segundo nível de adaptação**, podemos estimar os coeficientes da combinação linear convexa. Assim, podemos estimar os coeficientes $\alpha_{i,sp}^*$ por:

$$e_{\alpha,sp} = \sum_{i=1}^N e_{i,sp} \alpha_{i,sp}^* = \mathbf{0}$$

e definindo:

$$\bar{E}_{sp} = [e_{1,sp} \quad e_{2,sp} \quad \dots \quad e_{N,sp}] \quad (3.48)$$

e:

$$\alpha_{sp}^* = [\alpha_{1,sp}^* \quad \alpha_{2,sp}^* \quad \dots \quad \alpha_{N,sp}^*] \quad (3.49)$$

podemos escrever em forma matricial:

$$\bar{E}_{sp} \bar{\alpha}_{sp}^* = \sum_{i=1}^N e_{i,sp} \alpha_{i,sp}^* = 0 \quad (3.50)$$

e definindo:

$$E_{sp} \triangleq [e_{1,sp} - e_{N,sp} \quad e_{2,sp} - e_{N,sp} \quad \dots \quad e_{N-1,sp} - e_{N,sp}] \quad (3.51)$$

e:

$$\alpha_{sp}^* \triangleq [\alpha_{1,sp}^* \quad \alpha_{2,sp}^* \quad \dots \quad \alpha_{N-1,sp}^*] \quad (3.52)$$

com estas variáveis definidas podemos escrever:

$$E_{sp} \alpha_{sp}^* = -e_{N,sp} \quad (3.53)$$

e substituindo o vetor α_{sp}^* por uma estimativa α_{sp} , como anteriormente, pode-se obter uma equação diferencial para estimar α_{sp}^* :

$$\dot{\alpha}_{sp} = -\gamma_{n2,sp} E_{sp}^T E_{sp} \alpha_{sp} - \gamma_{n2,sp} E_{sp}^T e_{N,sp} \quad (3.54)$$

em que $\gamma_{n2,sp} > 0$ é chamado ganho adaptativo de segundo nível e a estimativa $\bar{\alpha}_{sp}$ de $\bar{\alpha}_{sp}^*$ fica da forma:

$$\bar{\alpha}_{sp}^T = [\alpha_{sp}^T \quad 1 - \bar{\mathbf{1}} \alpha_{sp}] \quad (3.55)$$

onde $\bar{\mathbf{1}}$ é o vetor linha $[1 \quad 1 \quad \dots \quad 1]$ de tamanho apropriado. Definimos, então, o erro paramétrico para a estimativa $\bar{\alpha}_{sp}$ e para α_{sp} :

$$\begin{aligned} \tilde{\alpha}_{sp} &\triangleq \bar{\alpha}_{sp} - \bar{\alpha}_{sp}^* \\ \tilde{\alpha}_{sp} &\triangleq \alpha_{sp} - \alpha_{sp}^* \end{aligned} \quad (3.56)$$

e como $\bar{\alpha}_{sp}^*$ é invariante no tempo, escrevemos:

$$\begin{aligned} \dot{\tilde{\alpha}}_{sp} &= \dot{\alpha}_{sp} - \cancel{\dot{\alpha}_{sp}^*}^0 = \dot{\alpha}_{sp} \\ \dot{\tilde{\alpha}}_{sp} &= \dot{\alpha}_{sp} - \cancel{\dot{\alpha}_{sp}^*}^0 = \dot{\alpha}_{sp} \end{aligned} \quad (3.57)$$

tal que, substituindo $\dot{\alpha}_{sp}$ por $\dot{\tilde{\alpha}}_{sp}$ e α_{sp} por $\tilde{\alpha}_{sp} + \alpha_{sp}^*$ em 3.54 e cancelando os termos

equivalentes devido a 3.53, temos:

$$\dot{\tilde{\alpha}}_{sp} = -\gamma_{n2,sp} E_{sp}^T E_{sp} \tilde{\alpha}_{sp} \quad (3.58)$$

a partir de uma candidata a função de Lyapunov definida positiva:

$$V(\tilde{\alpha}_{sp}) = \frac{1}{2\gamma_{n2,sp}} \tilde{\alpha}_{sp}^T \tilde{\alpha}_{sp} \quad (3.59)$$

derivando ao longo das trajetórias teremos:

$$\dot{V} = -N \tilde{\alpha}_{sp}^T E_{sp}^T E_{sp} \tilde{\alpha}_{sp} \quad (3.60)$$

nesta expressão de $\dot{V}$ fica expressa uma característica importante da Adaptação de Segundo Nível, isto é, a velocidade com que a função de energia V decresce está relacionada com o número de modelos escolhidos, de forma que quanto mais modelos de identificação de primeiro nível forem usados, mais rápida será a convergência dos parâmetros. $\dot{V}$ é semi-definida negativa e portanto V não pode crescer, temos então que:

$$\tilde{\alpha}_{sp} \in \mathcal{L}_\infty \rightarrow \tilde{\alpha}_{sp} \in \mathcal{L}_\infty$$

e que:

$$\tilde{\alpha}_{sp} \in \mathcal{L}_\infty \rightarrow \bar{\alpha}_{sp} \in \mathcal{L}_\infty$$

$$\tilde{\alpha}_{sp} \in \mathcal{L}_\infty \rightarrow \alpha_{sp} \in \mathcal{L}_\infty$$

e como:

$$E_{sp}, \alpha_{sp} \in \mathcal{L}_\infty \rightarrow \dot{\alpha}_{sp}, \dot{\tilde{\alpha}}_{sp} \in \mathcal{L}_\infty$$

quando o sinal de controle u for persistentemente excitante teremos que E_{sp} só será a matriz nula a partir de algum instante qualquer se as estimativas dos parâmetros forem equivalentes aos parâmetros corretos A_p e b_p , o que indica que uma combinação convexa destes parâmetros também tenderá para os valores corretos. As estimativas dos parâmetros A_p e b_p da planta, $\hat{A}_{n2,sp}$ e $\hat{b}_{n2,sp}$ são entregues pela combinação convexa de coeficientes $\alpha_{i,sp}, i = 1, \dots, N$ dos parâmetros $\hat{A}_{i,sp}$ e $\hat{b}_{i,sp}, i = 1, \dots, N$:

$$\begin{aligned} \hat{A}_{n2,sp} &= \text{proj}_{S_{\theta,a}}(\alpha_{1,sp} \hat{A}_{1,sp} + \alpha_{2,sp} \hat{A}_{2,sp} + \dots + \alpha_{N,sp} \hat{A}_{N,sp}) \\ \hat{b}_{n2,sp} &= \text{proj}_{S_{\theta,b}}(\alpha_{1,sp} \hat{b}_{1,sp} + \alpha_{2,sp} \hat{b}_{2,sp} + \dots + \alpha_{N,sp} \hat{b}_{N,sp}) \end{aligned} \quad (3.61)$$

em que $\text{proj}_{S_{\theta,a}}(\cdot)$ é o operador de projeção retangular dentro da região de incerteza $S_{\theta,a}$ e $\text{proj}_{S_{\theta,b}}(\cdot)$ é o operador de projeção retangular dentro da região de incerteza $S_{\theta,b}$.

Adaptação de Segundo Nível com Fator de Esquecimento

No capítulo 1 vimos que é possível acumular informações sobre os erros de identificação dos modelos de primeiro nível de forma a melhorar a convergência das estimativas dos parâmetros para seus valores corretos. No entanto, estipulamos que era adequado integrar desde o instante inicial pois consideramos a planta invariante no tempo. Na prática o uso

de métodos de identificação em tempo real se dá quando os parâmetros da planta variam lentamente ou não há tempo hábil para usar métodos de identificação por batelada. Neste caso, integrar desde o instante inicial como fizemos no capítulo 1 não é adequado. Se os parâmetros da planta variam lentamente então acumular informações recentes melhora os resultados de convergência das estimativas dos parâmetros para seus valores corretos. No entanto, acumular informações mais antigas pode produzir piora dos resultados. Assim, se quisermos acumular informações, devemos buscar algum critério de descarte de informações. Então, chegamos ao seguinte raciocínio:

$$\begin{aligned}
E_{sp}^T E_{sp} \alpha_{sp}^* &= -E_{sp}^T e_{N,sp} \\
\int_0^t e^{-\sigma(t-\tau)} E_{sp}^T(\tau) E_{sp}(\tau) \alpha_{sp}^* d\tau &= -\int_0^t e^{-\sigma(t-\tau)} E_{sp}^T(\tau) e_{N,sp}(\tau) d\tau \\
\int_0^t e^{-\sigma(t-\tau)} E_{sp}^T(\tau) E_{sp}(\tau) d\tau \alpha_{sp}^* &= -\int_0^t e^{-\sigma(t-\tau)} E_{sp}^T(\tau) e_{N,sp}(\tau) d\tau \\
0 &= -\int_0^t e^{-\sigma(t-\tau)} E_{sp}^T(\tau) E_{sp}(\tau) d\tau \alpha_{sp}^* - \int_0^t e^{-\sigma(t-\tau)} E_{sp}^T(\tau) e_{N,sp}(\tau) d\tau \\
0 &= -\int_0^t e^{-\sigma(t-\tau)} E_{sp}^T(\tau) E_{sp}(\tau) d\tau \alpha_{sp}^* - E_{sp}^T E_{sp} \alpha_{sp}^* - \int_0^t e^{-\sigma(t-\tau)} E_{sp}^T(\tau) e_{N,sp}(\tau) d\tau - E_{sp}^T e_{N,sp}
\end{aligned}$$

onde $\sigma > 0$ é chamado fator de esquecimento. Como os erros de identificação são uniformemente limitados e tendem a 0 a medida que o tempo t tende a infinito, as integrais são limitadas e tendem a valores nulos. Substituindo α_{sp}^* por sua estimativa e introduzindo o ganho adaptativo temos a seguinte equação:

$$\begin{aligned}
\dot{\alpha}_{sp} &= \gamma_{n2,sp} \left(-\int_0^t e^{-\sigma(t-\tau)} E_{sp}^T(\tau) E_{sp}(\tau) d\tau \alpha_{sp} - E_{sp}^T E_{sp} \alpha_{sp} \right. \\
&\quad \left. - \int_0^t e^{-\sigma(t-\tau)} E_{sp}^T(\tau) e_{N,sp}(\tau) d\tau - E_{sp}^T e_{N,sp} \right)
\end{aligned}$$

por facilidade de notação, usamos variáveis para as integrais:

$$\begin{aligned}
M_{sp} &= \int_0^t e^{-\sigma(t-\tau)} E_{sp}^T(\tau) E_{sp}(\tau) d\tau \\
v_{sp} &= \int_0^t e^{-\sigma(t-\tau)} E_{sp}^T(\tau) e_{N,sp}(\tau) d\tau
\end{aligned} \tag{3.62}$$

que podem ser geradas diretamente estipulando $M_{sp}(0) = \mathbf{0}$ e $v_{sp}(0) = \mathbf{0}$ pelas equações

diferenciais:

$$\begin{aligned}\dot{M}_{sp} &= -\sigma M_{sp} + E_{sp}^T E_{sp} \\ \dot{v}_{sp} &= -\sigma v_{sp} + E_{sp}^T e_{N,sp}\end{aligned}\quad (3.63)$$

e escrevemos:

$$\dot{\alpha}_{sp} = \gamma_{n2,sp}(-M_{sp}\alpha_{sp} - E_{sp}^T E_{sp}\alpha_{sp} - v_{sp} - E_{sp}^T e_{N,sp}) \quad (3.64)$$

usamos então uma candidata a função de Lyapunov definida positiva:

$$V = \frac{1}{2\gamma_{n2,sp}} \tilde{\alpha}_{sp}^T \tilde{\alpha}_{sp} \quad (3.65)$$

que resulta em:

$$\dot{V} = -N\tilde{\alpha}_{sp}^T (E_{sp}^T E_{sp} + M_{sp}) \tilde{\alpha}_{sp} \quad (3.66)$$

com a modificação proposta, a convergência de α_{sp} para α_{sp}^* passa a depender de informações presentes e passadas. Se a razão entre o autovalor máximo e o autovalor mínimo de quaisquer das matrizes $E_{sp}^T E_{sp}, M_{sp}$ ou $E_{sp}^T E_{sp} + M_{sp}$ for adequada pode-se também calcular α_{sp}^* diretamente por inversão de matrizes.

3.3.2 Caso SISO

N Modelos de Identificação por Regressão Linear

Novamente, seja a planta:

$$\Sigma_{p,SISO} : G_p(s) = \frac{y(s)}{u(s)} = \frac{N_p(s)}{D_p(s)}$$

em que:

$$\begin{aligned}N_p(s) &= b_1 s^{n-1} + b_2 s^{n-2} + \dots + b_{n-1} s + b_n \\ D_p(s) &= s^n + a_1 s^{n-1} + a_2 s^{n-2} + \dots + a_{n-1} s + a_n\end{aligned}\quad (3.67)$$

em que os limitantes superiores $b_1^+, \dots, b_n^+, a_1^+, a_n^+$ e inferiores $b_1^-, \dots, b_n^-, a_1^-, a_n^-$ dos coeficientes $b_1, \dots, b_n, a_1, \dots, a_n$ são conhecidos. Desta forma as combinações de limitantes $b_1^+, \dots, b_n^+, a_1^+, a_n^+$ e $b_1^-, \dots, b_n^-, a_1^-, a_n^-$ representam vértices de um politopo convexo que delimita a região de incerteza $S_{\theta,f} \in R^{2n}$ dos coeficientes $b_1, \dots, b_n, a_1, \dots, a_n$. A região de incerteza $S_{\theta,f}$ é conhecida. E como definimos anteriormente:

$$\begin{aligned}z(s) &\triangleq \frac{s^n}{\Lambda(s)} y(s) \\ \phi(s) &\triangleq \begin{bmatrix} \frac{-s^{n-1}y(s)}{\Lambda(s)} & \dots & \frac{-y(s)}{\Lambda(s)} & \frac{s^{n-1}u(s)}{\Lambda(s)} & \dots & \frac{u(s)}{\Lambda(s)} \end{bmatrix}^T \\ \theta_p^* &\triangleq [a_1 \quad \dots \quad a_n \quad b_1 \quad \dots \quad b_n]^T\end{aligned}$$

e o vetor regressor ϕ é gerado pela seguinte equação:

$$\begin{aligned}\dot{\phi}_1 &= \Lambda_c \phi_1 + ly \\ \dot{\phi}_2 &= \Lambda_c \phi_2 + lu \\ \phi &= [-\phi_1 \quad \phi_2]^T\end{aligned}\tag{3.68}$$

em que Λ_c e l são escolhidos de acordo com 3.12 e 4.13. Temos a seguinte parametrização:

$$z(s) = \theta_p^{*T} \phi$$

e os $i = 1, \dots, N$ modelos de identificação deste sinal:

$$\Sigma_{i,f} : \hat{z}_{i,f} = \hat{\theta}_{i,f}^T \phi\tag{3.69}$$

e os $i = 1, \dots, N$ erros paramétricos:

$$\tilde{\theta}_{i,f} = \hat{\theta}_{i,f} - \theta_p^*\tag{3.70}$$

definimos os $i = 1, \dots, N$ erros de identificação deste sinal:

$$e_{i,f} \triangleq \hat{z}_{i,f} - z\tag{3.71}$$

os erros de identificação normalizados são da forma:

$$\epsilon_{i,f} = \frac{e_{i,f}}{m^2}\tag{3.72}$$

onde $m^2 = 1 + n_s^2$ e n_s escolhido tal que:

$$\frac{\phi}{m} \in \mathcal{L}_\infty$$

e temos que:

$$\epsilon_{i,f} = \frac{\tilde{\theta}_{i,f}^T \phi}{m^2}\tag{3.73}$$

e os vetores de parâmetros $\hat{\theta}_{i,f}$, $i = 1, \dots, N$, são adaptados de acordo com o método do gradiente:

$$\dot{\hat{\theta}}_{i,f} = -\Gamma \epsilon_{i,f} \phi\tag{3.74}$$

a partir desta lei adaptativa obtemos uma expressão para as dinâmicas $\dot{e}_{i,f}$:

$$\dot{e}_{i,f} = \dot{\hat{\theta}}_{i,f}^T \phi + \tilde{\theta}_{i,f}^T \dot{\phi} = -\frac{1}{m^2} e_{i,f} \phi^T \Gamma \phi + \tilde{\theta}_{i,f}^T \dot{\phi}\tag{3.75}$$

os vetores de parâmetros $\hat{\theta}_{i,f}$, $i = 1, \dots, N$ formam um fecho convexo no espaço de parâmetros. Cada um dos pontos no interior ou fronteira deste fecho convexo pode ser

representado por uma combinação convexa:

$$\begin{aligned}\hat{\theta}_{v,f} &= \sum_{i=1}^N \hat{\theta}_{i,f} \beta_{i,f} \\ \sum_{i=1}^N \beta_{i,f} &= 1 \\ 0 &\leq \beta_{i,f} \leq 1\end{aligned}\tag{3.76}$$

se criarmos então um **MODELO DE IDENTIFICAÇÃO VIRTUAL** a partir de alguma destas combinações convexas:

$$\Sigma_{v,f} : \hat{z}_{v,f} = \theta_{v,f}^T \phi \tag{3.77}$$

e definirmos o erro de identificação para o modelo virtual:

$$e_{v,f} \triangleq \hat{z}_{v,f} - z \tag{3.78}$$

e definindo o erro paramétrico:

$$\tilde{\theta}_{v,f} = \hat{\theta}_{v,f} - \theta_p^* \tag{3.79}$$

a dinâmica do erro de identificação $e_{v,f}$ é:

$$\dot{e}_{v,f} = \dot{\tilde{\theta}}_{v,f}^T \phi + \tilde{\theta}_{v,f}^T \dot{\phi} \tag{3.80}$$

podemos manipular as expressões dos erros paramétricos:

$$\tilde{\theta}_{v,f} = \sum_{i=1}^N \hat{\theta}_{i,f} \beta_{i,f} - \theta_p^* = \sum_{i=1}^N \hat{\theta}_{i,f} \beta_{i,f} - \sum_{i=1}^N \theta_p^* \beta_{i,f} = \sum_{i=1}^N \tilde{\theta}_{i,f} \beta_{i,f} \tag{3.81}$$

segue que a lei adaptativa que governa o ajuste de $\hat{\theta}_{v,f}$ é da forma:

$$\dot{\hat{\theta}}_{v,f} = \sum_{i=1}^N \dot{\hat{\theta}}_{i,f} \beta_{i,f} = -\Gamma \sum_{i=1}^N \epsilon_{i,f} \beta_{i,f} \phi \tag{3.82}$$

e temos que:

$$\dot{e}_{v,f} = -\frac{1}{m^2} \sum_{i=1}^N e_{i,f} \beta_{i,f} \phi^T \Gamma \phi + \sum_{i=1}^N \tilde{\theta}_{i,f}^T \beta_{i,f} \dot{\phi} \tag{3.83}$$

no entanto não dispomos de uma expressão no tempo para os erros de identificação. Utilizamos, assim, as expressões das dinâmicas dos erros de identificação $\dot{e}_{i,f}$, temos que a

combinação convexa $\sum_{i=1}^N \dot{e}_{i,f} \beta_{i,f}$ é da forma:

$$\sum_{i=1}^N \dot{e}_{i,f} \beta_{i,f} = \sum_{i=1}^N \dot{\tilde{\theta}}_{i,f}^T \beta_{i,f} \phi + \sum_{i=1}^N \tilde{\theta}_{i,f}^T \beta_{i,f} \dot{\phi} = \dot{e}_{v,f} \tag{3.84}$$

ou seja, a dinâmica $\frac{d}{dt}(\sum_{i=1}^N e_{i,f}\beta_{i,f})$ da combinação convexa $\sum_{i=1}^N e_{i,f}\beta_{i,f}$ é exatamente igual à dinâmica do erro de identificação do modelo virtual $e_{v,f}$. A combinação convexa dos erros de identificação tende exponencialmente para o valor do erro de identificação do modelo virtual. Se estipularmos que $e_{v,f}(0) = \sum_{i=1}^N e_{i,f}(0)\beta_{i,f}$ então os dois se tornam equivalentes. Assim $\varepsilon_{v,f}$ se torna equivalente a $\sum_{i=1}^N \varepsilon_{i,f}\beta_{i,f}$. Feitas estas considerações, teremos então que a expressão da lei adaptativa para o modelo virtual se reduz a:

$$\dot{\hat{\theta}}_{v,f} = -\Gamma \varepsilon_{v,f} \phi \quad (3.85)$$

e novamente, a lei adaptativa obtida acima tem forma idêntica àquela usada nos modelos de primeiro nível $\Sigma_{i,f}$, $i = 1, \dots, N$. **Cada um dos pontos no interior do fecho convexo corresponde a um modelo virtual.** Conforme os modelos de primeiro nível têm seus parâmetros ajustados adaptativamente os modelos virtuais também tem seus parâmetros ajustados por leis idênticas. Nestas condições, **uma combinação convexa de coeficientes constantes dos parâmetros de modelos de primeiro nível se comporta como se fosse os parâmetros de um modelo de primeiro nível inicializados nos mesmos valores.** Assumindo, então, que os parâmetros verdadeiros da planta contidos no vetor θ_p^* pertencem inicialmente ao fecho convexo, podem ser representados por uma combinação convexa de coeficientes $\alpha_{i,f}^*, i = 1, \dots, N$ dos parâmetros dos modelos de primeiro nível:

$$\begin{aligned} \theta_p^* &= \sum_{i=1}^N \hat{\theta}_{i,f} \alpha_{i,f}^* \\ \sum_{i=1}^N \alpha_{i,f}^* &= 1 \\ 0 &\leq \alpha_{i,f}^* \leq 1 \end{aligned} \quad (3.86)$$

e definimos o modelo virtual:

$$\Sigma_{\alpha,f} : \hat{z}_{\alpha,f} = \theta_p^{*T} \phi \quad (3.87)$$

com erro de identificação:

$$e_{\alpha,f} \triangleq \hat{z}_{\alpha,f} - z \quad (3.88)$$

cuja dinâmica é:

$$\dot{e}_{\alpha,f} = -\frac{1}{m^2} e_{\alpha,f} \phi^T \Gamma \phi \quad (3.89)$$

que nos dá o seguinte resultado, caso $\lim_{t \rightarrow \infty} \phi \neq \mathbf{0}$:

$$\lim_{t \rightarrow \infty} e_{\alpha,f} = \lim_{t \rightarrow \infty} \sum_{i=1}^N e_{i,f} \alpha_{i,f}^* = 0 \quad (3.90)$$

desta forma, os parâmetros da planta podem deixar de pertencer ao fecho convexo devido ao efeito das condições iniciais. No entanto este resultado indica que os parâmetros da planta voltam a pertencer ao fecho convexo. Se a combinação convexa dos erros de identificação não-nulos se torna constante e nula a partir de um certo instante então a combinação convexa dos erros paramétricos também se torna constante e nula. Desta forma os coeficientes $\alpha_{i,f}^*, i = 1, \dots, N$ servem como alternativas de parametrização para a planta. Assim, como uma segunda camada de estimação, ou **segundo nível de adaptação**, podemos estimar os coeficientes da combinação linear. Consideramos, portanto, que a equação $\sum_{i=1}^N e_{i,f} \alpha_{i,f}^* = 0$ é uma ferramenta adequada de estimação. Definimos:

$$\bar{E}_f = [\epsilon_{1,f} \quad \dots \quad \epsilon_{N-1,f} \quad \epsilon_{N,f}] \quad (3.91)$$

e:

$$\bar{\alpha}_f^* = [\alpha_{1,f}^* \quad \dots \quad \alpha_{N-1,f}^*] \quad (3.92)$$

tal que temos em forma matricial:

$$\bar{E}_f \bar{\alpha}_f^* = \sum_{i=1}^N \epsilon_{i,f} \alpha_{i,f}^* = 0 \quad (3.93)$$

pela combinação convexa temos que:

$$\sum_{i=1}^N \alpha_{i,f} = 1$$

então o parâmetro $\alpha_{N,f}^*$ pode ser expresso por:

$$\alpha_{N,f} = 1 - \sum_{i=1}^{N-1} \alpha_{i,f}^*$$

e explicitando o último termo do somatório em $\bar{E}_f \bar{\alpha}_f^*$:

$$\bar{E}_f \bar{\alpha}_f^* = \sum_{i=1}^{N-1} \epsilon_{i,f} \alpha_{i,f}^* + \epsilon_{N,f} \alpha_{N,f}^*$$

e então substituímos $\alpha_{N,f}$ por sua expressão:

$$\bar{E}_f \bar{\alpha}_f^* = \sum_{i=1}^{N-1} \epsilon_{i,f} \alpha_{i,f}^* + \epsilon_{N,f} (1 - \sum_{i=1}^{N-1} \alpha_{i,f}^*) = 0$$

que reorganizado fica da seguinte forma:

$$\sum_{i=1}^{N-1} (\epsilon_{i,f} - \epsilon_{N,f}) \alpha_{i,f}^* = -\epsilon_{N,f} \quad (3.94)$$

e definimos:

$$E_f = [\epsilon_{1,f} - \epsilon_{N,f} \quad \epsilon_{2,f} - \epsilon_{N,f} \quad \dots \quad \epsilon_{N-1,f} - \epsilon_{N,f}] \quad (3.95)$$

e:

$$\alpha_f^* = [\alpha_{1,f}^* \quad \alpha_{2,f}^* \quad \dots \quad \alpha_{N-1,f}^*] \quad (3.96)$$

com estas variáveis definidas, reescrevemos a equação como:

$$E_f \alpha_f^* = -\epsilon_{N,f} \quad (3.97)$$

e substituindo o vetor α_f^* por uma estimativa α_f , como anteriormente, pode-se obter uma equação diferencial para estimar α_f^* :

$$\dot{\alpha}_f = -\gamma_{n2,f} E_f^T E_f \alpha_f - \gamma_{n2,f} E_f^T \epsilon_{N,f} \quad (3.98)$$

onde $\gamma_{n2,f} > 0$ e a estimativa $\tilde{\alpha}_f$ de α_f^* fica da forma:

$$\tilde{\alpha}_f^T = [\alpha_f^T \quad 1 - \vec{1}\alpha_f] \quad (3.99)$$

onde $\vec{1}$ é o vetor linha $[1 \quad 1 \quad \dots \quad 1]$ de tamanho apropriado. Definimos, então, o erro paramétrico para a estimativa $\tilde{\alpha}_f$ e para α_f :

$$\begin{aligned} \tilde{\tilde{\alpha}}_f &\triangleq \tilde{\alpha}_f - \alpha_f^* \\ \tilde{\alpha}_f &\triangleq \alpha_f - \alpha_f^* \end{aligned} \quad (3.100)$$

e como assumimos $\tilde{\alpha}_f^*$ invariante no tempo, escrevemos:

$$\begin{aligned} \dot{\tilde{\tilde{\alpha}}}_f &= \dot{\tilde{\alpha}}_f - \cancel{\dot{\alpha}_f^*}^0 = \dot{\tilde{\alpha}}_f \\ \dot{\tilde{\alpha}}_f &= \dot{\alpha}_f - \cancel{\dot{\alpha}_f^*}^0 = \dot{\alpha}_f \end{aligned} \quad (3.101)$$

tal que, substituindo $\dot{\alpha}_f$ por $\dot{\tilde{\alpha}}_f$ e α_f por $\tilde{\alpha}_f + \alpha_f^*$ em 4.31 e cancelando os termos equivalentes devido a 3.97, temos:

$$\dot{\tilde{\tilde{\alpha}}}_f = -\gamma_{n2,f} E_f^T E_f \tilde{\alpha}_f - \gamma_{n2,f} E_f^T e_{\alpha,f} \frac{1}{m^2} \quad (3.102)$$

onde o termo $-\gamma_{n2,f} E_f^T e_{\alpha,f} \frac{1}{m^2}$ aparece devido às condições iniciais. E a partir de uma candidata a função de Lyapunov definida positiva:

$$V(\tilde{\alpha}_f) = \frac{1}{2\gamma_{n2,f}} \tilde{\alpha}_f^T \tilde{\alpha}_f \quad (3.103)$$

derivando ao longo das trajetórias teremos:

$$\dot{V} = \frac{1}{\gamma_{n2,f}} \tilde{\alpha}_f^T \dot{\tilde{\tilde{\alpha}}}_f$$

e explicitando $\tilde{\alpha}_f$ e $\dot{\tilde{\alpha}}_f$:

$$\dot{V} = \begin{bmatrix} \tilde{\alpha}_f^T & \mathbf{1}^T \tilde{\alpha}_f \end{bmatrix} \begin{bmatrix} \dot{\tilde{\alpha}}_f^T \\ \mathbf{1}^T \dot{\tilde{\alpha}}_f \end{bmatrix}$$

ao substituirmos $\tilde{\alpha}_f$ por 3.102 e reorganizarmos, obtemos:

$$\dot{V} = -N\tilde{\alpha}_f^T E_f^T E_f \tilde{\alpha}_f - N\tilde{\alpha}_f^T E_f^T e_{\alpha,f} \frac{1}{m^2} \quad (3.104)$$

e pode-se sempre escolher $\Lambda(s)$ tal que o termo de sinal indefinido $-N\tilde{\alpha}_f^T E_f^T e_{\alpha,f} \frac{1}{m^2}$ tenda para 0 mais rapidamente que o termo de sinal definido. Nesta expressão de $\dot{V}$ fica expresso novamente que a rapidez de convergência dos parâmetros depende do número de modelos N . V não pode crescer a partir de um certo instante, temos então que:

$$\tilde{\alpha}_f \in \mathcal{L}_\infty \rightarrow \tilde{\alpha}_f \in \mathcal{L}_\infty$$

e que:

$$\tilde{\alpha}_f \in \mathcal{L}_\infty \rightarrow \tilde{\alpha}_f \in \mathcal{L}_\infty$$

$$\tilde{\alpha}_f \in \mathcal{L}_\infty \rightarrow \alpha_f \in \mathcal{L}_\infty$$

e como:

$$E_f, \alpha_f \in \mathcal{L}_\infty \rightarrow \dot{\alpha}_f, \dot{\tilde{\alpha}}_f \in \mathcal{L}_\infty$$

quando o sinal de controle u for persistentemente excitante teremos que E_f só será o vetor nulo a partir de algum instante quando as estimativas forem equivalentes aos parâmetros corretos, o que indica que uma combinação convexa destes parâmetros também tenderá para os valores corretos. A estimativa do vetor de parâmetros θ_p^* da planta, $\hat{\theta}_{n2,f}$ é entregue pela combinação convexa de coeficientes $\alpha_{i,f}, i = 1, \dots, N$ dos parâmetros $\hat{\theta}_{i,f}, i = 1, \dots, N$:

$$\hat{\theta}_{n2,f} = \text{proj}_{S_{\theta,f}}(\alpha_{1,f}\hat{\theta}_{1,f} + \alpha_{2,f}\hat{\theta}_{2,f} + \dots + \alpha_{N,f}\hat{\theta}_{N,f}) \quad (3.105)$$

em que $\text{proj}_{S_{\theta,f}}(\cdot)$ é o operador de projeção retangular dentro da região de incerteza $S_{\theta,f}$.

Comentário acerca da escolha dos parâmetros iniciais

Diferentemente dos Modelos de Identificação Série-Paralelos, as saídas $z_{i,f}(t)$ dos Modelos de Identificação por Regressão Linear são limitadas independentemente do valor dos parâmetros iniciais escolhidos, desde que sejam limitados, devido ao fato de que utilizamos o erro de identificação normalizado para atualizar os valores dos parâmetros e os sinais $z_{i,f}(t)$ serem gerados por regressão linear. Isto permite, por exemplo, a escolha de modelos com grandes diferenças de valores entre seus parâmetros iniciais ou que representam plantas instáveis sem maiores preocupações. Comparado com Modelos Série-Paralelos, a escolha de parâmetros iniciais muito discrepantes pode gerar problemas de atenuação excessiva dos erros de identificação $e_{i,sp}$ ao escolher uma matriz A_m

que seja simultaneamente capaz de estabilizar modelos de identificação com parâmetros iniciais muito grandes e parâmetros iniciais muito pequenos em módulo. Para ilustrar, considere a seguinte planta instável de ordem 1:

$$\Sigma_p : G(s) = \frac{b}{s+a} = \frac{20}{s-50}$$

vamos assumir que o sinal $u(t)$ é tal que a saída $y(t)$ da planta é limitada. Sabemos que $b \in [19 \ 21]$ e $a \in [-1 \ -1000]$. Podemos escolher os seguintes 4 pares de estimativas iniciais dos parâmetros da planta, tal que a região de incerteza dos parâmetros esteja contida no fecho convexo: $b_1 = 19, a_1 = -1, b_2 = 19, a_2 = -1000, b_3 = 21, a_3 = -1, b_4 = 21, a_4 = -1000$. Se os modelos forem do tipo Série-Paralelo, será necessário escolher um parâmetro $a_m > 1000$ de forma a tornar os modelos 2 e 4 estáveis. No entanto, neste caso teremos $|a_m| \gg |a_1|$ e $|a_m| \gg |a_3|$, o que fará com que os erros $e_{1,sp}$ e $e_{3,sp}$ sejam praticamente nulos, tornando a adaptação dos modelos 1 e 3 extremamente lenta. No entanto, se forem usados Modelos por Regressão Linear, a escolha de um polinômio com raiz que seja, em módulo, comparativamente pequena aos limitantes superiores, como por exemplo $\Lambda(s) = s + 1$, não tornará os modelos 2 e 4 instáveis.

Adaptação de Segundo Nível com Fator de Esquecimento

No capítulo 1 vimos que é possível acumular informações sobre os erros de identificação dos modelos de primeiro nível de forma a melhorar a convergência das estimativas dos parâmetros para seus valores corretos. No entanto, estipulamos que era adequado integrar desde o instante inicial pois consideramos a planta invariante no tempo. Na prática o uso de métodos de identificação em tempo real se dá quando os parâmetros da planta variam lentamente ou não há tempo hábil para usar métodos de identificação por batelada. Neste caso, integrar desde o instante inicial como fizemos no capítulo 1 não é adequado. Se os parâmetros da planta variam lentamente então acumular informações recentes melhora os resultados de convergência das estimativas dos parâmetros para seus valores corretos. No entanto, acumular informações mais antigas pode produzir piora dos resultados. Assim, se quisermos acumular informações, devemos buscar um critério de descarte de informações. Como anteriormente no caso da planta com vetor de estado acessível, chegamos ao seguinte raciocínio:

$$\begin{aligned}
E_f^T E_f \alpha_f^* &= -E_f^T \varepsilon_{N,f} \\
\int_0^t e^{-\sigma(t-\tau)} E_f^T(\tau) E_f(\tau) \alpha_f^* d\tau &= -\int_0^t e^{-\sigma(t-\tau)} E_f^T(\tau) \varepsilon_{N,f}(\tau) d\tau \\
\int_0^t e^{-\sigma(t-\tau)} E_f^T(\tau) E_f(\tau) d\tau \alpha_f^* &= -\int_0^t e^{-\sigma(t-\tau)} E_f^T(\tau) \varepsilon_{N,f}(\tau) d\tau \\
0 &= -\int_0^t e^{-\sigma(t-\tau)} E_f^T(\tau) E_f(\tau) d\tau \alpha_f^* - \int_0^t e^{-\sigma(t-\tau)} E_f^T(\tau) \varepsilon_{N,f}(\tau) d\tau \\
0 &= -\int_0^t e^{-\sigma(t-\tau)} E_f^T(\tau) E_f(\tau) d\tau \alpha_f^* - E_f^T E_f \alpha_f^* - \int_0^t e^{-\sigma(t-\tau)} E_f^T(\tau) \varepsilon_{N,f}(\tau) d\tau - E_f^T \varepsilon_{N,f}
\end{aligned}$$

onde $\sigma > 0$ é chamado fator de esquecimento. Como os erros de identificação são uniformemente limitados e tendem a 0 a medida que o tempo t tende a infinito, as integrais são limitadas e tendem a valores nulos. Substituindo α_f^* por sua estimativas e introduzindo o ganho adaptativo temos a seguinte equação:

$$\dot{\alpha}_f = \gamma_{n2,f} \left(-\int_0^t e^{-\sigma(t-\tau)} E_f^T(\tau) E_f(\tau) d\tau \alpha_f - E_f^T E_f \alpha_f - \int_0^t e^{-\sigma(t-\tau)} E_f^T(\tau) \varepsilon_{N,f}(\tau) d\tau - E_f^T \varepsilon_{N,f} \right)$$

por facilidade de notação, usamos variáveis para as integrais:

$$\begin{aligned}
M_f &= \int_0^t e^{-\sigma(t-\tau)} E_f^T(\tau) E_f(\tau) d\tau \\
v_f &= \int_0^t e^{-\sigma(t-\tau)} E_f^T(\tau) \varepsilon_{N,f}(\tau) d\tau
\end{aligned} \tag{3.106}$$

que podem ser geradas diretamente estipulando $M_f(0) = \mathbf{0}$ e $v_f(0) = \mathbf{0}$ pelas equações diferenciais:

$$\begin{aligned}
\dot{M}_f &= -\sigma M_f + E_f^T E_f \\
\dot{v}_f &= -\sigma v_f + E_f^T \varepsilon_{N,f}
\end{aligned} \tag{3.107}$$

e escrevemos:

$$\dot{\alpha}_f = \gamma_{n2,f} (-M_f \alpha_f - E_f^T E_f \alpha_f - v_f - E_f^T \varepsilon_{N,f}) \tag{3.108}$$

usamos então uma candidata a função de Lyapunov definida positiva:

$$V = \frac{1}{2\gamma_{n2,f}} \tilde{\alpha}_f^T \tilde{\alpha}_f \quad (3.109)$$

que resulta em:

$$\dot{V} = -N\tilde{\alpha}_f^T(E_f^T E_f + M_f)\tilde{\alpha}_f - N\tilde{\alpha}_f^T E_f^T e_{\alpha,f} \frac{1}{m^2} - N\tilde{\alpha}_f^T M_f \alpha_f^* \quad (3.110)$$

temos que $N\tilde{\alpha}_f^T M_f \alpha_f^* = N \int_0^t e^{-\sigma(t-\tau)} E_f^T(\tau) e_{\alpha}(\tau) d\tau$. Novamente, sempre é possível escolher $\Lambda(s)$ tal que os termos de sinal indefinido $-N\tilde{\alpha}_f^T E_f^T e_{\alpha,f} - N\tilde{\alpha}_f^T M_f \alpha_f^*$ tendam para 0 mais rapidamente que o termo de sinal definido $-N\tilde{\alpha}_f^T (E_f^T E_f + M_f) \tilde{\alpha}_f$. Dizemos isto pois os termos de sinal indefinido dependem das condições iniciais, que estão embutidas no escalar $e_{\alpha,f}$, que decai exponencialmente. Com a modificação proposta a convergência de α_f para α_f^* passa a depender de informações presentes e passadas. Outra forma de calcular os coeficientes corretos é monitorando os autovalores de M_f . Se a razão entre o autovalor máximo e o autovalor mínimo da matriz M_f for adequada pode-se calcular α_f^* diretamente por inversão de matrizes resolvendo o sistema de equações $M_f \alpha_f^* = -v_f$ para α_f^* .

3.4 Resumo dos Algoritmos e Estudos de Simulação

Apresentamos o Modelo de Identificação Série-Paralelo para a planta com vetor de estado acessível e o Modelo de Identificação por Regressão Linear para a planta SISO neste segundo capítulo. Discutimos algumas de suas propriedades para a planta estável de ordem n e grau relativo 1. Mostramos que o erro de identificação tende a 0 para estes modelos. Mencionamos que as estimativas tendem aos valores corretos na presença de um sinal de entrada com a característica de persistência de excitação. Provamos, para os Modelos de Primeiro Nível que existem coeficientes constantes de uma combinação convexa das estimativas dos parâmetros de N ou mais Modelos que produzem os parâmetros da planta. Demonstramos como uma **segunda camada de adaptação**, ou uma **adaptação em dois níveis** pode-se atualizar estimativas destes coeficientes para calcular uma estimativa de segundo nível dos parâmetros da planta.

3.4.1 Resumo dos Algoritmos

Caso o leitor deseje consultar rapidamente, listamos os algoritmos de identificação de primeiro e segundo nível de forma compacta. A operação $\text{vec}(M)$ toma como argumento uma matriz $M \in R^{n \times m}$ e retorna um vetor coluna $m \in R^{nm \times 1}$, formado pelas colunas de M empilhadas. A adaptação destes algoritmos para uma linguagem de programação qualquer é razoavelmente simples. Seguem os algoritmos:

Tabela 3.1: Algoritmos dos Modelos de Primeiro Nível para uma Planta de Grau n

Série-Paralelo	Regressão Linear
$\Sigma_p : \dot{x}_p = A_p x_p + B_p u$	$\Sigma_p : \dot{x}_p = A_p x_p + b_p u$
$\Sigma_{1,sp} : \dot{\hat{x}}_{1,sp} = A_m \hat{x}_{1,sp} + \hat{A}_{1,sp} x_p - A_m x_p + \hat{B}_{1,sp} u$	$y_p = h_p^T x_p$
$e_{1,sp} = \hat{x}_{1,sp} - x_p$	$z = \frac{s^n y}{\Lambda(s)}$
$\dot{\hat{A}}_{1,sp} = -P e_{1,sp} x_p^T$	$\dot{\phi}_1 = \Lambda_c \phi_1 + l y_p$
$\dot{\hat{B}}_{1,sp} = -P e_{1,sp} u^T$	$\dot{\phi}_2 = \Lambda_c \phi_2 + l u$
	$\phi^T = [\phi_1 \quad \phi_2]$
	$\Sigma_{1,f} : \hat{z}_{1,f} = \hat{\theta}_{1,f} \phi$
	$e_{1,f} = \hat{z}_{1,f} - z$
	$n_s^2 = \phi^T \phi$
	$Q = Q^T > 0$
	$m^2 = 1 + n_s^2$
	$\epsilon_{1,f} = \frac{e_{1,f}}{m^2}$
	$\Gamma = \Gamma^T > 0$
	$\dot{\hat{\theta}}_{1,f} = -\Gamma \epsilon_{1,f} \phi$

Tabela 3.2: Algoritmos da Adaptação de Segundo Nível baseado em Modelos de Identificação Série-Paralelos para uma Planta de Grau n com vetor de estado acessível

Segundo Nível Série-Paralelo	Segundo Nível Série-Paralelo Modificado
$\Sigma_p : \dot{x}_p = A_p x_p + B_p u$ $\Sigma_{i,sp} : \dot{\hat{x}}_{i,sp} = A_m \hat{x}_{i,sp} + \hat{A}_{i,sp} x_p - A_m x_p + \hat{B}_{i,sp} u$ $e_{i,sp} = \hat{x}_{i,sp} - x_p$ $\dot{\hat{A}}_{i,sp} = -P e_{i,sp} x_p^T$ $\dot{\hat{B}}_{i,sp} = -P e_{i,sp} u^T$ $E_{sp} = [e_{1,sp} - e_{N,sp} \quad \dots \quad e_{N-1,sp} - e_{N,sp}]$ $\dot{\alpha}_{sp} = -E_{sp}^T E_{sp} \alpha_{sp} - E_{sp}^T e_{N,sp}$ $\bar{\Theta}_{sp} = \begin{bmatrix} \text{vec}(\hat{A}_{1,sp}) & \dots & \text{vec}(\hat{A}_{N,sp}) \\ \text{vec}(\hat{B}_{1,sp}) & \dots & \text{vec}(\hat{B}_{N,sp}) \end{bmatrix}$ $\bar{\alpha}_{sp}^T = [\alpha_{sp}^T \quad 1 - \bar{\mathbf{1}} \alpha_{sp}]$ $\begin{bmatrix} \text{vec}(\hat{A}_{n2,sp}) \\ \text{vec}(\hat{B}_{n2,sp}) \end{bmatrix} = \text{proj}_{S_{\theta,a,b}}(\bar{\Theta}_{sp} \bar{\alpha}_{sp})$	$\Sigma_p : \dot{x}_p = A_p x_p + B_p u$ $\Sigma_{i,sp} : \dot{\hat{x}}_{i,sp} = A_m \hat{x}_{i,sp} + \hat{A}_{i,sp} x_p - A_m x_p + \hat{B}_{i,sp} u$ $e_{i,sp} = \hat{x}_{i,sp} - x_p$ $\dot{\hat{A}}_{i,sp} = -P e_{i,sp} x_p^T$ $\dot{\hat{B}}_{i,sp} = -P e_{i,sp} u^T$ $E_{sp} = [e_{1,sp} - e_{N,sp} \quad \dots \quad e_{N-1,sp} - e_{N,sp}]$ $M_{sp}(0) = \mathbf{0}$ $v_{sp}(0) = \mathbf{0}$ $\dot{M}_{sp} = -\sigma M_{sp} + E_{sp}^T E_{sp}$ $\dot{v}_{sp} = -\sigma v_{sp} + E_{sp}^T e_{N,sp}$ $\dot{\alpha}_{sp} = -(E_{sp}^T E_{sp} + M_{sp}) \alpha_{sp} - E_{sp}^T e_{N,sp} - v_{sp}$ $\bar{\Theta}_{sp} = \begin{bmatrix} \text{vec}(\hat{A}_{1,sp}) & \dots & \text{vec}(\hat{A}_{N,sp}) \\ \text{vec}(\hat{B}_{1,sp}) & \dots & \text{vec}(\hat{B}_{N,sp}) \end{bmatrix}$ $\bar{\alpha}_{sp}^T = [\alpha_{sp}^T \quad 1 - \bar{\mathbf{1}} \alpha_{sp}]$ $\begin{bmatrix} \text{vec}(\hat{A}_{n2,sp}) \\ \text{vec}(\hat{B}_{n2,sp}) \end{bmatrix} = \text{proj}_{S_{\theta,a,b}}(\bar{\Theta}_{sp} \bar{\alpha}_{sp})$

Tabela 3.3: Algoritmos da Adaptação de Segundo Nível baseada em Modelos de Identificação por Regressão Linear para uma Planta SISO de Grau n

Segundo Nível Regressão Linear	Segundo Nível Regressão Linear Modificado
$\Sigma_p : \dot{x}_p = A_p x_p + b_p u$ $y_p = h_p^T x_p$ $z = \frac{s^n y}{\Lambda(s)}$ $\dot{\phi}_1 = \Lambda_c \phi_1 + l y_p$ $\dot{\phi}_2 = \Lambda_c \phi_2 + l u$ $\phi^T = [-\phi_1 \quad \phi_2]$ $\Sigma_{i,f} : \hat{z}_{i,f} = \hat{\theta}_{i,f} \phi$ $e_{i,f} = \hat{z}_{i,f} - z$ $n_s^2 = \phi^T \phi$ $Q = Q^T > 0$ $m^2 = 1 + n_s^2$ $\epsilon_{i,f} = \frac{e_{i,f}}{m^2}$ $\Gamma = \Gamma^T > 0$ $\dot{\hat{\theta}}_{i,f} = -\Gamma \epsilon_{i,f} \phi$ $E_f = [\epsilon_{1,f} - \epsilon_{N,f} \quad \dots \quad \epsilon_{N-1,f} - \epsilon_{N,f}]$ $\dot{\alpha}_f = -E_f^T E_f \alpha_f - E_f^T \epsilon_{N,f}$ $\bar{\Theta}_f = [\hat{\theta}_{1,f} \quad \dots \quad \hat{\theta}_{N,f}]$ $\bar{\alpha}_f^T = [\alpha_f^T \quad 1 - \vec{1} \alpha_f]$ $\hat{\theta}_{n2,f} = \text{proj}_{S_{\theta,f}}(\bar{\Theta}_f \bar{\alpha}_f)$	$\Sigma_p : \dot{x}_p = A_p x_p + b_p u$ $y_p = h_p^T x_p$ $z = \frac{s^n y}{\Lambda(s)}$ $\dot{\phi}_1 = \Lambda_c \phi_1 + l y_p$ $\dot{\phi}_2 = \Lambda_c \phi_2 + l u$ $\phi^T = [-\phi_1 \quad \phi_2]$ $\Sigma_{i,f} : \hat{z}_{i,f} = \hat{\theta}_{i,f} \phi$ $e_{i,f} = \hat{z}_{i,f} - z$ $n_s^2 = \phi^T \phi$ $Q = Q^T > 0$ $m^2 = 1 + n_s^2$ $\epsilon_{i,f} = \frac{e_{i,f}}{m^2}$ $\Gamma = \Gamma^T > 0$ $\dot{\hat{\theta}}_{i,f} = -\Gamma \epsilon_{i,f} \phi$ $E_f = [\epsilon_{1,f} - \epsilon_{N,f} \quad \dots \quad \epsilon_{N-1,f} - \epsilon_{N,f}]$ $M_f(0) = \mathbf{0}$ $v_f(0) = \mathbf{0}$ $\dot{M}_f = -\sigma M_f + E_f^T E_f$ $\dot{v}_f = -\sigma v_f + E_f^T \epsilon_{N,f}$ $\dot{\alpha}_f = -(E_f^T E_f + M_f) \alpha_f - E_f^T \epsilon_{N,f} - v_f$ $\bar{\Theta}_f = [\hat{\theta}_{1,f} \quad \dots \quad \hat{\theta}_{N,f}]$ $\bar{\alpha}_f^T = [\alpha_f^T \quad 1 - \vec{1} \alpha_f]$ $\hat{\theta}_{n2,f} = \text{proj}_{S_{\theta,f}}(\bar{\Theta}_f \bar{\alpha}_f)$

em que $\text{proj}_{S_{\theta,a,b}}(\bar{\Theta}_{sp} \bar{\alpha}_{sp})$ é a projeção das estimativas dos elementos de A_p sobre a região de incerteza $S_{\theta,a}$ e das estimativas dos elementos de B_p sobre a região de incerteza $S_{\theta,b}$.

3.4.2 Estudos de Simulação

Planta com vetor de estado acessível

Considere a Planta a seguir:

$$\dot{x}_p = A_p x_p + b_p u = \begin{bmatrix} -1 & -2 \\ 0 & -3 \end{bmatrix} x_p + \begin{bmatrix} 2 \\ 3 \end{bmatrix} u$$

onde os elementos das matrizes A_p e do vetor b_p pertencem a uma região de incerteza conhecida:

$$a_{11} \in [-3 \quad -0.5]$$

$$a_{12} \in [-4 \quad -1]$$

$$a_{21} \in [-1 \quad 1]$$

$$a_{22} \in [-4 \quad -2]$$

$$b_1 \in [1 \quad 5]$$

$$b_2 \in [2 \quad 6]$$

e desejamos identificar os parâmetros desta planta em tempo real, assumindo que o vetor de estado x_p e a entrada u estão disponíveis para medição. Usamos o Modelo Série-Paralelo e a Adaptação de Segundo Nível com e sem Fator de Esquecimento. Lembramos que a Adaptação de Segundo Nível consiste na combinação convexa das estimativas de um conjunto de Modelos de Primeiro Nível. Os coeficientes da combinação convexa também estão sendo atualizados. Através desta adaptação em duas camadas se forma uma estimativa de Segundo Nível. Usaremos o número mínimo de modelos para este caso, $N = 7$. Para facilitar a comparação entre os resultados plotamos os gráficos das estimativas para cada caso na mesma figura. Omitimos informações consideradas de pouca relevância como por exemplo os gráficos dos Modelos de Identificação de Primeiro Nível cujas estimativas iniciais não coincidem com as estimativas iniciais de Segundo Nível. Para inicializar as simulações, usamos os seguintes valores:

$$A_m = \begin{bmatrix} -10 & 0 \\ 0 & -20 \end{bmatrix}$$

$$Q = \begin{bmatrix} -200 & 0 \\ 0 & -200 \end{bmatrix} \rightarrow P = \begin{bmatrix} 20 & 0 \\ 0 & 10 \end{bmatrix}$$

$$x_p(0) = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

$$u(t) = 1 + \sin(t) + \sin(1.7t) + \sin(3t)$$

$$\alpha_{1,sp}(0) = 1$$

$$\alpha_i(0) = 0, \quad i \neq 1$$

$$\gamma_{n2,sp} = 50$$

$$\sigma = 0.2$$

note-se que $u(t)$ foi escolhido PE de ordem 3 pois temos 6 parâmetros para estimar. Escolhemos estimativas iniciais para a matriz A_p :

$$\begin{aligned}
\hat{A}_{1,sp}(0) &= \begin{bmatrix} -3 & -4 \\ -1 & -3 \end{bmatrix} \\
\hat{A}_{2,sp}(0) &= \begin{bmatrix} 14.5 & -4 \\ -1 & -3 \end{bmatrix} \\
\hat{A}_{3,sp}(0) &= \begin{bmatrix} -3 & 17 \\ -1 & -3 \end{bmatrix} \\
\hat{A}_{4,sp}(0) &= \begin{bmatrix} -3 & -4 \\ 13 & -3 \end{bmatrix} \\
\hat{A}_{5,sp}(0) &= \begin{bmatrix} -3 & -4 \\ -1 & 10 \end{bmatrix} \\
\hat{A}_{6,sp}(0) &= \begin{bmatrix} -3 & -4 \\ -1 & -3 \end{bmatrix} \\
\hat{A}_{7,sp}(0) &= \begin{bmatrix} -3 & -4 \\ -1 & -3 \end{bmatrix}
\end{aligned}$$

e para o vetor b_p :

$$\begin{aligned}
\hat{b}_{1,sp}(0) &= \begin{bmatrix} 1 \\ 2 \end{bmatrix} \\
\hat{b}_{2,sp}(0) &= \begin{bmatrix} 1 \\ 2 \end{bmatrix} \\
\hat{b}_{3,sp}(0) &= \begin{bmatrix} 1 \\ 2 \end{bmatrix} \\
\hat{b}_{4,sp}(0) &= \begin{bmatrix} 1 \\ 2 \end{bmatrix} \\
\hat{b}_{5,sp}(0) &= \begin{bmatrix} 1 \\ 2 \end{bmatrix} \\
\hat{b}_{6,sp}(0) &= \begin{bmatrix} 29 \\ 2 \end{bmatrix} \\
\hat{b}_{7,sp}(0) &= \begin{bmatrix} 1 \\ 30 \end{bmatrix}
\end{aligned}$$

e obtivemos os seguintes resultados:




Figura 3.1: Comportamento das estimativas do elemento a_{11} da matriz A_p para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.




Figura 3.2: Comportamento das estimativas do elemento a_{12} da matriz A_p para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.




Figura 3.3: Comportamento das estimativas do elemento a_{21} da matriz A_p para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.




Figura 3.4: Comportamento das estimativas do elemento a_{22} da matriz A_p para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.




Figura 3.5: Comportamento das estimativas do elemento b_1 do vetor b_p para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.




Figura 3.6: Comportamento das estimativas do elemento b_2 do vetor b_p para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.




Figura 3.7: Primeiro elemento do vetor erro de Identificação do Modelo de Primeiro Nível com estimativa inicial $\hat{A}_{1,sp}(0)$ e $b_{1,sp}(0)$




Figura 3.8: Segundo elemento do vetor erro de Identificação do Modelo de Primeiro Nível com estimativa inicial $\hat{A}_{1,sp}(0)$ e $b_{1,sp}(0)$

verificamos que, de fato, ambos os elementos do vetor erro de identificação para o Modelo de Primeiro Nível inicializado em $\hat{A}_{1,sp}(0)$ e $\hat{b}_{1,sp}(0)$ estão se aproximando de 0 com $t = 20$ segundos nas Figuras 3.7 e 3.8. As estimativas de Primeiro Nível inicializadas em $\hat{A}_{1,sp}(0)$ e $\hat{b}_{1,sp}(0)$ estão se aproximando dos valores corretos. As estimativas de Segundo Nível sem Fator de Esquecimento atingem os valores corretos em $t \approx 10$ segundos. As estimativas de Segundo Nível com Fator de Esquecimento atingem os valores corretos em $t \approx 6$ segundos. Podemos ver o comportamento das estimativas nas Figuras 3.1 a 3.6. Vemos portanto que as estimativas de Primeiro Nível são mais lentas e mais oscilatórias

que ambos os conjuntos de estimativas de Segundo Nível na sua convergência para os valores corretos. Com a introdução de um Fator de Esquecimento na Adaptação de Segundo Nível temos como resultado uma convergência mais rápida e mais suave dos parâmetros para seus valores corretos em relação a Adaptação de Segundo Nível sem Fator de Esquecimento. Quaisquer dos Modelos de Identificação sujeitos a um sinal PE são adequados para a tarefa de identificação dos parâmetros. No entanto, há claramente um resultado em particular que é melhor em relação a rapidez e suavidade de convergência dos parâmetros para seus valores corretos. Este resultado é obtido através do acúmulo de informações através de uma operação de integração que detalhamos anteriormente neste capítulo.

Caso SISO

Após estas simulações, consideramos que apenas a saída da planta $y_p = [1 \ 0] x_p$ e $u(t)$ estão disponíveis para medição. Desta forma estamos identificando a planta em termos de sua função de transferência:

$$G_p(s) = \frac{N_p(s)}{D_p(s)} = \frac{b_1 s + b_2}{s^2 + a_1 s + a_2} = \frac{2s + 0}{s^2 + 4s + 3}$$

desejamos então identificar os coeficientes dos polinômios do numerador e denominador da função de transferência da planta $N_p(s)$ e $D_p(s)$. A região de incerteza para estes parâmetros é considerada conhecida:

$$\begin{aligned} a_1 &\in [3 \ 8] \\ a_2 &\in [1 \ 6] \\ b_1 &\in [-1 \ 7] \\ b_2 &\in [-3 \ 3] \end{aligned}$$

faremos uso do Modelo de Identificação por Regressão Linear, da Adaptação de Segundo Nível usando o número mínimo de modelos $N = 5$ com e sem Fator de Esquecimento. Para inicializar as simulações, usamos os seguintes valores:

$$\begin{aligned}
\Lambda(s) &= s^2 + 6s + 9 \\
\Lambda_c &= \begin{bmatrix} -6 & -9 \\ 1 & 0 \end{bmatrix} \\
l &= \begin{bmatrix} 1 \\ 0 \end{bmatrix} \\
\Gamma &= \begin{bmatrix} 100 & 0 & 0 & 0 \\ 0 & 100 & 0 & 0 \\ 0 & 0 & 100 & 0 \\ 0 & 0 & 0 & 100 \end{bmatrix} \\
x_p(0) &= \begin{bmatrix} 0.2 \\ 0.4 \end{bmatrix} \\
\phi_1(0) &= \phi_2(0) = 0 \\
u(t) &= 1 + \sin(t) + \sin(1.7t) + \sin(3t) \\
\alpha_{1,f}(0) &= 1 \\
\alpha_i(0) &= 0, \quad i \neq 1 \\
\gamma_{n2,f} &= 10 \\
\sigma &= 0.2
\end{aligned}$$

e escolhemos as estimativas iniciais para o vetor θ_p :

$$\begin{aligned}
\hat{\theta}_{1,f}^T(0) &= [3 \quad 1 \quad -1 \quad -3] \\
\hat{\theta}_{2,f}^T(0) &= [28 \quad 1 \quad -1 \quad -3] \\
\hat{\theta}_{3,f}^T(0) &= [3 \quad 26 \quad -1 \quad -3] \\
\hat{\theta}_{4,f}^T(0) &= [3 \quad 1 \quad 39 \quad -3] \\
\hat{\theta}_{5,f}^T(0) &= [3 \quad 1 \quad -1 \quad 27]
\end{aligned}$$

e como na simulação anterior nós omitimos informações consideradas de pouca relevância. Obtivemos os seguintes resultados:




Figura 3.9: Comportamento das estimativas do coeficiente a_1 do polinômio $D_p(s)$ para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.




Figura 3.10: Comportamento das estimativas do coeficiente a_2 do polinômio $D_p(s)$ para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.




Figura 3.11: Comportamento das estimativas do coeficiente b_1 do polinômio $N_p(s)$ para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.




Figura 3.12: Comportamento das estimativas do coeficiente b_2 do polinômio $N_p(s)$ para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.




Figura 3.13: Erro de Identificação não normalizado do Modelo de Primeiro Nível com estimativa inicial $\hat{\theta}_{1,f}(0)$

como $\dot{\phi}$ é uniformemente limitado temos que o erro de identificação não normalizado deve tender a 0 quando o $t \rightarrow \infty$. Isto de fato se confirma e pode ser visualizado na Figura 4.5. As estimativas de Primeiro Nível inicializadas em $\hat{\theta}_{1,f}(0)$ estão se aproximando dos valores corretos. As estimativas de Segundo Nível sem Fator de Esquecimento atingem os valores corretos em $t \approx 15$ segundos. As estimativas de Segundo Nível com Fator de Esquecimento atingem os valores corretos em $t \approx 6$ segundos. Podemos ver o comportamento das estimativas nas Figuras 4.1 a 4.4. Vemos portanto que as estimativas de Primeiro Nível são mais lentas que ambos os conjuntos de estimativas de Segundo Nível na sua convergência para os valores corretos, como no caso anterior. No entanto devido a escolha de um valor alto de ganho para a Adaptação de Segundo Nível sem Fator de Esquecimento, vemos que 3 das estimativas exibem mudanças abruptas. Com a introdução de um Fator de Esquecimento na Adaptação de Segundo Nível temos como resultado uma convergência mais rápida e mais suave dos parâmetros para seus valores corretos em relação a Adaptação de Segundo Nível sem Fator de Esquecimento, como no caso anterior. O efeito das condições iniciais $x_p^T(0) = [0.2 \ 0.4]$

decai exponencialmente e não afeta a convergência dos parâmetros significativamente. Quaisquer dos Modelos de Identificação sujeitos a um sinal PE são adequados para a tarefa de identificação dos parâmetros. No entanto a Adaptação de Segundo Nível com Fator de Esquecimento, para os valores de parâmetros escolhidos, se mostra uma ferramenta de identificação mais efetiva em comparação com a Adaptação de Segundo Nível sem Fator de Esquecimento. Interpretamos esta melhora de resultado da seguinte forma: $E_f^T E_f$ é obrigatoriamente de posto 1 ou 0. M_f obtida através da integral de convolução não tem restrição quanto a seu posto. A multiplicação de uma matriz por um vetor pode ser interpretada como uma operação de projeção do vetor sobre os autovetores daquela matriz, pesada pelos autovalores correspondentes. Assim, a multiplicação de $E_f^T E_f$ por α_f projeta α_f sobre o autovetor associado ao autovalor não nulo de $E_f^T E_f$ e descarta as

demais informações. Ocorre que se α_f tiver uma grande componente perpendicular a este autovetor esta informação será descartada. A multiplicação de M_f por α_f não necessariamente sofre desta desvantagem, pois M_f pode inclusive ser de posto cheio.

3.5 Conclusão

Neste capítulo apresentamos alguns Modelos de Identificação Convencionais que podem ser usados na identificação dos parâmetros em tempo real de uma Planta Linear Invariante no Tempo. Mostramos como estes Modelos podem servir como base para identificação através do conceito de Adaptação de Segundo Nível. Na Adaptação de Segundo Nível os coeficientes de uma combinação linear de múltiplos modelos são atualizados por uma lei integral e as estimativas são entregues por esta mesma combinação. O Modelo Série-Paralelo serve como base para o caso em que o vetor de estado da planta de grau n e as p entradas são acessíveis. O Modelo por Regressão Linear serve como base para o caso em que apenas a entrada e a saída da planta de grau n e grau relativo unitário estão disponíveis para medição. Disponibilizamos os algoritmos em forma compacta em um resumo para que o leitor possa testar o conceito por si mesmo em simulação. Neste capítulo tratamos apenas do problema da identificação dos parâmetros da planta, assumindo portanto que os sinais são limitados a priori. Desta forma escolhemos uma planta estável e um sinal de controle uniformemente limitado e PE.

Foram feitos estudos de simulação extensivos, nos quais avaliamos a Adaptação de Segundo Nível com e sem Fator de Esquecimento em relação ao Modelo Série-Paralelo para o caso da planta com vetor de estado acessível e o Modelo por Regressão Linear para o caso SISO. Terminamos aqui nosso estudo da Adaptação de Segundo Nível como ferramenta de identificação de parâmetros. Tendo estudado as propriedades da Adaptação de Segundo Nível, passaremos a seguir no capítulo 3 ao problema do Controle. Desta forma, serão dispensadas as premissas de que a planta é estável e de que o sinal de controle é uniformemente limitado a priori. Assim, passaremos a nos ocupar de 2 tarefas simultâneas: A estimação dos parâmetros da planta e a escolha de uma lei de controle que faça uso destas estimativas. A lei de controle escolhida deve produzir um sinal de controle uniformemente limitado que faça com que o sinal ou sinais de saída da planta sejam uniformemente limitados e cumpram o objetivo de rastreamento de um Modelo de Referência escolhido pelo projetista.

Capítulo 4

Controle Adaptativo Indireto

Finalmente, passamos a tratar do problema do controle de uma planta linear invariante no tempo. Fazemos um breve resumo dos resultados que obtivemos no capítulo anterior para o caso SISO com o Modelo de Identificação por Regressão Linear e a Adaptação de Segundo Nível baseada em múltiplos Modelos de Identificação por Regressão Linear. Após este resumo, detalhamos como são calculados os parâmetros do controlador a partir das estimativas dos parâmetros da planta. Provamos que a Adaptação de Segundo Nível possui as mesmas propriedades que o Método do Gradiente quando utilizada no Controle por Modelo de Referência Indireto para a planta de grau n e grau relativo 1 quando o Modelo de Referência escolhido tem grau n e grau relativo 1.

4.1 Planta de Ordem n e Grau Relativo Unitário

4.1.1 Controle por Modelo de Referência

Seja a planta linear invariante no tempo descrita pela seguinte função de transferência:

$$\Sigma_{p,SISO} : G_p(s) = \frac{y(s)}{u(s)} = \frac{N_p(s)}{D_p(s)} = k_p \frac{Z_p(s)}{D_p(s)}$$

em que:

$$\begin{aligned} N_p(s) &= b_1 s^{n-1} + b_2 s^{n-2} + \dots + b_{n-1} s + b_n \\ D_p(s) &= s^n + a_1 s^{n-1} + a_2 s^{n-2} + \dots + a_{n-1} s + a_n \\ k_p &= b_1 \\ Z_p(s) &= s^{n-1} + \frac{b_2}{b_1} s^{n-2} + \dots + \frac{b_{n-1}}{b_1} s + \frac{b_n}{b_1} \end{aligned} \tag{4.1}$$

e os coeficientes dos polinômios $N_p(s)$ e $D_p(s)$ são conhecidos. Assumimos que:

- **P1** $Z_p(s)$ é Hurwitz de grau $n - 1$
- **P2** O grau n de $D_p(s)$ é conhecido.
- **P3** O grau relativo de $G_p(s)$ é 1.
- **P4** O sinal de $b_1 = k_p$ é conhecido.
- **P5** $N_p(s)$ e $D_p(s)$ são coprimos

queremos projetar um controlador que entregue um sinal $u(t)$ que faça com que a saída da planta rastreie a saída de um Modelo de Referência:

$$\Sigma_m : W_m(s) = \frac{y_m(s)}{r(s)} = k_m \frac{Z_m(s)}{D_m(s)}$$

escolhido pelo projetista e que cumpra as seguintes condições:

- **M1** $Z_m(s)$ e $D_m(s)$ são Hurwitz e coprimos
- **M2** O grau de $D_m(s)$ é n
- **M3** O grau relativo de $W_m(s)$ é 1.

portanto:

$$\begin{aligned} Z_m(s) &= s^{n-1} + b_{m,2}s^{n-2} + \dots + b_{m,n-1}s + b_{m,n} \\ D_m(s) &= s^n + a_{m,1}s^{n-1} + a_{m,2}s^{n-2} + \dots + a_{m,n-1}s + a_{m,n} \end{aligned} \quad (4.2)$$

alimentado com uma referência $r(t)$ escolhida pelo projetista. A lei de controle deve ser escolhida tal que os polos da função de transferência em malha fechada de r para y sejam estáveis e iguais aos de $W_m(s)$. Se a função de transferência em malha fechada se torna equivalente a $W_m(s)$ então qualquer que seja o sinal de referência $r(t)$ a saída $y(t)$ da planta tenderá exponencialmente para a saída $y_m(t)$ do modelo. Uma escolha óbvia para tal tarefa seria uma lei de controle em malha aberta, no entanto não assumimos nada em relação à estabilidade da planta. $D_p(s)$ pode inclusive conter polos no semi plano direito aberto do plano complexo. Uma lei de controle em malha aberta para uma planta instável implicaria em cancelamentos de polos e zeros no semi plano direito aberto do plano complexo, levando à instabilidade do sistema. Assim, passamos a considerar a seguinte lei de controle por realimentação:

$$u = \theta_1^{*T} \frac{\Psi(s)}{\Lambda_w(s)} u + \theta_2^{*T} \frac{\Psi(s)}{\Lambda_w(s)} y + \theta_3^* y + c_0^* r = \theta^{*T} w \quad (4.3)$$

onde:

$$\begin{aligned} w &\triangleq \left[\frac{\Psi^T(s)}{\Lambda_w(s)} u \quad \frac{\Psi^T(s)}{\Lambda_w(s)} y \quad y \quad r \right]^T \\ \Psi(s) &\triangleq [s^{n-2} \quad s^{n-3} \quad \dots \quad s \quad 1]^T \\ \theta^* &\triangleq [\theta_1^{*T} \quad \theta_2^{*T} \quad \theta_3^* \quad c_0^*]^T \end{aligned} \quad (4.4)$$

como a planta e o modelo de referência são de mesmo grau e grau relativo escolhemos $\Lambda_w(s) = Z_m(s)$. O vetor regressor de controle w pode ser gerado por:

$$\begin{aligned} \dot{w}_1 &= F w_1 + g u \\ \dot{w}_2 &= F w_2 + g y \\ w &\triangleq [w_1 \quad w_2 \quad y \quad r]^T \end{aligned} \quad (4.5)$$

onde F e g são escolhidos de acordo com $Z_m(s)$. Os parâmetros do controlador $c_0^*, \theta_3^* \in \mathbb{R}^1$ e $\theta_1^*, \theta_2^* \in \mathbb{R}^{n-1}$ são constantes, calculados com base nas informações dos parâmetros

do modelo de referência e da planta. Queremos um vetor $\theta^* \in R^{2n}$ tal que a função de transferência em malha fechada de y para r seja equivalente a $W_m(s)$. As propriedades de entrada e saída da planta em malha fechada para esta lei de controle são dadas por:

$$y = G_c(s)r \quad (4.6)$$

onde:

$$G_c(s) = \frac{c_0^* k_p Z_p Z_m^2}{Z_m [(Z_m - \theta_1^{*T} \Psi) D_p(s) - k_p Z_p (\theta_2^{*T} \Psi + \theta_3^* Z_m)]} \quad (4.7)$$

gostaríamos de obter $G_c(s) = W_m(s)$:

$$\frac{c_0^* k_p Z_p Z_m^2}{Z_m [(Z_m - \theta_1^{*T} \Psi) D_p(s) - k_p Z_p (\theta_2^{*T} \Psi + \theta_3^* Z_m)]} = k_m \frac{Z_m}{D_m} \quad (4.8)$$

podemos escolher:

$$c_0^* = \frac{k_m}{k_p} \quad (4.9)$$

obtendo:

$$(Z_m - \theta_1^{*T} \Psi) D_p(s) - k_p Z_p (\theta_2^{*T} \Psi + \theta_3^* Z_m) = Z_p D_m \quad (4.10)$$

resta encontrar θ_1^*, θ_2^* e θ_3^* que satisfaçam a equação acima. A equação acima pode ser resolvida por inspeção, de forma que temos:

$$\begin{aligned} \theta_1^{*T} \Psi &= Z_m(s) - Z_p(s) \\ \theta_2^{*T} \Psi + \theta_3^* Z_m(s) &= \frac{D_p(s) - D_m(s)}{k_p} \end{aligned} \quad (4.11)$$

chamaremos as equações acima de equações de "matching", no sentido de que garantem que o comportamento de entrada e saída da planta é equivalente ao do modelo de referência.

4.1.2 Controle Adaptativo por Modelo de Referência Indireto

Estimador por Método do Gradiente

Seja a planta linear invariante no tempo descrita pela seguinte função de transferência:

$$\Sigma_{p,SISO} : G_p(s) = \frac{y(s)}{u(s)} = \frac{N_p(s)}{D_p(s)}$$

em que:

$$\begin{aligned} N_p(s) &= b_1 s^{n-1} + b_2 s^{n-2} + \dots + b_{n-1} s + b_n \\ D_p(s) &= s^n + a_1 s^{n-1} + a_2 s^{n-2} + \dots + a_{n-1} s + a_n \end{aligned} \quad (4.12)$$

em que os limitantes superiores $b_1^+, \dots, b_n^+, a_1^+, a_n^+$ e inferiores $b_1^-, \dots, b_n^-, a_1^-, a_n^-$ dos coeficientes $b_1, \dots, b_n, a_1, \dots, a_n$ são conhecidos. Desta forma as combinações de limitantes $b_1^+, \dots, b_n^+, a_1^+, a_n^+$ e $b_1^-, \dots, b_n^-, a_1^-, a_n^-$ representam vértices de um politopo convexo que delimita a região de incerteza $S_{\theta,f} \in R^{2n}$ dos coeficientes $b_1, \dots, b_n, a_1, \dots, a_n$. A região de incerteza $S_{\theta,f}$ é conhecida. Definimos anteriormente, no capítulo 2:

$$\begin{aligned} z(s) &\triangleq \frac{s^n}{\Lambda(s)} y(s) \\ \phi(s) &\triangleq \left[\frac{-s^{n-1}y(s)}{\Lambda(s)} \quad \dots \quad \frac{-y(s)}{\Lambda(s)} \quad \frac{s^{n-1}u(s)}{\Lambda(s)} \quad \dots \quad \frac{u(s)}{\Lambda(s)} \right]^T \\ \theta_p^* &\triangleq [a_1 \quad \dots \quad a_n \quad b_1 \quad \dots \quad b_n]^T \end{aligned} \quad (4.13)$$

e temos a seguinte parametrização para a planta:

$$z(s) = \theta_p^{*T} \phi \quad (4.14)$$

e o vetor regressor ϕ pode ser gerado através de filtros de $y(t)$ e $u(t)$:

$$\begin{aligned} \dot{\phi}_1 &= \Lambda_c \phi_1 + l y \\ \dot{\phi}_2 &= \Lambda_c \phi_2 + l u \\ \phi &= [-\phi_1 \quad \phi_2]^T \end{aligned} \quad (4.15)$$

e uma estimativa da saída z é gerada pelo modelo de identificação:

$$\Sigma_{1,f} : \hat{z}_{1,f} = \hat{\theta}_{1,f}^T \phi \quad (4.16)$$

e geramos o erro de identificação:

$$e_{1,f} \triangleq \hat{z}_{1,f} - z \quad (4.17)$$

então o erro de identificação normalizado pode ser construído:

$$\varepsilon_{1,f} = \frac{e_{1,f}}{m^2} \quad (4.18)$$

onde $m^2 = 1 + n_s^2$ e n_s é chamado de sinal normalizador, escolhido tal que $\frac{\phi}{m} \in \mathcal{L}_\infty$. A seguinte lei adaptativa pode ser utilizada para atualizar o valor da estimativa de θ_p^* :

$$\dot{\theta}_{1,f} = -\Gamma \varepsilon_{1,f} \phi \quad (4.19)$$

IMRAC com Método do Gradiente

assumindo que os polinômios $N_p(s)$ e $D_p(s)$ são coprimos, queremos fazer uso das estimativas obtidas para encontrar um sinal $u(t)$ que faça com que a saída da planta rastreie a saída de um Modelo de Referência:

$$\Sigma_m : W_m(s) = \frac{y_m(s)}{r(s)} = k_m \frac{Z_m(s)}{D_m(s)}$$

alimentado com uma referência $r(t)$ escolhida pelo projetista em que:

$$\begin{aligned} Z_m(s) &= s^{n-1} + b_{m,2}s^{n-2} + \dots + b_{m,n-1}s + b_{m,n} \\ D_m(s) &= s^n + a_{m,1}s^{n-1} + a_{m,2}s^{n-2} + \dots + a_{m,n-1}s + a_{m,n} \end{aligned} \quad (4.20)$$

e $N_m(s)$ e $D_m(s)$ são também escolhidos pelo projetista. Como vimos anteriormente, caso os parâmetros da planta fossem conhecidos poderíamos escolher 4.11 para atingir este objetivo. No entanto, não dispomos dos valores corretos dos parâmetros da planta. Ao invés disso, substituíremos os valores corretos por suas estimativas entregues pelo método do gradiente para calcular os parâmetros do controlador. Fazemos isto com base no princípio de equivalência a certeza. Temos então:

$$u = \theta_1^T \frac{\Psi(s)}{\Lambda_w(s)} u + \theta_2^T \frac{\Psi(s)}{\Lambda_w(s)} y + \theta_3 y + c_0 r = \theta^T w \quad (4.21)$$

com $\Lambda_w(s) = Z_m(s)$ para esse caso, e como estivemos estimando os coeficientes de $D_p(s)$ e $Z_p(s)$ temos então estimativas $\hat{D}_p(s)$ e $\hat{Z}_p(s)$ e $\hat{k}_p$:

$$\begin{aligned} \hat{k}_p &= \hat{b}_1 \\ \hat{D}_p(s) &= s^n + \hat{a}_1 s^{n-1} + \hat{a}_2 s^{n-2} + \dots + \hat{a}_n \\ \hat{Z}_p(s) &= s^{n-1} + \frac{\hat{b}_2}{\hat{b}_1} s^{n-2} + \dots + \frac{\hat{b}_n}{\hat{b}_1} \end{aligned} \quad (4.22)$$

que podemos usar no cálculo dos parâmetros do controlador. Calculamos os parâmetros do controlador com base em 4.11:

$$\begin{aligned} c_0 &= \frac{k_m}{\hat{k}_p} \\ \theta_1^T \Psi &= Z_m(s) - \hat{Z}_p(s) \\ \theta_2^T \Psi + \theta_3 Z_m(s) &= \frac{\hat{D}_p(s) - D_m(s)}{\hat{k}_p} \end{aligned} \quad (4.23)$$

para limitar os parâmetros calculados, temos que a estimativa $\hat{k}_p = \hat{b}_1$ deve ser restringida de atingir um valor nulo por projeção. Este esquema adaptativo garante, segundo a prova de estabilidade em (Ioannou & Sun 1996)[424-428], que todos os sinais envolvidos no sistema são uniformemente limitados e que o erro de saída $e_1 = y - y_m$ converge para 0 a medida que $t \rightarrow \infty$. Esta afirmação é verdadeira se a estimativa $\theta_p \in \mathcal{L}_\infty$, $\frac{1}{\hat{k}_p} \in \mathcal{L}_\infty$ e sua derivada $\dot{\theta}_p \in \mathcal{L}_2$, o que se verifica para o Método do Gradiente.

Estimador por Adaptação de Segundo Nível

Novamente, seja a planta:

$$\Sigma_{p,SISO} : G_p(s) = \frac{y(s)}{u(s)} = \frac{N_p(s)}{D_p(s)}$$

em que:

$$\begin{aligned} N_p(s) &= b_1 s^{n-1} + b_2 s^{n-2} + \dots + b_{n-1} s + b_n \\ D_p(s) &= s^n + a_1 s^{n-1} + a_2 s^{n-2} + \dots + a_{n-1} s + a_n \end{aligned} \quad (4.24)$$

em que os limitantes superiores $b_1^+, \dots, b_n^+, a_1^+, a_n^+$ e inferiores $b_1^-, \dots, b_n^-, a_1^-, a_n^-$ dos coeficientes $b_1, \dots, b_n, a_1, \dots, a_n$ são conhecidos. Desta forma as combinações de limitantes $b_1^+, \dots, b_n^+, a_1^+, a_n^+$ e $b_1^-, \dots, b_n^-, a_1^-, a_n^-$ representam vértices de um politopo convexo que delimita a região de incerteza $S_{\theta,f} \in R^{2n}$ dos coeficientes $b_1, \dots, b_n, a_1, \dots, a_n$. A região de incerteza $S_{\theta,f}$ é conhecida. E como definimos anteriormente:

$$\begin{aligned} z(s) &\triangleq \frac{s^n}{\Lambda(s)} y(s) \\ \phi(s) &\triangleq \left[\frac{-s^{n-1}y(s)}{\Lambda(s)} \quad \dots \quad \frac{-y(s)}{\Lambda(s)} \quad \frac{s^{n-1}u(s)}{\Lambda(s)} \quad \dots \quad \frac{u(s)}{\Lambda(s)} \right]^T \\ \theta_p^* &\triangleq [a_1 \quad \dots \quad a_n \quad b_1 \quad \dots \quad b_n]^T \end{aligned}$$

e o vetor regressor ϕ é gerado pela seguinte equação:

$$\begin{aligned} \dot{\phi}_1 &= \Lambda_c \phi_1 + l y \\ \dot{\phi}_2 &= \Lambda_c \phi_2 + l u \\ \phi &= [-\phi_1 \quad \phi_2]^T \end{aligned} \quad (4.25)$$

e temos a seguinte parametrização:

$$z(s) = \theta_p^{*T} \phi$$

e os $i = 1, \dots, N$ modelos de identificação deste sinal:

$$\Sigma_{i,f} : \hat{z}_{i,f} = \hat{\theta}_{i,f}^T \phi \quad (4.26)$$

e os $i = 1, \dots, N$ erros paramétricos:

$$\tilde{\theta}_{i,f} = \hat{\theta}_{i,f} - \theta_p^* \quad (4.27)$$

definimos os $i = 1, \dots, N$ erros de identificação deste sinal:

$$e_{i,f} \triangleq \hat{z}_{i,f} - z \quad (4.28)$$

os erros de identificação normalizados são da forma:

$$\varepsilon_{i,f} = \frac{e_{i,f}}{m^2} \quad (4.29)$$

e os vetores de parâmetros $\hat{\theta}_{i,f}$, $i = 1, \dots, N$, são adaptados de acordo com o método do gradiente:

$$\dot{\hat{\theta}}_{i,f} = -\Gamma \varepsilon_{i,f} \phi \quad (4.30)$$

e uma estimativa α_f pode ser atualizada por:

$$\dot{\alpha}_f = -\gamma_{n2,f} E_f^T E_f \alpha_f - \gamma_{n2,f} E_f^T \varepsilon_{N,f} \quad (4.31)$$

onde $\gamma_{n2,f} > 0$ e a estimativa $\bar{\alpha}_f$ fica da forma:

$$\bar{\alpha}_f^T = \begin{bmatrix} \alpha_f^T & 1 - \vec{1} \alpha_f \end{bmatrix} \quad (4.32)$$

onde $\vec{1}$ é o vetor linha $[1 \ 1 \ \dots \ 1]$ de tamanho apropriado. Assim pode-se gerar uma estimativa de segundo nível dos parâmetros da planta através dos coeficientes $\alpha_{i,f}$, que são os componentes do vetor $\bar{\alpha}_f$:

$$\hat{\theta}_{n2,f} = \text{proj}_{S_{\theta,f}}(\alpha_{1,f} \hat{\theta}_{1,f} + \alpha_{2,f} \hat{\theta}_{2,f} + \dots + \alpha_{N,f} \hat{\theta}_{N,f}) \quad (4.33)$$

em que $\text{proj}_{S_{\theta,f}}(\cdot)$ é o operador de projeção retangular dentro da região de incerteza $S_{\theta,f}$.

4.1.3 IMRAC com Adaptação de Segundo Nível

assumindo que os polinômios $N_p(s)$ e $D_p(s)$ são coprimos, queremos fazer uso das estimativas obtidas para encontrar um sinal $u(t)$ que faça com que a saída da planta rastreie a saída de um Modelo de Referência:

$$\Sigma_m : W_m(s) = \frac{y_m(s)}{r(s)} = k_m \frac{Z_m(s)}{D_m(s)}$$

alimentado com uma referência $r(t)$ escolhida pelo projetista em que:

$$\begin{aligned} Z_m(s) &= s^{n-1} + b_{m,2}s^{n-2} + \dots + b_{m,n-1}s + b_{m,n} \\ D_m(s) &= s^n + a_{m,1}s^{n-1} + a_{m,2}s^{n-2} + \dots + a_{m,n-1}s + a_{m,n} \end{aligned} \quad (4.34)$$

e $N_m(s)$ e $D_m(s)$ são também escolhidos pelo projetista. Como vimos anteriormente, caso os parâmetros da planta fossem conhecidos poderíamos escolher 4.11 para atingir este objetivo. No entanto, não dispomos dos valores corretos dos parâmetros da planta. Ao invés disso, substituiremos os valores corretos por suas estimativas entregues pelo método do gradiente para calcular os parâmetros do controlador. Fazemos isto com base no princípio de equivalência a certeza. Temos então:

$$u = \theta_1^T \frac{\Psi(s)}{\Lambda_w(s)} u + \theta_2^T \frac{\Psi(s)}{\Lambda_w(s)} y + \theta_3 y + c_0 r = \theta^T w \quad (4.35)$$

com $\Lambda_w(s) = Z_m(s)$ para esse caso, e como estivemos estimando os coeficientes de $D_p(s)$ e $Z_p(s)$ temos então estimativas $\hat{D}_p(s)$ e $\hat{Z}_p(s)$ e $\hat{k}_p$:

$$\begin{aligned} \hat{k}_p &= \hat{b}_1 \\ \hat{D}_p(s) &= s^n + \hat{a}_1 s^{n-1} + \hat{a}_2 s^{n-2} + \dots + \hat{a}_n \\ \hat{Z}_p(s) &= s^{n-1} + \frac{\hat{b}_2}{\hat{b}_1} s^{n-2} + \dots + \frac{\hat{b}_n}{\hat{b}_1} \end{aligned} \quad (4.36)$$

que podemos usar no cálculo dos parâmetros do controlador. Calculamos os parâmetros do controlador com base em 4.11:

$$\begin{aligned} c_0 &= \frac{k_m}{\hat{k}_p} \\ \theta_1^T \psi &= Z_m(s) - \hat{Z}_p(s) \\ \theta_2^T \psi + \theta_3 Z_m(s) &= \frac{\hat{D}_p(s) - D_m(s)}{\hat{k}_p} \end{aligned} \quad (4.37)$$

para limitar os parâmetros calculados, temos que a estimativa $\hat{k}_p = \hat{b}_1$ deve ser restringida de atingir um valor nulo por projeção. Este esquema adaptativo garante, segundo a prova de estabilidade em (Ioannou & Sun 1996)[424-428], que todos os sinais envolvidos no sistema são uniformemente limitados e que o erro de saída $e_1 = y - y_m$ converge para 0 a medida que $t \rightarrow \infty$. Esta afirmação é verdadeira se a estimativa $\hat{\theta}_p \in \mathcal{L}_\infty$, $\frac{1}{\hat{k}_p} \in \mathcal{L}_\infty$ e sua derivada $\dot{\hat{\theta}}_p \in \mathcal{L}_2$. Portanto devemos analisar a existência destas normas de $\hat{\theta}_p$ para a adaptação de segundo nível:

$$\hat{\theta}_{n2,f} = \alpha_{1,f} \hat{\theta}_{1,f} + \alpha_{2,f} \hat{\theta}_{2,f} + \dots + \alpha_{N,f} \hat{\theta}_{N,f}$$

omitimos o operador de projeção. Como determinamos anteriormente que $\alpha_{i,f} \in \mathcal{L}_\infty$, $i = 1, \dots, N$ e $\theta_{i,f} \in \mathcal{L}_\infty$, $i = 1, \dots, N$ claramente $\hat{\theta}_{n2,f} = \hat{\theta}_p \in \mathcal{L}_\infty$. Assumimos que a região de incerteza e que o sinal de $k_p = b_1$ são conhecidos, portanto a condição de que $\frac{1}{k_p} \in \mathcal{L}_\infty$ pode ser incorporada na projeção retangular. Finalmente, temos que:

$$\dot{\hat{\theta}}_{n2,f} = \sum_{i=1}^N \dot{\theta}_{i,f} \alpha_{i,f} + \sum_{i=1}^N \theta_{i,f} \dot{\alpha}_{i,f} \quad (4.38)$$

e temos que $\dot{\theta}_{i,f} = -\Gamma \varepsilon_{i,f} \phi$ pertence ao $\mathcal{L}_2$ pois $\frac{\phi}{m} \in \mathcal{L}_\infty$ e $\varepsilon_{i,f} m \in \mathcal{L}_2 \cap \mathcal{L}_\infty$ implicam que existe um limite superior para a norma $|\dot{\theta}_{i,f}|_2$:

$$\left(\int_0^\infty |\dot{\theta}_{i,f}(\tau)|^2 d\tau \right)^{\frac{1}{2}} \leq \sup\left(\frac{\phi}{m}\right) \|\Gamma\| \|\varepsilon_{i,f} m\|_2 \quad (4.39)$$

e como $\dot{\theta}_{i,f} \in \mathcal{L}_2 \cap \mathcal{L}_\infty$ e $\alpha_{i,f} \in \mathcal{L}_\infty$, pelo mesmo raciocínio temos que:

$$\left| \sum_{i=1}^N \dot{\theta}_{i,f} \alpha_{i,f} \right|_2 \leq \sum_{i=1}^N \sup(\alpha_{i,f}) |\dot{\theta}_{i,f}|_2 \quad (4.40)$$

portanto $\sum_{i=1}^N \dot{\theta}_{i,f} \alpha_{i,f} \in \mathcal{L}_2 \cap \mathcal{L}_\infty$. Como $\dot{\alpha}_f$ é da forma:

$$\dot{\alpha}_f = -E_f^T E_f \alpha_f - E_f^T \varepsilon_{N,f} \quad (4.41)$$

e como as colunas de E_f pertencem ao $\mathcal{L}_2$ e os coeficientes $\alpha_{i,f}$ são limitados podemos

escrever:

$$|\dot{\alpha}_f|_2 \leq \sup(|E_f|) \left[\sum_{i=1}^{N-1} |\varepsilon_{i,f} - \varepsilon_{N,f}|_2 \sup(\alpha_{i,f}) + |\varepsilon_{N,f}|_2 \right] \quad (4.42)$$

portanto $\dot{\alpha}_f \in \mathcal{L}_2 \cap \mathcal{L}_\infty$, que implica em $\alpha_{i,f} \in \mathcal{L}_2 \cap \mathcal{L}_\infty$, $i = 1, \dots, N$, e como $\theta_{i,f} \in \mathcal{L}_\infty$ temos que $\sum_{i=1}^N \theta_{i,f} \dot{\alpha}_{i,f} \in \mathcal{L}_2 \cap \mathcal{L}_\infty$. Portanto $\hat{\theta}_{n2,f} = \hat{\theta}_p \in \mathcal{L}_2 \cap \mathcal{L}_\infty$ e as mesmas condições para a norma de $\hat{\theta}_p$ e sua derivada que são verdadeiras para o Método do Gradiente também o são para a Adaptação de Segundo Nível. Note-se que desprezamos o efeito das condições iniciais nesta análise, pois provamos no capítulo 2 que o escalar $e_{\alpha,f}$ vai para 0 exponencialmente, não afetando portanto a existência destas normas. Podemos então utilizar o argumento demonstrado em (Ioannou & Sun 1996)[424-428]. O IMRAC fazendo uso da adaptação de segundo nível mantém as mesmas propriedades de estabilidade e convergência do erro de saída que o IMRAC fazendo uso do método do gradiente para estimar os parâmetros da planta.

4.2 Resumo dos Algoritmos e Estudos de Simulação

Neste capítulo apresentamos a lei de controle usada para que a planta rastreie um Modelo de Referência. É gerado um vetor regressor de controle w a partir de filtros da entrada e saída da planta. Uma combinação linear dos componentes deste regressor com os parâmetros do controlador gera o sinal de controle a ser introduzido na planta. Os parâmetros do controlador são calculados a partir dos parâmetros estimados da planta por um mapeamento baseado em equações de matching, como se os parâmetros da planta fossem conhecidos. Mostramos que as estimativas de segundo nível têm as mesmas propriedades de norma $\mathcal{L}_p$ das estimativas produzidas pelo Método do Gradiente. Desta forma, a mesma prova matemática de que o Método do Gradiente é adequado como estimador de parâmetros no Controle Adaptativo Indireto por Modelo de Referência (Ioannou & Sun 1996)[424-428] pode ser utilizada para provar o mesmo quanto a Adaptação de Segundo Nível. Assim, tanto para a Adaptação de Segundo Nível quanto para o Método do Gradiente o erro de saída tende a 0 e a planta segue o modelo de referência. As estimativas dos parâmetros da planta tendem aos valores corretos na presença de um sinal de entrada com a característica de persistência de excitação. Na ausência de um sinal PE apenas o erro de saída tende a 0 e o sinal de controle tende a u^* .

4.2.1 Resumo dos Algoritmos

Caso o leitor deseje consultar rapidamente, listamos os algoritmos usados neste capítulo para o Controle Adaptativo por Modelo de Referência Indireto de uma planta de grau n e grau relativo 1 e modelo de referência de grau n e grau relativo 1:

Tabela 4.1: Algoritmos de Controle por Modelo de Referência, Caso Ideal com Planta Conhecida e Controle Adaptativo baseado em Modelo de Identificação por Regressão Linear

Caso Ideal, Planta Conhecida	Regressão Linear
$\Sigma_p : \dot{x}_p = A_p x_p + b_p u$ $y_p = h_p^T x_p$ $\dot{x}_m = A_m x_m + b_m r$ $y_m = h_m^T x_m$ $c_0 = \frac{k_m}{\hat{k}_p}$ $\theta_1^T \psi(s) = \Lambda_w(s) - \frac{1}{k_p} N_p(s)$ $\theta_2^T \psi(s) + \theta_3 \Lambda_w(s) = \frac{D_p(s) - \Lambda_0(s) D_m(s)}{k_p}$ $\theta = [\theta_1 \ \theta_2 \ \theta_3 \ c_0]^T$ $\dot{w}_1 = F w_1 + g u$ $\dot{w}_2 = F w_2 + g y$ $w = [w_1 \ w_2 \ y \ r]^T$ $u = \theta^T w$	$\Sigma_p : \dot{x}_p = A_p x_p + b_p u$ $y_p = h_p^T x_p$ $z = \frac{s^n y}{\Lambda(s)}$ $\dot{\phi}_1 = \Lambda_c \phi_1 + l y_p$ $\dot{\phi}_2 = \Lambda_c \phi_2 + l u$ $\phi^T = [\phi_1 \ \phi_2]$ $\Sigma_{1,f} : \hat{z}_{1,f} = \hat{\theta}_{1,f} \phi$ $e_{1,f} = \hat{z}_{1,f} - z$ $n_s^2 = \phi^T \phi$ $Q = Q^T > 0$ $m^2 = 1 + n_s^2$ $\varepsilon_{1,f} = \frac{e_{1,f}}{m^2}$ $\Gamma = \Gamma^T > 0$ $\dot{\hat{\theta}}_{1,f} = -\Gamma \varepsilon_{1,f} \phi$ $\dot{x}_m = A_m x_m + b_m r$ $y_m = h_m^T x_m$ $c_0 = \frac{k_m}{\hat{k}_p}$ $\theta_1^T \psi(s) = \Lambda_w(s) - \frac{1}{\hat{k}_p} \hat{N}_p(s)$ $\theta_2^T \psi(s) + \theta_3 \Lambda_w(s) = \frac{\hat{D}_p(s) - \Lambda_0(s) D_m(s)}{\hat{k}_p}$ $\theta = [\theta_1 \ \theta_2 \ \theta_3 \ c_0]^T$ $\dot{w}_1 = F w_1 + g u$ $\dot{w}_2 = F w_2 + g y$ $w = [w_1 \ w_2 \ y \ r]^T$ $u = \theta^T w$

Tabela 4.2: Algoritmos de Controle Adaptativo por Modelo de Referência Indireto baseados em Adaptação de Segundo Nível a partir de Modelos de Identificação por Regressão Linear

Segundo Nível Regressão Linear	Segundo Nível Regressão Linear Modificado
$\Sigma_p : \dot{x}_p = A_p x_p + b_p u$ $y_p = h_p^T x_p$ $z = \frac{s^n y}{\Lambda(s)}$ $\dot{\phi}_1 = \Lambda_c \phi_1 + l y_p$ $\dot{\phi}_2 = \Lambda_c \phi_2 + l u$ $\phi^T = [-\phi_1 \quad \phi_2]$ $\Sigma_{i,f} : \hat{z}_{i,f} = \hat{\theta}_{i,f} \phi$ $e_{i,f} = \hat{z}_{i,f} - z$ $n_s^2 = \phi^T \phi$ $Q = Q^T > 0$ $m^2 = 1 + n_s^2$ $\epsilon_{i,f} = \frac{e_{i,f}}{m^2}$ $\Gamma = \Gamma^T > 0$ $\dot{\hat{\theta}}_{i,f} = -\Gamma \epsilon_{i,f} \phi$ $E_f = [e_{1,f} - e_{N,f} \quad \dots \quad e_{N-1,f} - e_{N,f}]$ $\dot{\alpha}_f = -E_f^T E_f \alpha_f - E_f^T e_{N,f}$ $\bar{\Theta}_f = [\hat{\theta}_{1,f} \quad \dots \quad \hat{\theta}_{N,f}]$ $\bar{\alpha}_f^T = [\alpha_f^T \quad 1 - \bar{\mathbf{1}} \alpha_f]$ $\hat{\theta}_{n2,f} = \text{projs}_{\Theta_f}(\bar{\Theta}_f \bar{\alpha}_f)$ $\dot{x}_m = A_m x_m + b_m r$ $y_m = h_m^T x_m$ $c_0 = \frac{k_m}{\hat{k}_p}$ $\theta_1^T \psi(s) = \Lambda_w(s) - \frac{1}{\hat{k}_p} \hat{N}_p(s)$ $\theta_2^T \psi(s) + \theta_3 \Lambda_w(s) = \frac{\hat{D}_p(s) - \Lambda_0(s) D_m(s)}{\hat{k}_p}$ $\theta = [\theta_1 \quad \theta_2 \quad \theta_3 \quad c_0]^T$ $\dot{w}_1 = F w_1 + g u$ $\dot{w}_2 = F w_2 + g y$ $w = [w_1 \quad w_2 \quad y \quad r]^T$ $u = \theta^T w$	$\Sigma_p : \dot{x}_p = A_p x_p + b_p u$ $y_p = h_p^T x_p$ $z = \frac{s^n y}{\Lambda(s)}$ $\dot{\phi}_1 = \Lambda_c \phi_1 + l y_p$ $\dot{\phi}_2 = \Lambda_c \phi_2 + l u$ $\phi^T = [-\phi_1 \quad \phi_2]$ $\Sigma_{i,f} : \hat{z}_{i,f} = \hat{\theta}_{i,f} \phi$ $e_{i,f} = \hat{z}_{i,f} - z$ $n_s^2 = \phi^T \phi$ $Q = Q^T > 0$ $m^2 = 1 + n_s^2$ $\epsilon_{i,f} = \frac{e_{i,f}}{m^2}$ $\Gamma = \Gamma^T > 0$ $\dot{\hat{\theta}}_{i,f} = -\Gamma \epsilon_{i,f} \phi$ $E_f = [e_{1,f} - e_{N,f} \quad \dots \quad e_{N-1,f} - e_{N,f}]$ $M_f(0) = \mathbf{0}$ $v_f(0) = \mathbf{0}$ $\dot{M}_f = -\sigma M_f + E_f^T E_f$ $\dot{v}_f = -\sigma v_f + E_f^T e_{N,f}$ $\dot{\alpha}_f = -(E_f^T E_f + M_f) \alpha_f - E_f^T e_{N,f} - v_f$ $\bar{\Theta}_f = [\hat{\theta}_{1,f} \quad \dots \quad \hat{\theta}_{N,f}]$ $\bar{\alpha}_f^T = [\alpha_f^T \quad 1 - \bar{\mathbf{1}} \alpha_f]$ $\hat{\theta}_{n2,f} = \text{projs}_{\Theta_f}(\bar{\Theta}_f \bar{\alpha}_f)$ $\dot{x}_m = A_m x_m + b_m r$ $y_m = h_m^T x_m$ $c_0 = \frac{k_m}{\hat{k}_p}$ $\theta_1^T \psi(s) = \Lambda_w(s) - \frac{1}{\hat{k}_p} \hat{N}_p(s)$ $\theta_2^T \psi(s) + \theta_3 \Lambda_w(s) = \frac{\hat{D}_p(s) - \Lambda_0(s) D_m(s)}{\hat{k}_p}$ $\theta = [\theta_1 \quad \theta_2 \quad \theta_3 \quad c_0]^T$ $\dot{w}_1 = F w_1 + g u$ $\dot{w}_2 = F w_2 + g y$ $w = [w_1 \quad w_2 \quad y \quad r]^T$ $u = \theta^T w$

4.2.2 Estudos de Simulação

Considere a planta a seguir:

$$G_p(s) = \frac{N_p(s)}{D_p(s)} = \frac{b_1s + b_2}{s^2 + a_1s + a_2} = \frac{2s + 1}{s^2 - 3s - 4}$$

desejamos estimar os coeficientes dos polinômios do numerador e denominador da função de transferência da planta $N_p(s)$ e $D_p(s)$. A região de incerteza para estes parâmetros é considerada conhecida:

$$\begin{aligned} a_1 &\in [-8 \quad -3] \\ a_2 &\in [-6 \quad -1.5] \\ b_1 &\in [-1 \quad 7] \\ b_2 &\in [0.5 \quad 1.5] \end{aligned}$$

faremos uso do Modelo de Identificação por Regressão Linear, da Adaptação de Segundo Nível usando o número mínimo de modelos $N = 5$ com e sem Fator de Esquecimento. Para inicializar as simulações, usamos os seguintes valores:

$$\begin{aligned} \Lambda(s) &= s^2 + 7s + 12 \\ \Lambda_c &= \begin{bmatrix} -6 & -9 \\ 1 & 0 \end{bmatrix} \\ l &= \begin{bmatrix} 1 \\ 0 \end{bmatrix} \\ \Gamma &= \begin{bmatrix} 100 & 0 & 0 & 0 \\ 0 & 100 & 0 & 0 \\ 0 & 0 & 100 & 0 \\ 0 & 0 & 0 & 100 \end{bmatrix} \\ x_p(0) &= \begin{bmatrix} 0.2 \\ 0.4 \end{bmatrix} \\ \phi_1(0) &= \phi_2(0) = 0 \\ r(t) &= 1 + \sin(t) + \sin(1.7t) + \sin(3t) \\ \alpha_{1,f}(0) &= 1 \\ \alpha_i(0) &= 0, \quad i \neq 1 \\ \gamma_{n2,f} &= 10 \\ \gamma'_{n2,f} &= 3 \\ \sigma &= 6 \end{aligned}$$

usamos o valor $\gamma'_{n2,f} = 3$ na simulação para a Adaptação de Segundo Nível Sem fator de esquecimento e $\gamma_{n2,f} = 10$ para Adaptação de Segundo Nível com Fator de Esquecimento. Escolhemos as estimativas iniciais para o vetor θ_p :

$$\begin{aligned}
\hat{\theta}_{1,f}^T(0) &= [-8 \quad -6 \quad 1 \quad 0.5] \\
\hat{\theta}_{2,f}^T(0) &= [29.5 \quad -6 \quad 1 \quad 0.5] \\
\hat{\theta}_{3,f}^T(0) &= [-8 \quad 16.5 \quad 1 \quad 0.5] \\
\hat{\theta}_{4,f}^T(0) &= [-8 \quad -6 \quad 31 \quad 0.5] \\
\hat{\theta}_{5,f}^T(0) &= [-8 \quad -6 \quad 1 \quad 5.5]
\end{aligned}$$

e adicionalmente, desejamos que a saída da planta rastreie a saída y_m de um modelo de referência estável escolhido pelo projetista:

$$W_m(s) = \frac{N_m(s)}{D_m(s)} = 1 \frac{s+4}{s^2+4s+4}$$

para tanto calculamos os parâmetros do controlador a partir das estimativas dos parâmetros da planta, resolvendo as equações polinomiais. Geramos um vetor regressor de controle gerado por filtragem do sinal de saída e do sinal de entrada da planta. A partir do vetor de parâmetros do controlador e do regressor de controle geramos uma lei de controle:

$$\begin{aligned}
\Lambda_w(s) &= s+4 \\
c_0 &= \frac{k_m}{\hat{k}_p} = \frac{1}{\hat{b}_1} \\
\theta_1 &= s+4-s-\frac{\hat{b}_2}{\hat{b}_1} = 4-\frac{\hat{b}_2}{\hat{b}_1} \\
\theta_2^T + \theta_3(s+4) &= \frac{\hat{D}_p(s)-D_m(s)}{\hat{k}_p} \\
\theta_2 &= \frac{-4\hat{a}_1+\hat{a}_2+12}{\hat{b}_1} \\
\theta_3 &= \frac{\hat{a}_1-4}{\hat{b}_1} \\
\theta &= [\theta_1 \quad \theta_2 \quad \theta_3 \quad c_0]^T \\
\dot{w}_1 &= -4w_1 + u \\
\dot{w}_2 &= -4w_2 + y \\
w &= [w_1 \quad w_2 \quad y \quad r]^T \\
u &= \theta^T w
\end{aligned}$$

omitimos informações consideradas de pouca relevância. Obtivemos os seguintes resultados:




Figura 4.1: Comportamento das estimativas do coeficiente a_1 do polinômio $D_p(s)$ para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.




Figura 4.2: Comportamento das estimativas do coeficiente a_2 do polinômio $D_p(s)$ para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.




Figura 4.3: Comportamento das estimativas do coeficiente b_1 do polinômio $N_p(s)$ para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.




Figura 4.4: Comportamento das estimativas do coeficiente b_2 do polinômio $N_p(s)$ para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.




Figura 4.5: Erro de saída da planta para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.




Figura 4.6: Sinal de Controle gerado pelo controlador com base nas estimativas do Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.

tanto o Modelo de Identificação por Regressão Linear quanto a Adaptação de Segundo Nível mantém o comportamento do sistema estável e, com os parâmetros do controlador calculados a partir de suas estimativas, fazem com que a saída da planta tenda para a saída do modelo de referência. Isto pode ser visualizado na Figura 4.5, com o erro de saída tendendo para 0 em todos os 3 casos. As estimativas de Primeiro Nível inicializadas em $\hat{\theta}_{1,f}(0)$ se dirigem lentamente em direção aos valores corretos. As estimativas de

Segundo Nível sem Fator de Esquecimento não atingem os valores corretos mas também estão se aproximando, mais rapidamente que o Modelo de Primeiro Nível. As estimativas de Segundo Nível com Fator de Esquecimento são as que mais se aproximam dos valores corretos. Podemos ver o comportamento das estimativas nas Figuras 4.1 a 4.4. Vemos novamente que as estimativas de Primeiro Nível são mais lentas que ambos os conjuntos de estimativas de Segundo Nível na sua convergência para os valores corretos, como no capítulo anterior. Apesar de não exibir convergência dos parâmetros para o tempo de simulação escolhido, a Adaptação de Segundo Nível sem Fator de Esquecimento exibe convergência do sinal de controle para o sinal de controle que seria gerado caso os parâmetros da planta fossem conhecidos. Com a introdução de um Fator de Esquecimento na Adaptação de Segundo Nível temos como resultado uma convergência mais rápida e mais suave dos parâmetros para seus valores corretos em relação a Adaptação de Segundo Nível sem Fator de Esquecimento, como no capítulo anterior. O efeito das condições iniciais $x_p^T(0) = [0.2 \ 0.4]$

afeta o erro de saída e a Adaptação de Segundo Nível com Fator de Esquecimento se mostra mais sensível, exibindo um pico no sinal de controle no começo da simulação. A seguir, fizemos uma simulação com uma referência $r(t) = 1$, que não é PE para este sistema:




Figura 4.7: Comportamento das estimativas do coeficiente a_1 do polinômio $D_p(s)$ para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.




Figura 4.8: Comportamento das estimativas do coeficiente a_2 do polinômio $D_p(s)$ para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.




Figura 4.9: Comportamento das estimativas do coeficiente b_1 do polinômio $N_p(s)$ para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.




Figura 4.10: Comportamento das estimativas do coeficiente b_2 do polinômio $N_p(s)$ para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.




Figura 4.11: Erro de saída da planta para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.




Figura 4.12: Sinal de Controle gerado pelo controlador com base nas estimativas do Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.

vemos que, na ausência de um sinal PE as estimativas dos parâmetros acabam por se manter em valores que não são os corretos. Isto pode ser visto nas Figuras 4.7 a 4.10. A Adaptação de Segundo Nível sem Fator de Esquecimento converge ligeiramente mais rápido que os outros dois casos mas exibe mais overshoot que a Adaptação de Segundo Nível com Fator de Esquecimento. O Modelo de Identificação por Regressão Linear exibe uma resposta mais lenta e mais oscilatória que ambos os tipos de Adaptação de Segundo Nível. Apesar de as estimativas dos parâmetros não atingirem os valores corretos, todos os 3 modelos são capazes de fazer com que a saída da planta siga a saída do modelo de referência e produzir um sinal de controle em regime permanente que é igual ao sinal de controle do controlador ideal, como pode ser visto nas Figuras 4.11 e 4.12. No entanto, como não houve convergência dos parâmetros para seus valores corretos, uma mudança qualquer no sinal de referência da planta certamente causará um novo transitório de adaptação das estimativas dos parâmetros.

4.3 Conclusão

Neste capítulo apresentamos brevemente o problema do Controle Adaptativo por Modelo de Referência Indireto para o caso da planta SISO de grau n e grau relativo 1, onde os parâmetros do controlador são calculados a partir de um mapeamento obtido pelas equações de "matching". Mostramos que a Adaptação de Segundo Nível pode substituir o Método do Gradiente na entrega das estimativas dos parâmetros da planta, sem perda das propriedades de estabilidade do sistema. Na Adaptação de Segundo Nível os coeficientes de uma combinação linear de múltiplos modelos são atualizados por uma lei integral e as estimativas são entregues por esta mesma combinação. Disponibilizamos os algoritmos em forma compacta em um resumo para que o leitor possa testar o conceito por si mesmo

em simulação. Dispensamos a hipótese que assumimos para os capítulos 1 e 2 de que a planta seja estável e adotamos uma lei de controle capaz de estabilizar a planta.

Foram feitos estudos de simulação com uma planta instável, nos quais avaliamos a Adaptação de Segundo Nível com e sem Fator de Esquecimento em relação ao Modelo por Regressão Linear para o caso SISO. Terminamos aqui os temas que gostaríamos de abordar para esta dissertação.

Capítulo 5

Conclusão

Neste trabalho apresentamos a adaptação de segundo nível, que é uma nova ferramenta de identificação/estimação de parâmetros. Mostramos a aplicação do conceito a plantas lineares. Devido ao uso das informações de múltiplos modelos de identificação em conjunto, as estimativas dos parâmetros exibem uma convergência mais rápida na adaptação de segundo nível quando comparada com modelos de identificação convencionais. Esta convergência mais rápida dos parâmetros se traduz, quando aplicada ao controle adaptativo indireto, numa melhor ação de controle. Nesta dissertação de mestrado nossas contribuições foram as seguintes:

- 1 Explicitar o conceito de adaptação de segundo nível para identificação dos parâmetros de uma planta de grau n e grau relativo 1 tendo como base o modelo por regressão linear para o caso SISO, discutindo suas propriedades.
- 2 A introdução de um fator de esquecimento na lei adaptativa da adaptação de segundo nível, de forma a acumular informações passadas e melhorar as propriedades de convergência das estimativas dos parâmetros da planta para seus valores corretos.
- 3 Analisar as normas $\mathcal{L}_p$ do vetor $\hat{\theta}_p$ de estimativas dos parâmetros da planta SISO de grau n e grau relativo 1 para a adaptação de segundo nível tendo como base o método do gradiente, o que permite concluir que a adaptação de segundo nível é uma ferramenta de estimação adequada em termos de estabilidade para se usar em conjunto com o controle adaptativo por modelo de referência indireto neste caso.

esperamos que esta dissertação sirva como um guia de uso da adaptação de segundo nível e como ponto de partida para novos trabalhos.

Anexos

Referências Bibliográficas

- Bitmead, R. (1984), ‘Persistence of excitation conditions and the convergence of adaptive schemes’, *IEEE Transactions on Information Theory* **30**(2), 183–191.
- Boyd, S. & S. S. Sastry (1986), ‘Necessary and sufficient conditions for parameter convergence in adaptive control’, *Automatica* **22**(6), 629–639.
- Han, Z. & K. S. Narendra (2010), Multiple adaptive models for control, *em* ‘Decision and Control (CDC), 2010 49th IEEE Conference on’, pp. 60–65.
- Han, Z. & K. S. Narendra (2012), ‘New concepts in adaptive control using multiple models’, *IEEE Transactions on Automatic Control* **57**(1), 78–89.
- Han, Zhuo & Kumpati Narendra (2011), ‘Second level adaptation using multiple models’, pp. 2350 – 2355.
- Ioannou, Petros A. & Jing Sun (1996), *Robust Adaptive Control*, Pearson Education, Inc.
- Narendra, K. S. & A. M. Annaswamy (1989), *Stable Adaptive Systems*, Prentice-Hall.
- Narendra, K. S. & J. Balakrishnan (1994), ‘Improving transient response of adaptive control systems using multiple models and switching’, *IEEE Transactions on Automatic Control* **39**(9), 1861–1866.
- Narendra, K. S. & J. Balakrishnan (1997), ‘Adaptive control using multiple models’, *IEEE Transactions on Automatic Control* **42**(2), 171–187.
- Narendra, K. S., J. Balakrishnan & M. K. Ciliz (1995), ‘Adaptation and learning using multiple models, switching, and tuning’, *IEEE Control Systems* **15**(3), 37–51.
- Narendra, K. S., Y. Wang & W. Chen (2014), Stability, robustness, and performance issues in second level adaptation, *em* ‘American Control Conference (ACC), 2014’, pp. 2377–2382.
- Narendra, K. S., Yu Wang & Wei Chen (2015), Extension of second level adaptation using multiple models to siso systems, *em* ‘2015 American Control Conference (ACC)’, pp. 171–176.
- Narendra, K. S. & Z. Han (2010), Location of models in multiple-model based adaptive control for improved performance, *em* ‘American Control Conference (ACC), 2010’, pp. 117–122.

- Narendra, K.S. (2016), Chapter two - hierarchical adaptive control of rapidly time-varying systems using multiple models, *em* K. G. Vamvoudakis & S. Jagannathan, eds., 'Control of Complex Systems', Butterworth-Heinemann, pp. 33 – 66.
URL: <https://www.sciencedirect.com/science/article/pii/B9780128052464000021>
- NARENDRA, KUMPATI S. & ANURADHA M. ANNASWAMY (1987), 'Persistent excitation in adaptive systems', *International Journal of Control* **45**(1), 127–160.
URL: <http://dx.doi.org/10.1080/00207178708933715>
- Narendra, Kumpati S., Yu Wang & Wei Chen (2012), The rationale for second level adaptation, *em* 'The 16th Yale Workshop on Adaptive and Learning Systems', Yale University.
- Pandey, V. K., I. Kar & C. Mahanta (2017), Controller design for a 3-dof helicopter using multiple models with second level adaptation, *em* '2017 Indian Control Conference (ICC)', pp. 99–104.
- Tao, G. (2003), *Adaptive Control Design and Analysis*, Wiley.