



UNIVERSIDADE FEDERAL DO RIO GRANDE DO NORTE
CENTRO DE TECNOLOGIA
PROGRAMA DE PÓS-GRADUAÇÃO EM ENGENHARIA ELÉTRICA E
DE COMPUTAÇÃO



Adaptação de Segundo Nível como Técnica de Estimação de Parâmetros e sua Aplicação ao Controle Adaptativo por Modelo de Referência

Pedro Yochinori Gushiken

Orientador: Prof. Dr. Aldayr Dantas de Araújo

Dissertação de Mestrado apresentada ao Programa de Pós-Graduação em Engenharia Elétrica e de Computação da UFRN (área de concentração: Engenharia de Computação) como parte dos requisitos para obtenção do título de Mestre em Ciências.

Número de ordem PPgEEC: M000
Natal, RN, janeiro de 2018

Resumo

Neste trabalho mostramos a adaptação de segundo nível baseada em modelos de identificação por regressão linear para o caso de uma planta de ordem 1 e para o caso de uma planta de ordem n onde apenas a entrada e a saída da planta estão disponíveis para medição (**SISO**). Propomos uma modificação na lei adaptativa da adaptação de segundo nível baseada no acumulo de informações do transitório. Em todos os casos verificamos por simulação que as estimativas entregues pela adaptação de segundo nível convergem muito mais rapidamente para os valores corretos que as estimativas entregues por modelos de identificação individuais e que a modificação proposta aumenta a velocidade e suaviza a convergência das estimativas. Finalmente, aplicamos a adaptação de segundo nível com base em modelos de identificação por regressão linear atualizados pelo método do gradiente normalizado ao problema do controle adaptativo por modelo de referência (**MRAC**) de uma planta **SISO** de ordem 1 e grau relativo unitário e ao controle de uma planta de ordem n e grau relativo unitário. Resultados de simulação mostram que o sinal de controle gerado com adaptação de segundo nível produz melhores resultados de rastreamento do modelo de referência comparada aos modelos de identificação individuais. Além disso, comparamos o **MRAC** indireto baseado em adaptação de segundo nível ao Controle Adaptativo por Modelo de Referência e Estrutura Variável (**VS-MRAC**).

Palavras-chave: Estimação de Parâmetros, Controle Adaptativo por Modelo de Referência, Adaptação de Segundo Nível, Controle Adaptativo Múltiplos Modelos, Controle Adaptativo com Estrutura Variável.

Abstract

In this dissertation we demonstrate the concept of second level adaptation as a parameter estimation method for the case of a plant of order unity, the case of a plant of order n with single input and output available for measurement (**SISO**). We propose a modified form of the adaptive law for second level adaptation based on integration of transient information. In all cases simulation studies show that the estimates reach their true values faster with second level adaptation compared to individual identification models and that the proposed modification is even faster and also smoother in this regard. Finally, we apply second level adaptation based on linear regression identification models updated through the normalized gradient method to the problem of model reference adaptive control (**MRAC**) of an order 1 plant with relative degree one and an order n **SISO** plant with relative degree one. Simulation results show that the control signal generated with second level adaptation yields better results of model reference tracking compared to individual identification models. We also compare the indirect **MRAC** based on second level adaptation to Variable Structure Model Reference Adaptive Control.

Keywords: Parameter Estimation, Model Reference Adaptive Control, Second Level Adaptation, Multiple Model Adaptive Control, Variable Structure Adaptive Control.

Sumário

Sumário	i
Lista de Figuras	v
Lista de Tabelas	ix
Lista de Símbolos e Abreviaturas	xi
1 Introdução	1
1.1 Sistemas Lineares e Não-Lineares	1
1.2 Controle Automático	2
1.3 Controle Clássico	4
1.4 Controle Adaptativo	5
1.5 Controle Adaptativo Direto e Indireto	6
1.6 Controle Adaptativo por Modelo de Referência	8
1.7 Controle Adaptativo com Estrutura Variável	8
1.8 Modelos de Identificação	10
1.9 Controle Adaptativo baseado em Múltiplos Modelos de Identificação . . .	10
1.10 Modelos Virtuais por Combinação Convexa	11
1.11 Adaptação de Segundo Nível	12
1.12 Estrutura do Trabalho	13
2 Estimação de Parâmetros, Ordem 1	15
2.1 Introdução	15
2.2 Descrição do Problema	16
2.3 Identificação Paramétrica Convencional	17
2.4 Adaptação de Segundo Nível	21
2.5 Adaptação de Segundo Nível Modificada	28
2.6 Resultados	31
2.6.1 Resumo dos Algoritmos	32
2.6.2 Estudos de Simulação	33
2.7 Conclusão	40
3 Controle da Planta de Ordem 1	41
3.1 Descrição do Problema	41
3.2 Planta com parâmetros conhecidos	42

3.3	Controle Adaptativo por Modelo de Referência Indireto	42
3.4	Controle Adaptativo por Modelo de Referência e Estrutura Variável . . .	43
3.5	Resultados	44
3.5.1	Resumo dos Algoritmos	44
3.5.2	Estudos de Simulação	46
3.6	Conclusão	51
4	Estimação de Parâmetros, Ordem n	53
4.1	Descrição do Problema	54
4.2	Estimação de Parâmetros Convencional	54
4.3	Adaptação de Segundo Nível	57
4.4	Adaptação de Segundo Nível com Fator de Esquecimento	64
4.5	Resultados	66
4.5.1	Resumo dos Algoritmos	67
4.5.2	Estudos de Simulação	68
4.6	Conclusão	73
5	Controle da Planta de Ordem n	75
5.1	Descrição do Problema	75
5.2	Planta com parâmetros conhecidos	76
5.3	Controle Adaptativo por Modelo de Referência Indireto	79
5.4	Controle Adaptativo por Modelo de Referência e Estrutura Variável . . .	80
5.5	Resultados	85
5.5.1	Resumo dos Algoritmos	85
5.5.2	Estudos de Simulação	88
5.6	Conclusão	101
6	Conclusão	103
	Referências Bibliográficas	105
A	Combinações Convexas	109
B	Conceitos sobre Sistemas	111
B.1	Representação	111
C	Estabilidade	113
C.1	Definições	113
C.2	Método Direto de Lyapunov	113
C.2.1	Funções definidas	113
C.2.2	Teoremas sobre estabilidade	114
C.3	Norma $\mathcal{L}_p$	114
C.4	Lema de Barbalat	114
C.4.1	Corolário 1	114
C.4.2	Corolário 2	115

C.4.3	Corolário 3	115
C.4.4	Corolário 4	115
C.5	Lema de Kalman-Yakubovitch-Lefschetz	115

Lista de Figuras

1.1	Sistema de Controle em Malha Aberta	3
1.2	Sistema de Controle em Malha Fechada	4
1.3	Controlador Adaptativo Direto	6
1.4	Controlador Adaptativo Indireto	7
1.5	Modelo de Identificação por Regressão Linear	11
1.6	Controlador Adaptativo Indireto de Segundo Nível	13
2.1	Erro de Identificação usando o Modelo por Regressão Linear para a planta Σ_p , 110 segundos de simulação	34
2.2	Estimativa do parâmetro $a_p = 3$ para a planta Σ_p para os Modelos de Identificação estudados, Adaptação de Segundo Nível com $N = 3, N = 4$ e $N = 8$ Modelos de Primeiro Nível por Regressão Linear, 20 segundos de simulação	36
2.3	Estimativa do parâmetro $k_p = 1.5$ para a planta Σ_p para os Modelos de Identificação estudados, Adaptação de Segundo Nível com $N = 3, N = 4$ e $N = 8$ Modelos de Primeiro Nível por Regressão Linear, 20 segundos de simulação	36
2.4	Erros de Identificação usando 3 Modelos por Regressão Linear para a planta Σ_p	37
2.5	Estimativas do parâmetro $a_p = 1.5$ para a planta Σ_p para 3 Modelos por Regressão Linear e a estimativa de Segundo Nível Modificada, 36 segundos de simulação	38
2.6	Estimativas do parâmetro $k_p = 1.5$ para a planta Σ_p para 3 Modelos por Regressão Linear e a estimativa de Segundo Nível Modificada, 36 segundos de simulação	38
2.7	Trajetória dos parâmetros $\hat{a}_{n2,f}$ e $\hat{k}_{n2,f}$ da Adaptação de Segundo Nível Modificada no espaço de parâmetros usando 3 Modelos por Regressão Linear para a planta Σ_p , aos 30 segundos de simulação	39
3.1	Estimativa do parâmetro $a_p = 3$ para a planta Σ_p de ordem 1 para o Modelo de Identificação por Regressão Linear e a Adaptação de Segundo Nível com $N=3$, 12 segundos de simulação	48
3.2	Estimativa do parâmetro $k_p = 1.5$ para a planta Σ_p de ordem 1 para o Modelo de Identificação por Regressão Linear e a Adaptação de Segundo Nível com $N=3$, 12 segundos de simulação	48

3.3	Saída da planta Σ_p de ordem 1 para o Controle Adaptativo Indireto baseado Modelo de Identificação por Regressão Linear, Controle Adaptativo Indireto baseado em Adaptação de Segundo Nível com $N=3$, Controle com Estrutura Variável e Controle com Parâmetros Conhecidos, 12 segundos de simulação	49
3.4	Detalhe da Figura 3.3, entre 0 e 0.2 segundos de simulação	49
3.5	Sinal de controle para Controle Adaptativo Indireto baseado Modelo de Identificação por Regressão Linear, Controle Adaptativo Indireto baseado em Adaptação de Segundo Nível com $N=3$ e Controle com Parâmetros Conhecidos da Planta de Ordem 1, 12 segundos de simulação	50
3.6	Sinal de controle para o Controle Adaptativo por Modelo de Referência e Estrutura Variável da Planta de Ordem 1, 12 segundos de simulação . . .	50
4.1	Comportamento das estimativas do coeficiente a_1 do polinômio $D_p(s)$ para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.	70
4.2	Comportamento das estimativas do coeficiente a_2 do polinômio $D_p(s)$ para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.	70
4.3	Comportamento das estimativas do coeficiente b_1 do polinômio $N_p(s)$ para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.	71
4.4	Comportamento das estimativas do coeficiente b_2 do polinômio $N_p(s)$ para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.	71
4.5	Erro de Identificação não normalizado do Modelo de Primeiro Nível com estimativa inicial $\hat{\theta}_{1,f}(0)$	72
5.1	Comportamento das estimativas do coeficiente a_1 do polinômio $D_p(s)$ para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.	91
5.2	Comportamento das estimativas do coeficiente a_2 do polinômio $D_p(s)$ para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.	91
5.3	Comportamento das estimativas do coeficiente b_1 do polinômio $N_p(s)$ para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.	92

5.4	Comportamento das estimativas do coeficiente b_2 do polinômio $N_p(s)$ para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.	92
5.5	Erro de saída da planta para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.	93
5.6	Sinal de Controle gerado pelo controlador com base nas estimativas do Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.	93
5.7	Erro de saída da planta para o controle por modelo de referência e estrutura variável.	95
5.8	Sinal de Controle gerado pelo controlador por modelo de referência e estrutura variável.	95
5.9	Comportamento das estimativas do coeficiente a_1 do polinômio $D_p(s)$ para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento com referência degrau.	96
5.10	Comportamento das estimativas do coeficiente a_2 do polinômio $D_p(s)$ para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento com referência degrau.	97
5.11	Comportamento das estimativas do coeficiente b_1 do polinômio $N_p(s)$ para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento com referência degrau.	97
5.12	Comportamento das estimativas do coeficiente b_2 do polinômio $N_p(s)$ para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento com referência degrau.	98
5.13	Erro de saída da planta para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento com referência degrau.	98
5.14	Sinal de Controle gerado pelo controlador com base nas estimativas do Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento com referência degrau.	99
5.15	Erro de saída da planta para o controlador com estrutura variável para referência degrau.	100
5.16	Sinal de Controle gerado pelo controlador com estrutura variável para referência degrau.	100

Lista de Tabelas

2.1	Algoritmo do Modelo por Regressão Linear para a Planta de Ordem 1 . . .	32
2.2	Algoritmos da Adaptação de Segundo Nível baseada em Modelos de Identificação por Regressão Linear para uma Planta de Ordem 1 e Grau relativo unitário	33
3.1	Algoritmo de Controle com Parâmetros Conhecidos e Controle Adaptativo por Modelo de Referência Indireto baseado em Modelo de Identificação por Regressão Linear para a Planta de Ordem 1	45
3.2	Algoritmo de Controle Adaptativo por Modelo de Referência Indireto baseado na Adaptação de Segundo Nível de um conjunto de Modelos de Identificação por Regressão Linear e Controle com Estrutura Variável para a Planta de Ordem 1	46
4.1	Algoritmo do Modelo de Identificação por Regressão Linear	67
4.2	Algoritmos da Adaptação de Segundo Nível baseada em Modelos de Identificação por Regressão Linear para uma Planta SISO de Grau n	68
5.1	Algoritmos de Controle por Modelo de Referência, Caso Ideal com Planta Conhecida e Controle Adaptativo baseado em Modelo de Identificação por Regressão Linear	86
5.2	Algoritmos de Controle Adaptativo por Modelo de Referência Indireto baseados em Adaptação de Segundo Nível a partir de Modelos de Identificação por Regressão Linear	87
5.3	Algoritmos de Controle Adaptativo por Modelo de Referência com Estrutura Variável	88

Lista de Símbolos e Abreviaturas

$(.)^T$	Operador de transposição de uma matriz ou vetor
N	Número de modelos de identificação usados na Adaptação de Segundo Nível
$(\dot{\cdot})$	Derivada de uma variável em relação ao tempo
$(\hat{\cdot})$	Estimativa de uma variável
$\inf(\cdot)$	Ínfimo de uma variável, maior cota inferior do conjunto de valores daquela variável
$\int_{(\cdot)}^{(\cdot)}(\cdot)$	Operador de integração
λ_{max}	Autovalor máximo de uma matriz
λ_{min}	Autovalor mínimo de uma matriz
$\sum_{(\cdot)}^{(\cdot)}(\cdot)$	Operador de somatório
$\sup(\cdot)$	Supremo de uma variável, menor cota superior do conjunto de valores daquela variável
$\mathbf{0}$	Matriz de tamanho apropriado (determinado pelo contexto da equação em que está sendo aplicada) cujos elementos são todos 0
$(\tilde{\cdot})$	Erro paramétrico, refere-se a diferença entre uma estimativa e o valor que está sendo estimado
$\vec{\mathbf{1}}$	Vetor linha de tamanho apropriado (determinado pelo contexto da equação em que está sendo aplicado) cujos elementos são todos 1
n	Grau da Planta ou SISO
n^*	Grau da relativo da planta ou SISO, neste trabalho assumimos sempre que $n^* = 1$
s	Variável complexa no domínio da frequência
Σ_p	Planta

$\Sigma_{1,f}$	Modelo de identificação por Regressão Linear 1 da planta
$\Sigma_{i,f}$	i-ésimo Modelo de identificação por Regressão Linear, com $i = 1, \dots, N$
$\Sigma_{v,f}$	Modelo de identificação Virtual da planta cujas estimativas dos parâmetros são formadas pela combinação convexa das estimativas de Modelos de Identificação por Regressão Linear
$D_m(s)$	Polinômio do denominador da função de transferência $W_m(s)$
$D_p(s)$	Polinômio do denominador da função de transferência $G_p(s)$
$G(s)$	Função de transferência da planta
$G_c(s)$	Função de transferência entre o sinal de referência e a saída da planta
$N_p(s)$	Polinômio do numerador da função de transferência $G_p(s)$
$W_m(s)$	Função de transferência do modelo de referência
$Z_m(s)$	Polinômio mônico do numerador da função de transferência $W_m(s)$
$Z_p(s)$	Polinômio mônico do numerador da função de transferência $G_p(s)$, igual a $N_p(s)$ dividido pelo ganho de alta frequência $b_1 = k_p$
$\Lambda(s)$	Polinômio mônico, Hurwitz, de grau n
$\dot{x}_p$	Primeira derivada em relação ao tempo do vetor de estado da planta
$\hat{z}_{1,f}$	Estimativa do Sinal Filtrado de Saída da Planta usando o Modelo de Identificação por Regressão Linear 1
$\hat{z}_{i,f}$	Estimativa do Sinal Filtrado de Saída da Planta usando o i-ésimo Modelo de Identificação por Regressão Linear, com $i = 1, \dots, N$
$\hat{z}_{v,f}$	Estimativa do Sinal Filtrado de Saída da Planta usando o Modelo Virtual
ϕ	Vetor Coluna formado pelos elementos ϕ_1 na primeira linha e ϕ_2 na segunda linha, e chamado vetor regressor
ϕ_1	Vetor gerado a partir de filtragens do sinal y por funções de transferência próprias $\frac{s^i}{\Lambda(s)}$, com $i = n - 1, \dots, 1$, usado para construir o vetor regressor ϕ
ϕ_2	Vetor gerado a partir de filtragens do sinal u por funções de transferência próprias $\frac{s^i}{\Lambda(s)}$, com $i = n - 1, \dots, 1$, usado para construir o vetor regressor ϕ
u	Sinal de entrada da planta
x_p	Vetor de estado da planta
y ou y_p	Sinal de Saída da Planta

z	Sinal de Saída da Planta filtrado por uma função de transferência própria $\frac{s^n}{\Lambda(s)}$
E_f	Vetor linha formado pela diferença entre os Erros de identificação $e_{i,f}$, com $i = 1, \dots, N-1$, e o erro $e_{N,f}$ em suas colunas
$\bar{E}_f$	Vetor linha formado pelos erros de identificação $e_{i,f}$, com $i = 1, \dots, N$, em suas colunas
$e_{1,f}$	Erro de identificação gerado pela diferença entre o sinal de saída do Modelo de identificação por Regressão Linear 1 e o sinal de saída da planta filtrado
$e_{N,f}$	Erro de identificação gerado pela diferença entre o sinal de saída do Modelo de identificação por Regressão Linear N e o sinal de saída da planta filtrado
$e_{i,f}$	Erro de identificação gerado pela diferença entre o sinal de saída do i-ésimo Modelo de identificação por Regressão Linear, com $i = 1, \dots, N$, e o sinal de saída da planta filtrado
$e_{v,f}$	Erro de identificação gerado pela diferença entre o sinal de saída do modelo virtual e o sinal de saída da planta filtrado
$\dot{\hat{\theta}}_{1,f}$	Lei adaptativa para atualização da estimativa $\hat{\theta}_{1,f}$
$\dot{\hat{\theta}}_{i,f}$	Lei adaptativa para atualização da estimativa $\hat{\theta}_{i,f}$, com $i = 1, \dots, N$
$\dot{\hat{a}}_{1,f}$	Lei adaptativa para atualização da estimativa $\hat{a}_{1,f}$
$\dot{\hat{a}}_{i,f}$	Lei adaptativa para atualização da estimativa $\hat{a}_{i,f}$, com $i = 1, \dots, N$
$\dot{\hat{a}}_{v,f}$	Lei adaptativa para atualização da estimativa $\hat{a}_{v,f}$
$\dot{\hat{k}}_{1,f}$	Lei adaptativa para atualização da Estimativa $\hat{k}_{1,f}$
$\dot{\hat{k}}_{i,f}$	Lei adaptativa para atualização da Estimativa $\hat{k}_{i,f}$
$\dot{\hat{k}}_{v,f}$	Lei adaptativa para atualização da Estimativa $\hat{k}_{v,f}$
$\hat{\theta}_{1,f}$	Estimativa do vetor de parâmetros θ_p^* da planta de ordem n e grau relativo 1 usando o Modelo de Identificação por Regressão Linear da Planta 1
$\hat{\theta}_{i,f}$	Estimativa do vetor de parâmetros θ_p^* da planta de ordem n e grau relativo 1 usando o i-ésimo Modelo de Identificação por Regressão Linear da Planta, com $i = 1, \dots, N$
$\hat{a}_{1,f}$	Estimativa do coeficiente do polinômio mônico do denominador da planta de ordem 1 usando o Modelo de Identificação por Regressão Linear 1
$\hat{a}_{i,f}$	Estimativa do coeficiente do polinômio mônico do denominador da planta de ordem 1 usando o i-ésimo Modelo de Identificação por Regressão Linear, com $i = 1, \dots, N$

$\hat{a}_{v,f}$	Estimativa do coeficiente do polinômio mônico do denominador da planta de ordem 1 a partir de uma combinação convexa de coeficientes β_i dos parâmetros dos modelos de identificação por regressão linear
$\hat{k}_{1,f}$	Estimativa do coeficiente do polinômio do numerador da planta de ordem 1 usando o Modelo de Identificação por Regressão Linear 1
$\hat{k}_{i,f}$	Estimativa do coeficiente do polinômio do numerador da planta de ordem 1 usando o i-ésimo Modelo de Identificação por Regressão Linear, com $i = 1, \dots, N$
$\hat{k}_{v,f}$	Estimativa do coeficiente do polinômio do numerador da planta de ordem 1 usando o Modelo Virtual
$\tilde{\theta}_{1,f}$	Erro paramétrico devido a diferença entre a estimativa $\hat{\theta}_{1,f}$ e o valor correto θ_p^*
$\tilde{\theta}_{i,f}$	Erro paramétrico devido a diferença entre a estimativa $\hat{\theta}_{i,f}$ e o valor correto θ_p^*
$\tilde{a}_{1,f}$	Erro paramétrico devido a diferença entre a estimativa $\hat{a}_{1,f}$ e o valor correto a_p
$\tilde{a}_{i,f}$	Erro paramétrico devido a diferença entre a estimativa $\hat{a}_{i,f}$ e o valor correto a_p
$\tilde{a}_{v,f}$	Erro paramétrico devido a diferença entre a estimativa $\hat{a}_{v,f}$ e o valor correto a_p
$\tilde{k}_{1,f}$	Erro paramétrico devido a diferença entre a estimativa $\hat{k}_{1,f}$ e o valor correto k_p
$\tilde{k}_{i,f}$	Erro paramétrico devido a diferença entre a estimativa $\hat{k}_{i,f}$ e o valor correto k_p
$\tilde{k}_{v,f}$	Erro paramétrico devido a diferença entre a estimativa $\hat{k}_{v,f}$ e o valor correto k_p
a_i	Coefficientes do polinômio mônico do denominador da planta SISO de ordem n e grau relativo 1, com $i = 1, \dots, n$, associados às variáveis complexas s^{n-i} do polinômio
a_i^+	Limitante superior da região de incerteza para os coeficientes a_i da planta SISO de ordem n e grau relativo 1, com $i = 1, \dots, n$
a_i^-	Limitante inferior da região de incerteza para os coeficientes a_i da planta SISO de ordem n e grau relativo 1, com $i = 1, \dots, n$
a_p	Coefficiente do polinômio mônico do denominador da planta de ordem 1
a_p^+	Limitante superior da região de incerteza para o coeficiente a_p da planta de ordem 1
a_p^-	Limitante inferior da região de incerteza para o coeficiente a_p da planta de ordem 1
b_i	Coefficientes do polinômio do numerador da planta SISO de ordem n e grau relativo 1, com $i = 1, \dots, n$, associados às variáveis complexas s^{n-i} do polinômio

b_i^+	Limitante superior da região de incerteza para os coeficientes b_i da planta SISO de ordem n e grau relativo 1, com $i = 1, \dots, n$
b_i^-	Limitante inferior da região de incerteza para o coeficiente b_i da planta SISO de ordem n e grau relativo 1, com $i = 1, \dots, n$
k_p	Coeficiente do polinômio do numerador da planta de ordem 1
k_p^+	Limitante superior da região de incerteza para o coeficiente k_p da planta de ordem 1
k_p^-	Limitante inferior da região de incerteza para o coeficiente k_p da planta de ordem 1
α_f	Vetor coluna formado pelos coeficientes $\alpha_{i,f}$ em suas linhas, com $i = 1, \dots, N-1$
α_f^*	Vetor coluna formado pelos coeficientes $\alpha_{i,f}^*$ em suas linhas, com $i = 1, \dots, N-1$
$\alpha_{i,f}$	Coeficientes da combinação convexa que são aplicados às estimativas $\hat{k}_{i,f}$ e $\hat{a}_{i,f}$, com $i = 1, \dots, N$, para formar uma estimativa de segundo nível dos parâmetros k_p e a_p ou coeficientes da combinação convexa que são aplicados às estimativas $\hat{\theta}_{i,f}$, com $i = 1, \dots, N$, para formar uma estimativa de segundo nível do vetor de parâmetros θ_p^* no caso da planta SISO de ordem n
$\alpha_{i,f}^*$	Coeficientes da combinação convexa que quando aplicados às estimativas $\hat{k}_{i,f}$ e $\hat{a}_{i,f}$, com $i = 1, \dots, N$, formam k_p e a_p respectivamente no caso da planta de ordem 1 ou coeficientes da combinação convexa que quando aplicados às estimativas $\hat{\theta}_{i,f}$, com $i = 1, \dots, N$, formam θ_p^* no caso da planta SISO de ordem n
$\bar{\alpha}_f$	Vetor coluna formado pelos coeficientes $\alpha_{i,f}$ em suas linhas, com $i = 1, \dots, N$
$\bar{\alpha}_f^*$	Vetor coluna formado pelos coeficientes $\alpha_{i,f}^*$ em suas linhas, com $i = 1, \dots, N$
$\beta_{i,f}$	Coeficientes de uma combinação convexa que são aplicados às estimativas $\hat{k}_{i,f}$ e $\hat{a}_{i,f}$, com $i = 1, \dots, N$ para formar estimativas virtuais $\hat{a}_{v,f}$ e $\hat{k}_{v,f}$ dos parâmetros ou coeficientes da combinação convexa que são aplicados às estimativas $\hat{\theta}_{i,f}$, com $i = 1, \dots, N$, para formar uma estimativa virtual do vetor de parâmetros θ_p^* no caso da planta SISO de ordem n
$\dot{\alpha}_f$	Lei adaptativa para atualização do vetor α_f
$\hat{\theta}_{n2,f}$	Estimativa de Segundo Nível do parâmetro θ_p^* da planta SISO de ordem n usando como base Modelos de Identificação por Regressão Linear
$\hat{a}_{n2,f}$	Estimativa de segundo nível do parâmetro a_p da planta de ordem 1 usando como base modelos de identificação por regressão linear

$\hat{k}_{n2,f}$	Estimativa de segundo nível do parâmetro k_p da planta de ordem 1 usando como base modelos de identificação por regressão linear
IMRAC	Indirect Model Reference Adaptive Control - Controle Adaptativo por Modelo de Referência Indireto
MMAC	Multiple Model Adaptive Control - Controle Adaptativo baseado em Múltiplos Modelos
MRAC	Model Reference Adaptive Control - Controle Adaptativo por Modelo de Referência
MRC	Model Reference Control - Controle por Modelo de Referência
PE	Persistently Exciting - Persistentemente Excitante
SISO	Single Input Single Output - Sistema com apenas uma variável de entrada e uma variável de saída

Capítulo 1

Introdução

Este trabalho trata de controle adaptativo indireto por modelo de referência, baseado em múltiplos modelos de identificação do processo a ser controlado. Escolhemos o controle por modelo de referência em oposição ao controle por posicionamento de polos, pois, apesar de possuir uma restrição em relação a plantas de fase não-mínima, o comportamento desejado da planta pode ser especificado mais detalhadamente, já que os zeros da função de transferência em malha fechada da planta com o controlador são posicionados.

O controle adaptativo encontra aplicação quando há incertezas paramétricas no sistema a ser controlado. Em particular, na estratégia indireta, os parâmetros da planta são estimados por meio de um modelo de identificação e as estimativas dos parâmetros da planta são utilizadas para calcular os parâmetros do controlador a cada instante. Neste contexto, nos propomos a estudar o método de estimação de parâmetros conhecido como adaptação de segundo nível.

O desempenho do controle adaptativo depende, em parte, da velocidade, precisão e acurácia com que os parâmetros do controlador são estimados. Na adaptação de segundo nível as estimativas dos parâmetros da planta são entregues por combinações convexas dos parâmetros de múltiplos modelos de identificação. Os coeficientes destas combinações convexas são, por sua vez, estimados como um segundo nível de adaptação.

A motivação desta escolha de objeto de estudo é a de que a adaptação de segundo nível apresenta uma velocidade de convergência dos parâmetros maior e, portanto, sua aplicação ao controle adaptativo leva possivelmente a um controlador com melhor desempenho.

A seguir colocamos alguns conceitos que consideramos necessários para embasar os comentários feitos acima:

1.1 Sistemas Lineares e Não-Lineares

Um sistema linear obedece ao princípio da superposição ao exibir as duas propriedades descritas abaixo:

- Homogeneidade (ou escalamento): A entrada é proporcional à saída. Para um aumento (ou diminuição) no valor do sinal de entrada, há uma variação diretamente proporcional da variável de saída em regime permanente;
- Aditividade: Se a soma de 2 ou mais sinais atua sobre a mesma entrada de um sistema linear, então o efeito total destes sinais sobre a saída pode ser determinado, considerando cada um dos sinais independentemente e somando os resultados.

Os sistemas que não obedecem a estas propriedades são chamados sistemas não-lineares.

1.2 Controle Automático

O controle automático representa uma forma de lidar com processos e sistemas lineares ou não lineares. O controle automático visa fazer com que algum conjunto de variáveis de interesse do projetista se comporte dentro de certas especificações, através do ajuste automático de algum outro conjunto de variáveis.

Variáveis de interesse podem ser das mais diversas, como, por exemplo, medidas de fluxo sanguíneo em corações artificiais, medidas de tensão e corrente em motores de indução, medidas de posição e velocidade em drones, braços robóticos e esteiras e o nível de tanques e reservatórios. Assim, sua aplicação se dá em muitos campos, tais como as ciências médicas, as indústrias automotiva e aeroespacial e a fabricação de bens de consumo e componentes eletrônicos.

A melhoria das técnicas de controle automático faz com que seja possível atingir desempenhos aceitáveis, em alguns casos ótimos, numa classe cada vez maior de sistemas dinâmicos. Assim, o controle automático permite a substituição de mão de obra humana por máquinas, na realização de tarefas repetitivas e também na realização de tarefas onde um operador humano não é capaz de responder em tempo hábil, ou com a precisão e acurácia necessárias.

No controle automático, se projeta um dispositivo chamado controlador, um sistema projetado de tal forma que, ao atuar em conjunto ao sistema dinâmico a ser controlado, o desempenho do conjunto de sistemas esteja dentro de certas especificações. Assim, mediante a aplicação de um ou mais sinais ao controlador, este deve produzir um ou mais sinais capazes de estimular a planta ou processo dinâmico, fazendo com que o conjunto de variáveis de interesse tenda cada uma para o valor desejado como valor final.

Em geral, um sistema físico exibe dinâmica, isto é, o efeito de um estímulo sobre uma planta não aparece instantaneamente em cada variável de interesse. Um exemplo disto é que uma chaleira com água não ferve no instante que acendemos o fogão, devemos aguardar para que a temperatura da água (variável de interesse) chegue ao valor desejado.

O intervalo de tempo entre o instante em que o sistema começa a receber o estímulo (calor) e o instante em que, na prática, todas as variáveis de interesse atingem seus valores finais e permanecem idênticos aos valores finais (ponto de fervura), é chamado de transitório. Quando todas as variáveis de interesse se aproximam dos valores iguais aos finais e neles permanecem, diz-se que o sistema se encontra em regime permanente.

Um objetivo comum no projeto de controladores é o de atingir os valores desejados em regime permanente passando por um transitório que seja o mais rápido e menos oscilatório possível. De forma geral, os sistemas de controle podem ser classificados como:

- **Sistema de Controle em Malha Aberta:** No controle em malha aberta, o controlador é conectado em série com o processo a ser controlado. O controlador é alimentado com um conjunto de sinais de referência e, conseqüentemente, produz um conjunto de sinais de controle tal que as saídas do processo tendam para as desejadas. Um sistema de controle em malha aberta se comporta da forma esperada somente se não ocorrer perturbação externa ou mudanças nos parâmetros do sistema. Se algum fator passa a atuar sobre o sistema, suas saídas serão afetadas, mas os sinais de controle permanecem nos mesmos valores independentemente disto. Representamos um sistema de controle em malha aberta na Figura 1.1.
- **Sistema de Controle em Malha Fechada:** Um sistema de controle em malha fechada mede os valores de variáveis de interesse ou os valores dos modos do sistema e compara estes valores ao comportamento desejado. Desta forma, o controle em malha fechada busca corrigir os valores dos sinais de controle, se algum fator passa a influir no sistema afetando as saídas ou modos internos. Representamos um sistema de controle em malha fechada na Figura 1.2.




Figura 1.1: Sistema de Controle em Malha Aberta




Figura 1.2: Sistema de Controle em Malha Fechada

1.3 Controle Clássico

Inicialmente, a teoria de controle se desenvolveu no sentido de abordar o problema do controle de sistemas lineares devido ao fato de estes obedecerem ao princípio da superposição. A análise matemática destes sistemas se revelou mais amena. Assim, um arcabouço teórico foi desenvolvido em torno do controle linear de sistemas lineares.

Um controlador linear tem seus parâmetros ajustados durante o projeto e eles permanecem constantes durante a operação. Há uma gama de métodos de projeto de controladores lineares para este tipo de sistema, tais como o lugar das raízes e os métodos por resposta frequencial.

No entanto, é raro que um sistema físico obedeça estritamente ao princípio da superposição dentro de toda sua faixa de operação. De fato, a maioria absoluta dos sistemas físicos exibe comportamento não-linear em algum grau. Por isso, para utilizar o arcabouço da teoria de controle de sistemas lineares, tipicamente o projetista se utiliza de modelos linearizados em torno do ponto de operação do sistema.

Com isso, a medida que o sistema se afasta do ponto de operação, o modelo linearizado deixa de ser válido e o controlador linear se torna incapaz de garantir as especificações sobre as variáveis de interesse, pois seus parâmetros são fixos e podem não ser adequados para lidar com o novo ponto de operação.

De fato, sistemas lineares e não-lineares são qualitativamente diferentes e nem sempre é possível para um controlador linear lidar favoravelmente com não-linearidades. Diversos fenômenos que afetam sistemas não-lineares simplesmente não podem ocorrer em sistemas lineares. Um exemplo muito comum é a saturação: tipicamente a planta ou sistema de controle não pode produzir um sinal cujo módulo excede um determinado valor, devido à limitações físicas.

Além disto, o controle clássico aborda o projeto do controlador sob a hipótese de que os parâmetros que descrevem o sistema são constantes e conhecidos sem incertezas. Não obstante, sistemas físicos tipicamente apresentam variação em seus parâmetros devido a desgaste, envelhecimento ou falhas. Além disso, normalmente os componentes de um sistema têm valores nominais que são obedecidos dentro de uma certa tolerância, como, por exemplo, resistores e capacitores. Na prática sempre há alguma quantidade de incerteza acerca dos parâmetros do sistema.

Finalmente, o controle clássico busca lidar com sistemas que dispõem de apenas uma variável de entrada e uma variável saída (Single Input Single Output - **SISO**). Muitos sistemas possuem um conjunto de mais de uma variável de saída ou de entrada, como é o caso de drones, que devem controlar simultaneamente elevação, velocidade, ângulos de rolagem, guinada e arfagem.

Assim, no sentido de superar estas limitações da teoria de controle clássica e abordar o projeto de controladores para sistemas cada vez mais complexos, a teoria de controle moderno desenvolve e apresenta técnicas de projeto de controladores não-lineares. Um exemplo de controlador não-linear é o controlador adaptativo.

1.4 Controle Adaptativo

No controle adaptativo, os parâmetros do controlador são ajustados de acordo com um mecanismo de estimação de parâmetros em tempo real. A partir de medidas de variáveis do sistema, como, por exemplo, sinal de controle e sinal de saída ou modos internos do sistema, é gerada uma lei de ajuste dos parâmetros.

O processo de estimação executado concorrentemente com o controle torna o controlador um sistema não-linear. Devido à não-linearidade, a análise dos sinais presentes no sistema em malha fechada se torna mais complexa.

Este tipo de controle costuma apresentar bons resultados quando os parâmetros da planta são conhecidos com incertezas consideradas suficientemente pequenas e esses parâmetros variam mais lentamente, frente à capacidade do mecanismo de ajustar o controlador. O motivo disto é que, no controle adaptativo, faz-se uso do princípio de equivalência à certeza. Assumimos que o processo de estimação faça com que o controlador busque se adaptar às circunstâncias de operação e tenda aos parâmetros que são adequados para aquelas condições de operação, atingindo um desempenho suficiente.

Assim, o desempenho do controle adaptativo depende, em parte, das características de velocidade, precisão e acurácia com que os parâmetros do controlador podem ser estimados frente a cada situação específica. Na maior parte dos casos, quanto mais rápido, preciso e acurado é o processo de estimação de parâmetros, melhor o desempenho.

O controle adaptativo tem duas estratégias principais, a direta e a indireta:

1.5 Controle Adaptativo Direto e Indireto

Como já mencionamos, um controlador adaptativo nada mais é do que um controlador cujos parâmetros são ajustados por um mecanismo de estimação. Suas duas estratégias são chamadas estratégia direta e estratégia indireta.

Na estratégia direta, os parâmetros do controlador são estimados. A planta é parametrizada em função dos parâmetros ideais do controlador, que são aqueles que seriam calculados por um projetista, caso os parâmetros da planta fossem constantes e conhecidos sem incertezas. O erro da saída do sistema em relação ao comportamento desejado é avaliado e usado na lei de ajuste dos parâmetros do controlador.

A vantagem do controle adaptativo direto é que a estrutura do controlador é mais simples, em relação ao controle adaptativo indireto, o que facilita a implementação. Um exemplo de diagrama de blocos de um controlador adaptativo direto está na Figura 1.3.




Figura 1.3: Controlador Adaptativo Direto

Na abordagem indireta, um modelo de identificação do sistema é ajustado em tempo real de acordo com as informações provenientes da planta, tal como o sinal de controle e saída. O objetivo do modelo de identificação é estimar os parâmetros da planta por

meio de alguma lei de ajuste, como o método do gradiente ou o método dos mínimos quadrados. Busca-se minimizar o erro de identificação entre a saída do modelo e a saída da planta. Considera-se que os parâmetros estimados da planta são os parâmetros verdadeiros e estes parâmetros são usados para realizar o cálculo dos parâmetros do controlador.

O controle adaptativo indireto sofre a desvantagem por ser uma estratégia mais complexa, porém, permite utilizar o conhecimento prévio sobre os parâmetros da planta mais facilmente para inicializar os parâmetros do modelo de identificação. Além disso há uma separação clara entre o processo de estimação dos parâmetros da planta e o ajuste dos parâmetros do controlador, que torna o entendimento da estratégia indireta mais intuitivo. Um exemplo de diagrama de blocos de um controlador adaptativo indireto está na Figura 1.4.




Figura 1.4: Controlador Adaptativo Indireto

1.6 Controle Adaptativo por Modelo de Referência

Como mencionamos, o controle busca garantir especificações sobre um conjunto de variáveis de interesse, por meio do ajuste de outro conjunto de variáveis. Estas especificações podem ser traduzidas na forma de um modelo de referência, um sistema que se comporta da forma desejada em malha aberta, ao ser alimentado por um sinal de referência.

O objetivo do controle por modelo de referência é o de projetar um controlador que faça com que o sistema de controle em malha fechada com a planta tenha sua função de transferência equivalente à do modelo de referência em malha aberta. O modelo de referência especifica a trajetória que as variáveis de interesse devem seguir durante o transitório e os seus valores em regime permanente.

Com este intuito, o controlador é projetado para atingir a chamada condição de **matching**, onde os zeros da planta são cancelados por polos do controlador e substituídos pelos zeros do modelo de referência, e os polos da função de transferência em malha fechada se tornam os polos da função de transferência do modelo de referência.

Devido ao cancelamento dos zeros da planta, o controle por modelo de referência (**MRC**) sofre limitação, sendo aplicável apenas à plantas de fase mínima, isto é, cujos zeros se encontram no semi plano esquerdo aberto do plano complexo. Isto ocorre pois, na prática, o cancelamento de raízes no semi plano direito aberto está sempre sujeito a erro numérico, cujo resíduo leva à instabilidade.

Uma das estratégias de controle que pode ser empregada dentro do paradigma do controle adaptativo é o controle adaptativo por modelo de referência (**MRAC**). Usando as equações obtidas a partir da condição de matching, podemos estimar, direta ou indiretamente, os parâmetros do controlador.

1.7 Controle Adaptativo com Estrutura Variável

No controle adaptativo convencional, as leis de ajuste para os parâmetros são leis integrais, isto é, a cada instante o valor da lei de ajuste é integrado ao valor atual das estimativas. Isto produz estimativas contínuas no tempo. No entanto, em muitos casos, a lei de ajuste integral do controle adaptativo convencional acaba não sendo suficientemente rápida em relação à dinâmica do sistema em que está sendo aplicada. De fato, quando este é o caso, o transitório do sistema se torna lento e oscilatório.

Além disso, quando a planta apresenta dinâmica não modelada ou é sujeita a distúrbios externos, o sistema não apresenta robustez (Rohrs et al. 1985, Costa & Hsu 1991). Para recuperar essa robustez, se fazem necessárias modificações nas leis de ajuste integral que, em geral, tornam ainda mais lento o ajuste das estimativas, limitando a classe de

sistemas para os quais o controle adaptativo convencional é, na prática, aplicável.

Dessa forma, uma ideia que emergiu na área de controle adaptativo, a partir do final dos anos de 1980, foi a de substituir as leis de ajuste integrais do controle adaptativo convencional por leis chaveadas, provenientes da teoria de sistemas com estrutura variável (Hsu & Costa 1989, Hsu 1990, Hsu et al. 1994, Oliveira 2003, Oliveira 2007, Oliveira & Araujo 2008a, Oliveira & Araujo 2008b, Fernandes et al. 2010).

Os sistemas com estrutura variável são baseados no controle à relé, com chaveamento do sinal de controle, isto é, o sinal de controle varia de forma abrupta entre um conjunto de valores.

Nos sistemas com estrutura variável, o sinal de controle restringe a dinâmica das variáveis de estado da planta a uma superfície, chamada superfície de deslizamento (Yanque et al. 2012, Teixeira et al. 2015).

Ao substituir as leis integrais por leis chaveadas, as estimativas dos parâmetros da planta ou controlador passam a ter um conjunto finito de valores que podem assumir, ou seja, as estimativas não variam gradualmente. Em vez disso, a cada instante a lei chaveada decide qual valor é o adequado para cada parâmetro. Assim, como uma forma de controle à relé, no controle adaptativo com estrutura variável há um chaveamento do sinal de controle.

Este chaveamento dá ao controle adaptativo por estrutura variável características desejáveis, tais como a rejeição à dinâmica não modelada e a distúrbios limitados, e a convergência do comportamento da planta para o desejado em tempo finito, sendo que esta última não é possível no caso convencional, mesmo quando os parâmetros da planta são conhecidos sem incertezas. Em contrapartida, o sinal de controle passa a exibir o fenômeno do chattering, no qual o sinal de controle passa a chavear com frequência arbitrariamente alta.

Há uma classe de sistemas dinâmicos para os quais um sinal de controle com chattering não é aplicável, o que motivou uma série de pesquisas que buscaram aproveitar as características desejáveis do controle por estrutura variável, porém suavizando o sinal de controle em regime permanente.

Uma ideia que vem sendo bastante explorada recentemente é a de projetar um controlador em modo dual, aproveitando as características de transitório do controle por estrutura variável e o sinal de controle suave das leis convencionais em regime permanente, o chamado controle adaptativo por modelo de referência em modo dual (Cunha et al. 2007, Cunha 2008, Cunha et al. 2009, Teixeira 2011, Teixeira et al. 2013, Teixeira 2016).

O tema deste trabalho não é o controle por estrutura variável. Apesar disto, mencionamos o mesmo para termos uma base de comparação para a técnica de estimação de

parâmetros que iremos estudar, a adaptação de segundo nível. Assim como o controle por estrutura chaveada, a adaptação de segundo nível se propõe a lidar com incertezas paramétricas maiores e variação mais rápida nos parâmetros da planta, como veremos nas seções a seguir.

1.8 Modelos de Identificação

Como vimos, o controle adaptativo indireto necessita ajustar os parâmetros de um modelo de identificação da planta em tempo real, parâmetros estes que são utilizados para calcular, por sua vez, os parâmetros do controlador.

Um modelo de identificação é um sistema virtual que buscamos tornar equivalente a alguma parametrização válida da planta. Para tanto assumimos conhecer a forma da função de transferência da planta ou a forma de sua representação em espaço de estados e usamos estas informações na criação do modelo de identificação.

O modelo de identificação usado neste trabalho é chamado modelo de identificação por regressão linear. Neste, busca-se fazer com que o sinal de saída do modelo de identificação seja equivalente ao sinal de saída da planta filtrado por uma função de transferência específica. Esta filtragem é feita pois o sinal filtrado pode ser parametrizado como uma combinação linear dos componentes de um vetor, chamado vetor regressor, o qual pode também ser gerado por filtragem dos sinais de saída e entrada da planta.

Os coeficientes desta combinação linear são os coeficientes dos polinômios do numerador e do denominador da função de transferência da planta. Assim, no modelo de identificação por regressão linear, estimamos os coeficientes dos polinômios da função de transferência da planta.

No modelo de identificação por regressão linear, desde que seja possível estabilizar o sistema através de uma ação de controle, o modelo de identificação é estável. Um diagrama de blocos do modelo de identificação por regressão linear se encontra disponível na Figura 1.5.

1.9 Controle Adaptativo baseado em Múltiplos Modelos de Identificação

Como já dissemos, o controle adaptativo costuma apresentar bons resultados quando a incerteza é suficientemente pequena e o mecanismo de estimação é suficientemente rápido. Nesse contexto, o controle adaptativo baseado em múltiplos modelos busca lidar com incertezas maiores acerca dos parâmetros da planta ou com variação paramétrica mais rápida.




Figura 1.5: Modelo de Identificação por Regressão Linear

Nos anos 90 (Narendra & Balakrishnan 1994, Narendra et al. 1995, Narendra & Balakrishnan 1997), foram feitas propostas de controle adaptativo baseado em múltiplos modelos através do chaveamento entre modelos de identificação inicializados com parâmetros diferentes, com alguns modelos tendo parâmetros fixos e outros, ajustados por leis integrais.

Apesar de exibir bons resultados de simulação, essa técnica apresenta uma limitação, pois se baseia na ideia de que os parâmetros de pelo menos um modelo devem estar localizados suficientemente próximos dos parâmetros da planta, fazendo com que seja necessário utilizar um grande número de modelos para atingir um bom desempenho, o que depende exponencialmente da ordem da planta. Em consequência, plantas de maior grau necessitariam de uma quantidade proibitiva de modelos inicializados de tal forma a garantir que os parâmetros da planta estivessem em uma vizinhança pequena de algum deles.

Mais recentemente, no entanto, em (Han & Narendra 2011), foi introduzido um novo conceito ao controle adaptativo baseado em múltiplos modelos de identificação, conhecido como adaptação de segundo nível. Utilizando a informação de cada um dos modelos é formada uma combinação dos parâmetros, que é utilizada como estimativa dos parâmetros da planta.

Em vez de necessitar de um número de modelos que cresce exponencialmente com a ordem da planta para garantir um bom desempenho, a adaptação de segundo nível necessita de um número que cresce linearmente.

1.10 Modelos Virtuais por Combinação Convexa

Em (Narendra & Han 2010) foi estabelecido, para um caso particular, que um modelo de identificação virtual cujos parâmetros são formados por uma combinação convexa dos parâmetros de múltiplos modelos de identificação se comporta, dentro de certas circunstâncias, de forma idêntica a um modelo de identificação inicializado com os mesmos

valores de parâmetros.

Consequentemente, uma combinação convexa dos parâmetros de múltiplos modelos de identificação pode ser utilizada como estimativa dos parâmetros da planta. De fato, se os parâmetros da planta pertencem ao interior ou fronteira de um fecho convexo formado pelos parâmetros dos modelos de identificação, então os parâmetros da planta permanecerão na fronteira ou interior desse fecho convexo, independentemente do ajuste dos parâmetros dos modelos de identificação.

Esta propriedade pode, então, ser explorada, pois além do ajuste dos parâmetros dos modelos de identificação, podemos, concorrentemente, estimar os coeficientes da combinação convexa referente aos parâmetros verdadeiros da planta.

1.11 Adaptação de Segundo Nível

Em um segundo nível de estimação, ou segunda camada de adaptação, busca-se estimar os coeficientes de uma combinação convexa de múltiplos modelos de identificação, para que essa combinação convexa tenda aos valores verdadeiros dos parâmetros da planta. Ao mesmo tempo, os parâmetros dos modelos de identificação também são ajustados. Passamos a chamar os modelos de identificação de modelos de primeiro nível.

Devido à propriedade do fecho convexo discutida anteriormente, é possível obter uma lei de ajuste para as estimativas dos coeficientes da combinação convexa, baseada nos erros de identificação dos modelos. Com isso, a adaptação de segundo nível entrega as estimativas dos parâmetros da planta como combinações convexas (a) de coeficientes variantes no tempo e (b) dos parâmetros de múltiplos modelos de identificação, também variantes no tempo.

A adaptação de segundo nível como método de estimação de parâmetros é muito mais rápida em atingir os parâmetros verdadeiros, em relação aos métodos de estimação convencionais, pelo fato de que as informações provenientes de múltiplas fontes são utilizadas e combinadas.

Como mencionamos no início do capítulo, esse trabalho tem como um de seus objetivos estudar a adaptação de segundo nível, começando pela caracterização do modelo de identificação por regressão linear e sua lei de ajuste, passando à investigação sobre a propriedade do fecho convexo para este modelo de identificação e, finalmente, à aplicação do conceito de adaptação de segundo nível como método de estimação de parâmetros.

Adicionalmente, como contribuição deste trabalho, realizamos uma modificação na lei de ajuste dos coeficientes da adaptação de segundo nível e que chamamos adaptação de segundo nível com fator de esquecimento, que levou a uma convergência mais rápida e suave dos parâmetros para seus valores corretos em estudos de simulação.

Finalmente, neste trabalho, aplicamos o conceito de adaptação de segundo nível como técnica de estimação de parâmetros ao controlador adaptativo por modelo de referência indireto. Substituímos as estimativas dos parâmetros da planta que seriam obtidas pelo método do gradiente normalizado por combinações convexas dos parâmetros de múltiplos modelos de identificação por regressão linear baseadas em adaptação de segundo nível.

Um diagrama de blocos deste conceito está disponível na Figura 1.6. A motivação por trás desta aplicação da adaptação de segundo nível ao controle adaptativo por modelo de referência indireto é a de melhorar o desempenho do controlador. Até onde sabemos, essa é primeira dissertação de mestrado a tratar da adaptação de segundo nível no Brasil.




Figura 1.6: Controlador Adaptativo Indireto de Segundo Nível

1.12 Estrutura do Trabalho

Este trabalho está organizado como segue:

O capítulo 1 contém esta introdução destinada a esclarecer o objetivo, tema e premissas do trabalho.

O capítulo 2 contém o caso da adaptação de segundo nível como método de estimação de parâmetros aplicado a uma planta de ordem 1 e grau relativo unitário. Primeiramente introduzimos o modelo de identificação por regressão linear, mostrando as leis de ajuste para seus parâmetros e demonstrando a estabilidade do processo de estimação. A seguir, discutimos a propriedade do fecho convexo e demonstramos como aplicar o conceito de adaptação de segundo nível. Demonstramos a estabilidade do estimador resultante. Disponibilizamos os algoritmos de forma compacta como um resumo no final do capítulo e realizamos a aplicação de cada um destes conceitos em estudos de simulação, de forma que o leitor possa comparar os resultados.

No capítulo 3, mostramos a condição de matching para um controlador por modelo de referência indireto para uma planta de ordem 1 e grau relativo unitário. A partir da condição de matching e das estimativas dos parâmetros da planta, os parâmetros do controlador adaptativo são calculados, na estratégia indireta. Finalmente, realizamos estudos de simulação comparando o método do gradiente, a adaptação de segundo nível e o controle com estrutura variável, este na estratégia direta.

O capítulo 4 contém o caso da adaptação de segundo nível como método de estimação de parâmetros para uma planta de ordem n e grau relativo unitário. Novamente introduzimos o modelo por regressão linear, mostramos sua lei de ajuste para os parâmetros e demonstramos a estabilidade do processo de estimação para cada um dos modelos. Discutimos a propriedade do fecho convexo e aplicamos o conceito de adaptação de segundo nível. Demonstramos a estabilidade do estimador resultante. Disponibilizamos os algoritmos de forma compacta como um resumo no final do capítulo e aplicamos cada um dos conceitos mostrados em estudos de simulação comparativos.

No capítulo 5, mostramos a condição de matching para o controlador por modelo de referência para uma planta de ordem n e grau relativo unitário. A partir da condição de matching e das estimativas dos parâmetros da planta, os parâmetros do controlador adaptativo são calculados, na estratégia indireta. Finalmente, realizamos estudos de simulação comparando o método do gradiente, adaptação de segundo nível, adaptação de segundo nível com fator de esquecimento e o controle com estrutura variável, este na estratégia direta.

No capítulo 6 concluímos discutindo o que foi feito e perspectivas futuras.

Capítulo 2

Estimação de Parâmetros, Ordem 1

2.1 Introdução

Ao modelar um sistema dinâmico como um sistema linear descrito por uma função de transferência, é comum lidar com incertezas nos coeficientes dos polinômios do numerador e denominador desta função, as chamadas incertezas paramétricas.

As incertezas paramétricas têm vários fatores, dentre os quais estão a falta de conhecimento completo sobre componentes físicos, cujos valores tipicamente se encontram dentro de uma certa tolerância, como resistores, capacitores, amortecedores, indutores; as aproximações na modelagem devido a eventual não-linearidade dos sistemas; variações dos parâmetros devido ao desgaste ou envelhecimento, como, por exemplo, uma engrenagem cujos dentes se desgastam com o uso ou o óleo de um motor de automóvel cuja viscosidade aumenta com o tempo; e, também, devido a falhas de componentes como um transformador danificado por sobretensão na linha de transmissão.

Uma forma de abordar o problema das incertezas paramétricas de modo a melhorar o conhecimento sobre a dinâmica atual do sistema é através da estimação dos parâmetros em tempo real, que permite um conhecimento mais preciso dos parâmetros. Isto, por sua vez, pode permitir decisões melhores acerca de qual ação de controle tomar.

Através de um modelo de estimação em tempo real do sistema estudado, gera-se a diferença entre o sinal de saída do sistema e o sinal de saída do modelo de estimação, o chamado erro de identificação. Este erro pode ser empregado para gerar leis integrais para atualizar as estimativas, que faz com que elas se aproximem dos valores corretos em regime permanente. Com isso, também, o erro de identificação tende a um valor nulo.

Quando um sistema linear é sujeito a um sinal de entrada com a característica de persistência de excitação, existe garantia de convergência das estimativas dos parâmetros para seus valores corretos (Boyd & Sastry 1986, NARENDRA & ANNASWAMY 1987, Bitmead 1984). O modelo de estimação se torna, então, um modelo de identificação pois eventualmente seus parâmetros serão idênticos aos parâmetros do sistema linear e não apenas estimativas próximas. Um exemplo de sinal persistentemente excitante de ordem

1 é um sinal senoidal contendo pelo menos uma frequência.

Apresentamos primeiramente um caso simples, da planta de ordem 1 e grau relativo unitário, por motivos didáticos, para que o leitor possa se familiarizar com as técnicas e conceitos discutidos, da forma como é feito na literatura como por exemplo em (Narendra & Annaswamy 1989, Ioannou & Sun 1996, Tao 2003).

Neste capítulo descreveremos o modelo de identificação por regressão linear, cujos parâmetros podem ser atualizados por leis integrais para identificar os parâmetros da função de transferência de uma planta de ordem 1 e grau relativo 1, e chamaremos esse modelo de modelo de primeiro nível. Para garantir a convergência dos parâmetros usaremos sinais de controle com persistência de excitação de ordem 1. Provaremos a estabilidade do estimador de parâmetros para tal modelo.

A descrição do modelo de identificação por regressão linear serve como uma introdução para que se possa discutir a técnica de estimação de parâmetros chamada adaptação de segundo nível, que foi introduzida por Han e Narendra em (Han & Narendra 2011), com base em propriedades mostradas em (Han & Narendra 2010), com resultados estendidos para o caso SISO em (Narendra et al. 2015).

Na adaptação de segundo nível, os coeficientes de uma combinação linear convexa das estimativas dos parâmetros da planta vindas de múltiplos modelos de identificação de primeiro nível são atualizados por leis integrais como uma segunda camada de adaptação. Isto traz uma vantagem em termos de rapidez de convergência dos parâmetros, como foi extensivamente demonstrado em (Han & Narendra 2012, Narendra et al. 2012, Narendra et al. 2014) e se deve ao fato de que a informação proveniente dos múltiplos modelos é combinada.

Colocamos os algoritmos utilizados nas Tabelas 2.1 e 2.2, apresentadas ao final do capítulo. Após a descrição dos métodos de identificação de parâmetros, fizemos estudos de simulação utilizando cada uma destes métodos, discutindo seus resultados.

2.2 Descrição do Problema

Considere a seguinte planta de ordem 1, grau relativo unitário, linear e invariante no tempo, descrita pela função de transferência:

$$\Sigma_p : G(s) = \frac{y(s)}{u(s)} = \frac{k_p}{s + a_p}$$

onde sabe-se que $G(s)$ é estritamente própria e os parâmetros $k_p \in [k_p^-, k_p^+]$, $k_p^+ > 0$ e $k_p^- > 0$ ou $k_p^+ < 0$ e $k_p^- < 0$ e $a_p \in [a_p^-, a_p^+]$, $a_p^+ > 0$ e $a_p^- > 0$ têm limitantes inferiores e superiores, $k_p^+, k_p^-, a_p^+, a_p^-$, que são conhecidos; y é o sinal de saída da planta e u é o sinal

de entrada da planta, ambos contínuos por partes.

O objetivo da identificação de parâmetros é, a partir dos sinais disponíveis para medição no sistema, determinar quais os valores dos parâmetros a_p e k_p . Inicialmente, consideramos que os sinais disponíveis são suficientes para realizar esta tarefa, o que se traduz na condição de que o sinal de entrada da planta seja uniformemente limitado e que seja capaz de excitar seus modos de forma persistente, ou seja, que $u(t)$ seja persistentemente excitante (PE). Um exemplo de sinal PE de ordem 1 é um sinal senoidal contendo pelo menos uma frequência.

2.3 Identificação Paramétrica Convencional

Ao manipular a função de transferência da planta, podemos escrever, no domínio da frequência, que:

$$sy(s) = -a_p y(s) + k_p u(s) \quad (2.1)$$

Definimos, então, o seguinte polinômio:

$$\Lambda(s) \triangleq s + \lambda \quad (2.2)$$

com $\lambda > 0$ e escrevemos a partir de 2.1:

$$\frac{s}{\Lambda(s)} y(s) = -a_p \frac{1}{\Lambda(s)} y(s) + k_p \frac{1}{\Lambda(s)} u(s) \quad (2.3)$$

Então, definimos os seguintes sinais:

$$\begin{aligned} z(s) &\triangleq \frac{s}{\Lambda(s)} y(s) \\ \phi(s) &\triangleq \begin{bmatrix} \frac{-y(s)}{\Lambda(s)} & \frac{u(s)}{\Lambda(s)} \end{bmatrix}^T \end{aligned} \quad (2.4)$$

onde é possível gerar ϕ , ao filtrarmos $y(t)$ e $u(t)$:

$$\begin{aligned} \dot{\phi}_1 &= -\lambda \phi_1 - y \\ \dot{\phi}_2 &= -\lambda \phi_2 + u \\ \phi &= [\phi_1 \quad \phi_2]^T \end{aligned} \quad (2.5)$$

que, a partir de 2.3, resulta na seguinte parametrização:

$$z(s) = [a_p \quad k_p] \phi \quad (2.6)$$

e podemos notar que z depende de uma combinação linear dos componentes do vetor ϕ , cujos coeficientes são os parâmetros do numerador e denominador da função de transferência da planta a_p e k_p .

Podemos gerar z da seguinte forma:

$$z = y + \lambda \phi_1 \quad (2.7)$$

Criamos, então, um modelo de identificação a partir de uma combinação linear dos sinais componentes do vetor ϕ :

$$\Sigma_{1,f} : \hat{z}_1 = [\hat{a}_{1,f} \quad \hat{k}_{1,f}] \phi \quad (2.8)$$

e temos agora um modelo cujos parâmetros desejamos ajustar, tal que tendam aos parâmetros da planta.

Queremos que a saída deste modelo se comporte identicamente ao sinal $z(t)$. Portanto, devemos avaliar a diferença entre o sinal de saída do modelo e o sinal z .

Definimos, então, um erro de identificação:

$$e_{1,f} \triangleq \hat{z}_1 - z \quad (2.9)$$

O sinal filtrado da saída da planta e seu modelo de identificação podem ser representados pelas equações diferenciais:

$$\begin{aligned} \dot{z} &= -\lambda z - a_p y + k_p u \\ \dot{\hat{z}}_1 &= -\lambda \hat{z}_1 - \hat{a}_{1,f} y + \hat{k}_{1,f} u - \dot{\hat{a}}_{1,f} \phi_1 + \dot{\hat{k}}_{1,f} \phi_2 \end{aligned} \quad (2.10)$$

Para avaliar a dinâmica do erro $\dot{e}_{1,f} = \dot{\hat{z}}_1 - \dot{z}$, pode-se substituir $\dot{z}$ e $\dot{\hat{z}}_1$ pelas expressões em 2.10. Assim, a dinâmica de $e_{1,f}$ é dada por:

$$\dot{e}_{1,f} = -\lambda \hat{z}_1 - \hat{a}_{1,f} y + \hat{k}_{1,f} u + \lambda z + a_p y - k_p u - \dot{\hat{a}}_{1,f} \phi_1 + \dot{\hat{k}}_{1,f} \phi_2 \quad (2.11)$$

Definimos os erros paramétricos, para simplificar a expressão 2.11:

$$\begin{aligned} \tilde{a}_{1,f} &\triangleq \hat{a}_{1,f} - a_p \\ \tilde{k}_{1,f} &\triangleq \hat{k}_{1,f} - k_p \end{aligned} \quad (2.12)$$

tal que:

$$\dot{e}_{1,f} = -\lambda e_{1,f} - \tilde{a}_{1,f} y + \tilde{k}_{1,f} u - \dot{\hat{a}}_{1,f} \phi_1 + \dot{\hat{k}}_{1,f} \phi_2 \quad (2.13)$$

Para analisar o comportamento deste sistema, usamos uma candidata a função de Lyapunov definida positiva da forma:

$$V(e_{1,f}, \tilde{a}_{1,f}, \tilde{k}_{1,f}) = \frac{1}{2}(e_{1,f}^2 + \tilde{a}_{1,f}^2 + \tilde{k}_{1,f}^2) \quad (2.14)$$

e derivamos ao longo das trajetórias, obtendo a seguinte expressão:

$$\begin{aligned}\dot{V} &= e_{1,f}\dot{e}_{1,f} + \tilde{a}_{1,f}\dot{\tilde{a}}_{1,f} + \tilde{k}_{1,f}\dot{\tilde{k}}_{1,f} \\ &= -\lambda e_{1,f}^2 - \tilde{a}_{1,f}e_{1,f}y + \tilde{k}_{1,f}e_{1,f}u + \tilde{a}_{1,f}\dot{\tilde{a}}_{1,f} + \tilde{k}_{1,f}\dot{\tilde{k}}_{1,f} - \dot{\hat{a}}_{1,f}e_{1,f}\phi_1 + \dot{\hat{k}}_{1,f}e_{1,f}\phi_2\end{aligned}\quad (2.15)$$

Como a planta é invariante no tempo, temos que:

$$\begin{aligned}\tilde{a}_{1,f} &= \hat{a}_{1,f} - a_p \rightarrow \dot{\tilde{a}}_{1,f} = \dot{\hat{a}}_{1,f} - \overset{0}{\dot{a}_p} = \dot{\hat{a}}_{1,f} \\ \tilde{k}_{1,f} &= \hat{k}_{1,f} - k_p \rightarrow \dot{\tilde{k}}_{1,f} = \dot{\hat{k}}_{1,f} - \overset{0}{\dot{k}_p} = \dot{\hat{k}}_{1,f}\end{aligned}$$

ou seja, a variação do erro paramétrico em relação ao tempo é idêntica à variação das próprias estimativas $\hat{a}_{1,f}$ e $\hat{k}_{1,f}$.

Este fato, em conjunto com 2.15 nos permite, então, escolher leis integrais para atualizar $\hat{a}_{1,f}$ e $\hat{k}_{1,f}$:

$$\begin{aligned}\dot{\hat{a}}_{1,f} &= e_{1,f}y \\ \dot{\hat{k}}_{1,f} &= -e_{1,f}u\end{aligned}\quad (2.16)$$

de forma que temos a seguinte expressão para $\dot{V}$:

$$\dot{V}(e_{1,f}, \tilde{a}_{1,f}, \tilde{k}_{1,f}) = -(\lambda + y\phi_1 + u\phi_2)e_{1,f}^2 \quad (2.17)$$

A região de incerteza que contém os parâmetros da planta é conhecida, assim como o sinal dos parâmetros, e, desta forma, para uma frequência de sinal de entrada qualquer, sabemos que o módulo da função de transferência da planta cumpre a seguinte restrição:

$$|G(jw)| \leq \left| \frac{k_p^+}{jw + a_p^-} \right| \quad (2.18)$$

e, portanto, desde que o sinal u seja uniformemente limitado e a planta seja estável, podemos garantir a seguinte condição:

$$\lambda > y\phi_1 + u\phi_2 \quad (2.19)$$

pois pode-se escolher λ maior que o supremo da soma dos módulos dos sinais $y\phi_1$ e $u\phi_2$.

As funções de transferência para ϕ_1 e ϕ_2 representam filtros passa-baixa de primeira ordem. O maior ganho de amplitude que um filtro passa-baixa de primeira ordem pode impor a um sinal é quando a frequência do sinal é nula. Devido a isto podemos escrever:

$$\begin{aligned}\sup(|y|) &\leq \sup(|u|) \left| \frac{k_p^+}{j\omega + a_p^-} \right| \\ \sup(|\phi_1|) &\leq \frac{\sup(|u|)}{\lambda} \left| \frac{k_p^+}{j\omega + a_p^-} \right| \\ \sup(|\phi_2|) &\leq \frac{\sup(|u|)}{\lambda}\end{aligned}$$

Temos, devido ao resultado acima, que a escolha de λ cumpre:

$$\lambda > \sup(|u|) \sqrt{\left| \frac{k_p^+}{j\omega + a_p^-} \right| + 1} \quad (2.20)$$

e é suficiente para garantir que $\dot{V}$ seja semi-definida negativa. Com isso, V não pode crescer, implicando em:

$$\begin{aligned}e_{1,f} &\in \mathcal{L}_\infty \\ \tilde{a}_{1,f} &\in \mathcal{L}_\infty \rightarrow \hat{a}_{1,f} \in \mathcal{L}_\infty \\ \tilde{k}_{1,f} &\in \mathcal{L}_\infty \rightarrow \hat{k}_{1,f} \in \mathcal{L}_\infty\end{aligned}$$

O sinal de controle u deve ser escolhido tal que seja capaz de excitar a planta persistentemente e seja uniformemente limitado e contínuo por partes, como mencionamos anteriormente.

Devido ao fato de que a planta é estável e u é uniformemente limitado, os sinais y e ϕ_2 são uniformemente limitados. Como o sinal y é uniformemente limitado, isto implica em ϕ_1 uniformemente limitado, que implica em z uniformemente limitado. Como $e_{1,f}$ e z são uniformemente limitados, isto implica em $\hat{z}_1$ uniformemente limitado. Como $e_{1,f}, y$ e u são uniformemente limitados, isto implica em $\hat{a}_{1,f}$ e $\hat{k}_{1,f}$ uniformemente limitados. Finalmente, a partir de 2.13, podemos concluir que $\dot{e}_{1,f}$ é uniformemente limitado, pois todos os outros sinais presentes na expressão são uniformemente limitados.

Então, manipulamos a equação 2.17:

$$\begin{aligned}e_{1,f}^2 &= -\frac{1}{\lambda + y\phi_1 + u\phi_2} \dot{V} \\ \int_0^\infty e_{1,f}^2 &\leq -\frac{1}{\lambda - \sup(|y\phi_1|) - \sup(|u\phi_2|)} \int_0^\infty \dot{V} \\ \int_0^\infty e_{1,f}^2 &\leq \frac{1}{\lambda - \sup(|y\phi_1|) - \sup(|u\phi_2|)} (V(0) - V(\infty))\end{aligned}$$

o que nos permite concluir que:

$$e_{1,f} \in \mathcal{L}_2$$

A partir de um corolário do lema de Barbalat, como $e_{1,f}$ é uniformemente limitado, tem norma $\mathcal{L}_2$ limitada e sua derivada é uniformemente limitada, temos que:

$$\lim_{t \rightarrow \infty} e_{1,f} = 0$$

e a saída $\hat{z}_1$ do modelo de identificação tende assintoticamente para z . Em outros termos, a saída modelo de identificação tende a se comportar como a saída da planta filtrada.

Por fim, quando o sinal de controle u é persistentemente excitante, $e_{1,f} = 0$ para todo tempo $t > t_0$, se e somente se $\tilde{a}_{1,f} = 0$ e $\tilde{k}_{1,f} = 0$. Assim, as estimativas $\hat{a}_{1,f}$ e $\hat{k}_{1,f}$ devem tender aos valores corretos a_p e k_p , respectivamente, para $t \rightarrow \infty$, fato que não demonstraremos nesta seção.

É importante notar que, ao usarmos o modelo de identificação por regressão linear, o valor de $\dot{V}$ depende de λ que é um parâmetro de projeto do estimador. Desse modo, a velocidade de convergência de $e_{1,f}$ para 0 depende de um parâmetro de projeto. $\hat{z}_1$ é gerado a partir de uma combinação linear dos componentes do vetor ϕ com os parâmetros $\hat{a}_{1,f}$ e $\hat{k}_{1,f}$.

Para mais informações acerca do modelo de identificação por regressão linear discutido, incluindo a prova de convergência das estimativas para os valores corretos na presença de um sinal de entrada PE, referimos o leitor a (Ioannou & Sun 1996, Narendra & Annaswamy 1989, Tao 2003).

2.4 Adaptação de Segundo Nível

A partir da parametrização que desenvolvemos na seção anterior, consideremos os $i = 1, \dots, N$, com $N \geq 3$, modelos de identificação por regressão linear:

$$\Sigma_{i,f} : \hat{z}_{i,f} = [\hat{a}_{i,f} \quad \hat{k}_{i,f}] \phi \quad (2.21)$$

onde os parâmetros $\hat{a}_{i,f}$ e $\hat{k}_{i,f}$ são inicializados nos vértices de um fecho convexo no espaço de parâmetros. Este fecho convexo deve conter a região de incerteza para os parâmetros a_p e k_p da planta, que é delimitada por um polítopo convexo cujos vértices são as combinações dos limitantes inferiores e superiores $k_p^+, k_p^-, a_p^+, a_p^-$, que são conhecidos. Neste caso, portanto, a escolha das estimativas iniciais $\hat{a}_{i,f}$ e $\hat{k}_{i,f}$ deve formar um fecho convexo que contém o polítopo convexo de vértices $[a_p^+ \quad k_p^+]^T$, $[a_p^+ \quad k_p^-]^T$, $[a_p^- \quad k_p^-]^T$, $[a_p^- \quad k_p^+]^T$ no espaço de parâmetros.

Definimos os $i = 1, \dots, N$ erros de identificação em relação ao sinal filtrado da planta

$z(t)$:

$$e_{i,f} \triangleq \hat{z}_{i,f} - z \quad (2.22)$$

Definimos os erros paramétricos dos N modelos, com $i = 1, \dots, N$:

$$\begin{aligned} \tilde{a}_{i,f} &\triangleq \hat{a}_{i,f} - a_p \\ \tilde{k}_{i,f} &\triangleq \hat{k}_{i,f} - k_p \end{aligned} \quad (2.23)$$

Seguindo o mesmo procedimento da seção anterior, as $2N$ estimativas dos parâmetros da planta podem ser atualizadas pelas leis integrais:

$$\begin{aligned} \dot{\hat{a}}_{i,f} &= e_{i,f} y \\ \dot{\hat{k}}_{i,f} &= -e_{i,f} u \end{aligned} \quad (2.24)$$

onde os N modelos de identificação têm a mesma estrutura e portanto usam o mesmo tipo de lei de ajuste de seus parâmetros. Cada um dos modelos de identificação tem a diferença entre seu sinal de saída e o sinal z avaliado e este erro de identificação é usado para realizar o ajuste dos parâmetros de cada modelo a cada instante de tempo.

A dinâmica de cada um dos erros de identificação, pelo mesmo procedimento da seção anterior, é da seguinte forma:

$$\dot{e}_{i,f} = -(\lambda + y\phi_1 + u\phi_2)e_{i,f} - \tilde{a}_{i,f}y + \tilde{k}_{i,f}u \quad (2.25)$$

com $i = 1, \dots, N$.

Faremos agora um detalhamento do raciocínio referente à introdução de uma segunda camada de estimação, ou adaptação de segundo nível. Como já mencionamos os vetores de parâmetros $[\hat{a}_{i,f} \ \hat{k}_{i,f}]$, $i = 1, \dots, N$ formam um fecho convexo no espaço de parâmetros. Cada um dos pontos no interior ou fronteira deste fecho convexo pode ser representado por uma combinação convexa:

$$\begin{aligned} \hat{a}_{v,f} &= \sum_{i=1}^N \hat{a}_{i,f} \beta_{i,f} \\ \hat{k}_{v,f} &= \sum_{i=1}^N \hat{k}_{i,f} \beta_{i,f} \\ \sum_{i=1}^N \beta_{i,f} &= 1 \\ 0 &\leq \beta_{i,f} \leq 1 \end{aligned} \quad (2.26)$$

Criamos um modelo de identificação virtual a partir de alguma destas combinações convexas:

$$\Sigma_{v,f} : \hat{z}_{v,f} = [\hat{a}_{v,f} \ \hat{k}_{v,f}] \phi \quad (2.27)$$

e buscamos saber quais as propriedades deste modelo de identificação virtual frente aos modelos de identificação por regressão linear que viemos estudando.

Definimos o erro de identificação para o modelo virtual:

$$e_{v,f} \triangleq \hat{z}_{v,f} - z \quad (2.28)$$

Definimos, também, os erros paramétricos para o modelo virtual:

$$\begin{aligned} \tilde{a}_{v,f} &\triangleq \hat{a}_{v,f} - a_p \\ \tilde{k}_{v,f} &\triangleq \hat{k}_{v,f} - k_p \end{aligned} \quad (2.29)$$

e podemos manipular suas expressões da seguinte forma:

$$\begin{aligned} \tilde{a}_{v,f} &= \sum_{i=1}^N \hat{a}_{i,f} \beta_{i,f} - a_p = \sum_{i=1}^N \hat{a}_{i,f} \beta_{i,f} - \sum_{i=1}^N a_p \beta_{i,f} = \sum_{i=1}^N \tilde{a}_{i,f} \beta_{i,f} \\ \tilde{k}_{v,f} &= \sum_{i=1}^N \hat{k}_{i,f} \beta_{i,f} - k_p = \sum_{i=1}^N \hat{k}_{i,f} \beta_{i,f} - \sum_{i=1}^N k_p \beta_{i,f} = \sum_{i=1}^N \tilde{k}_{i,f} \beta_{i,f} \end{aligned} \quad (2.30)$$

onde obtemos que, assim como as estimativas do modelo virtual são combinações convexas dos parâmetros dos modelos por regressão linear, os erros paramétricos para o modelo virtual podem ser obtidos como combinações convexas dos erros paramétricos dos modelos por regressão linear, com os mesmos coeficientes de combinação.

Como as estimativas $\hat{a}_{v,f}$ e $\hat{k}_{v,f}$ são combinações convexas dos parâmetros dos modelos por regressão linear, segue que as leis adaptativas que governam o ajuste de $k_{v,f}$ e $a_{v,f}$ são combinações convexas das leis de ajuste para os modelos por regressão linear:

$$\begin{aligned} \dot{\hat{a}}_{v,f} &= \sum_{i=1}^N \dot{\hat{a}}_{i,f} \beta_{i,f} = \sum_{i=1}^N e_{i,f} \beta_{i,f} y \\ \dot{\hat{k}}_{v,f} &= \sum_{i=1}^N \dot{\hat{k}}_{i,f} \beta_{i,f} = - \sum_{i=1}^N e_{i,f} \beta_{i,f} u \end{aligned} \quad (2.31)$$

Pelo mesmo procedimento que seguimos anteriormente, devido ao fato de utilizar a mesma estrutura dos modelos por regressão linear, assumimos que a dinâmica do erro de identificação terá a mesma forma da dos modelos de identificação por regressão linear:

$$\dot{e}_{v,f} = -(\lambda + y\phi_1 + u\phi_2)e_{v,f} - \tilde{a}_{v,f}y + \tilde{k}_{v,f}u \quad (2.32)$$

A equação 2.31 mostra que a lei de ajuste para os parâmetros do modelo virtual depende da combinação convexa dos erros de identificação dos modelos por regressão linear.

Vamos, portanto, analisar a dinâmica desta combinação convexa. Derivamos $\sum_{i=1}^N e_{i,f} \beta_{i,f}$, substituindo as dinâmicas dos erros $\dot{e}_{i,f}$ por suas expressões a partir de 2.25 e utilizando 2.30 para reagrupar as combinações convexas de erros paramétricos. Obtemos a seguinte

equação:

$$\sum_{i=1}^N \dot{e}_{i,f} \beta_{i,f} = -(\lambda + y\phi_1 + u\phi_2) \sum_{i=1}^N e_{i,f} \beta_{i,f} - \tilde{a}_{v,f} y + \tilde{k}_{v,f} u \quad (2.33)$$

e, comparando 2.32 com 2.33, vemos que a dinâmica da combinação convexa $\sum_{i=1}^N e_{i,f} \beta_{i,f}$ é idêntica à dinâmica do erro de identificação do modelo virtual $e_{v,f}$. A combinação convexa dos erros de identificação tende exponencialmente para o valor do erro de identificação do modelo virtual. Se estipularmos, no entanto, que $e_{v,f}(0) = \sum_{i=1}^N e_{i,f}(0) \beta_{i,f}$ então $e_{v,f}$ e $\sum_{i=1}^N e_{i,f} \beta_{i,f}$ se tornam idênticos. Assim, desde que $e_{v,f}(0) = \sum_{i=1}^N e_{i,f}(0) \beta_{i,f}$ teremos que o erro de identificação do modelo virtual é simplesmente a combinação convexa dos erros de identificação dos modelos de primeiro nível:

$$e_{v,f} = \sum_{i=1}^N e_{i,f} \beta_{i,f} \quad (2.34)$$

Feitas estas considerações, teremos então que as expressões das leis adaptativas se reduzem a:

$$\begin{aligned} \dot{\hat{a}}_{v,f} &= e_{v,f} y \\ \dot{\hat{k}}_{v,f} &= -e_{v,f} u \end{aligned} \quad (2.35)$$

e vemos que as leis adaptativas obtidas acima têm forma idêntica àsquelas usadas nos modelos de primeiro nível $\Sigma_{i,f}$, $i = 1, \dots, N$. Cada um dos pontos no interior do fecho convexo corresponde a um modelo virtual. Conforme os modelos de primeiro nível têm seus parâmetros ajustados adaptativamente os modelos virtuais também tem seus parâmetros ajustados por leis idênticas, pois um modelo virtual tem leis de ajuste equivalentes a de modelos de primeiro nível. Dentro das condições que descrevemos, uma combinação convexa de coeficientes constantes dos parâmetros de modelos de primeiro nível se comporta exatamente como parâmetros de um modelo de primeiro nível inicializados naqueles mesmos valores.

Então, os parâmetros verdadeiros da planta a_p e k_p , que pertencem inicialmente ao fecho convexo, podem ser representados por uma combinação convexa de coeficientes

$\alpha_{i,f}^*, i = 1, \dots, N$ dos parâmetros dos modelos de primeiro nível:

$$\begin{aligned} a_p &= \sum_{i=1}^N \hat{a}_{i,f} \alpha_{i,f}^* \\ k_p &= \sum_{i=1}^N \hat{k}_{i,f} \alpha_{i,f}^* \\ \sum_{i=1}^N \alpha_{i,f}^* &= 1 \\ 0 &\leq \alpha_{i,f}^* \leq 1 \end{aligned} \quad (2.36)$$

Definimos o seguinte modelo virtual:

$$\Sigma_{\alpha,f} : \hat{z}_{\alpha,f} = [a_p \quad k_p] \phi \quad (2.37)$$

Definimos o erro de identificação para este modelo virtual:

$$e_{\alpha,f} \triangleq \hat{z}_{\alpha,f} - z \quad (2.38)$$

cujas dinâmica é dada por:

$$\dot{e}_{\alpha,f} = -(\lambda + y\phi_1 + u\phi_2)e_{\alpha,f} \quad (2.39)$$

pois o erro paramétrico para este modelo virtual é nulo.

Vemos que o modelo virtual cujos parâmetros são idênticos aos da planta tende exponencialmente ao comportamento da própria planta. Como não podemos garantir com modelos de identificação por regressão linear que $\sum_{i=1}^N e_{i,f}(0)\alpha_{i,f}^* = 0$, o valor de $e_{\alpha,f}(0)$ pode ser não-nulo. No entanto, como escolhemos $\lambda > \sup(y\phi_1 + u\phi_2)$ o termo $(\lambda + y\phi_1 + u\phi_2)$ é sempre maior que 0 e $e_{\alpha,f}$ deve tender a 0 exponencialmente.

Portanto, mesmo que os parâmetros da planta deixem de pertencer ao fecho convexo devido ao efeito das condições iniciais, representadas por $e_{\alpha,f}(0)$ não-nulo, eventualmente a combinação convexa de coeficientes $\alpha_{i,f}^*$ dos erros de identificação dos modelos de primeiro nível tende a 0. Isto indica que em regime permanente os parâmetros da planta pertencem ao fecho convexo formado pelos parâmetros dos modelos de identificação de primeiro nível.

Se a combinação convexa dos erros de identificação não-nulos se torna constante e nula a partir de um certo instante então a combinação convexa dos erros paramétricos também deve se tornar constante e nula. Desta forma os coeficientes $\alpha_{i,f}^*, i = 1, \dots, N$ servem como alternativas de parametrização para a planta.

Assim, como uma segunda camada de estimação, ou segundo nível de adaptação, podemos buscar estimar os coeficientes da combinação linear. Consideramos, portanto, que

a equação $\sum_{i=1}^N e_{i,f} \alpha_{i,f}^* = 0$ é uma ferramenta adequada de estimação.

Definimos o seguinte vetor:

$$\bar{E}_f \triangleq [e_{1,f} \quad \dots \quad e_{N-1,f} \quad e_{N,f}] \quad (2.40)$$

Definimos também o vetor:

$$\bar{\alpha}_f^* \triangleq [\alpha_{1,f}^* \quad \dots \quad \alpha_{N-1,f}^* \quad \alpha_{N,f}^*] \quad (2.41)$$

tal que temos uma equação para $\sum_{i=1}^N e_{i,f} \alpha_{i,f}^* = 0$ em forma matricial:

$$\bar{E}_f \bar{\alpha}_f^* = \sum_{i=1}^N e_{i,f} \alpha_{i,f}^* = 0 \quad (2.42)$$

Os coeficientes $\alpha_{i,f}$ são coeficientes de uma combinação convexa, portanto:

$$\sum_{i=1}^N \alpha_{i,f} = 1$$

e a partir disto podemos expressar o coeficiente $\alpha_{N,f}^*$ por:

$$\alpha_{N,f} = 1 - \sum_{i=1}^{N-1} \alpha_{i,f}^* \quad (2.43)$$

Podemos isolar o termo $e_{N,f} \alpha_{N,f}^*$ na equação 2.42:

$$\bar{E}_f \bar{\alpha}_f^* = \sum_{i=1}^{N-1} e_{i,f} \alpha_{i,f}^* + e_{N,f} \alpha_{N,f}^*$$

e então substituir $\alpha_{N,f}$ por 2.43:

$$\bar{E}_f \bar{\alpha}_f^* = \sum_{i=1}^{N-1} e_{i,f} \alpha_{i,f}^* + e_{N,f} (1 - \sum_{i=1}^{N-1} \alpha_{i,f}^*) = 0$$

que reorganizado fica da seguinte forma:

$$\sum_{i=1}^{N-1} (e_{i,f} - e_{N,f}) \alpha_{i,f}^* = -e_{N,f} \quad (2.44)$$

Definimos a seguinte matriz:

$$E_f \triangleq [e_{1,f} - e_{N,f} \quad e_{2,f} - e_{N,f} \quad \dots \quad e_{N-1,f} - e_{N,f}] \quad (2.45)$$

Definimos o seguinte vetor:

$$\alpha_f^* \triangleq [\alpha_{1,f}^* \quad \alpha_{2,f}^* \quad \dots \quad \alpha_{N-1,f}^*] \quad (2.46)$$

e com estas variáveis definidas, reescrevemos a equação 2.44 como:

$$E_f \alpha_f^* = -e_{N,f} \quad (2.47)$$

A equação 2.47 é ponto de partida para estimar em tempo real os coeficientes da combinação convexa que produzem os parâmetros verdadeiros da planta. Substituímos o vetor α_f^* nesta equação por uma estimativa α_f , e a partir desta substituição obtemos uma equação diferencial para estimar α_f^* :

$$\dot{\alpha}_f = -E_f^T E_f \alpha_f - E_f^T e_{N,f} \quad (2.48)$$

A estimativa $\bar{\alpha}_f$ de α_f^* fica, então, da seguinte forma:

$$\bar{\alpha}_f^T = \begin{bmatrix} \alpha_f^T & 1 - \vec{1} \alpha_f \end{bmatrix} \quad (2.49)$$

onde $\vec{1}$ é o vetor linha $[1 \ 1 \ \dots \ 1]$ de tamanho apropriado.

Definimos o erro paramétrico para a estimativa $\bar{\alpha}_f$ e para α_f :

$$\begin{aligned} \tilde{\alpha}_f &\triangleq \bar{\alpha}_f - \alpha_f^* \\ \tilde{\alpha}_f &\triangleq \alpha_f - \alpha_f^* \end{aligned} \quad (2.50)$$

e como assumimos α_f^* invariante no tempo, temos que:

$$\begin{aligned} \dot{\tilde{\alpha}}_f &= \dot{\alpha}_f - \cancel{\dot{\alpha}_f^*} = \dot{\alpha}_f \\ \dot{\tilde{\alpha}}_f &= \dot{\alpha}_f - \cancel{\dot{\alpha}_f^*} = \dot{\alpha}_f \end{aligned} \quad (2.51)$$

Então, substituindo $\dot{\alpha}_f$ por $\dot{\tilde{\alpha}}_f$ e α_f por $\tilde{\alpha}_f + \alpha_f^*$ em 2.48 e cancelando os termos equivalentes devido a 2.47, temos que:

$$\dot{\tilde{\alpha}}_f = -E_f^T E_f \tilde{\alpha}_f - E_f^T e_{\alpha,f} \quad (2.52)$$

Usamos uma candidata a função de Lyapunov definida positiva para analisar a estabilidade deste estimador:

$$V(\tilde{\alpha}_f) = \frac{1}{2} \tilde{\alpha}_f^T \tilde{\alpha}_f \quad (2.53)$$

e derivando ao longo das trajetórias obtemos:

$$\dot{V} = \tilde{\alpha}_f^T \dot{\tilde{\alpha}}_f$$

e explicitando $\tilde{\alpha}_f$ e $\dot{\tilde{\alpha}}_f$ a partir de 2.50:

$$\dot{V} = \begin{bmatrix} \tilde{\alpha}_f^T & -\vec{1} \tilde{\alpha}_f \end{bmatrix} \begin{bmatrix} \dot{\tilde{\alpha}}_f^T \\ -\vec{1} \dot{\tilde{\alpha}}_f \end{bmatrix}$$

e ao substituírmos $\ddot{\alpha}_f$ por 4.54 e reorganizarmos, obtemos a seguinte expressão:

$$\dot{V} = -N\tilde{\alpha}_f^T E_f^T E_f \tilde{\alpha}_f - N\tilde{\alpha}_f^T E_f^T e_{\alpha,f} \quad (2.54)$$

Na equação 2.54 pode-se escolher λ tal que o termo de sinal indefinido $-N\tilde{\alpha}_f^T E_f^T e_{\alpha,f}$ tenda para 0 exponencialmente. Se os componentes de E_f e $\tilde{\alpha}_f$ tendem a 0 apenas assintoticamente, então o termo de sinal indefinido é, eventualmente, dominado pelo termo de sinal definido negativo $-N\tilde{\alpha}_f^T E_f^T E_f \tilde{\alpha}_f$. Nesta expressão de $\dot{V}$ fica expresso também que a rapidez de convergência dos parâmetros depende de alguma forma do número de modelos N .

Assumindo que uma escolha apropriada de λ foi feita temos que V não pode crescer a partir de um certo instante, que implica que os componentes de $\tilde{\alpha}_f, \dot{\alpha}_f$ são uniformemente limitados, o que por sua vez implica que os componentes de $\tilde{\alpha}_f$ e α_f são uniformemente limitados. Como os erros de identificação dos modelos de primeiro nível são uniformemente limitados e o vetor α_f é uniformemente limitado isto implica que $\dot{\alpha}_f, \ddot{\alpha}_f$ são uniformemente limitados.

Finalmente, quando o sinal de controle u for persistentemente excitante teremos que E_f só será o vetor nulo a partir de algum instante quando as estimativas dos parâmetros de primeiro nível forem equivalentes aos parâmetros corretos a_p e k_p , o que indica que uma combinação convexa destes parâmetros também tenderá para os valores corretos. As estimativas dos parâmetros a_p e k_p da planta, $\hat{a}_{n2,f}$ e $\hat{k}_{n2,f}$ são entregues pela combinação convexa de coeficientes $\alpha_{i,f}, i = 1, \dots, N$ dos parâmetros $\hat{a}_{i,f}$ e $\hat{k}_{i,f}, i = 1, \dots, N$:

$$\begin{aligned} \hat{a}_{n2,f} &= \alpha_{1,f}\hat{a}_{1,f} + \alpha_{2,f}\hat{a}_{2,f} + \dots + \alpha_{N,f}\hat{a}_{N,f} \\ \hat{k}_{n2,f} &= \alpha_{1,f}\hat{k}_{1,f} + \alpha_{2,f}\hat{k}_{2,f} + \dots + \alpha_{N,f}\hat{k}_{N,f} \end{aligned} \quad (2.55)$$

2.5 Adaptação de Segundo Nível Modificada

Como foi demonstrado na seção anterior, é possível estimar $\alpha_{i,sp}^*, i = 1, \dots, N$ através das equações 2.48 e 2.49. No entanto, como $E_f^T E_f$ é uma matriz de posto 1 ou 0, não podemos concluir mais nada sem a presença de um sinal com persistência de excitação pois $\lambda_{\min}(E_f^T E_f) \equiv 0$. Nesta seção iremos propor uma modificação na lei adaptativa da adaptação de segundo nível.

Assumindo condições iniciais nulas, partimos de 2.47 para escrever:

$$\begin{aligned}
E_f^T E_f \alpha_f^* &= -E_f^T e_{N,f} \\
\int_0^t E_f^T(\tau) E_f(\tau) \alpha_f^* d\tau &= -\int_0^t E_f^T(\tau) e_{N,f}(\tau) d\tau \\
\int_0^t E_f^T(\tau) E_f(\tau) d\tau \alpha_f^* &= -\int_0^t E_f^T(\tau) e_{N,f}(\tau) d\tau \\
0 &= -\int_0^t E_f^T(\tau) E_f(\tau) d\tau \alpha_f^* - \int_0^t E_f^T(\tau) e_{N,f}(\tau) d\tau \\
0 &= -\int_0^t E_f^T(\tau) E_f(\tau) d\tau \alpha_f^* - E_f^T E_f \alpha_f^* - \int_0^t E_f^T(\tau) e_{N,f}(\tau) d\tau - E_f^T e_{N,f}
\end{aligned} \tag{2.56}$$

e como os erros de identificação $e_{i,f}, i = 1, \dots, N$, são uniformemente limitados e tendem a 0 a medida que o tempo t tende a infinito, as integrais em 2.56 são limitadas e tendem a valores constantes. Substituindo α_f^* por sua estimativa, como no procedimento que realizamos na seção anterior, temos a seguinte equação:

$$\dot{\alpha}_f = -\int_0^t E_f^T(\tau) E_f(\tau) d\tau \alpha_f - E_f^T E_f \alpha_f - \int_0^t E_f^T(\tau) e_{N,f}(\tau) d\tau - E_f^T e_{N,f} \tag{2.57}$$

Por facilidade de notação, definimos as seguintes variáveis:

$$\begin{aligned}
M_f &\triangleq \int_0^t E_f^T(\tau) E_f(\tau) d\tau \\
v_f &\triangleq \int_0^t E_f^T(\tau) e_{N,f}(\tau) d\tau
\end{aligned} \tag{2.58}$$

e reescrevemos 2.57 como:

$$\dot{\alpha}_f = -M_f \alpha_f - E_f^T E_f \alpha_f - v_f - E_f^T e_{N,f} \tag{2.59}$$

Usamos uma candidata a função de Lyapunov definida positiva para avaliar a estabilidade deste estimador:

$$V(\tilde{\alpha}_f) = \frac{1}{2} \tilde{\alpha}_f^T \tilde{\alpha}_f \tag{2.60}$$

e derivando ao longo das trajetórias obtemos:

$$\dot{V} = -N\tilde{\alpha}_f^T(E_f^T E_f + M_f)\tilde{\alpha}_f \quad (2.61)$$

Para cada instante de tempo existe pelo menos um autovetor associado a um autovalor nulo da matriz $E_f^T E_f$. Então para um vetor arbitrário $w_q \in R^{N-1}$ constante:

$$w_q^T \left(\int_0^\infty E_f^T(\tau) E_f(\tau) d\tau \right) w_q > 0 \quad (2.62)$$

pois o vetor w_q , constante e não-nulo, não é múltiplo escalar de algum autovetor associado a um autovalor nulo da matriz $E_f^T E_f$ em todos os instantes, pois assumimos que a direção dos autovetores associados aos autovalores nulos desta matriz está variando durante o transitório. Portanto, qualquer que seja w_q , a inequação 2.62 se mantém. Portanto, a matriz M_f obtida pela integração de $E_f^T E_f$ a partir do instante inicial converge para uma matriz simétrica com valores de seus elementos constantes, definida positiva e de posto cheio.

Temos, então, para um intervalo finito entre 0 e $t_0 > 0$ escolhido tal que $\lambda_{\min}(E_f^T E_f + M_f) > 0$ a partir de t_0 , que:

$$\int_0^{t_0} \|\tilde{\alpha}_f\|^2 d\tau < K$$

onde K é um escalar finito, pois $\tilde{\alpha}_f$ é uniformemente limitado.

Assim, como $\lambda_{\min}(E_f^T E_f + M_f) > 0$ podemos utilizar a desigualdade de Rayleigh:

$$\begin{aligned} & \lambda_{\min}(E_f^T E_f + M_f) \|\tilde{\alpha}_f\|^2 \\ & \leq \\ & \tilde{\alpha}_f^T (E_f^T E_f + M_f) \tilde{\alpha}_f \\ & \leq \\ & \lambda_{\max}(E_f^T E_f + M_f) \|\tilde{\alpha}_f\|^2 \end{aligned} \quad (2.63)$$

e a partir de 2.61 e 2.63 temos que:

$$\|\tilde{\alpha}_f\|^2 \leq \frac{-\dot{V}}{N\lambda_{\min}(E_f^T E_f + M_f)}$$

Substituímos $\lambda_{\min}$ que varia com o tempo por um valor $\lambda_{\min,inf}$ constante, o ínfimo do conjunto de autovalores mínimos da matriz $E_f^T E_f + M_f$ a partir do instante t_0 e integrando temos:

$$\int_0^{\infty} \|\tilde{\alpha}_f(\tau)\|^2 d\tau \leq \int_0^{t_0} \|\tilde{\alpha}_f(\tau)\|^2 d\tau + \frac{-1}{N\lambda_{\min, \inf}(E_f^T E_f + M_f)} (V(\infty) - V(t_0))$$

e como $\int_0^{t_0} \|\tilde{\alpha}_f(\tau)\|^2 d\tau$ é um valor finito e $\frac{-1}{N\lambda_{\min, \inf}(E_f^T E_f + M_f)} (V(\infty) - V(t_0))$ é um valor finito temos que:

$$\tilde{\alpha}_f \in \mathcal{L}_2$$

Finalmente, por um corolário do lema de Barbalat, temos que o vetor $\tilde{\alpha}_f$ uniformemente limitado, sua norma $\mathcal{L}_2$ finita e sua derivada uniformemente limitada implicam em $\tilde{\alpha}_f$ que tende para 0 assintoticamente, que por sua vez implica em $\tilde{\alpha}_{N,f}$ que tende para 0 assintoticamente.

Portanto, com a modificação proposta, existe garantia de convergência dos coeficientes $\hat{\alpha}_{i,f}$, $i = 1, \dots, N$, para algum conjunto de valores corretos, no sentido de que produzem os parâmetros verdadeiros da planta. Não é necessário, para tanto, impor sobre a planta um sinal de controle com a característica de persistência de excitação, desde que as condições iniciais sejam nulas e a planta seja invariante no tempo.

Uma outra forma de calcular os coeficientes corretos é monitorando o posto de M_f e resolvendo o sistema de equações $M_f \alpha_f^{*T} = -v_f$ para α_f^* quando for verificado que M_f é de posto cheio e suficientemente distante de ser uma matriz singular, para evitar erro numérico.

É importante ressaltar, no entanto, que esta melhora na convergência dos parâmetros implica numa perda em outro aspecto importante da identificação de parâmetros, isto é, caso a planta tenha seus parâmetros variando lentamente no tempo, as informações acumuladas nos elementos da matriz M_f e do vetor v_f deixarão gradualmente de ser válidas na atualização ou cálculo dos coeficientes, fazendo com que os coeficientes acabem convergindo para valores distintos dos corretos, o que é algo que não acontece sem a modificação. Apesar disso, vimos que dentro das condições especificadas existe algum benefício em acumular informações passadas.

2.6 Resultados

Apresentamos o modelo de identificação por regressão linear neste primeiro capítulo. Discutimos algumas de suas propriedades para a planta estável de ordem 1 e grau relativo 1. Mostramos que o erro de identificação tende a 0 para este modelo. Mencionamos que as estimativas tendem aos valores corretos na presença de um sinal de entrada com a característica de persistência de excitação.

Provamos, para este tipo de modelo, que existem coeficientes constantes de uma combinação convexa das estimativas dos parâmetros de 3 ou mais modelos que produzem a_p e k_p . Demonstramos que, como uma segunda camada de adaptação, ou uma adaptação em dois níveis, pode-se atualizar estimativas destes coeficientes para calcular uma estimativa de segundo nível de a_p e k_p .

Finalmente, discutimos uma modificação na lei adaptativa da adaptação de segundo nível tal que não seja necessária a imposição de um sinal de controle com característica de persistência de excitação à planta de ordem 1 para que seja garantida a convergência dos parâmetros para seus valores corretos.

2.6.1 Resumo dos Algoritmos

Caso o leitor deseje consultar rapidamente, listamos os algoritmos de identificação nas Tabelas 2.1 e 2.2 a seguir:

Tabela 2.1: Algoritmo do Modelo por Regressão Linear para a Planta de Ordem 1

Regressão Linear

$$\Sigma_p : \dot{y} = -a_p y + k_p u$$

$$z = y + \lambda \phi_1$$

$$\dot{\phi}_1 = -\lambda \phi_1 - y$$

$$\dot{\phi}_2 = -\lambda \phi_2 + u$$

$$\phi^T = [\phi_1 \quad \phi_2]$$

$$\Sigma_{1,f} : \hat{z}_{1,f} = [-\hat{a}_{1,f} \quad \hat{k}_{1,f}] \phi$$

$$e_{1,f} = \hat{z}_{1,f} - z$$

$$\hat{\dot{a}}_{1,f} = e_{1,f} y$$

$$\hat{\dot{k}}_{1,f} = -e_{1,f} u$$

Tabela 2.2: Algoritmos da Adaptação de Segundo Nível baseada em Modelos de Identificação por Regressão Linear para uma Planta de Ordem 1 e Grau relativo unitário

Segundo Nível Regressão Linear	Segundo Nível Regressão Linear Modificado
$\Sigma_p : \dot{y} = -a_p y + k_p u$ $z = y + \lambda \phi_1$ $\dot{\phi}_1 = -\lambda \phi_1 - y$ $\dot{\phi}_2 = -\lambda \phi_2 + u$ $\phi^T = [\phi_1 \quad \phi_2]$ $\Sigma_{i,f} : \hat{z}_{i,f} = [-\hat{a}_{i,f} \quad \hat{k}_{i,f}] \phi$ $e_{i,f} = \hat{z}_{i,f} - z$ $\hat{a}_{i,f} = e_{i,f} y$ $\hat{k}_{i,f} = -e_{i,f} u$ $E_f = [e_{1,f} - e_{N,f} \quad \dots \quad e_{N-1,f} - e_{N,f}]$ $\dot{\alpha}_f = -E_f^T E_f \alpha_f - E_f^T e_{N,f}$ $\bar{\Theta}_f = \begin{bmatrix} \hat{a}_{1,f} & \dots & \hat{a}_{N,f} \\ \hat{k}_{1,f} & \dots & \hat{k}_{N,f} \end{bmatrix}$ $\bar{\alpha}_f^T = [\alpha_f^T \quad 1 - \vec{1} \alpha_f]$ $\begin{bmatrix} \hat{a}_{n2,f} \\ \hat{k}_{n2,f} \end{bmatrix} = \bar{\Theta}_f \bar{\alpha}_f$	$\Sigma_p : \dot{y} = -a_p y + k_p u$ $z = y + \lambda \phi_1$ $\dot{\phi}_1 = -\lambda \phi_1 - y$ $\dot{\phi}_2 = -\lambda \phi_2 + u$ $\phi^T = [\phi_1 \quad \phi_2]$ $\Sigma_{i,f} : \hat{z}_{i,f} = [-\hat{a}_{i,f} \quad \hat{k}_{i,f}] \phi$ $e_{i,f} = \hat{z}_{i,f} - z$ $\hat{a}_{i,f} = e_{i,f} y$ $\hat{k}_{i,f} = -e_{i,f} u$ $E_f = [e_{1,f} - e_{N,f} \quad \dots \quad e_{N-1,f} - e_{N,f}]$ $M_f(0) = \mathbf{0}$ $v_f(0) = \mathbf{0}$ $\dot{M}_f = E_f^T E_f$ $\dot{v}_f = E_f^T e_{N,f}$ $\dot{\alpha}_f = -(E_f^T E_f + M_f) \alpha_f - E_f^T e_{N,f} - v_f$ $\bar{\Theta}_f = \begin{bmatrix} \hat{a}_{1,f} & \dots & \hat{a}_{N,f} \\ \hat{k}_{1,f} & \dots & \hat{k}_{N,f} \end{bmatrix}$ $\bar{\alpha}_f^T = [\alpha_f^T \quad 1 - \vec{1} \alpha_f]$ $\begin{bmatrix} \hat{a}_{n2,f} \\ \hat{k}_{n2,f} \end{bmatrix} = \bar{\Theta}_f \bar{\alpha}_f$

2.6.2 Estudos de Simulação

Considere a Planta de Ordem 1 a seguir:

$$\Sigma_p : G(s) = \frac{3}{s + 1.5}$$

onde os parâmetros $k_p = 3$ e $a_p = 1.5$ pertencem a uma região de incerteza delimitada por $a_p^+ = 4$, $a_p^- = 0.5$, $k_p^+ = 6$, $k_p^- = 1$. Desejamos identificar os parâmetros desta planta em tempo real. Sua saída $y(t)$ e sua entrada $u(t)$ estão disponíveis para medição. Vamos usar o modelo de identificação por regressão linear e diversas implementações do conceito de adaptação de segundo nível, fazendo uso de conjuntos de modelos de identificação por regressão linear.

Na Adaptação de Segundo Nível estimativas de Primeiro Nível são combinadas linearmente por um conjunto de coeficientes que também estão, por sua vez, sendo atualizados

para formar uma estimativa de Segundo Nível. Usaremos o número mínimo de modelos para caso de ordem 1 e grau relativo 1, $N = 3$. Mostramos também resultados com $N = 4$ e $N = 8$ modelos. Também apresentamos e discutimos os resultados de simulações para $N = 3$ modelos com a modificação proposta para a lei adaptativa da adaptação de segundo nível.

Em todas as simulações utilizamos o sinal de entrada $u(t) = \sin(t)$ que é persistentemente excitante de ordem 1. Da mesma forma consideramos a condição inicial $y(0) = 0.2$ em todas as simulações a seguir. Sempre inicializamos os parâmetros de algum dos modelos de primeiro nível em $\hat{a}(0) = 0.5$ e $\hat{k}(0) = 6$ e os α_i dos modelos de segundo nível tal que as estimativas de segundo nível sejam $\hat{a}_{n,f}(0) = 0.5$ e $\hat{k}_{n,f}(0) = 6$. Usamos integração por passo fixo de 10^{-3} segundos.

Modelo por Regressão Linear

Escolhemos o parâmetro $\lambda = 4$.




Figura 2.1: Erro de Identificação usando o Modelo por Regressão Linear para a planta Σ_p , 110 segundos de simulação

para o modelo por regressão linear atualizado pela lei de ajuste convencional o erro de identificação está tendendo a 0 com $t = 110$ segundos na Figura 2.1, indicando convergência dos parâmetros. O modelo por regressão linear é capaz de identificar os parâmetros da planta. Porém isto só acontece após um intervalo de tempo que é bastante longo em relação a dinâmica da planta.

Segundo Nível, 3 Modelos por Regressão Linear

Inicializamos os parâmetros dos Modelos em $\hat{a}_{1,f}(0) = 0.5$ e $\hat{k}_{1,f}(0) = 1$, $\hat{a}_{2,f}(0) = 0.5$ e $\hat{k}_{2,f}(0) = 11$, $\hat{a}_{3,f}(0) = 7$ e $\hat{k}_{3,f}(0) = 1$, e os coeficientes da combinação convexa em

$\alpha_{1,f}(0) = 0.5, \alpha_{2,f}(0) = 0.5$ e $\alpha_{3,f}(0) = 0$. Escolhemos o parâmetro $\lambda = 4$, além disso escolhemos $\phi_1(0) = \phi_2(0) = 0$.

Segundo Nível, 4 Modelos por Regressão Linear

Inicializamos os parâmetros dos Modelos nos vértices da região de incerteza em $\hat{a}_{1,f}(0) = 0.5$ e $\hat{k}_{1,f}(0) = 1, \hat{a}_{2,f}(0) = 4$ e $\hat{k}_{2,f}(0) = 1, \hat{a}_{3,f}(0) = 4$ e $\hat{k}_{3,f}(0) = 6, \hat{a}_{4,f}(0) = 0.5$ e $\hat{k}_{4,f}(0) = 6$, e os coeficientes da combinação convexa em $\alpha_{1,f}(0) = 0, \alpha_{2,f}(0) = 0$ e $\alpha_{3,f}(0) = 0$ e $\alpha_{4,f}(0) = 1$. Escolhemos o parâmetro $\lambda = 4$, além disso escolhemos $\phi_1(0) = \phi_2(0) = 0$.

Segundo Nível, 8 Modelos por Regressão Linear

Consideramos que $y(0) = 0.2$, inicializamos os parâmetros dos Modelos em $\hat{a}_{1,f}(0) = 0.5$ e $\hat{k}_{1,f}(0) = 1, \hat{a}_{2,f}(0) = 2$ e $\hat{k}_{2,f}(0) = 1, \hat{a}_{3,f}(0) = 4$ e $\hat{k}_{3,f}(0) = 1, \hat{a}_{4,f}(0) = 4$ e $\hat{k}_{4,f}(0) = 3, \hat{a}_{5,f}(0) = 4$ e $\hat{k}_{5,f}(0) = 6, \hat{a}_{6,f}(0) = 2.5$ e $\hat{k}_{6,f}(0) = 6, \hat{a}_{7,f}(0) = 0.5$ e $\hat{k}_{7,f}(0) = 4, \hat{a}_{8,f}(0) = 0.5$ e $\hat{k}_{8,f}(0) = 6$, ao longo do perímetro da região de incerteza, e os coeficientes da combinação convexa em $\alpha_{i,f}(0) = 0, i \neq 8$ e $\alpha_{8,f}(0) = 1$. Escolhemos o parâmetro $\lambda = 4$, além disso escolhemos $\phi_1(0) = \phi_2(0) = 0$.

De forma a facilitar a comparação entre as estimativas, plotamos todas as estimativas de a_p no mesmo gráfico, que se encontra na Figura 2.2. Fizemos o mesmo para todas as estimativas de k_p , que estão representadas no gráfico da Figura 2.3. Escolhemos omitir as estimativas dos modelos que não iniciam em $\hat{a} = 0.5$ e $\hat{k} = 6$. Entendemos que estes modelos não contribuem com informações relevantes para uma comparação entre os parâmetros de um modelo de identificação de primeiro nível e os parâmetros atualizados através do conceito de adaptação de segundo nível inicializados em valores distintos.




Figura 2.2: Estimativa do parâmetro $a_p = 3$ para a planta Σ_p para os Modelos de Identificação estudados, Adaptação de Segundo Nível com $N = 3, N = 4$ e $N = 8$ Modelos de Primeiro Nível por Regressão Linear, 20 segundos de simulação




Figura 2.3: Estimativa do parâmetro $k_p = 1.5$ para a planta Σ_p para os Modelos de Identificação estudados, Adaptação de Segundo Nível com $N = 3, N = 4$ e $N = 8$ Modelos de Primeiro Nível por Regressão Linear, 20 segundos de simulação

Vemos que a Adaptação de Segundo Nível é mais rápida que o modelo de primeiro nível. A velocidade de convergência aumenta quando usamos mais modelos, mas não de uma forma linear. Tanto no caso em que $N = 4$ quanto $N = 8$ observamos um sobressinal menor nas estimativas em relação aos valores corretos e uma convergência mais rápida. No entanto é importante notar que dobramos o número de modelos em relação ao caso em que $N = 4$ e obtivemos uma convergência apenas um pouco mais rápida. Isto sugere

que a escolha acerca de quais valores usar para inicializar os parâmetros dos modelos de primeiro nível influi na velocidade de convergência dos parâmetros ou que a velocidade de convergência dos parâmetros está sujeita a uma lei de rendimentos decrescentes, no que se refere ao número de modelos.

Segundo Nível Modificado, 3 Modelos por Regressão Linear

Consideramos que $y(0) = 0$, inicializamos os parâmetros dos Modelos em $\hat{a}_{1,f}(0) = 0.5$ e $\hat{k}_{1,f}(0) = 1$, $\hat{a}_{2,f}(0) = 0.5$ e $\hat{k}_{2,f}(0) = 11$, $\hat{a}_{3,f}(0) = 7$ e $\hat{k}_{3,f}(0) = 1$, e os coeficientes da combinação convexa em $\alpha_{1,f}(0) = 0.5$, $\alpha_{2,f}(0) = 0.5$ e $\alpha_{3,f}(0) = 0$ e usamos o Método de Integração de Euler com passo fixo de 10^{-3} segundos e tempo de simulação de 36 segundos. O sinal de entrada foi escolhido como $u(t) = 1$ que, note-se, não é PE. Escolhemos o parâmetro $\lambda = 4$ e $\phi_1(0) = \phi_2(0) = 0$.




Figura 2.4: Erros de Identificação usando 3 Modelos por Regressão Linear para a planta Σ_p




Figura 2.5: Estimativas do parâmetro $a_p = 1.5$ para a planta Σ_p para 3 Modelos por Regressão Linear e a estimativa de Segundo Nível Modificada, 36 segundos de simulação




Figura 2.6: Estimativas do parâmetro $k_p = 1.5$ para a planta Σ_p para 3 Modelos por Regressão Linear e a estimativa de Segundo Nível Modificada, 36 segundos de simulação




Figura 2.7: Trajetória dos parâmetros $\hat{a}_{n2,f}$ e $\hat{k}_{n2,f}$ da Adaptação de Segundo Nível Modificada no espaço de parâmetros usando 3 Modelos por Regressão Linear para a planta Σ_p , aos 30 segundos de simulação

Verificamos que os erros de identificação rapidamente vão para 0 com $t \approx 5$ segundos na Figura 2.4 e as estimativas de primeiro nível ficaram mais próximas dos valores corretos nas Figuras 2.5 e 2.6.

De fato as estimativas em regime permanente para um sinal de entrada do tipo degrau unitário sempre se localizam sobre a reta de inclinação igual ao ganho em regime permanente da planta e que passa pelo ponto que contém os parâmetros corretos. Isto acontece pois o degrau carrega apenas uma informação (a amplitude). A senoide carrega duas informações (amplitude e fase), de forma que uma senoide pode ser usada para identificar univocamente dois parâmetros.

As estimativas de segundo nível em $t = 25$ segundos alcançam os valores corretos. Este resultado é interessante, e tem a seguinte interpretação: as informações sobre os parâmetros da planta se encontram disponíveis durante o transitório. O transitório é o período de tempo em que os modos da planta estão excitados. Armazenar informações acerca do transitório da planta e utilizar estas informações em conjunto com as informações do instante atual para atualizar os parâmetros nos permite um conhecimento melhor sobre os parâmetros do que ao utilizar apenas informações do instante atual para atualizar os parâmetros.

O trajeto no espaço de parâmetros pode ser visto na Figura 2.7. Como os parâmetros convergem para os valores corretos, a adaptação de segundo nível modificada com 3 modelos de primeiro nível por regressão linear de uma planta invariante no tempo sujeita a um sinal que provoca excitação de seus modos durante um intervalo de tempo finito é adequada para o objetivo de identificação de parâmetros, desde que partindo de condições iniciais nulas. O processo de identificação continua a ser mais lento do que a dinâmica da planta pois a convergência dos parâmetros se dá de fato após $t = 25$ segundos. No en-

tanto, não foi necessária a imposição de um sinal com persistência de excitação à entrada da planta.

2.7 Conclusão

Neste capítulo apresentamos o modelo de identificação por regressão linear para a planta de grau 1. Mostramos como este modelo pode servir como base para identificação através do conceito de adaptação de segundo nível.

Na adaptação de segundo nível os coeficientes de uma combinação linear de múltiplos modelos são atualizados por uma lei integral e as estimativas são entregues por esta mesma combinação. Disponibilizamos os algoritmos nas Tabelas 2.1 e 2.2.

Neste capítulo escolhemos um caso simples, uma planta de grau 1 com grau relativo unitário e estável e portanto com apenas dois parâmetros a serem estimados e com sinais limitados a priori. Desta forma, esperamos que as características da adaptação de segundo nível como método de estimação paramétrica tenham ficado evidenciadas de forma mais didática, por se tratar de um tema novo.

Foram feitos estudos de simulação, nos quais avaliamos que a adaptação de segundo nível exibe velocidade de convergência superior ao método do gradiente normalizado. Mostramos também que existe a possibilidade de identificar os parâmetros corretos na presença de um sinal de entrada sem persistência de excitação.

Capítulo 3

Controle da Planta de Ordem 1

Neste capítulo, passamos a tratar do problema do controle da planta de ordem 1, linear e invariante no tempo. Mostramos a lei de controle para o caso da planta com parâmetros conhecidos e como é feita a escolha dos parâmetros. A partir das equações obtidas para o caso da planta com parâmetros conhecidos, substituímos os parâmetros verdadeiros da planta por suas estimativas para implementar o controle adaptativo indireto convencional. Também demonstramos como podemos escolher leis de ajuste chaveadas para as estimativas dos parâmetros do controlador. No final do capítulo trazemos resultados de simulação para as estratégias de controle estudadas.

3.1 Descrição do Problema

Considere a planta linear invariante no tempo, de ordem 1 e grau relativo 1, descrita pela seguinte função de transferência:

$$\Sigma_p : G_p(s) = \frac{y(s)}{u(s)} = \frac{k_p}{s + a_p}$$

onde a saída $y(t)$ e a entrada $u(t)$ estão disponíveis para medição, e k_p e a_p pertencem a intervalos conhecidos, $k_p \in [k_p^-, k_p^+]$ e $a_p \in [a_p^-, a_p^+]$.

As seguintes hipóteses são verdadeiras:

- **P1** A ordem da planta e seu grau relativo são conhecidos
- **P2** O sinal de k_p é conhecido.

Nosso objetivo é o de projetar um controlador que produza um sinal de controle $u(t)$, para atuar sobre a entrada da planta, que faça com que a saída da planta rastreie a saída de um Modelo de Referência:

$$\Sigma_m : W_m(s) = \frac{y_m(s)}{r(s)} = \frac{k_m}{s + a_m}$$

escolhido pelo projetista e que cumpre as seguintes condições:

- **M1** A ordem do modelo e seu grau relativo são iguais aos da planta.

- **M2** $s + a_m$ é Hurwitz, isto é, $a_m > 0$.

Ao alimentar o modelo de referência com um sinal de referência $r(t)$ escolhido pelo projetista, uma trajetória para a saída da planta é especificada. A lei de controle deve ser escolhida tal que o polo da função de transferência em malha fechada de r para y seja igual a $s + a_m$. Se a função de transferência em malha fechada se torna equivalente a $W_m(s)$ então qualquer que seja o sinal de referência $r(t)$ a saída $y(t)$ da planta tenderá exponencialmente para a saída $y_m(t)$ do modelo.

3.2 Planta com parâmetros conhecidos

Consideremos que os coeficientes dos polinômios a_p e k_p são conhecidos.

Passamos a considerar a seguinte lei de controle por realimentação:

$$u^* = k_1^* y + k_2^* r \quad (3.1)$$

Queremos encontrar parâmetros k_1^* e k_2^* tal que a função de transferência em malha fechada de y para r seja equivalente a $W_m(s)$. As propriedades de entrada e saída da planta em malha fechada para esta lei de controle são dadas por:

$$\dot{y} = -a_p y + k_p (k_1^* y + k_2^* r) = -a_m y + k_m r \quad (3.2)$$

A partir de 3.2, os parâmetros k_1^* e k_2^* são calculados por inspeção como:

$$\begin{aligned} k_1^* &= \frac{a_p - a_m}{k_p} \\ k_2^* &= \frac{k_m}{k_p} \end{aligned} \quad (3.3)$$

Chamamos as equações 3.3 de equações de matching da planta de ordem 1. A partir das equações de matching temos os parâmetros do controlador em função dos parâmetros da planta que garantem que a função de transferência entre a referência e a saída da planta é equivalente a do modelo de referência, para a lei de controle por realimentação 3.1.

3.3 Controle Adaptativo por Modelo de Referência Indireto

Na seção anterior obtivemos equações para calcular os parâmetros do controlador em função dos parâmetros da planta.

Para aplicar os métodos de estimação de parâmetros que viemos estudando para a planta de ordem 1, vamos utilizar as equações 3.3, substituindo os parâmetros verdadeiros

da planta por suas estimativas:

$$\begin{aligned} k_1 &= \frac{\hat{a}_p - a_m}{\hat{k}_p} \\ k_2 &= \frac{k_m}{\hat{k}_p} \end{aligned} \quad (3.4)$$

Para limitar os parâmetros calculados, temos que a estimativa $\hat{k}_p$ deve ser restringida de atingir um valor nulo por projeção, por isto a hipótese de que seu sinal é conhecido. A lei de controle fica então da forma:

$$u = k_1 y + k_2 r \quad (3.5)$$

3.4 Controle Adaptativo por Modelo de Referência e Estrutura Variável

Consideremos a diferença entre o sinal de saída da planta e o sinal de saída do modelo de referência:

$$e_o = y - y_m \quad (3.6)$$

o chamado erro de saída.

Definimos os erros paramétricos para os parâmetros do controlador:

$$\begin{aligned} \tilde{k}_1 &= k_1 - k_1^* \\ \tilde{k}_2 &= k_2 - k_2^* \end{aligned} \quad (3.7)$$

A dinâmica do erro de saída é dada, então, por:

$$\dot{e}_o = \dot{y} - \dot{y}_m = -a_p y + k_p((\tilde{k}_1 + k_1^*)y + (\tilde{k}_2 + k_2^*)r) + a_m y_m - k_m r \quad (3.8)$$

que, simplificando, fica da forma:

$$\dot{e}_o = -a_m e_o + k_p(\tilde{k}_1 y + \tilde{k}_2 r) \quad (3.9)$$

Consideremos a seguinte candidata a função de Lyapunov:

$$V(e_o) = \frac{e_o^2}{2} \quad (3.10)$$

Derivando ao longo das trajetórias de V obtemos:

$$\dot{V} = -a_m e_o^2 + \tilde{k}_1 k_p e_o y + \tilde{k}_2 k_p e_o r \quad (3.11)$$

Como $k_p \in [k_p^-, k_p^+]$ e $a_p \in [a_p^-, a_p^+]$, temos que os parâmetros do controlador para

as equações de matching devem obedecer às seguintes inequações:

$$\begin{aligned} |k_1^*| &\leq \frac{\max(|a_p^+ - a_m|, |a_p^- - a_m|)}{\min(|k_p^+|, |k_p^-|)} \\ |k_2^*| &\leq \frac{|k_m|}{\min(|k_p^+|, |k_p^-|)} \end{aligned} \quad (3.12)$$

Definimos, então, os parâmetros:

$$\begin{aligned} \bar{k}_1 &= \frac{\max(|a_p^+ - a_m|, |a_p^- - a_m|)}{\min(|k_p^+|, |k_p^-|)} \\ \bar{k}_2 &= \frac{|k_m|}{\min(|k_p^+|, |k_p^-|)} \end{aligned} \quad (3.13)$$

Portanto, a cada instante podemos escolher os parâmetros do controlador de acordo com as seguintes leis chaveadas:

$$\begin{aligned} k_1 &= -\bar{k}_1 \operatorname{sign}(k_p e_o y) \\ k_2 &= -\bar{k}_2 \operatorname{sign}(k_p e_o r) \end{aligned} \quad (3.14)$$

Ao fazermos esta escolha de k_1 e k_2 , garantimos que $\operatorname{sign}(\tilde{k}_1) = -\operatorname{sign}(k_p e_o y)$ e que $\operatorname{sign}(\tilde{k}_2) = -\operatorname{sign}(k_p e_o r)$, desta forma os termos $\tilde{k}_1 k_p e_o y$ e $\tilde{k}_2 k_p e_o r$ em 3.11 passam a ser definidos negativos e $\dot{V}$ passa a ser definida negativa. Isto implica em e_o uniformemente limitado e pertencente ao $\mathcal{L}_2$. e_o uniformemente limitado implica em y uniformemente limitado. A partir de 3.9 concluímos que $\dot{e}_o$ é uniformemente limitado e, devido a um corolário do lema de Barbalat, e_o deve tender a 0 pelo menos assintoticamente.

3.5 Resultados

Neste capítulo apresentamos a lei de controle usada para que a planta de ordem 1 rastreie a saída de um modelo de referência. Usamos uma lei de controle por realimentação do sinal de saída da planta em conjunto com a referência.

Os parâmetros do controlador são calculados a partir dos parâmetros estimados da planta por um mapeamento baseado nas equações de matching 3.3, como se os parâmetros da planta fossem conhecidos. As estimativas podem ser obtidas pelos métodos estudados no capítulo 2.

Também descrevemos o controle com estrutura variável na estratégia direta.

3.5.1 Resumo dos Algoritmos

Caso o leitor deseje consultar rapidamente, listamos os algoritmos para o controle da planta de ordem 1 nas Tabelas 3.1 e 3.2 a seguir:

Tabela 3.1: Algoritmo de Controle com Parâmetros Conhecidos e Controle Adaptativo por Modelo de Referência Indireto baseado em Modelo de Identificação por Regressão Linear para a Planta de Ordem 1

Parâmetros Conhecidos	Regressão Linear
	$\Sigma_p : \dot{y} = -a_p y + k_p u$
	$\Sigma_m : \dot{y}_m = -a_m y_m + k_m r$
	$e_o = y - y_m$
	$z = y + \lambda \phi_1$
$\Sigma_p : \dot{y} = -a_p y + k_p u$	$\dot{\phi}_1 = -\lambda \phi_1 - y$
$\Sigma_m : \dot{y}_m = -a_m y_m + k_m r$	$\dot{\phi}_2 = -\lambda \phi_2 + u$
$e_o = y - y_m$	$\phi^T = [\phi_1 \quad \phi_2]$
$k_1^* = \frac{a_p - a_m}{k_p}$	$\Sigma_{1,f} : \hat{z}_{1,f} = [-\hat{a}_{1,f} \quad \hat{k}_{1,f}] \phi$
	$e_{1,f} = \hat{z}_{1,f} - z$
$k_2^* = \frac{k_m}{k_p}$	$\hat{a}_{1,f} = e_{1,f} y$
$u^* = k_1^* y + k_2^* r$	$\hat{k}_{1,f} = -e_{1,f} u$
	$k_1 = \frac{\hat{a}_{1,f} - a_m}{\hat{k}_{1,f}}$
	$k_2 = \frac{k_m}{\hat{k}_{1,f}}$
	$u = k_1 y + k_2 r$

Tabela 3.2: Algoritmo de Controle Adaptativo por Modelo de Referência Indireto baseado na Adaptação de Segundo Nível de um conjunto de Modelos de Identificação por Regressão Linear e Controle com Estrutura Variável para a Planta de Ordem 1

Segundo Nível Regressão Linear	Estrutura Variável
$\Sigma_p : \dot{y} = -a_p y + k_p u$ $\Sigma_m : \dot{y}_m = -a_m y_m + k_m r$ $e_o = y - y_m$ $z = y + \lambda \phi_1$ $\dot{\phi}_1 = -\lambda \phi_1 - y$ $\dot{\phi}_2 = -\lambda \phi_2 + u$ $\phi^T = [\phi_1 \quad \phi_2]$ $\Sigma_{i,f} : \hat{z}_{i,f} = [-\hat{a}_{i,f} \quad \hat{k}_{i,f}] \phi$ $e_{i,f} = \hat{z}_{i,f} - z$ $\hat{a}_{i,f} = e_{i,f} y$ $\hat{k}_{i,f} = -e_{i,f} u$ $E_f = [e_{1,f} - e_{N,f} \quad \dots \quad e_{N-1,f} - e_{N,f}]$ $\bar{\alpha}_f = -E_f^T E_f \alpha_f - E_f^T e_{N,f}$ $\bar{\Theta}_f = \begin{bmatrix} \hat{a}_{1,f} & \dots & \hat{a}_{N,f} \\ \hat{k}_{1,f} & \dots & \hat{k}_{N,f} \end{bmatrix}$ $\bar{\alpha}_f^T = \begin{bmatrix} \alpha_f^T & 1 - \bar{1} \alpha_f \end{bmatrix}$ $\begin{bmatrix} \hat{a}_{n2,f} \\ \hat{k}_{n2,f} \end{bmatrix} = \bar{\Theta}_f \bar{\alpha}_f$ $k_1 = \frac{\hat{a}_{n2,f} - a_m}{\hat{k}_{n2,f}}$ $k_2 = \frac{k_m}{\hat{k}_{n2,f}}$ $u = k_1 y + k_2 r$	$\Sigma_p : \dot{y} = -a_p y + k_p u$ $\Sigma_m : \dot{y}_m = -a_m y_m + k_m r$ $e_o = y - y_m$ $\bar{k}_1 \geq k_1^* $ $\bar{k}_2 \geq k_2^* $ $k_1 = -\bar{k}_1 \text{sign}(k_p e_o y)$ $k_2 = -\bar{k}_2 \text{sign}(k_p e_o r)$ $u = k_1 y + k_2 r$

3.5.2 Estudos de Simulação

Voltemos a considerar a planta de ordem 1 que estudamos no capítulo 2:

$$\Sigma_p : G(s) = \frac{3}{s + 1.5}$$

onde os parâmetros $k_p = 3$ e $a_p = 1.5$ pertencem a uma região de incerteza delimitada por $a_p^+ = 4$, $a_p^- = 0.5$, $k_p^+ = 6$, $k_p^- = 1$, como anteriormente. A saída $y(t)$ e sua entrada $u(t)$ estão disponíveis para medição.

Consideremos, agora, o seguinte modelo de referência:

$$\Sigma_m : W_m(s) = \frac{5}{s+5}$$

Queremos alimentar a planta com um sinal de controle tal que sua saída y rastreie a saída do modelo de referência y_m . Para tanto, vamos utilizar as leis de controle que estudamos neste capítulo, em conjunto com os métodos de estimação de parâmetros vistos no capítulo 2, quando oportuno.

Em todas as simulações utilizamos o sinal de entrada $u(t) = 1$. Da mesma forma consideramos a condição inicial $y(0) = 0.2$ em todas as simulações a seguir. Usamos integração por passo fixo de 10^{-3} segundos para as leis adaptativas convencionais e 10^{-4} segundos para o controle com estrutura variável.

Para a adaptação de segundo nível inicializamos os parâmetros dos Modelos em $\hat{a}_{1,f}(0) = 0.5$ e $\hat{k}_{1,f}(0) = 1$, $\hat{a}_{2,f}(0) = 0.5$ e $\hat{k}_{2,f}(0) = 11$, $\hat{a}_{3,f}(0) = 7$ e $\hat{k}_{3,f}(0) = 1$, e os coeficientes da combinação convexa em $\alpha_{1,f}(0) = 0.5$, $\alpha_{2,f}(0) = 0.5$ e $\alpha_{3,f}(0) = 0$. Escolhemos o parâmetro $\lambda = 4$, além disso escolhemos $\phi_1(0) = \phi_2(0) = 0$. O modelo de primeiro nível cujas estimativas utilizamos foi inicializado em $\hat{a}(0) = 0.5$ e $\hat{k} = 6$. Para o controle com estrutura chaveada calculamos os parâmetros $\bar{k}_1 = 4.5$ e $\bar{k}_2 = 5$ a partir de 3.13.

De forma a facilitar a comparação entre as estimativas, plotamos todas as estimativas de a_p no mesmo gráfico, que se encontra na Figura 3.1. Fizemos o mesmo para todas as estimativas de k_p , que estão representadas no gráfico da Figura 3.2. Escolhemos omitir as estimativas dos modelos de primeiro nível que não iniciam em $\hat{a} = 0.5$ e $\hat{k} = 6$. Entendemos que estes modelos não contribuem com informações relevantes pois são inicializados em valores distintos das estimativas de segundo nível iniciais.




Figura 3.1: Estimativa do parâmetro $a_p = 3$ para a planta Σ_p de ordem 1 para o Modelo de Identificação por Regressão Linear e a Adaptação de Segundo Nível com $N=3$, 12 segundos de simulação




Figura 3.2: Estimativa do parâmetro $k_p = 1.5$ para a planta Σ_p de ordem 1 para o Modelo de Identificação por Regressão Linear e a Adaptação de Segundo Nível com $N=3$, 12 segundos de simulação




Figura 3.3: Saída da planta Σ_p de ordem 1 para o Controle Adaptativo Indireto baseado Modelo de Identificação por Regressão Linear, Controle Adaptativo Indireto baseado em Adaptação de Segundo Nível com $N=3$, Controle com Estrutura Variável e Controle com Parâmetros Conhecidos, 12 segundos de simulação




Figura 3.4: Detalhe da Figura 3.3, entre 0 e 0.2 segundos de simulação




Figura 3.5: Sinal de controle para Controle Adaptativo Indireto baseado Modelo de Identificação por Regressão Linear, Controle Adaptativo Indireto baseado em Adaptação de Segundo Nível com $N=3$ e Controle com Parâmetros Conhecidos da Planta de Ordem 1, 12 segundos de simulação




Figura 3.6: Sinal de controle para o Controle Adaptativo por Modelo de Referência e Estrutura Variável da Planta de Ordem 1, 12 segundos de simulação

Vemos nas Figuras 3.1 e 3.2 que, para uma referência degrau, as estimativas não convergem para os valores corretos, tanto no caso da adaptação de segundo nível quanto para o modelo de identificação por regressão linear. Apesar disto, os controladores atualizados por leis integrais são capazes de cumprir o objetivo de rastreamento da saída do modelo de referência pela saída da planta, como podemos ver na Figura 3.3.

Enquanto isso, o controle com estrutura variável cumpre o objetivo de rastreamento quase que instantaneamente, como podemos ver na Figura 3.4 que é um detalhe dos instantes iniciais de simulação da Figura 3.3. O motivo pelo qual o controle com estrutura variável consegue um desempenho tão impressionante pode ser visto na Figura 3.6, isto é, o sinal de controle é de grande intensidade e por isso consegue forçar a planta rapidamente para o comportamento desejado.

A alta intensidade do sinal de controle para o controlador com estrutura variável se deve à incerteza acerca dos parâmetros da planta. É fato que, se nosso conhecimento acerca da região em que se encontram os parâmetros da planta fosse mais preciso, teríamos $\bar{k}_1$ e $\bar{k}_2$ menores como condição suficiente para garantir que o erro de saída tende a 0. Em outras palavras, se a região de incerteza acerca dos parâmetros da planta fosse menor, nosso sinal de controle poderia assumir valores menores em módulo.

Em oposição ao sinal de controle da Figura 3.6, temos os sinais de controle suaves da Figura 3.5, para o controlador com parâmetros conhecidos e o controle adaptativo usando as estimativas de primeiro e segundo nível.

3.6 Conclusão

Neste capítulo concluímos a análise do caso simples, para uma planta de ordem 1, ao abordar o problema do controle. Fizemos uso das equações de matching da planta de ordem 1 com parâmetros conhecidos, 3.3 e 3.1, substituindo os parâmetros corretos por estimativas para implementar a lei de controle, a partir de 3.4 e 3.5 e dos métodos de estimação de parâmetros, que estudamos no capítulo 2, para obter as estimativas.

Disponibilizamos os algoritmos nas Tabelas 3.1 e 3.2.

Foram feitos estudos de simulação, nos quais avaliamos que aplicar a adaptação de segundo nível ao controle adaptativo na estratégia indireta produz resultados de rastreamento do sinal de saída do modelo pelo sinal de saída da planta que são mais rápidos. Comparado com o controle com estrutura variável, no entanto, o desempenho de rastreamento do IMRAC com adaptação de segundo nível ainda é muito mais lento. Apesar disso, o controle com estrutura variável exibe um sinal de controle com alta intensidade e chattering enquanto o sinal de controle do IMRAC com parâmetros atualizados por leis integrais é suave, além de ser de baixa intensidade em comparação.

Capítulo 4

Estimação de Parâmetros, Ordem n

Continuamos, então, a estender resultados que obtivemos para estimação de parâmetros de plantas lineares invariantes no tempo de ordem 1 e grau relativo 1 para plantas lineares de ordem n e grau relativo 1.

Em (Han & Narendra 2012, Narendra et al. 2012, Narendra et al. 2014) entre as hipóteses colocadas na modelagem do sistema estão a de que o vetor b do espaço de estado da planta é conhecido, e que as matrizes se encontram em forma companheira. Buscamos então o conceito de adaptação de segundo nível para uma planta mais geral.

Neste trabalho, apresentamos o conceito de adaptação de segundo nível baseada em modelos de identificação por regressão linear. Este conceito é distinto da adaptação de segundo nível baseada em modelos de identificação série-paralelos apresentada por Narendra.

Demonstramos a seguir, para a planta de ordem n , que uma combinação convexa de coeficientes constantes das estimativas de modelos de primeiro nível é equivalente a um modelo de primeiro nível. Isto é estritamente verdadeiro quando os erros de identificação são inicialmente nulos.

Mostramos também que mesmo que os erros não sejam inicialmente nulos, a combinação convexa dos erros de identificação tende a 0 exponencialmente dependendo de um parâmetro de projeto. Devido a esta propriedade é possível estimar os coeficientes da combinação convexa das estimativas dos Modelos de Primeiro Nível que produzem os parâmetros verdadeiros da planta. O resultado disto, como já vimos para a planta de ordem 1, é um ganho em rapidez de convergência das estimativas de segundo nível para seus valores corretos em relação às estimativas de primeiro nível.

Ao obtermos uma convergência mais rápida dos parâmetros, a adaptação de segundo nível pode ser usada para gerar um sinal de controle melhor no que tange a especificações como energia utilizada e sobressinal, ao mesmo tempo que torna o transitório da planta mais rápido e mais suave como pode ser visto recentemente em (Pandey et al. 2017) e mostraremos em resultados de simulação no capítulo posterior a este.

Finalmente, apresentamos a adaptação de segundo nível com fator de esquecimento. Demonstramos por simulação que a coleta de informações através de uma integral de convolução ao longo do transitório resulta numa melhora do resultado da adaptação de segundo nível em termos de suavidade das estimativas e rapidez de convergência.

4.1 Descrição do Problema

Considere a seguinte planta de ordem n , grau relativo unitário, linear e invariante no tempo descrita pela função de transferência:

$$\Sigma_p : G_p(s) = \frac{y(s)}{u(s)} = \frac{N_p(s)}{D_p(s)}$$

em que:

$$\begin{aligned} N_p(s) &= b_1 s^{n-1} + b_2 s^{n-2} + \dots + b_{n-1} s + b_n \\ D_p(s) &= s^n + a_1 s^{n-1} + a_2 s^{n-2} + \dots + a_{n-1} s + a_n \end{aligned} \quad (4.1)$$

e os limitantes superiores $b_1^+, \dots, b_n^+, a_1^+, a_n^+$ e inferiores $b_1^-, \dots, b_n^-, a_1^-, a_n^-$ dos parâmetros $b_1, \dots, b_n, a_1, \dots, a_n$ são conhecidos. Desta forma as combinações de limitantes $b_1^+, \dots, b_n^+, a_1^+, a_n^+$ e $b_1^-, \dots, b_n^-, a_1^-, a_n^-$ representam vértices de um politopo convexo que delimita a região de incerteza $S_{\theta,f} \in R^{2n}$ dos parâmetros $b_1, \dots, b_n, a_1, \dots, a_n$ no espaço de parâmetros. A região de incerteza $S_{\theta,f}$ é conhecida. O grau dos polinômios $N_p(s)$ e $D_p(s)$ é conhecido.

Como no capítulo 2, o objetivo deste capítulo é o de identificação. Queremos conhecer os valores dos parâmetros $b_1, \dots, b_n, a_1, \dots, a_n$ da função de transferência da planta, através de medidas do sinal de entrada $u(t)$ e do sinal de saída $y(t)$. Consideramos, para tanto, que o sinal de entrada $u(t)$ é uniformemente limitado, persistentemente excitante de ordem n e contínuo por partes, além disto, assumimos que $u(t)$ é tal que há garantia que $y(t)$ é uniformemente limitado e contínuo por partes.

4.2 Estimação de Parâmetros Convencional

Ao manipular a função de transferência da planta podemos escrever, no domínio da frequência, que:

$$s^n y(s) = -a_1 s^{n-1} y(s) - \dots - a_n y(s) + b_1 s^{n-1} u(s) + \dots + b_n u(s) \quad (4.2)$$

Definimos, então, o seguinte polinômio, de grau n :

$$\Lambda(s) \triangleq s^n + \lambda_1 s^{n-1} + \lambda_2 s^{n-2} + \dots + \lambda_{n-1} s + \lambda_n \quad (4.3)$$

onde $\Lambda(s)$ é Hurwitz e mônico, e escrevemos a partir de 4.2 :

$$\frac{s^n}{\Lambda(s)}y(s) = -a_1 \frac{s^{n-1}}{\Lambda(s)}y(s) - \dots - a_n \frac{1}{\Lambda(s)}y(s) + b_1 \frac{s^{n-1}}{\Lambda(s)}u(s) + \dots + b_n \frac{1}{\Lambda(s)}u(s)$$

Então, definimos os seguintes sinais:

$$\begin{aligned} z(s) &\triangleq \frac{s^n}{\Lambda(s)}y(s) \\ \phi(s) &\triangleq \begin{bmatrix} -\frac{s^{n-1}y(s)}{\Lambda(s)} & \dots & -\frac{y(s)}{\Lambda(s)} & \frac{s^{n-1}u(s)}{\Lambda(s)} & \dots & \frac{u(s)}{\Lambda(s)} \end{bmatrix}^T \\ \theta_p^* &\triangleq [a_1 \quad \dots \quad a_n \quad b_1 \quad \dots \quad b_n]^T \end{aligned} \quad (4.4)$$

onde o vetor regressor ϕ pode ser gerado através de filtros de $y(t)$ e $u(t)$:

$$\begin{aligned} \dot{\phi}_1 &= \Lambda_c \phi_1 - l y \\ \dot{\phi}_2 &= \Lambda_c \phi_2 + l u \\ \phi &= [\phi_1 \quad \phi_2]^T \end{aligned} \quad (4.5)$$

em que Λ_c e l são escolhidos de acordo com 4.3 e 4.4.

Temos a partir de 4.4 e 4.2, portanto, a seguinte parametrização para a planta:

$$z(s) = \theta_p^{*T} \phi \quad (4.6)$$

e notamos que z depende de uma combinação linear dos componentes do vetor ϕ , cujos coeficientes são os parâmetros do numerador e denominador da função de transferência.

Podemos gerar z da seguinte forma:

$$z(t) = y + \lambda_f^T \phi_1 \quad (4.7)$$

onde $\lambda_f^T = [\lambda_1 \quad \lambda_2 \quad \dots \quad \lambda_{n-1} \quad \lambda_n]$.

Criamos, então, um modelo de identificação a partir de uma combinação linear dos sinais componentes do vetor ϕ como:

$$\Sigma_{1,f} : \hat{z}_{1,f} = \hat{\theta}_{1,f}^T \phi \quad (4.8)$$

e temos agora um modelo cujos parâmetros desejamos ajustar, tal que tendam aos parâmetros da planta, assim como no capítulo 2. Queremos que a saída deste modelo se comporte identicamente ao sinal $z(t)$. Portanto, devemos avaliar a diferença entre o sinal de saída do modelo e o sinal z .

Definimos o erro de identificação:

$$e_{1,f} \triangleq \hat{z}_{1,f} - z \quad (4.9)$$

Definimos também o seguinte sinal:

$$m^2 = 1 + n_s^2 \quad (4.10)$$

onde $n_s = \phi^T \phi$ é chamado de sinal normalizador, para esta escolha de n_s temos que o sinal $\frac{\phi}{m}$ é uniformemente limitado, mesmo que ϕ ou m não sejam uniformemente limitados.

Então, construímos o seguinte erro de identificação normalizado:

$$\epsilon_{1,f} = \frac{e_{1,f}}{m^2} \quad (4.11)$$

Definimos o erro paramétrico:

$$\tilde{\theta}_{1,f} \triangleq \hat{\theta}_{1,f} - \theta_p^* \quad (4.12)$$

e a partir de 4.9, 4.11 e 4.12 podemos expressar o erro de identificação normalizado como:

$$\epsilon_{1,f} = \frac{\tilde{\theta}_{1,f} \phi}{m^2} \quad (4.13)$$

ou seja, o erro de identificação normalizado depende da combinação linear dos sinais do vetor ϕ cujos coeficientes são os erros paramétricos para as estimativas dos parâmetros da função de transferência da planta.

Consideremos agora a seguinte função de custo:

$$J(\hat{\theta}_{1,f}) = \frac{\epsilon_{1,f}^2 m^2}{2} = \frac{(\hat{\theta}_{1,f}^T \phi - z)^2}{2m^2} \quad (4.14)$$

a qual gostaríamos de minimizar em relação ao vetor $\hat{\theta}_{1,f}$. Como $\frac{\phi}{m}$ é uniformemente limitado segue que $J(\hat{\theta}_{1,f})$ é convexa em $\hat{\theta}_{1,f}$. Aplicando o método do gradiente a trajetória que minimiza $J(\hat{\theta}_{1,f})$ é dada por:

$$\dot{\hat{\theta}}_{1,f} = -\Gamma \nabla J(\hat{\theta}_{1,f}) \quad (4.15)$$

onde $\Gamma = \Gamma^T > 0$ é uma matriz chamada matriz de ganhos adaptativos.

Temos que o gradiente desta função de custo é:

$$\nabla J(\theta_{1,f}) = \frac{(\hat{\theta}_{1,f}^T \phi - z)\phi}{m^2} = \epsilon_{1,f} \phi \quad (4.16)$$

e a partir 4.15 e 4.16 chegamos à seguinte lei adaptativa:

$$\dot{\hat{\theta}}_{1,f} = -\Gamma \epsilon_{1,f} \phi \quad (4.17)$$

Assumimos que a planta é invariante no tempo, portanto, θ_p^* é constante:

$$\tilde{\theta}_{1,f} = \hat{\theta}_{1,f} - \theta_p^* \rightarrow \dot{\tilde{\theta}}_{1,f} = \dot{\hat{\theta}}_{1,f} - \cancel{\dot{\theta}_p^*}^0 = \dot{\hat{\theta}}_{1,f} \quad (4.18)$$

e como no capítulo 2, a variação do erro paramétrico $\tilde{\theta}_{1,f}$ é idêntica à variação da própria estimativa do vetor de parâmetros da planta $\hat{\theta}_{1,f}$:

$$\dot{\tilde{\theta}}_{1,f} = -\Gamma \varepsilon_{1,f} \phi \quad (4.19)$$

Consideremos agora a seguinte candidata a função de Lyapunov, como forma de avaliar a estabilidade deste estimador:

$$V(\tilde{\theta}_{1,f}) = \frac{\tilde{\theta}_{1,f}^T \Gamma^{-1} \tilde{\theta}_{1,f}}{2} \quad (4.20)$$

derivando ao longo de suas trajetórias obtemos:

$$\dot{V} = \tilde{\theta}_{1,f}^T \phi \varepsilon_{1,f} = -\varepsilon_{1,f}^2 m^2 \leq 0 \quad (4.21)$$

e como $\dot{V}$ é semi-definida negativa V não pode crescer. Isto implica em $\tilde{\theta}_{1,f}$ uniformemente limitado, que implica em $\varepsilon_{1,f}, \varepsilon_{1,f} m$ uniformemente limitados. Como no capítulo 2, este resultado implica que $\varepsilon_{1,f} m \in \mathcal{L}_2$. Apesar de não garantir diretamente que $e_{1,f}$ tende para 0, devido às condições que impomos sobre $u(t)$ temos que $\frac{\phi}{m}, \frac{\dot{m}}{m}$ são uniformemente limitados e é possível demonstrar que $\frac{d(\varepsilon_{1,f} m)}{dt}$ é uniformemente limitado e aplicar o corolário do lema de Barbalat. Portanto o erro de identificação tende a 0 e a saída $\hat{z}_{1,f}$ do modelo de identificação tende para o sinal $z(t)$ assintoticamente.

Finalmente, como $u(t)$ é PE há garantia de convergência dos parâmetros para seus valores corretos. Para mais detalhes acerca deste modelo de identificação, incluindo prova da afirmação acerca da convergência dos parâmetros para seus valores corretos, referimos o leitor a (Ioannou & Sun 1996).

4.3 Adaptação de Segundo Nível

A partir da parametrização que desenvolvemos na seção anterior, consideremos os $i = 1, \dots, N$, com $N \geq 2n + 1$, modelos de identificação por regressão linear:

$$\Sigma_{i,f} : \hat{z}_{i,f} = \hat{\theta}_{i,f}^T \phi \quad (4.22)$$

onde os vetores de parâmetros $\hat{\theta}_{i,f}$ são inicializados nos vértices de um fecho convexo no espaço de parâmetros. Este fecho convexo deve conter a região de incerteza para os componentes do vetor de parâmetros θ_p^* da planta, que é delimitada por um polítopo convexo cujos vértices são as combinações dos limitantes inferiores e superiores $b_1^+, \dots, b_n^+, a_1^+, \dots, a_n^+$ e $b_1^-, \dots, b_n^-, a_1^-, \dots, a_n^-$, que são conhecidos.

Definimos os $i = 1, \dots, N$ erros de identificação das saídas destes modelos em relação ao sinal $z(t)$:

$$e_{i,f} \triangleq \hat{z}_{i,f} - z \quad (4.23)$$

Definimos os $i = 1, \dots, N$ erros paramétricos:

$$\tilde{\theta}_{i,f} = \hat{\theta}_{i,f} - \theta_p^* \quad (4.24)$$

Definimos os $i = 1, \dots, N$ erros de identificação normalizados:

$$\varepsilon_{i,f} = \frac{e_{i,f}}{m^2} \quad (4.25)$$

e temos que:

$$\varepsilon_{i,f} = \frac{\tilde{\theta}_{i,f} \phi}{m^2} \quad (4.26)$$

Pelo mesmo procedimento da seção anterior, temos que os vetores de parâmetros $\hat{\theta}_{i,f}$, $i = 1, \dots, N$ podem ser atualizados pelo método do gradiente:

$$\dot{\hat{\theta}}_{i,f} = -\Gamma \varepsilon_{i,f} \phi \quad (4.27)$$

onde os N modelos de identificação têm a mesma estrutura e portanto usam o mesmo tipo de lei de ajuste de seus parâmetros. Cada um dos modelos de identificação tem a diferença entre seu sinal de saída e o sinal z avaliado e este erro de identificação é usado para realizar o ajuste dos parâmetros de cada modelo a cada instante de tempo.

A partir desta lei adaptativa obtemos uma expressão para as dinâmicas $\dot{e}_{i,f}$:

$$\dot{e}_{i,f} = \dot{\hat{\theta}}_{i,f}^T \phi + \tilde{\theta}_{i,f}^T \dot{\phi} = -\frac{1}{m^2} e_{i,f} \phi^T \Gamma \phi + \tilde{\theta}_{i,f}^T \dot{\phi} \quad (4.28)$$

com $i = 1, \dots, N$.

Faremos agora um detalhamento do raciocínio que leva à adaptação de segundo nível, como fizemos no capítulo 2. Os vetores de parâmetros $\hat{\theta}_{i,f}$, $i = 1, \dots, N$ formam um fecho convexo no espaço de parâmetros. Cada um dos pontos no interior ou fronteira deste fecho convexo pode ser representado por uma combinação convexa:

$$\begin{aligned} \hat{\theta}_{v,f} &= \sum_{i=1}^N \hat{\theta}_{i,f} \beta_{i,f} \\ \sum_{i=1}^N \beta_{i,f} &= 1 \\ 0 &\leq \beta_{i,f} \leq 1 \end{aligned} \quad (4.29)$$

Criamos, então, um modelo de identificação virtual a partir de alguma destas combi-

nações convexas:

$$\Sigma_{v,f} : \hat{z}_{v,f} = \theta_{v,f}^T \phi \quad (4.30)$$

Definimos o erro de identificação para o modelo virtual:

$$e_{v,f} \triangleq \hat{z}_{v,f} - z \quad (4.31)$$

Definimos o erro paramétrico:

$$\tilde{\theta}_{v,f} \triangleq \hat{\theta}_{v,f} - \theta_p^* \quad (4.32)$$

e podemos manipular sua expressão:

$$\tilde{\theta}_{v,f} = \sum_{i=1}^N \hat{\theta}_{i,f} \beta_{i,f} - \theta_p^* = \sum_{i=1}^N \hat{\theta}_{i,f} \beta_{i,f} - \sum_{i=1}^N \theta_p^* \beta_{i,f} = \sum_{i=1}^N \tilde{\theta}_{i,f} \beta_{i,f} \quad (4.33)$$

onde obtemos que, assim como as estimativas do modelo virtual são combinações convexas dos parâmetros dos modelos por regressão linear, os erros paramétricos para o modelo virtual podem ser obtidos como combinações convexas dos erros paramétricos dos modelos por regressão linear, com os mesmos coeficientes de combinação.

Como o vetor de parâmetros do modelo virtual é uma combinação convexa dos parâmetros dos modelos de primeiro nível, segue que a lei de ajuste que atualiza o vetor de parâmetros do modelo virtual é a combinação convexa das leis de ajuste dos modelos de primeiro nível com os mesmos coeficientes de combinação:

$$\dot{\hat{\theta}}_{v,f} = \sum_{i=1}^N \dot{\hat{\theta}}_{i,f} \beta_{i,f} = -\Gamma \sum_{i=1}^N \epsilon_{i,f} \beta_{i,f} \phi \quad (4.34)$$

e temos que a lei de ajuste para o vetor de parâmetros do modelo virtual depende da combinação convexa dos erros de identificação normalizados dos modelos de primeiro nível. Devemos, portanto, analisar a dinâmica desta combinação convexa. Derivamos $\sum_{i=1}^N e_{i,f} \beta_{i,f}$, substituindo as dinâmicas dos erros $\dot{e}_{i,f}$ por suas expressões a partir de 4.28, as leis de ajuste $\dot{\hat{\theta}}_{i,f}$ por 4.27 e utilizando 4.33 para reagrupar as combinações convexas de erros paramétricos. Obtemos a seguinte equação:

$$\sum_{i=1}^N \dot{e}_{i,f} \beta_{i,f} = -\sum_{i=1}^N \epsilon_{i,f} \beta_{i,f} \phi^T \Gamma \phi + \sum_{i=1}^N \tilde{\theta}_{i,f}^T \beta_{i,f} \dot{\phi} \quad (4.35)$$

A expressão da dinâmica do erro de identificação não normalizado do modelo virtual é da mesma forma dos modelos de primeiro nível:

$$\dot{e}_{v,f} = \dot{\tilde{\theta}}_{v,f}^T \phi + \tilde{\theta}_{v,f}^T \dot{\phi} \quad (4.36)$$

e partir de 4.33, 4.34 e 4.36, obtemos:

$$\dot{e}_{v,f} = - \sum_{i=1}^N \epsilon_{i,f} \beta_{i,f} \phi^T \Gamma \phi + \sum_{i=1}^N \tilde{\theta}_{i,f}^T \beta_{i,f} \dot{\phi} \quad (4.37)$$

Comparamos 4.35 e 4.37 e vemos que dinâmica do erro de identificação $\dot{e}_{v,f}$ é idêntica à dinâmica da combinação convexa dos erros de identificação dos modelos de primeiro nível $\frac{d}{dt}(\sum_{i=1}^N e_{i,f} \beta_{i,f})$. A combinação convexa dos erros de identificação tende exponencialmente para o valor do erro de identificação do modelo virtual. Se estipularmos que $e_{v,f}(0) = \sum_{i=1}^N e_{i,f}(0) \beta_{i,f}$ então os dois se tornam idênticos. Se é verdade que $e_{v,f} \equiv \sum_{i=1}^N e_{i,f} \beta_{i,f}$ então $\epsilon_{v,f} \equiv \sum_{i=1}^N \epsilon_{i,f} \beta_{i,f}$.

Feitas estas considerações, teremos então que a expressão da lei adaptativa para o modelo virtual da equação 4.34 se reduz a:

$$\dot{\hat{\theta}}_{v,f} = -\Gamma \epsilon_{v,f} \phi \quad (4.38)$$

e a lei adaptativa obtida acima tem forma idêntica àquela usada nos modelos de primeiro nível $\Sigma_{i,f}$, $i = 1, \dots, N$. Cada um dos pontos no interior do fecho convexo corresponde a um modelo virtual. Conforme os modelos de primeiro nível têm seus parâmetros ajustados adaptativamente os modelos virtuais também tem seus parâmetros ajustados por leis idênticas. Nestas condições uma combinação convexa de coeficientes constantes dos parâmetros de modelos de primeiro nível se comporta como se fosse os parâmetros de um modelo de primeiro nível inicializados nos mesmos valores.

Consideramos que os parâmetros verdadeiros da planta contidos no vetor θ_p^* pertencem inicialmente ao fecho convexo e, portanto, podem ser representados por uma combinação convexa de coeficientes $\alpha_{i,f}^*, i = 1, \dots, N$ dos parâmetros dos modelos de primeiro nível:

$$\begin{aligned} \theta_p^* &= \sum_{i=1}^N \hat{\theta}_{i,f} \alpha_{i,f}^* \\ \sum_{i=1}^N \alpha_{i,f}^* &= 1 \\ 0 &\leq \alpha_{i,f}^* \leq 1 \end{aligned} \quad (4.39)$$

Definimos o modelo virtual:

$$\Sigma_{\alpha,f} : \hat{z}_{\alpha,f} = \theta_p^{*T} \phi \quad (4.40)$$

Definimos o erro de identificação:

$$e_{\alpha,f} \triangleq \hat{z}_{\alpha,f} - z \quad (4.41)$$

cuja dinâmica é dada por:

$$\dot{e}_{\alpha,f} = -\frac{1}{m^2} e_{\alpha,f} \phi^T \Gamma \phi \quad (4.42)$$

pois o erro paramétrico para este modelo é nulo e, portanto, desde que $\lim_{t \rightarrow \infty} \phi \neq \mathbf{0}$, temos que:

$$\lim_{t \rightarrow \infty} e_{\alpha,f} = \lim_{t \rightarrow \infty} \sum_{i=1}^N e_{i,f} \alpha_{i,f}^* = 0 \quad (4.43)$$

e o erro de identificação deste modelo virtual deve tender a 0 exponencialmente.

Vemos, como no capítulo 2, que o modelo virtual cujos parâmetros são idênticos aos da planta tende exponencialmente ao comportamento da própria planta. No entanto, não podemos garantir com modelos de identificação por regressão linear que $\sum_{i=1}^N e_{i,f}(0) \alpha_{i,f}^* = 0$, e portanto o valor de $e_{\alpha,f}(0)$ pode ser não-nulo. No entanto, $e_{\alpha,f}$ tende a 0 exponencialmente.

Portanto, mesmo que os parâmetros da planta deixem de pertencer ao fecho convexo devido ao efeito das condições iniciais, representadas por $e_{\alpha,f}(0)$ não-nulo, eventualmente a combinação convexa de coeficientes $\alpha_{i,f}^*$ dos erros de identificação dos modelos de primeiro nível tende a 0. Isto indica que em regime permanente os parâmetros da planta pertencem ao fecho convexo formado pelos parâmetros dos modelos de identificação de primeiro nível.

Se a combinação convexa dos erros de identificação não-nulos se torna constante e nula a partir de um certo instante então a combinação convexa dos erros paramétricos também deve se tornar constante e nula. Desta forma os coeficientes $\alpha_{i,f}^*, i = 1, \dots, N$ servem como alternativas de parametrização para a planta.

Assim, como uma segunda camada de estimação, ou segundo nível de adaptação, podemos buscar estimar os coeficientes da combinação linear. Consideramos, portanto, que a equação $\sum_{i=1}^N e_{i,f} \alpha_{i,f}^* = 0$ é uma ferramenta adequada de estimação.

Seguimos, a partir deste ponto, um procedimento similar ao do capítulo 2. Redefinimos o vetor $\bar{E}_f$:

$$\bar{E}_f = [\varepsilon_{1,f} \quad \dots \quad \varepsilon_{N-1,f} \quad \varepsilon_{N,f}] \quad (4.44)$$

para que usemos os erros de identificação normalizados ao invés dos erros de identificação dos modelos de primeiro nível.

Temos em forma matricial:

$$\bar{E}_f \bar{\alpha}_f^* = \sum_{i=1}^N \epsilon_{i,f} \alpha_{i,f}^* = 0 \quad (4.45)$$

Os coeficientes de $\alpha_{i,f}$ são coeficientes de uma combinação convexa, portanto:

$$\sum_{i=1}^N \alpha_{i,f}^* = 1$$

e a partir disto podemos expressar $\alpha_{N,f}^*$ por:

$$\alpha_{N,f} = 1 - \sum_{i=1}^{N-1} \alpha_{i,f}^* \quad (4.46)$$

Isolamos o termo $\epsilon_{N,f} \alpha_{N,f}^*$ do somatório na equação 4.45:

$$\bar{E}_f \bar{\alpha}_f^* = \sum_{i=1}^{N-1} \epsilon_{i,f} \alpha_{i,f}^* + \epsilon_{N,f} \alpha_{N,f}^*$$

e então substituímos $\alpha_{N,f}$ pela expressão da equação 4.46:

$$\bar{E}_f \bar{\alpha}_f^* = \sum_{i=1}^{N-1} \epsilon_{i,f} \alpha_{i,f}^* + \epsilon_{N,f} (1 - \sum_{i=1}^{N-1} \alpha_{i,f}^*) = 0$$

que reorganizado fica da seguinte forma:

$$\sum_{i=1}^{N-1} (\epsilon_{i,f} - \epsilon_{N,f}) \alpha_{i,f}^* = -\epsilon_{N,f} \quad (4.47)$$

Redefinimos o vetor:

$$E_f = [\epsilon_{1,f} - \epsilon_{N,f} \quad \epsilon_{2,f} - \epsilon_{N,f} \quad \dots \quad \epsilon_{N-1,f} - \epsilon_{N,f}] \quad (4.48)$$

pois estamos utilizando os erros de identificação normalizados.

A equação 4.47 pode, então, ser reescrita como:

$$E_f \alpha_f^* = -\epsilon_{N,f} \quad (4.49)$$

A equação 4.49 é ponto de partida para estimar em tempo real os coeficientes da combinação convexa que produzem os parâmetros verdadeiros da planta. Substituímos o vetor α_f^* nesta equação por uma estimativa α_f , como no capítulo 2, e a partir desta substituição podemos obter uma equação diferencial para estimar α_f^* :

$$\dot{\alpha}_f = -\gamma_{n2,f} E_f^T E_f \alpha_f - \gamma_{n2,f} E_f^T \epsilon_{N,f} \quad (4.50)$$

onde $\gamma_{n2,f} > 0$ é um parâmetro de ajuste do projetista que vamos chamar de ganho adaptativo de segundo nível.

A estimativa $\bar{\alpha}_f$ de $\bar{\alpha}_f^*$ fica da seguinte forma, como no capítulo 2:

$$\bar{\alpha}_f^T = \begin{bmatrix} \alpha_f^T & 1 - \vec{1}\alpha_f \end{bmatrix} \quad (4.51)$$

onde $\vec{1}$ é o vetor linha $[1 \ 1 \ \dots \ 1]$ de tamanho apropriado.

Definimos, então, o erro paramétrico para a estimativa $\bar{\alpha}_f$ e para α_f :

$$\begin{aligned} \tilde{\alpha}_f &\triangleq \bar{\alpha}_f - \bar{\alpha}_f^* \\ \tilde{\alpha}_f &\triangleq \alpha_f - \alpha_f^* \end{aligned} \quad (4.52)$$

e como assumimos $\bar{\alpha}_f^*$ invariante no tempo, temos que:

$$\begin{aligned} \dot{\tilde{\alpha}}_f &= \dot{\alpha}_f - \dot{\bar{\alpha}}_f^* = \dot{\alpha}_f \\ \dot{\tilde{\alpha}}_f &= \dot{\alpha}_f - \dot{\alpha}_f^* = \dot{\alpha}_f \end{aligned} \quad (4.53)$$

Então, substituindo $\dot{\alpha}_f$ por $\dot{\tilde{\alpha}}_f$ e α_f por $\tilde{\alpha}_f + \alpha_f^*$ em 4.50 e cancelando os termos equivalentes devido a 4.49, temos:

$$\dot{\tilde{\alpha}}_f = -\gamma_{n2,f} E_f^T E_f \tilde{\alpha}_f - \gamma_{n2,f} E_f^T e_{\alpha,f} \frac{1}{m^2} \quad (4.54)$$

onde o termo $-\gamma_{n2,f} E_f^T e_{\alpha,f} \frac{1}{m^2}$ aparece devido às condições iniciais não-nulas, pois não podemos assumir $e_{\alpha,f}(0) = 0$.

Consideremos, então, a seguinte candidata a função de Lyapunov definida positiva:

$$V(\tilde{\alpha}_f) = \frac{1}{2\gamma_{n2,f}} \tilde{\alpha}_f^T \tilde{\alpha}_f \quad (4.55)$$

derivando ao longo de suas trajetórias teremos:

$$\dot{V} = \frac{1}{\gamma_{n2,f}} \tilde{\alpha}_f^T \dot{\tilde{\alpha}}_f$$

e explicitando $\tilde{\alpha}_f$ e $\dot{\tilde{\alpha}}_f$:

$$\dot{V} = \begin{bmatrix} \tilde{\alpha}_f^T & \vec{1}\tilde{\alpha}_f \end{bmatrix} \begin{bmatrix} \dot{\tilde{\alpha}}_f^T \\ \vec{1}\dot{\tilde{\alpha}}_f \end{bmatrix}$$

ao substituirmos $\dot{\tilde{\alpha}}_f$ por 4.54 e reorganizarmos, obtemos que:

$$\dot{V} = -N\tilde{\alpha}_f^T E_f^T E_f \tilde{\alpha}_f - N\tilde{\alpha}_f^T E_f^T e_{\alpha,f} \frac{1}{m^2} \quad (4.56)$$

Na equação 4.56 o termo de sinal indefinido $-N\tilde{\alpha}_f^T E_f^T e_{\alpha,f} \frac{1}{m^2}$ tende para 0 exponencialmente pois $e_{\alpha,f}$ tende para 0 exponencialmente. Se os componentes de E_f e $\tilde{\alpha}_f$ tendem a

O apenas assintoticamente, então o termo de sinal indefinido é, eventualmente, dominado pelo termo de sinal definido negativo $-N\tilde{\alpha}_f^T E_f^T E_f \tilde{\alpha}_f$. Nesta expressão de $\dot{V}$ fica expresso novamente que a rapidez de convergência dos parâmetros na adaptação de segundo nível depende em algum grau do número de modelos N .

Assim, V não pode crescer a partir de um certo instante, o que implica em $\tilde{\alpha}_f, \tilde{\alpha}_f$ uniformemente limitados. $\tilde{\alpha}_f, \tilde{\alpha}_f$ uniformemente limitados implicam em $\tilde{\alpha}_f, \alpha_f$ uniformemente limitados. Como os erros de identificação dos modelos de primeiro nível são uniformemente limitados e α_f é uniformemente limitado isto implica em $\dot{\alpha}_f, \dot{\alpha}_f$ uniformemente limitados.

Por fim, quando o sinal de controle u for persistentemente excitante teremos que E_f só será o vetor nulo a partir de algum instante quando as estimativas de primeiro nível forem equivalentes aos parâmetros corretos, o que indica que uma combinação convexa destes parâmetros também tenderá para os valores corretos. A estimativa do vetor de parâmetros θ_p^* da planta, $\hat{\theta}_{n2,f}$, é entregue pela combinação convexa de coeficientes $\alpha_{i,f}, i = 1, \dots, N$ dos parâmetros $\hat{\theta}_{i,f}, i = 1, \dots, N$:

$$\hat{\theta}_{n2,f} = \text{proj}_{S_{\theta,f}}(\alpha_{1,f}\hat{\theta}_{1,f} + \alpha_{2,f}\hat{\theta}_{2,f} + \dots + \alpha_{N,f}\hat{\theta}_{N,f}) \quad (4.57)$$

em que $\text{proj}_{S_{\theta,f}}(\cdot)$ é o operador de projeção retangular dentro da região de incerteza $S_{\theta,f}$ delimitada pelo polítopo convexo cujos vértices são as combinações de limitantes $b_1^+, \dots, b_n^+, a_1^+, \dots, a_n^+$ e $b_1^-, \dots, b_n^-, a_1^-, \dots, a_n^-$.

4.4 Adaptação de Segundo Nível com Fator de Esquecimento

No capítulo 2 vimos que é possível acumular informações sobre os erros de identificação dos modelos de primeiro nível de forma a melhorar a convergência das estimativas dos parâmetros para seus valores corretos. No entanto, estipulamos que era adequado integrar desde o instante inicial pois consideramos a planta invariante no tempo. Na prática o uso de métodos de identificação em tempo real se dá quando os parâmetros da planta variam, o que torna métodos de identificação de parâmetros por batelada inefetivos. Neste caso, integrar desde o instante inicial como fizemos no capítulo 2 não é adequado.

Se os parâmetros da planta variam então acumular informações suficientemente recentes melhora os resultados de convergência das estimativas dos parâmetros para seus valores corretos. No entanto, acumular informações antigas pode produzir piora dos resultados. Assim, se quisermos acumular informações, devemos buscar um critério de descarte de informações.

Como contribuição deste trabalho chegamos ao seguinte raciocínio, com base na ideia presente em (Chowdhary et al. 2013) de acumular informações de instantes anteriores do

sistema para melhorar a convergências das estimativas dos parâmetros, aplicada à adaptação de segundo nível:

$$\begin{aligned}
E_f^T E_f \alpha_f^* &= -E_f^T \varepsilon_{N,f} \\
\int_0^t e^{-\sigma(t-\tau)} E_f^T(\tau) E_f(\tau) \alpha_f^* d\tau &= -\int_0^t e^{-\sigma(t-\tau)} E_f^T(\tau) \varepsilon_{N,f}(\tau) d\tau \\
\int_0^t e^{-\sigma(t-\tau)} E_f^T(\tau) E_f(\tau) d\tau \alpha_f^* &= -\int_0^t e^{-\sigma(t-\tau)} E_f^T(\tau) \varepsilon_{N,f}(\tau) d\tau \\
0 &= -\int_0^t e^{-\sigma(t-\tau)} E_f^T(\tau) E_f(\tau) d\tau \alpha_f^* - \int_0^t e^{-\sigma(t-\tau)} E_f^T(\tau) \varepsilon_{N,f}(\tau) d\tau \\
0 &= -\int_0^t e^{-\sigma(t-\tau)} E_f^T(\tau) E_f(\tau) d\tau \alpha_f^* - E_f^T E_f \alpha_f^* - \int_0^t e^{-\sigma(t-\tau)} E_f^T(\tau) \varepsilon_{N,f}(\tau) d\tau - E_f^T \varepsilon_{N,f}
\end{aligned}$$

onde $\sigma > 0$ é chamado fator de esquecimento e serve como nosso critério de descarte de informações.

Como os erros de identificação são uniformemente limitados e tendem a 0 a medida que o tempo t tende a infinito, as integrais são limitadas e tendem a valores nulos. Substituindo α_f^* por sua estimativa e introduzindo o ganho adaptativo, como no procedimento da seção anterior, temos a seguinte equação:

$$\dot{\alpha}_f = \gamma_{n2,f} \left(-\int_0^t e^{-\sigma(t-\tau)} E_f^T(\tau) E_f(\tau) d\tau \alpha_f - E_f^T E_f \alpha_f - \int_0^t e^{-\sigma(t-\tau)} E_f^T(\tau) \varepsilon_{N,f}(\tau) d\tau - E_f^T \varepsilon_{N,f} \right) \quad (4.58)$$

Redefinimos as seguintes variáveis:

$$\begin{aligned}
M_f &\triangleq \int_0^t e^{-\sigma(t-\tau)} E_f^T(\tau) E_f(\tau) d\tau \\
v_f &\triangleq \int_0^t e^{-\sigma(t-\tau)} E_f^T(\tau) \varepsilon_{N,f}(\tau) d\tau
\end{aligned} \quad (4.59)$$

que podem ser geradas diretamente estipulando $M_f(0) = \mathbf{0}$ e $v_f(0) = \mathbf{0}$ pelas equações diferenciais:

$$\begin{aligned}
\dot{M}_f &= -\sigma M_f + E_f^T E_f \\
\dot{v}_f &= -\sigma v_f + E_f^T \varepsilon_{N,f}
\end{aligned} \quad (4.60)$$

Então, reescrevemos 4.58 como:

$$\dot{\alpha}_f = \gamma_{n2,f}(-M_f \alpha_f - E_f^T E_f \alpha_f - v_f - E_f^T \epsilon_{N,f}) \quad (4.61)$$

Consideremos, então, a seguinte candidata a função de Lyapunov definida positiva:

$$V = \frac{1}{2\gamma_{n2,f}} \tilde{\alpha}_f^T \tilde{\alpha}_f \quad (4.62)$$

e derivando ao longo de suas trajetórias obtemos:

$$\dot{V} = -N\tilde{\alpha}_f^T (E_f^T E_f + M_f) \tilde{\alpha}_f - N\tilde{\alpha}_f^T E_f^T e_{\alpha,f} \frac{1}{m^2} - N\tilde{\alpha}_f^T M_f \alpha_f^* \quad (4.63)$$

Temos que $N\tilde{\alpha}_f^T M_f \alpha_f^* = N \int_0^t e^{-\sigma(t-\tau)} E_f^T(\tau) e_{\alpha}(\tau) d\tau$. Novamente, como e_{α} tende a 0 exponencialmente os termos de sinal indefinido $-N\tilde{\alpha}_f^T E_f^T e_{\alpha,f} - N\tilde{\alpha}_f^T M_f \alpha_f^*$ tendem a 0 exponencialmente. Se o restante dos sinais tende a 0 apenas assintoticamente, então os termos de sinal indefinido são, eventualmente, dominados pelo termo de sinal definido $-N\tilde{\alpha}_f^T (E_f^T E_f + M_f) \tilde{\alpha}_f$.

Com a modificação proposta a convergência de α_f para α_f^* passa a depender de informações presentes e passadas. Postulamos, para alguma escolha do parâmetro de projeto σ , que a lei de ajuste 4.61 produz resultados melhores que 4.50. De fato, no capítulo 2, demonstramos que ao integrar desde o instante inicial para uma planta invariante no tempo temos garantia de convergência dos parâmetros. Ou seja, há algum benefício em potencial nesta operação.

Outra forma de calcular os coeficientes corretos é monitorando o posto de M_f . Se a matriz M_f for de posto cheio pode-se calcular α_f^* diretamente por inversão de matrizes resolvendo o sistema de equações $M_f \alpha_f^* = -v_f$ para α_f^* .

4.5 Resultados

Apresentamos, neste capítulo, o modelo de identificação por regressão linear para a planta de ordem n . Discutimos suas propriedades. Demonstramos a estabilidade do estimador por método do gradiente normalizado e que o erro de identificação tende a 0 para este modelo. Mencionamos que as estimativas tendem aos valores corretos na presença de um sinal de entrada com a característica de persistência de excitação.

A partir deste modelo de identificação, provamos que existem coeficientes constantes de uma combinação convexa das estimativas dos parâmetros de N ou mais modelos que produzem os parâmetros da planta. Demonstramos que, como uma segunda camada de adaptação, ou uma adaptação em dois níveis, pode-se atualizar estimativas destes coeficientes para calcular uma estimativa de segundo nível dos parâmetros da planta.

4.5.1 Resumo dos Algoritmos

Caso o leitor deseje consultar rapidamente, listamos os algoritmos de identificação de primeiro e segundo nível nas Tabelas 4.1 e 4.2, a seguir:

Tabela 4.1: Algoritmo do Modelo de Identificação por Regressão Linear

Regressão Linear
$\Sigma_p : \dot{x}_p = A_p x_p + b_p u$
$y_p = h_p^T x_p$
$z = \frac{s^n y}{\Lambda(s)}$
$\dot{\phi}_1 = \Lambda_c \phi_1 + l y_p$
$\dot{\phi}_2 = \Lambda_c \phi_2 + l u$
$\phi^T = [\phi_1 \quad \phi_2]$
$\Sigma_{1,f} : \hat{z}_{1,f} = \hat{\theta}_{1,f} \phi$
$e_{1,f} = \hat{z}_{1,f} - z$
$n_s^2 = \phi^T \phi$
$Q = Q^T > 0$
$m^2 = 1 + n_s^2$
$\varepsilon_{1,f} = \frac{e_{1,f}}{m^2}$
$\Gamma = \Gamma^T > 0$
$\hat{\theta}_{1,f} = -\Gamma \varepsilon_{1,f} \phi$

Tabela 4.2: Algoritmos da Adaptação de Segundo Nível baseada em Modelos de Identificação por Regressão Linear para uma Planta SISO de Grau n

Segundo Nível Regressão Linear	Segundo Nível Regressão Linear Modificado
$\Sigma_p : \dot{x}_p = A_p x_p + b_p u$ $y_p = h_p^T x_p$ $z = \frac{s^n y}{\Lambda(s)}$ $\dot{\phi}_1 = \Lambda_c \phi_1 + l y_p$ $\dot{\phi}_2 = \Lambda_c \phi_2 + l u$ $\phi^T = [-\phi_1 \quad \phi_2]$ $\Sigma_{i,f} : \hat{z}_{i,f} = \hat{\theta}_{i,f} \phi$ $e_{i,f} = \hat{z}_{i,f} - z$ $n_s^2 = \phi^T \phi$ $Q = Q^T > 0$ $m^2 = 1 + n_s^2$ $\epsilon_{i,f} = \frac{e_{i,f}}{m^2}$ $\Gamma = \Gamma^T > 0$ $\dot{\hat{\theta}}_{i,f} = -\Gamma \epsilon_{i,f} \phi$ $E_f = [\epsilon_{1,f} - \epsilon_{N,f} \quad \dots \quad \epsilon_{N-1,f} - \epsilon_{N,f}]$ $\dot{\alpha}_f = -E_f^T E_f \alpha_f - E_f^T \epsilon_{N,f}$ $\bar{\Theta}_f = [\hat{\theta}_{1,f} \quad \dots \quad \hat{\theta}_{N,f}]$ $\bar{\alpha}_f^T = [\alpha_f^T \quad 1 - \vec{1} \alpha_f]$ $\hat{\theta}_{n2,f} = \text{projs}_{\bar{\Theta}_f}(\bar{\Theta}_f \bar{\alpha}_f)$	$\Sigma_p : \dot{x}_p = A_p x_p + b_p u$ $y_p = h_p^T x_p$ $z = \frac{s^n y}{\Lambda(s)}$ $\dot{\phi}_1 = \Lambda_c \phi_1 + l y_p$ $\dot{\phi}_2 = \Lambda_c \phi_2 + l u$ $\phi^T = [-\phi_1 \quad \phi_2]$ $\Sigma_{i,f} : \hat{z}_{i,f} = \hat{\theta}_{i,f} \phi$ $e_{i,f} = \hat{z}_{i,f} - z$ $n_s^2 = \phi^T \phi$ $Q = Q^T > 0$ $m^2 = 1 + n_s^2$ $\epsilon_{i,f} = \frac{e_{i,f}}{m^2}$ $\Gamma = \Gamma^T > 0$ $\dot{\hat{\theta}}_{i,f} = -\Gamma \epsilon_{i,f} \phi$ $E_f = [\epsilon_{1,f} - \epsilon_{N,f} \quad \dots \quad \epsilon_{N-1,f} - \epsilon_{N,f}]$ $M_f(0) = \mathbf{0}$ $v_f(0) = \mathbf{0}$ $\dot{M}_f = -\sigma M_f + E_f^T E_f$ $\dot{v}_f = -\sigma v_f + E_f^T \epsilon_{N,f}$ $\dot{\alpha}_f = -(E_f^T E_f + M_f) \alpha_f - E_f^T \epsilon_{N,f} - v_f$ $\bar{\Theta}_f = [\hat{\theta}_{1,f} \quad \dots \quad \hat{\theta}_{N,f}]$ $\bar{\alpha}_f^T = [\alpha_f^T \quad 1 - \vec{1} \alpha_f]$ $\hat{\theta}_{n2,f} = \text{projs}_{\bar{\Theta}_f}(\bar{\Theta}_f \bar{\alpha}_f)$

4.5.2 Estudos de Simulação

Consideremos a seguinte planta linear e invariante no tempo, de ordem 2:

$$G_p(s) = \frac{N_p(s)}{D_p(s)} = \frac{b_1 s + b_2}{s^2 + a_1 s + a_2} = \frac{2s + 0}{s^2 + 4s + 3}$$

onde conhecemos o grau de $N_p(s)$ e $D_p(s)$ e desejamos identificar os parâmetros $b_1 = 2, b_2 = 0, a_1 = 4, a_2 = 3$. A região de incerteza para estes parâmetros é considerada conhecida:

$$\begin{aligned}
a_1 &\in [3 \ 8] \\
a_2 &\in [1 \ 6] \\
b_1 &\in [-1 \ 7] \\
b_2 &\in [-3 \ 3]
\end{aligned}$$

Para realizar esta tarefa, utilizaremos como base um modelo de identificação por regressão linear atualizado pelo método do gradiente normalizado e, também, aplicaremos o conceito de adaptação de segundo nível usando o número mínimo de modelos $N = 5$, com e sem fator de esquecimento. Para inicializar as simulações, usamos os seguintes valores:

$$\begin{aligned}
\Lambda(s) &= s^2 + 6s + 9 \\
\Lambda_c &= \begin{bmatrix} -6 & -9 \\ 1 & 0 \end{bmatrix} \\
l &= \begin{bmatrix} 1 \\ 0 \end{bmatrix} \\
\Gamma &= \begin{bmatrix} 100 & 0 & 0 & 0 \\ 0 & 100 & 0 & 0 \\ 0 & 0 & 100 & 0 \\ 0 & 0 & 0 & 100 \end{bmatrix} \\
x_p(0) &= \begin{bmatrix} 0.2 \\ 0.4 \end{bmatrix} \\
\phi_1(0) &= \phi_2(0) = 0 \\
u(t) &= 1 + \sin(t) + \sin(1.7t) + \sin(3t) \\
\alpha_{1,f}(0) &= 1 \\
\alpha_i(0) &= 0, \quad i \neq 1 \\
\gamma_{n2,f} &= 10 \\
\sigma &= 0.2
\end{aligned}$$

onde as condições iniciais do vetor de estado da planta $x_p(0)$ são desconhecidas. Desta forma teremos $e_{\alpha,f}(0)$ não-nulo.

Escolhemos as seguintes estimativas iniciais do vetor θ_p para os modelos de identificação de primeiro nível:

$$\begin{aligned}
\hat{\theta}_{1,f}^T(0) &= [3 \ 1 \ -1 \ -3] \\
\hat{\theta}_{2,f}^T(0) &= [28 \ 1 \ -1 \ -3] \\
\hat{\theta}_{3,f}^T(0) &= [3 \ 26 \ -1 \ -3] \\
\hat{\theta}_{4,f}^T(0) &= [3 \ 1 \ 39 \ -3] \\
\hat{\theta}_{5,f}^T(0) &= [3 \ 1 \ -1 \ 27]
\end{aligned}$$

Como na simulação do capítulo 2, omitimos as informações acerca dos parâmetros

dos modelos de primeiro nível com índices $i = 2, 3, 4, 5$, pois consideramos estas informações de pouca relevância para comparar a estimação de parâmetros convencional com a adaptação de segundo nível, já que as estimativas de segundo nível são inicializadas com valores de estimativas iguais a $\hat{\theta}_{1,f}(0)$. Obtivemos os resultados das Figuras 4.1 a 4.5:




Figura 4.1: Comportamento das estimativas do coeficiente a_1 do polinômio $D_p(s)$ para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.




Figura 4.2: Comportamento das estimativas do coeficiente a_2 do polinômio $D_p(s)$ para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.




Figura 4.3: Comportamento das estimativas do coeficiente b_1 do polinômio $N_p(s)$ para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.




Figura 4.4: Comportamento das estimativas do coeficiente b_2 do polinômio $N_p(s)$ para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.




Figura 4.5: Erro de Identificação não normalizado do Modelo de Primeiro Nível com estimativa inicial $\hat{\theta}_{1,f}(0)$

Devido às condições que impomos sobre $u(t)$ o sinal $\dot{\phi}$ é uniformemente limitado. Assim, o erro de identificação não normalizado deve tender a 0 quando o $t \rightarrow \infty$. Isto de fato se confirma e pode ser visualizado na Figura 4.5.

As estimativas de primeiro nível inicializadas em $\hat{\theta}_{1,f}(0)$ estão se aproximando dos valores corretos. As estimativas de Segundo Nível sem Fator de Esquecimento atingem os valores corretos em $t \approx 15$ segundos. As estimativas de Segundo Nível com Fator de Esquecimento atingem os valores corretos em $t \approx 6$ segundos. Podemos ver o comportamento das estimativas nas Figuras 4.1 a 4.4.

Vemos, portanto, que as estimativas de primeiro nível são mais lentas que ambos os conjuntos de estimativas de Segundo Nível na sua convergência para os valores corretos. No entanto devido a escolha de um valor alto de ganho para a Adaptação de Segundo Nível sem Fator de Esquecimento, vemos que 3 das estimativas exibem mudanças abruptas. Com a introdução de um Fator de Esquecimento na Adaptação de Segundo Nível temos como resultado uma convergência mais rápida e mais suave dos parâmetros para seus valores corretos em relação a Adaptação de Segundo Nível sem Fator de Esquecimento, utilizando o mesmo valor de ganho.

O efeito das condições iniciais $x_p^T(0)$ decai exponencialmente e não afeta a convergência dos parâmetros significativamente.

Qualquer uma dos métodos de identificação de parâmetros que estudamos, para uma planta sujeita a um sinal PE, são adequados para o objetivo de identificação. No entanto, a lei adaptativa 4.61 da adaptação de segundo nível com fator de esquecimento, para os valores de parâmetros escolhidos, se mostra uma ferramenta de identificação mais efetiva

em comparação com a lei adaptativa 4.50 da adaptação de segundo nível e a lei adaptativa 4.17 do método do gradiente normalizado.

Interpretamos esta melhora de resultado da seguinte forma: $E_f^T E_f$ é obrigatoriamente de posto 1 ou 0, pois E_f é um vetor. No entanto, M_f obtida através da integral de convolução não tem restrição quanto a seu posto.

Sabemos que a multiplicação de uma matriz por um vetor pode ser interpretada como uma operação de projeção do vetor sobre os autovetores daquela matriz, pesada pelos autovalores correspondentes. Assim, consideremos a seguir a diferença entre as equações 4.61 e 4.50.

Temos que a multiplicação de $E_f^T E_f$ por α_f projeta α_f sobre o autovetor associado ao autovalor não nulo de $E_f^T E_f$ e descarta as demais informações, desta forma, apenas parte do vetor α_f é aproveitado em 4.50. Ocorre que se α_f tiver uma grande componente perpendicular a este autovetor esta informação será descartada. Por outro lado, a multiplicação de M_f por α_f não necessariamente possui esta desvantagem em todos os instantes de tempo, pois M_f pode inclusive ser de posto cheio.

4.6 Conclusão

Neste capítulo apresentamos o modelo de identificação por regressão linear para a planta de grau n . Mostramos como este modelo pode servir como base para identificação através do conceito de adaptação de segundo nível. Na adaptação de segundo nível os coeficientes de uma combinação linear de múltiplos modelos são atualizados por uma lei integral e as estimativas são entregues por esta mesma combinação.

Disponibilizamos os algoritmos em forma compacta nas Tabelas 4.1 e 4.2. Neste capítulo tratamos apenas do problema da identificação dos parâmetros da planta de ordem n , assumindo portanto que os sinais são limitados a priori. Desta forma escolhemos uma planta estável e um sinal de controle uniformemente limitado, contínuo por partes e PE. Foram feitos estudos de simulação, nos quais avaliamos a adaptação de segundo nível com e sem fator de esquecimento e o método do gradiente normalizado.

Terminamos aqui nosso estudo da adaptação de segundo nível como ferramenta de identificação de parâmetros. Tendo estudado a adaptação de segundo nível para a planta de ordem 1 e ordem n , passaremos a seguir, no capítulo 5, ao problema do controle da planta de ordem n e grau relativo 1 conhecida com incertezas.

No problema do controle adaptativo, dispensamos duas das premissas do problema de identificação, a de que a planta é estável ou estabilizada e a de que o sinal de controle é uniformemente limitado a priori. Assim, passaremos a nos ocupar do objetivo de calcular os parâmetros do controlador a partir das estimativas dos parâmetros da planta. A lei de

controle escolhida deve produzir um sinal de controle uniformemente limitado que faça com que o sinal de saída da planta seja uniformemente limitado e cumpra o objetivo de rastreamento de um modelo de referência escolhido pelo projetista.

Capítulo 5

Controle da Planta de Ordem n

Finalmente, passamos a tratar do problema do controle de uma planta linear invariante no tempo. Fazemos um breve resumo dos resultados que obtivemos no capítulo anterior para o caso SISO com o Modelo de Identificação por Regressão Linear e a Adaptação de Segundo Nível baseada em múltiplos Modelos de Identificação por Regressão Linear. Após este resumo, detalhamos como são calculados os parâmetros do controlador a partir das estimativas dos parâmetros da planta. No final do capítulo, trazemos resultados de simulação para as estratégias de controle estudadas.

5.1 Descrição do Problema

Considere a planta linear invariante no tempo, de ordem n e grau relativo 1, descrita pela seguinte função de transferência:

$$\Sigma_{p,SISO} : G_p(s) = \frac{y(s)}{u(s)} = \frac{N_p(s)}{D_p(s)} = k_p \frac{Z_p(s)}{D_p(s)}$$

onde apenas a saída $y(t)$ e a entrada $u(t)$ estão disponíveis para medição.

As seguintes hipóteses são verdadeiras:

- **P1** $Z_p(s)$ é mônico, Hurwitz e de grau $n - 1$
- **P2** O grau n de $D_p(s)$ é conhecido.
- **P3** O sinal de $b_1 = k_p$ é conhecido.
- **P4** $N_p(s)$ e $D_p(s)$ são coprimos

e, portanto:

$$\begin{aligned} N_p(s) &= b_1 s^{n-1} + b_2 s^{n-2} + \dots + b_{n-1} s + b_n \\ D_p(s) &= s^n + a_1 s^{n-1} + a_2 s^{n-2} + \dots + a_{n-1} s + a_n \\ k_p &= b_1 \\ Z_p(s) &= s^{n-1} + \frac{b_2}{b_1} s^{n-2} + \dots + \frac{b_{n-1}}{b_1} s + \frac{b_n}{b_1} \end{aligned} \tag{5.1}$$

onde os limitantes superiores $b_1^+, \dots, b_n^+, a_1^+, \dots, a_n^+$ e inferiores $b_1^-, \dots, b_n^-, a_1^-, \dots, a_n^-$ dos parâmetros $b_1, \dots, b_n, a_1, \dots, a_n$ são conhecidos.

Nosso objetivo é o de projetar um controlador que produza um sinal de controle $u(t)$, para atuar sobre a entrada da planta, que faça com que a saída da planta rastreie a saída de um Modelo de Referência:

$$\Sigma_m : W_m(s) = \frac{y_m(s)}{r(s)} = k_m \frac{Z_m(s)}{D_m(s)}$$

escolhido pelo projetista e que cumpre as seguintes condições:

- **M1** $Z_m(s)$ e $D_m(s)$ são Hurwitz e coprimos
- **M2** O grau de $D_m(s)$ é n
- **M3** O grau relativo de $W_m(s)$ é 1.

Assim, os polinômios $Z_m(s)$ e $D_m(s)$ são da seguinte forma:

$$\begin{aligned} Z_m(s) &= s^{n-1} + b_{m,2}s^{n-2} + \dots + b_{m,n-1}s + b_{m,n} \\ D_m(s) &= s^n + a_{m,1}s^{n-1} + a_{m,2}s^{n-2} + \dots + a_{m,n-1}s + a_{m,n} \end{aligned} \quad (5.2)$$

Ao alimentar o modelo de referência com um sinal de referência $r(t)$ escolhido pelo projetista, uma trajetória para a saída da planta é especificada. A lei de controle deve ser escolhida tal que os polos e zeros da função de transferência em malha fechada de r para y sejam estáveis e iguais aos de $W_m(s)$. Se a função de transferência em malha fechada se torna equivalente a $W_m(s)$ então qualquer que seja o sinal de referência $r(t)$ a saída $y(t)$ da planta tenderá exponencialmente para a saída $y_m(t)$ do modelo.

5.2 Planta com parâmetros conhecidos

Consideremos que os coeficientes dos polinômios $N_p(s)$ e $D_p(s)$ são conhecidos.

Uma escolha óbvia para realizar o objetivo de controle da planta seria uma lei de controle em malha aberta. No entanto, note-se que não assumimos nada em relação à localização dos polos da planta. $D_p(s)$ pode inclusive conter polos no semi plano direito aberto do plano complexo. Uma lei de controle em malha aberta para uma planta instável implicaria em cancelamentos de polos e zeros no semi plano direito aberto do plano complexo, levando à instabilidade do sistema. Desta forma, passamos a considerar a seguinte lei de controle por realimentação:

$$u = \theta_1^{*T} \frac{\Psi(s)}{\Lambda_w(s)} u + \theta_2^{*T} \frac{\Psi(s)}{\Lambda_w(s)} y + \theta_3^* y + c_0^* r = \theta^{*T} w \quad (5.3)$$

onde:

$$\begin{aligned} w &\triangleq \left[\frac{\psi^T(s)}{\Lambda_w(s)} u \quad \frac{\psi^T(s)}{\Lambda_w(s)} y \quad y \quad r \right]^T \\ \psi(s) &\triangleq [s^{n-2} \quad s^{n-3} \quad \dots \quad s \quad 1]^T \\ \theta^* &\triangleq [\theta_1^{*T} \quad \theta_2^{*T} \quad \theta_3^* \quad c_0^*]^T \end{aligned} \quad (5.4)$$

Como a planta e o modelo de referência são de mesmo grau e grau relativo escolhemos $\Lambda_w(s) = Z_m(s)$. O vetor regressor de controle w pode ser gerado por:

$$\begin{aligned} \dot{w}_1 &= F w_1 + g u \\ \dot{w}_2 &= F w_2 + g y \\ w &\triangleq [w_1 \quad w_2 \quad y \quad r]^T \end{aligned} \quad (5.5)$$

onde F e g são escolhidos de acordo com $Z_m(s)$. Os parâmetros do controlador $c_0^*, \theta_3^* \in R^1$ e $\theta_1^*, \theta_2^* \in R^{n-1}$ são constantes, calculados com base nas informações dos parâmetros do modelo de referência e da planta.

Queremos um vetor $\theta^* \in R^{2n}$ tal que a função de transferência em malha fechada de y para r seja equivalente a $W_m(s)$. De acordo com (Ioannou & Sun 1996) as propriedades de entrada e saída da planta em malha fechada para esta lei de controle são dadas por:

$$y = G_c(s)r \quad (5.6)$$

onde:

$$G_c(s) = \frac{c_0^* k_p Z_p Z_m^2}{Z_m [(Z_m - \theta_1^{*T} \psi) D_p(s) - k_p Z_p (\theta_2^{*T} \psi + \theta_3^* Z_m)]} \quad (5.7)$$

Gostaríamos de obter $G_c(s) = W_m(s)$:

$$\frac{c_0^* k_p Z_p Z_m^2}{Z_m [(Z_m - \theta_1^{*T} \psi) D_p(s) - k_p Z_p (\theta_2^{*T} \psi + \theta_3^* Z_m)]} = k_m \frac{Z_m}{D_m} \quad (5.8)$$

Então, escolhemos:

$$c_0^* = \frac{k_m}{k_p} \quad (5.9)$$

e, a partir de 5.8, obtemos:

$$(Z_m - \theta_1^{*T} \psi) D_p(s) - k_p Z_p (\theta_2^{*T} \psi + \theta_3^* Z_m) = Z_p D_m \quad (5.10)$$

resta encontrar θ_1^*, θ_2^* e θ_3^* que satisfaçam a equação 5.10.

Uma solução para θ_1^*, θ_2^* e θ_3^* pode ser encontrada por inspeção, de forma que temos:

$$\begin{aligned}\theta_1^{*T} \Psi &= Z_m(s) - Z_p(s) \\ \theta_2^{*T} \Psi + \theta_3^* Z_m(s) &= \frac{D_p(s) - D_m(s)}{k_p}\end{aligned}\quad (5.11)$$

e como a planta é de grau relativo unitário, 5.11 resulta nas seguintes expressões para os parâmetros θ_1^*, θ_2^* e θ_3^* do controlador em função dos parâmetros da planta:

$$\begin{aligned}\theta_1^* &= \left[b_{m,2} - \frac{b_2}{b_1} \quad b_{m,3} - \frac{b_3}{b_1} \quad \dots \quad b_{m,n} - \frac{b_n}{b_1} \right]^T \\ \theta_2^* &= \left[\frac{a_2 - a_{m,2} - (a_1 - a_{m,1})b_{m,2}}{k_p} \quad \frac{a_3 - a_{m,3} - (a_1 - a_{m,1})b_{m,3}}{k_p} \quad \dots \quad \frac{a_n - a_{m,n} - (a_1 - a_{m,1})b_{m,n}}{k_p} \right]^T \\ \theta_3^* &= \frac{a_1 - a_{m,1}}{k_p}\end{aligned}\quad (5.12)$$

Definimos os seguintes vetores, para facilitar a notação de 5.12:

$$\begin{aligned}\vec{a}_p &\triangleq [a_2 \quad a_3 \quad \dots \quad a_n]^T \\ \vec{a}_m &\triangleq [a_{m,2} \quad a_{m,3} \quad \dots \quad a_{m,n}]^T \\ \vec{b}_p &\triangleq \left[\frac{b_2}{b_1} \quad \frac{b_3}{b_1} \quad \dots \quad \frac{b_n}{b_1} \right]^T \\ \vec{b}_m &\triangleq [b_{m,2} \quad b_{m,3} \quad \dots \quad b_{m,n}]^T\end{aligned}\quad (5.13)$$

de forma que, a partir de 5.12 e 5.9 temos as seguintes expressões para os parâmetros do controlador:

$$\begin{aligned}c_0^* &= \frac{k_m}{k_p} \\ \theta_1^* &= \vec{b}_m - \vec{b}_p \\ \theta_2^* &= \frac{\vec{a}_p - \vec{a}_m - (a_1 - a_{m,1})\vec{b}_m}{k_p} \\ \theta_3^* &= \frac{a_1 - a_{m,1}}{k_p}\end{aligned}\quad (5.14)$$

Chamamos as equações 5.14 de equações de matching da planta de ordem n e grau relativo unitário. A partir das equações de matching temos os parâmetros do controlador em função dos parâmetros da planta que garantem que a função de transferência entre a referência e a saída da planta é equivalente à do modelo de referência, para a lei de controle por realimentação 5.3. É importante ressaltar que só foi possível obter uma relação linear entre os parâmetros do controlador e os da planta pois estamos tratando de uma planta de grau relativo unitário.

5.3 Controle Adaptativo por Modelo de Referência Indireto

Na seção anterior obtivemos equações para calcular os parâmetros do controlador em função dos parâmetros da planta.

Definimos os vetores:

$$\begin{aligned}\hat{\vec{a}}_p &\triangleq [\hat{a}_2 \quad \hat{a}_3 \quad \dots \quad \hat{a}_n]^T \\ \hat{\vec{b}}_p &\triangleq \begin{bmatrix} \hat{b}_2 & \hat{b}_3 & \dots & \hat{b}_n \\ \hat{b}_1 & \hat{b}_1 & \dots & \hat{b}_1 \end{bmatrix}^T\end{aligned}\quad (5.15)$$

Podemos extrair estes vetores do vetor de estimativas dos parâmetros da planta, $\hat{\theta}_p$:

$$\hat{\theta}_p = \begin{bmatrix} \hat{a}_1 & \hat{\vec{a}}_p^T & \hat{k}_p & \hat{\vec{b}}_p^T \end{bmatrix}^T \quad (5.16)$$

onde a estimativa $\hat{\theta}_p$ é obtida a partir de algum dos métodos de estimação estudados no capítulo 4, para a planta de ordem n . Podemos utilizar o método do gradiente normalizado a partir de um modelo de identificação por regressão linear ou a adaptação de segundo nível, com ou sem fator de esquecimento, a partir de um conjunto de $N \geq 2n + 1$ modelos de identificação por regressão linear.

Para aplicar os métodos de estimação de parâmetros que viemos estudando, vamos utilizar as equações 5.14, substituindo os parâmetros verdadeiros da planta por suas estimativas:

$$\begin{aligned}c_0 &= \frac{k_m}{\hat{k}_p} \\ \theta_1 &= \vec{b}_m - \hat{\vec{b}}_p \\ \theta_2 &= \frac{\hat{\vec{a}}_p - \vec{a}_m - (\hat{a}_1 - a_{m,1})\vec{b}_m}{\hat{k}_p} \\ \theta_3 &= \frac{\hat{a}_1 - a_{m,1}}{\hat{k}_p}\end{aligned}\quad (5.17)$$

Para limitar os parâmetros calculados, temos que a estimativa $\hat{k}_p = \hat{b}_1$ deve ser restringida de atingir um valor nulo por projeção. Temos, então, a seguinte lei de controle:

$$u = \theta_1^T \frac{\Psi(s)}{\Lambda_w(s)} u + \theta_2^T \frac{\Psi(s)}{\Lambda_w(s)} y + \theta_3 y + c_0 r = \theta^T w \quad (5.18)$$

Postulamos que, para estes métodos de estimação em conjunto com o cálculo dos parâmetros do controlador, o sinal de controle produzido por este controlador se aproxima do sinal de controle do controlador que seria projetado caso os parâmetros da planta fossem conhecidos, e, além disso, é uniformemente limitado e contínuo por partes. Postulamos também que o sistema resultante é estável, que todos os sinais em malha fechada são uni-

formemente limitados e que a saída da planta rastreia a saída do modelo de referência.

Como veremos no final deste capítulo, nossos resultados de simulação confirmam estes postulados para um caso particular. No entanto, é necessário investigar as condições suficientes para que isto ocorra em todos os casos. Portanto, uma prova analítica de estabilidade para o controlador adaptativo por modelo de referência indireto com adaptação de segundo nível para a planta de ordem n e grau relativo unitário se faz necessária. Deixamos esta prova como uma perspectiva a ser considerada para trabalhos futuros.

5.4 Controle Adaptativo por Modelo de Referência e Estrutura Variável

Consideremos a seguinte realização mínima em espaço de estado da planta:

$$\begin{aligned}\dot{x}_p &= A_p x_p + b_p u \\ y_p &= h_p^T x_p\end{aligned}\tag{5.19}$$

onde $x_p \in R^n$ é chamado vetor de estado da planta, $A_p \in R^{n \times n}$, $b_p \in R^n$, $h_p \in R^n$.

Definimos o seguinte vetor:

$$X \triangleq [x_p^T \quad w_1^T \quad w_2^T]^T\tag{5.20}$$

onde chamamos $X \in R^{3n-2}$ de vetor de estado aumentado da planta.

Definimos a matriz:

$$A_0 \triangleq \begin{bmatrix} A_p & 0 & 0 \\ 0 & F & 0 \\ g h_p^T & 0 & F \end{bmatrix}\tag{5.21}$$

Definimos o vetor:

$$b_0 \triangleq [b_p \quad g \quad 0]^T\tag{5.22}$$

Definimos, também, o vetor:

$$h_c \triangleq [h_p^T \quad 0 \quad 0]^T\tag{5.23}$$

A partir das definições 5.20, 5.21, 5.22, 5.23, e das equações 5.19 e 5.5, a dinâmica da planta em função do vetor de estado aumentado é da forma:

$$\begin{aligned}\dot{X} &= A_0 X + b_0 u \\ y_p &= h_c^T X\end{aligned}\tag{5.24}$$

Consideremos agora a lei de controle 5.3, inserindo a expressão para u em 5.24 e

substituindo y por $h_c^T X$, temos:

$$\dot{X} = A_0 + b_0(\theta_1^{*T} w_1 + \theta_2^{*T} w_2 + \theta_3^* h_c^T X + c_0^* r) \quad (5.25)$$

que reorganizado fica da seguinte forma:

$$\dot{X} = (A_0 + b_0 [\theta_3^* h_c^T \quad \theta_1^{*T} \quad \theta_2^{*T}])X + b_0 c_0^* r \quad (5.26)$$

Obtivemos os parâmetros da lei de controle 5.3 como os parâmetros do controlador que resultam na função de transferência em malha fechada da planta em conjunto com o controlador equivalente a função de transferência em malha aberta do modelo de referência.

Consideremos, então, uma realização mínima do modelo de referência em espaço de estado:

$$\begin{aligned} \dot{x}_m &= A_m x_m + b_m r \\ y_m &= h_p^T x_m \end{aligned} \quad (5.27)$$

Definimos o vetor de estado aumentado para o modelo de referência:

$$X_m \triangleq [x_m^T \quad w_1^T \quad w_2^T]^T \quad (5.28)$$

A lei de controle 5.3 faz com que x_p tenda para x_m exponencialmente, que faz com que X tenda para X_m exponencialmente. Desta forma, a dinâmica do vetor de estado aumentado da planta é idêntica à dinâmica do vetor de estado aumentado do modelo de referência.

Definimos a matriz:

$$A_c \triangleq A_0 + b_0 [\theta_3^* h_c^T \quad \theta_1^{*T} \quad \theta_2^{*T}] \quad (5.29)$$

Definimos o vetor:

$$b_c \triangleq b_0 c_0^* \quad (5.30)$$

Feitas estas definições, a dinâmica do modelo de referência em função de seu vetor de estado aumentado é:

$$\begin{aligned} \dot{X}_m &= A_c X_m + b_c r \\ y_m &= h_c^T X_m \end{aligned} \quad (5.31)$$

Definimos o seguinte erro aumentado:

$$e \triangleq X - X_m \quad (5.32)$$

Definimos os erros paramétricos para os parâmetros do controlador:

$$\begin{aligned}\tilde{c}_0 &\triangleq c_0 - c_0^* \\ \tilde{\theta}_1 &\triangleq \theta_1 - \theta_1^* \\ \tilde{\theta}_2 &\triangleq \theta_2 - \theta_2^* \\ \tilde{\theta}_3 &\triangleq \theta_3 - \theta_3^* \\ \tilde{\theta} &\triangleq \theta - \theta^* = [\tilde{\theta}_1^T \quad \tilde{\theta}_2^T \quad \tilde{\theta}_3 \quad \tilde{c}_0]^T\end{aligned}\tag{5.33}$$

A dinâmica do erro aumentado para a lei de controle 5.18 é:

$$\dot{e} = \dot{X} - \dot{X}_m = A_c e + b_c \frac{1}{c_0^*} \tilde{\theta} w\tag{5.34}$$

Consideremos a seguinte candidata a função de Lyapunov:

$$V(e) = \frac{e^T P e}{2}\tag{5.35}$$

Derivando ao longo das trajetórias de V obtemos:

$$\dot{V} = \frac{1}{2} (e^T P (A_c e + b_c \frac{1}{c_0^*} \tilde{\theta} w) + (A_c e + b_c \frac{1}{c_0^*} \tilde{\theta} w)^T P e)\tag{5.36}$$

e como o par (A_c, b_c) é controlável, A_c é assintoticamente estável e a planta e modelo são de grau relativo unitário, podemos utilizar o lema de Kalman-Yakubovitch-Lefschetz, tal que 5.36 fica da forma:

$$\dot{V} = -e^T Q e + e^T P b_c \frac{1}{c_0^*} \tilde{\theta} w\tag{5.37}$$

onde $Q = Q^T > 0$ é uma matriz definida positiva, e A_c cumpre $A_c^T P + P A_c = -2Q$. Temos ainda que $P b_c = h_c^T$.

Definimos o erro de saída entre a saída da planta e a saída do modelo de referência:

$$e_o \triangleq y - y_m = h_c^T e\tag{5.38}$$

o chamado erro de saída da planta.

Finalmente, a partir de 5.37 e 5.38 e fazendo uso de $P b_c = h_c^T$, a expressão para $\dot{V}$ fica da seguinte forma:

$$\dot{V} = -e^T Q e + e_o \frac{1}{c_0^*} \tilde{\theta} w\tag{5.39}$$

Como no caso da planta de ordem 1, podemos encontrar limitantes superiores para o valor absoluto dos elementos dos vetores θ_1^* e θ_2^* e para os parâmetros θ_3^* e c_0^* . A partir de 5.14 e do conhecimento dos limitantes superiores $b_1^+, \dots, b_n^+, a_1^+, a_n^+$ e inferiores $b_1^-, \dots, b_n^-, a_1^-, \dots, a_n^-$ para os parâmetros da planta, os escalares θ_3^* e c_0^* obedecem às

seguintes inequações:

$$\begin{aligned} |\theta_3^*| &\leq \frac{\max(|a_1^+ - a_{m,1}|, |a_1^- - a_{m,1}|)}{\min(|k_p^+|, |k_p^-|)} \\ |c_0^*| &\leq \frac{k_m}{\min(|k_p^+|, |k_p^-|)} \end{aligned} \quad (5.40)$$

Explicitamos os componentes dos vetores θ_1^* e θ_2^* :

$$\begin{aligned} \theta_1^* &= [\theta_{1,1}^* \quad \theta_{1,2}^* \quad \dots \quad \theta_{1,n-1}^*] \\ \theta_2^* &= [\theta_{2,1}^* \quad \theta_{2,2}^* \quad \dots \quad \theta_{2,n-1}^*] \end{aligned} \quad (5.41)$$

Os elementos de θ_1^* obedecem a:

$$|\theta_{1,i}^*| \leq \max(|p_{b,1,i}|, |p_{b,2,i}|) \quad (5.42)$$

onde:

$$\begin{aligned} p_{b,1,i} &= b_{m,i} - \frac{\min(b_i^+, b_i^-)}{\max(|b_1^+|, |b_1^-|)} \\ p_{b,2,i} &= b_{m,i} - \frac{\max(b_i^+, b_i^-)}{\min(|b_1^+|, |b_1^-|)} \end{aligned} \quad (5.43)$$

com $i = 2, \dots, n$.

Os elementos de θ_2^* obedecem a:

$$|\theta_{2,i}^*| \leq \max(|p_{a,1,i}|, |p_{a,2,i}|, |p_{a,3,i}|, |p_{a,4,i}|) \quad (5.44)$$

onde:

$$\begin{aligned} p_{a,1,i} &= \frac{a_i^+ - a_{m,i} - (a_1^- - a_{m,1})b_{m,i}}{\min(|k_p^+|, |k_p^-|)} \\ p_{a,2,i} &= \frac{a_i^- - a_{m,i} - (a_1^+ - a_{m,1})b_{m,i}}{\min(|k_p^+|, |k_p^-|)} \\ p_{a,3,i} &= \frac{a_i^+ - a_{m,i} - (a_1^+ - a_{m,1})b_{m,i}}{\min(|k_p^+|, |k_p^-|)} \\ p_{a,4,i} &= \frac{a_i^- - a_{m,i} - (a_1^- - a_{m,1})b_{m,i}}{\min(|k_p^+|, |k_p^-|)} \end{aligned} \quad (5.45)$$

com $i = 2, \dots, n$.

Definimos, então, os parâmetros:

$$\begin{aligned}\bar{\theta}_{1,i} &\triangleq \max(|p_{b,1,i}|, |p_{b,2,i}|) \\ \bar{\theta}_{2,i} &\triangleq \max(|p_{a,1,i}|, |p_{a,2,i}|, |p_{a,3,i}|, |p_{a,4,i}|) \\ \bar{\theta}_3 &\triangleq \frac{\max(|a_1^+ - a_{m,1}|, |a_1^- - a_{m,1}|)}{\min(|k_p^+|, |k_p^-|)} \\ \bar{c}_0 &\triangleq \frac{k_m}{\min(|k_p^+|, |k_p^-|)}\end{aligned}\tag{5.46}$$

e devido a 5.40, 5.42, 5.44, a escolha de parâmetros 5.46 garante que:

$$\begin{aligned}\bar{\theta}_{1,i} &\geq |\theta_{1,i}^*| \\ \bar{\theta}_{2,i} &\geq |\theta_{2,i}^*| \\ \bar{\theta}_3 &\geq |\theta_3^*| \\ \bar{c}_0 &\geq |c_0^*|\end{aligned}\tag{5.47}$$

A partir da equação 5.39, expandimos o termo $\tilde{\theta}w$ usando 5.33 e 5.5, tal que:

$$\dot{V} = -e^T Q e + e_o \frac{1}{c_0^*} (\tilde{\theta}_1 w_1 + \tilde{\theta}_2 w_2 + \tilde{\theta}_3 y + \tilde{c}_0 r)\tag{5.48}$$

Explicitamos os componentes de w_1 e w_2 :

$$\begin{aligned}w_1 &= [w_{1,1} \quad w_{1,2} \quad \dots \quad w_{1,n-1}] \\ w_2 &= [w_{2,1} \quad w_{2,2} \quad \dots \quad w_{2,n-1}]\end{aligned}\tag{5.49}$$

de forma que, a cada instante, podemos escolher os parâmetros do controlador de acordo com as seguintes leis chaveadas:

$$\begin{aligned}\theta_{1,i} &= -\bar{\theta}_{1,i} \text{sign}(c_0^* e_o w_{1,i}) \\ \theta_{2,i} &= -\bar{\theta}_{2,i} \text{sign}(c_0^* e_o w_{2,i}) \\ \theta_3 &= -\bar{\theta}_3 \text{sign}(c_0^* e_o y) \\ c_0 &= -\bar{c}_0 \text{sign}(c_0^* e_o r)\end{aligned}\tag{5.50}$$

com $i = 1, \dots, n-1$.

Ao fazermos esta escolha de leis chaveadas, garantimos que $\text{sign}(\frac{1}{c_0^*} \tilde{\theta}w) = -\text{sign}(e_o)$ e o termo $e_o \frac{1}{c_0^*} \tilde{\theta}w$ em 5.39 passa a ter sinal definido negativo, fazendo com que $\dot{V}$ passe a ser definida negativa. Isto implica em e uniformemente limitado e pertencente ao $\mathcal{L}_2$, que consequentemente implica em e_o uniformemente limitado e pertencente ao $\mathcal{L}_2$. e_o uniformemente limitado implica em y uniformemente limitado. A partir de 5.34 concluímos que $\dot{e}$ é uniformemente limitado, o que implica em $\dot{e}_o$ uniformemente limitado. Finalmente, devido a um corolário do lema de Barbalat, e_o deve tender a 0 pelo menos assintoticamente.

5.5 Resultados

Neste capítulo apresentamos a lei de controle usada para que a planta rastreie a saída de um modelo de referência. É gerado um vetor regressor de controle w a partir de filtros da entrada e saída da planta. Uma combinação linear dos componentes deste regressor com os parâmetros do controlador gera o sinal de controle a ser introduzido na planta.

Os parâmetros do controlador são calculados a partir dos parâmetros estimados da planta por um mapeamento baseado nas equações de matching 5.14, como se os parâmetros da planta fossem conhecidos. Excetua-se o caso do controle com estrutura variável, onde utilizamos a estratégia direta, já que o controle com estrutura variável não é tema central deste trabalho, e a implementação é mais simples na estratégia direta.

5.5.1 Resumo dos Algoritmos

Caso o leitor deseje consultar rapidamente, listamos os algoritmos usados neste capítulo para o controle adaptativo por modelo de referência indireto de uma planta de grau n e grau relativo 1 e modelo de referência de grau n e grau relativo 1, nas Tabelas 5.1, 5.2 e 5.3, a seguir:

Tabela 5.1: Algoritmos de Controle por Modelo de Referência, Caso Ideal com Planta Conhecida e Controle Adaptativo baseado em Modelo de Identificação por Regressão Linear

Caso Ideal, Planta Conhecida	Regressão Linear
$\Sigma_p : \dot{x}_p = A_p x_p + b_p u$	$\Sigma_p : \dot{x}_p = A_p x_p + b_p u$
$y_p = h_p^T x_p$	$y_p = h_p^T x_p$
$\dot{x}_m = A_m x_m + b_m r$	$z = \frac{s^n y}{\Lambda(s)}$
$y_m = h_m^T x_m$	$\dot{\phi}_1 = \Lambda_c \phi_1 - l y_p$
$c_0 = \frac{k_m}{k_p}$	$\dot{\phi}_2 = \Lambda_c \phi_2 + l u$
$\theta_1 = \vec{b}_m - \vec{b}_p$	$\phi^T = [\phi_1 \quad \phi_2]$
$\theta_2 = \frac{\vec{a}_p - \vec{a}_m - (a_1 - a_{m,1})\vec{b}_m}{k_p}$	$\Sigma_{1,f} : \hat{z}_{1,f} = \hat{\theta}_{1,f} \phi$
$\theta_3 = \frac{a_1 - a_{m,1}}{k_p}$	$e_{1,f} = \hat{z}_{1,f} - z$
$\theta = [\theta_1 \quad \theta_2 \quad \theta_3 \quad c_0]^T$	$n_s^2 = \phi^T \phi$
$\dot{w}_1 = F w_1 + g u$	$m^2 = 1 + n_s^2$
$\dot{w}_2 = F w_2 + g y$	$\varepsilon_{1,f} = \frac{e_{1,f}}{m^2}$
$w = [w_1 \quad w_2 \quad y \quad r]^T$	$\Gamma = \Gamma^T > 0$
$u = \theta^{*T} w$	$\hat{\theta}_{1,f} = -\Gamma \varepsilon_{1,f} \phi$
	$\begin{bmatrix} \hat{a}_1 & \hat{a}_p^T & \hat{k}_p & \hat{b}_p^T \end{bmatrix}^T = \hat{\theta}_{1,f}$
	$c_0 = \frac{k_m}{\hat{k}_p}$
	$\theta_1 = \vec{b}_m - \hat{b}_p$
	$\theta_2 = \frac{\hat{a}_p - \vec{a}_m - (\hat{a}_1 - a_{m,1})\vec{b}_m}{\hat{k}_p}$
	$\theta_3 = \frac{\hat{a}_1 - a_{m,1}}{\hat{k}_p}$
	$\theta = [\theta_1 \quad \theta_2 \quad \theta_3 \quad c_0]^T$
	$\dot{w}_1 = F w_1 + g u$
	$\dot{w}_2 = F w_2 + g y$
	$w = [w_1 \quad w_2 \quad y \quad r]^T$
	$u = \theta^T w$

Tabela 5.2: Algoritmos de Controle Adaptativo por Modelo de Referência Indireto baseados em Adaptação de Segundo Nível a partir de Modelos de Identificação por Regressão Linear

Segundo Nível Regressão Linear	Segundo Nível Regressão Linear Modificado
$\Sigma_p : \dot{x}_p = A_p x_p + b_p u$ $y_p = h_p^T x_p$ $z = \frac{s^n y}{\Lambda(s)}$ $\dot{\phi}_1 = \Lambda_c \phi_1 - l y_p$ $\dot{\phi}_2 = \Lambda_c \phi_2 + l u$ $\phi^T = [\phi_1 \quad \phi_2]$ $\Sigma_{i,f} : \hat{z}_{i,f} = \hat{\theta}_{i,f} \phi$ $e_{i,f} = \hat{z}_{i,f} - z$ $n_s^2 = \phi^T \phi$ $m^2 = 1 + n_s^2$ $\epsilon_{i,f} = \frac{e_{i,f}}{m^2}$ $\Gamma = \Gamma^T > 0$ $\dot{\hat{\theta}}_{i,f} = -\Gamma \epsilon_{i,f} \phi$ $E_f = [\epsilon_{1,f} - \epsilon_{N,f} \quad \dots \quad \epsilon_{N-1,f} - \epsilon_{N,f}]$ $\dot{\alpha}_f = -E_f^T E_f \alpha_f - E_f^T \epsilon_{N,f}$ $\bar{\Theta}_f = [\hat{\theta}_{1,f} \quad \dots \quad \hat{\theta}_{N,f}]$ $\bar{\alpha}_f^T = [\alpha_f^T \quad 1 - \vec{1} \alpha_f]$ $\hat{\theta}_{n2,f} = \text{proj}_{S_{\theta,f}}(\bar{\Theta}_f \bar{\alpha}_f)$ $\begin{bmatrix} \hat{a}_1 & \hat{a}_p^T & \hat{k}_p & \hat{b}_p^T \end{bmatrix}^T = \hat{\theta}_{n2,f}$ $c_0 = \frac{k_m}{\hat{k}_p}$ $\theta_1 = \vec{b}_m - \hat{b}_p$ $\theta_2 = \frac{\hat{a}_p - \vec{a}_m - (\hat{a}_1 - a_{m,1}) \vec{b}_m}{\hat{k}_p}$ $\theta_3 = \frac{\hat{a}_1 - a_{m,1}}{\hat{k}_p}$ $\theta = [\theta_1 \quad \theta_2 \quad \theta_3 \quad c_0]^T$ $\dot{w}_1 = F w_1 + g u$ $\dot{w}_2 = F w_2 + g y$ $w = [w_1 \quad w_2 \quad y \quad r]^T$ $u = \theta^T w$	$\Sigma_p : \dot{x}_p = A_p x_p + b_p u$ $y_p = h_p^T x_p$ $z = \frac{s^n y}{\Lambda(s)}$ $\dot{\phi}_1 = \Lambda_c \phi_1 - l y_p$ $\dot{\phi}_2 = \Lambda_c \phi_2 + l u$ $\phi^T = [\phi_1 \quad \phi_2]$ $\Sigma_{i,f} : \hat{z}_{i,f} = \hat{\theta}_{i,f} \phi$ $e_{i,f} = \hat{z}_{i,f} - z$ $n_s^2 = \phi^T \phi$ $m^2 = 1 + n_s^2$ $\epsilon_{i,f} = \frac{e_{i,f}}{m^2}$ $\Gamma = \Gamma^T > 0$ $\dot{\hat{\theta}}_{i,f} = -\Gamma \epsilon_{i,f} \phi$ $E_f = [\epsilon_{1,f} - \epsilon_{N,f} \quad \dots \quad \epsilon_{N-1,f} - \epsilon_{N,f}]$ $M_f(0) = \mathbf{0}$ $v_f(0) = \mathbf{0}$ $\dot{M}_f = -\sigma M_f + E_f^T E_f$ $\dot{v}_f = -\sigma v_f + E_f^T \epsilon_{N,f}$ $\dot{\alpha}_f = -(E_f^T E_f + M_f) \alpha_f - E_f^T \epsilon_{N,f} - v_f$ $\bar{\Theta}_f = [\hat{\theta}_{1,f} \quad \dots \quad \hat{\theta}_{N,f}]$ $\bar{\alpha}_f^T = [\alpha_f^T \quad 1 - \vec{1} \alpha_f]$ $\hat{\theta}_{n2,f} = \text{proj}_{S_{\theta,f}}(\bar{\Theta}_f \bar{\alpha}_f)$ $\begin{bmatrix} \hat{a}_1 & \hat{a}_p^T & \hat{k}_p & \hat{b}_p^T \end{bmatrix}^T = \hat{\theta}_{n2,f}$ $c_0 = \frac{k_m}{\hat{k}_p}$ $\theta_1 = \vec{b}_m - \hat{b}_p$ $\theta_2 = \frac{\hat{a}_p - \vec{a}_m - (\hat{a}_1 - a_{m,1}) \vec{b}_m}{\hat{k}_p}$ $\theta_3 = \frac{\hat{a}_1 - a_{m,1}}{\hat{k}_p}$ $\theta = [\theta_1 \quad \theta_2 \quad \theta_3 \quad c_0]^T$ $\dot{w}_1 = F w_1 + g u$ $\dot{w}_2 = F w_2 + g y$ $w = [w_1 \quad w_2 \quad y \quad r]^T$ $u = \theta^T w$

Tabela 5.3: Algoritmos de Controle Adaptativo por Modelo de Referência com Estrutura Variável

Variável	Controle Adaptativo por Modelo de Referência com Estrutura Variável
	$\Sigma_p : \dot{x}_p = A_p x_p + b_p u$
	$y_p = h_p^T x_p$
	$\dot{x}_m = A_m x_m + b_m r$
	$y_m = h_m^T x_m$
	$e_o = y - y_m$
	$\dot{w}_1 = F w_1 + g u$
	$\dot{w}_2 = F w_2 + g y$
	$w = [w_1 \ w_2 \ y \ r]^T$
	$\bar{\theta}_{1,i} \geq \theta_{1,i}^* $
	$\bar{\theta}_{2,i} \geq \theta_{2,i}^* $
	$\bar{\theta}_3 \geq \theta_3^* $
	$\bar{c}_0 \geq c_0^* $
	$\theta_{1,i} = -\bar{\theta}_{1,i} \text{sign}(c_0^* e_o w_{1,i})$
	$\theta_{2,i} = -\bar{\theta}_{2,i} \text{sign}(c_0^* e_o w_{2,i})$
	$\theta_3 = -\bar{\theta}_3 \text{sign}(c_0^* e_o y)$
	$c_0 = -\bar{c}_0 \text{sign}(c_0^* e_o r)$
	$\theta = [\theta_1 \ \theta_2 \ \theta_3 \ c_0]^T$
	$u = \theta^T w$

5.5.2 Estudos de Simulação

Considere a planta a seguir:

$$G_p(s) = \frac{N_p(s)}{D_p(s)} = \frac{b_1 s + b_2}{s^2 + a_1 s + a_2} = \frac{2s + 1}{s^2 - 3s - 4}$$

desejamos estimar os coeficientes dos polinômios do numerador e denominador da função de transferência da planta $N_p(s)$ e $D_p(s)$.

A região de incerteza para estes parâmetros é considerada conhecida:

$$a_1 \in [-8 \ -3]$$

$$a_2 \in [-6 \ -1.5]$$

$$b_1 \in [1 \ 7]$$

$$b_2 \in [0.5 \ 1.5]$$

Faremos uso do Modelo de Identificação por Regressão Linear e da Adaptação de

Segundo Nível usando o número mínimo de modelos $N = 5$ com e sem Fator de Esquecimento.

Para inicializar as simulações, usamos os seguintes valores:

$$\begin{aligned}\Lambda(s) &= s^2 + 7s + 12 \\ \Lambda_c &= \begin{bmatrix} -6 & -9 \\ 1 & 0 \end{bmatrix} \\ l &= \begin{bmatrix} 1 \\ 0 \end{bmatrix} \\ \Gamma &= \begin{bmatrix} 100 & 0 & 0 & 0 \\ 0 & 100 & 0 & 0 \\ 0 & 0 & 100 & 0 \\ 0 & 0 & 0 & 100 \end{bmatrix} \\ x_p(0) &= \begin{bmatrix} 0.2 \\ 0.4 \end{bmatrix} \\ \phi_1(0) &= \phi_2(0) = 0 \\ r(t) &= 1 + \sin(t) + \sin(1.7t) + \sin(3t) \\ \alpha_{1,f}(0) &= 1 \\ \alpha_i(0) &= 0, \quad i \neq 1 \\ \gamma_{n2,f} &= 10 \\ \gamma'_{n2,f} &= 3 \\ \sigma &= 6\end{aligned}$$

onde usamos o valor $\gamma'_{n2,f} = 3$ na simulação para a Adaptação de Segundo Nível Sem fator de esquecimento e $\gamma_{n2,f} = 10$ para Adaptação de Segundo Nível com Fator de Esquecimento.

Escolhemos as estimativas iniciais para o vetor θ_p :

$$\begin{aligned}\hat{\theta}_{1,f}^T(0) &= [-8 \quad -6 \quad 1 \quad 0.5] \\ \hat{\theta}_{2,f}^T(0) &= [29.5 \quad -6 \quad 1 \quad 0.5] \\ \hat{\theta}_{3,f}^T(0) &= [-8 \quad 16.5 \quad 1 \quad 0.5] \\ \hat{\theta}_{4,f}^T(0) &= [-8 \quad -6 \quad 31 \quad 0.5] \\ \hat{\theta}_{5,f}^T(0) &= [-8 \quad -6 \quad 1 \quad 5.5]\end{aligned}$$

Consideremos, agora, o seguinte modelo de referência:

$$W_m(s) = \frac{N_m(s)}{D_m(s)} = 1 \frac{s+4}{s^2+4s+4}$$

onde desejamos que a saída da planta rastreie a saída y_m do modelo de referência.

Calculamos os parâmetros do controlador a partir das estimativas dos parâmetros da planta, a partir das equações 5.17. Geramos um vetor regressor de controle por filtragem do sinal de saída e do sinal de entrada da planta. Por fim, a partir do vetor de parâmetros do controlador e do regressor de controle geramos uma lei de controle, como a seguir:

$$\begin{aligned}
 \Lambda_w(s) &= s + 4 \\
 c_0 &= \frac{k_m}{\hat{k}_p} = \frac{1}{\hat{b}_1} \\
 \theta_1 &= 4 - \frac{\hat{b}_2}{\hat{b}_1} \\
 \theta_2 &= \frac{-4\hat{a}_1 + \hat{a}_2 + 12}{\hat{b}_1} \\
 \theta_3 &= \frac{\hat{a}_1 - 4}{\hat{b}_1} \\
 \theta &= [\theta_1 \quad \theta_2 \quad \theta_3 \quad c_0]^T \\
 \dot{w}_1 &= -4w_1 + u \\
 \dot{w}_2 &= -4w_2 + y \\
 w &= [w_1 \quad w_2 \quad y \quad r]^T \\
 u &= \theta^T w
 \end{aligned}$$

Nos resultados a seguir, omitimos os gráficos obtidos para os modelos com índice $i = 2, 3, 4, 5$ por entender que, por iniciarem em valores distintos das estimativas de segundo nível, não servem como base para comparação entre a adaptação de segundo nível e o modelo de identificação convencional. Nestas simulações usamos um passo de fixo de simulação de 10^{-3} segundos. Obtivemos os seguintes resultados, mostrados nos gráficos das Figuras 5.1 a 5.6:




Figura 5.1: Comportamento das estimativas do coeficiente a_1 do polinômio $D_p(s)$ para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.




Figura 5.2: Comportamento das estimativas do coeficiente a_2 do polinômio $D_p(s)$ para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.




Figura 5.3: Comportamento das estimativas do coeficiente b_1 do polinômio $N_p(s)$ para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.




Figura 5.4: Comportamento das estimativas do coeficiente b_2 do polinômio $N_p(s)$ para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.




Figura 5.5: Erro de saída da planta para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.




Figura 5.6: Sinal de Controle gerado pelo controlador com base nas estimativas do Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento.

Tanto o Modelo de Identificação por Regressão Linear quanto a Adaptação de Segundo Nível mantém o comportamento do sistema estável e, com os parâmetros do controlador calculados a partir de suas estimativas, fazem com que a saída da planta tenda para a saída do modelo de referência. Isto pode ser visualizado na Figura 5.5, com o erro de saída tendendo para 0 em todos os 3 casos.

As estimativas de Primeiro Nível inicializadas em $\hat{\theta}_{1,f}(0)$ se dirigem lentamente em direção aos valores corretos. As estimativas de Segundo Nível sem Fator de Esquecimento não atingem os valores corretos mas também estão se aproximando, mais rapidamente que o Modelo de Primeiro Nível. As estimativas de Segundo Nível com Fator de Esquecimento são as que mais se aproximam dos valores corretos. Podemos ver o comportamento das estimativas nas Figuras 5.1 a 5.4.

Vemos novamente que as estimativas de Primeiro Nível são mais lentas que ambos os conjuntos de estimativas de Segundo Nível na sua convergência para os valores corretos, como no capítulo anterior.

Apesar de não exibir convergência dos parâmetros para o tempo de simulação escolhido, a Adaptação de Segundo Nível sem Fator de Esquecimento exibe convergência do sinal de controle para o sinal de controle que seria gerado caso os parâmetros da planta fossem conhecidos, como pode ser visto na Figura 5.6.

Com a introdução de um fator de esquecimento na adaptação de segundo nível os parâmetros convergem para seus valores corretos, de forma rápida e suave, como no capítulo anterior. Utilizamos, inclusive, um valor de ganho mais alto para a adaptação de segundo nível com fator de esquecimento do que o que usamos para a adaptação de segundo nível sem fator de esquecimento.

O efeito das condições iniciais $x_p^T(0)$ afeta o erro de saída e produz um sobressinal no sinal de controle no início da simulação, no caso dos controladores adaptativos.

A seguir, fizemos uma simulação para o controlador adaptativo por modelo de referência e estrutura variável. Calculamos os parâmetros $\bar{\theta}_1 = 3.93, \bar{\theta}_2 = 42.5, \bar{\theta}_3 = 12$ e $\bar{\theta}_4 = 1$. Nesta simulação usamos um passo de fixo de simulação de 10^{-4} segundos. Mostramos os resultados nas Figuras 5.7 e 5.8:




Figura 5.7: Erro de saída da planta para o controle por modelo de referência e estrutura variável.




Figura 5.8: Sinal de Controle gerado pelo controlador por modelo de referência e estrutura variável.

Para o controle por estrutura variável, vemos na Figura 5.7 que, de fato, o erro de saída tende a uma vizinhança pequena de 0 quase que instantaneamente. Este desempenho é muito melhor que o exibido pelos controladores adaptados por leis integrais, ao compararmos as Figuras 5.7 e 5.5. Em contrapartida, o sinal de controle na Figura 5.8 exibe chattering e assume valores absolutos muito altos em relação ao sinal de controle do controlador para a planta com parâmetros conhecidos ou controladores adaptativos da Figura 5.6.

De fato, uma das motivações do controle em modo dual, como por exemplo em (Teixeira 2016), é o de combinar as boas características de transitório da planta para o controle com estrutura variável com o sinal de controle suave e de menor intensidade em regime permanente do controle adaptativo por leis integrais. Os trabalhos acerca do controle em modo dual têm utilizado leis adaptativas convencionais, similares à que utilizamos para o modelo de primeiro nível nesta dissertação.

Com isto em mente, questionamos se, em vez das leis adaptativas convencionais, seria possível utilizar a adaptação de segundo nível no controle em modo dual, de forma a melhorar o desempenho do mesmo em regime permanente, como perspectiva para trabalhos futuros.

A seguir, refizemos as simulações com uma referência $r(t) = 1$, que não é PE para este sistema:




Figura 5.9: Comportamento das estimativas do coeficiente a_1 do polinômio $D_p(s)$ para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento com referência degrau.




Figura 5.10: Comportamento das estimativas do coeficiente a_2 do polinômio $D_p(s)$ para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento com referência degrau.




Figura 5.11: Comportamento das estimativas do coeficiente b_1 do polinômio $N_p(s)$ para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento com referência degrau.




Figura 5.12: Comportamento das estimativas do coeficiente b_2 do polinômio $N_p(s)$ para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento com referência degrau.




Figura 5.13: Erro de saída da planta para o Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento com referência degrau.




Figura 5.14: Sinal de Controle gerado pelo controlador com base nas estimativas do Modelo de Primeiro Nível, Adaptação de Segundo Nível sem Fator de Esquecimento e Adaptação de Segundo Nível com Fator de Esquecimento com referência degrau.

Vemos que, na ausência de um sinal PE as estimativas dos parâmetros acabam por se manter em valores que não são os corretos. Isto pode ser visto nas Figuras 5.9 a 5.12.

A Adaptação de Segundo Nível sem Fator de Esquecimento faz com que o erro de saída tenda a 0 mais rapidamente que os outros dois casos mas exibe um sobressinal maior no erro de saída, em relação que a Adaptação de Segundo Nível com Fator de Esquecimento. O Modelo de Identificação por Regressão Linear exibe uma resposta mais lenta e mais oscilatória que ambos os tipos de Adaptação de Segundo Nível.

Apesar de as estimativas dos parâmetros não atingirem os valores corretos, todos os 3 modelos são capazes de fazer com que a saída da planta siga a saída do modelo de referência e produzir um sinal de controle em regime permanente que é igual ao sinal de controle do controlador ideal, como pode ser visto nas Figuras 5.13 e 5.14. No entanto, como não houve convergência dos parâmetros para seus valores corretos, uma mudança qualquer no sinal de referência da planta certamente causará um novo transitório de adaptação das estimativas dos parâmetros.

A seguir, colocamos os resultados para o controlador por estrutura variável, nas Figuras 5.15 e 5.16:




Figura 5.15: Erro de saída da planta para o controlador com estrutura variável para referência degrau.




Figura 5.16: Sinal de Controle gerado pelo controlador com estrutura variável para referência degrau.

Novamente, obtivemos um erro de saída que tende para uma vizinhança pequena de 0 muito rapidamente, como podemos ver na Figura 5.15. Apesar disso, o sinal de controle exibe chattering e assume valores muito grandes em módulo, como podemos ver na Figura 5.16. Estas características do sinal de controle podem se mostrar indesejáveis ou mesmo intoleráveis, a depender do sistema ou processo a ser controlado. Além disso, um sinal de controle maior em módulo implica em maior gasto de energia.

5.6 Conclusão

Neste capítulo apresentamos brevemente o problema do controle adaptativo por modelo de referência indireto para o caso da planta SISO de grau n e grau relativo 1, onde os parâmetros do controlador são calculados a partir de um mapeamento obtido pelas equações de matching 5.14, considerando as estimativas como se fossem os parâmetros verdadeiros. Dispensamos a hipótese que assumimos para os capítulos 1 e 2 de que a planta seja estável e adotamos uma lei de controle capaz de estabilizar a planta.

Mostramos que a adaptação de segundo nível pode, apenas no caso das simulações que fizemos, substituir o método do gradiente normalizado na entrega das estimativas dos parâmetros da planta, sem perda das propriedades de estabilidade do sistema. Na adaptação de segundo nível os coeficientes de uma combinação linear de múltiplos modelos são atualizados por uma lei integral e as estimativas são entregues por esta mesma combinação.

Simulamos também o controle adaptativo por modelo de referência e estrutura variável na estratégia direta, comparando seus resultados com aqueles obtidos para o controle adaptativo por leis integrais. Vimos que, apesar de atingir um desempenho muito superior em relação à convergência do erro de saída para 0, o controle com estrutura variável exibe um sinal de controle que pode se mostrar indesejável em regime permanente.

Disponibilizamos os algoritmos utilizados nas Tabelas 5.1, 5.2 e 5.3.

Foram feitos estudos de simulação do controle de uma planta instável, nos quais avaliámos a adaptação de segundo nível com e sem fator de esquecimento em relação ao modelo por regressão linear para o caso SISO aplicados ao controle adaptativo por modelo de referência na estratégia indireta. Também comparamos estes resultados com o controle adaptativo por modelo de referência e estrutura variável na estratégia direta. Terminamos aqui os temas que gostaríamos de abordar para esta dissertação.

Capítulo 6

Conclusão

Neste trabalho apresentamos a adaptação de segundo nível, que é uma nova ferramenta de identificação/estimação de parâmetros, e mostramos a aplicação do conceito a plantas lineares.

Devido ao uso das informações de múltiplos modelos de identificação em conjunto, as estimativas dos parâmetros exibem uma convergência mais rápida na adaptação de segundo nível, quando comparada com modelos de identificação convencionais. Esta convergência mais rápida dos parâmetros se traduz, quando aplicada ao controle adaptativo indireto, numa melhor ação de controle.

Nesta dissertação de mestrado nossas contribuições foram as seguintes:

- 1 Explicitar o conceito de adaptação de segundo nível para identificação dos parâmetros de uma planta de ordem n e grau relativo 1, tendo como base o modelo por regressão linear cujos parâmetros são atualizados pelo método do gradiente normalizado para o caso SISO, discutindo suas propriedades. Trata-se de contribuição nova, pois o modelo de identificação utilizado até então para a adaptação de segundo nível é do tipo série-paralelo, como, por exemplo, em (?).
- 2 A introdução de um fator de esquecimento na lei integral da adaptação de segundo nível, de forma a acumular informações passadas e melhorar as propriedades de convergência das estimativas dos parâmetros da planta para seus valores corretos.

Entre as perspectivas futuras estão:

- 1 Uma prova de estabilidade do controlador adaptativo indireto baseado na adaptação de segundo nível para a planta de ordem n e grau relativo qualquer.
- 2 O uso das estimativas de segundo nível nos controladores adaptativos em modo dual, que foram mencionados na introdução, para a estratégia indireta.
- 3 Uma extensão dos resultados obtidos para adaptação de segundo nível no caso da planta com múltiplas entradas e múltiplas saídas.
- 4 Uma aplicação da adaptação de segundo nível ao controle adaptativo por posicionamento de polos, de forma que seja possível aplicar o conceito para plantas de fase não mínima.

- 5 O uso da adaptação de segundo nível em conjunto com chaveamento entre múltiplos modelos de identificação, por meio da avaliação de funções de custo, como, por exemplo, em (Narendra 2016).

Há, de fato, muitas direções em que o trabalho acerca da adaptação de segundo nível pode ser desenvolvido, por se tratar de algo recente. Como mencionamos na introdução, esta é uma das primeiras dissertações de mestrado feitas no Brasil acerca deste tema. Desta forma, esperamos que esta dissertação sirva como um guia inicial de uso do conceito de adaptação de segundo nível e como ponto de partida para novos trabalhos acerca deste novo método.

Referências Bibliográficas

- Bitmead, R. (1984), 'Persistence of excitation conditions and the convergence of adaptive schemes', *IEEE Transactions on Information Theory* **30**(2), 183–191.
- Boyd, S. & S. S. Sastry (1986), 'Necessary and sufficient conditions for parameter convergence in adaptive control', *Automatica* **22**(6), 629–639.
- Chowdhary, Girish, Tansel Yucelen, Maximillian Mühlegg & Eric N. Johnson (2013), 'Concurrent learning adaptive control of linear systems with exponentially convergent bounds', *International Journal of Adaptive Control and Signal Processing* **27**(4), 280–301.
URL: <http://dx.doi.org/10.1002/acs.2297>
- Costa, R. R. & L. Hsu (1991), 'Unmodeled dynamics in adaptive control systems revisited', *Systems & Control Letters* **16**, 341–348.
- Cunha, C. D. (2008), *Controlador em Modo Dual Adaptativo Robusto - DMARC*, Tese de doutorado, Universidade Federal do Rio Grande do Norte, Natal, RN.
- Cunha, C. D., A. D. Araujo & F. C. Mota (2007), 'Controlador em modo dual adaptativo robusto para plantas com grau relativo unitário: Prova de estabilidade', *Revista Controle e Automação* **18**(2), 223–232.
- Cunha, C. D., A. D. Araujo & F. C. Mota (2009), 'Controlador em modo dual adaptativo robusto para plantas com grau relativo arbitrário', *Revista Controle e Automação* **20**(1), 72–82.
- Fernandes, M. V. A., S. M. Dias, A. D. Araujo, J. B. Oliveira & K. I. M. P. Queiroz (2010), Shunt indirect variable structure model reference adaptive controller for plants with arbitrary relative degree, *em* 'Proceedings of 11th International Workshop on Variable Structure Systems 1', pp. 283–288.
- Han, Z. & K. S. Narendra (2010), Multiple adaptive models for control, *em* 'Decision and Control (CDC), 2010 49th IEEE Conference on', pp. 60–65.
- Han, Z. & K. S. Narendra (2012), 'New concepts in adaptive control using multiple models', *IEEE Transactions on Automatic Control* **57**(1), 78–89.
- Han, Zhuo & Kumpati Narendra (2011), 'Second level adaptation using multiple models', pp. 2350 – 2355.

- Hsu, L. (1990), 'Variable structure model reference adaptive control using only input and output measurements: The general case', *IEEE Trans. Automatic Control* **AC-35**(11), 1238–1243.
- Hsu, L., A. D. Araujo & R. R. Costa (1994), 'Analysis and design of i/o based variable structure adaptive control', *IEEE Trans. Automatic Control* **39**(1), 4–21.
- Hsu, L. & R. R. Costa (1989), 'Variable structure model reference adaptive control using only input and output measurements - part i', *International Journal of Control* **49**(2), 399–416.
- Ioannou, Petros A. & Jing Sun (1996), *Robust Adaptive Control*, Pearson Education, Inc.
- Narendra, K. S. & A. M. Annaswamy (1989), *Stable Adaptive Systems*, Prentice-Hall.
- Narendra, K. S. & J. Balakrishnan (1994), 'Improving transient response of adaptive control systems using multiple models and switching', *IEEE Transactions on Automatic Control* **39**(9), 1861–1866.
- Narendra, K. S. & J. Balakrishnan (1997), 'Adaptive control using multiple models', *IEEE Transactions on Automatic Control* **42**(2), 171–187.
- Narendra, K. S., J. Balakrishnan & M. K. Ciliz (1995), 'Adaptation and learning using multiple models, switching, and tuning', *IEEE Control Systems* **15**(3), 37–51.
- Narendra, K. S., Y. Wang & W. Chen (2014), Stability, robustness, and performance issues in second level adaptation, *em* 'American Control Conference (ACC), 2014', pp. 2377–2382.
- Narendra, K. S., Yu Wang & Wei Chen (2015), Extension of second level adaptation using multiple models to siso systems, *em* '2015 American Control Conference (ACC)', pp. 171–176.
- Narendra, K. S. & Z. Han (2010), Location of models in multiple-model based adaptive control for improved performance, *em* 'American Control Conference (ACC), 2010', pp. 117–122.
- Narendra, K.S. (2016), Chapter two - hierarchical adaptive control of rapidly time-varying systems using multiple models, *em* K. G. Vamvoudakis & S. Jagannathan, eds., 'Control of Complex Systems', Butterworth-Heinemann, pp. 33 – 66.
URL: <https://www.sciencedirect.com/science/article/pii/B9780128052464000021>
- NARENDRA, KUMPATI S. & ANURADHA M. ANNASWAMY (1987), 'Persistent excitation in adaptive systems', *International Journal of Control* **45**(1), 127–160.
URL: <http://dx.doi.org/10.1080/00207178708933715>
- Narendra, Kumpati S., Yu Wang & Wei Chen (2012), The rationale for second level adaptation, *em* 'The 16th Yale Workshop on Adaptive and Learning Systems', Yale University.

- Oliveira, J. B. (2003), *Controle adaptativo indireto por modelo de referência e estrutura variável*, Dissertação de mestrado, Universidade Federal do Rio Grande do Norte, Natal, RN.
- Oliveira, J. B. (2007), *Estabilidade e Robustez de um Controlador Adaptativo Indireto por Modelo de Referência e Estrutura Variável*, Tese de doutorado, Universidade Federal do Rio Grande do Norte, Natal, RN.
- Oliveira, J. B. & A. D. Araujo (2008a), 'Design and stability analysis of an indirect variable structure model reference adaptive control', *International Journal of Control* **81**(12), 1870–1877.
- Oliveira, J. B. & A. D. Araujo (2008b), A modified design for the vs-mrac based on the indirect approach: Stability analysis, *em* 'Proceedings of the 17th IFAC 2008 WC 1', pp. 13121–13126.
- Pandey, V. K., I. Kar & C. Mahanta (2017), Controller design for a 3-dof helicopter using multiple models with second level adaptation, *em* '2017 Indian Control Conference (ICC)', pp. 99–104.
- Rohrs, C. E., L. Valavani, M. Athans & G. Stein (1985), 'Robustness of continuous-time adaptive control algorithms in the presence of unmodeled dynamics', *IEEE Trans. Automatic Control AC-* **30**(9), 881–889.
- Tao, G. (2003), *Adaptive Control Design and Analysis*, Wiley.
- Teixeira, L. R. L. (2011), *Uma abordagem indireta para o controlador em modo dual adaptativo robusto*, Dissertação de mestrado, Universidade Federal do Rio Grande do Norte, Natal, RN.
- Teixeira, L. R. L., J. B. Oliveira & A. D. Araujo (2013), An intuitive design for the dual mode adaptive robust controller based on indirect control, *em* 'Proceedings of the European Control Conference 2013 - ECC '13 1', pp. 4526–4531.
- Teixeira, L. R. L., J. B. Oliveira & A. D. Araujo (2015), 'Smooth indirect adaptive sliding mode control', *International Journal of Robust and Nonlinear Control* **25**(6), 775–790.
- Teixeira, Leonardo Rodrigues de Lima (2016), *Controlador em Modo Dual Adaptativo Robusto Indireto (IDMARC). 2016. 93f*, Tese (Doutorado em Engenharia Elétrica e de Computação) - Centro de Tecnologia, Universidade Federal do Rio Grande do Norte, Natal.
- Yanque, I., E. V. L. Nunes, R. R. Costa & L. Hsu (2012), Binary mimo mrac using a passifying multiplier - a smooth transition to sliding mode control, *em* 'Proceedings of the 2012 American Control Conference', pp. 1925–1930.

Apêndice A

Combinações Convexas

Um conjunto K em um espaço linear L é chamado convexo se o segmento de reta ab estiver contido em K para quaisquer elementos $a, b \in K$, isto é, $x_t = (1-t)a + tb \in K$ para qualquer $a, b \in K$, para qualquer $t \in [0, 1]$.

Sejam $a_1, a_2, \dots, a_n$ elementos arbitrários de um espaço linear L e $\lambda_1, \lambda_2, \dots, \lambda_n$ sejam números reais. O elemento $a = a_1\lambda_1 + a_2\lambda_2 + \dots + a_n\lambda_n$ é chamado uma combinação linear de $a_1, a_2, \dots, a_n$. Se todos os números $\lambda_1, \lambda_2, \dots, \lambda_n$ são não negativos e $\lambda_1 + \lambda_2 + \dots + \lambda_n = 1$ então o elemento a é chamado de combinação convexa dos elementos $a_1, a_2, \dots, a_n$.

Deixe que K seja um subconjunto convexo do espaço linear L . Então todas as combinações convexas dos elementos de K pertencem a K .

O fecho convexo K_c de um conjunto de pontos P de um espaço linear L é o menor subconjunto convexo que contém todos os pontos do conjunto P .

Apêndice B

Conceitos sobre Sistemas

Um sistema é dito invariante no tempo se suas características não variam.

Um sistema é dito linear se obedece ao princípio da superposição. Sistemas que não obedecem ao princípio da superposição são chamados sistemas não-lineares.

Um sistema com uma única entrada e única saída disponíveis para medição é denominado SISO (Single Input Single Output). Caso um sistema tenha múltipla entradas e múltiplas saídas este é denominado MIMO (Multiple Input Multiple Output).

Um sistema é dito dinâmico caso suas saídas dependam dos valores passados de suas entradas. Caso a saída dependa apenas do valor presente das entradas o sistema é dito estático.

B.1 Representação

Um sistema dinâmico, linear, invariante no tempo e SISO pode ser representado em espaço de estados pelas seguintes equações:

$$\begin{aligned}\dot{x} &= Ax + bu \\ y &= h^T x + du\end{aligned}\tag{B.1}$$

onde $A \in R^{n \times n}$, $b \in R^n$, $h^T \in R^n$ e $d \in R$ são os parâmetros da planta em espaço de estados. Esta representação descreve uma relação entre o sinal de entrada u e a saída da planta y .

Outra forma de obter uma relação entre variáveis é a partir do domínio da frequência:

$$G(s) \triangleq \frac{Y(s)}{U(s)} = \frac{N(s)}{D(s)} = \frac{b_1 s^m + \dots + b_m}{a_1 s^n + \dots + a_n}\tag{B.2}$$

onde $G(s)$ é chamada função de transferência entre $Y(s)$ e $U(s)$, $N(s)$ é chamado polinômio do numerador e $D(s)$ é chamado polinômio do denominador. O grau n do polinômio $D(s)$ determina a ordem do sistema. A diferença entre o grau n de $D(s)$ e o grau m de $N(s)$ determina o grau relativo. As raízes de $D(s)$ são chamadas polos. As raízes de $N(s)$

são chamadas zeros. Os polos e zeros determinam o comportamento dinâmico do sistema.

A partir de uma representação do tipo B.1 da planta é possível obter uma representação do tipo B.2 e vice-versa.

Um sistema linear representado por uma função de transferência $G(s)$ é estável se todos os seus polos tem parte real negativa, caso algum polo tenha parte real positiva o sistema é instável.

Um sistema linear representado por uma função de transferência $G(s)$ é chamado de fase mínima se todos os seus zeros tem parte real negativa, caso algum zero tenha parte real positiva o sistema é de fase não-mínima.

Apêndice C

Estabilidade

C.1 Definições

Considerando o sistema descrito por:

$$\dot{x} = f(x, t), x(t_0) = x_0 \quad (\text{C.1})$$

onde $f \in R^n$ é uma função e $x \in R^n$ o vetor de estado. Os elementos que compõem x são variáveis de estado. As seguintes definições são úteis:

- **Definição C.1.1** Um estado x^* é dito ponto de equilíbrio de um sistema descrito por C.1 se $f(t, x^*) = 0$, ou seja, se $x(0) = x^*$ implica que $x \equiv x^*$.
- **Definição C.1.2** O ponto de equilíbrio x^* é dito estável se para todo t_0 e para toda bola de raio $\epsilon > 0$ existe uma bola de raio $\delta(\epsilon, t_0)$ tal que $|x_0 - x^*| < \delta$ implica em $|x(t) - x^*| < \epsilon$ para todo $t \geq t_0$.
- **Definição C.1.3** O ponto de equilíbrio x^* é dito assintoticamente estável se é estável e se existe uma bola de raio $\delta(t_0)$ tal que $|x_0 - x^*| < \delta$ implica em $\lim_{t \rightarrow \infty} |x(t) - x^*| = 0$.

Para sistemas lineares com um único ponto de equilíbrio, quando diz-se que o sistema é estável estamos nos referindo à estabilidade de seu ponto de equilíbrio.

C.2 Método Direto de Lyapunov

A teoria de Lyapunov lida com funções de energia para buscar entender as propriedades de estabilidade de um sistema. As seguintes definições são úteis neste trabalho:

C.2.1 Funções definidas

- **Definição C.2.1.1** Uma função $V(x)$ é definida positiva ($V(x) > 0$) em uma vizinhança de $x = 0$ se $V(x) > 0$ qualquer que seja x pertencente a uma bola de raio ϵ com $x \neq 0$ e $V(0) = 0$.
- **Definição C.2.1.2** Uma função $V(x)$ é semi-definida positiva ($V(x) \geq 0$) em uma vizinhança de $x = 0$ se $V(x) \geq 0$ qualquer que seja x pertencente a uma bola de raio ϵ com $x \neq 0$ e $V(0) = 0$.

- **Definição C.2.1.3** Uma função $V(x)$ é definida negativa ($V(x) < 0$) em uma vizinhança de $x = 0$ se $V(x) < 0$ qualquer que seja x pertencente a uma bola de raio ε com $x \neq 0$ e $V(0) = 0$.
- **Definição C.2.1.4** Uma função $V(x)$ é semi-definida negativa ($V(x) \leq 0$) em uma vizinhança de $x = 0$ se $V(x) \leq 0$ qualquer que seja x pertencente a uma bola de raio ε com $x \neq 0$ e $V(0) = 0$.

C.2.2 Teoremas sobre estabilidade

- **Definição C.2.2.1** Se para o sistema C.1 há uma função $V(x)$ definida positiva e continuamente diferenciável tal que $\dot{V}(x)$ é semi-definida negativa, então $V(x)$ não pode crescer e x^* é um ponto de equilíbrio estável
- **Definição C.2.2.2** Se para o sistema C.1 há uma função $V(x)$ definida positiva e continuamente diferenciável tal que $\dot{V}(x)$ é definida negativa, então $V(x)$ deve decrescer e x^* é um ponto de equilíbrio assintoticamente estável

C.3 Norma $\mathcal{L}_p$

Para funções no tempo a norma $\mathcal{L}_p$ é definida como:

$$\|x\|_p \triangleq \left(\int_0^\infty |x(\tau)|^p d\tau \right)^{1/p} \quad (\text{C.2})$$

para $p \in [1, \infty)$ e dizemos que $x \in \mathcal{L}_p$ quando $\|x\|_p$ existe e é finita. Adicionalmente, definimos a norma $\mathcal{L}_\infty$:

$$\|x\|_\infty \triangleq \sup_{t \geq 0} |x(t)| \quad (\text{C.3})$$

e dizemos que $x \in \mathcal{L}_\infty$ quando $\|x\|_\infty$ existe. Pode-se também dizer que x é uniformemente limitado.

C.4 Lema de Barbalat

Deixe que $f(t) : \mathbb{R} \rightarrow \mathbb{R}$ seja diferenciável e tenda a um limite finito a medida que $t \rightarrow \infty$. Se $\dot{f}(t)$ é uniformemente contínua então $\dot{f}(t) \rightarrow 0$ a medida que $t \rightarrow \infty$.

C.4.1 Corolário 1

Se $f(t) : \mathbb{R} \rightarrow \mathbb{R}$ é diferenciável duas vezes e tende a um limite finito a medida que $t \rightarrow \infty$ e sua segunda derivada é limitada, então $\dot{f}(t) \rightarrow 0$ a medida que $t \rightarrow \infty$. Em geral uma derivada que tende a 0 não implica que a função tende a um valor em particular ou vice-versa. É possível que uma derivada $\dot{f}(t)$ tenda a 0 a medida que $t \rightarrow \infty$ sem que $f(t)$

tenda a algum valor em particular. Também é possível que $f(t)$ tenda a algum valor a medida que $t \rightarrow \infty$ sem que sua derivada $\dot{f}(t)$ tenda a 0.

C.4.2 Corolário 2

Seja uma função escalar $V = V(t, x)$ tal que:

- $V(t, x)$ tem um limite inferior
- $\dot{V}(t, x)$ é semi-definida negativa ao longo das trajetórias de $\dot{x} = f(t, x)$
- $\dot{V}(t, x)$ é uniformemente contínua

então $\dot{V}(t, x) \rightarrow 0$ a medida que $t \rightarrow \infty$.

C.4.3 Corolário 3

Se $f(t) : R^+ \rightarrow R$ é uniformemente contínua para todo $t \geq 0$, e se o limite da integral:

$$\lim_{t \rightarrow \infty} \int_0^t f(\tau) d\tau \quad (C.4)$$

existe e é finito, então:

$$\lim_{t \rightarrow \infty} f(t) = 0 \quad (C.5)$$

C.4.4 Corolário 4

Seja $f(t) = |g(t)|^p$, se $g, \dot{g} \in \mathcal{L}_\infty$ e $g \in \mathcal{L}_p$, para algum $p \in [1, \infty)$, então $\lim_{t \rightarrow \infty} g(t) = 0$. Este corolário é aquele ao qual nos referimos no texto quando mencionamos que, devido a um corolário do lema de barbalat, algum sinal tende a 0 assintoticamente.

C.5 Lema de Kalman-Yakubovitch-Lefschetz

Se o par (A, b) de uma representação B.1 de um sistema é controlável e A é assintoticamente estável e o grau relativo do sistema é unitário, temos que:

$$\begin{aligned} A^T P + PA &= -2Q \\ Pb &= h^T \end{aligned} \quad (C.6)$$

onde $Q = Q^T > 0, P = P^T > 0$ são matrizes definidas positivas.