



UNIVERSIDADE FEDERAL DO RIO GRANDE DO NORTE
CENTRO DE TECNOLOGIA
PROGRAMA DE PÓS-GRADUAÇÃO EM ENGENHARIA ELÉTRICA E
DE COMPUTAÇÃO



Adaptação de Segundo Nível como Técnica de Estimação de Parâmetros e sua Aplicação ao Controle Adaptativo por Modelo de Referência

Pedro Yochinori Gushiken

Orientador: Prof. Dr. Aldayr Dantas de Araújo

Dissertação de Mestrado apresentada ao Programa de Pós-Graduação em Engenharia Elétrica e de Computação da UFRN (área de concentração: Automação e Sistemas) como parte dos requisitos para obtenção do título de Mestre em Ciências.

Número de ordem PPgEEC: M520
Natal, RN, janeiro de 2018

Universidade Federal do Rio Grande do Norte - UFRN

Sistema de Bibliotecas - SISBI

Catálogo da publicação na fonte. UFRN - Biblioteca Central Zila Mamede

Gushiken, Pedro Yochinori.

Adaptação de segundo nível como técnica de estimação de parâmetros e sua aplicação ao controle adaptativo por modelo de referência / Pedro Yochinori Gushiken. - 2018.

146 f.: il.

Dissertação (mestrado) - Universidade Federal do Rio Grande do Norte, Centro de Tecnologia, Programa de Pós-Graduação em Engenharia Elétrica e de Computação. Natal, RN, 2018.

Orientador: Prof. Dr. Aldayr Dantas de Araújo.

1. Estimação de parâmetros - Dissertação. 2. Controle adaptativo por modelo de referência - Dissertação. 3. Adaptação de segundo nível - Dissertação. 4. Controle adaptativo com múltiplos modelos - Dissertação. 5. Controle adaptativo com estrutura variável - Dissertação. I. Araújo, Aldayr Dantas de. II. Título.

RN/UF/BCZM


CDU 519.23




Universidade Federal do Rio Grande do Norte
**PROGRAMA DE PÓS-GRADUAÇÃO EM ENGENHARIA ELÉTRICA E DE
COMPUTAÇÃO**

ATA Nº 520

Aos trinta e um dias do mês de janeiro do ano de dois mil e dezoito, foi realizada a 520ª sessão de defesa de dissertação de mestrado do Programa de Pós-Graduação em Engenharia Elétrica e de Computação da UFRN, na qual o mestrando Pedro Yochinori Gushiken apresentou o trabalho que tem como título: Adaptação de Segundo Nível como Técnica de Estimção de Parâmetros e sua Aplicação ao Controle Adaptativo por Modelo de Referência. A sessão teve início às 09h00min, tendo a banca examinadora sido constituída pelos seguintes participantes: Francisco das Chagas da Silva Júnior (Dr. IFRN, Examinador Externo à Instituição), Josenalde Barbosa de Oliveira (Dr. UFRN, Examinador Externo ao Programa) e Aldayr Dantas De Araujo (Dr. UFRN, Orientador). Após a apresentação do trabalho e o exame pela banca, o mestrando foi considerado **APROVADO**, tendo sido lavrada a presente ata, que vai assinada pelos examinadores e pelo mestrando. A versão final da tese deverá ser entregue ao programa, no prazo máximo de 60 dias, contendo as modificações sugeridas pela banca examinadora e constante na folha de correção anexa. Conforme o Artigo 49 da Resolução 197/2013 - CONSEPE, o candidato não terá o título se não cumprir as exigências acima.


Dr. FRANCISCO DAS CHAGAS DA SILVA JÚNIOR, IFRN

Examinador Externo à Instituição


Dr. JOSENALDE BARBOSA DE OLIVEIRA, UFRN

Examinador Externo ao Programa


Dr. ALDAYR DANTAS DE ARAUJO, UFRN

Presidente


PEDRO YOCHINORI GUSHIKEN

Mestrando

*À Thaylãna e à Maria, pela
paciência durante a realização deste
trabalho.*

Agradecimentos

Ao professor Aldayr Dantas de Araújo sou extremamente grato pela orientação esmerada e cuidadosa, que esculpiu com elegância este trabalho a partir de sua forma bruta.

Aos professores e colegas do LACI, em especial o professor Allan de Medeiros Martins que esclareceu dúvidas que se mostraram fundamentais para a confecção deste trabalho, e aos professores Samaherni Moraes Dias e Kurios Iuri Pinheiro de Melo Queiroz, cujos comentários ajudaram a melhorá-lo.

Ao professor Leonardo Rodrigues de Lima Teixeira pelo entusiasmo inspirador.

Aos colegas de mestrado Isaac Dantas Isidório e Winnie de Lima Torres pela companhia e amizade durante as aulas.

À minha família, em especial aos meus pais, Maria do Socorro e Mauricio Gushiken, e à minha esposa Thaylãna Mayra, pelo apoio incondicional durante esta jornada.

Aos meus filhos, João e Gael.

Ao CNPq, pelo apoio financeiro que possibilitou a elaboração deste trabalho.

Resumo

Neste trabalho mostramos a técnica de estimação de parâmetros para plantas lineares invariantes no tempo conhecida como adaptação de segundo nível baseada em múltiplos modelos de identificação por regressão linear, tanto para o caso de uma planta de ordem 1 quanto para o caso de uma planta de ordem n onde apenas a entrada e a saída da planta estão disponíveis para medição (SISO). Propomos uma modificação na lei adaptativa da adaptação de segundo nível baseada no acúmulo de informações do transitório. Em todos os casos verificamos por simulação que as estimativas entregues pela adaptação de segundo nível convergem muito mais rapidamente para os valores corretos que as estimativas entregues por modelos de identificação individuais e que a modificação proposta aumenta a velocidade e suaviza a convergência das estimativas. Aplicamos a adaptação de segundo nível com base em modelos de identificação por regressão linear atualizados pelo método do gradiente ao problema do controle adaptativo por modelo de referência (MRAC) de uma planta SISO de ordem 1 e ao caso de uma planta de ordem n e grau relativo unitário, este caso com o gradiente normalizado. Resultados de simulação mostram que o sinal de controle gerado com adaptação de segundo nível produz melhores resultados de rastreamento do modelo de referência quando comparada aos modelos de identificação individuais. Além disso, comparamos o MRAC indireto baseado em adaptação de segundo nível ao Controle Adaptativo por Modelo de Referência e Estrutura Variável (VS-MRAC).

Palavras-chave: Estimação de parâmetros, Controle adaptativo por modelo de referência, Adaptação de segundo nível, Controle adaptativo com múltiplos modelos, Controle adaptativo com estrutura variável.

Abstract

In this dissertation we demonstrate the concept of second level adaptation as a parameter estimation method based on multiple linear regression identification models for the case of a plant of order unity, and the case of a plant of order n with single input and output available for measurement (SISO). We propose a modified form of the adaptive law for second level adaptation based on integration of transient information. In all cases simulation studies show that the estimates reach their true values faster with second level adaptation compared to individual identification models and that the proposed modification is even faster and also smoother in this regard. We apply second level adaptation based on linear regression identification models updated through the gradient method to the problem of model reference adaptive control (MRAC) in the case of an order 1 plant and the case of an order n and relative degree one SISO plant, in this case with normalized gradient method. Simulation results show that the control signal generated with second level adaptation yields better results of model reference tracking compared to individual identification models. We also compare the indirect MRAC based on second level adaptation to the variable structure model reference adaptive control (VS-MRAC) scheme.

Keywords: Parameter estimation, Model reference adaptive control, Second level adaptation, Multiple model adaptive control, Variable structure adaptive control.

Sumário

Sumário	i
Lista de Figuras	iii
Lista de Tabelas	vii
Lista de Símbolos e Abreviaturas	ix
1 Introdução	13
2 Estimação de Parâmetros, Ordem 1	17
2.1 Introdução	17
2.2 Descrição do Problema	18
2.3 Identificação Paramétrica Convencional	19
2.4 Adaptação de Segundo Nível	23
2.5 Adaptação de Segundo Nível Modificada	31
2.6 Resultados	34
2.7 Conclusão	42
3 Controle da Planta de Ordem 1	43
3.1 Descrição do Problema	43
3.2 Planta com Parâmetros Conhecidos	44
3.3 Controle Adaptativo por Modelo de Referência Indireto	44
3.4 Controle Adaptativo por Modelo de Referência e Estrutura Variável	45
3.5 Resultados	46
3.6 Conclusão	53
4 Estimação de Parâmetros, Ordem n	55
4.1 Descrição do Problema	56
4.2 Estimação de Parâmetros Convencional	57
4.3 Adaptação de Segundo Nível	60
4.4 Adaptação de Segundo Nível com fator de esquecimento	67
4.5 Resultados	69
4.6 Conclusão	78

5	Controle da Planta de Ordem n	79
5.1	Descrição do Problema	79
5.2	Planta com Parâmetros Conhecidos	80
5.3	Controle Adaptativo por Modelo de Referência Indireto	83
5.4	Controle Adaptativo por Modelo de Referência e Estrutura Variável	84
5.5	Resultados	89
5.6	Conclusão	104
6	Conclusões e Perspectivas	105
	Referências Bibliográficas	107
A	Combinações Convexas	111
A.1	Teorema 1	111
A.2	Teorema 2	113
B	Conceitos sobre Sistemas	115
B.1	Representação	115
C	Estabilidade	117
C.1	Definições	117
C.2	Método Direto de Lyapunov	117
C.2.1	Funções Definidas	117
C.2.2	Teoremas sobre Estabilidade	118
C.3	Norma $\mathcal{L}_p$	118
C.4	Lema de Barbalat	118
C.4.1	Corolário 1	118
C.4.2	Corolário 2	119
C.4.3	Corolário 3	119
C.4.4	Corolário 4	119
C.5	Função Estritamente Real Positiva	119
C.6	Lema de Meyer-Kalman-Yakubovitch	119

Lista de Figuras

1	Sistema de controle em malha aberta	2
2	Sistema de controle em malha fechada	3
3	Controlador adaptativo direto	5
4	Controlador adaptativo indireto	6
5	Modelo de identificação por regressão linear	10
1.1	Controlador adaptativo indireto de segundo nível	15
2.1	Valor de λ e do sinal $ y\phi_1 (t) + u\phi_2 (t)$, 20 segundos de simulação	36
2.2	Erros de identificação dos modelos de primeiro nível usando o modelo por regressão linear e do modelo virtual usando SLA com $N = 3$ para a planta Σ_p , 110 segundos de simulação	37
2.3	Erros de identificação dos modelos de primeiro nível usando o modelo por regressão linear e do modelo virtual usando SLA com $N = 3$ para a planta Σ_p , 20 segundos de simulação	37
2.4	Estimativa do parâmetro $a_p = 1.5$ para a planta Σ_p para o modelo de identificação por regressão linear, SLA com $N = 3$, $N = 4$ e $N = 8$ modelos de primeiro nível por regressão linear, 20 segundos de simulação	39
2.5	Estimativa do parâmetro $k_p = 3$ para a planta Σ_p para o modelo de identificação por regressão linear, SLA com $N = 3$, $N = 4$ e $N = 8$ modelos de primeiro nível por regressão linear, 20 segundos de simulação	39
2.6	Erros de identificação usando 3 modelos por regressão linear e o erro do modelo virtual usando SLA com base nestes modelos para a planta Σ_p . .	40
2.7	Estimativas do parâmetro $a_p = 1.5$ para a planta Σ_p para 3 modelos por regressão linear e SLA modificada, 36 segundos de simulação	41
2.8	Estimativas do parâmetro $k_p = 3$ para a planta Σ_p para 3 modelos por regressão linear e SLA modificada, 36 segundos de simulação	41
2.9	Trajatória dos parâmetros $\hat{a}_{n2,f}$ e $\hat{k}_{n2,f}$ da SLA modificada no espaço de parâmetros usando 3 modelos por regressão linear para a planta Σ_p , aos 30 segundos de simulação	42
3.1	Valor de λ e do sinal $ y\phi_1 (t) + u\phi_2 (t)$, 20 segundos de simulação	48
3.2	Estimativa do parâmetro $a_p = 3$ para a planta Σ_p de ordem 1 para o modelo de identificação por regressão linear e a SLA com $N=3$, 12 segundos de simulação	49

3.3	Estimativa do parâmetro $k_p = 1.5$ para a planta Σ_p de ordem 1 para o modelo de identificação por regressão linear e a SLA com $N=3$, 12 segundos de simulação	50
3.4	Saída da planta Σ_p de ordem 1 para o IMRAC baseado no modelo de identificação por regressão linear, SLA com $N=3$ e VS-MRAC, 12 segundos de simulação	50
3.5	Detalhe da Figura 3.4, entre 0 e 0.2 segundos de simulação	51
3.6	Sinal de controle para o VS-MRAC da planta de ordem 1, 12 segundos de simulação	52
3.7	Sinal de controle para o IMRAC baseado no modelo de identificação por regressão linear, SLA com $N=3$, e controle com parâmetros conhecidos da planta de ordem 1, 12 segundos de simulação	52
4.1	Comportamento das estimativas do coeficiente a_1 do polinômio $D_p(s)$ para o modelo de primeiro nível, SLA e SLAFF.	74
4.2	Comportamento das estimativas do coeficiente a_2 do polinômio $D_p(s)$ para o modelo de primeiro nível, SLA e SLAFF.	74
4.3	Comportamento das estimativas do coeficiente b_1 do polinômio $N_p(s)$ para o modelo de primeiro nível, SLA e SLAFF.	75
4.4	Comportamento das estimativas do coeficiente b_2 do polinômio $N_p(s)$ para o modelo de primeiro nível, SLA e SLAFF.	76
4.5	Erro de identificação não normalizado do modelo de primeiro nível com estimativa inicial $\hat{\theta}_{1,f}(0)$ e dos modelos virtuais com SLA e SLAFF, 20 segundos de simulação.	77
4.6	Erro de identificação não normalizado do modelo de primeiro nível com estimativa inicial $\hat{\theta}_{1,f}(0)$ e dos modelos virtuais com SLA e SLAFF, 6 segundos de simulação.	77
5.1	Comportamento das estimativas do coeficiente a_1 do polinômio $D_p(s)$ para o modelo de primeiro nível, SLA e SLAFF.	93
5.2	Comportamento das estimativas do coeficiente a_2 do polinômio $D_p(s)$ para o modelo de primeiro nível, SLA e SLAFF.	94
5.3	Comportamento das estimativas do coeficiente b_1 do polinômio $N_p(s)$ para o modelo de primeiro nível, SLA e SLAFF.	95
5.4	Comportamento das estimativas do coeficiente b_2 do polinômio $N_p(s)$ para o modelo de primeiro nível, SLA e SLAFF.	95
5.5	Comportamento da norma euclidiana do vetor de erro paramétrico $\tilde{\theta}_p$ para o modelo de primeiro nível, SLA e SLAFF.	96
5.6	Erro de saída da planta para o modelo de primeiro nível, SLA e SLAFF.	96
5.7	Sinal de controle gerado pelo controlador com base nas estimativas do modelo de primeiro nível, SLA e SLAFF.	97
5.8	Erro de saída da planta para o VS-MRAC.	97
5.9	Sinal de controle gerado pelo VS-MRAC.	98
5.10	Comportamento das estimativas do coeficiente a_1 do polinômio $D_p(s)$ para o modelo de primeiro nível, SLA e SLAFF com referência degrau.	99

5.11	Comportamento das estimativas do coeficiente a_2 do polinômio $D_p(s)$ para o modelo de primeiro nível, SLA e SLAFF com referência degrau. .	99
5.12	Comportamento das estimativas do coeficiente b_1 do polinômio $N_p(s)$ para o modelo de primeiro nível, SLA e SLAFF com referência degrau. .	100
5.13	Comportamento das estimativas do coeficiente b_2 do polinômio $N_p(s)$ para o modelo de primeiro nível, SLA e SLAFF com referência degrau. .	101
5.14	Comportamento da norma euclidiana do vetor de erro paramétrico $\tilde{\theta}_p$ para o modelo de primeiro nível, SLA e SLAFF com referência degrau.	101
5.15	Erro de saída da planta para o modelo de primeiro nível, SLA e SLAFF com referência degrau.	102
5.16	Sinal de controle gerado pelo controlador com base nas estimativas do modelo de primeiro nível, SLA e SLAFF com referência degrau.	102
5.17	Erro de saída da planta para o VS-MRAC com referência degrau.	103
5.18	Sinal de controle gerado pelo VS-MRAC com referência degrau.	103

Lista de Tabelas

2.1	Equações necessárias para identificação de parâmetros para a planta de ordem 1 e grau relativo unitário	35
3.1	Equações necessárias para o controle da planta de ordem 1 e grau relativo unitário	47
4.1	Equações necessárias para identificação de parâmetros para a planta de ordem n e grau relativo unitário	71
5.1	Equações necessárias para o controle da planta de ordem n e grau relativo unitário	89
5.2	Equações necessárias para a estimação de parâmetros da planta de ordem n e grau relativo unitário	90

Lista de Símbolos e Abreviaturas

$(.)^T$	Operador de transposição de uma matriz ou vetor
N	Número de modelos de identificação usados na adaptação de segundo nível
$(\dot{\cdot})$	Derivada de uma variável em relação ao tempo
$(\hat{\cdot})$	Estimativa de uma variável
$\inf(\cdot)$	Ínfimo de uma variável, maior cota inferior do conjunto de valores daquela variável
$\int_{(\cdot)}^{(\cdot)}(\cdot)$	Operador de integração
λ_{max}	Autovalor máximo de uma matriz
λ_{min}	Autovalor mínimo de uma matriz
$\sum_{(\cdot)}^{(\cdot)}(\cdot)$	Operador de somatório
$\sup(\cdot)$	Supremo de uma variável, menor cota superior do conjunto de valores daquela variável
$\mathbf{0}$	Matriz de tamanho apropriado (determinado pelo contexto da equação em que está sendo aplicada) cujos elementos são todos 0
$(\tilde{\cdot})$	Erro paramétrico, refere-se à diferença entre uma estimativa e o valor que está sendo estimado
$\vec{\mathbf{1}}$	Vetor linha de tamanho apropriado (determinado pelo contexto da equação em que está sendo aplicado) cujos elementos são todos 1
n	Grau da planta SISO
n^*	Grau relativo da planta SISO, neste trabalho assumimos sempre que $n^* = 1$
s	Variável complexa no domínio da frequência
Σ_p	Planta

$\Sigma_{1,f}$	Primeiro modelo de identificação por regressão linear da planta
$\Sigma_{i,f}$	i-ésimo modelo de identificação por regressão linear, com $i = 1, \dots, N$
$\Sigma_{v,f}$	Modelo de identificação virtual da planta cujas estimativas dos parâmetros são formadas pela combinação convexa das estimativas de N modelos de identificação por regressão linear
$D_m(s)$	Polinômio do denominador da função de transferência $W_m(s)$
$D_p(s)$	Polinômio do denominador da função de transferência $G_p(s)$
$G(s)$	Função de transferência da planta
$G_c(s)$	Função de transferência entre o sinal de referência e a saída da planta
$N_p(s)$	Polinômio do numerador da função de transferência $G_p(s)$
$W_m(s)$	Função de transferência do modelo de referência
$Z_m(s)$	Polinômio mônico do numerador da função de transferência $W_m(s)$
$Z_p(s)$	Polinômio mônico do numerador da função de transferência $G_p(s)$, igual a $N_p(s)$ dividido pelo ganho de alta frequência $b_1 = k_p$
$\Lambda(s)$	Polinômio mônico, Hurwitz, de grau n
$\dot{x}_p$	Primeira derivada em relação ao tempo do vetor de estado da planta
$\hat{z}_{1,f}$	Estimativa do sinal filtrado de saída da planta usando o modelo de identificação por regressão linear 1
$\hat{z}_{i,f}$	Estimativa do sinal filtrado de saída da planta usando o i-ésimo modelo de identificação por regressão linear, com $i = 1, \dots, N$
$\hat{z}_{v,f}$	Estimativa do sinal filtrado de saída da planta usando o modelo virtual
ϕ	Vetor coluna formado pelos elementos ϕ_1 na primeira linha e ϕ_2 na segunda linha, e chamado vetor regressor
ϕ_1	Vetor gerado a partir de filtragens do sinal y por funções de transferência próprias $\frac{s^i}{\Lambda(s)}$, com $i = n - 1, \dots, 1$, usado para construir o vetor regressor ϕ
ϕ_2	Vetor gerado a partir de filtragens do sinal u por funções de transferência próprias $\frac{s^i}{\Lambda(s)}$, com $i = n - 1, \dots, 1$, usado para construir o vetor regressor ϕ
u	Sinal de entrada da planta
x_p	Vetor de estado da planta
y ou y_p	Sinal de saída da planta

z	Sinal de saída da planta filtrado por uma função de transferência própria $\frac{s^n}{\Lambda(s)}$
E_f	Vetor linha formado pela diferença entre os erros de identificação $e_{i,f}$, com $i = 1, \dots, N-1$, e o erro $e_{N,f}$ em suas colunas
$\bar{E}_f$	Vetor linha formado pelos erros de identificação $e_{i,f}$, com $i = 1, \dots, N$, em suas colunas
$e_{1,f}$	Erro de identificação gerado pela diferença entre o sinal de saída do modelo de identificação por regressão linear 1 e o sinal de saída da planta filtrado
$e_{N,f}$	Erro de identificação gerado pela diferença entre o sinal de saída do modelo de identificação por regressão linear N e o sinal de saída da planta filtrado
$e_{i,f}$	Erro de identificação gerado pela diferença entre o sinal de saída do i -ésimo modelo de identificação por regressão linear, com $i = 1, \dots, N$, e o sinal de saída da planta filtrado
$e_{v,f}$	Erro de identificação gerado pela diferença entre o sinal de saída do modelo virtual e o sinal de saída da planta filtrado
$\dot{\hat{\theta}}_{1,f}$	Lei adaptativa para atualização da estimativa $\hat{\theta}_{1,f}$
$\dot{\hat{\theta}}_{i,f}$	Lei adaptativa para atualização da estimativa $\hat{\theta}_{i,f}$, com $i = 1, \dots, N$
$\dot{\hat{\theta}}_{v,f}$	Lei adaptativa para atualização da estimativa $\hat{\theta}_{v,f}$
$\dot{\hat{a}}_{1,f}$	Lei adaptativa para atualização da estimativa $\hat{a}_{1,f}$
$\dot{\hat{a}}_{i,f}$	Lei adaptativa para atualização da estimativa $\hat{a}_{i,f}$, com $i = 1, \dots, N$
$\dot{\hat{a}}_{v,f}$	Lei adaptativa para atualização da estimativa $\hat{a}_{v,f}$
$\dot{\hat{k}}_{1,f}$	Lei adaptativa para atualização da estimativa $\hat{k}_{1,f}$
$\dot{\hat{k}}_{i,f}$	Lei adaptativa para atualização da estimativa $\hat{k}_{i,f}$
$\dot{\hat{k}}_{v,f}$	Lei adaptativa para atualização da estimativa $\hat{k}_{v,f}$
$\hat{\theta}_{1,f}$	Estimativa do vetor de parâmetros θ_p^* da planta de ordem n e grau relativo 1 usando o modelo de identificação por regressão linear da planta 1
$\hat{\theta}_{i,f}$	Estimativa do vetor de parâmetros θ_p^* da planta de ordem n e grau relativo 1 usando o i -ésimo modelo de identificação por regressão linear da planta, com $i = 1, \dots, N$
$\hat{\theta}_{v,f}$	Estimativa de θ_p^* a partir de uma combinação convexa de coeficientes β_i dos parâmetros dos modelos de identificação por regressão linear

$\hat{a}_{1,f}$	Estimativa do coeficiente do polinômio mônico do denominador da planta de ordem 1 usando o modelo de identificação por regressão linear 1
$\hat{a}_{i,f}$	Estimativa do coeficiente do polinômio mônico do denominador da planta de ordem 1 usando o i-ésimo modelo de identificação por regressão linear, com $i = 1, \dots, N$
$\hat{a}_{v,f}$	Estimativa do coeficiente do polinômio mônico do denominador da planta de ordem 1 a partir de uma combinação convexa de coeficientes β_i dos parâmetros dos modelos de identificação por regressão linear
$\hat{k}_{1,f}$	Estimativa do coeficiente do polinômio do numerador da planta de ordem 1 usando o modelo de identificação por regressão linear 1
$\hat{k}_{i,f}$	Estimativa do coeficiente do polinômio do numerador da planta de ordem 1 usando o i-ésimo modelo de identificação por regressão linear, com $i = 1, \dots, N$
$\hat{k}_{v,f}$	Estimativa do coeficiente do polinômio do numerador da planta de ordem 1 usando o modelo virtual
$\tilde{\theta}_{1,f}$	Erro paramétrico devido a diferença entre a estimativa $\hat{\theta}_{1,f}$ e o valor correto θ_p^*
$\tilde{\theta}_{i,f}$	Erro paramétrico devido a diferença entre a estimativa $\hat{\theta}_{i,f}$ e o valor correto θ_p^*
$\tilde{\theta}_{v,f}$	Erro paramétrico devido a diferença entre a estimativa $\hat{\theta}_{v,f}$ e o valor correto θ_p^*
$\tilde{a}_{1,f}$	Erro paramétrico devido a diferença entre a estimativa $\hat{a}_{1,f}$ e o valor correto a_p
$\tilde{a}_{i,f}$	Erro paramétrico devido a diferença entre a estimativa $\hat{a}_{i,f}$ e o valor correto a_p
$\tilde{a}_{v,f}$	Erro paramétrico devido a diferença entre a estimativa $\hat{a}_{v,f}$ e o valor correto a_p
$\tilde{k}_{1,f}$	Erro paramétrico devido a diferença entre a estimativa $\hat{k}_{1,f}$ e o valor correto k_p
$\tilde{k}_{i,f}$	Erro paramétrico devido a diferença entre a estimativa $\hat{k}_{i,f}$ e o valor correto k_p
$\tilde{k}_{v,f}$	Erro paramétrico devido a diferença entre a estimativa $\hat{k}_{v,f}$ e o valor correto k_p
a_i	Coefficientes do polinômio mônico do denominador da planta SISO de ordem n e grau relativo 1, com $i = 1, \dots, n$, associados às variáveis complexas s^{n-i} do polinômio
a_i^+	Limitante superior da região de incerteza para os coeficientes a_i da planta SISO de ordem n e grau relativo 1, com $i = 1, \dots, n$
a_i^-	Limitante inferior da região de incerteza para os coeficientes a_i da planta SISO de ordem n e grau relativo 1, com $i = 1, \dots, n$
a_p	Coefficiente do polinômio mônico do denominador da planta de ordem 1

a_p^+	Limitante superior da região de incerteza para o coeficiente a_p da planta de ordem 1
a_p^-	Limitante inferior da região de incerteza para o coeficiente a_p da planta de ordem 1
b_i	Coefficientes do polinômio do numerador da planta SISO de ordem n e grau relativo 1, com $i = 1, \dots, n$, associados às variáveis complexas s^{n-i} do polinômio
b_i^+	Limitante superior da região de incerteza para os coeficientes b_i da planta SISO de ordem n e grau relativo 1, com $i = 1, \dots, n$
b_i^-	Limitante inferior da região de incerteza para o coeficiente b_i da planta SISO de ordem n e grau relativo 1, com $i = 1, \dots, n$
k_p	Coefficiente do polinômio do numerador da planta de ordem 1
k_p^+	Limitante superior da região de incerteza para o coeficiente k_p da planta de ordem 1
k_p^-	Limitante inferior da região de incerteza para o coeficiente k_p da planta de ordem 1
α_f	Vetor coluna formado pelos coeficientes $\alpha_{i,f}$ em suas linhas, com $i = 1, \dots, N-1$
α_f^*	Vetor coluna formado pelos coeficientes $\alpha_{i,f}^*$ em suas linhas, com $i = 1, \dots, N-1$
$\alpha_{i,f}$	Coefficientes da combinação convexa que são aplicados às estimativas $\hat{k}_{i,f}$ e $\hat{a}_{i,f}$, com $i = 1, \dots, N$, para formar uma estimativa de segundo nível dos parâmetros k_p e a_p , no caso da planta de ordem 1, ou coeficientes da combinação convexa que são aplicados às estimativas $\hat{\theta}_{i,f}$, com $i = 1, \dots, N$, para formar uma estimativa de segundo nível do vetor de parâmetros θ_p^* , no caso da planta SISO de ordem n
$\alpha_{i,f}^*$	Coefficientes da combinação convexa que quando aplicados às estimativas $\hat{k}_{i,f}$ e $\hat{a}_{i,f}$, com $i = 1, \dots, N$, formam k_p e a_p respectivamente, no caso da planta de ordem 1, ou coeficientes da combinação convexa que quando aplicados às estimativas $\hat{\theta}_{i,f}$, com $i = 1, \dots, N$, formam θ_p^* , no caso da planta SISO de ordem n
$\bar{\alpha}_f$	Vetor coluna formado pelos coeficientes $\alpha_{i,f}$ em suas linhas, com $i = 1, \dots, N$
$\bar{\alpha}_f^*$	Vetor coluna formado pelos coeficientes $\alpha_{i,f}^*$ em suas linhas, com $i = 1, \dots, N$
$\beta_{i,f}$	Coefficientes de uma combinação convexa que são aplicados às estimativas $\hat{k}_{i,f}$ e $\hat{a}_{i,f}$, com $i = 1, \dots, N$ para formar estimativas virtuais $\hat{a}_{v,f}$ e $\hat{k}_{v,f}$ dos parâmetros, no caso da planta de ordem 1, ou coeficientes da combinação convexa que são aplicados às estimativas $\hat{\theta}_{i,f}$, com $i = 1, \dots, N$, para formar uma estimativa virtual do vetor de parâmetros θ_p^* , no caso da planta SISO de ordem n

$\dot{\alpha}_f$	Lei adaptativa para atualização do vetor α_f
$\hat{\theta}_{n2,f}$	Estimativa de segundo nível do parâmetro θ_p^* da planta SISO de ordem n usando como base modelos de identificação por regressão linear
$\hat{a}_{n2,f}$	Estimativa de segundo nível do parâmetro a_p da planta de ordem 1 usando como base modelos de identificação por regressão linear
$\hat{k}_{n2,f}$	Estimativa de segundo nível do parâmetro k_p da planta de ordem 1 usando como base modelos de identificação por regressão linear
APPC	Adaptive Pole Placement Control - Controle adaptativo por posicionamento de polos
DMARC	Dual Mode Adaptive Robust Control - Controle em modo dual adaptativo robusto
IDMARC	Indirect Dual Mode Adaptive Robust Control - Controle em modo dual adaptativo robusto indireto
IMRAC	Indirect Model Reference Adaptive Control - Controle adaptativo por modelo de referência indireto
MMAC	Multiple Model Adaptive Control - Controle adaptativo baseado em múltiplos modelos
MRAC	Model Reference Adaptive Control - Controle adaptativo por modelo de referência
MRC	Model Reference Control - Controle por modelo de referência
PE	Persistently Exciting - Persistentemente excitante
PPC	Pole Placement Control - Controle por posicionamento de polos
SISO	Single Input Single Output - Sistema com apenas uma variável de entrada e uma variável de saída
SLA	Second Level Adaptation - Adaptação de segundo nível
SLAFF	Second Level Adaptation with Forgetting Factor - Adaptação de segundo nível com fator de esquecimento
VS-MRAC	Variable Structure Model Reference Adaptive Control - Controle adaptativo por modelo de referência e estrutura variável

Apresentação

Um sistema linear obedece ao princípio da superposição ao exibir as duas propriedades descritas abaixo:

- Homogeneidade (ou escalamento): A entrada é proporcional à saída. Para um aumento (ou diminuição) no valor do sinal de entrada, há uma variação diretamente proporcional da variável de saída em regime permanente;
- Aditividade: Se a soma de 2 ou mais sinais atua sobre a mesma entrada de um sistema linear, então o efeito total destes sinais sobre a saída pode ser determinado, considerando cada um dos sinais independentemente e somando os resultados.

Os sistemas que não obedecem a estas propriedades são chamados sistemas não-lineares.

Uma forma de lidar com processos e sistemas lineares ou não lineares é através do controle automático. O controle automático visa fazer com que algum conjunto de variáveis de processo se comporte dentro de certas especificações, através do ajuste automático de algum outro conjunto de variáveis manipuladas.

Variáveis de processo podem ser das mais diversas formas, como, por exemplo, medidas de fluxo sanguíneo em corações artificiais, medidas de tensão e corrente em motores de indução, medidas de posição e velocidade em drones, braços robóticos e esteiras e o nível de tanques e reservatórios. Assim, sua aplicação se dá em muitos campos, tais como as ciências médicas, as indústrias automotiva e aeroespacial e a fabricação de bens de consumo e componentes eletrônicos.

A melhoria das técnicas de controle automático faz com que seja possível atingir desempenhos aceitáveis, em alguns casos ótimos, numa classe cada vez maior de sistemas dinâmicos. Assim, o controle automático permite a substituição de mão de obra humana por máquinas, na realização de tarefas repetitivas e também na realização de tarefas onde um operador humano não é capaz de responder em tempo hábil, ou com a precisão e acurácia necessárias.

No controle automático, se projeta um dispositivo chamado controlador, um sistema projetado de tal forma que, ao atuar em conjunto ao sistema dinâmico a ser controlado, o desempenho do conjunto de sistemas esteja dentro de certas especificações. Assim, mediante a aplicação de um ou mais sinais ao controlador, este deve produzir um ou mais sinais capazes de estimular a planta ou processo dinâmico, fazendo com que o conjunto de

variáveis de processo tenda cada uma para o valor desejado como valor final, o chamado *setpoint*.

Em geral, um sistema físico exibe dinâmica, isto é, o efeito de um estímulo sobre uma planta não aparece instantaneamente em cada variável de processo. Um exemplo disto é que uma chaleira com água não ferve no instante que acendemos o fogão, devemos aguardar para que a temperatura da água (variável de processo) chegue ao valor desejado. O intervalo de tempo entre o instante em que o sistema começa a receber o estímulo (calor) e o instante em que, na prática, todas as variáveis de processo atingem seus valores finais e permanecem idênticos aos valores finais (ponto de fervura), é chamado de transitório. Quando todas as variáveis de processo se aproximam dos valores iguais aos finais e neles permanecem, diz-se que o sistema se encontra em regime permanente.

Um objetivo comum no projeto de controladores é o de atingir os valores desejados em regime permanente passando por um transitório que seja o mais rápido e menos oscilatório possível. De forma geral, os sistemas de controle podem ser classificados como:

- Sistema de Controle em Malha Aberta: No controle em malha aberta, o controlador é conectado em série com o processo a ser controlado. O controlador é alimentado com um conjunto de sinais de referência e, conseqüentemente, produz um conjunto de sinais de controle tal que as saídas do processo tendam para as saídas desejadas. Um sistema de controle em malha aberta se comporta da forma esperada somente se não ocorrer perturbação externa ou mudanças nos parâmetros do sistema. Se algum fator passa a atuar sobre o sistema, suas saídas serão afetadas, mas os sinais de controle permanecem nos mesmos valores independentemente disto. Representamos um sistema de controle em malha aberta na Figura 1.
- Sistema de Controle em Malha Fechada: Um sistema de controle em malha fechada mede os valores de variáveis de processo ou os valores dos modos do sistema e compara estes valores ao comportamento desejado. Desta forma o controle em malha fechada busca corrigir os valores dos sinais de controle, se algum fator passa a influir no sistema afetando as saídas ou modos internos. Representamos um sistema de controle em malha fechada na Figura 2.




Figura 1: Sistema de controle em malha aberta

Inicialmente, a teoria de controle se desenvolveu no sentido de abordar o problema do controle de sistemas lineares devido ao fato de estes obedecerem ao princípio da superposição. A análise matemática destes sistemas se revelou mais amena. Assim, um arcabouço teórico foi desenvolvido em torno do controle linear de sistemas lineares e uma literatura




Figura 2: Sistema de controle em malha fechada

extensa existe na área, como por exemplo (Ogata 2010, Chen 1999).

Um controlador linear tem seus parâmetros ajustados durante o projeto e eles permanecem constantes durante a operação. Há uma gama de métodos bem estabelecidos de projeto de controladores lineares para este tipo de sistema, tais como o lugar das raízes de (Evans 1948) e os métodos por resposta frequencial, como o critério apresentado em (Nyquist 1932).

No entanto, é raro que um sistema físico obedeça estritamente ao princípio da superposição dentro de toda sua faixa de operação. De fato, a maioria absoluta dos sistemas físicos exibe comportamento não-linear em algum grau. Por isso, para utilizar o arcabouço da teoria de controle de sistemas lineares, tipicamente o projetista se utiliza de modelos linearizados em torno do ponto de operação do sistema.

Com isso, à medida que o sistema se afasta do ponto de operação, o modelo linearizado deixa de ser válido e o controlador linear se torna incapaz de garantir as especificações sobre as variáveis de processo, pois seus parâmetros são fixos e podem não ser adequados para lidar com o novo ponto de operação.

De fato, sistemas lineares e não-lineares são qualitativamente diferentes e nem sempre é possível para um controlador linear lidar favoravelmente com não-linearidades. Diversos fenômenos que afetam sistemas não-lineares simplesmente não podem ocorrer em sistemas lineares (Khalil 1996). Um exemplo muito comum é a saturação: tipicamente a planta ou sistema de controle não pode produzir um sinal cujo módulo excede um determinado valor, devido às limitações físicas.

Além disto, o controle clássico aborda o projeto do controlador sob a hipótese de que os parâmetros que descrevem o sistema são constantes e conhecidos sem incertezas. Não obstante, sistemas físicos tipicamente apresentam variação em seus parâmetros devida ao desgaste, envelhecimento ou falhas. Além disso, normalmente os componentes de um sis-

tema têm valores nominais que são obedecidos dentro de uma certa tolerância, como, por exemplo, resistores e capacitores. Na prática sempre há alguma quantidade de incerteza acerca dos parâmetros do sistema.

Finalmente, o controle clássico busca lidar com sistemas que dispõem de apenas uma variável de entrada e uma variável de saída (Single Input Single Output - SISO). Muitos sistemas possuem um conjunto de mais de uma variável de saída ou de entrada, como é o caso de drones, que devem controlar simultaneamente elevação, velocidade, ângulos de rolagem, guinada e arfagem.

Assim, no sentido de superar estas limitações da teoria de controle clássica e abordar o projeto de controladores para sistemas cada vez mais complexos, a teoria de controle moderno desenvolve e apresenta técnicas de projeto de controladores não-lineares. Um exemplo de controlador não-linear é o controlador adaptativo, introduzido nos anos de 1950. Uma rica revisão do histórico do controle adaptativo pode ser vista em (Aström 2014).

No controle adaptativo, os parâmetros do controlador são ajustados de acordo com um mecanismo de estimação de parâmetros em tempo real. A partir de medidas de variáveis do sistema, como, por exemplo, sinal de controle e sinal de saída ou modos internos do sistema, é gerada uma lei de ajuste dos parâmetros.

O processo de estimação executado concorrentemente com o controle torna o controlador um sistema não-linear. Devido à não-linearidade, a análise dos sinais presentes no sistema em malha fechada se torna mais complexa. De fato, a primeira preocupação ao projetar este tipo de controlador deve ser em garantir a estabilidade do sistema em malha fechada. Para tanto, a análise de estabilidade do controlador adaptativo passou a utilizar de várias ferramentas matemáticas, em especial a teoria de Lyapunov, introduzida em sua dissertação de 1892 e publicada originalmente em russo. Uma das inúmeras traduções deste trabalho para o inglês é (Lyapunov 1992). A partir dos anos de 1960, esta teoria passou a ser utilizada amplamente para gerar leis de controle e comprovar a estabilidade de controladores adaptativos.

Hoje, entende-se que o controle adaptativo costuma apresentar bons resultados quando os parâmetros da planta são conhecidos com incertezas consideradas suficientemente pequenas e esses parâmetros variam mais lentamente, frente à capacidade do mecanismo de ajustar o controlador. O motivo disto é que, no controle adaptativo, faz-se uso do princípio de equivalência à certeza (Simon 1956). Assumimos que o processo de estimação faça com que o controlador busque se adaptar às circunstâncias de operação e tenda aos parâmetros que são adequados para aquelas condições de operação, atingindo um desempenho suficiente.

Assim, o desempenho do controle adaptativo depende, em parte, das características de velocidade, precisão e acurácia com que os parâmetros do controlador podem ser es-

timados frente a cada situação específica. Na maior parte dos casos, quanto mais rápido, preciso e acurado é o processo de estimação de parâmetros, melhor o desempenho.

O controle adaptativo possui duas estratégias, que são chamadas estratégia direta e estratégia indireta. Na estratégia direta, os parâmetros do controlador são estimados. A planta é parametrizada em função dos parâmetros ideais do controlador, que são aqueles que seriam calculados por um projetista, caso os parâmetros da planta fossem constantes e conhecidos sem incertezas. O erro da saída do sistema em relação ao comportamento desejado é avaliado e usado na lei de ajuste dos parâmetros do controlador.

A vantagem do controle adaptativo direto é que a estrutura do controlador é mais simples, em relação ao controle adaptativo indireto, o que facilita a implementação. Um exemplo de diagrama de blocos de um controlador adaptativo direto está na Figura 3.




Figura 3: Controlador adaptativo direto

Na abordagem indireta, um modelo de identificação do sistema é ajustado em tempo real de acordo com as informações provenientes da planta, tais como os sinais de controle e saída. O objetivo do modelo de identificação é estimar os parâmetros da planta por meio de alguma lei de ajuste, como o método do gradiente ou o método dos mínimos quadrados (Ljung 1999). Busca-se minimizar o erro de identificação entre a saída do modelo e a saída da planta. Considera-se que os parâmetros estimados da planta são os parâmetros verdadeiros e estes parâmetros são usados para realizar o cálculo dos parâmetros do controlador.

O controle adaptativo indireto sofre a desvantagem por ser uma estratégia mais complexa, porém, permite utilizar o conhecimento prévio sobre os parâmetros da planta mais facilmente para inicializar os parâmetros do modelo de identificação. Além disso há uma separação clara entre o processo de estimação dos parâmetros da planta e o ajuste dos parâmetros do controlador, que torna o entendimento da estratégia indireta mais intuitivo. Um exemplo de diagrama de blocos de um controlador adaptativo indireto está na Figura 4.




Figura 4: Controlador adaptativo indireto

Como mencionamos, o controle busca garantir o atendimento de especificações sobre um conjunto de variáveis de processo, por meio do ajuste de outro conjunto de variáveis manipuladas. Estas especificações podem ser traduzidas na forma de um modelo de referência, um sistema que se comporta da forma desejada em malha aberta, ao ser alimentado por um sinal de referência.

O objetivo do controle por modelo de referência (MRC - *Model Reference Control*) é o de projetar um controlador que faça com que o sistema de controle em malha fechada

com a planta tenha sua função de transferência equivalente à do modelo de referência em malha aberta. O modelo de referência especifica a trajetória que as variáveis de processo devem seguir durante o transitório e os seus valores em regime permanente.

Com este intuito, o controlador é projetado para atingir a chamada condição de *matching*, onde os zeros da planta são cancelados por polos do controlador e substituídos pelos zeros do modelo de referência, e os polos da função de transferência em malha fechada se tornam os polos da função de transferência do modelo de referência.

Devido ao cancelamento dos zeros da planta, o MRC sofre limitação, sendo aplicável apenas às plantas de fase mínima, isto é, cujos zeros se encontram no semi plano esquerdo aberto do plano complexo. Isto ocorre pois, na prática, o cancelamento de raízes no semi plano direito aberto está sempre sujeito a erro numérico, cujo resíduo pode levar, facilmente, à instabilidade.

Outra forma de atender especificações é através da determinação, pelo projetista, de um polinômio desejado para o denominador da função de transferência da planta em malha fechada. Desta forma, o controlador passa a ser responsável apenas por posicionar os polos da função de transferência em malha fechada, sem cancelamento de zeros, e seus parâmetros são calculados através da resolução de uma equação diofantina. Este tipo de controle é chamado de controle por posicionamento de polos (PPC - *Pole Placement Control*).

Entre o MRC e o PPC, o PPC é a forma mais geral de controle pois se aplica às plantas de fase não mínima. Em contrapartida, as especificações garantidas pelo MRC são mais estritas, pois o projetista tem os zeros da função de transferência em malha fechada à sua disposição para posicionar e, assim, conseguir o comportamento desejado na saída da planta. De forma mais detalhada, a diferença entre os dois é de que o projetista que utiliza o PPC pode especificar quais constantes de tempo aparecerão nas exponenciais que representam a resposta ao impulso $h(t)$ da planta em malha fechada, mas não consegue especificar os valores das constantes multiplicando estas exponenciais. O MRC especifica tanto as constantes de tempo quanto as constantes que multiplicam as exponenciais, sendo capaz de especificar completamente o comportamento de $h(t)$.

Uma das estratégias de controle que pode ser empregada dentro do paradigma do controle adaptativo é o controle adaptativo por modelo de referência (MRAC - *Model Reference Adaptive Control*). Usando as equações obtidas a partir da condição de *matching*, podemos estimar, direta ou indiretamente, os parâmetros do controlador. Quando o MRAC é utilizado com estratégia indireta, nos referimos a ele por IMRAC (*Indirect Model Reference Adaptive Control*).

No controle adaptativo convencional, as leis de ajuste para os parâmetros são leis integrais, isto é, a cada instante o valor da lei de ajuste é integrado ao valor atual das estimativas. Isto produz estimativas contínuas no tempo. No entanto, em muitos casos, a lei

de ajuste integral do controle adaptativo convencional acaba não sendo suficientemente rápida em relação à dinâmica do sistema em que está sendo aplicada. De fato, quando este é o caso, o transitório do sistema se torna lento e oscilatório.

Além disso, quando a planta apresenta dinâmica não modelada ou é sujeita a distúrbios externos, o sistema não apresenta robustez (Rohrs et al. 1985, Costa & Hsu 1991). Para recuperar essa robustez, se fazem necessárias modificações nas leis de ajuste integral que, em geral, tornam ainda mais lento o ajuste das estimativas, limitando a classe de sistemas para os quais o controle adaptativo convencional é, na prática, aplicável.

Dessa forma, uma ideia que emergiu na área de controle adaptativo, a partir do final dos anos de 1980, foi a de substituir as leis de ajuste integrais do controle adaptativo convencional por leis chaveadas, provenientes da teoria de sistemas com estrutura variável (Hsu & Costa 1989, Hsu 1990, Hsu et al. 1994, Oliveira 2003, Oliveira 2007, Oliveira & Araujo 2008a, Oliveira & Araujo 2008b, Fernandes et al. 2010).

Os sistemas com estrutura variável (Utkin 1977, Utkin 1978) são baseados no controle à relé, com chaveamento do sinal de controle, isto é, o sinal de controle varia de forma abrupta entre um conjunto de valores. O sinal de controle restringe a dinâmica das variáveis de estado da planta a uma superfície, chamada superfície de deslizamento (Yanque et al. 2012, Teixeira et al. 2015).

Ao substituir as leis integrais por leis chaveadas, as estimativas dos parâmetros da planta ou controlador passam a ter um conjunto finito de valores que podem ser assumidos, ou seja, as estimativas não variam gradualmente. Em vez disso, a cada instante a lei chaveada decide qual valor é o adequado para cada parâmetro. Assim, como uma forma de controle à relé, no controle adaptativo com estrutura variável há um chaveamento do sinal de controle.

Este chaveamento dá ao controle adaptativo por estrutura variável características desejáveis, tais como a rejeição à dinâmica não modelada e a distúrbios limitados, e a convergência do comportamento da planta para o desejado em tempo finito para plantas com grau relativo unitário, sendo que esta última não é possível no caso convencional, mesmo quando os parâmetros da planta são conhecidos sem incertezas. Em contrapartida, o sinal de controle passa a exibir o fenômeno do *chattering*, no qual passa a chavear com frequência arbitrariamente alta.

Há uma classe de sistemas dinâmicos para os quais um sinal de controle com *chattering* não é aplicável, o que motivou uma série de pesquisas que buscaram aproveitar as características desejáveis do controle por estrutura variável, porém suavizando o sinal de controle em regime permanente.

Uma ideia que vem sendo bastante explorada recentemente é a de projetar um controlador em modo dual, aproveitando as características de transitório do controle por estru-

tura variável e o sinal de controle suave das leis convencionais em regime permanente, o chamado controle em modo dual adaptativo robusto (DMARC - *Dual Mode Adaptive Robust Control*)(Cunha et al. 2007, Cunha 2008, Cunha et al. 2009, Teixeira 2011, Teixeira et al. 2013, Teixeira 2016).

O tema deste trabalho não é o controle por estrutura variável. Apesar disto, mencionamos o mesmo para termos uma base de comparação para a técnica de estimação de parâmetros que iremos estudar, a adaptação de segundo nível (SLA - *Second Level Adaptation*). Assim como o controle por estrutura variável, a SLA se propõe a lidar com incertezas paramétricas maiores em relação às que o controle adaptativo convencional pode abordar.

Como vimos, o controle adaptativo indireto necessita ajustar os parâmetros de um modelo de identificação da planta em tempo real, parâmetros estes que são utilizados para calcular, por sua vez, os parâmetros do controlador.

Um modelo de identificação é um sistema virtual que buscamos tornar equivalente à alguma parametrização válida da planta. Para tanto assumimos conhecer a forma da função de transferência da planta ou a forma de sua representação em espaço de estado e usamos estas informações na criação do modelo de identificação.

O modelo de identificação usado neste trabalho é chamado modelo de identificação por regressão linear. Neste, busca-se fazer com que o sinal de saída do modelo de identificação seja equivalente ao sinal de saída da planta filtrado por uma função de transferência específica. Esta filtragem é feita pois o sinal filtrado pode ser parametrizado como uma combinação linear dos componentes de um vetor, chamado vetor regressor, o qual pode também ser gerado por filtragem dos sinais de saída e entrada da planta.

Os coeficientes desta combinação linear são os coeficientes dos polinômios do numerador e do denominador da função de transferência da planta. Assim, no modelo de identificação por regressão linear, estimamos os coeficientes dos polinômios da função de transferência da planta.

No modelo de identificação por regressão linear, desde que seja possível estabilizar o sistema através de uma ação de controle, o modelo de identificação é estável. Um diagrama de blocos do modelo de identificação por regressão linear se encontra disponível na Figura 5.

Este trabalho trata de controle adaptativo indireto por modelo de referência, baseado em múltiplos modelos de identificação do processo a ser controlado. Escolhemos o MRC em oposição ao PPC, pois, apesar de possuir uma restrição em relação a plantas de fase não-mínima, o comportamento desejado da planta pode ser especificado mais detalhadamente, já que os zeros da função de transferência em malha fechada da planta com o controlador são posicionados, como foi dito anteriormente.




Figura 5: Modelo de identificação por regressão linear

O controle adaptativo encontra aplicação quando há incertezas paramétricas no sistema a ser controlado. Em particular, na estratégia indireta, os parâmetros da planta são estimados por meio de um modelo de identificação e as estimativas dos parâmetros da planta são utilizadas para calcular os parâmetros do controlador a cada instante. Neste contexto, nos propomos a estudar o método de estimação de parâmetros conhecido como adaptação de segundo nível (SLA - *Second Level Adaptation*) e introduzimos uma variante deste método, que nomeamos adaptação de segundo nível com fator de esquecimento (SLAFF - *Second Level Adaptation with Forgetting Factor*).

O desempenho do controle adaptativo depende, em parte, da velocidade, precisão e acurácia com que os parâmetros do controlador são estimados. Na SLA as estimativas dos parâmetros da planta são entregues por combinações convexas dos parâmetros de múltiplos modelos de identificação. Os coeficientes destas combinações convexas são, por sua vez, estimados como um segundo nível de adaptação.

A motivação desta escolha de objeto de estudo é a de que a SLA apresenta uma velocidade de convergência dos parâmetros maior e, portanto, sua aplicação ao controle adaptativo leva possivelmente a um controlador com melhor desempenho.

Estrutura do Trabalho

Este trabalho está organizado como segue:

No Capítulo 1 será feito o embasamento teórico dos assuntos necessários à uma melhor compreensão deste trabalho.

O Capítulo 2 contém o caso da SLA como método de estimação de parâmetros aplicado a uma planta de ordem 1 e grau relativo unitário. Primeiramente introduzimos o modelo de identificação por regressão linear, mostrando as leis de ajuste para seus parâ-

metros e demonstrando a estabilidade do processo de estimação, sem normalização. A seguir, discutimos a propriedade do fecho convexo e demonstramos como aplicar o conceito de SLA. Demonstramos a estabilidade do estimador resultante. Introduzimos uma modificação na SLA de forma a garantir convergência dos parâmetros sem sinal PE, para condições iniciais nulas, que ajuda a embasar, posteriormente, a introdução da SLAFF no Capítulo 4. Disponibilizamos as equações necessárias de forma compacta em tabela no final do Capítulo e realizamos a aplicação de cada um destes conceitos em estudos de simulação, de forma que o leitor possa comparar os resultados.

No Capítulo 3, mostramos a condição de *matching* para o IMRAC de uma planta de ordem 1 e grau relativo unitário. A partir da condição de *matching* e das estimativas dos parâmetros da planta, os parâmetros do controlador adaptativo são calculados, na estratégia indireta. Finalmente, realizamos estudos de simulação comparando o método do gradiente e a SLA aplicados ao IMRAC e o VS-MRAC na estratégia direta.

O Capítulo 4 contém o caso da SLA como método de estimação de parâmetros para uma planta de ordem n e grau relativo unitário. Novamente introduzimos o modelo por regressão linear, mostramos sua lei de ajuste para os parâmetros e demonstramos a estabilidade do processo de estimação para cada um dos modelos, desta vez com normalização. Discutimos a propriedade do fecho convexo e aplicamos o conceito de SLA. Demonstramos a estabilidade do estimador resultante. Introduzimos a SLAFF e demonstramos a estabilidade desta variante da SLA como estimador de parâmetros. Disponibilizamos as equações necessárias de forma compacta em tabela no final do Capítulo e aplicamos cada um dos conceitos mostrados em estudos de simulação comparativos.

No Capítulo 5, mostramos a condição de *matching* do MRC para uma planta de ordem n e grau relativo unitário. A partir da condição de *matching* e das estimativas dos parâmetros da planta, os parâmetros do controlador adaptativo são calculados, na estratégia indireta. Finalmente, realizamos estudos de simulação comparando o método do gradiente, SLA e SLAFF aplicados ao IMRAC e o VS-MRAC na estratégia direta.

No Capítulo 6 concluímos discutindo o que foi feito e perspectivas futuras.

Capítulo 1

Introdução

Como vimos na apresentação, o controle adaptativo costuma apresentar bons resultados quando a incerteza é suficientemente pequena e o mecanismo de estimação é suficientemente rápido. Nesse contexto, o controle adaptativo baseado em múltiplos modelos busca lidar com incertezas maiores acerca dos parâmetros da planta ou com variação paramétrica mais rápida.

Nos anos 90, foram feitas propostas de controle adaptativo baseado em múltiplos modelos através do chaveamento entre modelos de identificação inicializados com parâmetros diferentes, com alguns modelos tendo parâmetros fixos e outros, ajustados por leis integrais (Narendra & Balakrishnan 1994, Narendra et al. 1995, Narendra & Balakrishnan 1997).

Apesar de exibir bons resultados de simulação, essa técnica apresenta uma limitação, pois se baseia na ideia de que os parâmetros de pelo menos um modelo devem estar localizados suficientemente próximos dos parâmetros da planta, fazendo com que seja necessário utilizar um grande número de modelos para atingir um bom desempenho, o que depende exponencialmente da ordem da planta. Em consequência, plantas de ordem maior necessitariam de uma quantidade proibitiva de modelos inicializados de tal forma a garantir que os parâmetros da planta estivessem em uma vizinhança pequena de algum deles.

Mais recentemente, no entanto, em (Han & Narendra 2011), a SLA foi introduzida como um novo conceito ao controle adaptativo baseado em múltiplos modelos de identificação. Utilizando a informação de cada um dos modelos é formada uma combinação dos parâmetros, que é utilizada como estimativa dos parâmetros da planta.

Em vez de necessitar de um número de modelos que cresce exponencialmente com a ordem da planta para garantir um bom desempenho, a SLA necessita de um número que cresce linearmente.

Em (Narendra & Han 2010) foi estabelecido, para um caso particular, que um modelo de identificação virtual cujos parâmetros são formados por uma combinação convexa dos

parâmetros de múltiplos modelos de identificação se comporta, dentro de certas circunstâncias, de forma idêntica a um modelo de identificação inicializado com os mesmos valores de parâmetros.

Consequentemente, uma combinação convexa dos parâmetros de múltiplos modelos de identificação pode ser utilizada como estimativa dos parâmetros da planta. De fato, se os parâmetros da planta pertencem ao interior ou fronteira de um fecho convexo formado pelos parâmetros dos modelos de identificação, então os parâmetros da planta permanecerão na fronteira ou interior desse fecho convexo, independentemente do ajuste dos parâmetros dos modelos de identificação.

Esta propriedade pode, então, ser explorada, pois além do ajuste dos parâmetros dos modelos de identificação, podemos, concorrentemente, estimar os coeficientes da combinação convexa referente aos parâmetros verdadeiros da planta.

Em um segundo nível de estimação, ou segunda camada de adaptação, busca-se estimar os coeficientes de uma combinação convexa de múltiplos modelos de identificação, para que essa combinação convexa tenda aos valores verdadeiros dos parâmetros da planta. Ao mesmo tempo, os parâmetros dos modelos de identificação também são ajustados. Passamos a chamar os modelos de identificação de modelos de primeiro nível.

Devido à propriedade do fecho convexo discutida anteriormente, é possível obter uma lei de ajuste para as estimativas dos coeficientes da combinação convexa, baseada nos erros de identificação dos modelos. Com isso, a SLA entrega as estimativas dos parâmetros da planta como combinações convexas (a) de coeficientes variantes no tempo e (b) dos parâmetros de múltiplos modelos de identificação, também variantes no tempo.

A SLA como método de estimação de parâmetros é muito mais rápida em atingir os parâmetros verdadeiros (Han & Narendra 2011, Han & Narendra 2012, Narendra et al. 2012, Narendra et al. 2014, Narendra et al. 2015, Gushiken & Araujo 2016), em relação aos métodos de estimação convencionais, pelo fato de que as informações provenientes de múltiplas fontes são utilizadas e combinadas.

Como mencionamos inicialmente, este trabalho tem como um de seus objetivos estudar a SLA, começando pela caracterização do modelo de identificação por regressão linear e sua lei de ajuste, passando à investigação sobre a propriedade do fecho convexo para este modelo de identificação e, finalmente, à aplicação do conceito de SLA como método de estimação de parâmetros.

Adicionalmente, como contribuição deste trabalho, realizamos uma modificação na lei de ajuste dos coeficientes da SLA e que chamamos adaptação de segundo nível com fator de esquecimento, à qual nos referimos por SLAFF (*Second Level Adaptation with Forgetting Factor*), que levou a uma convergência mais rápida e suave dos parâmetros para seus valores corretos em estudos de simulação no Capítulo 4.

O diagrama ilustra um sistema de controle adaptativo com identificação de modelo. O processo é o seguinte:

- A referência $r(t)$ é fornecida ao **Sistema de Controle** e ao bloco de **Realimentação**.
- O **Sistema de Controle** envia um sinal para a **Planta**.
- A **Planta** produz a saída $y(t)$.
- A saída $y(t)$ é realimentada diretamente para o **Sistema de Controle** e também para o bloco de **Realimentação**.
- Simultaneamente, a saída $y(t)$ é enviada para o **Conjunto de Modelos de Identificação da Planta**.
- O **Conjunto de Modelos de Identificação da Planta** fornece estimados $\hat{y}_{i,f}(t)$ para o bloco de **Ajuste dos Parâmetros dos Modelos**.
- O bloco de **Ajuste dos Parâmetros dos Modelos** também recebe a saída $y(t)$ e envia sinais para o **Ajuste dos Coeficientes da Combinação** e para o **Conjunto de Modelos de Identificação da Planta**.
- O **Ajuste dos Coeficientes da Combinação** recebe a saída $y(t)$ e envia sinais para o **Sistema de Controle** e para o **Conjunto de Modelos de Identificação da Planta**.
- O **Conjunto de Modelos de Identificação da Planta** também envia um sinal para o **Sistema de Controle**.

Figura 1.1: Controlador adaptativo indirecto de segundo nivel

Capítulo 2

Estimação de Parâmetros, Ordem 1

2.1 Introdução

Ao modelar um sistema dinâmico como um sistema linear descrito por uma função de transferência, é comum lidar com incertezas nos coeficientes dos polinômios do numerador e denominador desta função, as chamadas incertezas paramétricas.

As incertezas paramétricas têm vários fatores, dentre os quais estão: a falta de conhecimento completo sobre componentes físicos, cujos valores tipicamente se encontram dentro de uma certa tolerância, como resistores, capacitores, amortecedores, indutores; as aproximações na modelagem devido à eventual não-linearidade dos sistemas; variações dos parâmetros devido ao desgaste ou envelhecimento, como, por exemplo, uma engrenagem cujos dentes se desgastam com o uso ou o óleo de um motor de automóvel cuja viscosidade aumenta com o tempo; e, também, devido às falhas de componentes como um transformador danificado por sobretensão na linha de transmissão.

Uma forma de abordar o problema das incertezas paramétricas de modo a melhorar o conhecimento sobre a dinâmica atual do sistema é através da estimação dos parâmetros em tempo real, que permite um conhecimento mais preciso dos parâmetros. Isto, por sua vez, pode permitir decisões melhores acerca de qual ação de controle tomar.

Através de um modelo de estimação em tempo real do sistema estudado, gera-se a diferença entre o sinal de saída do sistema e o sinal de saída do modelo de estimação, o chamado erro de identificação. Este erro pode ser empregado para gerar leis integrais para atualizar as estimativas, que faz com que elas se aproximem dos valores corretos em regime permanente. Com isso, também, o erro de identificação tende a um valor nulo.

Quando um sistema linear é sujeito a um sinal de entrada com a característica de persistência de excitação, existe garantia de convergência das estimativas dos parâmetros para seus valores corretos (Boyd & Sastry 1986, Narendra & Annaswamy 1987, Bitmead 1984). O modelo de estimação se torna, então, um modelo de identificação pois eventualmente seus parâmetros serão idênticos aos parâmetros do sistema linear e não apenas estimativas próximas. Um exemplo de sinal persistentemente excitante (PE - *Persistently*

Exciting) de ordem 1 é um sinal senoidal contendo pelo menos uma frequência.

Apresentamos primeiramente um caso simples, da planta de ordem 1 e grau relativo unitário, por motivos didáticos, para que o leitor possa se familiarizar com as técnicas e conceitos discutidos, da forma como é feito na literatura como por exemplo em (Narendra & Annaswamy 1989, Ioannou & Sun 1996, Tao 2003).

Neste Capítulo descreveremos o modelo de identificação por regressão linear, cujos parâmetros podem ser atualizados por leis integrais para identificar os parâmetros da função de transferência de uma planta de ordem 1 e grau relativo 1, e chamaremos esse modelo de modelo de primeiro nível. Para garantir a convergência dos parâmetros usaremos um sinal de referência na entrada da planta com persistência de excitação de ordem 1. Provaremos a estabilidade do estimador de parâmetros para tal modelo.

A descrição do modelo de identificação por regressão linear serve como uma introdução para que se possa discutir a técnica de estimação de parâmetros chamada SLA, que foi introduzida por Han e Narendra em (Han & Narendra 2011), com base em propriedades mostradas pelos mesmos autores em 2010, com resultados estendidos para o caso SISO (Narendra et al. 2015).

Na SLA, os coeficientes de uma combinação linear convexa das estimativas dos parâmetros da planta vindas de múltiplos modelos de identificação de primeiro nível são atualizados por leis integrais com uma segunda camada de adaptação. Isto traz uma vantagem em termos de rapidez de convergência dos parâmetros, como foi extensivamente demonstrado na literatura (Han & Narendra 2012, Narendra et al. 2012, Narendra et al. 2014) e se deve ao fato de que a informação proveniente dos múltiplos modelos é combinada.

Após a descrição dos métodos de identificação de parâmetros, fizemos estudos de simulação utilizando cada um destes métodos, discutindo seus resultados.

2.2 Descrição do Problema

Considere a seguinte planta LIT de ordem 1 e grau relativo unitário, descrita pela função de transferência:

$$\Sigma_p : G(s) = \frac{y(s)}{u(s)} = \frac{k_p}{s + a_p} \quad (2.1)$$

onde sabe-se que $G(s)$ é estritamente própria e os parâmetros $k_p \in [k_p^-, k_p^+]$, $k_p^+ > 0$ e $k_p^- > 0$ ou $k_p^+ < 0$ e $k_p^- < 0$ e $a_p \in [a_p^-, a_p^+]$, $a_p^+ > 0$ e $a_p^- > 0$ têm limitantes inferiores e superiores, $k_p^+, k_p^-, a_p^+, a_p^-$, que são conhecidos; y é o sinal de saída da planta e u é o sinal de entrada da planta, ambos contínuos por partes. Note-se que utilizamos a planta estável, cujo polo pertence ao semi-plano esquerdo do plano complexo, para limitar a

complexidade do problema tratado inicialmente. Poderíamos colocar como condição, alternativamente, que o sinal $u(t)$ é tal que a saída da planta é uniformemente limitada.

O objetivo da identificação de parâmetros é, a partir dos sinais disponíveis para medição no sistema, determinar quais os valores dos parâmetros a_p e k_p . Inicialmente, consideramos que os sinais disponíveis são suficientes para realizar esta tarefa, o que se traduz na condição de que o sinal de entrada da planta seja uniformemente limitado e que seja capaz de excitar seus modos de forma persistente, ou seja, que $u(t)$ seja PE. Um exemplo de sinal PE de ordem 1 é um sinal senoidal contendo pelo menos uma frequência.

2.3 Identificação Paramétrica Convencional

Ao manipular a função de transferência da planta, podemos escrever, no domínio da frequência, que:

$$sy(s) = -a_p y(s) + k_p u(s) \quad (2.2)$$

Definimos, então, o seguinte polinômio:

$$\Lambda(s) \triangleq s + \lambda \quad (2.3)$$

com $\lambda > 0$ e escrevemos a partir de 2.2:

$$\frac{s}{\Lambda(s)} y(s) = -a_p \frac{1}{\Lambda(s)} y(s) + k_p \frac{1}{\Lambda(s)} u(s) \quad (2.4)$$

Então, definimos os seguintes sinais:

$$\begin{aligned} z(s) &\triangleq \frac{s}{\Lambda(s)} y(s) \\ \phi_1(s) &\triangleq \frac{-y(s)}{\Lambda(s)} \\ \phi_2(s) &\triangleq \frac{u(s)}{\Lambda(s)} \\ \phi(s) &\triangleq \begin{bmatrix} \frac{-y(s)}{\Lambda(s)} & \frac{u(s)}{\Lambda(s)} \end{bmatrix}^T = [\phi_1 \quad \phi_2]^T \end{aligned} \quad (2.5)$$

onde é possível gerar ϕ , ao filtrarmos $y(t)$ e $u(t)$:

$$\begin{aligned} \dot{\phi}_1 &= -\lambda \phi_1 - y \\ \dot{\phi}_2 &= -\lambda \phi_2 + u \end{aligned} \quad (2.6)$$

que, a partir de 2.4, resulta na seguinte parametrização:

$$z(s) = [a_p \quad k_p] \phi \quad (2.7)$$

e podemos notar que z depende de uma combinação linear dos componentes do vetor ϕ ,

cujos coeficientes são os parâmetros do denominador e numerador da função de transferência da planta a_p e k_p .

Podemos gerar z da seguinte forma:

$$z = s \frac{y}{\Lambda(s)} = y - \frac{\lambda y}{\Lambda(s)} = y + \lambda \phi_1 \quad (2.8)$$

Criamos, então, um modelo de identificação a partir de uma combinação linear dos sinais componentes do vetor ϕ :

$$\Sigma_{1,f} : \hat{z}_1 = [\hat{a}_{1,f} \quad \hat{k}_{1,f}] \phi \quad (2.9)$$

e temos agora um modelo cujos parâmetros desejamos ajustar, tal que tendam aos parâmetros da planta.

Queremos que a saída deste modelo se comporte identicamente ao sinal $z(t)$. Portanto, devemos avaliar a diferença entre o sinal de saída do modelo e o sinal z .

Definimos, então, um erro de identificação:

$$e_{1,f} \triangleq \hat{z}_1 - z \quad (2.10)$$

O sinal filtrado da saída da planta e seu modelo de identificação podem ser representados pelas equações diferenciais:

$$\begin{aligned} \dot{z} &= -\lambda z - a_p y + k_p u \\ \dot{\hat{z}}_1 &= -\lambda \hat{z}_1 - \hat{a}_{1,f} y + \hat{k}_{1,f} u - \hat{a}_{1,f} \phi_1 + \hat{k}_{1,f} \phi_2 \end{aligned} \quad (2.11)$$

Para avaliar a dinâmica do erro $\dot{e}_{1,f} = \dot{\hat{z}}_1 - \dot{z}$, pode-se substituir $\dot{z}$ e $\dot{\hat{z}}_1$ pelas expressões em 2.11. Assim, a dinâmica de $e_{1,f}$ é dada por:

$$\dot{e}_{1,f} = -\lambda \hat{z}_1 - \hat{a}_{1,f} y + \hat{k}_{1,f} u + \lambda z + a_p y - k_p u - \hat{a}_{1,f} \phi_1 + \hat{k}_{1,f} \phi_2 \quad (2.12)$$

Definimos os erros paramétricos, para simplificar a expressão 2.12:

$$\begin{aligned} \tilde{a}_{1,f} &\triangleq \hat{a}_{1,f} - a_p \\ \tilde{k}_{1,f} &\triangleq \hat{k}_{1,f} - k_p \end{aligned} \quad (2.13)$$

tal que:

$$\dot{e}_{1,f} = -\lambda e_{1,f} - \tilde{a}_{1,f} y + \tilde{k}_{1,f} u - \hat{a}_{1,f} \phi_1 + \hat{k}_{1,f} \phi_2 \quad (2.14)$$

Para analisar o comportamento deste sistema, usamos uma candidata a função de Lyapunov definida positiva da forma:

$$V(e_{1,f}, \tilde{a}_{1,f}, \tilde{k}_{1,f}) = \frac{1}{2} (e_{1,f}^2 + \tilde{a}_{1,f}^2 + \tilde{k}_{1,f}^2) \quad (2.15)$$

Derivamos ao longo das trajetórias de V , obtendo a seguinte expressão:

$$\begin{aligned}\dot{V} &= e_{1,f}\dot{e}_{1,f} + \tilde{a}_{1,f}\dot{\tilde{a}}_{1,f} + \tilde{k}_{1,f}\dot{\tilde{k}}_{1,f} \\ &= -\lambda e_{1,f}^2 - \tilde{a}_{1,f}e_{1,f}y + \tilde{k}_{1,f}e_{1,f}u + \tilde{a}_{1,f}\dot{\tilde{a}}_{1,f} + \tilde{k}_{1,f}\dot{\tilde{k}}_{1,f} - \dot{\tilde{a}}_{1,f}e_{1,f}\phi_1 + \dot{\tilde{k}}_{1,f}e_{1,f}\phi_2\end{aligned}\quad (2.16)$$

Como a planta é invariante no tempo, temos que:

$$\begin{aligned}\tilde{a}_{1,f} &= \hat{a}_{1,f} - a_p \rightarrow \dot{\tilde{a}}_{1,f} = \dot{\hat{a}}_{1,f} - \dot{a_p} \overset{0}{=} \dot{\hat{a}}_{1,f} \\ \tilde{k}_{1,f} &= \hat{k}_{1,f} - k_p \rightarrow \dot{\tilde{k}}_{1,f} = \dot{\hat{k}}_{1,f} - \dot{k_p} \overset{0}{=} \dot{\hat{k}}_{1,f}\end{aligned}$$

ou seja, a variação do erro paramétrico em relação ao tempo é idêntica à variação das próprias estimativas $\hat{a}_{1,f}$ e $\hat{k}_{1,f}$.

Este fato, em conjunto com 2.16 nos permite, então, escolher leis integrais para atualizar $\hat{a}_{1,f}$ e $\hat{k}_{1,f}$:

$$\begin{aligned}\dot{\hat{a}}_{1,f} &= e_{1,f}y \\ \dot{\hat{k}}_{1,f} &= -e_{1,f}u\end{aligned}\quad (2.17)$$

de forma que temos a seguinte expressão para $\dot{V}$:

$$\dot{V}(e_{1,f}, \tilde{a}_{1,f}, \tilde{k}_{1,f}) = -(\lambda + y\phi_1 + u\phi_2)e_{1,f}^2 \quad (2.18)$$

A região de incerteza que contém os parâmetros da planta é conhecida, assim como o sinal dos parâmetros, e, desta forma, para uma frequência de sinal de entrada qualquer, sabemos que o módulo da função de transferência da planta cumpre a seguinte restrição:

$$|G(jw)| \leq \left| \frac{k_p^+}{jw + a_p^-} \right| \quad (2.19)$$

e, portanto, desde que o sinal u seja uniformemente limitado e a planta seja estável, podemos garantir a seguinte condição:

$$\lambda > y\phi_1 + u\phi_2 \quad (2.20)$$

pois pode-se escolher λ maior que o supremo da soma dos módulos dos sinais $y\phi_1$ e $u\phi_2$.

As funções de transferência para ϕ_1 e ϕ_2 representam filtros passa-baixa de primeira ordem. O maior ganho de amplitude que um filtro passa-baixa de primeira ordem pode impor a um sinal é quando a frequência do sinal é nula. Devido a isto podemos escrever:

$$\begin{aligned}\sup(|y|) &\leq \sup(|u|) \left| \frac{k_p^+}{jw + a_p^-} \right| \\ \sup(|\phi_1|) &\leq \frac{\sup(|u|)}{\lambda} \left| \frac{k_p^+}{jw + a_p^-} \right| \\ \sup(|\phi_2|) &\leq \frac{\sup(|u|)}{\lambda}\end{aligned}$$

Temos, devido ao resultado acima, que a escolha de λ que cumpre:

$$\lambda > \sup(|u|) \sqrt{\left| \frac{k_p^+}{jw + a_p^-} \right| + 1} \quad (2.21)$$

será suficiente para garantir que $\dot{V}$ seja semi-definida negativa. Com isso, V não pode crescer (ver C.2), implicando em:

$$\begin{aligned}e_{1,f} &\in \mathcal{L}_\infty \\ \tilde{a}_{1,f} &\in \mathcal{L}_\infty \rightarrow \hat{a}_{1,f} \in \mathcal{L}_\infty \\ \tilde{k}_{1,f} &\in \mathcal{L}_\infty \rightarrow \hat{k}_{1,f} \in \mathcal{L}_\infty\end{aligned}$$

O sinal de controle u deve ser escolhido tal que seja capaz de excitar a planta persistentemente e seja uniformemente limitado e contínuo por partes, como mencionamos anteriormente.

Devido ao fato de que a planta é estável e u é uniformemente limitado, os sinais y e ϕ_2 são uniformemente limitados. Como o sinal y é uniformemente limitado, isto implica em ϕ_1 uniformemente limitado, que implica em z uniformemente limitado. Como $e_{1,f}$ e z são uniformemente limitados, isto implica em $\hat{z}_1$ uniformemente limitado. Como $e_{1,f}$, y e u são uniformemente limitados, isto implica em $\hat{a}_{1,f}$ e $\hat{k}_{1,f}$ uniformemente limitados. Finalmente, a partir de 2.14, podemos concluir que $\dot{e}_{1,f}$ é uniformemente limitado, pois todos os outros sinais presentes na expressão são uniformemente limitados.

Então, manipulamos a equação 2.18:

$$\begin{aligned}e_{1,f}^2 &= -\frac{1}{\lambda + y\phi_1 + u\phi_2} \dot{V} \\ \int_0^\infty e_{1,f}^2 &\leq -\frac{1}{\lambda - \sup(|y\phi_1|) - \sup(|u\phi_2|)} \int_0^\infty \dot{V} \\ \int_0^\infty e_{1,f}^2 &\leq \frac{1}{\lambda - \sup(|y\phi_1|) - \sup(|u\phi_2|)} (V(0) - V(\infty))\end{aligned}$$

o que nos permite concluir que:

$$e_{1,f} \in \mathcal{L}_2$$

A partir de um corolário do Lema de Barbalat (ver C.4.4), como $e_{1,f}$ é uniformemente limitado, pertence ao $\mathcal{L}_2$ e sua derivada é uniformemente limitada, temos que:

$$\lim_{t \rightarrow \infty} e_{1,f} = 0$$

e a saída $\hat{z}_1$ do modelo de identificação tende assintoticamente para z . Em outros termos, a saída do modelo de identificação tende a se comportar como a saída da planta filtrada.

Por fim, quando o sinal de controle u é PE, $e_{1,f} = 0$ para todo tempo $t > t_0$, se e somente se $\tilde{a}_{1,f} = 0$ e $\tilde{k}_{1,f} = 0$. Assim, as estimativas $\hat{a}_{1,f}$ e $\hat{k}_{1,f}$ devem tender aos valores corretos a_p e k_p , respectivamente, para $t \rightarrow \infty$, fato que não demonstraremos nesta Seção.

É importante notar que, ao usarmos o modelo de identificação por regressão linear, o valor de $\dot{V}$ depende de $\hat{\lambda}$ que é um parâmetro de projeto do estimador. Desse modo, a velocidade de convergência de $e_{1,f}$ para 0 depende de um parâmetro de projeto. $\hat{z}_1$ é gerado a partir de uma combinação linear dos componentes do vetor ϕ com os parâmetros $\hat{a}_{1,f}$ e $\hat{k}_{1,f}$.

Para mais informações acerca do modelo de identificação por regressão linear discutido, incluindo a prova de convergência das estimativas para os valores corretos na presença de um sinal de entrada PE, referimos o leitor a (Ioannou & Sun 1996, Narendra & Annaswamy 1989, Tao 2003).

2.4 Adaptação de Segundo Nível

A partir da parametrização que desenvolvemos na Seção anterior, consideremos os $i = 1, \dots, N$, com $N \geq 2n + 1$, modelos de identificação por regressão linear:

$$\Sigma_{i,f} : \hat{z}_{i,f} = [\hat{a}_{i,f} \quad \hat{k}_{i,f}] \phi \quad (2.22)$$

onde os parâmetros $\hat{a}_{i,f}$ e $\hat{k}_{i,f}$ são inicializados nos vértices de um fecho convexo no espaço de parâmetros. Este fecho convexo deve conter a região de incerteza para os parâmetros a_p e k_p da planta, que é delimitada por um polítopo convexo cujos vértices são as combinações dos limitantes inferiores e superiores $k_p^+, k_p^-, a_p^+, a_p^-$, que são conhecidos. Neste caso, portanto, a escolha das estimativas iniciais $\hat{a}_{i,f}$ e $\hat{k}_{i,f}$ deve formar um fecho convexo que contém o polítopo convexo de vértices $[a_p^+ \quad k_p^+]^T$, $[a_p^+ \quad k_p^-]^T$, $[a_p^- \quad k_p^-]^T$, $[a_p^- \quad k_p^+]^T$ no espaço de parâmetros.

Assim, definimos os $i = 1, \dots, N$ erros de identificação em relação ao sinal filtrado da

planta $z(t)$:

$$e_{i,f} \triangleq \hat{z}_{i,f} - z \quad (2.23)$$

Definimos os erros paramétricos dos N modelos, com $i = 1, \dots, N$:

$$\begin{aligned} \tilde{a}_{i,f} &\triangleq \hat{a}_{i,f} - a_p \\ \tilde{k}_{i,f} &\triangleq \hat{k}_{i,f} - k_p \end{aligned} \quad (2.24)$$

Seguindo o mesmo procedimento da Seção anterior, as $2N$ estimativas dos parâmetros da planta podem ser atualizadas pelas leis integrais:

$$\begin{aligned} \dot{\hat{a}}_{i,f} &= e_{i,f}y \\ \dot{\hat{k}}_{i,f} &= -e_{i,f}u \end{aligned} \quad (2.25)$$

onde os N modelos de identificação têm a mesma estrutura e, portanto, usam o mesmo tipo de lei de ajuste dos seus parâmetros. Cada um dos modelos de identificação tem a diferença entre seu sinal de saída e o sinal z avaliado e este erro de identificação é usado para realizar o ajuste dos parâmetros de cada modelo a cada instante de tempo.

A dinâmica de cada um dos erros de identificação para os N modelos, conforme 2.14 e 2.17, é da seguinte forma:

$$\dot{e}_{i,f} = -(\lambda + y\phi_1 + u\phi_2)e_{i,f} - \tilde{a}_{i,f}y + \tilde{k}_{i,f}u \quad (2.26)$$

com $i = 1, \dots, N$.

Faremos agora um detalhamento do raciocínio referente à introdução de uma segunda camada de estimação, ou SLA. Como já mencionamos, os vetores de parâmetros $[\hat{a}_{i,f} \ \hat{k}_{i,f}]$, $i = 1, \dots, N$ formam um fecho convexo no espaço de parâmetros. Cada um dos pontos no interior ou fronteira deste fecho convexo pode ser representado por uma combinação convexa (ver anexo A):

$$\begin{aligned} \hat{a}_{v,f} &= \sum_{i=1}^N \hat{a}_{i,f} \beta_{i,f} \\ \hat{k}_{v,f} &= \sum_{i=1}^N \hat{k}_{i,f} \beta_{i,f} \\ \sum_{i=1}^N \beta_{i,f} &= 1 \\ 0 &\leq \beta_{i,f} \leq 1 \end{aligned} \quad (2.27)$$

onde $\beta_{i,f}$, $i = 1, \dots, N$ são os coeficientes da combinação convexa para este modelo virtual.

Criamos um modelo de identificação virtual a partir de alguma destas combinações

convexas:

$$\Sigma_{v,f} : \hat{z}_{v,f} = [\hat{a}_{v,f} \quad \hat{k}_{v,f}] \phi \quad (2.28)$$

e buscamos saber quais as propriedades deste modelo de identificação virtual frente aos modelos de identificação por regressão linear que viemos estudando.

Definimos o erro de identificação para o modelo virtual:

$$e_{v,f} \triangleq \hat{z}_{v,f} - z \quad (2.29)$$

Definimos, também, os erros paramétricos para o modelo virtual:

$$\begin{aligned} \tilde{a}_{v,f} &\triangleq \hat{a}_{v,f} - a_p \\ \tilde{k}_{v,f} &\triangleq \hat{k}_{v,f} - k_p \end{aligned} \quad (2.30)$$

e podemos manipular suas expressões da seguinte forma:

$$\begin{aligned} \tilde{a}_{v,f} &= \sum_{i=1}^N \hat{a}_{i,f} \beta_{i,f} - a_p = \sum_{i=1}^N \hat{a}_{i,f} \beta_{i,f} - \sum_{i=1}^N a_p \beta_{i,f} = \sum_{i=1}^N \tilde{a}_{i,f} \beta_{i,f} \\ \tilde{k}_{v,f} &= \sum_{i=1}^N \hat{k}_{i,f} \beta_{i,f} - k_p = \sum_{i=1}^N \hat{k}_{i,f} \beta_{i,f} - \sum_{i=1}^N k_p \beta_{i,f} = \sum_{i=1}^N \tilde{k}_{i,f} \beta_{i,f} \end{aligned} \quad (2.31)$$

onde obtemos que, assim como as estimativas do modelo virtual são combinações convexas dos parâmetros dos modelos por regressão linear, os erros paramétricos para o modelo virtual podem ser obtidos como combinações convexas dos erros paramétricos dos modelos por regressão linear, com os mesmos coeficientes de combinação.

Como as estimativas $\hat{a}_{v,f}$ e $\hat{k}_{v,f}$ são combinações convexas dos parâmetros dos modelos por regressão linear, segue que as leis adaptativas que governam o ajuste de $\hat{k}_{v,f}$ e $\hat{a}_{v,f}$ são combinações convexas das leis de ajuste para os modelos por regressão linear:

$$\begin{aligned} \dot{\hat{a}}_{v,f} &= \sum_{i=1}^N \dot{\hat{a}}_{i,f} \beta_{i,f} = \sum_{i=1}^N e_{i,f} \beta_{i,f} y \\ \dot{\hat{k}}_{v,f} &= \sum_{i=1}^N \dot{\hat{k}}_{i,f} \beta_{i,f} = - \sum_{i=1}^N e_{i,f} \beta_{i,f} u \end{aligned} \quad (2.32)$$

Pelo mesmo procedimento que seguimos anteriormente, devido ao fato de utilizar a mesma estrutura dos modelos por regressão linear, assumimos que a dinâmica do erro de identificação terá a mesma forma da dos modelos de identificação por regressão linear:

$$\dot{e}_{v,f} = -(\lambda + y\phi_1 + u\phi_2)e_{v,f} - \tilde{a}_{v,f}y + \tilde{k}_{v,f}u \quad (2.33)$$

A equação 2.32 mostra que a lei de ajuste para os parâmetros do modelo virtual depende da combinação convexa dos erros de identificação dos modelos por regressão linear.

Vamos, portanto, analisar a dinâmica desta combinação convexa. Derivamos $\sum_{i=1}^N e_{i,f} \beta_{i,f}$, substituindo as dinâmicas dos erros $\dot{e}_{i,f}$ por suas expressões a partir de 2.26 e utilizando 2.31 para reagrupar as combinações convexas de erros paramétricos, obtemos a seguinte equação:

$$\sum_{i=1}^N \dot{e}_{i,f} \beta_{i,f} = -(\lambda + y\phi_1 + u\phi_2) \sum_{i=1}^N e_{i,f} \beta_{i,f} - \tilde{a}_{v,f} y + \tilde{k}_{v,f} u \quad (2.34)$$

e, comparando 2.33 com 2.34, vemos que a dinâmica da combinação convexa $\sum_{i=1}^N e_{i,f} \beta_{i,f}$ é idêntica à dinâmica do erro de identificação do modelo virtual $e_{v,f}$. A combinação convexa dos erros de identificação tende exponencialmente para o valor do erro de identificação do modelo virtual. Se estipularmos, no entanto, que $e_{v,f}(0) = \sum_{i=1}^N e_{i,f}(0) \beta_{i,f}$ então $e_{v,f}$ e $\sum_{i=1}^N e_{i,f} \beta_{i,f}$ se tornam idênticos. Assim, desde que $e_{v,f}(0) = \sum_{i=1}^N e_{i,f}(0) \beta_{i,f}$, teremos que o erro de identificação do modelo virtual é simplesmente a combinação convexa dos erros de identificação dos modelos de primeiro nível:

$$e_{v,f} = \sum_{i=1}^N e_{i,f} \beta_{i,f} \quad (2.35)$$

Feitas estas considerações, teremos então que as expressões das leis adaptativas se reduzem a:

$$\begin{aligned} \hat{a}_{v,f} &= e_{v,f} y \\ \hat{k}_{v,f} &= -e_{v,f} u \end{aligned} \quad (2.36)$$

e vemos que as leis adaptativas obtidas acima têm forma idêntica às usadas nos modelos de primeiro nível $\Sigma_{i,f}$, $i = 1, \dots, N$. Cada um dos pontos no interior do fecho convexo corresponde a um modelo virtual. Conforme os modelos de primeiro nível têm seus parâmetros ajustados adaptativamente, os modelos virtuais também têm seus parâmetros ajustados por leis idênticas, pois um modelo virtual tem leis de ajuste equivalentes às de um modelo de primeiro nível. Dentro das condições que descrevemos, uma combinação convexa de coeficientes constantes dos parâmetros de modelos de primeiro nível se comporta exatamente como parâmetros de um modelo de primeiro nível inicializados naqueles mesmos valores.

Então, os parâmetros verdadeiros da planta a_p e k_p , que pertencem inicialmente ao fecho convexo, podem ser representados por uma combinação convexa de coeficientes

$\alpha_{i,f}^*$, $i = 1, \dots, N$ dos parâmetros dos modelos de primeiro nível:

$$\begin{aligned} a_p &= \sum_{i=1}^N \hat{a}_{i,f} \alpha_{i,f}^* \\ k_p &= \sum_{i=1}^N \hat{k}_{i,f} \alpha_{i,f}^* \\ \sum_{i=1}^N \alpha_{i,f}^* &= 1 \\ 0 &\leq \alpha_{i,f}^* \leq 1 \end{aligned} \quad (2.37)$$

Definimos o seguinte modelo virtual:

$$\Sigma_{\alpha,f} : \hat{z}_{\alpha,f} = \begin{bmatrix} a_p & k_p \end{bmatrix} \phi \quad (2.38)$$

Definimos o erro de identificação para este modelo virtual:

$$e_{\alpha,f} \triangleq \hat{z}_{\alpha,f} - z \quad (2.39)$$

cuja dinâmica é dada por:

$$\dot{e}_{\alpha,f} = -(\lambda + y\phi_1 + u\phi_2)e_{\alpha,f} \quad (2.40)$$

pois o erro paramétrico para este modelo virtual é nulo.

Vemos que o modelo virtual cujos parâmetros são idênticos aos da planta tende exponencialmente ao comportamento da própria planta. Como não podemos garantir com modelos de identificação por regressão linear que $\sum_{i=1}^N e_{i,f}(0)\alpha_{i,f}^* = 0$, o valor de $e_{\alpha,f}(0)$ pode ser não-nulo. No entanto, como escolhemos $\lambda > \sup(y\phi_1 + u\phi_2)$ o termo $(\lambda + y\phi_1 + u\phi_2)$ é sempre maior que 0 e $e_{\alpha,f}$ deve tender a 0 exponencialmente.

Portanto, mesmo que os parâmetros da planta deixem de pertencer ao fecho convexo devido ao efeito das condições iniciais, representadas por $e_{\alpha,f}(0)$ não-nulo, eventualmente a combinação convexa de coeficientes $\alpha_{i,f}^*$ dos erros de identificação dos modelos de primeiro nível tende a 0. Isto indica que em regime permanente os parâmetros da planta pertencem ao fecho convexo formado pelos parâmetros dos modelos de identificação de primeiro nível.

Se a combinação convexa dos erros de identificação não-nulos se torna constante e nula a partir de um certo instante, então a combinação convexa dos erros paramétricos também deve se tornar constante e nula. Desta forma os coeficientes $\alpha_{i,f}^*$, $i = 1, \dots, N$ servem como alternativas de parametrização para a planta.

Assim, com uma segunda camada de estimação, ou segundo nível de adaptação, podemos estimar os coeficientes da combinação linear. Consideramos, portanto, que a equação

$\sum_{i=1}^N e_{i,f} \alpha_{i,f}^* = 0$ é uma ferramenta adequada de estimação.

Por esta razão, necessitamos de um número de modelos $N \geq 2n + 1$, sendo necessários pelo menos $N = 2n + 1$ modelos pois uma combinação linear de $2n + 1$ vetores pertencentes ao R^{2n} tem dimensionalidade máxima igual a $2n$. Em outras palavras, necessitamos de um número mínimo de modelos a partir do qual seja possível a existência de pelo menos uma representação dos parâmetros da planta através de uma combinação convexa de coeficientes $\alpha_{i,f}^*$, $i = 1, \dots, N$ dos parâmetros dos modelos. Por exemplo, para o caso da planta de ordem 1 e grau relativo unitário que estamos tratando, onde $n = 1$, são necessários no mínimo 3 modelos para representar um ponto qualquer no espaço de parâmetros R^2 por uma combinação linear dos parâmetros destes modelos. Se escolhêssemos apenas 2 modelos, seríamos capazes de representar através de uma combinação linear somente os pontos da reta que contém os 2. Pelo mesmo motivo, é necessário que pelo menos um dos modelos escolhidos não pertença a um segmento de reta contendo os modelos restantes, no caso para $n = 1$.

Definimos o seguinte vetor:

$$\bar{E}_f \triangleq [e_{1,f} \quad \dots \quad e_{N-1,f} \quad e_{N,f}] \quad (2.41)$$

Definimos também o vetor:

$$\bar{\alpha}_f^* \triangleq [\alpha_{1,f}^* \quad \dots \quad \alpha_{N-1,f}^* \quad \alpha_{N,f}^*]^T \quad (2.42)$$

tal que temos uma equação para $\sum_{i=1}^N e_{i,f} \alpha_{i,f}^* = 0$ em forma matricial:

$$\bar{E}_f \bar{\alpha}_f^* = \sum_{i=1}^N e_{i,f} \alpha_{i,f}^* = 0 \quad (2.43)$$

Os coeficientes $\alpha_{i,f}$ são coeficientes de uma combinação convexa, portanto:

$$\sum_{i=1}^N \alpha_{i,f} = 1$$

e a partir disto podemos expressar o coeficiente $\alpha_{N,f}^*$ por:

$$\alpha_{N,f} = 1 - \sum_{i=1}^{N-1} \alpha_{i,f}^* \quad (2.44)$$

Podemos isolar o termo $e_{N,f} \alpha_{N,f}^*$ na equação 2.43:

$$\bar{E}_f \bar{\alpha}_f^* = \sum_{i=1}^{N-1} e_{i,f} \alpha_{i,f}^* + e_{N,f} \alpha_{N,f}^*$$

e então substituir $\alpha_{N,f}$ por 2.44:

$$\bar{E}_f \bar{\alpha}_f^* = \sum_{i=1}^{N-1} e_{i,f} \alpha_{i,f}^* + e_{N,f} (1 - \sum_{i=1}^{N-1} \alpha_{i,f}^*) = 0$$

que reorganizado fica da seguinte forma:

$$\sum_{i=1}^{N-1} (e_{i,f} - e_{N,f}) \alpha_{i,f}^* = -e_{N,f} \quad (2.45)$$

Definimos a seguinte matriz:

$$E_f \triangleq \begin{bmatrix} e_{1,f} - e_{N,f} & e_{2,f} - e_{N,f} & \dots & e_{N-1,f} - e_{N,f} \end{bmatrix} \quad (2.46)$$

Definimos o seguinte vetor:

$$\alpha_f^* \triangleq [\alpha_{1,f}^* \quad \alpha_{2,f}^* \quad \dots \quad \alpha_{N-1,f}^*]^T \quad (2.47)$$

e com estas variáveis definidas, reescrevemos a equação 2.45 como:

$$E_f \alpha_f^* = -e_{N,f} \quad (2.48)$$

A equação 2.48 é ponto de partida para estimar em tempo real os coeficientes da combinação convexa que produzem os parâmetros verdadeiros da planta. Substituímos o vetor α_f^* nesta equação por uma estimativa α_f , e a partir desta substituição obtemos uma equação diferencial para estimar α_f^* :

$$\dot{\alpha}_f = -E_f^T E_f \alpha_f - E_f^T e_{N,f} \quad (2.49)$$

A estimativa $\bar{\alpha}_f$ de $\bar{\alpha}_f^*$ fica, então, da seguinte forma:

$$\bar{\alpha}_f = \begin{bmatrix} \alpha_f^T & 1 - \vec{1} \alpha_f \end{bmatrix}^T \quad (2.50)$$

onde $\vec{1}$ é o vetor linha $[1 \quad 1 \quad \dots \quad 1]$ de tamanho apropriado.

Definimos o erro paramétrico para a estimativa $\bar{\alpha}_f$ e para α_f :

$$\begin{aligned} \tilde{\alpha}_f &\triangleq \bar{\alpha}_f - \bar{\alpha}_f^* \\ \tilde{\alpha}_f &\triangleq \alpha_f - \alpha_f^* \end{aligned} \quad (2.51)$$

e como assumimos $\bar{\alpha}_f^*$ invariante no tempo, temos que:

$$\begin{aligned} \dot{\tilde{\alpha}}_f &= \dot{\alpha}_f - \cancel{\dot{\bar{\alpha}}_f^*}^0 = \dot{\alpha}_f \\ \dot{\tilde{\alpha}}_f &= \dot{\alpha}_f - \cancel{\dot{\alpha}_f^*}^0 = \dot{\alpha}_f \end{aligned} \quad (2.52)$$

Então, substituindo $\dot{\alpha}_f$ por $\dot{\tilde{\alpha}}_f$ e α_f por $\tilde{\alpha}_f + \alpha_f^*$ em 2.49 e cancelando os termos

equivalentes devido à equação 2.48, temos que:

$$\dot{\tilde{\alpha}}_f = -E_f^T E_f \tilde{\alpha}_f - E_f^T e_{\alpha,f} \quad (2.53)$$

Usamos uma candidata a função de Lyapunov definida positiva para analisar a estabilidade deste estimador:

$$V(\tilde{\alpha}_f) = \frac{1}{2} \tilde{\alpha}_f^T \tilde{\alpha}_f \quad (2.54)$$

Derivando ao longo das trajetórias obtemos:

$$\dot{V} = \tilde{\alpha}_f^T \dot{\tilde{\alpha}}_f$$

e explicitando $\tilde{\alpha}_f$ e $\dot{\tilde{\alpha}}_f$ a partir de 2.51:

$$\dot{V} = \begin{bmatrix} \tilde{\alpha}_f^T & -\mathbf{1}^T \tilde{\alpha}_f \end{bmatrix} \begin{bmatrix} \dot{\tilde{\alpha}}_f \\ -\mathbf{1}^T \dot{\tilde{\alpha}}_f \end{bmatrix}$$

e ao substituírmos $\dot{\tilde{\alpha}}_f$ por 4.56 e reorganizarmos, obtemos a seguinte expressão:

$$\dot{V} = -N \tilde{\alpha}_f^T E_f^T E_f \tilde{\alpha}_f - N \tilde{\alpha}_f^T E_f^T e_{\alpha,f} \quad (2.55)$$

Na equação 2.55 pode-se escolher λ tal que o termo de sinal indefinido $-N \tilde{\alpha}_f^T E_f^T e_{\alpha,f}$ tenda para 0 exponencialmente. Se os componentes de E_f e $\tilde{\alpha}_f$ tendem a 0 apenas assintoticamente, então o termo de sinal indefinido é, eventualmente, dominado pelo termo de sinal definido negativo $-N \tilde{\alpha}_f^T E_f^T E_f \tilde{\alpha}_f$. Nesta expressão de $\dot{V}$ fica expresso também que a rapidez de convergência dos parâmetros depende de alguma forma do número de modelos N .

Assumindo que uma escolha apropriada de λ foi feita temos que V não pode crescer a partir de um certo instante (ver C.2), o que implica que os componentes de $\tilde{\alpha}_f$, $\tilde{\alpha}_f$ são uniformemente limitados, o que por sua vez implica que os componentes de $\tilde{\alpha}_f$ e α_f são uniformemente limitados. Como os erros de identificação dos modelos de primeiro nível são uniformemente limitados e o vetor α_f é uniformemente limitado isto implica que $\dot{\alpha}_f$, $\dot{\tilde{\alpha}}_f$ são uniformemente limitados.

Finalmente, quando o sinal de controle u for PE teremos que E_f só será o vetor nulo a partir de algum instante quando as estimativas dos parâmetros de primeiro nível forem equivalentes aos parâmetros corretos a_p e k_p , o que indica que uma combinação convexa destes parâmetros também tenderá para os valores corretos. As estimativas dos parâmetros a_p e k_p da planta, $\hat{a}_{n2,f}$ e $\hat{k}_{n2,f}$ são entregues pela combinação convexa de coeficientes $\alpha_{i,f}$, $i = 1, \dots, N$ dos parâmetros $\hat{a}_{i,f}$ e $\hat{k}_{i,f}$, $i = 1, \dots, N$:

$$\begin{aligned} \hat{a}_{n2,f} &= \alpha_{1,f} \hat{a}_{1,f} + \alpha_{2,f} \hat{a}_{2,f} + \dots + \alpha_{N,f} \hat{a}_{N,f} \\ \hat{k}_{n2,f} &= \alpha_{1,f} \hat{k}_{1,f} + \alpha_{2,f} \hat{k}_{2,f} + \dots + \alpha_{N,f} \hat{k}_{N,f} \end{aligned} \quad (2.56)$$

2.5 Adaptação de Segundo Nível Modificada

Como foi demonstrado na Seção anterior, é possível estimar $\alpha_{i,f}^*$, $i = 1, \dots, N$ através das equações 2.49 e 2.50. No entanto, como $E_f^T E_f$ é uma matriz de posto 1 ou 0, não podemos concluir mais nada sem a presença de um sinal com persistência de excitação pois $\lambda_{\min}(E_f^T E_f) \equiv 0$. Nesta Seção iremos propor uma modificação na lei adaptativa da SLA.

Assumindo condições iniciais nulas, partimos de 2.48 para escrever:

$$E_f^T E_f \alpha_f^* = -E_f^T e_{N,f} \quad (2.57)$$

Podemos integrar ambos os lados da equação, para obter:

$$\int_0^t E_f^T(\tau) E_f(\tau) \alpha_f^* d\tau = - \int_0^t E_f^T(\tau) e_{N,f}(\tau) d\tau \quad (2.58)$$

e, como α_f^* é invariante no tempo, podemos colocá-lo como um fator que pós-multiplica a integral $\int_0^t E_f^T(\tau) E_f(\tau) d\tau$, para obter:

$$\int_0^t E_f^T(\tau) E_f(\tau) d\tau \alpha_f^* = - \int_0^t E_f^T(\tau) e_{N,f}(\tau) d\tau \quad (2.59)$$

Finalmente, somamos 2.57 e 2.59 e, a seguir, colocamos todos os termos no lado direito da equação, para obter:

$$0 = - \int_0^t E_f^T(\tau) E_f(\tau) d\tau \alpha_f^* - E_f^T E_f \alpha_f^* - \int_0^t E_f^T(\tau) e_{N,f}(\tau) d\tau - E_f^T e_{N,f} \quad (2.60)$$

e como os erros de identificação $e_{i,f}$, $i = 1, \dots, N$, são uniformemente limitados e tendem a 0 à medida que o tempo t tende a infinito, as integrais em 2.60 são limitadas e tendem a valores constantes. Substituindo α_f^* por sua estimativa, como no procedimento que realizamos na Seção anterior, temos a seguinte equação:

$$\dot{\alpha}_f = - \int_0^t E_f^T(\tau) E_f(\tau) d\tau \alpha_f - E_f^T E_f \alpha_f - \int_0^t E_f^T(\tau) e_{N,f}(\tau) d\tau - E_f^T e_{N,f} \quad (2.61)$$

Por facilidade de notação, definimos as seguintes variáveis:

$$\begin{aligned} M_f &\triangleq \int_0^t E_f^T(\tau) E_f(\tau) d\tau \\ v_f &\triangleq \int_0^t E_f^T(\tau) e_{N,f}(\tau) d\tau \end{aligned} \quad (2.62)$$

e reescrevemos 2.61 como:

$$\dot{\alpha}_f = -M_f \alpha_f - E_f^T E_f \alpha_f - v_f - E_f^T e_{N,f} \quad (2.63)$$

Usamos uma candidata a função de Lyapunov definida positiva para avaliar a estabilidade deste estimador:

$$V(\tilde{\alpha}_f) = \frac{1}{2} \tilde{\alpha}_f^T \tilde{\alpha}_f \quad (2.64)$$

Derivando ao longo das trajetórias obtemos:

$$\dot{V} = -N \tilde{\alpha}_f^T (E_f^T E_f + M_f) \tilde{\alpha}_f \quad (2.65)$$

que implica em $\tilde{\alpha}$ uniformemente limitado (ver C.2).

Para cada instante de tempo existe pelo menos um autovetor associado a um autovalor nulo da matriz $E_f^T E_f$. Então, para um vetor arbitrário $w_q \in \mathbb{R}^{N-1}$ constante, temos:

$$w_q^T \left(\int_0^\infty E_f^T(\tau) E_f(\tau) d\tau \right) w_q > 0 \quad (2.66)$$

pois o vetor w_q , constante e não-nulo, não é múltiplo escalar de algum autovetor associado a um autovalor nulo da matriz $E_f^T E_f$ em todos os instantes, pois assumimos que a direção dos autovetores associados aos autovalores nulos desta matriz está variando durante o transitório. Portanto, qualquer que seja w_q , a inequação 2.66 se mantém. Portanto, a matriz M_f obtida pela integração de $E_f^T E_f$ a partir do instante inicial converge para uma matriz simétrica com valores de seus elementos constantes, definida positiva e de posto cheio.

Temos, então, para um intervalo finito entre 0 e $t_0 > 0$ escolhido tal que $\lambda_{\min}(E_f^T E_f + M_f) > 0$ a partir de t_0 , que:

$$\int_0^{t_0} \|\tilde{\alpha}_f\|^2 d\tau < K$$

onde K é um escalar finito, pois $\tilde{\alpha}_f$ é uniformemente limitado.

Assim, utilizamos a desigualdade de Rayleigh:

$$\lambda_{\min}(E_f^T E_f + M_f) \|\tilde{\alpha}_f\|^2 \leq \tilde{\alpha}_f^T (E_f^T E_f + M_f) \tilde{\alpha}_f \leq \lambda_{\max}(E_f^T E_f + M_f) \|\tilde{\alpha}_f\|^2 \quad (2.67)$$

e a partir de 2.65 e 2.67 temos que:

$$\|\tilde{\alpha}_f\|^2 \leq \frac{-\dot{V}}{N\lambda_{\min}(E_f^T E_f + M_f)}$$

Substituímos $\lambda_{\min}$ que varia com o tempo por um valor $\lambda_{\min,inf}$ constante, o ínfimo do conjunto de autovalores mínimos da matriz $E_f^T E_f + M_f$ a partir do instante t_0 e integrando temos:

$$\int_0^\infty \|\tilde{\alpha}_f(\tau)\|^2 d\tau \leq \int_0^{t_0} \|\tilde{\alpha}_f(\tau)\|^2 d\tau + \frac{1}{N\lambda_{\min,inf}(E_f^T E_f + M_f)} (V(t_0) - V(\infty))$$

e como $\int_0^{t_0} \|\tilde{\alpha}_f(\tau)\|^2 d\tau$ é um valor finito e $\frac{1}{N\lambda_{\min,inf}(E_f^T E_f + M_f)} (V(t_0) - V(\infty))$ é um valor finito temos que:

$$\tilde{\alpha}_f \in \mathcal{L}_2$$

Finalmente, por um corolário do Lema de Barbalat (ver C.4.4), temos que o vetor $\tilde{\alpha}_f$ uniformemente limitado e pertencente ao $\mathcal{L}_2$ e sua derivada uniformemente limitada implicam em $\tilde{\alpha}_f$ que tende para 0 assintoticamente, que por sua vez implica em $\tilde{\alpha}_{N,f}$ que tende para 0 assintoticamente.

Portanto, com a modificação proposta, existe garantia de convergência dos coeficientes $\hat{\alpha}_{i,f}$, $i = 1, \dots, N$, para algum conjunto de valores corretos, no sentido de que produzem os parâmetros verdadeiros da planta. Não é necessário, para tanto, impor sobre a planta um sinal de controle com a característica de persistência de excitação, desde que as condições iniciais sejam nulas e a planta seja invariante no tempo.

Uma outra forma de calcular os coeficientes corretos é monitorando o posto de M_f e resolvendo o sistema de equações $M_f \alpha_f^{*T} = -v_f$ para α_f^* quando for verificado que M_f é de posto cheio e suficientemente distante de ser uma matriz singular, para evitar erro numérico.

É importante ressaltar, no entanto, que esta melhora na convergência dos parâmetros implica numa perda em outro aspecto importante da identificação de parâmetros, isto é, caso a planta tenha seus parâmetros variando lentamente no tempo, as informações acumuladas nos elementos da matriz M_f e do vetor v_f deixarão gradualmente de ser válidas na atualização ou cálculo dos coeficientes, fazendo com que os coeficientes acabem

convergindo para valores distintos dos corretos, o que é algo que não acontece sem a modificação. Apesar disso, vimos que dentro das condições especificadas existe algum benefício em acumular informações passadas.

2.6 Resultados

Apresentamos o modelo de identificação por regressão linear neste Capítulo. Discutimos algumas de suas propriedades para a planta estável de ordem 1 e grau relativo 1. Mostramos que o erro de identificação tende a 0 para este modelo. Mencionamos que as estimativas tendem aos valores corretos na presença de um sinal de entrada com a característica de persistência de excitação.

Provamos, para este tipo de modelo, que existem coeficientes constantes de uma combinação convexa das estimativas dos parâmetros de 3 ou mais modelos que produzem a_p e k_p . Demonstramos que, com uma segunda camada de adaptação, ou uma adaptação em dois níveis, pode-se atualizar estimativas destes coeficientes para calcular uma estimativa de segundo nível de a_p e k_p .

Finalmente, discutimos uma modificação na lei adaptativa da SLA tal que não seja necessária a imposição de um sinal de controle com característica de persistência de excitação à planta de ordem 1 para que seja garantida a convergência dos parâmetros para seus valores corretos.

Por fim, caso o leitor deseje consultar rapidamente, listamos as equações necessárias na Tabela 2.1.

Vamos, agora, considerar a planta de ordem 1 a seguir:

$$\Sigma_p : G(s) = \frac{3}{s + 1.5}$$

onde os parâmetros $k_p = 3$ e $a_p = 1.5$ pertencem a uma região de incerteza delimitada por $a_p^+ = 4$, $a_p^- = 0.5$, $k_p^+ = 6$, $k_p^- = 1$. Desejamos identificar os parâmetros desta planta em tempo real. Sua saída $y(t)$ e sua entrada $u(t)$ estão disponíveis para medição. Vamos usar o modelo de identificação por regressão linear e o conceito de SLA, fazendo uso de conjuntos de modelos de identificação por regressão linear.

Na SLA estimativas de primeiro nível são combinadas linearmente por um conjunto de coeficientes que também estão, por sua vez, sendo atualizados para formar uma estimativa de segundo nível. Usaremos o número mínimo de modelos para o caso de ordem 1 e grau relativo 1, $N = 3$. Mostramos também resultados com $N = 4$ e $N = 8$ modelos. Também apresentamos e discutimos os resultados de simulações para $N = 3$ modelos com a modificação proposta para a lei adaptativa da SLA.

Tabela 2.1: Equações necessárias para identificação de parâmetros para a planta de ordem 1 e grau relativo unitário

Planta		Fonte	
$\Sigma_p : \dot{y} = -a_p y + k_p u$ $\dot{\phi}_1 = -\lambda \phi_1 - y$ $\dot{\phi}_2 = -\lambda \phi_2 + u$ $\phi = [\phi_1 \ \phi_2]^T$ $z = y + \lambda \phi_1$		2.1, B.1, 2.6 e 2.8	
Modelos de Primeiro Nível		Fonte	
$\Sigma_{i,f} : \hat{z}_{i,f} = [\hat{a}_{i,f} \ \hat{k}_{i,f}] \phi$ $e_{i,f} = \hat{z}_{i,f} - z$ $\hat{a}_{i,f} = e_{i,f} y$ $\hat{k}_{i,f} = -e_{i,f} u$		2.9, 2.10 e 2.17	
Adaptação de Segundo Nível			
Convencional	Fonte	Modificada	Fonte
$E_f = [e_{1,f} - e_{N,f} \ \dots \ e_{N-1,f} - e_{N,f}]$ $\dot{\alpha}_f = -E_f^T E_f \alpha_f - E_f^T e_{N,f}$ $\bar{\Theta}_f = \begin{bmatrix} \hat{a}_{1,f} & \dots & \hat{a}_{N,f} \\ \hat{k}_{1,f} & \dots & \hat{k}_{N,f} \end{bmatrix}$ $\bar{\alpha}_f^T = [\alpha_f^T \ 1 - \bar{\mathbf{1}} \alpha_f]$ $\begin{bmatrix} \hat{a}_{n2,f} \\ \hat{k}_{n2,f} \end{bmatrix} = \bar{\Theta}_f \bar{\alpha}_f$	2.46, 2.49, 2.50 e 2.56	$M_f(0) = \mathbf{0}$ $v_f(0) = \mathbf{0}$ $\dot{M}_f = E_f^T E_f$ $\dot{v}_f = E_f^T e_{N,f}$ $X_f = E_f^T E_f + M_f$ $x_f = E_f^T e_{N,f} + v_f$ $\dot{\alpha}_f = -X_f \alpha_f - x_f$ $\bar{\Theta}_f = \begin{bmatrix} \hat{a}_{1,f} & \dots & \hat{a}_{N,f} \\ \hat{k}_{1,f} & \dots & \hat{k}_{N,f} \end{bmatrix}$ $\bar{\alpha}_f^T = [\alpha_f^T \ 1 - \bar{\mathbf{1}} \alpha_f]$ $\begin{bmatrix} \hat{a}_{n2,f} \\ \hat{k}_{n2,f} \end{bmatrix} = \bar{\Theta}_f \bar{\alpha}_f$	2.62, 2.63, 2.50 e 2.56

Em todas as simulações utilizamos o sinal de entrada $u(t) = \sin(t)$ que é PE de ordem 1. Da mesma forma consideramos a condição inicial $y(0) = 0.2$ em todas as simulações a seguir. Comparamos os métodos de estimação para estimativas que iniciam em $\hat{a}(0) = 0.5$ e $\hat{k}(0) = 6$, tal que a comparação entre os métodos seja a mais justa possível. Usamos integração por passo fixo de 10^{-3} segundos, que é suficiente para evitar erros numéricos. Adicionalmente, escolhemos o parâmetro $\lambda = 4$ para todas as simulações, pois intuimos que a dinâmica do filtro deve ter constante de tempo comparável à da planta, no entanto, note-se que esta escolha não respeita o valor obtido através de 2.21. Apesar disto, $\lambda = 4$ é maior que $\sup(y\phi_1) + \sup(u\phi_2)$, neste caso, como pode ser visto na Figura 2.1.




Figura 2.1: Valor de λ e do sinal $|y\phi_1|(t) + |u\phi_2|(t)$, 20 segundos de simulação

SLA, 3 Modelos por Regressão Linear

Para esta simulação, inicializamos os parâmetros dos modelos em $\hat{a}_{1,f}(0) = 0.5$ e $\hat{k}_{1,f}(0) = 1$, $\hat{a}_{2,f}(0) = 0.5$ e $\hat{k}_{2,f}(0) = 11$, $\hat{a}_{3,f}(0) = 7$ e $\hat{k}_{3,f}(0) = 1$, e os coeficientes da combinação convexa em $\alpha_{1,f}(0) = 0.5$, $\alpha_{2,f}(0) = 0.5$ e $\alpha_{3,f}(0) = 0$. Com estas escolhas, as estimativas de segundo nível iniciais são $\hat{a}_{n2,f}(0) = 0.5$ e $\hat{k}_{n2,f}(0) = 6$.

A seguir, extraímos os resultados da simulação da SLA com $N = 3$ para demonstrar o comportamento dos erros de identificação. Para os modelos por regressão linear atualizados pela lei de ajuste convencional o erro de identificação está tendendo a 0 com $t = 110$ segundos na Figura 2.2, indicando convergência dos parâmetros, com o modelo 2 um pouco mais distante da convergência que 1 e 3. Em contrapartida, o erro de identificação do modelo virtual converge com $t \approx 15$ segundos, o que pode ser visto com mais detalhes em 2.3. Apesar de os modelos por regressão linear serem capazes de identificar os parâmetros da planta, isto só acontece após um intervalo de tempo que é bastante longo em relação à dinâmica da planta.




Figura 2.2: Erros de identificação dos modelos de primeiro nível usando o modelo por regressão linear e do modelo virtual usando SLA com $N = 3$ para a planta Σ_p , 110 segundos de simulação




Figura 2.3: Erros de identificação dos modelos de primeiro nível usando o modelo por regressão linear e do modelo virtual usando SLA com $N = 3$ para a planta Σ_p , 20 segundos de simulação

SLA, 4 Modelos por Regressão Linear

Na segunda simulação, inicializamos os parâmetros dos modelos nos vértices da região de incerteza em $\hat{a}_{1,f}(0) = 0.5$ e $\hat{k}_{1,f}(0) = 1$, $\hat{a}_{2,f}(0) = 4$ e $\hat{k}_{2,f}(0) = 1$, $\hat{a}_{3,f}(0) = 4$ e $\hat{k}_{3,f}(0) = 6$, $\hat{a}_{4,f}(0) = 0.5$ e $\hat{k}_{4,f}(0) = 6$, e os coeficientes da combinação convexa em $\alpha_{1,f}(0) = 0$, $\alpha_{2,f}(0) = 0$ e $\alpha_{3,f}(0) = 0$ e $\alpha_{4,f}(0) = 1$. Com estas escolhas, as estimativas de segundo nível iniciais são $\hat{a}_{n2,f}(0) = 0.5$ e $\hat{k}_{n2,f}(0) = 6$.

SLA, 8 Modelos por Regressão Linear

Para a última simulação inicializamos os parâmetros dos modelos em $\hat{a}_{1,f}(0) = 0.5$ e $\hat{k}_{1,f}(0) = 1$, $\hat{a}_{2,f}(0) = 2$ e $\hat{k}_{2,f}(0) = 1$, $\hat{a}_{3,f}(0) = 4$ e $\hat{k}_{3,f}(0) = 1$, $\hat{a}_{4,f}(0) = 4$ e $\hat{k}_{4,f}(0) = 3$, $\hat{a}_{5,f}(0) = 4$ e $\hat{k}_{5,f}(0) = 6$, $\hat{a}_{6,f}(0) = 2.5$ e $\hat{k}_{6,f}(0) = 6$, $\hat{a}_{7,f}(0) = 0.5$ e $\hat{k}_{7,f}(0) = 4$, $\hat{a}_{8,f}(0) = 0.5$ e $\hat{k}_{8,f}(0) = 6$, ao longo do perímetro da região de incerteza, e os coeficientes da combinação convexa em $\alpha_{i,f}(0) = 0$, $i \neq 8$ e $\alpha_{8,f}(0) = 1$. Com estas escolhas, as estimativas de segundo nível iniciais são $\hat{a}_{n2,f}(0) = 0.5$ e $\hat{k}_{n2,f}(0) = 6$.

De forma a facilitar a comparação entre as estimativas, plotamos todas as estimativas de a_p no mesmo gráfico, que se encontra na Figura 2.4. Fizemos o mesmo para todas as estimativas de k_p , que estão representadas no gráfico da Figura 2.5. Escolhemos omitir as estimativas dos modelos de primeiro nível, exceto a que inicia em $\hat{a}_{4,f} = 0.5$ e $\hat{k}_{4,f} = 6$, da simulação para a SLA com $N = 4$. Como já mencionamos, entendemos que estes modelos não contribuem com informações relevantes para uma comparação entre os parâmetros de um modelo de identificação de primeiro nível e os parâmetros atualizados através do conceito de SLA. Para uma comparação mais justa entre dois métodos de estimação distintos, acreditamos que são necessárias condições iniciais iguais.

Vemos nas Figuras 2.4 e 2.5 que a SLA é mais rápida que o modelo de primeiro nível. A velocidade de convergência aumenta quando usamos mais modelos, mas não de uma forma linear. Tanto no caso em que $N = 4$ quanto $N = 8$ observamos um sobressinal menor nas estimativas em relação aos valores corretos e uma convergência mais rápida. No entanto, é importante notar que dobramos o número de modelos em relação ao caso em que $N = 4$ e obtivemos uma convergência apenas um pouco mais rápida. Isto sugere que a escolha acerca de quais valores usar para inicializar os parâmetros dos modelos de primeiro nível influi na velocidade de convergência dos parâmetros ou que a velocidade de convergência dos parâmetros está sujeita a uma lei de rendimentos decrescentes, no que se refere ao número de modelos.

Segundo Nível Modificado, 3 Modelos por Regressão Linear

A seguir, testamos a SLA modificada, apresentada neste capítulo. Consideramos que $y(0) = 0$, inicializamos os parâmetros dos modelos em $\hat{a}_{1,f}(0) = 0.5$ e $\hat{k}_{1,f}(0) = 1$, $\hat{a}_{2,f}(0) = 0.5$ e $\hat{k}_{2,f}(0) = 11$, $\hat{a}_{3,f}(0) = 7$ e $\hat{k}_{3,f}(0) = 1$, e os coeficientes da combinação




Figura 2.4: Estimativa do parâmetro $a_p = 1.5$ para a planta Σ_p para o modelo de identificação por regressão linear, SLA com $N = 3$, $N = 4$ e $N = 8$ modelos de primeiro nível por regressão linear, 20 segundos de simulação




Figura 2.5: Estimativa do parâmetro $k_p = 3$ para a planta Σ_p para o modelo de identificação por regressão linear, SLA com $N = 3$, $N = 4$ e $N = 8$ modelos de primeiro nível por regressão linear, 20 segundos de simulação

convexa em $\alpha_{1,f}(0) = 0.5$, $\alpha_{2,f}(0) = 0.5$ e $\alpha_{3,f}(0) = 0$ e usamos o Método de Integração de Euler com passo fixo de 10^{-3} segundos e tempo de simulação de 36 segundos. O sinal de entrada foi escolhido como $u(t) = 1$ que, note-se, não é PE.




Figura 2.6: Erros de identificação usando 3 modelos por regressão linear e o erro do modelo virtual usando SLA com base nestes modelos para a planta Σ_p

Verificamos que os erros de identificação rapidamente vão para 0 com $t \approx 5$ segundos na Figura 2.6 e as estimativas de primeiro nível ficaram mais próximas dos valores corretos nas Figuras 2.7 e 2.8.

De fato as estimativas em regime permanente para um sinal de entrada do tipo degrau unitário sempre se localizam sobre a reta de inclinação igual ao ganho em regime permanente da planta e que passa pelo ponto que contém os parâmetros corretos. Isto acontece pois o degrau carrega apenas uma informação (a amplitude). A senoide carrega duas informações (amplitude e fase), de forma que uma senoide pode ser usada para identificar univocamente até dois parâmetros de uma planta linear.

As estimativas de segundo nível em $t = 25$ segundos alcançam os valores corretos. Este resultado é interessante, e tem a seguinte interpretação: as informações sobre os parâmetros da planta se encontram disponíveis durante o transitório. O transitório é o período de tempo em que os modos da planta estão excitados. Armazenar informações acerca do transitório da planta e utilizar estas informações em conjunto com as do instante atual para atualizar os parâmetros nos permite um conhecimento melhor do que ao utilizar apenas informações do instante atual para esta tarefa.

O trajeto no espaço de parâmetros pode ser visto na Figura 2.9. Como os parâmetros convergem para os valores corretos, a SLA modificada com 3 modelos de primeiro nível por regressão linear de uma planta invariante no tempo sujeita a um sinal que provoca excitação de seus modos durante um intervalo de tempo finito é adequada para o objetivo




Figura 2.7: Estimativas do parâmetro $a_p = 1.5$ para a planta Σ_p para 3 modelos por regressão linear e SLA modificada, 36 segundos de simulação




Figura 2.8: Estimativas do parâmetro $k_p = 3$ para a planta Σ_p para 3 modelos por regressão linear e SLA modificada, 36 segundos de simulação

de identificação de parâmetros, desde que partindo de condições iniciais nulas. O processo de identificação continua a ser mais lento do que a dinâmica da planta pois a convergência dos parâmetros se dá de fato após $t = 25$ segundos. No entanto, não foi necessária a imposição de um sinal com persistência de excitação à entrada da planta.




Figura 2.9: Trajetória dos parâmetros $\hat{a}_{n2,f}$ e $\hat{k}_{n2,f}$ da SLA modificada no espaço de parâmetros usando 3 modelos por regressão linear para a planta Σ_p , aos 30 segundos de simulação

2.7 Conclusão

Neste Capítulo apresentamos o modelo de identificação por regressão linear para a planta de ordem 1. Mostramos como este modelo pode servir como base para identificação através do conceito de SLA.

Na SLA os coeficientes de uma combinação linear de múltiplos modelos são atualizados por uma lei integral e as estimativas são entregues por esta mesma combinação.

Neste Capítulo escolhemos um caso simples, uma planta de ordem 1 com grau relativo unitário e estável e, portanto, com apenas dois parâmetros a serem estimados e com sinais limitados a priori. Desta forma, esperamos que as características da SLA como método de estimação paramétrica tenham ficado evidenciadas de forma mais didática, por se tratar de um tema novo.

Foram feitos estudos de simulação, nos quais avaliamos que a SLA exibe velocidade de convergência superior ao estimador convencional com modelo de primeiro nível. Mostramos também que existe a possibilidade de identificar os parâmetros corretos na presença de um sinal de entrada sem persistência de excitação, dentro de condições iniciais nulas.

Capítulo 3

Controle da Planta de Ordem 1

Neste Capítulo, passamos a tratar do problema do controle da planta LIT de ordem 1. Mostramos a lei de controle para o caso da planta com parâmetros conhecidos e como é feita a escolha dos parâmetros. A partir das equações obtidas para o caso da planta com parâmetros conhecidos, substituímos os parâmetros verdadeiros da planta por suas estimativas para implementar o controle adaptativo indireto convencional. Também demonstramos como podemos escolher leis de ajuste chaveadas para as estimativas dos parâmetros do controlador. No final do Capítulo trazemos resultados de simulação para as estratégias de controle estudadas.

3.1 Descrição do Problema

Considere a planta LIT de ordem 1 e grau relativo unitário, descrita pela seguinte função de transferência:

$$\Sigma_p : G_p(s) = \frac{y(s)}{u(s)} = \frac{k_p}{s + a_p} \quad (3.1)$$

onde a saída $y(t)$ e a entrada $u(t)$ estão disponíveis para medição, e k_p e a_p pertencem a intervalos conhecidos, $k_p \in [k_p^-, k_p^+]$ e $a_p \in [a_p^-, a_p^+]$.

As seguintes hipóteses são verdadeiras:

- **P1** A ordem da planta e seu grau relativo são conhecidos
- **P2** O sinal de k_p é conhecido.

devido à hipótese **P2**, convencionamos, sem perda de generalidade, que $k_p > 0$.

Nosso objetivo é o de projetar um controlador que produza um sinal de controle $u(t)$, para atuar sobre a entrada da planta, que faça com que a saída da planta rastreie a saída de um modelo de referência:

$$\Sigma_m : W_m(s) = \frac{y_m(s)}{r(s)} = \frac{k_m}{s + a_m} \quad (3.2)$$

escolhido pelo projetista e que cumpre as seguintes condições:

- **M1** A ordem do modelo e seu grau relativo são iguais aos da planta.
- **M2** $s + a_m$ é Hurwitz, isto é, $a_m > 0$.
- **M3** O sinal de k_m é igual ao sinal de k_p , ou seja, $k_m > 0$

Ao alimentar o modelo de referência com um sinal de referência $r(t)$ escolhido pelo projetista, uma trajetória para a saída da planta é especificada. A lei de controle deve ser escolhida tal que o polo da função de transferência em malha fechada de r para y seja igual a $s + a_m$. Se a função de transferência em malha fechada se torna equivalente à $W_m(s)$, então qualquer que seja o sinal de referência $r(t)$, a saída $y(t)$ da planta tenderá exponencialmente para a saída $y_m(t)$ do modelo.

3.2 Planta com Parâmetros Conhecidos

Consideremos que a_p e k_p são conhecidos. Passamos, então, a considerar a seguinte lei de controle por realimentação:

$$u^* = k_1^* y + k_2^* r \quad (3.3)$$

Queremos encontrar parâmetros k_1^* e k_2^* tal que a função de transferência em malha fechada de y para r seja equivalente à $W_m(s)$. As propriedades de entrada e saída da planta em malha fechada para esta lei de controle são dadas por:

$$\dot{y} = -a_p y + k_p (k_1^* y + k_2^* r) = -a_m y + k_m r \quad (3.4)$$

A partir de 3.4, os parâmetros k_1^* e k_2^* são calculados por inspeção como:

$$\begin{aligned} k_1^* &= \frac{a_p - a_m}{k_p} \\ k_2^* &= \frac{k_m}{k_p} \end{aligned} \quad (3.5)$$

Chamamos as equações 3.5 de equações de *matching* da planta de ordem 1. A partir das equações de *matching* temos os parâmetros do controlador em função dos parâmetros da planta que garantem que a função de transferência entre a referência e a saída da planta é equivalente à do modelo de referência, para a lei de controle por realimentação 3.3.

3.3 Controle Adaptativo por Modelo de Referência Indireto

Na Seção anterior obtivemos equações para calcular os parâmetros do controlador em função dos parâmetros da planta.

Para aplicar os métodos de estimação de parâmetros que viemos estudando para a planta de ordem 1, vamos utilizar as equações 3.5, substituindo os parâmetros verdadeiros da planta por suas estimativas:

$$\begin{aligned} k_1 &= \frac{\hat{a}_p - a_m}{\hat{k}_p} \\ k_2 &= \frac{k_m}{\hat{k}_p} \end{aligned} \quad (3.6)$$

Para limitar os parâmetros calculados, temos que a estimativa $\hat{k}_p$ deve ser restringida, por projeção, de atingir um valor nulo, e, por isto, há a necessidade do sinal de k_p ser conhecido. A lei de controle fica, então, da forma:

$$u = k_1 y + k_2 r \quad (3.7)$$

3.4 Controle Adaptativo por Modelo de Referência e Estrutura Variável

Consideremos a diferença entre o sinal de saída da planta e o sinal de saída do modelo de referência:

$$e_o = y - y_m \quad (3.8)$$

chamado erro de saída.

Definimos os erros paramétricos para os parâmetros do controlador:

$$\begin{aligned} \tilde{k}_1 &= k_1 - k_1^* \\ \tilde{k}_2 &= k_2 - k_2^* \end{aligned} \quad (3.9)$$

A dinâmica do erro de saída é dada, então, por:

$$\dot{e}_o = \dot{y} - \dot{y}_m = -a_p y + k_p((\tilde{k}_1 + k_1^*)y + (\tilde{k}_2 + k_2^*)r) + a_m y_m - k_m r \quad (3.10)$$

que, simplificando, fica da forma:

$$\dot{e}_o = -a_m e_o + k_p(\tilde{k}_1 y + \tilde{k}_2 r) \quad (3.11)$$

Consideremos a seguinte candidata a função de Lyapunov:

$$V(e_o) = \frac{e_o^2}{2} \quad (3.12)$$

Derivando ao longo das trajetórias de V obtemos:

$$\dot{V} = -a_m e_o^2 + \tilde{k}_1 k_p e_o y + \tilde{k}_2 k_p e_o r \quad (3.13)$$

Como $k_p \in [k_p^- \ k_p^+]$ e $a_p \in [a_p^- \ a_p^+]$, temos que os parâmetros do controlador para as equações de matching devem obedecer às seguintes inequações:

$$\begin{aligned} |k_1^*| &\leq \frac{\max(|a_p^+ - a_m|, |a_p^- - a_m|)}{\min(|k_p^+|, |k_p^-|)} \\ |k_2^*| &\leq \frac{|k_m|}{\min(|k_p^+|, |k_p^-|)} \end{aligned} \quad (3.14)$$

Definimos, então, os parâmetros:

$$\begin{aligned} \bar{k}_1 &= \frac{\max(|a_p^+ - a_m|, |a_p^- - a_m|)}{\min(|k_p^+|, |k_p^-|)} \\ \bar{k}_2 &= \frac{|k_m|}{\min(|k_p^+|, |k_p^-|)} \end{aligned} \quad (3.15)$$

Portanto, a cada instante podemos escolher os parâmetros do controlador de acordo com as seguintes leis chaveadas:

$$\begin{aligned} k_1 &= -\bar{k}_1 \operatorname{sign}(k_p e_o y) \\ k_2 &= -\bar{k}_2 \operatorname{sign}(k_p e_o r) \end{aligned} \quad (3.16)$$

Ao fazermos esta escolha de k_1 e k_2 , garantimos que $\operatorname{sign}(\tilde{k}_1) = -\operatorname{sign}(k_p e_o y)$ e que $\operatorname{sign}(\tilde{k}_2) = -\operatorname{sign}(k_p e_o r)$, e, desta forma, os termos $\tilde{k}_1 k_p e_o y$ e $\tilde{k}_2 k_p e_o r$ em 3.13 passam a ser definidos negativos e $\dot{V}$ passa a ser definida negativa. Isto implica em e_o uniformemente limitado e pertencente ao $\mathcal{L}_2$ (ver C.2). e_o uniformemente limitado implica em y uniformemente limitado. A partir de 3.11 concluímos que $\dot{e}_o$ é uniformemente limitado e, devido a um corolário do Lema de Barbalat (ver C.4.4), e_o deve tender a 0 pelo menos assintoticamente.

3.5 Resultados

Neste Capítulo apresentamos a lei de controle usada para que a planta de ordem 1 rastreie a saída de um modelo de referência. Usamos uma lei de controle por realimentação do sinal de saída da planta em conjunto com a referência.

Os parâmetros do controlador são calculados a partir dos parâmetros estimados da planta por um mapeamento baseado nas equações de *matching* 3.5, como se os parâmetros da planta fossem conhecidos. As estimativas podem ser obtidas pelos métodos estudados no Capítulo 2. Também descrevemos o VS-MRAC na estratégia direta.

Caso o leitor deseje consultar rapidamente, listamos as equações necessárias para o controle da planta de ordem 1 na Tabela 3.1.

Tabela 3.1: Equações necessárias para o controle da planta de ordem 1 e grau relativo unitário

Planta e Modelo de Referência			
Planta	Fonte	Modelo de Referência	Fonte
$\Sigma_p : \dot{y} = -a_p y + k_p u$	3.1 e B.1	$\Sigma_m : \dot{y}_m = -a_m y_m + k_m r$	3.2 e B.1
Controle			
Lei de Controle	Fonte	Equações de Matching	Fonte
$u = k_1 y + k_2 r$	3.7	$k_1 = \frac{a_p - a_m}{k_p}$ $k_2 = \frac{k_m}{k_p}$	3.6
Estimativas dos Parâmetros			
Modelos de Primeiro Nível	Fonte	Estrutura Variável	Fonte
$z = y + \lambda \phi_1$ $\dot{\phi}_1 = -\lambda \phi_1 - y$ $\dot{\phi}_2 = -\lambda \phi_2 + u$ $\phi = [\phi_1 \ \phi_2]^T$ $\Sigma_{i,f} : \hat{z}_{i,f} = [\hat{a}_{i,f} \ \hat{k}_{i,f}] \phi$ $e_{i,f} = \hat{z}_{i,f} - z$ $\dot{\hat{a}}_{i,f} = e_{i,f} y$ $\dot{\hat{k}}_{i,f} = -e_{i,f} u$	2.8, 2.6, 2.9, 2.10 e 2.17	$e_o = y - y_m$ $\bar{k}_1 \geq k_1^* $ $\bar{k}_2 \geq k_2^* $ $k_1 = -\bar{k}_1 \text{sign}(k_p e_o y)$ $k_2 = -\bar{k}_2 \text{sign}(k_p e_o r)$	3.8, 3.15 e 3.16
Adaptação de Segundo Nível			Fonte
$E_f = [e_{1,f} - e_{N,f} \ \dots \ e_{N-1,f} - e_{N,f}]$ $\dot{\alpha}_f = -E_f^T E_f \alpha_f - E_f^T e_{N,f}$ $\bar{\Theta}_f = \begin{bmatrix} \hat{a}_{1,f} & \dots & \hat{a}_{N,f} \\ \hat{k}_{1,f} & \dots & \hat{k}_{N,f} \end{bmatrix}$ $\bar{\alpha}_f^T = [\alpha_f^T \ 1 - \bar{\mathbf{1}} \alpha_f]$ $\begin{bmatrix} \hat{a}_{n2,f} \\ \hat{k}_{n2,f} \end{bmatrix} = \bar{\Theta}_f \bar{\alpha}_f$			2.46, 2.49, 2.50 e 2.56

Voltemos a considerar a planta de ordem 1 que estudamos no Capítulo 2:

$$\Sigma_p : G(s) = \frac{3}{s + 1.5}$$

onde os parâmetros $k_p = 3$ e $a_p = 1.5$ pertencem a uma região de incerteza delimitada por $a_p^+ = 4$, $a_p^- = 0.5$, $k_p^+ = 6$, $k_p^- = 1$, como anteriormente. A saída $y(t)$ e sua entrada $u(t)$ estão disponíveis para medição.

Consideremos, agora, o seguinte modelo de referência:

$$\Sigma_m : W_m(s) = \frac{5}{s + 5}$$

Queremos alimentar a planta com um sinal de controle tal que sua saída y rastreie a saída do modelo de referência y_m . Para tanto, vamos utilizar as leis de controle que estudamos neste Capítulo, em conjunto com os métodos de estimação de parâmetros vistos no Capítulo 2, quando oportuno.




Figura 3.1: Valor de λ e do sinal $|y\phi_1|(t) + |u\phi_2|(t)$, 20 segundos de simulação

Em todas as simulações utilizamos o sinal de referência $r(t) = 1$. Da mesma forma consideramos a condição inicial $y(0) = 0.2$ em todas as simulações a seguir. Usamos integração por passo fixo de 10^{-3} segundos para as leis adaptativas convencionais e 10^{-4} segundos para o VS-MRAC. Adicionalmente, escolhemos o parâmetro $\lambda = 4$ para todas as simulações, pois intuimos que a dinâmica do filtro deve ter constante de tempo comparável à da planta, no entanto, note-se que esta escolha não respeita o valor obtido através de 2.21. Apesar disto, $\lambda = 4$ é maior que $\sup(y\phi_1) + \sup(u\phi_2)$, neste caso, como pode ser visto na Figura 3.1.

Para a SLA inicializamos os parâmetros dos modelos em $\hat{a}_{1,f}(0) = 0.5$ e $\hat{k}_{1,f}(0) = 1$, $\hat{a}_{2,f}(0) = 0.5$ e $\hat{k}_{2,f}(0) = 11$, $\hat{a}_{3,f}(0) = 7$ e $\hat{k}_{3,f}(0) = 1$, e os coeficientes da combinação

convexa em $\alpha_{1,f}(0) = 0.5$, $\alpha_{2,f}(0) = 0.5$ e $\alpha_{3,f}(0) = 0$. O modelo de primeiro nível cujas estimativas utilizamos foi inicializado em $\hat{a} = 0.5$ e $\hat{k} = 6$. Para o controle com estrutura chaveada calculamos os parâmetros $\bar{k}_1 = 4.5$ e $\bar{k}_2 = 5$ a partir de 3.15.




Figura 3.2: Estimativa do parâmetro $a_p = 3$ para a planta Σ_p de ordem 1 para o modelo de identificação por regressão linear e a SLA com $N=3$, 12 segundos de simulação

De forma a facilitar a comparação entre as estimativas, plotamos todas as estimativas de a_p no mesmo gráfico, que se encontra na Figura 3.2. Fizemos o mesmo para todas as estimativas de k_p , que estão representadas no gráfico da Figura 3.3. Escolhemos omitir as estimativas dos modelos de primeiro nível que não iniciam em $\hat{a} = 0.5$ e $\hat{k} = 6$. Entendemos que estes modelos não contribuem com informações relevantes pois são inicializados em valores distintos das estimativas de segundo nível iniciais.

Vemos nas Figuras 3.2 e 3.3 que, para uma referência degrau, as estimativas não convergem para os valores corretos, tanto no caso da SLA quanto para o modelo de identificação por regressão linear. Apesar disto, os controladores atualizados por leis integrais são capazes de cumprir o objetivo de rastreamento da saída do modelo de referência pela saída da planta, como podemos ver na Figura 3.4. Fazemos esta menção, especificamente, pois só é possível afirmar que o IMRAC é estável sem convergência de parâmetros havendo garantia disto. Isto é, como não fizemos uma prova de estabilidade do IMRAC com SLA neste trabalho, nos limitamos a afirmar que, neste caso, houve convergência.

Enquanto isso, o VS-MRAC cumpre o objetivo de rastreamento quase que instantaneamente, como podemos ver na Figura 3.5 que é um detalhe dos instantes iniciais de simulação da Figura 3.4. O motivo pelo qual o VS-MRAC consegue um desempenho tão impressionante pode ser visto na Figura 3.6, isto é, o sinal de controle é de grande intensidade e por isso consegue forçar a planta rapidamente para o comportamento desejado.




Figura 3.3: Estimativa do parâmetro $k_p = 1.5$ para a planta Σ_p de ordem 1 para o modelo de identificação por regressão linear e a SLA com $N=3$, 12 segundos de simulação




Figura 3.4: Saída da planta Σ_p de ordem 1 para o IMRAC baseado no modelo de identificação por regressão linear, SLA com $N=3$ e VS-MRAC, 12 segundos de simulação

A alta intensidade do sinal de controle para o VS-MRAC se deve à incerteza acerca dos parâmetros da planta. É fato que, se nosso conhecimento acerca da região em que se encontram os parâmetros da planta fosse mais preciso, teríamos $\bar{k}_1$ e $\bar{k}_2$ menores como condição suficiente para garantir que o erro de saída tenda a 0. Em outras palavras, se a região de incerteza acerca dos parâmetros da planta fosse menor, nosso sinal de controle poderia assumir valores menores em módulo.

Em oposição ao sinal de controle da Figura 3.6, temos os sinais de controle suaves da Figura 3.7, para o controlador com parâmetros conhecidos e o controle adaptativo usando as estimativas de primeiro e segundo nível. Note-se que, nesta aplicação ao controle, a SLA produz um sinal de controle que converge muito mais rapidamente que o modelo convencional para àquele produzido pelo controlador com parâmetros conhecidos.




Figura 3.5: Detalhe da Figura 3.4, entre 0 e 0.2 segundos de simulação




Figura 3.6: Sinal de controle para o VS-MRAC da planta de ordem 1, 12 segundos de simulação




Figura 3.7: Sinal de controle para o IMRAC baseado no modelo de identificação por regressão linear, SLA com $N=3$, e controle com parâmetros conhecidos da planta de ordem 1, 12 segundos de simulação

3.6 Conclusão

Neste Capítulo concluímos a análise do caso simples, para uma planta de ordem 1, ao abordar o problema do controle. Fizemos uso das equações de *matching* da planta de ordem 1 com parâmetros conhecidos, substituindo os parâmetros corretos por estimativas para implementar a lei de controle, e dos métodos de estimação de parâmetros, que estudamos no Capítulo 2, para obter as estimativas.

Foram feitos estudos de simulação, nos quais avaliamos que aplicar a SLA ao IMRAC produz resultados de rastreamento do sinal de saída do modelo pelo sinal de saída da planta que são mais rápidos. Comparado com o VS-MRAC, no entanto, o desempenho de rastreamento do IMRAC com SLA ainda é muito mais lento. Apesar disso, o VS-MRAC exibe um sinal de controle com alta intensidade e *chattering* enquanto o sinal de controle do IMRAC com parâmetros atualizados por leis integrais é suave, além de ser de baixa intensidade em comparação.

Capítulo 4

Estimação de Parâmetros, Ordem n

Continuamos, então, a estender resultados que obtivemos para estimação de parâmetros de plantas LIT de ordem 1 e grau relativo 1 para plantas SISO LIT de ordem n e grau relativo 1.

Em (Han & Narendra 2012, Narendra et al. 2012, Narendra et al. 2014) entre as hipóteses colocadas na modelagem do sistema estão a de que o vetor b do espaço de estado da planta é conhecido, e que as matrizes se encontram em forma companheira. Buscamos, então, o conceito de SLA para uma planta mais geral.

Neste trabalho, apresentamos o conceito de SLA baseada em modelos de identificação por regressão linear. Este conceito é distinto da SLA baseada em modelos de identificação paralelos ou série-paralelos apresentada para o caso SISO em (Narendra et al. 2015). No trabalho mencionado, os modelos de identificação são baseados em um conjunto de equações diferenciais que tem relação entrada-saída equivalente à da planta, através de um vetor de parâmetros θ , cujos elementos dependem linearmente dos coeficientes dos polinômios do denominador e numerador da função de transferência da planta e dos valores de elementos escolhidos para um par $\{\Lambda, l\}$, como pode ser verificado nas páginas 151 a 157 de (Narendra & Annaswamy 1989). Apesar da similaridade entre os dois métodos, no caso da SLA baseada em modelos de identificação por regressão linear, obtemos diretamente os coeficientes dos polinômios da função de transferência da planta.

Demonstramos a seguir, para a planta de ordem n , que uma combinação convexa de coeficientes constantes das estimativas de modelos de primeiro nível é equivalente a um modelo de primeiro nível. Isto é estritamente verdadeiro quando os erros de identificação são inicialmente nulos.

Mostramos também que mesmo que os erros não sejam inicialmente nulos, a combinação convexa dos erros de identificação tende a 0 exponencialmente dependendo de um parâmetro de projeto. Devido a esta propriedade é possível estimar os coeficientes da combinação convexa das estimativas dos modelos de primeiro nível que produzem os parâmetros verdadeiros da planta. O resultado disto, como já vimos para a planta de ordem 1, é um ganho em rapidez de convergência das estimativas de segundo nível para seus

valores corretos em relação às estimativas de primeiro nível.

Ao obtermos uma convergência mais rápida dos parâmetros, a SLA pode ser usada para gerar um sinal de controle melhor no que tange a especificações como energia utilizada e convergência para o sinal de controle do controlador com parâmetros conhecidos, ao mesmo tempo que torna o transitório da planta mais rápido e mais suave como pode ser visto recentemente em (Pandey et al. 2017) e mostraremos em resultados de simulação no Capítulo posterior a este.

Finalmente, apresentamos a SLAFF. Demonstramos por simulação que, no caso da planta estudada, a coleta de informações através de uma integral de convolução ao longo do transitório resulta numa melhora do resultado da SLA em termos de suavidade das estimativas e rapidez de convergência.

4.1 Descrição do Problema

Considere a seguinte planta LIT de ordem n e grau relativo unitário, descrita pela função de transferência:

$$\Sigma_p : G_p(s) = \frac{y(s)}{u(s)} = \frac{N_p(s)}{D_p(s)} \quad (4.1)$$

em que:

$$\begin{aligned} N_p(s) &= b_1 s^{n-1} + b_2 s^{n-2} + \dots + b_{n-1} s + b_n \\ D_p(s) &= s^n + a_1 s^{n-1} + a_2 s^{n-2} + \dots + a_{n-1} s + a_n \end{aligned} \quad (4.2)$$

e os limitantes superiores $b_1^+, \dots, b_n^+, a_1^+, \dots, a_n^+$ e inferiores $b_1^-, \dots, b_n^-, a_1^-, \dots, a_n^-$ dos parâmetros $b_1, \dots, b_n, a_1, \dots, a_n$ são conhecidos. Desta forma as combinações de limitantes $b_1^+, \dots, b_n^+, a_1^+, \dots, a_n^+$ e $b_1^-, \dots, b_n^-, a_1^-, \dots, a_n^-$ representam vértices de um politopo convexo que delimita a região de incerteza $S_{\theta,f} \in \mathbb{R}^{2n}$ dos parâmetros $b_1, \dots, b_n, a_1, \dots, a_n$ no espaço de parâmetros. A região de incerteza $S_{\theta,f}$ é conhecida. Os graus dos polinômios $N_p(s)$ e $D_p(s)$ são conhecidos.

Como no Capítulo 2, o objetivo deste Capítulo é o de identificação. Queremos conhecer os valores dos parâmetros $b_1, \dots, b_n, a_1, \dots, a_n$ da função de transferência da planta, através de medidas do sinal de entrada $u(t)$ e do sinal de saída $y(t)$. Consideramos, para tanto, que o sinal de entrada $u(t)$ é uniformemente limitado, PE de ordem n e contínuo por partes, e, além disso, assumimos que $u(t)$ é tal que há garantia que $y(t)$ é uniformemente limitado e contínuo por partes.

4.2 Estimação de Parâmetros Convencional

Ao manipular a função de transferência da planta podemos escrever, no domínio da frequência, que:

$$s^n y(s) = -a_1 s^{n-1} y(s) - \dots - a_n y(s) + b_1 s^{n-1} u(s) + \dots + b_n u(s) \quad (4.3)$$

Definimos, então, o seguinte polinômio, de grau n :

$$\Lambda(s) \triangleq s^n + \lambda_1 s^{n-1} + \lambda_2 s^{n-2} + \dots + \lambda_{n-1} s + \lambda_n \quad (4.4)$$

onde $\Lambda(s)$ é Hurwitz e mônico, e escrevemos a partir de 4.3 :

$$\frac{s^n}{\Lambda(s)} y(s) = -a_1 \frac{s^{n-1}}{\Lambda(s)} y(s) - \dots - a_n \frac{1}{\Lambda(s)} y(s) + b_1 \frac{s^{n-1}}{\Lambda(s)} u(s) + \dots + b_n \frac{1}{\Lambda(s)} u(s)$$

Então, definimos os seguintes sinais:

$$\begin{aligned} z(s) &\triangleq \frac{s^n}{\Lambda(s)} y(s) \\ \phi_1(s) &\triangleq \left[\frac{-s^{n-1} y(s)}{\Lambda(s)} \quad \dots \quad \frac{-y(s)}{\Lambda(s)} \right]^T \\ \phi_2(s) &\triangleq \left[\frac{s^{n-1} u(s)}{\Lambda(s)} \quad \dots \quad \frac{u(s)}{\Lambda(s)} \right]^T \\ \phi(s) &\triangleq \left[\frac{-s^{n-1} y(s)}{\Lambda(s)} \quad \dots \quad \frac{-y(s)}{\Lambda(s)} \quad \frac{s^{n-1} u(s)}{\Lambda(s)} \quad \dots \quad \frac{u(s)}{\Lambda(s)} \right]^T = [\phi_1^T \quad \phi_2^T]^T \\ \theta_p^* &\triangleq [a_1 \quad \dots \quad a_n \quad b_1 \quad \dots \quad b_n]^T \end{aligned} \quad (4.5)$$

onde o vetor regressor ϕ pode ser gerado através de filtros de $y(t)$ e $u(t)$:

$$\begin{aligned} \dot{\phi}_1 &= \Lambda_c \phi_1 - l y \\ \dot{\phi}_2 &= \Lambda_c \phi_2 + l u \end{aligned} \quad (4.6)$$

em que a matriz Λ_c e o vetor l são escolhidos de acordo com 4.4 e 4.5 e uma das escolhas possíveis, dado o polinômio $\Lambda(s)$, é:

$$\begin{aligned} \Lambda_c &= \begin{bmatrix} -\lambda_1 & -\lambda_2 & \dots & -\lambda_n \\ 1 & 0 & \dots & 0 \\ 0 & 1 & \dots & 0 \\ \dots & \dots & \dots & \dots \\ 0 & 0 & \dots & 1 \end{bmatrix} \\ l &= [1 \quad 0 \quad \dots \quad 0]^T \end{aligned} \quad (4.7)$$

Temos a partir de 4.5 e 4.3, portanto, a seguinte parametrização para a planta:

$$z(s) = \theta_p^{*T} \phi \quad (4.8)$$

e notamos que z depende de uma combinação linear dos componentes do vetor ϕ , cujos coeficientes são os parâmetros do numerador e denominador da função de transferência.

Podemos gerar z da seguinte forma:

$$z(t) = \frac{s^n y}{\Lambda(s)} = y - \lambda_1 \frac{s^{n-1} y(s)}{\Lambda(s)} - \dots - \lambda_n \frac{y(s)}{\Lambda(s)} = y + \lambda_f^T \phi_1 \quad (4.9)$$

onde $\lambda_f^T = [\lambda_1 \ \lambda_2 \ \dots \ \lambda_{n-1} \ \lambda_n]$.

Criamos, então, um modelo de identificação a partir de uma combinação linear dos sinais componentes do vetor ϕ como:

$$\Sigma_{1,f} : \hat{z}_{1,f} = \hat{\theta}_{1,f}^T \phi \quad (4.10)$$

e temos agora um modelo cujos parâmetros desejamos ajustar, tal que tendam aos parâmetros da planta, assim como no Capítulo 2. Queremos que a saída deste modelo se comporte identicamente ao sinal $z(t)$. Portanto, devemos avaliar a diferença entre o sinal de saída do modelo e o sinal z .

Definimos o erro de identificação:

$$e_{1,f} \triangleq \hat{z}_{1,f} - z \quad (4.11)$$

Definimos também o seguinte sinal:

$$m^2 = 1 + n_s^2 \quad (4.12)$$

onde $n_s = \phi^T \phi$ é chamado de sinal normalizador.

Para esta escolha de n_s temos que o sinal $\frac{\phi}{m}$ é uniformemente limitado, mesmo que ϕ ou m não sejam uniformemente limitados.

Então, construímos o seguinte erro de identificação normalizado:

$$\varepsilon_{1,f} = \frac{e_{1,f}}{m^2} \quad (4.13)$$

Definimos o erro paramétrico:

$$\tilde{\theta}_{1,f} \triangleq \hat{\theta}_{1,f} - \theta_p^* \quad (4.14)$$

e a partir de 4.11, 4.13 e 4.14 podemos expressar o erro de identificação normalizado como:

$$\varepsilon_{1,f} = \frac{\tilde{\theta}_{1,f}^T \phi}{m^2} \quad (4.15)$$

ou seja, o erro de identificação normalizado depende da combinação linear dos sinais do

vetor ϕ cujos coeficientes são os erros paramétricos para as estimativas dos parâmetros da função de transferência da planta.

Consideremos agora a seguinte função de custo:

$$J(\hat{\theta}_{1,f}) = \frac{\varepsilon_{1,f}^2 m^2}{2} = \frac{(\hat{\theta}_{1,f}^T \phi - z)^2}{2m^2} \quad (4.16)$$

a qual gostaríamos de minimizar em relação ao vetor $\hat{\theta}_{1,f}$. Como $\frac{\phi}{m}$ é uniformemente limitado segue que $J(\hat{\theta}_{1,f})$ é convexa em $\hat{\theta}_{1,f}$. Aplicando o método do gradiente a trajetória que minimiza $J(\hat{\theta}_{1,f})$ é dada por:

$$\dot{\hat{\theta}}_{1,f} = -\Gamma \nabla J(\hat{\theta}_{1,f}) \quad (4.17)$$

onde $\Gamma = \Gamma^T > 0$ é uma matriz diagonal, de elementos $\gamma_{ii} > 0$, com $i = 1, \dots, 2n$, chamada matriz de ganhos adaptativos.

Temos que o gradiente desta função de custo é:

$$\nabla J(\theta_{1,f}) = \frac{(\hat{\theta}_{1,f}^T \phi - z)\phi}{m^2} = \varepsilon_{1,f} \phi \quad (4.18)$$

e a partir 4.17 e 4.18 chegamos à seguinte lei adaptativa:

$$\dot{\hat{\theta}}_{1,f} = -\Gamma \varepsilon_{1,f} \phi \quad (4.19)$$

Assumimos que a planta é invariante no tempo, e, portanto, θ_p^* é constante:

$$\tilde{\theta}_{1,f} = \hat{\theta}_{1,f} - \theta_p^* \rightarrow \dot{\tilde{\theta}}_{1,f} = \dot{\hat{\theta}}_{1,f} - \overset{0}{\dot{\theta}_p^*} = \dot{\hat{\theta}}_{1,f} \quad (4.20)$$

e como no Capítulo 2, a variação do erro paramétrico $\tilde{\theta}_{1,f}$ é idêntica à variação da própria estimativa do vetor de parâmetros da planta $\hat{\theta}_{1,f}$:

$$\dot{\tilde{\theta}}_{1,f} = -\Gamma \varepsilon_{1,f} \phi \quad (4.21)$$

Consideremos agora a seguinte candidata a função de Lyapunov, como forma de avaliar a estabilidade deste estimador:

$$V(\tilde{\theta}_{1,f}) = \frac{\tilde{\theta}_{1,f}^T \Gamma^{-1} \tilde{\theta}_{1,f}}{2} \quad (4.22)$$

Derivando ao longo das trajetórias de V obtemos:

$$\dot{V} = \tilde{\theta}_{1,f}^T \phi \varepsilon_{1,f} = -\varepsilon_{1,f}^2 m^2 \leq 0 \quad (4.23)$$

e como $\dot{V}$ é semi-definida negativa, V não pode crescer (ver C.2). Isto implica em $\tilde{\theta}_{1,f}$ uniformemente limitado, o que implica em $\varepsilon_{1,f}, \varepsilon_{1,f} m$ uniformemente limitados. Como no Capítulo 2, este resultado implica que $\varepsilon_{1,f} m \in \mathcal{L}_2$. Apesar de não garantir diretamente

que $e_{1,f}$ tenda para 0, devido às condições que impomos sobre $u(t)$, temos que $\frac{\dot{\phi}}{m}, \frac{\dot{m}}{m}$ são uniformemente limitados e é possível demonstrar que $\frac{d(\varepsilon_{1,f}m)}{dt}$ é uniformemente limitado e aplicar o corolário do Lema de Barbalat (ver C.4.4). Portanto, o erro de identificação tende a 0 e a saída $\hat{z}_{1,f}$ do modelo de identificação tende para o sinal $z(t)$ assintoticamente.

Finalmente, como $u(t)$ é PE há garantia de convergência dos parâmetros para seus valores corretos. Para mais detalhes acerca deste modelo de identificação, incluindo prova da afirmação acerca da convergência dos parâmetros para seus valores corretos, referimos o leitor a (Ioannou & Sun 1996).

4.3 Adaptação de Segundo Nível

A partir da parametrização que desenvolvemos na Seção anterior, consideremos os $i = 1, \dots, N$, com $N \geq 2n + 1$, modelos de identificação por regressão linear:

$$\Sigma_{i,f} : \hat{z}_{i,f} = \hat{\theta}_{i,f}^T \phi \quad (4.24)$$

onde os vetores de parâmetros $\hat{\theta}_{i,f}$ são inicializados nos vértices de um fecho convexo no espaço de parâmetros. Este fecho convexo deve conter a região de incerteza para os componentes do vetor de parâmetros θ_p^* da planta, que é delimitada por um polítopo convexo cujos vértices são as combinações dos limitantes inferiores e superiores $b_1^+, \dots, b_n^+, a_1^+, \dots, a_n^+$ e $b_1^-, \dots, b_n^-, a_1^-, \dots, a_n^-$, que são conhecidos.

Definimos os $i = 1, \dots, N$ erros de identificação das saídas destes modelos em relação ao sinal $z(t)$:

$$e_{i,f} \triangleq \hat{z}_{i,f} - z \quad (4.25)$$

Definimos os $i = 1, \dots, N$ erros paramétricos:

$$\tilde{\theta}_{i,f} = \hat{\theta}_{i,f} - \theta_p^* \quad (4.26)$$

Definimos os $i = 1, \dots, N$ erros de identificação normalizados:

$$\varepsilon_{i,f} = \frac{e_{i,f}}{m^2} \quad (4.27)$$

e temos que:

$$\varepsilon_{i,f} = \frac{\tilde{\theta}_{i,f}^T \phi}{m^2} \quad (4.28)$$

Pelo mesmo procedimento da Seção anterior, temos que os vetores de parâmetros $\hat{\theta}_{i,f}$, $i = 1, \dots, N$ podem ser atualizados pelo método do gradiente:

$$\dot{\hat{\theta}}_{i,f} = -\Gamma \varepsilon_{i,f} \phi \quad (4.29)$$

onde os N modelos de identificação têm a mesma estrutura e, portanto, usam o mesmo tipo de lei de ajuste de seus parâmetros. Cada um dos modelos de identificação tem a diferença entre seu sinal de saída e o sinal z avaliado e este erro de identificação é usado para realizar o ajuste dos parâmetros de cada modelo a cada instante de tempo.

A partir desta lei adaptativa obtemos uma expressão para as dinâmicas $\dot{e}_{i,f}$:

$$\dot{e}_{i,f} = \ddot{\theta}_{i,f}^T \phi + \tilde{\theta}_{i,f}^T \dot{\phi} = -\frac{1}{m^2} e_{i,f} \phi^T \Gamma \phi + \tilde{\theta}_{i,f}^T \dot{\phi} \quad (4.30)$$

com $i = 1, \dots, N$.

Faremos agora um detalhamento do raciocínio que leva à SLA, como fizemos no Capítulo 2. Os vetores de parâmetros $\hat{\theta}_{i,f}$, $i = 1, \dots, N$ formam um fecho convexo no espaço de parâmetros. Cada um dos pontos no interior ou fronteira deste fecho convexo pode ser representado por uma combinação convexa:

$$\begin{aligned} \hat{\theta}_{v,f} &= \sum_{i=1}^N \hat{\theta}_{i,f} \beta_{i,f} \\ \sum_{i=1}^N \beta_{i,f} &= 1 \\ 0 &\leq \beta_{i,f} \leq 1 \end{aligned} \quad (4.31)$$

onde $\beta_{i,f}$, $i = 1, \dots, N$ são os coeficientes da combinação convexa para este modelo virtual.

Criamos, então, um modelo de identificação virtual a partir de alguma destas combinações convexas:

$$\Sigma_{v,f} : \hat{z}_{v,f} = \theta_{v,f}^T \phi \quad (4.32)$$

Definimos o erro de identificação para o modelo virtual:

$$e_{v,f} \triangleq \hat{z}_{v,f} - z \quad (4.33)$$

Definimos o erro paramétrico:

$$\tilde{\theta}_{v,f} \triangleq \hat{\theta}_{v,f} - \theta_p^* \quad (4.34)$$

e podemos manipular sua expressão:

$$\tilde{\theta}_{v,f} = \sum_{i=1}^N \hat{\theta}_{i,f} \beta_{i,f} - \theta_p^* = \sum_{i=1}^N \hat{\theta}_{i,f} \beta_{i,f} - \sum_{i=1}^N \theta_p^* \beta_{i,f} = \sum_{i=1}^N \tilde{\theta}_{i,f} \beta_{i,f} \quad (4.35)$$

onde obtemos que, assim como as estimativas do modelo virtual são combinações convexas dos parâmetros dos modelos por regressão linear, os erros paramétricos para o modelo virtual podem ser obtidos como combinações convexas dos erros paramétricos dos modelos por regressão linear, com os mesmos coeficientes de combinação.

Como o vetor de parâmetros do modelo virtual é uma combinação convexa dos parâmetros dos modelos de primeiro nível, segue que a lei de ajuste que atualiza o vetor de parâmetros do modelo virtual é a combinação convexa das leis de ajuste dos modelos de primeiro nível com os mesmos coeficientes de combinação:

$$\dot{\hat{\theta}}_{v,f} = \sum_{i=1}^N \dot{\hat{\theta}}_{i,f} \beta_{i,f} = -\Gamma \sum_{i=1}^N \epsilon_{i,f} \beta_{i,f} \phi \quad (4.36)$$

e temos que a lei de ajuste para o vetor de parâmetros do modelo virtual depende da combinação convexa dos erros de identificação normalizados dos modelos de primeiro nível. Devemos, portanto, analisar a dinâmica desta combinação convexa. Derivamos $\sum_{i=1}^N e_{i,f} \beta_{i,f}$, substituindo as dinâmicas dos erros $\dot{e}_{i,f}$ por suas expressões a partir de 4.30, as leis de ajuste $\dot{\hat{\theta}}_{i,f}$ por 4.29 e utilizando 4.35 para reagrupar as combinações convexas de erros paramétricos, obtemos a seguinte equação:

$$\sum_{i=1}^N \dot{e}_{i,f} \beta_{i,f} = - \sum_{i=1}^N \epsilon_{i,f} \beta_{i,f} \phi^T \Gamma \phi + \sum_{i=1}^N \tilde{\theta}_{i,f}^T \beta_{i,f} \dot{\phi} \quad (4.37)$$

A expressão da dinâmica do erro de identificação não normalizado do modelo virtual é da mesma forma dos modelos de primeiro nível:

$$\dot{e}_{v,f} = \tilde{\theta}_{v,f}^T \phi + \tilde{\theta}_{v,f}^T \dot{\phi} \quad (4.38)$$

e, a partir de 4.35, 4.36 e 4.38, obtemos:

$$\dot{e}_{v,f} = - \sum_{i=1}^N \epsilon_{i,f} \beta_{i,f} \phi^T \Gamma \phi + \sum_{i=1}^N \tilde{\theta}_{i,f}^T \beta_{i,f} \dot{\phi} \quad (4.39)$$

Comparamos 4.37 e 4.39 e vemos que dinâmica do erro de identificação $\dot{e}_{v,f}$ é idêntica à dinâmica da combinação convexa dos erros de identificação dos modelos de primeiro nível $\frac{d}{dt} \left(\sum_{i=1}^N e_{i,f} \beta_{i,f} \right)$. A combinação convexa dos erros de identificação tende exponencialmente para o valor do erro de identificação do modelo virtual. Se estipularmos que $e_{v,f}(0) = \sum_{i=1}^N e_{i,f}(0) \beta_{i,f}$, então os dois se tornam idênticos. Se é verdade que $e_{v,f} \equiv \sum_{i=1}^N e_{i,f} \beta_{i,f}$, então $\epsilon_{v,f} \equiv \sum_{i=1}^N \epsilon_{i,f} \beta_{i,f}$.

Feitas estas considerações, teremos, então, que a expressão da lei adaptativa para o modelo virtual da equação 4.36 se reduz a:

$$\dot{\hat{\theta}}_{v,f} = -\Gamma \epsilon_{v,f} \phi \quad (4.40)$$

e a lei adaptativa obtida acima tem forma idêntica àquela usada nos modelos de primeiro nível $\Sigma_{i,f}$, $i = 1, \dots, N$. Cada um dos pontos no interior do fecho convexo corresponde a

um modelo virtual. Conforme os modelos de primeiro nível têm seus parâmetros ajustados adaptativamente, os modelos virtuais também têm seus parâmetros ajustados por leis idênticas. Nestas condições uma combinação convexa de coeficientes constantes dos parâmetros de modelos de primeiro nível se comporta como se fosse os parâmetros de um modelo de primeiro nível inicializados nos mesmos valores.

Consideramos que os parâmetros verdadeiros da planta contidos no vetor θ_p^* pertencem inicialmente ao fecho convexo e, portanto, podem ser representados por uma combinação convexa de coeficientes $\alpha_{i,f}^*$, $i = 1, \dots, N$ dos parâmetros dos modelos de primeiro nível:

$$\begin{aligned}\theta_p^* &= \sum_{i=1}^N \hat{\theta}_{i,f} \alpha_{i,f}^* \\ \sum_{i=1}^N \alpha_{i,f}^* &= 1 \\ 0 &\leq \alpha_{i,f}^* \leq 1\end{aligned}\tag{4.41}$$

Definimos o modelo virtual:

$$\Sigma_{\alpha,f} : \hat{z}_{\alpha,f} = \theta_p^{*T} \phi\tag{4.42}$$

Definimos o erro de identificação:

$$e_{\alpha,f} \triangleq \hat{z}_{\alpha,f} - z\tag{4.43}$$

cujas dinâmica é dada por:

$$\dot{e}_{\alpha,f} = -\frac{1}{m^2} e_{\alpha,f} \phi^T \Gamma \phi\tag{4.44}$$

pois o erro paramétrico para este modelo é nulo e, portanto, desde que $\lim_{t \rightarrow \infty} \phi \neq \mathbf{0}$, temos que:

$$\lim_{t \rightarrow \infty} e_{\alpha,f} = \lim_{t \rightarrow \infty} \sum_{i=1}^N e_{i,f} \alpha_{i,f}^* = 0\tag{4.45}$$

e o erro de identificação deste modelo virtual deve tender a 0 exponencialmente.

Vemos, como no Capítulo 2, que o modelo virtual cujos parâmetros são idênticos aos da planta tende exponencialmente ao comportamento da própria planta. No entanto, não podemos garantir com modelos de identificação por regressão linear que $\sum_{i=1}^N e_{i,f}(0) \alpha_{i,f}^* = 0$ e, portanto, o valor de $e_{\alpha,f}(0)$ pode ser não-nulo. No entanto, $e_{\alpha,f}$ tende a 0 exponencialmente.

Portanto, mesmo que os parâmetros da planta deixem de pertencer ao fecho convexo devido ao efeito das condições iniciais, representadas por $e_{\alpha,f}(0)$ não-nulo, eventualmente

a combinação convexa de coeficientes $\alpha_{i,f}^*$ dos erros de identificação dos modelos de primeiro nível tende a 0. Isto indica que em regime permanente os parâmetros da planta pertencem ao fecho convexo formado pelos parâmetros dos modelos de identificação de primeiro nível.

Se a combinação convexa dos erros de identificação não-nulos se torna constante e nula a partir de um certo instante, então a combinação convexa dos erros paramétricos também deve se tornar constante e nula. Desta forma os coeficientes $\alpha_{i,f}^*$, $i = 1, \dots, N$ servem como alternativas de parametrização para a planta.

Assim, com uma segunda camada de estimação, ou segundo nível de adaptação, podemos buscar estimar os coeficientes da combinação linear. Consideramos, portanto, que a equação $\sum_{i=1}^N e_{i,f} \alpha_{i,f}^* = 0$ é uma ferramenta adequada de estimação.

Novamente, como no Capítulo 2, é por esta razão que são necessários pelo menos $N = 2n + 1$ modelos de identificação. Uma combinação convexa de $2n + 1$ vetores pertencentes ao R^{2n} tem dimensionalidade máxima igual a $2n$, fato que explicamos também no Capítulo 2. Isto é, precisamos de um número mínimo de modelos a partir do qual seja possível a existência de pelo menos uma representação dos parâmetros da planta através de uma combinação convexa de coeficientes $\alpha_{i,f}^*$, $i = 1, \dots, N$ dos parâmetros dos modelos. Também é necessário escolher os parâmetros dos modelos de forma a garantir que, inicialmente, a dimensionalidade do fecho seja a mesma da região de incerteza.

Seguimos, a partir deste ponto, um procedimento similar ao do Capítulo 2. Redefinimos o vetor $\bar{E}_f$:

$$\bar{E}_f = [\epsilon_{1,f} \quad \dots \quad \epsilon_{N-1,f} \quad \epsilon_{N,f}] \quad (4.46)$$

para que usemos os erros de identificação normalizados ao invés dos erros de identificação dos modelos de primeiro nível.

Temos em forma matricial:

$$\bar{E}_f \bar{\alpha}_f^* = \sum_{i=1}^N \epsilon_{i,f} \alpha_{i,f}^* = 0 \quad (4.47)$$

Os coeficientes de $\alpha_{i,f}$ são coeficientes de uma combinação convexa, e, portanto:

$$\sum_{i=1}^N \alpha_{i,f}^* = 1$$

e a partir disto podemos expressar $\alpha_{N,f}^*$ por:

$$\alpha_{N,f} = 1 - \sum_{i=1}^{N-1} \alpha_{i,f}^* \quad (4.48)$$

Isolamos o termo $\epsilon_{N,f}\alpha_{N,f}^*$ do somatório na equação 4.47:

$$\bar{E}_f \bar{\alpha}_f^* = \sum_{i=1}^{N-1} \epsilon_{i,f} \alpha_{i,f}^* + \epsilon_{N,f} \alpha_{N,f}^*$$

e, então, substituímos $\alpha_{N,f}$ pela expressão da equação 4.48:

$$\bar{E}_f \bar{\alpha}_f^* = \sum_{i=1}^{N-1} \epsilon_{i,f} \alpha_{i,f}^* + \epsilon_{N,f} \left(1 - \sum_{i=1}^{N-1} \alpha_{i,f}^*\right) = 0$$

que reorganizado fica da seguinte forma:

$$\sum_{i=1}^{N-1} (\epsilon_{i,f} - \epsilon_{N,f}) \alpha_{i,f}^* = -\epsilon_{N,f} \quad (4.49)$$

Redefinimos o vetor:

$$E_f = [\epsilon_{1,f} - \epsilon_{N,f} \quad \epsilon_{2,f} - \epsilon_{N,f} \quad \dots \quad \epsilon_{N-1,f} - \epsilon_{N,f}] \quad (4.50)$$

pois estamos utilizando os erros de identificação normalizados.

A equação 4.49 pode, então, ser reescrita como:

$$E_f \alpha_f^* = -\epsilon_{N,f} \quad (4.51)$$

A equação 4.51 é ponto de partida para estimar em tempo real os coeficientes da combinação convexa que produzem os parâmetros verdadeiros da planta. Substituímos o vetor α_f^* nesta equação por uma estimativa α_f , como no Capítulo 2, e a partir desta substituição podemos obter uma equação diferencial para estimar α_f^* :

$$\dot{\alpha}_f = -\gamma_{n2,f} E_f^T E_f \alpha_f - \gamma_{n2,f} E_f^T \epsilon_{N,f} \quad (4.52)$$

onde $\gamma_{n2,f} > 0$ é um parâmetro de ajuste do projetista que vamos chamar de ganho adaptativo de segundo nível.

A estimativa $\bar{\alpha}_f$ de $\bar{\alpha}_f^*$ fica da seguinte forma, como no Capítulo 2:

$$\bar{\alpha}_f^T = [\alpha_f^T \quad 1 - \vec{1} \alpha_f] \quad (4.53)$$

onde $\vec{1}$ é o vetor linha $[1 \quad 1 \quad \dots \quad 1]$ de tamanho apropriado.

Definimos, então, o erro paramétrico para a estimativa $\bar{\alpha}_f$ e para α_f :

$$\begin{aligned} \tilde{\bar{\alpha}}_f &\triangleq \bar{\alpha}_f - \bar{\alpha}_f^* \\ \tilde{\alpha}_f &\triangleq \alpha_f - \alpha_f^* \end{aligned} \quad (4.54)$$

e como assumimos $\tilde{\alpha}_f^*$ invariante no tempo, temos que:

$$\begin{aligned}\ddot{\tilde{\alpha}}_f &= \dot{\tilde{\alpha}}_f - \cancel{\dot{\tilde{\alpha}}_f}^0 = \dot{\tilde{\alpha}}_f \\ \dot{\tilde{\alpha}}_f &= \dot{\alpha}_f - \cancel{\dot{\alpha}_f}^0 = \dot{\alpha}_f\end{aligned}\quad (4.55)$$

Então, substituindo $\dot{\alpha}_f$ por $\dot{\tilde{\alpha}}_f$ e α_f por $\tilde{\alpha}_f + \alpha_f^*$ em 4.52 e cancelando os termos equivalentes devido à equação 4.51, temos:

$$\dot{\tilde{\alpha}}_f = -\gamma_{n2,f} E_f^T E_f \tilde{\alpha}_f - \gamma_{n2,f} E_f^T e_{\alpha,f} \frac{1}{m^2} \quad (4.56)$$

onde o termo $-\gamma_{n2,f} E_f^T e_{\alpha,f} \frac{1}{m^2}$ aparece devido às condições iniciais não-nulas, pois não podemos assumir $e_{\alpha,f}(0) = 0$.

Consideremos, então, a seguinte candidata a função de Lyapunov definida positiva:

$$V(\tilde{\alpha}_f) = \frac{1}{2\gamma_{n2,f}} \tilde{\alpha}_f^T \tilde{\alpha}_f \quad (4.57)$$

Derivando ao longo de suas trajetórias teremos:

$$\dot{V} = \frac{1}{\gamma_{n2,f}} \tilde{\alpha}_f^T \dot{\tilde{\alpha}}_f$$

e explicitando $\tilde{\alpha}_f$ e $\dot{\tilde{\alpha}}_f$:

$$\dot{V} = \begin{bmatrix} \tilde{\alpha}_f^T & \mathbf{1}^T \tilde{\alpha}_f \end{bmatrix} \begin{bmatrix} \dot{\tilde{\alpha}}_f \\ \mathbf{1} \dot{\tilde{\alpha}}_f \end{bmatrix}$$

ao substituírmos $\dot{\tilde{\alpha}}_f$ por 4.56 e reorganizarmos, obtemos que:

$$\dot{V} = -N \tilde{\alpha}_f^T E_f^T E_f \tilde{\alpha}_f - N \tilde{\alpha}_f^T E_f^T e_{\alpha,f} \frac{1}{m^2} \quad (4.58)$$

Na equação 4.58 o termo de sinal indefinido $-N \tilde{\alpha}_f^T E_f^T e_{\alpha,f} \frac{1}{m^2}$ tende para 0 exponencialmente pois $e_{\alpha,f}$ tende para 0 exponencialmente. Se os componentes de E_f e $\tilde{\alpha}_f$ tendem a 0 apenas assintoticamente, então o termo de sinal indefinido é, eventualmente, dominado pelo termo de sinal definido negativo $-N \tilde{\alpha}_f^T E_f^T E_f \tilde{\alpha}_f$. Nesta expressão de $\dot{V}$ fica expresso novamente que a rapidez de convergência dos parâmetros na SLA depende em algum grau do número de modelos N .

Assim, V não pode crescer a partir de um certo instante, o que implica em $\tilde{\alpha}_f$, $\tilde{\alpha}_f$ uniformemente limitados (ver C.2). $\tilde{\alpha}_f$, $\tilde{\alpha}_f$ uniformemente limitados implicam em $\tilde{\alpha}_f$, α_f uniformemente limitados. Como os erros de identificação dos modelos de primeiro nível são uniformemente limitados e α_f é uniformemente limitado isto implica em $\dot{\alpha}_f$, $\dot{\tilde{\alpha}}_f$ uniformemente limitados.

Por fim, quando o sinal de controle u for PE teremos que E_f só será o vetor nulo a partir de algum instante quando as estimativas de primeiro nível forem equivalentes aos parâmetros corretos, o que indica que uma combinação convexa destes parâmetros também tenderá para os valores corretos. A estimativa do vetor de parâmetros θ_p^* da planta, $\hat{\theta}_{n2,f}$, é entregue pela combinação convexa de coeficientes $\alpha_{i,f}$, $i = 1, \dots, N$ dos parâmetros $\hat{\theta}_{i,f}$, $i = 1, \dots, N$:

$$\hat{\theta}_{n2,f} = \text{proj}_{S_{\theta,f}}(\alpha_{1,f}\hat{\theta}_{1,f} + \alpha_{2,f}\hat{\theta}_{2,f} + \dots + \alpha_{N,f}\hat{\theta}_{N,f}) \quad (4.59)$$

em que $\text{proj}_{S_{\theta,f}}(\cdot)$ é o operador de projeção retangular dentro da região de incerteza $S_{\theta,f}$ delimitada pelo politopo convexo cujos vértices são as combinações de limitantes $b_1^+, \dots, b_n^+, a_1^+, \dots, a_n^+$ e $b_1^-, \dots, b_n^-, a_1^-, \dots, a_n^-$.

4.4 Adaptação de Segundo Nível com fator de esquecimento

No Capítulo 2 vimos que é possível acumular informações sobre os erros de identificação dos modelos de primeiro nível de forma a melhorar a convergência das estimativas dos parâmetros para seus valores corretos. No entanto, estipulamos que era adequado integrar desde o instante inicial pois consideramos a planta invariante no tempo. Na prática o uso de métodos de identificação em tempo real se dá quando os parâmetros da planta variam, o que torna métodos de identificação de parâmetros por batelada inefetivos. Neste caso, acumular informações indiscriminadamente desde o instante inicial como fizemos no Capítulo 2 não é adequado.

Se os parâmetros da planta variam, então acumular informações suficientemente recentes melhora os resultados de convergência das estimativas dos parâmetros para seus valores corretos. No entanto, acumular informações antigas pode produzir piora dos resultados. Assim, se quisermos acumular informações, devemos buscar um critério de descarte de informações consideradas antigas.

Como contribuição deste trabalho chegamos ao seguinte raciocínio, com base na ideia de Chowdhary et al. (2013) de acumular informações de instantes anteriores do sistema para melhorar a convergência das estimativas dos parâmetros, aplicada à SLA:

Em primeiro, consideremos novamente a equação 4.51 e, a partir dela, podemos escrever:

$$E_f^T E_f \alpha_f^* = -E_f^T \epsilon_{N,f} \quad (4.60)$$

Podemos integrar ambos os lados de 4.60, similarmente ao que fizemos no Capítulo

2:

$$\int_0^t e^{-\sigma(t-\tau)} E_f^T(\tau) E_f(\tau) \alpha_f^* d\tau = - \int_0^t e^{-\sigma(t-\tau)} E_f^T(\tau) \varepsilon_{N,f}(\tau) d\tau \quad (4.61)$$

e, como α_f^* é invariante no tempo, podemos colocá-lo como um fator pós-multiplicando a integral $\int_0^t e^{-\sigma(t-\tau)} E_f^T(\tau) E_f(\tau) d\tau$ para obter:

$$\int_0^t e^{-\sigma(t-\tau)} E_f^T(\tau) E_f(\tau) d\tau \alpha_f^* = - \int_0^t e^{-\sigma(t-\tau)} E_f^T(\tau) \varepsilon_{N,f}(\tau) d\tau \quad (4.62)$$

Somamos 4.60 e 4.62 e, a seguir, colocamos todos os termos no lado direito da equação:

$$0 = - \int_0^t e^{-\sigma(t-\tau)} E_f^T(\tau) E_f(\tau) d\tau \alpha_f^* - E_f^T E_f \alpha_f^* - \int_0^t e^{-\sigma(t-\tau)} E_f^T(\tau) \varepsilon_{N,f}(\tau) d\tau - E_f^T \varepsilon_{N,f} \quad (4.63)$$

onde $\sigma > 0$ é chamado fator de esquecimento e serve como nosso critério de descarte de informações. Quanto maior o valor escolhido para σ , mais rapidamente se descartam informações de instantes anteriores.

Como os erros de identificação são uniformemente limitados e tendem a 0 à medida que o tempo t tende a infinito, as integrais são limitadas e tendem a valores nulos. Substituindo α_f^* por sua estimativa e introduzindo o ganho adaptativo $\gamma_{n2,f}$, como no procedimento da Seção anterior, temos a seguinte equação:

$$\dot{\alpha}_f = \gamma_{n2,f} \left(- \int_0^t e^{-\sigma(t-\tau)} E_f^T(\tau) E_f(\tau) d\tau \alpha_f - E_f^T E_f \alpha_f - \int_0^t e^{-\sigma(t-\tau)} E_f^T(\tau) \varepsilon_{N,f}(\tau) d\tau - E_f^T \varepsilon_{N,f} \right) \quad (4.64)$$

Redefinimos as seguintes variáveis:

$$\begin{aligned} M_f &\triangleq \int_0^t e^{-\sigma(t-\tau)} E_f^T(\tau) E_f(\tau) d\tau \\ v_f &\triangleq \int_0^t e^{-\sigma(t-\tau)} E_f^T(\tau) \varepsilon_{N,f}(\tau) d\tau \end{aligned} \quad (4.65)$$

que podem ser geradas diretamente estipulando $M_f(0) = \mathbf{0}$ e $v_f(0) = \mathbf{0}$ pelas equações

diferenciais:

$$\begin{aligned}\dot{M}_f &= -\sigma M_f + E_f^T E_f \\ \dot{v}_f &= -\sigma v_f + E_f^T \epsilon_{N,f}\end{aligned}\quad (4.66)$$

Então, reescrevemos 4.64 como:

$$\dot{\alpha}_f = \gamma_{n2,f}(-M_f \alpha_f - E_f^T E_f \alpha_f - v_f - E_f^T \epsilon_{N,f}) \quad (4.67)$$

Consideremos, então, a seguinte candidata a função de Lyapunov definida positiva:

$$V = \frac{1}{2\gamma_{n2,f}} \tilde{\alpha}_f^T \tilde{\alpha}_f \quad (4.68)$$

Derivando ao longo de suas trajetórias obtemos:

$$\dot{V} = -N \tilde{\alpha}_f^T (E_f^T E_f + M_f) \tilde{\alpha}_f - N \tilde{\alpha}_f^T E_f^T e_{\alpha,f} \frac{1}{m^2} - N \tilde{\alpha}_f^T M_f \alpha_f^* \quad (4.69)$$

Temos que $N \tilde{\alpha}_f^T M_f \alpha_f^* = N \int_0^t e^{-\sigma(t-\tau)} E_f^T(\tau) e_{\alpha}(\tau) d\tau$. Novamente, como e_{α} tende a 0 exponencialmente, os termos de sinal indefinido $-N \tilde{\alpha}_f^T E_f^T e_{\alpha,f} - N \tilde{\alpha}_f^T M_f \alpha_f^*$ tendem a 0 exponencialmente. Se o restante dos sinais tende a 0 apenas assintoticamente, então os termos de sinal indefinido são, eventualmente, dominados pelo termo de sinal definido $-N \tilde{\alpha}_f^T (E_f^T E_f + M_f) \tilde{\alpha}_f$.

Com a modificação proposta, a convergência de α_f para α_f^* passa a depender de informações presentes e passadas. Postulamos, para alguma escolha do parâmetro de projeto σ , que a lei de ajuste 4.67 produz resultados melhores que 4.52. De fato, no Capítulo 2, demonstramos que ao integrar, sem descarte de informações, desde o instante inicial, temos garantia de convergência das estimativas dos parâmetros, no caso de uma planta invariante no tempo. Ou seja, há algum benefício em potencial nesta operação.

Outra forma de calcular os coeficientes corretos é monitorando o posto de M_f . Se a matriz M_f for de posto cheio pode-se calcular α_f^* diretamente por inversão de matrizes resolvendo o sistema de equações $M_f \alpha_f^* = -v_f$ para α_f^* . Neste trabalho não utilizamos esta forma de calcular os coeficientes.

Doravante, tendo introduzido esta variante da SLA, nos referimos à adaptação de segundo nível com fator de esquecimento neste texto como SLAFF (*Second Level Adaptation with Forgetting Factor*).

4.5 Resultados

Apresentamos, neste Capítulo, o modelo de identificação por regressão linear para a planta de ordem n . Discutimos suas propriedades. Demonstramos a estabilidade do esti-

mador por método do gradiente normalizado e que o erro de identificação tende a 0 para este modelo. Mencionamos que as estimativas tendem aos valores corretos na presença de um sinal de entrada com a característica de persistência de excitação.

A partir deste modelo de identificação, provamos que existem coeficientes constantes de uma combinação convexa das estimativas dos parâmetros de N ou mais modelos que produzem os parâmetros da planta. Demonstramos a SLA, que consiste em atualizar estimativas destes coeficientes para calcular uma estimativa de segundo nível dos parâmetros da planta e introduzimos o conceito de SLAFF, onde uma integral de convolução foi introduzida para fazer proveito de informações de instantes passados na lei integral da SLA.

Caso o leitor deseje consultar rapidamente, listamos as equações necessárias para identificação de parâmetros, de primeiro e segundo nível, na Tabela 4.1.

Vamos considerar a seguinte planta LIT, de ordem 2:

$$G_p(s) = \frac{N_p(s)}{D_p(s)} = \frac{b_1s + b_2}{s^2 + a_1s + a_2} = \frac{2s + 0}{s^2 + 4s + 3}$$

onde conhecemos o grau de $N_p(s)$ e $D_p(s)$ e desejamos identificar os parâmetros $b_1 = 2, b_2 = 0, a_1 = 4, a_2 = 3$. A região de incerteza para estes parâmetros é considerada conhecida:

$$a_1 \in [3 \quad 8]$$

$$a_2 \in [1 \quad 6]$$

$$b_1 \in [-1 \quad 7]$$

$$b_2 \in [-3 \quad 3]$$

Para realizar esta tarefa, utilizaremos como base um modelo de identificação por regressão linear atualizado pelo método do gradiente normalizado e, também, aplicaremos o conceito de SLA e de SLAFF usando o número mínimo de modelos $N = 5$. Para inicializar as simulações, usamos os seguintes valores:

Tabela 4.1: Equações necessárias para identificação de parâmetros para a planta de ordem n e grau relativo unitário

$\Sigma_p : \dot{x}_p = A_p x_p + b_p u$ $y_p = h_p^T x_p$ $\dot{\phi}_1 = \Lambda_c \phi_1 - l y_p$ $\dot{\phi}_2 = \Lambda_c \phi_2 + l u$ $\Lambda_c = \begin{bmatrix} -\lambda_1 & -\lambda_2 & \dots & -\lambda_n \\ 1 & 0 & \dots & 0 \\ 0 & 1 & \dots & 0 \\ \dots & \dots & \dots & \dots \\ 0 & 0 & \dots & 1 \end{bmatrix}$ $l = \begin{bmatrix} 1 & 0 \end{bmatrix}^T$ $\phi = \begin{bmatrix} \phi_1 & \phi_2 \end{bmatrix}^T$ $z = \frac{s^n y}{\Lambda(s)} = y + \lambda_f^T \phi_1$		Fonte	
		4.1, B.1, 4.9, 4.6 e 4.5	
Modelos de Primeiro Nível		Fonte	
$\Sigma_{i,f} : \hat{z}_{i,f} = \hat{\theta}_{i,f}^T \phi$ $e_{i,f} = \hat{z}_{i,f} - z$ $n_s^2 = \phi^T \phi$ $m^2 = 1 + n_s^2$ $\varepsilon_{i,f} = \frac{e_{i,f}}{m^2}$ $\Gamma = \Gamma^T > 0$ $\dot{\hat{\theta}}_{i,f} = -\Gamma \varepsilon_{i,f} \phi$		4.10, 4.12, 4.13 e 4.19	
Adaptação de Segundo Nível			
Convencional	Fonte	Fator de Esquecimento	Fonte
$E_f = \begin{bmatrix} \varepsilon_{1,f} - \varepsilon_{N,f} & \dots & \varepsilon_{N-1,f} - \varepsilon_{N,f} \end{bmatrix}$ $\dot{\alpha}_f = \gamma_{n2,f} (-E_f^T E_f \alpha_f - E_f^T \varepsilon_{N,f})$ $\bar{\Theta}_f = \begin{bmatrix} \hat{\theta}_{1,f} & \dots & \hat{\theta}_{N,f} \end{bmatrix}$ $\bar{\alpha}_f^T = \begin{bmatrix} \alpha_f^T & 1 - \bar{\mathbf{1}} \alpha_f \end{bmatrix}$ $\hat{\theta}_{n2,f} = \text{proj}_{S_{\theta,f}}(\bar{\Theta}_f \bar{\alpha}_f)$	4.50, 4.52, 4.53 e 4.59	Como convencional, exceto: $M_f(0) = \mathbf{0}$ $v_f(0) = \mathbf{0}$ $\dot{M}_f = -\sigma M_f + E_f^T E_f$ $\dot{v}_f = -\sigma v_f + E_f^T \varepsilon_{N,f}$ $X_f = M_f + E_f^T E_f$ $x_f = E_f^T \varepsilon_{N,f} + v_f$ $\dot{\alpha}_f = \gamma_{n2,f} (-X_f \alpha_f - x_f)$	4.66, 4.67, 4.53 e 4.59

$$\Lambda(s) = s^2 + \lambda_1 s + \lambda_2 = s^2 + 6s + 9$$

$$\Lambda_c = \begin{bmatrix} -\lambda_1 & -\lambda_2 \\ 1 & 0 \end{bmatrix} = \begin{bmatrix} -6 & -9 \\ 1 & 0 \end{bmatrix}$$

$$l = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$$

$$\Gamma = \begin{bmatrix} \gamma_{11} & 0 & 0 & 0 \\ 0 & \gamma_{22} & 0 & 0 \\ 0 & 0 & \gamma_{33} & 0 \\ 0 & 0 & 0 & \gamma_{44} \end{bmatrix} = 100I$$

$$x_p(0) = \begin{bmatrix} 0.2 \\ 0.4 \end{bmatrix}$$

$$\phi_1(0) = \phi_2(0) = 0$$

$$u(t) = 1 + \varepsilon_1 \sin(t) + \varepsilon_2 \sin(1.7t) + \varepsilon_3 \sin(3t) = 1 + \sin(t) + \sin(1.7t) + \sin(3t)$$

$$\alpha_{1,f}(0) = 1$$

$$\alpha_i(0) = 0, \quad i \neq 1$$

$$\gamma_{n2,f} = 10$$

$$\sigma = 0.2$$

Como $x_p(0)$ é um vetor não-nulo teremos $e_{\alpha,f}(0)$ não-nulo. Os valores das componentes senoidais para o sinal $r(t)$ PE são escolhidos com amplitudes $\varepsilon_1 = \varepsilon_2 = \varepsilon_3 = 1$ para garantir uma excitação significativa dos modos da planta, que torna a convergência dos parâmetros mais rápida. O polinômio $\Lambda(s)$ foi escolhido para ter polos que determinem uma dinâmica cuja rapidez seja comparável à da planta. Os valores dos ganhos adaptativos de primeiro e segundo nível e do fator de esquecimento foram escolhidos iterando manualmente a partir de várias simulações.

Escolhemos as seguintes estimativas iniciais do vetor θ_p para os modelos de identificação de primeiro nível:

$$\hat{\theta}_{1,f}^T(0) = [3 \quad 1 \quad -1 \quad -3]$$

$$\hat{\theta}_{2,f}^T(0) = [28 \quad 1 \quad -1 \quad -3]$$

$$\hat{\theta}_{3,f}^T(0) = [3 \quad 26 \quad -1 \quad -3]$$

$$\hat{\theta}_{4,f}^T(0) = [3 \quad 1 \quad 39 \quad -3]$$

$$\hat{\theta}_{5,f}^T(0) = [3 \quad 1 \quad -1 \quad 27]$$

onde esta escolha foi feita com base nos Teoremas 1 e 2 (ver A.1 e A.2). A região de incerteza S_{θ_f} é delimitada por um politopo convexo de 2^{2n} vértices e gostaríamos de escolher os vértices de um fecho convexo de $2n + 1$ vértices que contém a região de incerteza, para inicializar os parâmetros dos modelos. Desta forma, o Teorema 2 é diretamente aplicável. Escolhemos $p' = N = 5$, de forma que calculamos os parâme-

tros com base nos intervalos, obtendo $\hat{\theta}_{1,f}^T(0) = [3 \ 1 \ -1 \ -3]$, $\hat{\theta}_{2,f}(0) = \hat{\theta}_{1,f}(0) + N(a_1^+ - a_1^-)e_1$, $\hat{\theta}_{3,f}^T(0) = \hat{\theta}_{1,f}^T(0) + N(a_2^+ - a_2^-)e_2$, $\hat{\theta}_{4,f}^T(0) = \hat{\theta}_{1,f}^T(0) + N(b_1^+ - b_1^-)e_3$ e $\hat{\theta}_{5,f}^T(0) = \hat{\theta}_{1,f}^T(0) + N(b_2^+ - b_2^-)e_4$, com os e_i sendo vetores coluna de 4 elementos, com um elemento de valor 1 na posição i , com $i = 1, \dots, 4$, e o restante de seus elementos sendo nulos.

Observamos que não é necessário se preocupar com os altos valores de amplitude em módulo de alguns dos parâmetros iniciais obtidos para estes modelos pelos seguintes motivos:

- A estabilidade dos modelos está atrelada à estabilidade da planta, isto é, estes altos valores de amplitude não implicam em instabilidade dos modelos.
- A projeção retangular na estimativa de segundo nível impede que seus elementos assumam valores de amplitude fora da região de incerteza.
- Cada modelo de primeiro nível é independente dos demais, isto é, uma estimativa $\hat{z}_{i,f}$ não afeta as demais.
- Erros de identificação de alta amplitude implicam numa convergência mais rápida dos coeficientes da SLA

Como na simulação do Capítulo 2, omitimos as informações acerca dos parâmetros dos modelos de primeiro nível com índices $i = 2, 3, 4, 5$, pois consideramos estas informações de pouca relevância para comparar a estimação de parâmetros convencional com a SLA, já que as estimativas de segundo nível são inicializadas com valores de estimativas iguais a $\hat{\theta}_{1,f}(0)$. Queremos comparar a SLA e SLAFF com uma estimativa de primeiro nível para parâmetros iniciais iguais. Com estes valores de inicialização, obtivemos os resultados das Figuras 4.1 a 4.6.

Devido às condições que impomos sobre $u(t)$ o sinal ϕ é uniformemente limitado. Assim, o erro de identificação não normalizado deve tender a 0 quando $t \rightarrow \infty$. Isto de fato se confirma e pode ser visualizado na Figura 4.5, com uma diminuição significativa da amplitude do erro ao longo da simulação. Em comparação, o modelo virtual associado à SLA tem seu erro convergindo para 0 em $t \approx 13$ segundos, e o modelo virtual associado à SLAFF tem erro convergindo para 0 em $t \approx 5.5$ segundos, podendo ser visto mais detalhadamente em 4.6.

As estimativas de primeiro nível inicializadas em $\hat{\theta}_{1,f}(0)$ estão se aproximando dos valores corretos. As estimativas de segundo nível sem fator de esquecimento atingem os valores corretos em $t \approx 15$ segundos. As estimativas de segundo nível com fator de esquecimento atingem os valores corretos em $t \approx 6$ segundos. Podemos ver o comportamento das estimativas nas Figuras 4.1 a 4.4.

Vemos, portanto, que as estimativas de primeiro nível são mais lentas que ambos os conjuntos de estimativas de segundo nível na sua convergência para os valores corretos.




Figura 4.1: Comportamento das estimativas do coeficiente a_1 do polinômio $D_p(s)$ para o modelo de primeiro nível, SLA e SLAFF.




Figura 4.2: Comportamento das estimativas do coeficiente a_2 do polinômio $D_p(s)$ para o modelo de primeiro nível, SLA e SLAFF.

No entanto, devido à escolha de um valor alto de ganho para a SLA, vemos que 3 das estimativas exibem mudanças abruptas. Com a introdução de um fator de esquecimento na SLA, ou seja, com a SLAFF, temos como resultado uma convergência mais rápida e mais suave dos parâmetros para seus valores corretos em relação a SLA, utilizando o mesmo valor de ganho.




Figura 4.3: Comportamento das estimativas do coeficiente b_1 do polinômio $N_p(s)$ para o modelo de primeiro nível, SLA e SLAFF.

Vemos que o efeito das condições iniciais $x_p^T(0)$ decai exponencialmente e não afeta a convergência dos parâmetros significativamente.

Qualquer uma dos métodos de identificação de parâmetros que estudamos, para uma planta sujeita a um sinal PE, são adequados para o objetivo de identificação. No entanto, a lei adaptativa 4.67 da SLAFF, para os valores de parâmetros escolhidos, se mostra uma ferramenta de identificação mais efetiva em comparação com a lei adaptativa 4.52 da SLA e a lei adaptativa 4.19 do método do gradiente normalizado.

Interpretamos esta melhora de resultado da seguinte forma: $E_f^T E_f$ é obrigatoriamente de posto 1 ou 0, pois E_f é um vetor. No entanto, M_f obtida através da integral de convolução não tem restrição quanto a seu posto.

Sabemos que a multiplicação de uma matriz por um vetor pode ser interpretada como uma operação de projeção do vetor sobre os autovetores daquela matriz, pesada pelos autovalores correspondentes. Assim, consideremos a seguir a diferença entre as equações 4.67 e 4.52.

Temos que a multiplicação de $E_f^T E_f$ por α_f projeta α_f sobre o autovetor associado ao autovalor não nulo de $E_f^T E_f$ e descarta as demais informações, e, desta forma, apenas




Figura 4.4: Comportamento das estimativas do coeficiente b_2 do polinômio $N_p(s)$ para o modelo de primeiro nível, SLA e SLAFF.

parte do vetor α_f é aproveitado em 4.52. Ocorre que se α_f tiver uma grande componente ortogonal a este autovetor esta informação será descartada. Por outro lado, a multiplicação de M_f por α_f não necessariamente possui esta desvantagem em todos os instantes de tempo, pois M_f pode inclusive ser de posto cheio.

É também preciso notar que, apesar de termos obtido vantagens em simulação com a SLAFF em relação à SLA, não é possível descartar a necessidade de um sinal PE na entrada da planta, como fizemos no Capítulo 2.




Figura 4.5: Erro de identificação não normalizado do modelo de primeiro nível com estimativa inicial $\hat{\theta}_{1,f}(0)$ e dos modelos virtuais com *SLA* e *SLAFF*, 20 segundos de simulação.




Figura 4.6: Erro de identificação não normalizado do modelo de primeiro nível com estimativa inicial $\hat{\theta}_{1,f}(0)$ e dos modelos virtuais com *SLA* e *SLAFF*, 6 segundos de simulação.

4.6 Conclusão

Neste Capítulo apresentamos o modelo de identificação por regressão linear para a planta de ordem n e grau relativo unitário. Mostramos como este modelo pode servir como base para identificação através do conceito de SLA. Na SLA os coeficientes de uma combinação linear de múltiplos modelos são atualizados por uma lei integral e as estimativas são entregues por esta mesma combinação. Introduzimos o conceito de SLAFF ao modificar a SLA para admitir o acúmulo e descarte de informações passadas, com o intuito de melhorar a convergência dos parâmetros.

Tratamos apenas do problema da identificação dos parâmetros da planta de ordem n , assumindo, portanto, que os sinais são limitados à priori. Desta forma escolhemos uma planta estável e um sinal de controle uniformemente limitado, contínuo por partes e PE. Foram feitos estudos de simulação, nos quais avaliamos a SLA, a SLAFF e o método do gradiente normalizado.

Terminamos aqui nosso estudo da SLA como ferramenta de identificação de parâmetros. Tendo estudado a SLA para a planta de ordem 1 e ordem n , passaremos a seguir, no Capítulo 5, ao problema do controle da planta de ordem n e grau relativo 1 conhecida com incertezas.

No problema do controle adaptativo, dispensamos duas das premissas do problema de identificação, a de que a planta é estável ou estabilizada e a de que o sinal de controle é uniformemente limitado à priori. Assim, passaremos a nos ocupar do objetivo de calcular os parâmetros do controlador a partir das estimativas dos parâmetros da planta. A lei de controle escolhida deve produzir um sinal de controle uniformemente limitado que faça com que o sinal de saída da planta seja uniformemente limitado e cumpra o objetivo de rastreamento de um modelo de referência escolhido pelo projetista.

Capítulo 5

Controle da Planta de Ordem n

Finalmente, passamos a tratar do problema do controle de uma planta SISO LIT de ordem n de grau relativo unitário. Detalhamos como são calculados os parâmetros do controlador a partir das estimativas dos parâmetros da planta, obtendo as equações de *matching* para este caso. As estimativas dos parâmetros da planta são obtidas pelos métodos estudados no Capítulo 4 e aplicadas às equações de *matching*. Apresentamos também o VS-MRAC, na estratégia direta. No final do Capítulo, trazemos resultados de simulação para as estratégias de controle estudadas.

5.1 Descrição do Problema

Considere a planta SISO LIT, de ordem n e grau relativo 1, descrita pela seguinte função de transferência:

$$\Sigma_p : G_p(s) = \frac{y(s)}{u(s)} = \frac{N_p(s)}{D_p(s)} = k_p \frac{Z_p(s)}{D_p(s)} \quad (5.1)$$

onde apenas a saída $y(t)$ e a entrada $u(t)$ estão disponíveis para medição.

As seguintes hipóteses são verdadeiras:

- **P1** $Z_p(s)$ é mônico, Hurwitz e de grau $n - 1$
- **P2** O grau n de $D_p(s)$ é conhecido.
- **P3** O sinal de $b_1 = k_p$ é conhecido.
- **P4** $N_p(s)$ e $D_p(s)$ são coprimos

e, portanto:

$$\begin{aligned} N_p(s) &= b_1 s^{n-1} + b_2 s^{n-2} + \dots + b_{n-1} s + b_n \\ D_p(s) &= s^n + a_1 s^{n-1} + a_2 s^{n-2} + \dots + a_{n-1} s + a_n \\ k_p &= b_1 \\ Z_p(s) &= s^{n-1} + \frac{b_2}{k_p} s^{n-2} + \dots + \frac{b_{n-1}}{k_p} s + \frac{b_n}{k_p} \end{aligned} \quad (5.2)$$

onde os limitantes superiores $b_1^+, \dots, b_n^+, a_1^+, \dots, a_n^+$ e inferiores $b_1^-, \dots, b_n^-, a_1^-, \dots, a_n^-$ dos parâmetros $b_1, \dots, b_n, a_1, \dots, a_n$ são conhecidos.

Nosso objetivo é o de projetar um controlador que produza um sinal de controle $u(t)$, para atuar sobre a entrada da planta, que faça com que a saída da planta rastreie a saída de um Modelo de Referência:

$$\Sigma_m : W_m(s) = \frac{y_m(s)}{r(s)} = k_m \frac{Z_m(s)}{D_m(s)} \quad (5.3)$$

escolhido pelo projetista e que cumpre as seguintes condições:

- **M1** $Z_m(s)$ e $D_m(s)$ são Hurwitz e coprimos
- **M2** O grau de $D_m(s)$ é n
- **M3** O grau relativo de $W_m(s)$ é 1.
- **M4** $W_m(s)$ é ERP (ver C.5).

Assim, os polinômios $Z_m(s)$ e $D_m(s)$ são da seguinte forma:

$$\begin{aligned} Z_m(s) &= s^{n-1} + b_{m,2}s^{n-2} + \dots + b_{m,n-1}s + b_{m,n} \\ D_m(s) &= s^n + a_{m,1}s^{n-1} + a_{m,2}s^{n-2} + \dots + a_{m,n-1}s + a_{m,n} \end{aligned} \quad (5.4)$$

Ao alimentar o modelo de referência com um sinal de referência $r(t)$ escolhido pelo projetista, uma trajetória para a saída da planta é especificada. A lei de controle deve ser escolhida tal que os polos e zeros da função de transferência em malha fechada de r para y sejam iguais aos de $W_m(s)$. Se a função de transferência em malha fechada se torna equivalente à $W_m(s)$, então qualquer que seja o sinal de referência $r(t)$ a saída $y(t)$ da planta tenderá exponencialmente para a saída $y_m(t)$ do modelo.

5.2 Planta com Parâmetros Conhecidos

Consideremos que os coeficientes dos polinômios $N_p(s)$ e $D_p(s)$ são conhecidos.

Uma escolha óbvia para realizar o objetivo de controle da planta seria uma lei de controle em malha aberta. No entanto, note-se que não assumimos nada em relação à localização dos polos da planta. $D_p(s)$ pode inclusive conter polos no semi plano direito aberto do plano complexo. Uma lei de controle em malha aberta para uma planta instável implicaria em cancelamentos de polos e zeros no semi plano direito aberto do plano complexo, levando à instabilidade do sistema. Desta forma passamos a considerar a seguinte lei de controle por realimentação:

$$u^* = \theta_1^{*T} \frac{\Psi(s)}{\Lambda_w(s)} u + \theta_2^{*T} \frac{\Psi(s)}{\Lambda_w(s)} y + \theta_3^* y + c_0^* r = \theta^{*T} w \quad (5.5)$$

onde:

$$\begin{aligned} w &\triangleq \begin{bmatrix} \frac{\psi^T(s)}{\Lambda_w(s)}u & \frac{\psi^T(s)}{\Lambda_w(s)}y & y & r \end{bmatrix}^T \\ \psi(s) &\triangleq [s^{n-2} \quad s^{n-3} \quad \dots \quad s \quad 1]^T \\ \theta^* &\triangleq [\theta_1^{*T} \quad \theta_2^{*T} \quad \theta_3^* \quad c_0^*]^T \end{aligned} \quad (5.6)$$

Como a planta e o modelo de referência são de mesma ordem e grau relativo escolhemos $\Lambda_w(s) = Z_m(s)$. O vetor regressor de controle w pode ser gerado por:

$$\begin{aligned} \dot{w}_1 &= Fw_1 + gu \\ \dot{w}_2 &= Fw_2 + gy \\ w &\triangleq [w_1 \quad w_2 \quad y \quad r]^T \end{aligned} \quad (5.7)$$

onde F e g são escolhidos de acordo com $Z_m(s)$. Os parâmetros do controlador $c_0^*, \theta_3^* \in \mathbb{R}^1$ e $\theta_1^*, \theta_2^* \in \mathbb{R}^{n-1}$ são constantes, calculados com base nas informações dos parâmetros do modelo de referência e da planta.

Queremos um vetor $\theta^* \in \mathbb{R}^{2n}$ tal que a função de transferência em malha fechada de y para r seja equivalente à $W_m(s)$. De acordo com (Ioannou & Sun 1996) as propriedades de entrada e saída da planta em malha fechada para esta lei de controle são dadas por:

$$y = G_c(s)r \quad (5.8)$$

onde:

$$G_c(s) = \frac{c_0^* k_p Z_p Z_m^2}{Z_m[(Z_m - \theta_1^{*T} \psi) D_p(s) - k_p Z_p (\theta_2^{*T} \psi + \theta_3^* Z_m)]} \quad (5.9)$$

Gostaríamos de obter $G_c(s) = W_m(s)$:

$$\frac{c_0^* k_p Z_p Z_m^2}{Z_m[(Z_m - \theta_1^{*T} \psi) D_p(s) - k_p Z_p (\theta_2^{*T} \psi + \theta_3^* Z_m)]} = k_m \frac{Z_m}{D_m} \quad (5.10)$$

então, escolhemos:

$$c_0^* = \frac{k_m}{k_p} \quad (5.11)$$

e, a partir de 5.10, obtemos:

$$(Z_m - \theta_1^{*T} \psi) D_p(s) - k_p Z_p (\theta_2^{*T} \psi + \theta_3^* Z_m) = Z_p D_m \quad (5.12)$$

Resta encontrar θ_1^* , θ_2^* e θ_3^* que satisfaçam a equação 5.12.

Uma solução para θ_1^* , θ_2^* e θ_3^* pode ser encontrada por inspeção, de forma que temos:

$$\begin{aligned}\theta_1^{*T}\psi &= Z_m(s) - Z_p(s) \\ \theta_2^{*T}\psi + \theta_3^*Z_m(s) &= \frac{D_p(s) - D_m(s)}{k_p}\end{aligned}\quad (5.13)$$

e, como a planta é de grau relativo unitário, 5.13 resulta nas seguintes expressões para os parâmetros θ_1^* , θ_2^* e θ_3^* do controlador em função dos parâmetros da planta:

$$\begin{aligned}\theta_1^* &= \left[b_{m,2} - \frac{b_2}{k_p} \quad b_{m,3} - \frac{b_3}{k_p} \quad \dots \quad b_{m,n} - \frac{b_n}{k_p} \right]^T \\ \theta_2^* &= \left[\frac{a_2 - a_{m,2} - (a_1 - a_{m,1})b_{m,2}}{k_p} \quad \frac{a_3 - a_{m,3} - (a_1 - a_{m,1})b_{m,3}}{k_p} \quad \dots \quad \frac{a_n - a_{m,n} - (a_1 - a_{m,1})b_{m,n}}{k_p} \right]^T \\ \theta_3^* &= \frac{a_1 - a_{m,1}}{k_p}\end{aligned}\quad (5.14)$$

Definimos os seguintes vetores, para facilitar a notação de 5.14:

$$\begin{aligned}\vec{a}_p &\triangleq [a_2 \quad a_3 \quad \dots \quad a_n]^T \\ \vec{a}_m &\triangleq [a_{m,2} \quad a_{m,3} \quad \dots \quad a_{m,n}]^T \\ \vec{b}_p &\triangleq \left[\frac{b_2}{k_p} \quad \frac{b_3}{k_p} \quad \dots \quad \frac{b_n}{k_p} \right]^T \\ \vec{b}_m &\triangleq [b_{m,2} \quad b_{m,3} \quad \dots \quad b_{m,n}]^T\end{aligned}\quad (5.15)$$

de forma que, a partir de 5.14 e 5.11 temos as seguintes expressões para os parâmetros do controlador:

$$\begin{aligned}c_0^* &= \frac{k_m}{k_p} \\ \theta_1^* &= \vec{b}_m - \vec{b}_p \\ \theta_2^* &= \frac{\vec{a}_p - \vec{a}_m - (a_1 - a_{m,1})\vec{b}_m}{k_p} \\ \theta_3^* &= \frac{a_1 - a_{m,1}}{k_p}\end{aligned}\quad (5.16)$$

Chamamos as equações 5.16 de equações de *matching* da planta de ordem n e grau relativo unitário. A partir das equações de *matching* temos os parâmetros do controlador em função dos parâmetros da planta que garantem que a função de transferência entre a referência e a saída da planta é equivalente à do modelo de referência, para a lei de controle por realimentação 5.5. É importante ressaltar que só foi possível obter uma relação linear entre os parâmetros do controlador e os da planta pois estamos tratando de uma planta de grau relativo unitário.

5.3 Controle Adaptativo por Modelo de Referência Indireto

Na Seção anterior obtivemos equações para calcular os parâmetros do controlador em função dos parâmetros da planta.

Definimos os vetores:

$$\begin{aligned}\hat{\vec{a}}_p &\triangleq [\hat{a}_2 \quad \hat{a}_3 \quad \dots \quad \hat{a}_n]^T \\ \hat{\vec{b}}_p &\triangleq \begin{bmatrix} \hat{b}_2 & \hat{b}_3 & \dots & \hat{b}_n \\ \hat{k}_p & \hat{k}_p & \dots & \hat{k}_p \end{bmatrix}^T\end{aligned}\quad (5.17)$$

Podemos extrair estes vetores do vetor de estimativas dos parâmetros da planta, $\hat{\theta}_p$:

$$\hat{\theta}_p = \begin{bmatrix} \hat{a}_1 & \hat{\vec{a}}_p^T & \hat{k}_p & \hat{k}_p \hat{\vec{b}}_p^T \end{bmatrix}^T \quad (5.18)$$

onde a estimativa $\hat{\theta}_p$ é obtida a partir de algum dos métodos de estimação estudados no Capítulo 4, para a planta de ordem n . Podemos utilizar o método do gradiente normalizado a partir de um modelo de identificação por regressão linear ou a adaptação de segundo nível, com ou sem fator de esquecimento, a partir de um conjunto de $N \geq 2n + 1$ modelos de identificação por regressão linear.

Para aplicar os métodos de estimação de parâmetros que viemos estudando, vamos utilizar as equações 5.16, substituindo os parâmetros verdadeiros da planta por suas estimativas:

$$\begin{aligned}c_0 &= \frac{k_m}{\hat{k}_p} \\ \theta_1 &= \vec{b}_m - \hat{\vec{b}}_p \\ \theta_2 &= \frac{\hat{\vec{a}}_p - \vec{a}_m - (\hat{a}_1 - a_{m,1})\vec{b}_m}{\hat{k}_p} \\ \theta_3 &= \frac{\hat{a}_1 - a_{m,1}}{\hat{k}_p}\end{aligned}\quad (5.19)$$

Para limitar os parâmetros calculados, temos que a estimativa $\hat{k}_p = \hat{b}_1$ deve ser restringida, por projeção, de atingir um valor nulo. Temos, então, a seguinte lei de controle:

$$u = \theta_1^T \frac{\Psi(s)}{\Lambda_w(s)} u + \theta_2^T \frac{\Psi(s)}{\Lambda_w(s)} y + \theta_3 y + c_0 r = \theta^T w \quad (5.20)$$

Postulamos que, para estes métodos de estimação em conjunto com o cálculo dos parâmetros do controlador, o sinal de controle produzido por este controlador se aproxima do sinal de controle u^* do controlador que seria projetado caso os parâmetros da planta fossem conhecidos, e, além disso, é uniformemente limitado e contínuo por partes. Pos-

tulamos também que o sistema resultante é estável, que todos os sinais em malha fechada são uniformemente limitados e que a saída da planta rastreia a saída do modelo de referência.

Como veremos no final deste Capítulo, nossos resultados de simulação confirmam estes postulados para um caso particular. No entanto, é necessário investigar as condições suficientes para que isto ocorra em todos os casos. Portanto, uma prova analítica de estabilidade para o controlador adaptativo por modelo de referência indireto com adaptação de segundo nível para a planta de ordem n e grau relativo unitário se faz necessária. Deixamos esta prova como uma perspectiva a ser considerada para trabalhos futuros.

5.4 Controle Adaptativo por Modelo de Referência e Estrutura Variável

Consideremos a seguinte realização mínima em espaço de estado da planta:

$$\begin{aligned}\dot{x}_p &= A_p x_p + b_p u \\ y_p &= h_p^T x_p\end{aligned}\tag{5.21}$$

onde $x_p \in R^n$ é chamado vetor de estado da planta, $A_p \in R^{n \times n}$, $b_p \in R^n$, $h_p \in R^n$.

Definimos o seguinte vetor:

$$X \triangleq [x_p^T \quad w_1^T \quad w_2^T]^T\tag{5.22}$$

onde chamamos $X \in R^{3n-2}$ de vetor de estado aumentado da planta.

Definimos a matriz:

$$A_0 \triangleq \begin{bmatrix} A_p & 0 & 0 \\ 0 & F & 0 \\ g h_p^T & 0 & F \end{bmatrix}\tag{5.23}$$

Definimos o vetor:

$$b_0 \triangleq [b_p \quad g \quad 0]^T\tag{5.24}$$

Definimos, também, o vetor:

$$h_c \triangleq [h_p^T \quad 0 \quad 0]^T\tag{5.25}$$

A partir das definições 5.22, 5.23, 5.24, 5.25, e das equações 5.21 e 5.7, a dinâmica da planta em função do vetor de estado aumentado é da forma:

$$\begin{aligned}\dot{X} &= A_0 X + b_0 u \\ y_p &= h_c^T X\end{aligned}\tag{5.26}$$

Consideremos agora a lei de controle 5.5, inserindo a expressão para u em 5.26 e substituindo y por $h_c^T X$, para obter:

$$\dot{X} = A_0 + b_0(\theta_1^{*T} w_1 + \theta_2^{*T} w_2 + \theta_3^* h_c^T X + c_0^* r) \quad (5.27)$$

que reorganizado fica da seguinte forma:

$$\dot{X} = (A_0 + b_0 [\theta_3^* h_c^T \quad \theta_1^{*T} \quad \theta_2^{*T}])X + b_0 c_0^* r \quad (5.28)$$

Obtivemos os parâmetros da lei de controle 5.5 como aqueles que resultam na função de transferência em malha fechada da planta equivalente à função de transferência do modelo de referência.

Consideremos, então, uma realização mínima do modelo de referência em espaço de estado:

$$\begin{aligned} \dot{x}_m &= A_m x_m + b_m r \\ y_m &= h_p^T x_m \end{aligned} \quad (5.29)$$

Definimos o vetor de estado aumentado para o modelo de referência:

$$X_m \triangleq [x_m^T \quad w_1^T \quad w_2^T]^T \quad (5.30)$$

A lei de controle 5.5 faz com que x_p tenda para x_m exponencialmente, que faz com que X tenda para X_m exponencialmente. Desta forma a dinâmica do vetor de estado aumentado da planta é idêntica à dinâmica do vetor de estado aumentado do modelo de referência.

Definimos a matriz:

$$A_c \triangleq A_0 + b_0 [\theta_3^* h_c^T \quad \theta_1^{*T} \quad \theta_2^{*T}] \quad (5.31)$$

Definimos o vetor:

$$b_c \triangleq b_0 c_0^* \quad (5.32)$$

Feitas estas definições, a dinâmica do modelo de referência em função de seu vetor de estado aumentado é:

$$\begin{aligned} \dot{X}_m &= A_c X_m + b_c r \\ y_m &= h_c^T X_m \end{aligned} \quad (5.33)$$

Definimos o seguinte erro aumentado:

$$e \triangleq X - X_m \quad (5.34)$$

Definimos os erros paramétricos para os parâmetros do controlador:

$$\begin{aligned}\tilde{c}_0 &\triangleq c_0 - c_0^* \\ \tilde{\theta}_1 &\triangleq \theta_1 - \theta_1^* \\ \tilde{\theta}_2 &\triangleq \theta_2 - \theta_2^* \\ \tilde{\theta}_3 &\triangleq \theta_3 - \theta_3^* \\ \tilde{\theta} &\triangleq \theta - \theta^* = [\tilde{\theta}_1^T \quad \tilde{\theta}_2^T \quad \tilde{\theta}_3 \quad \tilde{c}_0]^T\end{aligned}\tag{5.35}$$

A dinâmica do erro aumentado para a lei de controle 5.20 é:

$$\dot{e} = \dot{X} - \dot{X}_m = A_c e + b_c \frac{1}{c_0^*} \tilde{\theta} w\tag{5.36}$$

Consideremos a seguinte candidata a função de Lyapunov:

$$V(e) = \frac{e^T P e}{2}\tag{5.37}$$

Derivando ao longo das trajetórias de V obtemos:

$$\dot{V} = \frac{1}{2} (e^T P (A_c e + b_c \frac{1}{c_0^*} \tilde{\theta} w) + (A_c e + b_c \frac{1}{c_0^*} \tilde{\theta} w)^T P e)\tag{5.38}$$

e como A_c é assintoticamente estável e o modelo de referência é de grau relativo unitário, com a função de transferência $W_m(s)$ escolhida ERP, podemos utilizar o lema de Meyer-Kalman-Yakubovitch (ver C.6), tal que 5.38 fica da forma:

$$\dot{V} = -e^T Q e + e^T P b_c \frac{1}{c_0^*} \tilde{\theta} w\tag{5.39}$$

onde $Q = Q^T > 0$ e $P = P^T > 0$ são matrizes definidas positivas, e A_c cumpre $A_c^T P + P A_c = -2Q$. Temos ainda que $P b_c = h_c$.

Definimos o erro de saída entre a saída da planta e a saída do modelo de referência:

$$e_o \triangleq y - y_m = h_c^T e\tag{5.40}$$

o chamado erro de saída da planta.

Finalmente, a partir de 5.39 e 5.40 e fazendo uso de $P b_c = h_c$, a expressão para $\dot{V}$ fica da seguinte forma:

$$\dot{V} = -e^T Q e + e_o \frac{1}{c_0^*} \tilde{\theta} w\tag{5.41}$$

Como no caso da planta de ordem 1, podemos encontrar limitantes superiores para o valor absoluto dos elementos dos vetores θ_1^* e θ_2^* e para os parâmetros θ_3^* e c_0^* . A partir de 5.16 e do conhecimento dos limitantes superiores $b_1^+, \dots, b_n^+, a_1^+, a_n^+$ e inferiores $b_1^-, \dots, b_n^-, a_1^-, \dots, a_n^-$ para os parâmetros da planta, os escalares θ_3^* e c_0^* obedecem às

seguintes inequações:

$$\begin{aligned} |\theta_3^*| &\leq \frac{\max(|a_1^+ - a_{m,1}|, |a_1^- - a_{m,1}|)}{\min(|k_p^+|, |k_p^-|)} \\ |c_0^*| &\leq \frac{k_m}{\min(|k_p^+|, |k_p^-|)} \end{aligned} \quad (5.42)$$

Explicitamos os componentes dos vetores θ_1^* e θ_2^* :

$$\begin{aligned} \theta_1^* &= [\theta_{1,1}^* \quad \theta_{1,2}^* \quad \dots \quad \theta_{1,n-1}^*] \\ \theta_2^* &= [\theta_{2,1}^* \quad \theta_{2,2}^* \quad \dots \quad \theta_{2,n-1}^*] \end{aligned} \quad (5.43)$$

Os elementos de θ_1^* obedecem a:

$$|\theta_{1,i}^*| \leq \max(|p_{b,1,i}|, |p_{b,2,i}|) \quad (5.44)$$

onde:

$$\begin{aligned} p_{b,1,i} &= b_{m,i} - \frac{\min(b_i^+, b_i^-)}{\max(|b_1^+|, |b_1^-|)} \\ p_{b,2,i} &= b_{m,i} - \frac{\max(b_i^+, b_i^-)}{\min(|b_1^+|, |b_1^-|)} \end{aligned} \quad (5.45)$$

com $i = 2, \dots, n$.

Os elementos de θ_2^* obedecem a:

$$|\theta_{2,i}^*| \leq \max(|p_{a,1,i}|, |p_{a,2,i}|, |p_{a,3,i}|, |p_{a,4,i}|) \quad (5.46)$$

onde:

$$\begin{aligned} p_{a,1,i} &= \frac{a_i^+ - a_{m,i} - (a_1^- - a_{m,1})b_{m,i}}{\min(|k_p^+|, |k_p^-|)} \\ p_{a,2,i} &= \frac{a_i^- - a_{m,i} - (a_1^+ - a_{m,1})b_{m,i}}{\min(|k_p^+|, |k_p^-|)} \\ p_{a,3,i} &= \frac{a_i^+ - a_{m,i} - (a_1^+ - a_{m,1})b_{m,i}}{\min(|k_p^+|, |k_p^-|)} \\ p_{a,4,i} &= \frac{a_i^- - a_{m,i} - (a_1^- - a_{m,1})b_{m,i}}{\min(|k_p^+|, |k_p^-|)} \end{aligned} \quad (5.47)$$

com $i = 2, \dots, n$.

Definimos, então, os parâmetros:

$$\begin{aligned}\bar{\theta}_{1,i} &\triangleq \max(|p_{b,1,i}|, |p_{b,2,i}|) \\ \bar{\theta}_{2,i} &\triangleq \max(|p_{a,1,i}|, |p_{a,2,i}|, |p_{a,3,i}|, |p_{a,4,i}|) \\ \bar{\theta}_3 &\triangleq \frac{\max(|a_1^+ - a_{m,1}|, |a_1^- - a_{m,1}|)}{\min(|k_p^+|, |k_p^-|)} \\ \bar{c}_0 &\triangleq \frac{k_m}{\min(|k_p^+|, |k_p^-|)}\end{aligned}\tag{5.48}$$

e, devido às equações 5.42, 5.44, 5.46, a escolha de parâmetros 5.48 garante que:

$$\begin{aligned}\bar{\theta}_{1,i} &\geq |\theta_{1,i}^*| \\ \bar{\theta}_{2,i} &\geq |\theta_{2,i}^*| \\ \bar{\theta}_3 &\geq |\theta_3^*| \\ \bar{c}_0 &\geq |c_0^*|\end{aligned}\tag{5.49}$$

A partir da equação 5.41, expandimos o termo $\tilde{\theta}w$ usando 5.35 e 5.7, tal que:

$$\dot{V} = -e^T Q e + e_o \frac{1}{c_0^*} (\tilde{\theta}_1 w_1 + \tilde{\theta}_2 w_2 + \tilde{\theta}_3 y + \tilde{c}_0 r)\tag{5.50}$$

Explicitamos os componentes de w_1 e w_2 :

$$\begin{aligned}w_1 &= [w_{1,1} \quad w_{1,2} \quad \dots \quad w_{1,n-1}] \\ w_2 &= [w_{2,1} \quad w_{2,2} \quad \dots \quad w_{2,n-1}]\end{aligned}\tag{5.51}$$

de forma que, a cada instante, podemos escolher os parâmetros do controlador de acordo com as seguintes leis chaveadas:

$$\begin{aligned}\theta_{1,i} &= -\bar{\theta}_{1,i} \text{sign}(c_0^* e_o w_{1,i}) \\ \theta_{2,i} &= -\bar{\theta}_{2,i} \text{sign}(c_0^* e_o w_{2,i}) \\ \theta_3 &= -\bar{\theta}_3 \text{sign}(c_0^* e_o y) \\ c_0 &= -\bar{c}_0 \text{sign}(c_0^* e_o r)\end{aligned}\tag{5.52}$$

com $i = 1, \dots, n-1$.

Ao fazermos esta escolha de leis chaveadas, garantimos que $\text{sign}(\frac{1}{c_0^*} \tilde{\theta}w) = -\text{sign}(e_o)$ e o termo $e_o \frac{1}{c_0^*} \tilde{\theta}w$ em 5.41 passa a ter sinal definido negativo, fazendo com que $\dot{V}$ passe a ser definida negativa. Isto implica em e uniformemente limitado e pertencente ao $\mathcal{L}_2$ (ver C.2), que consequentemente implica em e_o uniformemente limitado e pertencente ao $\mathcal{L}_2$. e_o uniformemente limitado implica em y uniformemente limitado. A partir de 5.36 concluímos que $\dot{e}$ é uniformemente limitado, o que implica em $\dot{e}_o$ uniformemente limitado. Finalmente, devido a um corolário do Lema de Barbalat (ver C.4.4), e_o deve tender a 0 pelo menos assintoticamente.

5.5 Resultados

Neste Capítulo apresentamos a lei de controle usada para que a planta rastreie a saída de um modelo de referência. É gerado um vetor regressor de controle w a partir de filtros da entrada e saída da planta. Uma combinação linear dos componentes deste regressor com os parâmetros do controlador gera o sinal de controle a ser introduzido na planta.

Os parâmetros do controlador são calculados a partir dos parâmetros estimados da planta por um mapeamento baseado nas equações de *matching* 5.16, como se os parâmetros da planta fossem conhecidos. Excetua-se o caso do VS-MRAC, onde utilizamos a estratégia direta, já que o VS-MRAC não é tema central deste trabalho, e a implementação é mais simples na estratégia direta.

Tabela 5.1: Equações necessárias para o controle da planta de ordem n e grau relativo unitário

Planta e Modelo de Referência			
Planta	Fonte	Modelo de Referência	Fonte
$\Sigma_p : \dot{x}_p = A_p x_p + b_p u$ $y_p = h_p^T x_p$	5.1 e B.1	$\Sigma_m : \dot{x}_m = A_m x_m + b_m r$ $y_m = h_m^T x_m$	5.3 e B.1
Controle			
Lei de Controle	Fonte	Equações de Matching	Fonte
$\dot{w}_1 = F w_1 + g u$ $\dot{w}_2 = F w_2 + g y$ $w = [w_1 \ w_2 \ y \ r]^T$ $u = \theta^T w$	5.7 e 5.5	$c_0 = \frac{k_m}{k_p}$ $\theta_1 = \vec{b}_m - \vec{b}_p$ $\theta_2 = \frac{\vec{a}_p - \vec{a}_m - (a_1 - a_{m,1})\vec{b}_m}{k_p}$ $\theta_3 = \frac{a_1 - a_{m,1}}{k_p}$ $\theta = [\theta_1 \ \theta_2 \ \theta_3 \ c_0]^T$	5.7 e 5.16

Caso o leitor deseje consultar rapidamente, listamos as equações necessárias neste Capítulo para o IMRAC de uma planta de ordem n e grau relativo 1 e modelo de referência de ordem n e grau relativo 1, nas Tabelas 5.1 e 5.2:

Vamos considerar a planta a seguir:

$$G_p(s) = \frac{N_p(s)}{D_p(s)} = \frac{b_1 s + b_2}{s^2 + a_1 s + a_2} = \frac{2s + 1}{s^2 - 3s - 4}$$

Desejamos estimar os coeficientes dos polinômios do numerador e denominador da função de transferência da planta $N_p(s)$ e $D_p(s)$.

Tabela 5.2: Equações necessárias para a estimação de parâmetros da planta de ordem n e grau relativo unitário

Estimativas dos Parâmetros			
Modelos de Primeiro Nível	Fonte	Estrutura Variável	Fonte
$z = \frac{s^n y}{\Lambda(s)} = y + \lambda_f^T \phi_1$ $\dot{\phi}_1 = \Lambda_c \phi_1 - l y_p$ $\dot{\phi}_2 = \Lambda_c \phi_2 + l u$ $\phi = [\phi_1^T \ \phi_2^T]^T$ $\Sigma_{i,f} : \hat{z}_{i,f} = \hat{\theta}_{i,f} \phi$ $e_{i,f} = \hat{z}_{i,f} - z$ $n_s^2 = \phi^T \phi$ $m^2 = 1 + n_s^2$ $\varepsilon_{i,f} = \frac{e_{i,f}}{m^2}$ $\Gamma = \Gamma^T > 0$ $\dot{\hat{\theta}}_{i,f} = -\Gamma \varepsilon_{i,f} \phi$ $\begin{bmatrix} \hat{a}_1 & \hat{a}_p^T & \hat{k}_p & \hat{k}_p \hat{b}_p^T \end{bmatrix}^T = \hat{\theta}_{i,f}$	4.9, 4.6, 4.5, 4.10, 4.12, 4.13, 4.19 e 5.18	$e_o = y - y_m$ $\bar{\theta}_{1,i} \geq \theta_{1,i}^* $ $\bar{\theta}_{2,i} \geq \theta_{2,i}^* $ $\bar{\theta}_3 \geq \theta_3^* $ $\bar{c}_0 \geq c_0^* $ $\theta_{1,i} = -\bar{\theta}_{1,i} \text{sign}(c_0^* e_o w_{1,i})$ $\theta_{2,i} = -\bar{\theta}_{2,i} \text{sign}(c_0^* e_o w_{2,i})$ $\theta_3 = -\bar{\theta}_3 \text{sign}(c_0^* e_o y)$ $c_0 = -\bar{c}_0 \text{sign}(c_0^* e_o r)$	5.40, 5.48 e 5.52
Nível 2	Fonte	Nível 2, Fator de Esquecimento	Fonte
$E_f = [\varepsilon_{1,f} - \varepsilon_{N,f} \ \dots \ \varepsilon_{N-1,f} - \varepsilon_{N,f}]$ $\dot{\alpha}_f = \gamma_{n2,f} (-E_f^T E_f \alpha_f - E_f^T \varepsilon_{N,f})$ $\bar{\Theta}_f = [\hat{\theta}_{1,f} \ \dots \ \hat{\theta}_{N,f}]$ $\bar{\alpha}_f^T = [\alpha_f^T \ 1 - \bar{\mathbf{1}} \alpha_f]$ $\hat{\theta}_{n2,f} = \text{proj}_{S_{\theta,f}}(\bar{\Theta}_f \bar{\alpha}_f)$ $\begin{bmatrix} \hat{a}_1 & \hat{a}_p^T & \hat{k}_p & \hat{k}_p \hat{b}_p^T \end{bmatrix}^T = \hat{\theta}_{n2,f}$	4.50, 4.52, 4.53, 4.59 e 5.18	$M_f(0) = \mathbf{0}$ $v_f(0) = \mathbf{0}$ $\dot{M}_f = -\sigma M_f + E_f^T E_f$ $\dot{v}_f = -\sigma v_f + E_f^T \varepsilon_{N,f}$ $X_f = M_f + E_f^T E_f$ $x_f = E_f^T \varepsilon_{N,f} + v_f$ $\dot{\alpha}_f = \gamma_{n2,f} (-X_f \alpha_f - x_f)$ $\bar{\Theta}_f = [\hat{\theta}_{1,f} \ \dots \ \hat{\theta}_{N,f}]$ $\bar{\alpha}_f^T = [\alpha_f^T \ 1 - \bar{\mathbf{1}} \alpha_f]$ $\hat{\theta}_{n2,f} = \text{proj}_{S_{\theta,f}}(\bar{\Theta}_f \bar{\alpha}_f)$ $\begin{bmatrix} \hat{a}_1 & \hat{a}_p^T & \hat{k}_p & \hat{k}_p \hat{b}_p^T \end{bmatrix}^T = \hat{\theta}_{n2,f}$	4.66, 4.67, 4.53, 4.59 e 5.18

A região de incerteza para os coeficientes de $N_p(s)$ e $D_p(s)$ é considerada conhecida:

$$\begin{aligned} a_1 &\in [-8 \quad -3] \\ a_2 &\in [-6 \quad -1.5] \\ b_1 &\in [1 \quad 7] \\ b_2 &\in [0.5 \quad 1.5] \end{aligned}$$

Faremos uso do modelo de identificação por regressão linear e da SLA e da SLAFF usando o número mínimo de modelos $N = 5$.

Para inicializar as simulações, usamos os seguintes valores:

$$\begin{aligned} \Lambda(s) &= s^2 + \lambda_1 s + \lambda_2 = s^2 + 6s + 9 \\ \Lambda_c &= \begin{bmatrix} -\lambda_1 & -\lambda_2 \\ 1 & 0 \end{bmatrix} = \begin{bmatrix} -6 & -9 \\ 1 & 0 \end{bmatrix} \\ l &= \begin{bmatrix} 1 \\ 0 \end{bmatrix} \\ \Gamma &= \begin{bmatrix} \gamma_{11} & 0 & 0 & 0 \\ 0 & \gamma_{22} & 0 & 0 \\ 0 & 0 & \gamma_{33} & 0 \\ 0 & 0 & 0 & \gamma_{44} \end{bmatrix} = 100I \\ x_p(0) &= \begin{bmatrix} 0.2 \\ 0.4 \end{bmatrix} \\ \phi_1(0) &= \phi_2(0) = 0 \\ r(t) &= 1 + \epsilon_1 \sin(t) + \epsilon_2 \sin(1.7t) + \epsilon_3 \sin(3t) = 1 + \sin(t) + \sin(1.7t) + \sin(3t) \\ \alpha_{1,f}(0) &= 1 \\ \alpha_i(0) &= 0, \quad i \neq 1 \\ \gamma_{n2,f} &= 10 \\ \gamma'_{n2,f} &= 3 \\ \sigma &= 6 \end{aligned}$$

Os valores das componentes senoidais para o sinal $r(t)$ PE são escolhidos com amplitudes $\epsilon_1 = \epsilon_2 = \epsilon_3 = 1$ para garantir uma excitação significativa dos modos da planta, que torna a convergência dos parâmetros mais rápida. O polinômio $\Lambda(s)$ foi escolhido para ter polos que determinem uma dinâmica cuja rapidez seja comparável à da planta. Os valores dos ganhos adaptativos de primeiro e segundo nível e do fator de esquecimento foram escolhidos iterando manualmente a partir de várias simulações, com $\gamma'_{n2,f} = 3$ na simulação para a SLA e $\gamma_{n2,f} = 10$ para SLAFF.

Escolhemos as estimativas iniciais para o vetor θ_p :

$$\begin{aligned}
\hat{\theta}_{1,f}^T(0) &= [-8 \quad -6 \quad 1 \quad 0.5] \\
\hat{\theta}_{2,f}^T(0) &= [29.5 \quad -6 \quad 1 \quad 0.5] \\
\hat{\theta}_{3,f}^T(0) &= [-8 \quad 16.5 \quad 1 \quad 0.5] \\
\hat{\theta}_{4,f}^T(0) &= [-8 \quad -6 \quad 31 \quad 0.5] \\
\hat{\theta}_{5,f}^T(0) &= [-8 \quad -6 \quad 1 \quad 5.5]
\end{aligned}$$

onde, novamente, esta escolha foi feita com base nos Teoremas 1 e 2 (ver A.1 e A.2). Escolhemos, então, $p' = N$, de forma que calculamos os parâmetros com base nos intervalos, obtendo $\hat{\theta}_{1,f}^T(0) = [-8 \quad -6 \quad 1 \quad 0.5]$, $\hat{\theta}_{2,f}^T(0) = \hat{\theta}_{1,f}^T(0) + 5(a_1^+ - a_1^-)e_1$, $\hat{\theta}_{3,f}^T(0) = \hat{\theta}_{1,f}^T(0) + 5(a_2^+ - a_2^-)e_2$, $\hat{\theta}_{4,f}^T(0) = \hat{\theta}_{1,f}^T(0) + 5(b_1^+ - b_1^-)e_3$ e $\hat{\theta}_{5,f}^T(0) = \hat{\theta}_{1,f}^T(0) + 5(b_2^+ - b_2^-)e_4$ com e_i tendo um elemento de valor 1 na posição i , com $i = 1, \dots, 4$, e os elementos restantes sendo nulos.

Observamos, novamente, que não é necessário se preocupar com os altos valores de amplitude em módulo de alguns dos parâmetros iniciais obtidos para estes modelos pelos seguintes motivos:

- A estabilidade dos modelos está atrelada à estabilidade da planta, isto é, estes altos valores de amplitude não implicam em instabilidade dos modelos, a menos que a planta em si exiba um comportamento instável fazendo com que o vetor ϕ cresça sem limite.
- A projeção retangular na estimativa de segundo nível impede que seus elementos assumam valores de amplitude fora da região de incerteza.
- Cada modelo de primeiro nível é independente dos demais, isto é, uma estimativa $\hat{z}_{i,f}$ não afeta as demais. De fato, apenas uma estimativa de primeiro nível pode ser aplicada ao IMRAC para gerar um sinal de controle, de forma que podemos escolher a mais adequada.
- Erros de identificação de alta amplitude implicam numa convergência mais rápida dos coeficientes da SLA

Consideremos, agora, o seguinte modelo de referência:

$$W_m(s) = \frac{N_m(s)}{D_m(s)} = 1 \frac{s+4}{s^2+4s+4}$$

onde desejamos que a saída da planta rastreie a saída y_m do modelo de referência. Note-se que $W_m(s)$ é ERP, com sua fase contida no intervalo entre 0 e $-\frac{\pi}{2}$ radianos.

Calculamos os parâmetros do controlador a partir das estimativas dos parâmetros da planta, com a utilização das equações 5.19. Geramos um vetor regressor de controle por filtragem do sinal de saída e do sinal de entrada da planta. Por fim, a partir do vetor de parâmetros do controlador e do regressor de controle geramos uma lei de controle, como a seguir:

$$\begin{aligned}
\Lambda_w(s) &= s + 4 \\
c_0 &= \frac{k_m}{\hat{k}_p} = \frac{1}{\hat{b}_1} \\
\theta_1 &= 4 - \frac{\hat{b}_2}{\hat{b}_1} \\
\theta_2 &= \frac{-4\hat{a}_1 + \hat{a}_2 + 12}{\hat{b}_1} \\
\theta_3 &= \frac{\hat{a}_1 - 4}{\hat{b}_1} \\
\theta &= [\theta_1 \quad \theta_2 \quad \theta_3 \quad c_0]^T \\
\dot{w}_1 &= -4w_1 + u \\
\dot{w}_2 &= -4w_2 + y \\
w &= [w_1 \quad w_2 \quad y \quad r]^T \\
u &= \theta^T w
\end{aligned}$$

Nos resultados a seguir, omitimos os gráficos obtidos para os modelos com índice $i = 2, 3, 4, 5$ por entender que, por iniciarem em valores distintos das estimativas de segundo nível, não servem como base para comparação entre a SLA e o modelo de identificação convencional. Nestas simulações usamos um passo fixo de simulação de 10^{-3} segundos. Obtivemos os seguintes resultados, mostrados nos gráficos das Figuras 5.1 a 5.7.




Figura 5.1: Comportamento das estimativas do coeficiente a_1 do polinômio $D_p(s)$ para o modelo de primeiro nível, SLA e SLAFF.

Tanto o modelo de identificação por regressão linear quanto a SLA mantêm o com-




Figura 5.2: Comportamento das estimativas do coeficiente a_2 do polinômio $D_p(s)$ para o modelo de primeiro nível, SLA e SLAFF.

portamento do sistema estável e, assim, com os parâmetros do controlador calculados a partir de suas estimativas, fazem com que a saída da planta tenda para a saída do modelo de referência. Isto pode ser visualizado na Figura 5.6, com o erro de saída tendendo para 0 no caso da SLA e SLAFF, e a amplitude do erro de saída para o modelo de primeiro nível diminuindo ao longo da simulação. Para um tempo de simulação maior, eventualmente o erro de saída para o modelo de primeiro nível também tenderá a 0. Note-se que, no caso do controle da planta instável, obtivemos resultados melhores com um fator de esquecimento muito maior que aquele utilizado no Capítulo 4, cujo valor era de 0.2.

As estimativas de primeiro nível inicializadas em $\hat{\theta}_{1,f}(0)$ se dirigem lentamente em direção aos valores corretos. As estimativas da SLA não atingem os valores corretos mas também estão se aproximando mais rapidamente de que no caso do modelo de primeiro nível. As estimativas da SLAFF chegam aos valores corretos. Podemos ver o comportamento das estimativas nas Figuras 5.1 a 5.4.

Em adição, colocamos a Figura 5.5, com os erros paramétricos $\|\tilde{\theta}\|(t)$, demonstrando que, de fato, a SLAFF atinge convergência dos parâmetros em $t \approx 15$ segundos, e a norma do erro diminui muito mais rapidamente para a SLA do que para o modelo convencional.

Vemos novamente que as estimativas de primeiro nível são mais lentas que ambos os conjuntos de estimativas de segundo nível na sua convergência para os valores corretos, como no Capítulo anterior.

Apesar de não exibir convergência dos parâmetros para o tempo de simulação escolhido, a SLA exibe convergência do sinal de controle para aquele que seria gerado caso os parâmetros da planta fossem conhecidos, como pode ser visto na Figura 5.7.




Figura 5.3: Comportamento das estimativas do coeficiente b_1 do polinômio $N_p(s)$ para o modelo de primeiro nível, SLA e SLAFF.




Figura 5.4: Comportamento das estimativas do coeficiente b_2 do polinômio $N_p(s)$ para o modelo de primeiro nível, SLA e SLAFF.




Figura 5.5: Comportamento da norma euclidiana do vetor de erro paramétrico $\tilde{\theta}_p$ para o modelo de primeiro nível, SLA e SLAFF.




Figura 5.6: Erro de saída da planta para o modelo de primeiro nível, SLA e SLAFF.

Com a introdução de um fator de esquecimento na SLA os parâmetros convergem para seus valores corretos, de forma rápida e suave, como no Capítulo anterior. Utilizamos, inclusive, um valor de ganho mais alto para a SLAFF do que o que acabamos por utilizar para a SLA, pois em simulação a SLA obteve resultados com oscilações muito bruscas para um ganho $\gamma_{n2,f} = 10$, e por fim foi necessário reduzir o valor desta variável.

O efeito das condições iniciais $x_p^T(0)$ afeta o erro de saída e produz um sinal de controle de grande amplitude no início da simulação, no caso dos controladores adaptativos.




Figura 5.7: Sinal de controle gerado pelo controlador com base nas estimativas do modelo de primeiro nível, SLA e SLAFF.

A seguir, fizemos uma simulação para o VS-MRAC. Calculamos os parâmetros $\bar{\theta}_1 = 3.93$, $\bar{\theta}_2 = 42.5$, $\bar{\theta}_3 = 12$ e $\bar{c}_0 = 1$. Nesta simulação usamos um passo fixo de simulação de 10^{-4} segundos. Mostramos os resultados nas Figuras 5.8 e 5.9:




Figura 5.8: Erro de saída da planta para o VS-MRAC.

Para o VS-MRAC, vemos na Figura 5.8 que, de fato, o erro de saída tende a uma vizinhança pequena de 0 quase que instantaneamente. Este desempenho é muito melhor que o exibido pelos controladores adaptados por leis integrais, ao compararmos as Figuras 5.8 e 5.6. Em contrapartida, o sinal de controle na Figura 5.9 exhibe *chattering* e assume




Figura 5.9: Sinal de controle gerado pelo VS-MRAC.

valores absolutos muito altos em relação ao sinal de controle do controlador para a planta com parâmetros conhecidos ou controladores adaptativos da Figura 5.7.

De fato, uma das motivações do controle em modo dual como, por exemplo em (Teixeira 2016), é o de combinar as boas características de transitório da planta para o controle com estrutura variável com o sinal de controle suave e de menor intensidade em regime permanente do controle adaptativo por leis integrais. Os trabalhos acerca do controle em modo dual têm utilizado leis adaptativas convencionais, similares à que utilizamos para o modelo de primeiro nível nesta dissertação.

Com isto em mente, questionamos se, em vez das leis adaptativas convencionais, seria possível utilizar a SLA no controle em modo dual, de forma a melhorar o desempenho do mesmo em regime permanente, como perspectiva para trabalhos futuros.

A seguir, refizemos as simulações, porém com um sinal referência $r(t) = 1$, que não é PE para este sistema:

Vemos que, na ausência de um sinal PE as estimativas dos parâmetros acabam por se manter em valores que não são os corretos. Isto pode ser visto nas Figuras 5.10 a 5.13.

A SLA faz com que o erro de saída tenda a 0 mais rapidamente que os outros dois casos, mas exibe um sobressinal maior no erro de saída, em relação ao que ocorre com a SLAFF. O modelo de identificação por regressão linear exibe uma resposta mais lenta e mais oscilatória que ambos os tipos de SLA.

Em adição, colocamos a Figura 5.14, que contém $\|\tilde{\theta}\|(t)$, demonstrando, também neste caso, que a SLAFF produz uma estimativa muito mais próxima dos parâmetros ver-




Figura 5.10: Comportamento das estimativas do coeficiente a_1 do polinômio $D_p(s)$ para o modelo de primeiro nível, SLA e SLAFF com referência degrau.




Figura 5.11: Comportamento das estimativas do coeficiente a_2 do polinômio $D_p(s)$ para o modelo de primeiro nível, SLA e SLAFF com referência degrau.

dadeiros da planta, do que a SLA ou o modelo convencional.




Figura 5.12: Comportamento das estimativas do coeficiente b_1 do polinômio $N_p(s)$ para o modelo de primeiro nível, SLA e SLAFF com referência degrau.

Apesar de as estimativas dos parâmetros não atingirem os valores corretos, todos os 3 modelos são capazes de fazer com que a saída da planta siga a saída do modelo de referência e produzir um sinal de controle em regime permanente que é igual ao sinal de controle do controlador ideal, como pode ser visto nas Figuras 5.15 e 5.16. Novamente, como no Capítulo 3, esta menção é feita de forma específica para esta simulação, pois não fizemos uma prova de estabilidade para o IMRAC com SLA ou SLAFF. No entanto, como não houve convergência dos parâmetros para seus valores corretos, uma mudança qualquer no sinal de referência da planta certamente causará um novo transitório de adaptação das estimativas dos parâmetros.

A seguir, colocamos os resultados para o VS-MRAC, nas Figuras 5.17 e 5.18.

Novamente, obtivemos um erro de saída que tende para uma vizinhança pequena de 0 muito rapidamente, como podemos ver na Figura 5.17. Apesar disso, o sinal de controle exibe *chattering* e assume valores muito grandes em módulo, como podemos ver na Figura 5.18. Estas características do sinal de controle podem se mostrar indesejáveis ou mesmo intoleráveis, a depender do sistema ou processo a ser controlado. Além disso, um sinal de controle maior em módulo implica em maior gasto de energia.




Figura 5.13: Comportamento das estimativas do coeficiente b_2 do polinômio $N_p(s)$ para o modelo de primeiro nível, SLA e SLAFF com referência degrau.




Figura 5.14: Comportamento da norma euclidiana do vetor de erro paramétrico $\tilde{\theta}_p$ para o modelo de primeiro nível, SLA e SLAFF com referência degrau.




Figura 5.15: Erro de saída da planta para o modelo de primeiro nível, SLA e SLAFF com referência degrau.




Figura 5.16: Sinal de controle gerado pelo controlador com base nas estimativas do modelo de primeiro nível, SLA e SLAFF com referência degrau.




Figura 5.17: Erro de saída da planta para o VS-MRAC com referência degrau.




Figura 5.18: Sinal de controle gerado pelo VS-MRAC com referência degrau.

5.6 Conclusão

Neste Capítulo apresentamos brevemente o problema do IMRAC para o caso da planta SISO de ordem n e grau relativo 1, onde os parâmetros do controlador são calculados a partir de um mapeamento obtido pelas equações de *matching*, considerando as estimativas como se fossem os parâmetros verdadeiros. Dispensamos a hipótese que assumimos para o Capítulo 4 de que a planta seja estável e adotamos uma lei de controle capaz de estabilizar a planta.

Mostramos que a SLA pode, no caso das simulações que fizemos, substituir o método do gradiente normalizado na entrega das estimativas dos parâmetros da planta, sem perda das propriedades de estabilidade do sistema. Na SLA os coeficientes de uma combinação linear de múltiplos modelos são atualizados por uma lei integral e as estimativas são entregues por esta mesma combinação.

Simulamos também o VS-MRAC na estratégia direta, comparando seus resultados com aqueles obtidos para o controle adaptativo por leis integrais. Vimos que, apesar de atingir um desempenho muito superior em relação à convergência do erro de saída para 0, o controle com estrutura variável exibe um sinal de controle que pode se mostrar indesejável em regime permanente, devido à alta intensidade e ao *chattering*.

Foram feitos estudos de simulação do controle de uma planta instável, nos quais avaliámos a SLA e a SLAFF em relação ao modelo por regressão linear para o caso SISO aplicadas ao IMRAC. Também comparamos estes resultados com o VS-MRAC na estratégia direta. Terminamos aqui os temas que gostaríamos de abordar para esta dissertação.

Capítulo 6

Conclusões e Perspectivas

Neste trabalho apresentamos a SLA, que é uma nova ferramenta de identificação/estimação de parâmetros, e mostramos a aplicação do conceito a plantas SISO LIT com grau relativo unitário.

Devido ao uso das informações de múltiplos modelos de identificação em conjunto, as estimativas dos parâmetros exibem uma convergência mais rápida na adaptação de segundo nível, quando comparada com modelos de identificação convencionais. Esta convergência mais rápida dos parâmetros se traduz, quando aplicada ao IMRAC, numa melhor ação de controle.

Nesta dissertação de mestrado nossas contribuições foram as seguintes:

- 1 Explicitar o conceito de adaptação de segundo nível para identificação dos parâmetros de uma planta de ordem n e grau relativo 1, tendo como base o modelo por regressão linear cujos parâmetros são atualizados pelo método do gradiente normalizado para o caso SISO, discutindo suas propriedades. O modelo de identificação utilizado para a SLA de uma planta SISO LIT de ordem n em (Narendra et al. 2015) é do tipo paralelo (representação I) ou série-paralelo (representação II). Nestas representações, as estimativas obtidas dependem tanto da planta quanto dos valores escolhidos para os filtros. No entanto, ao usar como base o modelo por regressão linear, obtém-se diretamente as estimativas dos coeficientes dos polinômios da função de transferência da planta.
- 2 O conceito de SLAFF, onde fizemos a introdução de um fator de esquecimento na lei integral da SLA, de forma a acumular uma parcela de informações passadas e melhorar as propriedades de convergência das estimativas dos parâmetros da planta para seus valores corretos.

Entre as perspectivas futuras estão:

- 1 Uma prova de estabilidade do IMRAC com SLA para a planta de ordem n e grau relativo unitário. Embora tenhamos uma prova de estabilidade para o estimador neste trabalho, as condições dentro das quais a aplicação da SLA ao IMRAC produz um controlador estável são de natureza crucial para qualquer aplicação prática, e devem ser conhecidas. Este tipo de controlador exibe estabilidade global?

- 2 O uso das estimativas de segundo nível nos controladores adaptativos em modo dual, que foram mencionados na introdução e no Capítulo 5, para a estratégia indireta.
- 3 Uma aplicação da adaptação de segundo nível ao controle adaptativo por posicionamento de polos na estratégia indireta, de forma que seja possível aplicar o conceito para plantas de fase não mínima.
- 4 Um estudo da robustez a distúrbios e dinâmicas não modeladas, para a SLA aplicada ao IMRAC.
- 5 O uso da SLA dentro de uma hierarquia de estimadores, onde várias técnicas, como por exemplo o chaveamento entre modelos de identificação, são utilizadas concorrentemente, como discutido por Narendra em (Narendra 2016).
- 6 Implementação prática da SLA aplicada ao IMRAC de uma planta real, como por exemplo um motor de indução ou controle de nível de reservatório.

Há, de fato, muitas direções em que o trabalho acerca da SLA pode ser desenvolvido, por se tratar de algo recente. Como mencionamos na introdução, esta é uma das primeiras dissertações de mestrado feitas no Brasil acerca deste tema. Desta forma esperamos que esta dissertação sirva como um guia inicial de uso do conceito de adaptação de segundo nível e como ponto de partida para novos trabalhos acerca deste método.

Referências Bibliográficas

- Aström, Karl (2014), 'History of adaptive control', pp. 1–9.
URL: https://doi.org/10.1007/978-1-4471-5102-9_120-1
- Bitmead, R. (1984), 'Persistence of excitation conditions and the convergence of adaptive schemes', *IEEE Transactions on Information Theory* **30**(2), 183–191.
- Boyd, S. & S. S. Sastry (1986), 'Necessary and sufficient conditions for parameter convergence in adaptive control', *Automatica* **22**(6), 629–639.
- Chen, Chi-Tsong (1999), *Linear system theory and design*, Oxford University Press.
- Chowdhary, Girish, Tansel Yucelen, Maximillian Mühlegg & Eric N. Johnson (2013), 'Concurrent learning adaptive control of linear systems with exponentially convergent bounds', *International Journal of Adaptive Control and Signal Processing* **27**(4), 280–301.
URL: <http://dx.doi.org/10.1002/acs.2297>
- Costa, R. R. & L. Hsu (1991), 'Unmodeled dynamics in adaptive control systems revisited', *Systems & Control Letters* **16**, 341–348.
- Cunha, C. D. (2008), Controlador em modo dual adaptativo robusto - DMARC, Tese de doutorado, Universidade Federal do Rio Grande do Norte, Natal, RN.
- Cunha, C. D., A. D. Araujo & F. C. Mota (2007), 'Controlador em modo dual adaptativo robusto para plantas com grau relativo unitário: Prova de estabilidade', *Revista Controle e Automação* **18**(2), 223–232.
- Cunha, C. D., A. D. Araujo & F. C. Mota (2009), 'Controlador em modo dual adaptativo robusto para plantas com grau relativo arbitrário', *Revista Controle e Automação* **20**(1), 72–82.
- Evans, W. R. (1948), 'Graphical analysis of control systems', *Transactions of the American Institute of Electrical Engineers* **67**(1), 547–551.
- Fernandes, M. V. A., S. M. Dias, A. D. Araujo, J. B. Oliveira & K. I. M. P. Queiroz (2010), Shunt indirect variable structure model reference adaptive controller for plants with arbitrary relative degree, *em* 'Proceedings of 11th International Workshop on Variable Structure Systems 1', pp. 283–288.

- Gushiken, P. Y. & A. D. Araujo (2016), 'Adaptação de segundo nível usando modelos fixos com desligamento do sinal persistentemente excitante', *Anais do XXI Congresso Brasileiro de Automática. Vitória - Espírito Santo* pp. 1–6.
- Han, Z. & K. S. Narendra (2011), Second level adaptation using multiple models, *em* 'Proceedings of the 2011 American Control Conference', pp. 2350–2355.
- Han, Z. & K. S. Narendra (2012), 'New concepts in adaptive control using multiple models', *IEEE Transactions on Automatic Control* **57**(1), 78–89.
- Hsu, L. (1990), 'Variable structure model reference adaptive control using only input and output measurements: The general case', *IEEE Trans. Automatic Control* **AC-35**(11), 1238–1243.
- Hsu, L., A. D. Araujo & R. R. Costa (1994), 'Analysis and design of i/o based variable structure adaptive control', *IEEE Trans. Automatic Control* **39**(1), 4–21.
- Hsu, L. & R. R. Costa (1989), 'Variable structure model reference adaptive control using only input and output measurements - part i', *International Journal of Control* **49**(2), 399–416.
- Ioannou, Petros A. & Jing Sun (1996), *Robust adaptive control*, Pearson Education, Inc.
- Khalil, Hassan K. (1996), *Nonlinear systems*, Prentice Hall.
- Ljung, Lennart (1999), *System identification - theory for the user*, Prentice-Hall.
- Lyapunov, A. M. (1992), 'The general problem of the stability of motion', *International Journal of Control* **55**(3), 531–534.
URL: <https://doi.org/10.1080/00207179208934253>
- Narendra, K. S. & A. M. Annaswamy (1987), 'Persistent excitation in adaptive systems', *International Journal of Control* **45**(1), 127–160.
URL: <http://dx.doi.org/10.1080/00207178708933715>
- Narendra, K. S. & A. M. Annaswamy (1989), *Stable adaptive systems*, Prentice-Hall.
- Narendra, K. S. & J. Balakrishnan (1994), 'Improving transient response of adaptive control systems using multiple models and switching', *IEEE Transactions on Automatic Control* **39**(9), 1861–1866.
- Narendra, K. S. & J. Balakrishnan (1997), 'Adaptive control using multiple models', *IEEE Transactions on Automatic Control* **42**(2), 171–187.
- Narendra, K. S., J. Balakrishnan & M. K. Ciliz (1995), 'Adaptation and learning using multiple models, switching, and tuning', *IEEE Control Systems* **15**(3), 37–51.
- Narendra, K. S., Y. Wang & W. Chen (2014), Stability, robustness, and performance issues in second level adaptation, *em* 'American Control Conference (ACC), 2014', pp. 2377–2382.

- Narendra, K. S., Yu Wang & Wei Chen (2015), Extension of second level adaptation using multiple models to siso systems, *em* '2015 American Control Conference (ACC)', pp. 171–176.
- Narendra, K. S. & Z. Han (2010), Location of models in multiple-model based adaptive control for improved performance, *em* 'American Control Conference (ACC), 2010', pp. 117–122.
- Narendra, K.S. (2016), Chapter two - hierarchical adaptive control of rapidly time-varying systems using multiple models, *em* K. G. Vamvoudakis & S. Jagannathan, eds., 'Control of Complex Systems', Butterworth-Heinemann, pp. 33 – 66.
URL: <https://www.sciencedirect.com/science/article/pii/B9780128052464000021>
- Narendra, Kumpati S., Yu Wang & Wei Chen (2012), The rationale for second level adaptation, *em* 'The 16th Yale Workshop on Adaptive and Learning Systems', Yale University.
- Nyquist, H. (1932), 'Regeneration theory', *The Bell System Technical Journal* **11**(1), 126–147.
- Ogata, Katsuhiko (2010), *Modern control engineering*, Pearson Education, Inc.
- Oliveira, J. B. (2003), Controle adaptativo indireto por modelo de referência e estrutura variável, Dissertação de mestrado, Universidade Federal do Rio Grande do Norte, Natal, RN.
- Oliveira, J. B. (2007), Estabilidade e robustez de um controlador adaptativo indireto por modelo de referência e estrutura variável, Tese de doutorado, Universidade Federal do Rio Grande do Norte, Natal, RN.
- Oliveira, J. B. & A. D. Araujo (2008a), 'Design and stability analysis of an indirect variable structure model reference adaptive control', *International Journal of Control* **81**(12), 1870–1877.
- Oliveira, J. B. & A. D. Araujo (2008b), A modified design for the vs-mrac based on the indirect approach: Stability analysis, *em* 'Proceedings of the 17th IFAC 2008 WC 1', pp. 13121–13126.
- Pandey, V. K., I. Kar & C. Mahanta (2017), Controller design for a 3-dof helicopter using multiple models with second level adaptation, *em* '2017 Indian Control Conference (ICC)', pp. 99–104.
- Rohrs, C. E., L. Valavani, M. Athans & G. Stein (1985), 'Robustness of continuous-time adaptive control algorithms in the presence of unmodeled dynamics', *IEEE Trans. Automatic Control* **AC-30**(9), 881–889.
- Simon, Herbert A. (1956), 'Dynamic programming under uncertainty with a quadratic criterion function', *Econometrica* **24**(1), 74–81.
URL: <http://www.jstor.org/stable/1905261>

- Tao, G. (2003), *Adaptive control design and analysis*, Wiley.
- Teixeira, L. R. L. (2011), Uma abordagem indireta para o controlador em modo dual adaptativo robusto, Dissertação de mestrado, Universidade Federal do Rio Grande do Norte, Natal, RN.
- Teixeira, L. R. L., J. B. Oliveira & A. D. Araujo (2013), An intuitive design for the dual mode adaptive robust controller based on indirect control, *em* 'Proceedings of the European Control Conference 2013 - ECC '13 1', pp. 4526–4531.
- Teixeira, L. R. L., J. B. Oliveira & A. D. Araujo (2015), 'Smooth indirect adaptive sliding mode control', *International Journal of Robust and Nonlinear Control* **25**(6), 775–790.
- Teixeira, Leonardo Rodrigues de Lima (2016), Controlador em modo dual adaptativo robusto indireto (IDMARC). 2016. 93f, Tese de doutorado, Universidade Federal do Rio Grande do Norte, Natal.
- Utkin, V. (1977), 'Variable structure systems with sliding modes', *IEEE Transactions on Automatic Control* **22**(2), 212–222.
- Utkin, V.L. (1978), *Sliding Modes and Their Application in Variable Structure Systems*, Imported Publications, Incorporated.
URL: <https://books.google.com.br/books?id=KWoyAAAACAAJ>
- Yanque, I., E. V. L. Nunes, R. R. Costa & L. Hsu (2012), Binary mimo mrac using a passifying multiplier - a smooth transition to sliding mode control, *em* 'Proceedings of the 2012 American Control Conference', pp. 1925–1930.

Apêndice A

Combinações Convexas

Um conjunto K em um espaço linear L é chamado convexo se o segmento de reta ab estiver contido em K para quaisquer elementos $a, b \in K$, isto é, $x_t = (1-t)a + tb \in K$ para qualquer $a, b \in K$, para qualquer $t \in [0, 1]$.

Sejam $a_1, a_2, \dots, a_n$ elementos arbitrários de um espaço linear L e $\lambda_1, \lambda_2, \dots, \lambda_n$ sejam números reais. O elemento $a = a_1\lambda_1 + a_2\lambda_2 + \dots + a_n\lambda_n$ é chamado uma combinação linear de $a_1, a_2, \dots, a_n$. Se todos os números $\lambda_1, \lambda_2, \dots, \lambda_n$ são não negativos e $\lambda_1 + \lambda_2 + \dots + \lambda_n = 1$ então, o elemento a é chamado de combinação convexa dos elementos $a_1, a_2, \dots, a_n$.

Deixe que K seja um subconjunto convexo do espaço linear L . Então, todas as combinações convexas dos elementos de K pertencem a K .

O fecho convexo K_c de um conjunto de pontos P de um espaço linear L é o menor subconjunto convexo que contém todos os pontos do conjunto P .

A.1 Teorema 1

Considere uma classe de vetor $w_u \in R^p$, cujos elementos $w_{u,i}$, $i = 1, \dots, p$, pertencem à intervalos fechados $[0, 1]$. Esta classe de vetor está contida num politopo convexo $P_{u,1}$ de 2^p vértices, que são representados pelas linhas da seguinte matriz $W_u \in R^{2^p \times p}$:

$$W_u = \begin{bmatrix} 0 & \dots & 0 & 0 \\ 0 & \dots & 0 & 1 \\ 0 & \dots & 1 & 0 \\ 0 & \dots & 1 & 1 \\ \dots & \dots & \dots & \dots \\ 1 & \dots & 0 & 0 \\ 1 & \dots & 0 & 1 \\ 1 & \dots & 1 & 0 \\ 1 & \dots & 1 & 1 \end{bmatrix} \quad (\text{A.1})$$

Para este politopo convexo, há um outro politopo convexo $P_{u,2}$ cujos $p+1$ vértices

são definidos pelo vetor nulo $\vec{0}$ e pelos vetores pe_i , onde $e_i = [0 \ \dots \ 0 \ 1 \ 0 \ \dots \ 0]^T$ e o elemento de valor 1 se encontra na posição i , com $i = 1, \dots, p$.

O polítopo convexo $P_{u,2}$ contém o polítopo convexo $P_{u,1}$. Cada um dos pontos no interior de $P_{u,1}$ pode ser representado como uma combinação convexa dos $p+1$ vértices de $P_{u,2}$.

Prova: Vamos considerar a classe de vetor w_u :

$$w_u = [w_{u,1} \ w_{u,2} \dots \ w_{u,p}]^T \quad (\text{A.2})$$

a partir dos vértices não-nulos de $P_{u,2}$ podemos escrever w_u como:

$$w_u = \frac{w_{u,1}}{p}e_1 + \frac{w_{u,2}}{p}e_2 + \dots + \frac{w_{u,p}}{p}e_p \quad (\text{A.3})$$

Definimos os seguintes escalares:

$$\alpha_i = \frac{w_{u,i}}{p} \quad (\text{A.4})$$

com $i = 1, \dots, p$.

Para esta representação de w_u , verifica-se por inspeção que:

$$0 \leq \alpha_i \leq 1 \quad (\text{A.5})$$

com $i = 1, \dots, p$, devido ao intervalo em que os $w_{u,i}$, $i = 1, \dots, p$ estão contidos. Adicionalmente, a seguinte desigualdade também é verdadeira:

$$0 \leq \sum_{i=1}^p \frac{w_{u,i}}{p} \leq 1 \quad (\text{A.6})$$

pois verificamos por inspeção que o somatório assume valor máximo $\sum_{i=1}^p \frac{w_{u,i}}{p} = 1$ quando todos os $w_{u,i} = 1$ e valor mínimo $\sum_{i=1}^p \frac{w_{u,i}}{p} = 0$ quando todos os $w_{u,i} = 0$, não podendo assumir valores fora deste intervalo fechado.

Estipulamos, então, que:

$$\alpha_0 = 1 - \sum_{i=1}^p \frac{w_{u,i}}{p} \quad (\text{A.7})$$

e devido à A.6, temos que:

$$0 \leq \alpha_0 \leq 1 \quad (\text{A.8})$$

Finalmente, w_u pode ser representado por:

$$w_u = \alpha_0 \vec{0} + \alpha_1 e_1 + \alpha_2 e_2 + \dots + \alpha_p e_p \quad (\text{A.9})$$

onde os coeficientes α_i , $i = 0, \dots, p$, cumprem a condição remanescente de convexidade, devido a A.7, de que:

$$\sum_{i=0}^p \alpha_i = 1 \quad (\text{A.10})$$

e tendo A.10 e A.8 em conjunto com A.5, temos que a representação A.9 da classe de vetor w_u trata-se de uma combinação convexa. Portanto, $P_{u,2}$ contém $P_{u,1}$ e cada um dos pontos no interior do politopo $P_{u,1}$ pode ser representado como uma combinação convexa dos $p+1$ vértices do politopo $P_{u,2}$.

Corolário: Qualquer politopo convexo $P_{u,3}$ cujos $p+1$ vértices são definidos pelo vetor nulo $\vec{0}$ e pelos vetores $p'e_i$, com $p' \geq p$ contém $P_{u,2}$ e $P_{u,1}$.

A.2 Teorema 2

Seja a classe de vetor $w_x \in R^p$, cujos elementos estão contidos em intervalos fechados $[w_{x,i}^-, w_{x,i}^+]$, com $i = 1, \dots, p$. Esta classe de vetor está contida num politopo convexo $W_{x,1}$ de 2^p vértices, que são representados pelas linhas da seguinte matriz $W_x \in R^{2^p \times p}$:

$$W_x = \begin{bmatrix} w_{x,1}^- & \dots & w_{x,p-1}^- & w_{x,p}^- \\ w_{x,1}^- & \dots & w_{x,p-1}^- & w_{x,p}^+ \\ w_{x,1}^- & \dots & w_{x,p-1}^+ & w_{x,p}^- \\ w_{x,1}^- & \dots & w_{x,p-1}^+ & w_{x,p}^+ \\ \dots & \dots & \dots & \dots \\ w_{x,1}^+ & \dots & w_{x,p-1}^- & w_{x,p}^- \\ w_{x,1}^+ & \dots & w_{x,p-1}^- & w_{x,p}^+ \\ w_{x,1}^+ & \dots & w_{x,p-1}^+ & w_{x,p}^- \\ w_{x,1}^+ & \dots & w_{x,p-1}^+ & w_{x,p}^+ \end{bmatrix} \quad (\text{A.11})$$

Para este politopo convexo, há um outro politopo convexo $W_{x,2}$ cujos $p+1$ vértices são definidos pelo vetor $w_x^- = [w_{x,1}^- \ w_{x,2}^- \ \dots \ w_{x,p}^-]^T$ e pelos vetores $w_x^- + pe_i(w_{x,i}^+ - w_{x,i}^-)$, onde $e_i = [0 \ \dots \ 0 \ 1 \ 0 \ \dots \ 0]^T$ e o elemento de valor 1 se encontra na posição i , com $i = 1, \dots, p$.

O politopo convexo $W_{x,2}$ contém o politopo convexo $W_{x,1}$. Cada um dos pontos no interior de $W_{x,1}$ pode ser representado como uma combinação convexa dos $p+1$ vértices de $W_{x,2}$.

Prova: Vamos considerar a classe de vetor w_x :

$$w_x = [w_{x,1} \ w_{x,2} \ \dots \ w_{x,p}]^T \quad (\text{A.12})$$

Sabemos que cada elemento de w_x possui um valor mínimo e, desta forma, pode-se usar mudança de coordenadas para deslocar a origem do sistema de coordenadas para o vetor w_x^- , tal que, no novo sistema de coordenadas, podemos representar o seguinte vetor:

$$w_d = [w_{x,1} - w_{x,1}^- \quad w_{x,2} - w_{x,2}^- \dots \quad w_{x,p} - w_{x,p}^-]^T \quad (\text{A.13})$$

como sendo equivalente à w_x no sistema de coordenadas original. Note-se que, quando alguma componente de w_x equivale ao valor mínimo para o intervalo em que está contida, seu valor correspondente em w_d é 0. Da mesma forma, quando alguma componente de w_x equivale ao valor máximo para o intervalo em que está contida, seu valor correspondente em w_d é $w_{x,i}^+ - w_{x,i}^-$.

A seguir, podemos mudar a escala de cada um dos p eixos do sistema de coordenadas, dividindo cada um deles por uma proporção de $w_{x,i}^+ - w_{x,i}^-$. Neste novo sistema de coordenadas, com estas proporções para os eixos, podemos representar o seguinte vetor:

$$w_u = [w_{u,1} \quad w_{u,2} \dots \quad w_{u,p}]^T \quad (\text{A.14})$$

como sendo equivalente à w_x e w_d em seus respectivos sistemas de coordenadas. Para este vetor, cada uma de suas componentes pertence ao intervalo fechado $[0 \ 1]$. Portanto, como consequência do Teorema 1, há um politopo convexo $W_{x,2}$ de $p+1$ vértices que contém $W_{x,1}$. Neste sistema de coordenadas, os vértices de $W_{x,2}$ são formados pelo vetor nulo e pelos vetores pe_i , onde $e_i = [0 \ \dots \ 0 \ 1 \ 0 \ \dots \ 0]^T$ e o elemento de valor 1 se encontra na posição i , com $i = 1, \dots, p$.

Revertendo as mudanças de escala nos eixos de coordenadas e a mudança de coordenadas que deslocou w_x^- para a origem, temos que os vértices de $W_{x,2}$, no sistema de coordenadas original, são dados por $w_x^- = [w_{x,1}^- \quad w_{x,2}^- \quad \dots \quad w_{x,p}^-]$ e pelos vetores $w_x^- + pe_i(w_{x,i}^+ - w_{x,i}^-)$.

Corolário: Qualquer politopo convexo $W_{x,3}$ cujos $p+1$ vértices são definidos por $w_x^- = [w_{x,1}^- \quad w_{x,2}^- \quad \dots \quad w_{x,p}^-]$ e pelos vetores $w_x^- + p'e_i(w_{x,i}^+ - w_{x,i}^-)$, com $p' \geq p$, contém $W_{x,2}$ e $W_{x,1}$.

Apêndice B

Conceitos sobre Sistemas

Um sistema é dito invariante no tempo se suas características não variam.

Um sistema é dito linear se obedece ao princípio da superposição. Sistemas que não obedecem ao princípio da superposição são chamados sistemas não-lineares.

Um sistema com uma única entrada e única saída disponíveis para medição é denominado SISO (Single Input Single Output). Caso um sistema tenha múltiplas entradas e múltiplas saídas este é denominado MIMO (Multiple Input Multiple Output).

Um sistema é dito dinâmico caso suas saídas dependam dos valores passados de suas entradas. Caso a saída dependa apenas do valor presente das entradas o sistema é dito estático.

B.1 Representação

Um sistema dinâmico, linear, invariante no tempo e SISO pode ser representado em espaço de estado pelas seguintes equações:

$$\begin{aligned}\dot{x} &= Ax + bu \\ y &= h^T x + du\end{aligned}\tag{B.1}$$

onde $A \in R^{n \times n}$, $b \in R^n$, $h^T \in R^n$ e $d \in R$ são os parâmetros da planta em espaço de estado. Esta representação descreve uma relação entre o sinal de entrada u e a saída da planta y .

Outra forma de obter uma relação entre variáveis é a partir do domínio da frequência:

$$G(s) \triangleq \frac{Y(s)}{U(s)} = \frac{N(s)}{D(s)} = \frac{b_1 s^m + \dots + b_m}{a_1 s^n + \dots + a_n}\tag{B.2}$$

onde $G(s)$ é chamada função de transferência entre $Y(s)$ e $U(s)$, $N(s)$ é chamado polinômio do numerador e $D(s)$ é chamado polinômio do denominador. O grau n do polinômio $D(s)$ determina a ordem do sistema. A diferença entre o grau n de $D(s)$ e o grau m de $N(s)$ determina o grau relativo. As raízes de $D(s)$ são chamadas polos. As raízes de $N(s)$

são chamadas zeros. Os polos e zeros determinam o comportamento dinâmico do sistema.

A partir de uma representação do tipo B.1 da planta é possível obter uma representação do tipo B.2 e vice-versa.

Um sistema linear representado por uma função de transferência $G(s)$ é estável se todos os seus polos têm parte real negativa, e caso algum polo tenha parte real positiva o sistema é instável.

Um sistema linear representado por uma função de transferência $G(s)$ é chamado de fase mínima se todos os seus zeros têm parte real negativa, e caso algum zero tenha parte real positiva o sistema é de fase não-mínima.

Apêndice C

Estabilidade

C.1 Definições

Considere o sistema descrito por:

$$\dot{x} = f(x, t), x(t_0) = x_0 \quad (\text{C.1})$$

onde $f \in R^n$ é uma função e $x \in R^n$ o vetor de estado. Os elementos que compõem x são variáveis de estado. As seguintes definições são úteis:

- **Definição C.1.1** Um estado x^* é dito ponto de equilíbrio de um sistema descrito por C.1 se $f(x^*, t) = 0$, ou seja, se $x(0) = x^*$ implica que $x \equiv x^*$.
- **Definição C.1.2** O ponto de equilíbrio x^* é dito estável se para todo t_0 e para toda bola de raio $\epsilon > 0$ existe uma bola de raio $\delta(\epsilon, t_0)$ tal que $|x_0 - x^*| < \delta$ implica em $|x(t) - x^*| < \epsilon$ para todo $t \geq t_0$.
- **Definição C.1.3** O ponto de equilíbrio x^* é dito assintoticamente estável se é estável e se existe uma bola de raio $\delta(t_0)$ tal que $|x_0 - x^*| < \delta$ implica em $\lim_{t \rightarrow \infty} |x(t) - x^*| = 0$.

Para sistemas lineares com um único ponto de equilíbrio, quando diz-se que o sistema é estável estamos nos referindo à estabilidade de seu ponto de equilíbrio.

C.2 Método Direto de Lyapunov

A teoria de Lyapunov lida com funções de energia para buscar entender as propriedades de estabilidade de um sistema. As seguintes definições são úteis neste trabalho:

C.2.1 Funções Definidas

- **Definição C.2.1.1** Uma função $V(x)$ é definida positiva ($V(x) > 0$) em uma vizinhança de $x = 0$ se $V(x) > 0$ qualquer que seja x pertencente a uma bola de raio ϵ com $x \neq 0$ e $V(0) = 0$.
- **Definição C.2.1.2** Uma função $V(x)$ é semi-definida positiva ($V(x) \geq 0$) em uma vizinhança de $x = 0$ se $V(x) \geq 0$ qualquer que seja x pertencente a uma bola de raio ϵ com $x \neq 0$ e $V(0) = 0$.

- **Definição C.2.1.3** Uma função $V(x)$ é definida negativa ($V(x) < 0$) em uma vizinhança de $x = 0$ se $V(x) < 0$ qualquer que seja x pertencente a uma bola de raio ε com $x \neq 0$ e $V(0) = 0$.
- **Definição C.2.1.4** Uma função $V(x)$ é semi-definida negativa ($V(x) \leq 0$) em uma vizinhança de $x = 0$ se $V(x) \leq 0$ qualquer que seja x pertencente a uma bola de raio ε com $x \neq 0$ e $V(0) = 0$.

C.2.2 Teoremas sobre Estabilidade

- **Definição C.2.2.1** Se para o sistema C.1 há uma função $V(x)$ definida positiva e continuamente diferenciável tal que $\dot{V}(x)$ é semi-definida negativa, então $V(x)$ não pode crescer e x^* é um ponto de equilíbrio estável.
- **Definição C.2.2.2** Se para o sistema C.1 há uma função $V(x)$ definida positiva e continuamente diferenciável tal que $\dot{V}(x)$ é definida negativa, então $V(x)$ deve decrescer e x^* é um ponto de equilíbrio assintoticamente estável.

C.3 Norma $\mathcal{L}_p$

Para funções no tempo a norma $\mathcal{L}_p$ é definida como:

$$\|x\|_p \triangleq \left(\int_0^\infty |x(\tau)|^p d\tau \right)^{1/p} \quad (\text{C.2})$$

para $p \in [1, \infty)$ e dizemos que $x \in \mathcal{L}_p$ quando $\|x\|_p$ existe e é finita. Adicionalmente, definimos a norma $\mathcal{L}_\infty$:

$$\|x\|_\infty \triangleq \sup_{t \geq 0} |x(t)| \quad (\text{C.3})$$

e dizemos que $x \in \mathcal{L}_\infty$ quando $\|x\|_\infty$ existe. Pode-se também dizer que x é uniformemente limitado.

C.4 Lema de Barbalat

Deixe que $f(t) : \mathbb{R} \rightarrow \mathbb{R}$ seja diferenciável e tenda a um limite finito à medida que $t \rightarrow \infty$. Se $\dot{f}(t)$ é uniformemente contínua, então $\dot{f}(t) \rightarrow 0$ à medida que $t \rightarrow \infty$.

C.4.1 Corolário 1

Se $f(t) : \mathbb{R} \rightarrow \mathbb{R}$ é diferenciável duas vezes e tende a um limite finito à medida que $t \rightarrow \infty$ e sua segunda derivada é limitada, então $\dot{f}(t) \rightarrow 0$ à medida que $t \rightarrow \infty$. Em geral uma derivada que tenda a 0 não implica que a função tenda a um valor em particular ou vice-versa. É possível que uma derivada $\dot{f}(t)$ tenda a 0 à medida que $t \rightarrow \infty$ sem que $f(t)$

tenda a algum valor em particular. Também é possível que $f(t)$ tenda a algum valor à medida que $t \rightarrow \infty$ sem que sua derivada $\dot{f}(t)$ tenda a 0.

C.4.2 Corolário 2

Seja uma função escalar $V = V(t, x)$ tal que:

- $V(t, x)$ tem um limite inferior
- $\dot{V}(t, x)$ é semi-definida negativa ao longo das trajetórias de $\dot{x} = f(t, x)$
- $\dot{V}(t, x)$ é uniformemente contínua

então, $\dot{V}(t, x) \rightarrow 0$ à medida que $t \rightarrow \infty$.

C.4.3 Corolário 3

Se $f(t) : \mathbb{R}^+ \rightarrow \mathbb{R}$ é uniformemente contínua para todo $t \geq 0$, e se o limite da integral:

$$\lim_{t \rightarrow \infty} \int_0^t f(\tau) d\tau \quad (\text{C.4})$$

existe e é finito, então:

$$\lim_{t \rightarrow \infty} f(t) = 0 \quad (\text{C.5})$$

C.4.4 Corolário 4

Seja $f(t) = |g(t)|^p$, se $g, \dot{g} \in \mathcal{L}_\infty$ e $g \in \mathcal{L}_p$, para algum $p \in [1, \infty)$, então $\lim_{t \rightarrow \infty} g(t) = 0$. Este corolário é aquele ao qual nos referimos no texto quando mencionamos que, devido a um corolário do Lema de barbalat, algum sinal tende a 0 assintoticamente.

C.5 Função Estritamente Real Positiva

Um função de transferência $H(s)$, com $n^* = 1$, é ERP sse:

- 1 $H(s)$ é analítica em $\text{Re}[s] \geq 0$
- 2 $\text{Re}[H(j\omega)] > 0, \forall \omega \in (-\infty, \infty)$, e
- 3 $\lim_{\omega^2 \rightarrow \infty} \omega^2 \text{Re}[H(j\omega)] > 0$

C.6 Lema de Meyer-Kalman-Yakubovitch

Dado um escalar $\gamma \geq 0$, vetores b e h , uma matriz A assintoticamente estável, e uma matriz simétrica definida positiva L , se:

$$\text{Re}[H(j\omega)] \triangleq \text{Re}\left[\frac{\gamma}{2} + h^T(j\omega I - A)^{-1}b\right] > 0 \quad (\text{C.6})$$

para qualquer w real, então existe um escalar $\varepsilon > 0$, um vetor q e uma matriz simétrica e definida positiva P tal que:

$$\begin{aligned} A^T P + PA &= -qq^T - \varepsilon L \\ Pb - h &= \sqrt{\gamma}q \end{aligned} \tag{C.7}$$

Devido à natureza dos problemas tratados nesta dissertação, nestes casos a constante γ em C.7 é zero. Desta forma, uma função de transferência $h^T(sI - A)^{-1}b$ ERP garante a existência de uma matriz $P = P^T > 0$, que satisfaz:

$$\begin{aligned} A^T P + PA &= -Q \\ Pb &= h \end{aligned} \tag{C.8}$$

onde $Q = Q^T > 0$.