

Capítulo 1

Considerações Adicionais sobre Adaptação de Segundo Nível

1.1 Projeção dos pesos alfa da adaptação de segundo nível numa área de incerteza dos parâmetros com fronteira convexa e suave.

Seja:

$$\hat{\theta}_p = \bar{\Theta}\alpha \quad (1.1)$$

o modelo virtual criado a partir de uma combinação convexa de $n+1$ modelos de identificação. Tal que $\bar{\Theta} \in R^{(n+1) \times n}$ e $\alpha \in R^{n+1}$ e $\hat{\theta}_p \in R^n$

Se $g(\theta)$ delimita uma região suave e convexa dentro da qual estão contidos os parâmetros da planta então a escolha dos parâmetros iniciais dos modelos de identificação (vértices do fecho convexo inicial) na adaptação de segundo nível implica no seguinte problema:

Como utilizar toda a informação disponível sobre a região de incerteza $g(\theta)$? Em outras palavras, como escolher os parâmetros dos modelos de identificação iniciais de forma que o fecho convexo no espaço de parâmetros englobe a fronteira $g(\theta)$ com o melhor ajuste possível?

Um fecho convexo delimitado por um número finito de vértices não tem uma fronteira suave e portanto é possível apenas minimizar o volume de fecho convexo "desperdiçado" com a escolha dos vértices. Desta forma nos propomos a criar uma lei de projeção para o vetor α de forma que, na fronteira de $g(\theta)$, α se mantenha na região de incerteza conhecida.

Assim temos um problema de projeção dos parâmetros α da adaptação de segundo nível onde seguimos os argumentos padrão para a projeção: α permanece inalterado quando α se encontra no interior da região delimitada pelo conjunto Φ ou na fronteira com tendência a entrar e é projetado quando α se encontra na fronteira com tendência a sair.

Definimos uma região elipsóide em relação ao vetor θ , centrada no ponto θ_c :

$$g(\theta) = (\theta - \theta_c)^T P (\theta - \theta_c) - M^2 \quad (1.2)$$

onde $\theta \in R^n$, $\theta_c \in R^n$, $P = P^T \in R^{n \times n}$ e M é um escalar. O interior do elipsóide é caracterizado por $g(\theta) < 0$ e sua fronteira por $g(\theta) = 0$. Denotamos o interior do elipsóide pela região S e sua fronteira por $\delta(S)$.

Fazendo uma mudança de coordenadas para α , obtemos diretamente outro elipsóide:




Figura 1.1: Ilustração do problema, em preto uma fronteira suave e convexa $g(\theta)$ e em azul um fecho convexo delimitado por 3 vértices no R^2 . A escolha dos mesmos no problema da adaptação de segundo nível implica que a estimativa $\hat{\theta}_p$ criada a partir da combinação convexa pode ter sua trajetória passando por fora da região de incerteza

$$g(\alpha) = (\bar{\Theta}\alpha - \theta_c)^T P(\bar{\Theta}\alpha - \theta_c) \quad (1.3)$$

o gradiente deste elipsóide é dado por:

$$\nabla g(\alpha) = 2\bar{\Theta}^T P \bar{\Theta}\alpha - 2\bar{\Theta}^T P \theta_c \quad (1.4)$$

Seja a lei adaptativa para o modelo virtual usada na adaptação de segundo nível:

$$\dot{\alpha} = -E^T(t)E(t)\alpha - E^T(t)e_{n+1}(t) \quad (1.5)$$

Usando as definições anteriores estabelecemos a seguinte lei com projeção

$$\dot{\alpha} = \begin{cases} \dot{\alpha}, & \text{se } \alpha \in S \text{ ou } (\alpha \in \delta(S) \text{ e } \dot{\alpha}^T \nabla g(\alpha) < 0) \\ Pr(\dot{\alpha}), & \text{caso contrário} \end{cases} \quad (1.6)$$

Onde $Pr(\dot{\alpha})$ é obtido extraindo a componente do vetor na mesma direção do gradiente:

$$Pr(\dot{\alpha}) = \dot{\alpha} - \nabla g^T \dot{\alpha} \nabla g (\nabla g^T \nabla g)^{-1} \quad (1.7)$$

Finalmente, temos o problema descrito no apêndice B do livro do Ioannou, onde é possível, com essa lei de projeção para um elipsóide, que o vetor resultante da iteração seguinte na simulação esteja fora da região de incerteza definida pelo elipsóide. Desta forma, fazemos o seguinte raciocínio: Se um vetor se encontra próximo à fronteira de um dado elipsóide, trazer o vetor até a fronteira é apenas uma questão de andar na direção apropriada do gradiente:

$$\alpha_{k+1}^{ajustado} = \alpha_{k+1} - L \nabla g \quad (1.8)$$

desta forma resolvemos a seguinte equação de segundo grau no escalar L , caso $g(\alpha_{k+1}) > 0$.

$$(\bar{\Theta}(\alpha - L \nabla g) - \theta_c)^T P(\bar{\Theta}(\alpha - L \nabla g) - \theta_c) - M^2 = 0 \quad (1.9)$$

de onde obtemos os coeficientes a, b, c da equação de segundo grau em L
 $aL^2 + bL + c = 0$, onde:

$$a = \nabla g^T \bar{\Theta} P \bar{\Theta} \nabla g \quad (1.10)$$

e

$$b = -\alpha^T \bar{\Theta}^T P \bar{\Theta} \nabla g - \nabla g^T \bar{\Theta}^T P \bar{\Theta} \alpha + \nabla g^T \bar{\Theta}^T P \theta_c + \theta_c^T P \bar{\Theta} \nabla g \quad (1.11)$$

e finalmente:

$$c = \alpha^T \bar{\Theta}^T P \bar{\Theta} \alpha - \alpha^T \bar{\Theta}^T P \theta_c - \theta_c^T P \theta_c - M^2 \quad (1.12)$$

tal que:

$$L_{1,2} = (-b \pm \sqrt{b^2 - 4ac})/2a \quad (1.13)$$

e $L = \min(L_1, L_2)$

Aplicando esta lei de projeção, garantimos que α pertence à região de incerteza definida pelo elipsóide em $g(\alpha)$. Partindo deste argumento para uma única região, é possível expandir o raciocínio para a união de múltiplos elipsóides definidos por uma série de funções $g_i(\theta)$, de forma que é possível "desenhar" uma quantidade maior de regiões de incerteza de parâmetros.

1.2 Aprendizado Concorrente/Paralelo

Em [CHOWDHARY,2010], foi introduzido o conceito de "concurrent learning" para o controle adaptativo convencional, onde a necessidade de um sinal com a característica de persistência de excitação (como por exemplo um sinal rico em frequências) para garantir a convergência das estimativas dos parâmetros da planta para seus valores corretos é removida, sendo no lugar necessário apenas que os dados usados para gerar a taxa de adaptação dos parâmetros sejam armazenados em um certo número de instantes distintos e que tais dados formem um conjunto linearmente independente.

No caso do controle adaptativo com adaptação de segundo nível, seja a equação de adaptação dos parâmetros α da seguinte forma (apresentada na forma original sem projeção):

$$\dot{\alpha} = -E^T(t)E(t)\alpha(t) - E^T(t)e_{n+1}(t) \quad (1.14)$$

Notamos o seguinte fato: A dimensionalidade dos pontos de equilíbrio na equação está diretamente relacionada com o posto da matriz $E^T(t)E(t)$. De fato, quando existe excitação de magnitude suficiente em todos os modos da planta e dos modelos de identificação, o posto da matriz é cheio e está distante de uma matriz de posto deficiente. Desta forma existe apenas um único α tal que $\dot{\alpha} = 0$. Caso sejamos capazes de armazenar os dados em diferentes instantes de tempo garantindo que matriz $M = \sum E_j^T E_j$ tem posto cheio, propomos a seguinte equação:

$$\dot{\alpha} = -E^T(t)E(t)\alpha(t) - E^T(t)e_{n+1}(t) - \sum E_j^T E_j \alpha(t) - \sum E_j^T e_{n+1,j} \quad (1.15)$$

Seja a candidata à função de Lyapunov:

$$V(\tilde{\alpha}) = \frac{1}{2} \tilde{\alpha}^T \tilde{\alpha} \quad (1.16)$$

Seja α invariante, $\dot{\tilde{\alpha}} = \dot{\alpha}$, diferenciando obtemos:

$$\dot{V}(\tilde{\alpha}) = \tilde{\alpha}^T (-E^T(t)E(t)\alpha(t) - E^T(t)e_{n+1}(t) - \sum E_j^T E_j \alpha(t) - \sum E_j^T e_{n+1,j}) \quad (1.17)$$

Como $\tilde{\alpha} = \alpha - \alpha^*$, substituímos $\alpha = \tilde{\alpha} + \alpha^*$. Já que assumimos que existe uma única solução para $\alpha = \alpha^*$ tal que $\sum E_j^T E_j \alpha = -\sum E_j^T e(n+1), j$ pois o posto da matriz M é cheio e α^* também

é uma solução de α para o instante presente mesmo que $E^T(t)E(t)$ não tenha posto cheio, podemos escrever $E^T(t)E(t)\alpha^* = -E^T(t)e_{n+1}(t)$, desta forma, substituindo:

$$\dot{V}(\tilde{\alpha}) = -\tilde{\alpha}(E^T(t)E(t) + \sum E_j^T E_j)(\tilde{\alpha} + \alpha^*) - \tilde{\alpha}(E^T(t)e_{n+1}(t) + \sum E_j^T e_{n+1}, j) \quad (1.18)$$

Mas $(E^T(t)E(t) + \sum E_j^T E_j)\alpha^* = -(E^T(t)e_{n+1}(t) + \sum E_j^T e_{n+1}, j)$, desta forma obtemos cancelamento dos termos de sinal indefinido, obtendo:

$$\dot{V}(\tilde{\alpha}) = -\tilde{\alpha}(E^T(t)E(t) + \sum E_j^T E_j)\tilde{\alpha} \quad (1.19)$$

Como para uma matriz qualquer temos sempre que $P^T P$ possui autovalores positivos ou nulos, sabemos que $(E^T(t)E(t) + \sum E_j^T E_j) > 0$, e portanto $\dot{V}(\tilde{\alpha}) < 0$ e o sistema de identificação converge exponencialmente para a origem $\tilde{\alpha} = 0$