

0.1 Aprendizado Concorrente/Paralelo, Prova de Convergência para Identificação

Em [CHOWDHARY,2010], foi introduzido o conceito de "concurrent learning" para o controle adaptativo convencional, onde a necessidade de um sinal com a característica de persistência de excitação (como por exemplo um sinal rico em frequências) para garantir a convergência das estimativas dos parâmetros da planta para seus valores corretos é removida, sendo no lugar necessário apenas que os dados usados para gerar a taxa de adaptação dos parâmetros sejam armazenados em um certo número de instantes distintos e que tais dados formem um conjunto linearmente independente.

No caso do controle adaptativo com adaptação de segundo nível e modelos de identificação fixos, seja a equação de adaptação dos parâmetros α da seguinte forma (apresentada na forma original sem projeção):

$$\dot{\alpha} = -E^T(t)E(t)\alpha(t) - E^T(t)e_{n+1}(t) \quad (1)$$

Notamos o seguinte fato: A dimensionalidade dos pontos de equilíbrio na equação está diretamente relacionada com o posto da matriz $E^T(t)E(t)$. De fato, quando existe excitação de magnitude suficiente em todos os modos da planta e dos modelos de identificação, o posto da matriz é cheio e está distante de uma matriz de posto deficiente. Desta forma existe apenas um único α tal que $\dot{\alpha} = 0$. Caso sejamos capazes de armazenar os dados em diferentes instantes de tempo garantindo que matriz $M = \sum E_j^T E_j$ tem posto cheio, propomos a seguinte equação:

$$\dot{\alpha} = -E^T(t)E(t)\alpha(t) - E^T(t)e_{n+1}(t) - \sum E_j^T E_j \alpha(t) - \sum E_j^T e_{n+1,j} \quad (2)$$

Seja a candidata à função de Lyapunov:

$$V(\tilde{\alpha}) = \frac{1}{2} \tilde{\alpha}^T \tilde{\alpha} \quad (3)$$

Seja α^* invariante, $\dot{\tilde{\alpha}} = \dot{\alpha}$, diferenciando obtemos:

$$\dot{V}(\tilde{\alpha}) = \tilde{\alpha}^T (-E^T(t)E(t)\alpha(t) - E^T(t)e_{n+1}(t) - \sum E_j^T E_j \alpha(t) - \sum E_j^T e_{n+1,j}) \quad (4)$$

Como $\tilde{\alpha} = \alpha - \alpha^*$, substituimos $\alpha = \tilde{\alpha} + \alpha^*$. Já que assumimos que existe uma única solução para $\alpha = \alpha^*$ tal que $\sum E_j^T E_j \alpha = -\sum E_j^T e_{n+1,j}$ pois o posto da matriz M é cheio e α^* também é uma solução de α para o instante presente mesmo que $E^T(t)E(t)$ não tenha posto cheio, podemos escrever $E^T(t)E(t)\alpha^* = -E^T(t)e_{n+1}(t)$, desta forma, substituindo:

$$\dot{V}(\tilde{\alpha}) = -\tilde{\alpha}(E^T(t)E(t) + \sum E_j^T E_j)(\tilde{\alpha} + \alpha^*) - \tilde{\alpha}(E^T(t)e_{n+1}(t) + \sum E_j^T e_{n+1,j}) \quad (5)$$

Mas $(E^T(t)E(t) + \sum E_j^T E_j)\alpha^* = -(E^T(t)e_{n+1}(t) + \sum E_j^T e_{n+1,j})$, desta forma obtemos cancelamento dos termos de sinal indefinido, obtendo:

$$\dot{V}(\tilde{\alpha}) = -\tilde{\alpha}(E^T(t)E(t) + \sum E_j^T E_j)\tilde{\alpha} \quad (6)$$

Como para uma matriz qualquer temos sempre que $P^T P$ possui autovalores positivos ou nulos, sabemos que $(E^T(t)E(t) + \sum E_j^T E_j) > 0$, e portanto $\dot{V}(\tilde{\alpha}) < 0$ e $V(\tilde{\alpha})$ é uma função de Lyapunov. Concluimos que o sistema de identificação converge assintoticamente para a origem $\tilde{\alpha} = 0$.

0.2 Caso Discreto, Ganho Escalar

Por simplicidade, escrevemos:

$$M \equiv E^T(k)E(k) + \sum E_j^T E_j \quad (7)$$

$$v \equiv E^T(t)e_{n+1}(t) + \sum E_j^T e_{n+1,j} \quad (8)$$

Prosseguimos à análise para o caso discreto, substituindo as equações diferenciais por equações diferença e introduzindo um ganho γ na análise.

$$\alpha(k+1) = \alpha(k) + \gamma T_s * (-M\alpha(k) - v) \quad (9)$$

Como $\alpha = \tilde{\alpha} + \alpha^*$, podemos escrever:

$$\alpha(k+1) = \alpha(k) + \gamma T_s * (-M\tilde{\alpha}(k)) \quad (10)$$

$$\tilde{\alpha}(k+1) = \alpha(k+1) - \alpha^* \quad (11)$$

$$\tilde{\alpha}(k+1) = \tilde{\alpha}(k) + \gamma T_s * (-M\tilde{\alpha}(k)) \quad (12)$$

E denotamos a mudança na função de energia $V(\tilde{\alpha}, k) = \frac{1}{2}\tilde{\alpha}^T \tilde{\alpha}$, na amostra seguinte:

$$\Delta V(\tilde{\alpha}, k+1) = V(\tilde{\alpha}, k+1) - V(\tilde{\alpha}, k) \quad (13)$$

que se torna:

$$\Delta V = (\tilde{\alpha}(k) + \gamma T_s * (-M\tilde{\alpha}(k)))^T (\tilde{\alpha}(k) + \gamma T_s * (-M\tilde{\alpha}(k))) - \tilde{\alpha}(k)^T \tilde{\alpha}(k) \quad (14)$$

$$\Delta V = -2\gamma T_s \tilde{\alpha}^T M \tilde{\alpha} + \gamma^2 T_s^2 \tilde{\alpha}^T M^2 \tilde{\alpha} \quad (15)$$

Que se torna:

$$\Delta V = \gamma T_s \tilde{\alpha}^T (-2M + \gamma T_s M^2) \tilde{\alpha} \quad (16)$$

Fazer com que simultaneamente $\Delta V < 0$ e maximizando o módulo desta quantia, recaímos num problema de autovalores, cuja solução ótima é:

$$\gamma = \frac{1}{T_s * \lambda_{M,max}} \quad (17)$$

0.3 Caso Discreto, Matriz de Ganhos

Como curiosidade, analisamos o caso:

$$\alpha(k+1) = \alpha(k) + P T_s * (-M\alpha(k) - v) \quad (18)$$

Em que $P = P^T > 0$, é trivial notar que, caso escolhamos $P = M^{-1} * T_s^{-1}$, temos $V(\tilde{\alpha}, k+1) = 0$, e o problema fica sujeito apenas ao condicionamento numérico da matriz M . Lembramos que a matriz M não é formada a partir de processos físicos sujeitos a ruído de medição e perturbações, e sim de modelos de identificação fixos escolhidos pelo projetista, com seu condicionamento numérico à disposição.