

Sobre a Adaptação de Segundo Nível como Técnica de Estimação de Parâmetros em Plantas Lineares Parcialmente Conhecidas e sua Aplicação ao Controle Adaptativo

Orientador: Aldayr Dantas de Araújo
Pedro Yochinori Gushiken

Universidade Federal do Rio Grande do Norte

22 de Junho de 2017

Sumário

- 1 Introdução
- 2 Conceitos para o caso com Variáveis de Estado Acessíveis
 - IMRAC
 - Adaptação de Segundo Nível aplicada ao IMRAC (IMRAC-A2N)
- 3 Conceitos para o caso SISO com $n^* = 1$
 - Fundamentação Teórica
 - Adaptação de Segundo Nível
 - IMRAC-A2N
 - IDMARC-A2N
- 4 Objetivos

Contextualização

1 IMRAC, Planta SISO parcialmente conhecida

Contextualização

- 1 IMRAC, Planta SISO parcialmente conhecida
- 2 Identificação

Contextualização

- 1 IMRAC, Planta SISO parcialmente conhecida
- 2 Identificação

Contextualização

- 1 IMRAC, Planta SISO parcialmente conhecida
- 2 Identificação
- 3 Caso com Variáveis de Estado Acessíveis

Contextualização

- 1 IMRAC, Planta SISO parcialmente conhecida
- 2 Identificação
- 3 Caso com Variáveis de Estado Acessíveis
- 4 Caso Entrada-Saída

Descrições

Seja a planta com variáveis de estado acessíveis:

$$\dot{x}_p(t) = A_p x_p(t) + b u(t)$$

E o modelo de referência:

$$\dot{x}_m(t) = A_m x_m(t) + b r(t)$$

em que:

b é conhecido

A_m tem forma companheira

A_p tem forma companheira

Descrições, Cont.

Seja o modelo de identificação (série-paralelo):

$$\hat{x}_p = A_m \hat{x}_p(t) + [A_1(t) - A_m]x_p(t) + bu(t)$$

em que A_1 tem forma companheira.

Equações, Cont.

A lei de controle:

$$u(t) = r(t) + k^T(t)x_p(t)$$

O vetor de parâmetros do controlador:

$$k(t) = \theta_m - \theta_1(t) = k^* - \phi_1(t)$$

$k^* \rightarrow$ controlador para planta conhecida

$\phi_1(t) \rightarrow$ erro entre os parâmetros da planta e suas estimativas

$\theta_m \rightarrow$ modelo de referência

$\theta_1(t) \rightarrow$ modelo de identificação

Lei Adaptativa

Definindo o erro de identificação:

$$e_1(t) = \hat{x}_p(t) - x_p(t)$$

E a lei adaptativa:

$$\dot{\theta}_1 = \dot{\phi}_1 = -e_1^T P b x_p(t)$$

A partir da teoria de Lyapunov, com candidata $V(e_1(t), \phi_1(t)) = \frac{1}{2}e_1^T(t)Pe_1(t) + \phi_1^T\phi_1(t)$, prova-se que:

$$\lim_{t \rightarrow \infty} e_1(t) = 0$$

e que:

$$\lim_{t \rightarrow \infty} \phi_1(t) = 0, \quad r(t) \text{ P.E}$$

Resultados de Simulação para Adaptação de Primeiro Nível




Figura: Planta com $\theta_p^{*T} = [2.3 \quad -3.6]$, $\theta_m^{*T} = [-4 \quad -4]$, $\theta_1^T(0) = [-3 \quad -2]$

Localização de θ_p^*

Se o vetor de parâmetros desconhecidos θ_p^* da planta estiver contido no fecho convexo S dos parâmetros iniciais $\theta_i(0)$ de N modelos (onde $N \geq n + 1$), $\theta_p^* \in S \quad \forall t$, desde que $x_i(0) = x_p(0)$, $\forall i$.

Múltiplos Modelos

Seja o conjunto de modelos de identificação descritos por:

$$\Sigma_i : \hat{x}_i = A_m \hat{x}_i(t) + [A_i(t) - A_m]x_p(t) + bu(t)$$

Faremos uso da propriedade do fecho convexo para criar um modelo virtual a partir de uma combinação linear dos parâmetros dos modelos Σ_i . Por praticidade, usaremos o número mínimo de modelos $N = n + 1$ daqui em diante.

Tendo em mente como discutido anteriormente que:

$$\sum_{i=1}^{n+1} \alpha_i \theta_i(t) = \theta_p$$

$$\sum_{i=1}^{n+1} \alpha_i \phi(t_0) = 0$$

$$\sum_{i=1}^{n+1} \alpha_i = 1$$

$$\theta_i(t_0) = \theta_0$$

$$e_i(t_0) = 0$$

$$\dot{\theta}_i(t) = \dot{\phi}_i(t) = -e_i^T(t) P b x_p(t)$$

É possível enxergar as constantes $\alpha_1, \alpha_2, \dots, \alpha_{n+1}$ como uma alternativa de parametrização da planta. Consequentemente, a rapidez e precisão na estimação de α_i é que determinam seu desempenho.

$$\sum_{i=1}^{n+1} \alpha_i \theta_i(t) = \theta_p$$

$$\sum_{i=1}^{n+1} \alpha_i e_i(t) = 0$$

Em forma matricial:

$$\bar{\Theta}(t)\bar{\alpha} = \theta_p$$

$$\bar{E}(t)\bar{\alpha} = 0$$

onde $\bar{\Theta}, \bar{E} \in R^{n \times (n+1)}$

Podemos então expressar:

$$\Theta(t)\alpha = \theta_p - \theta_{n+1}$$

$$E(t)\alpha = -e_{n+1}(t)$$

onde $\Theta(t), E(t) \in R^{n \times n}$, onde cada vetor coluna é $\theta_i(t) - \theta_{n+1}(t)$ e $e_i(t) - e_{n+1}(t)$ respectivamente e $\alpha^T = [\alpha_1, \dots, \alpha_n]$. De onde obtemos a equação diferencial:

$$\dot{\hat{\alpha}} = -\gamma E^T(t)E(t)\hat{\alpha} - \gamma E^T(t)e_{n+1}(t)$$

onde $0 < \gamma \leq 1/(\lambda_{\max}(E^T E)h)$. É importante frisar que α^* que mapeia θ_p^* não depende do tempo t .

Figura de Mérito η

Definimos a seguinte figura de mérito:


$$\eta = \frac{\dot{\alpha}^T Q \dot{\alpha}}{1 + \dot{\alpha}^T Q \dot{\alpha}}$$

E um escalar real:

$$d \in]0, 1[$$

Para $\eta \geq d$ a referência é PE. Se $\eta < d$ o valor do sinal de referência retorna assintoticamente para um valor constante.

Simulação para IMRAC-A2N com variáveis de estado da planta acessíveis



Parametrização da Planta, I

Seja a planta SISO, $n^* = 1$:

$$W(s) = k_p \frac{N_p(s)}{D_p(s)}$$

$$N_p(s) = s^{n-1} + \sum_{i=1}^{n-1} \beta_i s^{n-1-i}$$

$$D_p(s) = s^n + \alpha_1 s^{n-1} + \sum_{i=1}^{n-1} \alpha_{i+1} s^{n-1-i}$$

e um modelo de referência na forma:

$$M(s) = k_m \frac{N_m(s)}{D_m(s)}$$

$$N_m(s) = s^{n-1} + \sum_{i=1}^{n-1} \beta_{m,i} s^{n-1-i}$$

$$D_m(s) = s^n + \alpha_{m,1} s^{n-1} + \sum_{i=1}^{n-1} \alpha_{m,i+1} s^{n-1-i}$$

Parametrização da Planta, I, Cont

Gera-se um erro entre a saída da planta e a saída do modelo:

$$e_0 = y - y_m$$

Que chamamos erro de saída.

Parametrização da Planta, I, Cont

A planta é parcialmente conhecida, e temos $2n$ parâmetros para estimar com apenas $y(t)$ e $u(t)$ medidos. Geramos então filtrados dos sinais de entrada e da saída $v_1, v_2 \in R^{n-1}$:

$$\dot{v}_1 = \Lambda_w v_1 + g u$$

$$\dot{v}_2 = \Lambda_w v_2 + g y$$

Onde $g = [0 \quad \dots \quad \gamma_g]$, $\gamma_g > 0$, e o par (Λ, g) deve ser escolhido tal que:

$$(sI - \Lambda_w)^{-1} g = \frac{\gamma_g}{N_m(s)} [1 \quad s \quad \dots \quad s^{n-2}]^T$$

Parametrização da Planta, I, Cont

Cria-se um vetor de sinais da seguinte forma:

$$w^T = \begin{bmatrix} v_1^T & y & v_2^T & r \end{bmatrix}$$

No caso ideal, onde os parâmetros da planta são conhecidos, mapeia-se um vetor θ_c^* a partir dos coeficientes do numerador e denominador da planta e a lei de controle é da forma:

$$u = \theta_c^{*T} w$$

Com $\theta_c^T = \begin{bmatrix} \theta_{v1}^* & \theta_n^* & \theta_{v2}^* & \theta_{2n}^* \end{bmatrix}$ o vetor de parâmetros do controlador que garante a dinâmica em malha fechada da planta igual a dinâmica do modelo de referência.

Algoritmo IMRAC

Quando os parâmetros da planta são desconhecidos realiza-se um processo de estimação:

$$\dot{\hat{k}}_p = -\gamma_p e_0 \zeta_p$$

$$\dot{\hat{\beta}} = \Gamma_\beta e_0 v_1 \operatorname{sgn}(k_p)$$

$$\dot{\hat{\alpha}}_1 = -\gamma_1 e_0 \zeta_1$$

$$\dot{\hat{\alpha}} = -\Gamma_\alpha e_0 v_2$$

Onde $\zeta_p = \frac{\beta_m^T v_1}{\gamma_g} - u - \frac{\hat{\beta}^T v_1}{\gamma_g}$ e $\zeta_1 = y - \frac{\beta_m^T v_2}{\gamma_g}$. Γ_β e Γ_α são matrizes diagonais definidas positivas e $\gamma_p > 0$ e $\gamma_1 > 0$, e $\hat{k}_p$ é projetado tal que $|k_p| > k_0$.

Algoritmo IMRAC,Cont

E calculamos os parâmetros do controlador para gerar a lei de controle

$$u = \theta_{v1}^T v_1 + \theta_n y + \theta_{v2}^T v_2 + \theta_{2n} r:$$

$$\theta_{v1} = \frac{\beta_m - \beta}{\gamma}$$

$$\theta_n = \frac{\alpha_1 - \alpha_{m,1}}{k_p}$$

$$\theta_{v2} = \frac{\alpha - \alpha_m + (\alpha_{m,1} - \alpha_1)\beta_m}{k_p \gamma}$$

$$\theta_{2n} = \frac{km}{k_p}$$

Algoritmo IVS-MRAC

Substituem-se as estimativas dos parâmetros da planta por leis chaveadas:

$$\hat{k}_p = k_{p,nom} - \bar{k}_p \operatorname{sgn}(e_o(\frac{\beta_m^T v_1}{\gamma} - u - \frac{\beta^T v_1}{\gamma}))$$

$$\hat{\beta}_i = -\bar{\beta}_i \operatorname{sgn}(e_o \frac{-v_{1,i}}{\gamma}), i = 1, \dots, n-1$$

$$\hat{\alpha}_1 = -\bar{\alpha}_1 \operatorname{sgn}(e_o(y - \frac{\beta_m^T v_2}{\gamma}))$$

$$\hat{\alpha}_i = -\bar{\alpha}_i \operatorname{sgn}(e_o \frac{v_{2,i-1}}{\gamma}), i = 2, \dots, n$$

Algoritmo IVS-MRAC, Cont

E calculamos os parâmetros do controlador:

$$\theta_{v1} = \frac{\beta_m - \beta}{\gamma}$$

$$\theta_n = \frac{\alpha_1 - \alpha_{m,1}}{k_p}$$

$$\theta_{v2} = \frac{\alpha - \alpha_m + (\alpha_{m,1} - \alpha_1)\beta_m}{k_p \gamma}$$

$$\theta_{2n} = \frac{km}{k_p}$$

Algoritmo IDMARC

O IDMARC pode ser interpretado tal que estimativas dos parâmetros da planta sejam entregues através de uma combinação convexa:

$$\hat{k}_p = (1 - \mu)\hat{k}_{p,vs} + \mu\hat{k}_{p,int}$$

$$\hat{\beta} = (1 - \mu)\hat{\beta}_{vs} + \mu\hat{\beta}_{int}$$

$$\hat{\alpha}_1 = (1 - \mu)\hat{\alpha}_{1,vs} + \mu\hat{\alpha}_{1,int}$$

$$\hat{\alpha} = (1 - \mu)\hat{\alpha}_{vs} + \mu\hat{\alpha}_{int}$$

onde:

$$\mu = e^{\frac{-e_0^2}{L}}$$

Algoritmo IDMARC, Cont

E calculamos os parâmetros do controlador:

$$\theta_{v1} = \frac{\beta_m - \beta}{\gamma}$$

$$\theta_n = \frac{\alpha_1 - \alpha_{m,1}}{k_p}$$

$$\theta_{v2} = \frac{\alpha - \alpha_m + (\alpha_{m,1} - \alpha_1)\beta_m}{k_p \gamma}$$

$$\theta_{2n} = \frac{km}{k_p}$$

Parametrização da Planta, II

Adotamos agora uma parametrização diferente para a planta SISO $n^* = 1$:

$$s^n y = \theta^{*T} Y$$

com $\theta^* \in R^{2n}$:

$$\theta^* = [b_{n-1}, b_{n-2}, \dots, b_1, b_0, a_{n-1}, a_{n-2}, \dots, a_1, a_0]^T$$

e $Y \in R^{2n}$:

$$Y = [u^{(n-1)}, u^{(n-2)}, \dots, u, -y^{(n-1)}, -y^{(n-2)}, -y]^T$$

Parametrização da Planta, II, Cont

Gerando um sinal filtrado z a partir de y , tal que:

$$z = \frac{s^n y}{\Lambda(s)}$$

Podemos escrever z da seguinte forma:

$$z = \theta^{*T} \phi$$

Parametrização da Planta, II, Cont

$\phi \in R^{2n-2}$ pode ser gerado através da filtragem dos sinais de entrada e saída da planta:

$$\begin{aligned}\dot{\phi}_1(t) &= \Lambda_c \phi_1 + l u \\ \dot{\phi}_2(t) &= \Lambda_c \phi_2 + l y\end{aligned}$$

Com $\phi = [\phi_1 \ \phi_2]^T$ Onde Λ_c, l representam no espaço de estados o vetor de funções de transferência:

$$\frac{[s^{(n-1)}, s^{(n-2)}, \dots, s^0]^T}{\Lambda(s)}$$

Equivalência entre as Parametrizações I e II

Para obter a parametrização I a partir da parametrização II, os parâmetros do numerador e do denominador da planta podem ser extraídos do vetor de parâmetros θ^* da planta:

$$\theta^* = \left[b_{n-1} \quad \{b_{n-2} \quad \dots \quad b_1 \quad b_0\} \quad a_{n-1} \quad \{a_{n-2} \quad \dots \quad a_1 \quad a_0\} \right]^T$$

$$\theta^* = \left[k_p \quad \frac{1}{k_p} \beta^T \quad \alpha_1 \quad \alpha^T \right]^T$$

Múltiplos Modelos de Identificação

Estabelecemos agora um conjunto de $N \geq 2n + 1$ Modelos de Identificação:

$$\Sigma_i : z_i = \theta_i^T \phi$$

Onde os parâmetros θ_i delimitam um fecho convexo S tal que $\theta_p^* \in S$. Definimos então o erro de identificação destes modelos:

$$e_i = z_i - \hat{z}$$

Múltiplos Modelos de Identificação, Cont

Os parâmetros da planta podem ser expressos como uma combinação convexa:

$$\theta_p^* = \theta_1 \alpha_1^* + \dots + \theta_N \alpha_N^* = \bar{\Theta} \bar{\alpha}^*$$

Como no caso para variáveis de estado acessíveis criamos uma matriz $E(t)$:

$$E(t) = \begin{bmatrix} e_1 - e_N & e_2 - e_N & \dots & e_{N-1} - e_N \end{bmatrix}$$

Aprendizado Convergente

De forma a acumular informações passadas para garantir convergência dos parâmetros para seus valores corretos, integramos $E^T E$ e $E^T e_N$, criando os sinais:

$$v(0) = 0$$

$$\dot{v} = -\sigma v + E^T e_N(t)$$

$$M(0) = 0$$

$$\dot{M} = -\sigma M + E^T(t)E(t)$$

Com $\sigma > 0$ escolhido tal que $M \in L_\infty$ e $v \in L_\infty$.

Estimamos α^* a partir de:

$$\dot{\hat{\alpha}} = -P[E^T E \hat{\alpha} + E^T e_{n+1} + M \hat{\alpha} + v]$$

Com:

$$P = \begin{cases} \alpha_0, & \text{se } \alpha_0 < 1/(\lambda_{\max}(E^T E)h) \\ & \text{e } \lambda_{\min}(M + E^T E) < K_{\min} \\ 1/(2\lambda_{\max}(E^T E)h), & \text{se } \alpha_0 > 1/(\lambda_{\max}(E^T E)h) \\ & \text{e } \lambda_{\min}(M + E^T E) < K_{\min} \\ (M + E^T E)^{-1}/h, & \text{se } \lambda_{\min}(M + E^T E) \geq K_{\min} \end{cases}$$

$$\alpha_0 > 0 \text{ e } K_{\min} > 0.$$

Estabilidade do Estimador

Com a lei de estimação proposta e a partir da seguinte candidata a função de Lyapunov:

$$V(\tilde{\alpha}) = \tilde{\alpha}^T \tilde{\alpha}$$

temos $\dot{V}(\tilde{\alpha}) < 0$ e o estimador é estável. Analisando no domínio discreto temos:

$$\Delta V(\tilde{\alpha}, k+1) = \begin{cases} hP\tilde{\alpha}^T X^{-1}(-2D + hPD^2)X\tilde{\alpha} < 0, & \text{se } \lambda_{\min}(M + E^T E) < K_{\min} \\ -\tilde{\alpha}^T \tilde{\alpha} < 0, & \text{se } \lambda_{\min}(M + E^T E) \geq K_{\min} \end{cases}$$

Onde $M + E^T E = X^{-1}DX$.

Adaptação de Segundo Nível, Cont

O espaço de busca dos parâmetros é limitado por projeção de forma a garantir que $0 < \alpha_i < 1, \forall i$. Com o vetor de parâmetros α estimado geramos:

$$\alpha_N = 1 - \sum_{i=1}^{N-1} \alpha_i$$

E as estimativas dos parâmetros da planta são calculadas como:

$$\hat{\theta}_p = \bar{\Theta} \hat{\alpha}$$

Com $\hat{\alpha} = \begin{bmatrix} \hat{\alpha}^T & \alpha_N \end{bmatrix}^T$

IMRAC com Adaptação de Segundo Nível

Estimamos os parâmetros da planta a partir da definição de um conjunto de modelos de identificação que forma um fecho convexo que contém os parâmetros da planta:

$$\dot{\hat{\alpha}} = -P[E^T E \hat{\alpha} + E^T e_{n+1} + M \hat{\alpha} + v]$$

$$\alpha_N = 1 - \sum_{i=1}^{N-1} \alpha_i$$

$$\hat{\hat{\alpha}} = \begin{bmatrix} \hat{\alpha}^T & \alpha_N \end{bmatrix}^T$$

$$\hat{\theta}_p = \begin{bmatrix} k_p & \frac{1}{k_p} \beta^T & \alpha_1 & \alpha^T \end{bmatrix} = \bar{\Theta} \hat{\hat{\alpha}}$$

IMRAC com Adaptação de Segundo Nível

E calculamos os parâmetros do controlador:

$$\theta_{v1} = \frac{\beta_m - \beta}{\gamma}$$

$$\theta_n = \frac{\alpha_1 - \alpha_{m,1}}{k_p}$$

$$\theta_{v2} = \frac{\alpha - \alpha_m + (\alpha_{m,1} - \alpha_1)\beta_m}{k_p \gamma}$$

$$\theta_{2n} = \frac{km}{k_p}$$

Caso para Simulação, IMRAC-A2N

Consideramos a planta:

$$W(s) = \frac{y(s)}{u(s)} = 1 \frac{s^2 + 4s + 3}{s^3 + 4s^2 + 4.5s + 1.875} \quad (1)$$

que deve seguir o modelo de referência:







$$M(s) = \frac{y_m(s)}{r(s)} = 2.5 \frac{s^2 + 8s + 6}{s^3 + 9s^2 + 23s + 15} \quad (2)$$

Caso para Simulação, IMRAC-A2N,Cont







e cujos parâmetros estão contidos no fecho convexo:

$$\Theta = \begin{bmatrix} -4.2748 & -2.0727 & 3.1990 & -5.7136 & -0.3390 & 1.6579 & 4.2983 \\ 10.3168 & -2.8507 & 7.4804 & 4.8865 & -0.2454 & 7.8240 & -2.3002 \\ -0.1756 & 3.0194 & 9.5034 & -0.0940 & -0.7587 & 3.6440 & -0.6675 \\ 1.6518 & 7.4110 & 4.0450 & 1.7125 & 10.8438 & 6.8285 & -3.7609 \\ 3.4023 & 3.1134 & 10.9909 & 5.4061 & 5.2530 & 2.8326 & -1.7132 \\ 2.0863 & -0.5700 & -0.4138 & 6.2352 & 3.1425 & 4.9063 & 0.2758 \end{bmatrix}$$

IMRAC-A2N, Simulação 1



IMRAC-A2N com Ruído e Perturbação em $t = 2s$, Simulação 2



IDMARC com Adaptação de Segundo Nível

Estimamos os parâmetros da planta usando a Adaptação de Segundo Nível:

$$\dot{\hat{\alpha}} = -P[E^T E \hat{\alpha} + E^T e_{n+1} + M \hat{\alpha} + v]$$

$$\alpha_N = 1 - \sum_{i=1}^{N-1} \alpha_i$$

$$\hat{\alpha} = \begin{bmatrix} \hat{\alpha}^T & \alpha_N \end{bmatrix}^T$$

$$\hat{\theta}_p = \begin{bmatrix} k_p & \frac{1}{k_{p,a2n}} \beta_{a2n}^T & \alpha_{1,a2n} & \alpha_{a2n}^T \end{bmatrix} = \bar{\Theta} \hat{\alpha}$$

IDMARC com Adaptação de Segundo Nível

E realizamos uma combinação convexa:

$$\hat{k}_p = (1 - \mu)\hat{k}_{p,vs} + \mu\hat{k}_{p,a2n}$$

$$\hat{\beta} = (1 - \mu)\hat{\beta}_{vs} + \mu\hat{\beta}_{a2n}$$

$$\hat{\alpha}_1 = (1 - \mu)\hat{\alpha}_{1,vs} + \mu\hat{\alpha}_{1,a2n}$$

$$\hat{\alpha} = (1 - \mu)\hat{\alpha}_{vs} + \mu\hat{\alpha}_{a2n}$$

IDMARC com Adaptação de Segundo Nível

E modificamos ligeiramente o cálculo de μ :

$$\bar{\mu} = -q + (1 + q)e^{\frac{-e_0^2}{L}}$$

$$\mu = \begin{cases} \bar{\mu}, & \text{se } \bar{\mu} \leq 1 \text{ e } \bar{\mu} \geq 0 \\ 0 & \text{se } \bar{\mu} < 0 \\ 1 & \text{se } \bar{\mu} > 1 \end{cases}$$

com $q > 0$, de forma a permitir a atuação exclusiva do controle por estrutura variável quando e_0 é muito grande.

Caso para Simulação, IDMARC-A2N

Consideramos a planta:

$$W(s) = \frac{y(s)}{u(s)} = 1 \frac{s^2 + 4s + 3}{s^3 - 4s^2 - 4.5s - 1.875}$$

que deve seguir o modelo de referência:

$$M(s) = \frac{y_m(s)}{r(s)} = 2.5 \frac{s^2 + 8s + 6}{s^3 + 9s^2 + 23s + 15}$$


Caso para Simulação, IDMARC-A2N, Cont

O fecho que contém os parâmetros da planta é:


$$\bar{\Theta} = \begin{bmatrix} -4.274 & -2.072 & 3.199 & -5.713 & -0.339 & 1.657 & 4.298 \\ 10.316 & -2.850 & 7.480 & 4.886 & -0.245 & 7.824 & -2.300 \\ -0.175 & 3.019 & 9.503 & -0.094 & -0.758 & 3.644 & -0.667 \\ -1.651 & -7.411 & -4.045 & -1.712 & -10.843 & -6.828 & 3.760 \\ -3.402 & -3.113 & -10.990 & -5.406 & -5.253 & -2.832 & 1.713 \\ -2.086 & 0.570 & 0.413 & -6.235 & -3.142 & -4.906 & -0.275 \end{bmatrix}$$



IDMARC-A2N, Simulação 1



IDMARC-A2N com Ruído e Perturbação em $t = 2s$, Simulação 2



Objetivos

Como objetivos adicionais futuros consideramos:

- 1 Provas de Estabilidade (IDMARC-A2N,IMRAC-A2N para Planta SISO com $n^* = 1$)
- 2 Análise considerando Ruído e Perturbação
- 3 Simulações com Dinâmica não-modelada da Planta
- 4 Uso do Modelo Série-Paralelo na Formulação Matemática para a Planta SISO com $n^* = 1$
- 5 Métodos de Escolha da Matriz que representa o fecho convexo do conjunto de modelos