



UNIVERSIDADE FEDERAL DO RIO GRANDE DO NORTE
CENTRO DE TECNOLOGIA
PROGRAMA DE PÓS-GRADUAÇÃO EM ENGENHARIA ELÉTRICA E
DE COMPUTAÇÃO



Sobre a Adaptação de Segundo Nível como Técnica de Estimação de Parâmetros em Plantas Lineares Parcialmente Conhecidas e sua Aplicação ao Controle Adaptativo

Pedro Yochinori Gushiken

Orientador: Prof. Dr. Aldayr Dantas de Araújo

Dissertação de Mestrado apresentada ao Programa de Pós-Graduação em Engenharia Elétrica e de Computação da UFRN (área de concentração: Engenharia de Computação) como parte dos requisitos para obtenção do título de Mestre em Ciências.

Número de ordem PPgEEC: M000
Natal, RN, junho de 2016

Divisão de Serviços Técnicos

Catálogo da publicação na fonte. UFRN / Biblioteca Central Zila Mamede

Gushiken, Pedro Yochinori.

Sobre a Adaptação de Segundo Nível como Técnica de Estimação de Parâmetros em Plantas Lineares Parcialmente Conhecidas / Pedro Yochinori Gushiken - Natal, RN, 2017

23 p.

Orientador: Aldayr Dantas de Araújo

Co-orientador:

Tese (mestrado) - Universidade Federal do Rio Grande do Norte. Centro de Tecnologia. Programa de Pós-Graduação em Engenharia Elétrica e de Computação.

1. Redação técnica - Tese. 2. $\text{\LaTeX}$ - Tese. I. Melo, Sicrano Matosinho de. II. Amaral, Beltrano Catandura do. III. Título.

RN/UF/BCZM

CDU 004.932(043.2)

Sobre a Adaptação de Segundo Nível como Técnica de Estimação de Parâmetros em Plantas Lineares Parcialmente Conhecidas e sua Aplicação ao Controle Adaptativo

Pedro Yochinori Gushiken

Dissertação de Mestrado aprovada em 31 de junho de 2016 pela banca examinadora composta pelos seguintes membros:

Prof. Dr. Aldayr Dantas de Araújo (orientador) DCA/UFRN

Prof. Dr. (co-orientador) DCA/UFRN

Prof. Dr. DCEP/UFRN

Prof^ª Dr^a DCA/UFRN

*À Thaylana e à Maria, pela
paciência durante a realização deste
trabalho.*

Agradecimentos

Ao Professor Aldayr Dantas de Araújo, sou extremamente grato pela orientação.

Ao Professor Leonardo Rodrigues de Lima Teixeira pela contribuição de sua tese de doutorado para estudo deste mestrando.

Aos Professores e colegas da base de pesquisa, em especial professor Allan de Medeiros Martins que esclareceu dúvidas que se mostraram fundamentais para a confecção deste trabalho.

Aos colegas de mestrado Isaac Dantas Isidório e Winnie de Lima Torres pela companhia e amizade.

À minha família, em especial à mamãe dona Maria do Socorro e à minha esposa Thaylanã Mayra, pelo apoio incondicional durante esta jornada.

À CAPES, pelo apoio financeiro.

Resumo

A adaptação de segundo nível é uma técnica de estimação de parâmetros que foi introduzida recentemente e tem demonstrado resultados de rapidez de convergência dos parâmetros e simplicidade das leis adaptativas propostas que são considerados promissores. É suficiente que o conjunto de parâmetros da planta pertença a um fecho convexo. Este trabalho busca descrever as provas matemáticas e algoritmos envolvidos no uso da adaptação de segundo nível como técnica de estimação de parâmetros de plantas lineares. É feito também um estudo de caso de um controlador adaptativo por modelo de referência e de um controlador em modo dual indireto adaptativo robusto, fazendo uso da técnica mencionada com algumas inovações introduzidas neste documento.

Palavras-chave: Adaptação de Segundo Nível, Controle Adaptativo, Estimação de Parâmetros, Identificação.

Abstract

Second level Adaptation is a scheme for parameter estimation that was recently introduced and has displayed results for rapid convergence of the parameters and simplicity of the proposed adaptive laws, which are considered promising. It's sufficient that all the set of plant parameters belongs to a convex hull. This thesis seeks to describe the mathematical proofs and algorithms involved in using second level adaptation for the purpose of estimating the parameters of a linear plant. A study with a model reference adaptive controller and an indirect dual mode adaptive robust controller is made.

Keywords: Second Level Adaptation, Adaptive Control, Parameter Estimation, Identification.

Sumário

Sumário	i
Lista de Figuras	v
Lista de Tabelas	vii
1 Introdução	1
Lista de Símbolos e Abreviaturas	1
2 Referencial Teórico	5
2.1 Estimação de Parâmetros em Tempo Real	5
2.1.1 Planta Linear Invariante no Tempo com Acesso às Variáveis de Estado	5
2.1.2 Planta Linear Invariante no Tempo de Grau Relativo 1 com Realimentação de Entrada-Saída	7
2.1.3 Simetria Radial das Trajetórias de Múltiplos Modelos	10
2.2 Controle Adaptativo	12
2.2.1 Controle Adaptativo por Posicionamento de Polos	12
2.2.2 Controle Adaptativo por Modelo de Referência	14
2.2.3 Controle Adaptativo por Modelo de Referência e Estrutura Variável	16
3 Adaptação de Segundo Nível	19
3.1 Variáveis de Estado Acessíveis	19
3.1.1 Pertencimento do Vetor de Parâmetros da Planta à um Fecho Convexo de $2n+1$ modelos de identificação	19
3.2 Realimentação de Entrada e Saída	22
3.2.1 Pertencimento do Vetor de Parâmetros da Planta à um Fecho Convexo de $2n+1$ modelos de identificação	22
3.2.2 Múltiplos Modelos	23
3.3 Excitação dos Modos da Planta	23
3.3.1 Excitação dos modos da planta e conceito de Persistência	23
3.3.2 Desligamento do Sinal Persistentemente Excitante	26
3.4 Projeção	27
3.4.1 Projeção Retangular	27
3.4.2 Projeção dos numa área de com fronteira convexa e suave.	27

3.5	Estabilidade	29
3.5.1	Estabilidade do Estimador para Adaptação de Segundo Nível sem modificações	29
3.5.2	Estabilidade do Estimador no caso discreto para Adaptação de Segundo Nível modificada por um ganho escalar	30
3.5.3	Estabilidade do Estimador no caso discreto para Adaptação de Segundo Nível modificada com Matriz de Ganhos P	31
3.5.4	Aprendizado Convergente	32
4	Adaptação de Segundo Nível aplicada ao Controle	33
4.1	Adaptação de Segundo Nível aplicada ao Controle Adaptativo por Modelo de Referência de Plantas com Polinômio do Numerador conhecido e Variáveis de Estado Acessíveis	33
4.1.1	Formulação	33
4.1.2	Simulação 1 - Planta Instável de Segunda Ordem	34
4.1.3	Simulação 2 - Planta Instável de Terceira Ordem	34
4.1.4	Simulação 3 - Planta Instável de Segunda Ordem com Perturbação na Entrada	36
4.1.5	Simulação 4 - Planta Instável de Segunda Ordem com Ruído de Medição	38
4.2	Adaptação de Segundo Nível aplicada ao Controle Adaptativo por Modelo de Referência de uma Planta com Grau Relativo Unitário com realimentação de Entrada e Saída	39
4.2.1	Formulação	39
4.2.2	Simulação 1 - Planta Estável de Terceira Ordem	40
4.2.3	Simulação 2 - Planta Estável de Terceira Ordem com Ruído de Medição na Saída da Planta	40
4.2.4	Simulação 3 - Planta Estável de Terceira Ordem com Perturbação na Entrada	40
4.2.5	Simulação 4 - Planta Estável de Terceira Ordem com Ruído de Medição na Saída e Perturbação na Entrada	40
4.3	Adaptação de Segundo Nível aplicada ao Controle Adaptativo em Modo Dual Indireto Adaptativo Robusto de uma Planta com Grau Relativo Unitário e Realimentação de Entrada e Saída	43
4.3.1	Simulação 1 - Planta Estável de Terceira Ordem	43
4.3.2	Simulação 2 - Planta Estável de Terceira Ordem com Ruído de Medição na Saída da Planta	43
4.3.3	Simulação 3 - Planta Estável de Terceira Ordem com Perturbação na Entrada	43
4.3.4	Simulação 4 - Planta Estável de Terceira Ordem com Ruído de Medição na Saída e Perturbação na Entrada	46
4.3.5	Simulação 5 - Planta Instável de Terceira Ordem	46
4.3.6	Simulação 6 - Planta Instável de Terceira Ordem com Ruído de Medição na Saída da Planta	47

4.3.7	Simulação 7 - Planta Instável de Terceira Ordem com Perturbação na Entrada	47
4.3.8	Simulação 8 - Planta Instável de Terceira Ordem com Ruído de Medição na Saída e Perturbação na Entrada	47
5	Implementação	51
5.1	MATLAB	51
5.1.1	Adaptação de Segundo Nível aplicada ao Controle Adaptativo por Modelo de Referência de uma Planta com Polinômio do Numerador Conhecido e Acesso às Variáveis de Estado da Planta	51
5.1.2	Adaptação de Segundo Nível aplicada ao Controle Adaptativo por Modelo de Referência de uma Planta com Grau Relativo Unitário e Realimentação de Entrada e Saída	54
5.1.3	Adaptação de Segundo Nível aplicada ao Controle Adaptativo em Modo Dual Indireto Adaptativo Robusto de uma Planta com Grau Relativo Unitário e Realimentação de Entrada e Saída	59
6	Conclusão	65
	Referências bibliográficas	67

Lista de Figuras

2.1	Ilustração de uma iteração da Adaptação de dois modelos $\theta_{j,1}$ e $\theta_{j,2}$ pertencendo a uma mesma reta θ_r contendo θ^* no espaço de parâmetros, os modelos continuam pertencendo a uma reta θ_s contendo θ^*	12
4.1	a) Trajetória dos parâmetros b) Comportamento da figura de Mérito η c) Norma do vetor de erros entre as variáveis de estado da planta e do modelo de referência d) Sinal de Controle e) Comportamento da Saída da Planta, Referência/Ganho Estático e Saída do Modelo de Referência	35
4.2	a) Trajetória dos parâmetros em termos do valor de cada α_i b) Comportamento da figura de Mérito η c) Norma do vetor de erros entre as variáveis de estado da planta e do modelo de referência d) Sinal de Controle e) Comportamento da Saída da Planta, Referência/Ganho Estático e Saída do Modelo de Referência	36
4.3	a) Trajetória dos parâmetros onde a linha em verde é o caminho feito após a introdução da perturbação b) Comportamento da figura de Mérito η c) Norma do vetor de erros entre as variáveis de estado da planta e do modelo de referência d) Sinal de Controle e) Comportamento da Saída da Planta, Referência/Ganho Estático e Saída do Modelo de Referência . . .	37
4.4	a) Trajetória dos parâmetros b) Comportamento da figura de Mérito η c) Norma do vetor de erros entre as variáveis de estado da planta e do modelo de referência d) Sinal de Controle e) Comportamento da Saída da Planta, Referência/Ganho Estático e Saída do Modelo de Referência	38
4.5	Simulação para o MRAC aplicando Adaptação de Segundo Nível: a) Erro de Saída b) Saída da Planta e do Modelo de Referência c) Sinal de Controle d, e, f) Trajetória dos parâmetros α	41
4.6	Simulação para o MRAC aplicando Adaptação de Segundo Nível com Ruído de Medição: a) Erro de Saída b) Saída da Planta e do Modelo de Referência c) Sinal de Controle d, e, f) Trajetória dos parâmetros α . . .	41
4.7	Simulação para o MRAC aplicando Adaptação de Segundo Nível com Perturbação introduzida na entrada da planta em $t=2s$: a) Erro de Saída b) Saída da Planta e do Modelo de Referência c) Sinal de Controle d, e, f) Trajetória dos parâmetros α	42
4.8	Simulação para o MRAC aplicando Adaptação de Segundo Nível com ruído de medição na saída da planta e perturbação na entrada: a) Erro de Saída b) Saída da Planta e do Modelo de Referência c) Sinal de Controle d, e, f) Trajetória dos parâmetros α	42

4.9	Simulação para o IDMARC aplicando Adaptação de Segundo Nível: <i>a)</i> Erro de Saída <i>b)</i> Saída da Planta e do Modelo de Referência <i>c)</i> Sinal de Controle <i>d, e, f)</i> Trajetória dos parâmetros α	44
4.10	Simulação para o IDMARC aplicando Adaptação de Segundo Nível com ruído de medição na saída da planta: <i>a)</i> Erro de Saída <i>b)</i> Saída da Planta e do Modelo de Referência <i>c)</i> Sinal de Controle <i>d, e, f)</i> Trajetória dos parâmetros α	45
4.11	Simulação para o IDMARC aplicando Adaptação de Segundo Nível com perturbação na entrada da planta: <i>a)</i> Erro de Saída <i>b)</i> Saída da Planta e do Modelo de Referência <i>c)</i> Sinal de Controle <i>d, e, f)</i> Trajetória dos parâmetros α	45
4.12	Simulação para o IDMARC aplicando Adaptação de Segundo Nível com ruído de medição na saída e perturbação na entrada da planta: <i>a)</i> Erro de Saída <i>b)</i> Saída da Planta e do Modelo de Referência <i>c)</i> Sinal de Controle <i>d, e, f)</i> Trajetória dos parâmetros α	46
4.13	Simulação para o IDMARC aplicando Adaptação de Segundo Nível com ruído de medição na saída e perturbação na entrada da planta instável: <i>a)</i> Erro de Saída <i>b)</i> Saída da Planta e do Modelo de Referência <i>c)</i> Sinal de Controle <i>d, e, f)</i> Trajetória dos parâmetros α	47
4.14	Simulação para o IDMARC aplicando Adaptação de Segundo Nível com ruído de medição na saída e perturbação na entrada da planta instável: <i>a)</i> Erro de Saída <i>b)</i> Saída da Planta e do Modelo de Referência <i>c)</i> Sinal de Controle <i>d, e, f)</i> Trajetória dos parâmetros α	48
4.15	Simulação para o IDMARC aplicando Adaptação de Segundo Nível com ruído de medição na saída e perturbação na entrada da planta instável: <i>a)</i> Erro de Saída <i>b)</i> Saída da Planta e do Modelo de Referência <i>c)</i> Sinal de Controle <i>d, e, f)</i> Trajetória dos parâmetros α	48
4.16	Simulação para o IDMARC aplicando Adaptação de Segundo Nível com ruído de medição na saída e perturbação na entrada da planta instável: <i>a)</i> Erro de Saída <i>b)</i> Saída da Planta e do Modelo de Referência <i>c)</i> Sinal de Controle <i>d, e, f)</i> Trajetória dos parâmetros α	49

Lista de Tabelas

4.1	Parâmetros de Simulação do MRAC com realimentação de entrada e saída	40
4.2	Parâmetros de Simulação do IDMARC	44

Capítulo 1

Introdução

Na área de Teoria de Controle alguns dos tópicos estudados se referem às propriedades de classes de controladores para plantas com apenas uma variável de entrada e uma variável de saída *Single-Input-Single-Output* (SISO) onde apenas estas variáveis estão disponíveis para medição e também para plantas desta forma com acesso à todas as variáveis de estado para medição. Estas classes de controladores tipicamente buscam implementar uma lei de controle capaz de resolver um problema matemático: Determinar qual o valor da variável de entrada u que deve ser demandada pelo controlador sobre o atuador, tal que a variável de interesse y da planta seja conduzida pelo atuador até uma determinada referência r . Este problema é denominado problema do rastreamento. Exemplos de variáveis de processo sujeitas ao problema são posição, velocidade, aceleração, nível, pressão, tensão elétrica, campo magnético e carga, dentre outras.

No controle de plantas e processos dinâmicos é comum que os parâmetros sejam desconhecidos ou conhecidos com incertezas e além disso que o processo a ser controlado possua não-linearidades (como por exemplo atrasos de transporte), distúrbios e que os sensores usados apresentem ruído de medição. Além disso os parâmetros de um sistema dinâmico qualquer podem variar lentamente ao longo do tempo, como por exemplo devido ao desgaste dos componentes mecânicos, o que pode deteriorar o comportamento do sistema em malha fechada. Esta falta de um conhecimento exato sobre como se dá a dinâmica da planta dificulta o projeto de controladores lineares (controladores P, PI, PD, PID, Avanço, Atraso e Avanço-Atraso), cujos ganhos devem ser calculados respeitando um certo conservadorismo de forma a garantir a estabilidade e robustez do sistema. Esta limitação levou, ao longo de várias décadas, ao desenvolvimento de classes de controladores não lineares voltados a lidar efetivamente com plantas reais, com garantias matemáticas de funcionamento. Exemplos incluem mas não se restringem aos Controladores de Estrutura Variável (tese professores), Controladores projetados a partir de lógica Fuzzy, Controle H infinito e H 2 e o Controle Adaptativo, além de estratégias híbridas. Cada um destes controladores apresenta uma série de benefícios e limitações, de forma que cada caso deve ser analisado de acordo com as especificações de desempenho, robustez e propriedades da planta, além do hardware disponível para implementação dos algoritmos.

O Controle Adaptativo lida com a estimação dos parâmetros θ_p^* da planta e subse-

quente cálculo dos parâmetros ideais do controlador, a chamada estratégia indireta, ou estimação direta dos parâmetros ideais do controlador, a estratégia direta, de forma simultânea ao controle em si. Existem também duas estratégias principais de implementação, a partir destas estimativas, da lei de controle u do Controlador Adaptativo, que analisaremos neste trabalho: Por Posicionamento de Polos e Por Modelo de Referência.

No Controle Adaptativo Por Posicionamento de Polos, apenas o polinômio referente ao denominador da função de transferência do conjunto planta+controlador deve ser escolhido como parte do projeto. No Controle Adaptativo por Modelo de Referência tanto os zeros quanto os polos em malha e o ganho do sistema em malha fechada são especificados. Não surpreendentemente, o Controle Adaptativo por Modelo de Referência costuma apresentar exigências mais duras na sua implementação, pois requer cancelamento de zeros pelo Controlador.

Nesta dissertação analisamos o problema do Controle Adaptativo usando a estratégia indireta, isto é, o uso de um estimador dos parâmetros da planta por leis integrais atuando em conjunto com o Controlador, de forma que os parâmetros do controlador sejam atualizados em tempo real de acordo com as estimativas dos parâmetros da planta. Tradicionalmente o Controle Adaptativo com leis integrais apresenta uma limitação em termos da velocidade de convergência do sinal de controle para aquele que garante o desempenho desejado (condição de matching), e também dos parâmetros para seus valores verdadeiros dada a condição de existência de um sinal de entrada ou referência com persistência de excitação. Esta limitação resulta diretamente em um transitório da planta que é lento e oscilatório, algo indesejável na absoluta maioria das aplicações.

Em (Narendra et al. 2014, Narendra et al. 2012, Han & Narendra 2010a, Han & Narendra 2012, Han & Narendra 2010b) foi introduzido um método de estimação de parâmetros com leis integrais conhecido como Adaptação de Segundo Nível, baseada na adaptação de um modelo virtual formado a partir da combinação convexa de um conjunto de modelos de identificação. Para tanto é necessário conhecimento da região do espaço de parâmetros em que se encontram os parâmetros da planta, como por exemplo numa planta intervalar, onde os coeficientes da função de transferência estão contidos em intervalos conhecidos. Também é necessário que o conjunto de modelos de identificação forme um fecho convexo que contenha esta região. Naqueles trabalhos foi demonstrado que esta técnica de estimação apresenta diversas vantagens em relação às técnicas de estimação de parâmetros convencionais, como por exemplo a linearidade da lei integral usada.

Neste trabalho investigamos as propriedades da Adaptação de Segundo Nível como técnica de estimação de parâmetros, com acesso às variáveis de estado da planta e no caso em que apenas a entrada e a saída estão disponíveis para medição. Demonstramos que, caso seja possível demonstrar que uma determinada soma de matrizes $M(t) + E^T(t)E(t)$ gerada a partir de leis integrais é de posto cheio, esta técnica garante uma velocidade de adaptação instantânea.

Algumas inovações propostas na dissertação se tratam de modificações no algoritmo original proposto por (Narendra et al. 2014). Mostramos que é possível garantir a convergência dos parâmetros para seus valores verdadeiros no caso de plantas lineares invariantes quando o sinal de entrada cumpre uma condição de excitação dos modos da planta por tempo finito. No caso de técnicas de estimação de parâmetros em tempo real convencionais tais como o Método do Gradiente e o Método dos Mínimos Quadrados esta garantia só se dá para um sinal de entrada que cumpra uma condição de persistência de excitação, uma exigência muito mais estrita. Explicitamos algoritmos de projeção de forma a limitar o espaço de busca dos parâmetros e também ajudar nas garantias de estabilidade. Introduzimos fórmulas analíticas para escolha dos ganhos adaptativos consoante informações provenientes dos modelos de identificação, de forma a simplificar o problema do projeto da lei adaptativa integral do estimador e garantir estabilidade da adaptação independente do passo de integração. Estas modificações têm por objetivo culminar em propostas de Controladores Adaptativos que busquem tratar de certas dificuldades que podem aparecer na implementação do Controle Adaptativo, tais como:

- Transitório lento e oscilatório
- Problemas de caracterização da robustez
- Excesso de Parâmetros de projeto
- Parâmetros de Projeto Não-Intuitivos

Combinamos a Adaptação de Segundo Nível ao Controlador Adaptativo por Modelo de Referência e ao Controlador Adaptativo por Posicionamento de Polos. Finalmente, combinamos o Controle Adaptativo Convencional utilizando a Adaptação de Segundo Nível como técnica de estimação de parâmetros com os Sistemas de Estrutura Variável, como em (Hsu 1990, Hsu et al. 1994, Hsu & Costa 1989), usando a matemática desenvolvida para o Controlador em Modo Dual Adaptativo Robusto Indireto (ID-MARC) a partir de (Cunha 2008, Cunha et al. 2007, Mota & Araujo 2002, Oliveira 2003, Oliveira 2007, Oliveira & Araujo 2008a, Oliveira & Araujo 2008b, Tahmasebi et al. 2016, Teixeira 2011, Teixeira et al. 2013), que busca combinar as boas propriedades de transitório dos Sistemas com Estrutura Variável ao sinal de controle suave gerado pelo Controle Adaptativo.

O capítulo 1 contém esta introdução. O capítulo 2 apresenta a fundamentação teórica dos métodos de estimação de parâmetros conhecidos como Método do Gradiente e Método dos Mínimos Quadrados e as estratégias indiretas de Controle Adaptativo por Modelo de Referência e Controle Adaptativo por Posicionamento de Polos, tanto para o caso em que as variáveis de estado da planta estão acessíveis quanto no caso entrada-saída. No capítulo 3 demonstramos as justificativas e provas matemáticas relacionadas à Adaptação de Segundo Nível. No Capítulo 4 realizamos a aplicação matemática da Adaptação de Segundo Nível ao Controlador Adaptativo por Modelo de Referência, discutidos na fundamentação teórica, com resultados de simulação e também a aplicamos ao Controlador em Modo Dual Adaptativo Robusto Indireto. No capítulo 5 detalhamos os algoritmos usados.

Capítulo 2

Referencial Teórico

As formulações e conceitos descritos a seguir foram retirados, exceto quando notado contrariamente no texto, de (Narendra & Annaswamy 1989, M. Krstic & Kokotovic 1995, Tao 2003, Ioannou & Sun 1996, Chen 1999, Ogata 2010, Khalil 1996, Teixeira 2016).

2.1 Estimação de Parâmetros em Tempo Real

2.1.1 Planta Linear Invariante no Tempo com Acesso às Variáveis de Estado

Seja uma planta linear invariante no tempo, com parâmetros conhecidos com incertezas, da forma:

$$\dot{x}_p = A_p x_p + b_p u \quad (2.1)$$

$$y = h^T x_p \quad (2.2)$$

Com $A_p \in R^{n \times n}$, $b_p \in R^n$, $u \in R$, $h \in R^n$ e $y \in R$, cujo vetor de estados $x_p \in R^n$ esta disponível para medição. Sua função de transferência é:

$$W(s) = h^T (sI - A_p)^{-1} b_p = k_p \frac{N_p(s)}{D_p(s)} \quad (2.3)$$

E desejamos estimar os coeficientes dos polinômios $N_p(s)$ e $D_p(s)$ e o ganho k_p , assumindo os polinômios em forma mônica. Estipulamos um modelo para estimação da saída y da planta construído a partir de estimativas dos parâmetros da planta, considerando que h^T é conhecido:

$$\hat{\dot{x}}_p = \hat{A}_p \hat{x}_p + \hat{b}_p u \quad (2.4)$$

$$\hat{y} = h^T \hat{x}_p \quad (2.5)$$

O chamado modelo paralelo. Definimos então o erro de identificação:

$$e_1 = \hat{x}_p - x_p \quad (2.6)$$

O problema da estimação de parâmetros neste contexto pode ser enunciado da seguinte forma: Como definir leis para a atualização das estimativas $\hat{A}_p$ e $\hat{b}_p$ tal que o erro $e_1(t)$ tenda a 0 a medida que o tempo t tende a infinito. Para tanto, analisemos a dinâmica do erro:

$$\dot{e}_1 = \dot{\hat{x}}_p - \dot{x}_p \quad (2.7)$$

$$\dot{e}_1 = \hat{A}_p \hat{x}_p + \hat{b}_p u - A_p x_p - b_p u \quad (2.8)$$

Definindo $\tilde{A}_p$ como a diferença entre o parâmetro A_p correto e o atual $\hat{A}_p = A_p - \tilde{A}_p$ e $\tilde{b}_p$ da mesma forma tal que $\hat{b}_p = b_p - \tilde{b}_p$ temos:

$$\dot{e}_1 = A_p e_1 - \tilde{A}_p \hat{x}_p - \tilde{b}_p u \quad (2.9)$$

A origem $\tilde{A}_p = 0_{n \times n}$, $\tilde{b}_p = 0_{n \times 1}$ e $e_1 = 0_{n \times 1}$ é um ponto de equilíbrio. Necessitamos projetar uma lei adaptativa tal que, dadas certas condições, este ponto seja atrativo e estável. Note-se que estamos assumindo que $\det(sI - A_p)^{-1}$ é um polinômio com raízes no semi-plano esquerdo aberto, ou seja, que a planta tem a origem como ponto de equilíbrio estável. Esta hipótese pode ser relaxada desde que uma lei de controle adequada para o sinal u seja escolhida de tal forma a tornar o comportamento da planta estável, garantindo sinais limitados na estimação.

Método do Erro de Saída

Usando a candidata a função de Lyapunov:

$$V(e_1, \tilde{A}_p, \tilde{b}_p) = e_1^T P e_1 + tr \left(\frac{\tilde{A}_p^T P \tilde{A}_p}{\gamma_1} \right) + tr \left(\frac{\tilde{b}_p^T P \tilde{b}_p}{\gamma_2} \right) \quad (2.10)$$

Onde $tr(\cdot)$ denota o traço da matriz, temos a derivada da forma:

$$\dot{V} = -e_1^T e_1 + 2tr \left(\frac{\tilde{A}_p^T P \dot{\tilde{A}}_p}{\gamma_1} + \tilde{A}_p^T P e_1 \hat{x}_p + \frac{\tilde{b}_p^T P \dot{\tilde{b}}_p}{\gamma_2} + \tilde{b}_p^T P e_1 u \right) \quad (2.11)$$

Como $\dot{\tilde{A}}_p = \dot{\hat{A}}_p$ e $\dot{\tilde{b}}_p = \dot{\hat{b}}_p$, é possível escolher:

$$\dot{\hat{A}}_p = -\gamma_1 e_1 \hat{x}_p^T \quad (2.12)$$

$$\dot{\hat{b}}_p = -\gamma_2 e_1 u \quad (2.13)$$

Tornando $\dot{V}$ semi-definida negativa e portanto garantindo que $V(e_1, \tilde{A}_p, \tilde{b}_p)$ não cresce.

2.1.2 Planta Linear Invariante no Tempo de Grau Relativo 1 com Realimentação de Entrada-Saída

Adotando agora uma parametrização diferente para a planta, podemos escrever:

$$y = \theta^{*T} Y \quad (2.14)$$

Com:

$$\theta^* = [b_{n-1}, b_{n-2}, \dots, b_1, b_0, a_{n-1}, a_{n-2}, \dots, a_1, a_0]^T \quad (2.15)$$

E o vetor Y da forma:

$$Y = [u^{(n-1)}, u^{(n-2)}, \dots, u, -y^{(n-1)}, -y^{(n-2)}, -y]^T \quad (2.16)$$

Ou seja, a planta pode ser escrita a partir de seus parâmetros verdadeiros em função de um vetor regressor natural Y , inacessível para medição. Neste caso temos apenas y e u disponíveis para medição e novamente queremos construir um estimador para os $2n$ coeficientes dos polinômios $N_p(s)$, $D_p(s)$ e o ganho k_p contidos no vetor de parâmetros θ^* da planta. Como temos disponíveis presentemente apenas 2 sinais é necessário considerar informações passadas para que seja possível estimar os $2n$ parâmetros da planta. Para tanto são implementados filtros da entrada e da saída da planta seguindo o raciocínio a seguir: Escolhendo um polinômio $\Lambda(s)$ com raízes no semi-plano esquerdo aberto tal que:

$$\Lambda(s) = s^n + \lambda_{n-1}s^{n-1} + \dots + \lambda_0 \quad (2.17)$$

E seja:

$$\lambda^T = [\lambda_{n-1}, \lambda_{n-2}, \dots, \lambda_0]$$

Podemos expressar:

$$\Lambda(s) = s^n + \lambda^T \alpha_{n-1} \quad (2.18)$$

Sendo:

$$\alpha_{n-1} = [s^{(n-1)}, s^{(n-2)}, \dots, s^0]^T$$

$y(t)$ é então filtrado, tal que seja criado um sinal $z(t)$:

$$z = \frac{s^n y}{\Lambda(s)} \quad (2.19)$$

calculamos então os vetores $\phi_1 \in R^n$ e $\phi_2 \in R^n$:

$$\begin{aligned} \dot{\phi}_1(t) &= \Lambda_c \phi_1 + l u \\ \dot{\phi}_2(t) &= \Lambda_c \phi_2 + l y \end{aligned} \quad (2.20)$$

Onde o par Λ_c, l vem da conversão para espaço de estados de $\frac{\alpha_{n-1}(s)}{\Lambda(s)}$ ao se estipular $C^T = I_{n \times n}$, todas as variáveis de estado como variáveis de interesse. É uma parametrização

válida para z é:

$$z = \theta^{*T} \phi \quad (2.21)$$

O vetor $\phi = [\phi_1, \phi_2]^T$ é de fato equivalente a um filtrado do vetor regressor natural Y , porém o mesmo é construtível e portanto passível de ser utilizado em uma lei de estimação. Geramos então a saída $\hat{z}$ de um modelo de estimação:

$$\hat{z} = \theta^T \phi \quad (2.22)$$

E analisando, por simplicidade, o erro não normalizado temos:

$$e_1 = \hat{z} - z \quad (2.23)$$

Caracterizando:

$$\tilde{\theta} = \theta - \theta^* \quad (2.24)$$

O erro entre o valor construído a partir do vetor regressor ϕ e dos parâmetros do modelo de estimação e a saída filtrada da planta pode ser expresso como:

$$e_1 = \hat{z} - z = \tilde{\theta}^T \phi \quad (2.25)$$

Um comentário importante a se fazer sobre a escolha de e_1 desta forma e não como $z - \hat{z}$ é que o sujeito da ação de adaptação neste caso é o modelo de estimação. A dinâmica desejada é de que o valor estimado $\hat{z}$ seja levado a se aproximar de z . O comportamento da planta nesta análise é, a princípio, independente do estimador.

Caso não tenhamos garantia de que $\phi \in \mathcal{L}_\infty$, ou seja, que o regressor seja limitado - como por exemplo no caso em que a planta apresenta polinômio no denominador com autovalores contidos no semi plano direito aberto, ou, cometendo um certo abuso de linguagem, quando a planta é instável - podemos gerar um sinal de normalização tal que $\frac{\phi}{m} \in \mathcal{L}_\infty$, com $m^2 = 1 + n_s^2$ e a escolha de n_s^2 sendo tipicamente $\phi^T \phi$ ou $\phi^T P \phi$ com $P \geq 0$:

$$\varepsilon_1 = \frac{\hat{z} - z}{m^2} \quad (2.26)$$

Método do Gradiente com Função de Custo Instantânea

Consideremos uma função de custo $J(\theta)$, de forma a resolver o problema da minimização da função a partir do parâmetro θ , da seguinte forma:

$$J(\theta) = \frac{\varepsilon_1^2 m^2}{2} \quad (2.27)$$

Que pode ser expressa em termos de θ como:

$$J(\theta) = \frac{(\theta^T \phi - z)^2}{2m^2} \quad (2.28)$$

Como $J(\theta)$ é convexa em relação ao espaço de parâmetros de θ e o sinal m garante que as componentes da função são individualmente limitados, podemos aplicar o método do gradiente, isto é, avaliar o gradiente da função de custo em relação ao parâmetro θ , buscando andar na direção contrária do crescimento da função:

$$\dot{\theta} = -\Gamma \nabla J(\theta) \quad (2.29)$$

Onde $\Gamma = \Gamma^T > 0$ é uma matriz contendo os ganhos adaptativos. Note-se que a matriz representa, geometricamente, um cisalhamento do vetor $\dot{\theta}$ que será gerado para que a estimativa θ "caminhe" no espaço de parâmetros. O gradiente de $J(\theta)$ é:

$$\nabla \theta = \frac{(\theta^T \phi - z) \phi}{m^2} = \varepsilon_1 \phi \quad (2.30)$$

Desta forma, a lei adaptativa usada para gerar θ fica da forma:

$$\dot{\theta} = -\Gamma \varepsilon_1 \phi \quad (2.31)$$

Método dos Mínimos Quadrados

Pode-se também escolher uma função de custo que pesa não apenas o erro atual, mas em instantes anteriores e também a estimativa inicial de θ :

$$J(\theta) = \frac{1}{2} \int_0^t e^{-\beta(t-\tau)} \frac{[z(\tau) - \theta^T(t) \phi(\tau)]}{m^2(\tau)} d\tau + \frac{1}{2} e^{-\beta t} (\theta - \theta_0)^T Q_0 (\theta - \theta_0) \quad (2.32)$$

Note-se particularmente o termo $\theta^T(t) \phi(\tau)$ dentro da operação de integração nesta equação. Ao buscar o valor do vetor θ no instante t que minimiza a diferença $z(\tau) - \theta^T(t) \phi(\tau)$, o estamos fazendo considerando um intervalo de tempo e não mais apenas informações instantâneas como no método do gradiente. O segundo termo da função penaliza a estimativa inicial θ_0 . O gradiente desta função é:

$$\nabla J(\theta) = e^{-\beta t} Q_0 (\theta(t) - \theta_0) - \int_0^t e^{-\beta(t-\tau)} \frac{[z(\tau) - \theta^T(t) \phi(\tau)]}{m^2(\tau)} \phi(\tau) d\tau \quad (2.33)$$

E igualando a 0 se obtém:

$$\theta(t) = P(t) [e^{-\beta t} Q_0 \theta_0 - \int_0^t e^{-\beta(t-\tau)} \frac{[z(\tau) \phi(\tau)]}{m^2(\tau)} d\tau] \quad (2.34)$$

Com:

$$P^{-1} = [e^{-\beta t} Q_0 - \int_0^t e^{-\beta(t-\tau)} \frac{[\phi(\tau) \phi^T(\tau)]}{m^2(\tau)} d\tau] \quad (2.35)$$

Como $\phi \phi^T$ é semi definida positiva a cada instante e $Q_0 = Q_0^T > 0$ então $\exists P(t), \forall t$.

Fazendo uso da identidade:

$$\frac{dPP^{-1}}{dt} = \dot{P}P^{-1} + P\frac{dP^{-1}}{dt} = 0 \quad (2.36)$$

Podemos mostrar que $\dot{P}$ satisfaz a equação diferencial:

$$\dot{P} = \beta P - P \frac{\phi\phi^T}{m^2} P \quad (2.37)$$

Desta forma, o cálculo da inversa é evitado atualizando P a partir de uma equação diferencial. Usando o mesmo raciocínio para $\theta(t)$ e diferenciando em relação ao tempo usando o resultado obtido para P diretamente e $\varepsilon_1 m^2 = \theta^T \phi - z$, podemos obter:

$$\dot{\theta} = -P\varepsilon_1\phi \quad (2.38)$$

Este é o chamado método dos mínimos quadrados recursivo. Similarmente ao método do gradiente, temos uma dependência do erro ε_1 e do vetor regressor ϕ , no entanto substitui-se a matriz Γ estática por uma matriz P atualizada a cada instante.

2.1.3 Simetria Radial das Trajetórias de Múltiplos Modelos

Esta é uma contribuição que pretendemos fazer na dissertação.

Realimentação de Entrada e Saída

Seja uma planta linear e o conjunto todos os modelos de identificação tal que:

$$(\theta^* - \theta_i)^T (\theta^* - \theta_i) = 1 \quad (2.39)$$

Caracterizando o erro de saída de cada modelo e uma lei adaptativa integral como por exemplo a seguir, para o caso com realimentação apenas da entrada e da saída da planta:

$$e_{o,i} = \hat{z}_{p,i} - z_p \quad (2.40)$$

Com a lei integral:

$$\dot{\theta}_i = \Gamma e_{o,i} \phi \quad (2.41)$$

E dada a seguinte condição:

$$z_p(0) = \hat{z}_{p,i}(0) \quad (2.42)$$

Seja o conjunto de todos os modelos de identificação cujos parâmetros se localizam sobre uma reta θ_r que liga um modelo qualquer no instante t_0 $\theta_i(t_0)$ a θ^* :

$$\theta_r = \theta^* + k(\theta_i(t_0) - \theta^*) \quad (2.43)$$

É válido expressar o erro entre os filtrados da saída como:

$$e_{i,o} = \tilde{\theta}_i \phi = \|\tilde{\theta}_i\| \vec{\tilde{\theta}}^T \phi \quad (2.44)$$

Onde $\vec{\tilde{\theta}}$ expressa a direção de $\tilde{\theta}$ e $\|\tilde{\theta}\|$ sua norma, podemos expressar $\dot{\theta}_i$ como:

$$\dot{\theta}_i = \Gamma \|\tilde{\theta}\| \vec{\tilde{\theta}}^T \phi \quad (2.45)$$

E escrevendo $K_1 = \Gamma \vec{\tilde{\theta}}^T \phi$, a lei adaptativa pode ser expressa como:

$$\dot{\theta}_i = \|\tilde{\theta}_i\| K_1 \phi \quad (2.46)$$

$K_1 \phi$ é constante ao longo da reta θ_r , que pode ser escrita:

$$\theta_r = \theta^* + k \tilde{\theta}_i \quad (2.47)$$

Seja um modelo pertencente a θ_r :

$$\theta_j(t_0) = \theta^* + k(\theta_j(t_0) - \theta^*) \quad (2.48)$$

Usando a integração por passo fixo h :

$$\theta_j(t_0 + h) = \theta^* + k(\theta_j(t_0) + h \dot{\theta}_j - \theta^*) \quad (2.49)$$

Substituindo a expressão 2.46 em 2.49 temos:

$$\theta_j(t_0 + h) = \theta^* + k(\theta_j(t_0) + h \|\tilde{\theta}_j(t_0)\| K_1 \phi - \theta^*) \quad (2.50)$$

Que pode ser manipulada para ficar na forma:

$$\theta_j(t_0 + h) = \theta^* + k \tilde{\theta}_j(t_0) + kh \|\tilde{\theta}_j(t_0)\| K_1 \phi \quad (2.51)$$

Escolhamos valores diferentes para $\theta_j(t_0)$, começando por $k = 0$, com $\theta_j(t_0) = \theta^*$, neste caso:

$$\theta_j(t_0 + h) = \theta_j(t_0) = \theta^* \quad (2.52)$$

Para $k = k'$:

$$\theta_j(t_0 + h) = \theta_j(t_0) = \theta^* + k' \tilde{\theta}_j(t_0) + k' h K_1 \phi \quad (2.53)$$

Para $k = k''$:

$$\theta_j(t_0 + h) = \theta_j(t_0) = \theta^* + k'' \tilde{\theta}_j(t_0) + k'' h K_1 \phi \quad (2.54)$$

Podemos então escrever:

$$\tilde{\theta}'_i = \tilde{\theta}_j + h K_1 \phi \quad (2.55)$$

E portanto, para um instante posterior, existe uma reta θ_s , passando por θ^* , que contém

os pontos pertencentes a θ_r atualizados após uma iteração da integração usando o método de Euler:

$$\theta_s = \theta_r(t_0 + h) = \theta^* + k\tilde{\theta}'_i \quad (2.56)$$




Figura 2.1: Ilustração de uma iteração da Adaptação de dois modelos $\theta_{j,1}$ e $\theta_{j,2}$ pertencendo a uma mesma reta θ_r contendo θ^* no espaço de parâmetros, os modelos continuam pertencendo a uma reta θ_s contendo θ^*

Induzindo este mesmo raciocínio para os instantes posteriores, e expandindo-o para todas as retas que passam pelo ponto θ^* , chegamos a conclusão de que as trajetórias dos parâmetros de múltiplos modelos adaptados simultaneamente possuem simetria radial com θ^* como ponto focal. Uma consequência deste argumento é que caso θ^* pertença inicialmente à reta ligando dois modelos de identificação atualizados simultaneamente, θ^* pertencerá à reta para todo o tempo t .

2.2 Controle Adaptativo

2.2.1 Controle Adaptativo por Posicionamento de Polos

Sabemos, pelo princípio do modelo interno, que para que uma planta seja capaz de rastrear um determinado sinal ou rejeitar uma perturbação, é necessário que a estrutura da planta em malha direta contenha um polo capaz de gerar aquele sinal ou perturbação. De tal forma que, no design do controlador, se faz necessário introduzir um polinômio $Q_m(s)$ no denominador tal que a estrutura do controlador se torna:

$$C(s) = \frac{P(s)}{L(s)Q_m(s)} \quad (2.57)$$

Usando uma malha de realimentação unitária, chegamos a uma função de transferência tal que:

$$G_{mf}(s) = \frac{P(s)N_p(s)}{L(s)Q_m(s)D_p(s) + N_p(s)P(s)} \quad (2.58)$$

Uma estratégia explorada na literatura para garantir a estabilidade do controlador e o objetivo de rastreamento e rejeição da perturbação é a de escolher um polinômio $A^*(s)$ e resolver a equação diofantina da forma:

$$L(s)Q_m(s)D_p(s) + N_p(s)P(s) = A^*(s) \quad (2.59)$$

Com relação aos polinômios do numerador e denominador do controlador $C(s)$, que são $P(s)$ e $L(s)$, de forma que os polos da função de transferência em malha fechada correspondam aos polos de $A^*(s)$. Esta estratégia é conhecida como *Controle por Posicionamento de Polos*.

Porém desejamos realizar simultaneamente a estimação e controle. Desta forma escolhemos como estratégia de controle o posicionamento adaptativo de polos, que é predicado na resolução da mesma equação diofantina para o polinômio desejado A^* a cada iteração da simulação, com base nas estimativas dos polinômios do numerador e denominador da planta $\hat{N}_p(s)$ e $\hat{D}_p(s)$:

$$\hat{L}Q_m\hat{D}_p + \hat{P}\hat{N}_p = A^* \quad (2.60)$$

Fazendo $D(s) = \hat{D}_p(s)Q_m(s)$ e $N(s) = \hat{N}_p(s)$ a equação é resolvida através da montagem da matriz de Sylvester, tal que:

$$S_m = \begin{bmatrix} D_0 & D_1 & \dots & D_n & 0 & \dots & 0 \\ N_0 & N_1 & \dots & N_n & 0 & \dots & 0 \\ 0 & D_0 & \dots & D_{n-1} & D_n & \dots & 0 \\ 0 & N_0 & \dots & N_{n-1} & N_n & \dots & 0 \\ \dots & \dots & \dots & \dots & \dots & \dots & \dots \\ 0 & 0 & \dots & 0 & D_0 & \dots & D_n \\ 0 & 0 & \dots & 0 & N_0 & \dots & N_n \end{bmatrix}$$

Onde $D_0, \dots, D_n$ e $N_0, \dots, N_n$ são os coeficientes dos polinômios $D(s)$ e $N(s)$ respectivamente.

$$v = [L_0 \quad P_0 \quad L_1 \quad P_1 \quad \dots \quad L_m \quad P_m]$$

Onde $L_0, \dots, L_m(s)$ e $P_0, \dots, P_m$ são os coeficientes dos polinômios $L(s)$ e $P(s)$ respectivamente.

$$f = [F_0 \quad F_1 \quad \dots \quad F_n \quad F_{n+1} \quad \dots \quad F_{n+m}]$$

Onde $F_0, \dots, F_{n+m}$ são os coeficientes do polinômio $A^*(s)$ escolhido. De tal forma que

$$S_m^T v^T = f^T \quad (2.61)$$

E resolvendo para v obtemos a função de transferência $C(s)$ do controlador.

Tal que o sinal de controle realimentado é:

$$u_p = (\Lambda - \hat{L}Q_m) \frac{1}{\Lambda} u_p - \hat{P} \frac{1}{\Lambda} (y_p - r) \quad (2.62)$$

Onde $\Lambda(s)$ representa um polinômio com autovalores no semiplano esquerdo aberto. A medida que as estimativas $\hat{N}_p$ e $\hat{D}_p$ convergem, os parâmetros do controlador são atualizados e a função de transferência em malha fechada se aproxima de $A^*(s)$.

Prova de Estabilidade

2.2.2 Controle Adaptativo por Modelo de Referência

Seja um modelo virtual com mesmo grau e grau relativo da planta, de entrada r e saída y_m , criado para produzir uma referência do comportamento desejado para a planta, cuja função de transferência é:

$$M(s) = k_m \frac{N_m(s)}{D_m(s)} \quad (2.63)$$

Definindo o erro de saída:

$$e_o = y - y_m \quad (2.64)$$

O modelo é escolhido pelo projetista com a intenção de que a planta a ser controlada o acompanhe em sua dinâmica, assumindo que os sinais envolvidos são uniformemente limitados e contínuos por partes. Desta forma, o erro de saída deve tender a 0 a medida que o tempo t tende a infinito, com y conduzido até y_m por uma entrada de controle u apropriada. Para manter o polinômio do sistema em malha fechada de mesma ordem se torna necessário gerar filtros dos sinais de entrada e saída da planta para alimentar a malha de controle. Efetivamente se pretende cancelar os zeros da planta para substituí-los pelos zeros do modelo, tal que a função de transferência da planta em malha fechada contenha $N_p(s)$ tanto no denominador quanto no numerador, e portanto este método deve ser utilizado apenas para plantas de fase mínima, com zeros no semi plano esquerdo aberto:

$$\begin{aligned} \dot{v}_1 &= \Lambda v_1 + g u \\ \dot{v}_2 &= \Lambda v_2 + g y \end{aligned} \quad (2.65)$$

$v_1, v_2 \in R^{n-1}$, e o par (Λ, g) deve ser escolhido tal que $\det(sI - \Lambda) = N_m(s)$, e tal que:

$$(sI - \Lambda)^{-1}g = \frac{\gamma}{N_m(s)} [1 \quad s \quad \dots \quad s^{n-2}] \quad (2.66)$$

. Caso Λ seja colocado em forma canônica controlável $g = [0 \quad \dots \quad \gamma]$. A partir destes filtros criamos um sinal w :

$$w^T = [v_1 \quad y \quad v_2 \quad r] \quad (2.67)$$

e a lei de controle se torna:

$$u = \theta_c^T w \quad (2.68)$$

onde θ_c representa o vetor de parâmetros do controlador, caso os parâmetros corretos sejam escolhidos, temos

$$u = u^* = \theta_c^{*T} w \quad (2.69)$$

que garante que o comportamento da planta em malha fechada seja igual ao do modelo. O vetor de parâmetros ideal do controlador, θ_c^* , pode ser mapeado a partir do vetor de parâmetros verdadeiros da planta θ^* e dos coeficientes dos polinômios do modelo de referência $M(s)$. Para tanto vamos explicitar os polinômios da planta e do modelo como em (Lima Teixeira e Araujo):

$$W(s) = k_p \frac{N_p(s)}{D_p(s)}$$

$$N_p(s) = s^{n-1} + \sum_{i=1}^{n-1} \beta_i s^{n-1-i} \quad (2.70)$$

$$D_p(s) = s^n + \alpha_1 s^{n-1} + \sum_{i=1}^{n-1} \alpha_{i+1} s^{n-1-i}$$

Para a planta, e o modelo na forma:

$$M(s) = k_m \frac{N_m(s)}{D_m(s)}$$

$$N_m(s) = s^{n-1} + \sum_{i=1}^{n-1} \beta_{m,i} s^{n-1-i} \quad (2.71)$$

$$D_m(s) = s^n + \alpha_{m,1} s^{n-1} + \sum_{i=1}^{n-1} \alpha_{m,i+1} s^{n-1-i}$$

E podemos especificar, omitindo, por conveniência, a notação "chapéu" para denotar

que θ é uma estimativa dos parâmetros θ^* verdadeiros da planta:

$$\begin{aligned}\theta &= [b_{n-1} \ b_{n-2} \ \dots \ b_1 \ b_0 \ a_{n-1} \ a_{n-2} \ \dots \ a_1 \ a_0]^T \\ \theta &= [k_p \ \beta^T \ \alpha_1 \ \alpha^T]^T\end{aligned}\quad (2.72)$$

Com $\beta, \alpha \in R^{n-1}$, k_p, α_1 escalares, com $k_p = b_{n-1}$ e assim por diante. Utilizando um processo de estimação de parâmetros qualquer, tais como o Método do Gradiente, Método dos Mínimos Quadrados ou a Adaptação de Segundo Nível que é tema desta dissertação, podemos obter os valores das estimativas. E, como em (Cunha 2007), podemos calcular os parâmetros do controlador como:

$$\begin{aligned}\theta_{v1} &= \frac{\beta_m - \beta}{\gamma} \\ \theta_n &= \frac{\alpha_1 - \alpha_{m,1}}{k_p} \\ \theta_{v2} &= \frac{\alpha - \alpha_m + (\alpha_{m,1} - \alpha_1)\beta_m}{k_p \gamma} \\ \theta_{2n} &= \frac{km}{k_p}\end{aligned}\quad (2.73)$$

2.2.3 Controle Adaptativo por Modelo de Referência e Estrutura Variável

Novamente, seja um modelo virtual como em 2.63, criado tal que ao ser alimentado com uma referência r produza uma saída y_m , tal que possamos gerar o erro de saída como em 2.64. Usando toda a formulação descrita entre 2.63 e 2.73, o Controle Adaptativo Indireto por Modelo de Referência e Estrutura Variável (IVS-MRAC) substitui as leis adaptativas integrais, que produzem um transitório lento e oscilatório na planta, por leis chaveadas, tomando como base o projeto a partir de uma candidata a função de Lyapunov tal que os termos de sinal indefinido na análise da derivada da função sejam dominados por termos de sinal definido negativo. Esta abordagem apresenta uma série de vantagens em relação ao Controle Adaptativo com leis integrais, tais como a convergência do erro de saída e_o para zero em tempo finito, transitório rápido e pouco oscilatório e robustez a dinâmicas não modeladas e perturbações de entrada. No entanto, como um "trade-off" para que seja possível conseguir estas características, o controle por estrutura variável apresenta um sinal de controle chaveado de alta frequência e uma maior fragilidade frente ao ruído de medição na saída da planta. As leis chaveadas para os parâmetros da planta

são da forma:

$$\begin{aligned}
 \hat{k}_p &= k_{p,nom} - \bar{k}_p \operatorname{sgn}(e_o(\frac{\beta_m^T v_1}{\gamma} - u - \frac{\beta^T v_1}{\gamma})) \\
 \hat{\beta}_i &= -\bar{\beta}_i \operatorname{sgn}(e_o \frac{-v_{1,i}}{\gamma}), i = 1, \dots, n-1 \\
 \hat{\alpha}_1 &= -\bar{\alpha}_1 \operatorname{sgn}(e_o(y - \frac{\beta_m^T v_2}{\gamma})) \\
 \hat{\alpha}_i &= -\bar{\alpha}_i \operatorname{sgn}(e_o \frac{v_{2,i-1}}{\gamma}), i = 2, \dots, n
 \end{aligned} \tag{2.74}$$

Lembrando que o parâmetro γ vem da escolha feita em 2.66. Também é importante notar que estamos substituindo o valor das estimativas dos parâmetros da planta pelos valores gerados por estas leis chaveadas. De fato não há nenhum processo de estimação de parâmetros acontecendo aqui, porém como o IVS-MRAC é baseado no IMRAC comete-se o abuso de linguagem de nos referirmos aos valores gerados por estas leis chaveadas como se fossem estimativas dos parâmetros da planta.

As condições suficientes -mas não necessárias, tal que existe garantia sobre o comportamento do sistema caso sejam cumpridas, mas não existe, estritamente, garantia de um comportamento diverso caso não sejam- para o dimensionamento das amplitudes $\bar{k}_p, \bar{\beta}_i, \bar{\alpha}_1, \bar{\alpha}_i$ dos relés e obtenção do modo deslizante -onde $e_o \dot{e}_o < 0$, como em (citar)- são:

$$\begin{aligned}
 \bar{k}_p &> |k_p^* - k_{p,nom}|, \text{ com } k_{p,nom} > \bar{k}_p \\
 \bar{\beta}_i &> |\beta_i^*|, i = 1, \dots, n-1 \\
 \bar{\alpha}_1 &> |\alpha_1^*|, \\
 \bar{\alpha}_i &> |\alpha_i^*|, i = 2, \dots, n
 \end{aligned} \tag{2.75}$$

Usamos as estimativas dos parâmetros da planta diretamente em 2.73 para atualizar os valores dos parâmetros θ_c do controlador, que por conseguinte também se tornam chaveados.

Capítulo 3

Adaptação de Segundo Nível

3.1 Variáveis de Estado Acessíveis

3.1.1 Pertencimento do Vetor de Parâmetros da Planta à um Fecho Convexo de $2n+1$ modelos de identificação

Para um fecho convexo, delimitado por $2n+1$ modelos de identificação contendo cada um $2n$ parâmetros, denotado por uma matriz $\bar{\Theta}$:

$$\bar{\Theta} \in R^{2n \times (2n+1)} \quad (3.1)$$

Para especificar um ponto dentro ou na fronteira do fecho, pode-se realizar uma combinação linear convexa dos $2n+1$ modelos:

$$\theta_v = \alpha_1 \theta_1 + \dots + \alpha_{n+1} \theta_{2n+1} \quad (3.2)$$

Desde que estipulemos que:

$$0 \leq \alpha_i \leq 1 \quad (3.3)$$

$$\sum_{i=1}^{2n+1} \alpha_i = 1 \quad (3.4)$$

Para a seguinte lei adaptativa:

$$\dot{\theta}_1 = -e_1^T P b x_p(t) \quad (3.5)$$

3.5, realizando a atualização dos valores dos parâmetros usando o método de integração de Euler por passo fixo temos:

$$\theta_v(t_0 + h) = \theta_v(t_0) + h \dot{\theta}_v \quad (3.6)$$

Que pode ser expresso como:

$$\theta_v(t_0 + h) = \alpha_1(t_0) \theta_1(t_0) + \dots + \alpha_{2n+1}(t_0) \theta_{2n+1}(t_0) + h(-e_v^T P b x_p) \quad (3.7)$$

Caso os valores das variáveis de estado iniciais dos modelos de identificação sejam iguais é possível formar e_v como uma combinação linear dos erros dos modelos:

$$e_v(t_0) = \alpha_1(t_0)e_1(t_0) + \dots + \alpha_{2n+1}(t_0)e_{2n+1}(t_0) \quad (3.8)$$

E 3.7 fica na forma:

$$\begin{aligned} \theta_v(t_0 + h) &= \alpha_1(t_0)\theta_1(t_0) + \dots + \alpha_{2n+1}(t_0)\theta_{2n+1}(t_0) \\ &\quad + h(-(\alpha_1(t_0)e_1(t_0) + \dots + \alpha_{2n+1}(t_0)e_{2n+1}(t_0))TPbx_p) \end{aligned} \quad (3.9)$$

Pós-multiplicando por Pbx_p no segundo termo:

$$\begin{aligned} \theta_v(t_0 + h) &= \alpha_1(t_0)\theta_1(t_0) + \dots + \alpha_{2n+1}(t_0)\theta_{2n+1}(t_0) \\ &\quad + h(\alpha_1(t_0)\dot{\theta}_1(t_0) + \dots + \alpha_{2n+1}(t_0)\dot{\theta}_{2n+1}(t_0)) \end{aligned} \quad (3.10)$$

E portanto:

$$\theta_v(t + h) = \alpha_1(t_0)\theta_1(t_0 + h) + \dots + \alpha_{2n+1}(t_0)\theta_{2n+1}(t_0 + h) \quad (3.11)$$

O conjunto dos parâmetros $\alpha_i(t_0)$ usado para exprimir θ_v em função de uma combinação convexa dos parâmetros dos $2n + 1$ modelos é invariante entre iterações sucessivas da integração pelo Método de Euler. O mesmo conjunto de parâmetros $\alpha_i(t_0)$ mapeia $\theta_v(t_0)$ a partir dos parâmetros $\theta_i(t_0)$ e também mapeia $\theta_v(t_0 + h)$ a partir dos parâmetros $\theta_i(t_0 + h)$. Assim, caso θ^* esteja localizado dentro do fecho ou em sua fronteira podemos utilizar:

$$\theta_v = \theta^* \quad (3.12)$$

$$e^* = \alpha_1 e_1 + \dots + \alpha_{n+1} e_{n+1} = x_p - x_p = \vec{0} \quad (3.13)$$

E portanto:

$$\begin{aligned} \theta^*(t_0 + h) &= \theta^*(t_0) \\ &= \alpha_1\theta_1(t_0) + \dots + \alpha_{2n+1}\theta_{2n+1}(t_0) \\ &= \alpha_1\theta_1(t_0 + h) + \dots + \alpha_{n+1}\theta_{2n+1}(t_0 + h) \end{aligned} \quad (3.14)$$

Como α é invariante temos que θ^* pode ser mapeado univocamente a partir dele e do conjunto de $2n + 1$ modelos de identificação, mesmo que os valores dos modelos de identificação estejam sendo, por si mesmos, adaptados por leis integrais. Chamamos α que mapeia θ^* como α^* . Portanto o problema da estimação dos parâmetros verdadeiros θ_p^* da planta pode ser transformado no problema da estimação do vetor α^* dos coeficientes da combinação convexa do modelo. Somos levados ao uso de um modelo virtual produzido a partir da combinação convexa para determinar o sinal de controle da planta. Uma prova mais rigorosa das propriedades discutidas pode ser encontrada em (Han & Narendra 2012).

Múltiplos Modelos

Sejam os $n + 1$ modelos de identificação, como em (Narendra et al. 2014):

$$\Sigma_i : \dot{x}_i = A_m x_i(t) + [A_i(t) - A_m]x_p(t) + bu(t) \quad (3.15)$$

onde θ_i^T é a última linha de cada matriz A_i e θ_i pode ser fixo ou adaptado segundo as leis convencionais.

Sabemos que, se θ_p se encontra no fecho convexo delimitado por pelo menos $n + 1$ modelos, existem $0 \leq \alpha_i \leq 1$, e $\sum_{i=1}^{n+1} \alpha_i = 1$ tal que:

$$\sum_{i=1}^{n+1} \alpha_i \theta_i(t_0) = \theta_p \quad (3.16)$$

Definimos o erro entre os modelos e a planta:

$$e_i(t) = x_i(t) - x_p(t) \quad (3.17)$$

e o erro entre os parâmetros da planta e dos modelos:

$$\tilde{\theta}_i(t) = \theta_i(t) - \theta_p \quad (3.18)$$

Então segue que:

$$\sum_{i=1}^{n+1} \alpha_i \tilde{\theta}_i(t_0) = \theta_p - \sum_{i=1}^{n+1} \alpha_i \theta_i(t_0) = 0 \quad (3.19)$$

Destas equações, temos que:

$$\sum_{i=1}^{n+1} \alpha_i e_i(t) = 0 \quad (3.20)$$

E, em forma matricial:

$$\bar{\Theta}(t) \bar{\alpha} = \theta_p \quad (3.21)$$

$$\bar{E}(t) \bar{\alpha} = 0 \quad (3.22)$$

onde $\bar{\Theta}$ e $\bar{E}$ são matrizes $n \times (n + 1)$.

Podemos expressar:

$$\Theta(t) \alpha = \theta_p - \theta_{n+1} \quad (3.23)$$

$$E(t) \alpha = -e_{n+1}(t) \quad (3.24)$$

onde $\Theta(t)$ e $E(t)$ são matrizes $n \times n$, onde cada vetor coluna é $\theta_i(t) - \theta_{n+1}(t)$ e $e_i(t) - e_{n+1}(t)$, respectivamente, e $\alpha^T = [\alpha_1, \dots, \alpha_n]$. A partir de (18), podemos obter uma lei

adaptativa para α :

$$\dot{\hat{\alpha}} = -E^T(t)E(t)\hat{\alpha} - E^T(t)e_{n+1}(t) \quad (3.25)$$

Chamamos esta lei integral de Adaptação de Segundo Nível. Notamos que a multiplicação da equação no lado direito por um escalar não altera o ponto de equilíbrio. E definindo o erro entre a estimativa $\hat{\alpha}$ e seu valor correto α como $\tilde{\alpha} = \hat{\alpha}(t) - \alpha$, temos a equação:

$$\dot{\tilde{\alpha}} = -E^T(t)E(t)\tilde{\alpha} \quad (3.26)$$

Alternativamente, α pode ser calculado algebricamente por:

$$\alpha = E^{-1}(t)e_{n+1}(t) \quad (3.27)$$

onde e_{n+1} é o erro do modelo (n+1):

$$e_{n+1} = x_{n+1} - x_p \quad (3.28)$$

3.2 Realimentação de Entrada e Saída

O caso de realimentação de entrada e saída, expresso nesta forma usando modelos de identificação paralelo como a seguir é uma contribuição que pretendemos fazer na dissertação.

3.2.1 Pertencimento do Vetor de Parâmetros da Planta à um Fecho Convexo de $2n+1$ modelos de identificação

Usando agora a parametrização da planta e modelos de identificação das equações 2.21 e 2.22, com o erro de saída 2.26 e a lei integral 2.31 refazemos o argumento apresentado em 3.1.1 para o caso da estimação de parâmetros de uma planta onde apenas a entrada e saída da planta estão disponíveis para medição. Partindo de 3.7 escrevemos:

$$\theta_v(t_0 + h) = \theta_v(t_0) + h\dot{\theta}_v = \theta_v(t_0) + h(-\Gamma \epsilon_v \phi) \quad (3.29)$$

E expressando a ϵ_v como uma combinação convexa temos:

$$\theta_v(t_0 + h) = \theta_v(t_0) + h\dot{\theta}_v = \theta_v(t_0) + h(-\Gamma(\sum_{i=1}^{2n+1} e_i \alpha_i) \phi) \quad (3.30)$$

Que pode ser expressa exatamente como 3.11. Portanto o argumento se sustenta também para a parametrização adotada quando geramos um filtrado da saída da planta tal que seja possível criar um vetor regressor ϕ de forma e estimar os parâmetros. Pelo mesmo argumento aplicado em 3.1.1, chegamos a conclusão de que α^* é invariante entre iterações sucessivas da integração pelo Método de Euler.

3.2.2 Múltiplos Modelos

Seja o conjunto de modelos de identificação da forma:

$$\Sigma_i : \hat{z}_i = \theta_i^T \phi \quad (3.31)$$

Definimos o erro entre a saída dos modelos e o filtrado da saída da planta z :

$$e_i = \hat{z}_i - z \quad (3.32)$$

Partindo da equação do erro paramétrico 3.18, podemos redefinir a matriz $E(t)$ do caso com variáveis de estado da planta acessíveis para um vetor linha tal que:

$$E(t) = [\hat{z}_1 - \hat{z}_{2n+1} \quad \hat{z}_2 - \hat{z}_{2n+1} \quad \dots \quad \hat{z}_{2n} - \hat{z}_{2n+1}] \quad (3.33)$$

E somos levados diretamente à 3.25.

3.3 Excitação dos Modos da Planta

3.3.1 Excitação dos modos da planta e conceito de Persistência

Seguindo (Boyd & Sastry 1986, Chowdhary et al. 2013) Nos conceitos discutidos anteriormente, a convergência dos parâmetros para seus valores corretos só é garantida caso a lei adaptativa integral $\hat{\theta}$ tenha a possibilidade, ao longo do tempo, de atualizar θ na direção do parâmetro correto θ^* . Esta garantia não é possível se por exemplo a planta se encontra em regime permanente com referência degrau pois haverá apenas uma direção na qual o parâmetro pode ser adaptado. Neste caso a convergência só se dá se θ^* se encontrar exatamente na direção correta. A lei adaptativa integral, no caso do método do gradiente e mínimos quadrados, avalia o vetor regressor para tomar uma decisão, que tem dois aspectos principais:

- 1 Em que sentido do vetor regressor o parâmetro deve ser atualizado
- 2 Qual deve ser o módulo da atualização

Esta dependência da lei adaptativa integral no vetor regressor para estimar o vetor de parâmetros levou pesquisadores na área do controle adaptativo e estimação de parâmetros a designar uma qualidade do vetor regressor que habilite a lei adaptativa a varrer todo o espaço de parâmetros. Várias definições desta propriedade, a Persistência de Excitação, e exemplos de sinais que a possuem existem na literatura [referencias]. Usamos a seguinte definição para ela:

Um vetor de sinais limitado $\phi(t)$ é persistentemente excitante se e somente se para todo tempo $t > t_0$ existe um intervalo $T > 0$ e $\gamma > 0$ tal que:

$$\int_t^{t+T} \phi(t) \phi^T \geq \gamma I \quad (3.34)$$

Esta propriedade costuma apresentar várias limitações práticas que observamos na implementação. As duas principais sendo as seguintes: 1) Para tornar o vetor regressor da planta PE, normalmente, o sinal de entrada usado é um sinal rico em frequências de ordem igual a da planta, o que produz uma saída igualmente rica em frequências, isto é, oscilatória, o que pode ser indesejável. 2) É necessário ter algum conhecimento prévio da planta pois um sinal rico em frequências que são excessivamente atenuadas pela planta não será capaz de tornar o vetor regressor suficientemente excitante, tornando a adaptação excessivamente lenta. Em outras palavras, não temos noção clara da ordem de grandeza do nível de excitação γ produzido por um sinal de entrada PE a menos que tenhamos conhecimento prévio sobre os parâmetros da planta ou pelo menos sobre a região em que estão situados, o que é geralmente o caso. Mesmo assim um sinal de entrada que tenha garantia de ser PE pode se mostrar custoso e em muitos casos é completamente indesejável.

Começamos definindo e discutindo a Persistência de Excitação, passaremos agora a um conceito mais básico:

Um vetor de sinais limitado $\phi(t)$ é excitante ao longo de um intervalo $[t, t + T]$, $T > 0$ e $t > t_0$ se existe $\gamma > 0$ tal que:

$$\int_t^{t+T} \phi(\tau) \phi^T(\tau) d\tau \geq \gamma I \quad (3.35)$$

Tendo esta definição em mente, faremos a análise de uma integral similar para o caso monovariável em que $z_i = \theta_i^T \phi$ e os parâmetros θ_i são fixos, assumindo que existe excitação dos modos da planta no intervalo T:

$$\int_t^{t+T} E^T(\tau) E(\tau) d\tau = \int_t^{t+T} \begin{bmatrix} e_1 - e_{n+1} & \dots & e_n - e_{n+1} \end{bmatrix}^T \begin{bmatrix} e_1 - e_{n+1} & \dots & e_n - e_{n+1} \end{bmatrix} d\tau$$

Como $e_i = z_i - z_p$, pode ser expressa como:

$$\int_t^{t+T} E^T(\tau) E(\tau) d\tau = \int_t^{t+T} \begin{bmatrix} z_1 - z_{n+1} & \dots & z_n - z_{n+1} \end{bmatrix}^T \begin{bmatrix} z_1 - z_{n+1} & \dots & z_n - z_{n+1} \end{bmatrix} d\tau$$

Definindo $\tilde{\theta}_{vi} = \theta_i - \theta_{n+1}$, podemos realizar o seguinte raciocínio:

$$\begin{aligned}
\int_t^{t+T} E^T(\tau)E(\tau)d\tau &= \int_t^{t+T} [z_1 - z_{n+1} \quad \dots \quad z_n - z_{n+1}]^T [z_1 - z_{n+1} \quad \dots \quad z_n - z_{n+1}] d\tau \\
\int_t^{t+T} E^T(\tau)E(\tau)d\tau &= \int_t^{t+T} [\theta_1^T \phi - \theta_{n+1}^T \phi \quad \dots \quad \theta_n^T \phi - \theta_{n+1}^T \phi]^T [\theta_1^T \phi - \theta_{n+1}^T \phi \quad \dots \quad \theta_n^T \phi - \theta_{n+1}^T \phi] d\tau \\
\int_t^{t+T} E^T(\tau)E(\tau)d\tau &= \int_t^{t+T} [\tilde{\theta}_{v1}^T \phi \quad \dots \quad \tilde{\theta}_{vn}^T \phi]^T [\tilde{\theta}_{v1}^T \phi \quad \dots \quad \tilde{\theta}_{vn}^T \phi] d\tau
\end{aligned}$$

Reorganizando:

$$\int_t^{t+T} E^T(\tau)E(\tau)d\tau = \int_t^{t+T} \begin{bmatrix} \tilde{\theta}_{v1}^T \phi \phi^T \tilde{\theta}_{v1} & \dots & \tilde{\theta}_{vn}^T \phi \phi^T \tilde{\theta}_{vn} \\ \dots & \dots & \dots \\ \tilde{\theta}_{v1}^T \phi \phi^T \tilde{\theta}_{vn} & \dots & \tilde{\theta}_{vn}^T \phi \phi^T \tilde{\theta}_{vn} \end{bmatrix} d\tau \quad (3.36)$$

Podemos realizar a integração da seguinte forma, pois os modelos são fixos:

$$\begin{aligned}
\int_t^{t+T} E^T(\tau)E(\tau)d\tau &= \\
&\begin{bmatrix} \tilde{\theta}_{v1}^T [\int_t^{t+T} \phi \phi^T d\tau] \tilde{\theta}_{v1} & \dots & \tilde{\theta}_{vn}^T [\int_t^{t+T} \phi \phi^T d\tau] \tilde{\theta}_{vn} \\ \dots & \dots & \dots \\ \tilde{\theta}_{v1}^T [\int_t^{t+T} \phi \phi^T d\tau] \tilde{\theta}_{vn} & \dots & \tilde{\theta}_{vn}^T [\int_t^{t+T} \phi \phi^T d\tau] \tilde{\theta}_{vn} \end{bmatrix} \quad (3.37)
\end{aligned}$$

Podemos substituir $\int_t^{t+T} \phi \phi^T d\tau$ pelo ínfimo αI , tornando o lado direito da equação menor, pois sabemos que $E^T(t)E(t) \geq 0, \forall t$, portanto escrevemos:

$$\int_t^{t+T} E^T(\tau)E(\tau)d\tau > \alpha \begin{bmatrix} \tilde{\theta}_{v1}^T \tilde{\theta}_{v1} & \dots & \tilde{\theta}_{vn}^T \tilde{\theta}_{vn} \\ \dots & \dots & \dots \\ \tilde{\theta}_{v1}^T \tilde{\theta}_{vn} & \dots & \tilde{\theta}_{vn}^T \tilde{\theta}_{vn} \end{bmatrix}$$

E como assumimos a existência de um fecho convexo dos parâmetros de identificação, é necessariamente verdade que dois modelos de identificação não ocupem a mesma posição no espaço de parâmetros, cada $\tilde{\theta}_{vi}$ contém pelo menos um elemento não-nulo e portanto:

$$\begin{bmatrix} \tilde{\theta}_{v1}^T \tilde{\theta}_{v1} & \dots & \tilde{\theta}_{vn}^T \tilde{\theta}_{vn} \\ \dots & \dots & \dots \\ \tilde{\theta}_{v1}^T \tilde{\theta}_{vn} & \dots & \tilde{\theta}_{vn}^T \tilde{\theta}_{vn} \end{bmatrix} > \beta I$$

Com $\beta > 0$. Assim, substituindo a matriz pelo seu ínfimo chegamos a:

$$\int_t^{t+T} E^T(\tau)E(\tau)d\tau > \alpha' I \quad (3.38)$$

Com $\alpha' > 0$, indicando que, se a integral de $E^T(t)E(t)$ ao longo de um certo período T cumpre esta condição, a mesma condição deve ser cumprida para a integral da matriz de covariância $\phi \phi^T$ e portanto houve excitação dos modos da planta cujos parâmetros estão

contidos no fecho convexo formado pelos parâmetros dos modelos de identificação.

Esta propriedade é mais amena à implementação. De fato, para uma planta SISO LIT partindo do repouso, qualquer degrau não nulo é excitante durante o transitório da planta. Assim como a resposta ao impulso é uma representação unívoca do comportamento observável e controlável da planta, intuimos que seja possível estimar os parâmetros verdadeiros observando o vetor regressor por um tempo finito partindo da introdução de uma referência ou entrada excitante.

3.3.2 Desligamento do Sinal Persistentemente Excitante

Como visto anteriormente, para garantir a convergência dos parâmetros, tanto no controle adaptativo convencional quanto na adaptação de segundo nível, é necessária na entrada da planta a presença de um sinal persistentemente excitante, como por exemplo um sinal rico em frequências, de forma que seja garantido um certo nível de excitação da planta. Para cada dois parâmetros a serem estimados, é necessária uma senoide numa frequência capaz de excitar a planta. No entanto, a introdução de um sinal senoidal em uma planta linear produz uma saída com essa mesma característica. Desejamos eliminar este sinal quando o mesmo não for mais necessário.

Definimos a figura de mérito η como em (Gushiken & Araujo 2016):

$$\eta = q \frac{\dot{\hat{\alpha}}^T \dot{\hat{\alpha}}}{1 + q \dot{\hat{\alpha}}^T \dot{\hat{\alpha}}} \quad (3.39)$$

onde $q > 0$ é um escalar, de forma que, para $\dot{\hat{\alpha}} \uparrow$ grande tenhamos o valor de $\eta \rightarrow 1$ e quando $\dot{\hat{\alpha}} \downarrow$, $\eta \rightarrow 0$.

Introduzimos o seguinte sinal de referência:

$$r(t) = \begin{cases} r_1(t), & \text{se } \eta < m \\ r_2(t), & \eta \geq m \end{cases}, \quad (3.40)$$

onde

$$\dot{r}_1(t) = v * (-r(t) + c) \quad (3.41)$$

$$r_2(t) = c + l \sum_{i=1}^{\text{ceil}(n/2)} \sin(w_i t) \quad (3.42)$$

As constantes c, l, m, w_i, v são escolhidas pelo projetista com $m, l \in]0, 1[$, $v, w_i > 0$. $r_2(t)$ é rico em frequências em relação a uma planta de ordem n . A função $\text{ceil}(n/2)$ tem valor $n/2$ quando n é par e valor $(n/2 + 1/2)$ quando n é ímpar. Este sinal foi uma forma heurística de extrair as informações da planta mantendo o valor de r em regime permanente uma constante.

3.4 Projeção

3.4.1 Projeção Retangular

Um detalhe importante na adaptação de $\hat{\alpha}$, é que a equação 3.25 não garante que $0 \leq \hat{\alpha}_i \leq 1$ e, desta forma, é necessário implementar projeção destes parâmetros, já que $\hat{\alpha}$ deve se manter no fecho convexo. Como a região em que $\hat{\alpha}$ se encontra é retangular para os parâmetros $i = 1, \dots, n$, implementamos as seguintes modificações no algoritmo:

$$\dot{\hat{\alpha}}_i = \begin{cases} 0, & \text{se } \hat{\alpha}_i \geq 1 \text{ e } \dot{\hat{\alpha}}_i > 0 \\ & \text{ou } \hat{\alpha}_i \leq 0 \text{ e } \dot{\hat{\alpha}}_i < 0 \\ \dot{\hat{\alpha}}_i, & \text{caso contrário} \end{cases} \quad (3.43)$$

e como $1 - \sum_{i=1}^n \hat{\alpha}_i = \hat{\alpha}_{n+1}$, e $-\sum_{i=1}^n \dot{\hat{\alpha}}_i = \dot{\hat{\alpha}}_{n+1}$:

$$\dot{\hat{\alpha}}_i = \begin{cases} 0, & \text{se } \hat{\alpha}_{n+1} \geq 1 \text{ e } \dot{\hat{\alpha}}_{n+1} > 0 \\ & \text{ou } \hat{\alpha}_{n+1} \leq 0 \text{ e } \dot{\hat{\alpha}}_{n+1} < 0 \\ & \text{e } \text{sgn}(\dot{\hat{\alpha}}_{n+1}) = \text{sgn}(\dot{\hat{\alpha}}_i) \\ \dot{\hat{\alpha}}_i, & \text{caso contrário} \end{cases} \quad (3.44)$$

3.4.2 Projeção dos numa área de com fronteira convexa e suave.

Seja:

$$\hat{\theta}_p = \bar{\Theta}\alpha \quad (3.45)$$

o modelo virtual criado a partir de uma combinação convexa de $n+1$ modelos de identificação. Tal que $\bar{\Theta} \in R^{(n+1) \times n}$ e $\alpha \in R^{n+1}$ e $\hat{\theta}_p \in R^n$

Se $g(\theta)$ delimita uma região suave e convexa dentro da qual estão contidos os parâmetros da planta então a escolha dos parâmetros iniciais dos modelos de identificação (vértices do fecho convexo inicial) na adaptação de segundo nível implica no seguinte problema:

Como utilizar toda a informação disponível sobre a região de incerteza $g(\theta)$? Em outras palavras, como escolher os parâmetros dos modelos de identificação iniciais de forma que o fecho convexo no espaço de parâmetros englobe a fronteira $g(\theta)$ com o melhor ajuste possível?

Um fecho convexo delimitado por um número finito de vértices não tem uma fronteira suave e portanto é possível apenas minimizar o volume de fecho convexo "desperdiçado" com a escolha dos vértices. Desta forma nos propomos a criar uma lei de projeção para o vetor α de forma que, na fronteira de $g(\theta)$, α se mantenha na região de incerteza conhecida.

Assim temos um problema de projeção dos parâmetros α da adaptação de segundo nível onde seguimos os argumentos padrão para a projeção: $\dot{\alpha}$ permanece inalterado quando α se encontra no interior da região delimitada pelo conjunto Φ ou na fronteira com tendência a entrar e é projetado quando α se encontra na fronteira com tendência a sair.

Definimos uma região elipsóide em relação ao vetor θ , centrada no ponto θ_c :

$$g(\theta) = (\theta - \theta_c)^T P (\theta - \theta_c) - M^2 \quad (3.46)$$

onde $\theta \in R^n$, $\theta_c \in R^n$, $P = P^T \in R^{n \times n}$ e M é um escalar. O interior do elipsóide é caracterizado por $g(\theta) < 0$ e sua fronteira por $g(\theta) = 0$. Denotamos o interior do elipsóide pela região S e sua fronteira por $\delta(S)$.

Fazendo uma mudança de coordenadas para α , obtemos diretamente outro elipsóide:

$$g(\alpha) = (\bar{\Theta}\alpha - \theta_c)^T P (\bar{\Theta}\alpha - \theta_c) \quad (3.47)$$

o gradiente deste elipsóide é dado por:

$$\nabla g(\alpha) = 2\bar{\Theta}^T P \bar{\Theta}\alpha - 2\bar{\Theta}^T P \theta_c \quad (3.48)$$

Seja a lei adaptativa para o modelo virtual usada na adaptação de segundo nível:

$$\dot{\alpha} = -E^T(t)E(t)\alpha - E^T(t)e_{n+1}(t) \quad (3.49)$$

Usando as definições anteriores estabelecemos a seguinte lei com projeção

$$\dot{\alpha} = \begin{cases} \dot{\alpha}, & \text{se } \alpha \in S \text{ ou } (\alpha \in \delta(S) \text{ e } \dot{\alpha}^T \nabla g(\alpha) < 0) \\ Pr(\dot{\alpha}), & \text{caso contrário} \end{cases} \quad (3.50)$$

Onde $Pr(\dot{\alpha})$ é obtido extraindo a componente do vetor na mesma direção do gradiente:

$$Pr(\dot{\alpha}) = \dot{\alpha} - \nabla g^T \dot{\alpha} \nabla g (\nabla g^T \nabla g)^{-1} \quad (3.51)$$

Finalmente, temos o problema descrito no apêndice B do livro do Ioannou, onde é possível, com essa lei de projeção para um elipsóide, que o vetor resultante da iteração seguinte na simulação esteja fora da região de incerteza definida pelo elipsóide. Desta forma, fazemos o seguinte raciocínio: Se um vetor se encontra próximo à fronteira de um dado elipsóide, trazer o vetor até a fronteira é apenas uma questão de andar na direção apropriada do gradiente:

$$\alpha_{k+1}^{ajustado} = \alpha_{k+1} - L \nabla g \quad (3.52)$$

desta forma resolvemos a seguinte equação de segundo grau no escalar L , caso $g(\alpha_{k+1}) > 0$.

$$(\bar{\Theta}(\alpha - L \nabla g) - \theta_c)^T P (\bar{\Theta}(\alpha - L \nabla g) - \theta_c) - M^2 = 0 \quad (3.53)$$

de onde obtemos os coeficientes a, b, c da equação de segundo grau em L

$aL^2 + bL + c = 0$, onde:

$$a = \nabla g^T \bar{\Theta} P \bar{\Theta} \nabla g \quad (3.54)$$

e

$$b = -\alpha^T \bar{\Theta}^T P \bar{\Theta} \nabla g - \nabla g^T \bar{\Theta}^T P \bar{\Theta} \alpha + \nabla g^T \bar{\Theta}^T P \theta_c + \theta_c^T P \bar{\Theta} \nabla g \quad (3.55)$$

e finalmente:

$$c = \alpha^T \bar{\Theta}^T P \bar{\Theta} \alpha - \alpha^T \bar{\Theta}^T P \theta_c - \theta_c^T P \theta_c - M^2 \quad (3.56)$$

tal que:

$$L_{1,2} = (-b \pm \sqrt{b^2 - 4ac}) / 2a \quad (3.57)$$

e $L = \min(L_1, L_2)$

Aplicando esta lei de projeção, garantimos que α pertence à região de incerteza definida pelo elipsóide em $g(\alpha)$. Partindo deste argumento para uma única região, é possível expandir o raciocínio para a união de múltiplos elipsóides definidos por uma série de funções $g_i(\theta)$, de forma que é possível "desenhar" uma quantidade maior de regiões de incerteza de parâmetros.

3.5 Estabilidade

3.5.1 Estabilidade do Estimador para Adaptação de Segundo Nível sem modificações

Utilizando a seguinte candidata a função de Lyapunov:

$$V(\tilde{\alpha}) = \alpha^T \alpha \quad (3.58)$$

Derivando, e tendo em mente que $\hat{\alpha} = \tilde{\alpha} + \alpha^*$:

$$\begin{aligned} \dot{V}(\tilde{\alpha}) &= 2\dot{\tilde{\alpha}}^T \alpha \\ \dot{V}(\tilde{\alpha}) &= 2(-E^T E \hat{\alpha} - E^T e_{n+1})^T \tilde{\alpha} \\ \dot{V}(\tilde{\alpha}) &= 2(-E^T E (\tilde{\alpha} + \alpha^*) - E^T e_{n+1})^T \tilde{\alpha} \\ \dot{V}(\tilde{\alpha}) &= 2(-E^T E \tilde{\alpha})^T \tilde{\alpha} \\ \dot{V}(\tilde{\alpha}) &= -2\tilde{\alpha}^T E^T E \tilde{\alpha} \leq 0 \end{aligned}$$

Portanto, como o posto de $E^T(t)E(t)$ pode não ser cheio, $\dot{V}$ é semi-definida negativa, indicando que a energia do erro paramétrico $\tilde{\alpha}$ não cresce. A equação 3.25 é adequada para estimar α^* , com garantia de convergência dos parâmetros para seus valores corretos

caso o sinal de referência ou o sinal de entrada tenham a característica de persistência de excitação, que tornará o posto de $E^T(t)E(t)$ cheio.

3.5.2 Estabilidade do Estimador no caso discreto para Adaptação de Segundo Nível modificada por um ganho escalar

Caso modifiquemos 3.25 introduzindo um ganho γ , teremos a seguinte equação:

$$\dot{\hat{\alpha}} = -\gamma E^T(t)E(t)\hat{\alpha} - \gamma E^T(t)e_{n+1} \quad (3.59)$$

Passemos agora para um raciocínio em tempo discreto, que inevitavelmente será aquele usado nas simulações, apesar de nos esforçarmos para reproduzir condições contínuas com passo de integração pequeno:

$$\hat{\alpha}(k+1) = \hat{\alpha}(k) - h\gamma E^T(k)E(k)\hat{\alpha}(k) - h\gamma E^T(k)e_{n+1}(k) \quad (3.60)$$

Onde h é o passo de integração pelo método de Euler. Usando a mesma candidata a função de Lyapunov obtemos:

$$\begin{aligned} \Delta V(\tilde{\alpha}, k+1) &= V(\tilde{\alpha}, k+1) - V(\tilde{\alpha}, k) \\ \Delta V(\tilde{\alpha}, k+1) &= \tilde{\alpha}^T(k+1)\tilde{\alpha}(k+1) - \tilde{\alpha}^T(k)\tilde{\alpha}(k) \\ \Delta V(\tilde{\alpha}, k+1) &= (\tilde{\alpha}(k) - h\gamma E^T(k)E(k)\hat{\alpha}(k) - h\gamma E^T(k)e_{n+1}(k))^T (\tilde{\alpha}(k) - \\ &\quad h\gamma E^T(k)E(k)\hat{\alpha}(k) - h\gamma E^T(k)e_{n+1}(k)) - \tilde{\alpha}^T(k)\tilde{\alpha}(k) \\ \hat{\alpha} &= \tilde{\alpha} + \alpha^* \\ \Delta V(\tilde{\alpha}, k+1) &= (\tilde{\alpha}(k) - h\gamma E^T(k)E(k)\tilde{\alpha}(k))^T (\tilde{\alpha}(k) - h\gamma E^T(k)E(k)\tilde{\alpha}(k)) - \tilde{\alpha}^T(k)\tilde{\alpha}(k) \\ \Delta V(\tilde{\alpha}, k+1) &= (\tilde{\alpha}(k)^T - h\gamma \tilde{\alpha}^T(k)E^T(k)E(k))(\tilde{\alpha}(k) - h\gamma E^T(k)E(k)\tilde{\alpha}(k)) - \tilde{\alpha}^T(k)\tilde{\alpha}(k) \\ \Delta V(\tilde{\alpha}, k+1) &= \tilde{\alpha}(k)^T \tilde{\alpha}(k) - 2h\gamma \tilde{\alpha}^T(k)E^T(k)E(k)\tilde{\alpha}(k) + \\ &\quad h^2\gamma^2 \tilde{\alpha}^T(k)E^T(k)E(k)E^T(k)E(k)\tilde{\alpha}(k) - \tilde{\alpha}(k)^T \tilde{\alpha}(k) \\ \Delta V(\tilde{\alpha}, k+1) &= -2h\gamma \tilde{\alpha}^T(k)E^T(k)E(k)\tilde{\alpha}(k) + h^2\gamma^2 \tilde{\alpha}^T(k)E^T(k)E(k)E^T(k)E(k)\tilde{\alpha}(k) \end{aligned}$$

Notamos o aparecimento de um termo positivo neste caso, correspondente ao fato de que a adaptação em tempo discreto é sempre uma aproximação, devemos portanto tratar de escolher γ tal que seja possível garantir $\Delta V \leq 0$, decompomos $E^T E$ na forma de seus autovalores e autovetores:

$$E^T E = X^{-1}DX \quad (3.61)$$

E obtemos:

$$\Delta V(\tilde{\alpha}, k+1) = h\gamma \tilde{\alpha}^T X^{-1}(-2D + h\gamma D^2)X\tilde{\alpha} \quad (3.62)$$

Assim, γ deve ser escolhido de forma que a matriz $(-2D + h\gamma D^2)$ seja definida ou

semi-definida negativa, e para tanto:

$$\gamma \leq 1/(\lambda_{\max}(E^T E)h) \quad (3.63)$$

E, de fato, podemos escolher $\gamma = 1/(2\lambda_{\max}(E^T E)h)$ de forma a minimizar ΔV , maximizando seu módulo.

3.5.3 Estabilidade do Estimador no caso discreto para Adaptação de Segundo Nível modificada com Matriz de Ganhos P

Note-se que 3.24 permite a inversão de $E(t)$ para o cálculo de α diretamente caso a matriz seja não-singular, o que se traduz na existência de um nível de excitação na planta e nos modelos de identificação, porém isto só levará aos parâmetros verdadeiros num caso ideal onde não existem distúrbios na entrada ou saída da planta ou ruídos de medição dos sinais. Prosseguimos ao seguinte raciocínio: Modificando 3.25 com a introdução de uma matriz $P = P^T > 0$, temos:

$$\dot{\hat{\alpha}} = -PE^T E \hat{\alpha} - PE^T e_{n+1} \quad (3.64)$$

Que leva a um desenvolvimento similar a 3.60, substituindo γ por P :

$$\hat{\alpha}(k+1) = \hat{\alpha}(k) - hPE^T(k)E(k)\hat{\alpha}(k) - hPE^T(k)e_{n+1}(k) \quad (3.65)$$

Usando 3.58 como candidata temos:

$$\Delta V(\tilde{\alpha}, k+1) = V(\tilde{\alpha}, k+1) - V(\tilde{\alpha}, k)$$

$$\Delta V(\tilde{\alpha}, k+1) = \tilde{\alpha}^T(k+1)\tilde{\alpha}(k+1) - \tilde{\alpha}^T(k)\tilde{\alpha}(k)$$

$$\Delta V(\tilde{\alpha}, k+1) = (\tilde{\alpha}(k) - hPE^T(k)E(k)\hat{\alpha}(k) - hPE^T(k)e_{n+1}(k))^T(\tilde{\alpha}(k) - hPE^T(k)E(k)\hat{\alpha}(k) - hPE^T(k)e_{n+1}(k)) - \tilde{\alpha}^T(k)\tilde{\alpha}(k)$$

$$\hat{\alpha} = \tilde{\alpha} + \alpha^*$$

$$\Delta V(\tilde{\alpha}, k+1) = (\tilde{\alpha}(k) - hPE^T(k)E(k)\tilde{\alpha}(k))^T(\tilde{\alpha}(k) - hPE^T(k)E(k)\tilde{\alpha}(k)) - \tilde{\alpha}^T(k)\tilde{\alpha}(k)$$

$$\Delta V(\tilde{\alpha}, k+1) = (\tilde{\alpha}^T(k) - h\tilde{\alpha}^T(k)E^T(k)E(k)P^T)(\tilde{\alpha}(k) - hPE^T(k)E(k)\tilde{\alpha}(k)) - \tilde{\alpha}^T(k)\tilde{\alpha}(k)$$

$$\Delta V(\tilde{\alpha}, k+1) = \tilde{\alpha}^T \tilde{\alpha} - 2h\tilde{\alpha}^T PE^T(k)E(k)\tilde{\alpha} + h^2\tilde{\alpha}^T E^T(k)E(k)P^2 E^T(k)E(k)\tilde{\alpha} - \tilde{\alpha}^T \tilde{\alpha}$$

$$\Delta V(\tilde{\alpha}, k+1) = -2h\tilde{\alpha}^T PE^T(k)E(k)\tilde{\alpha} + h^2\tilde{\alpha}^T E^T(k)E(k)P^2 E^T(k)E(k)\tilde{\alpha}$$

$$\Delta V(\tilde{\alpha}, k+1) = -2h\tilde{\alpha}^T PE^T(k)E(k)\tilde{\alpha} + h^2\tilde{\alpha}^T PE^T(k)E(k)E^T(k)E(k)P\tilde{\alpha}$$

$$\Delta V(\tilde{\alpha}, k+1) = -2h\tilde{\alpha}^T PX^{-1}DX\tilde{\alpha} + h^2\tilde{\alpha}^T PX^{-1}D^2XP\tilde{\alpha}$$

$$\Delta V(\tilde{\alpha}, k+1) = h\tilde{\alpha}^T PX^{-1}(-2DX + hD^2XP)\tilde{\alpha}$$

$$P = \frac{\sigma}{h}X^{-1}D^{-1}X$$

$$\Delta V(\tilde{\alpha}, k+1) = \tilde{\alpha}^T(-2\sigma + \sigma^2)\tilde{\alpha}$$

Ou seja, se for possível calcular a inversa de $E^T E$ num determinado instante, não é necessário que realizemos a inversão imediatamente, podemos especificar uma constante $\sigma < 1$ tal que o cálculo da posição de α^* se dê de forma gradual com uma dinâmica determinada pelo projetista. A lei adaptativa proposta nos permite estimar a direção do parâmetro θ^* em relação a θ .

3.5.4 Aprendizado Convergente

O trabalho de (Chowdhary et al. 2013), nos inspirou a apresentar o seguinte argumento: Se a posição de α^* é constante, isto, se os parâmetros da planta são invariantes no tempo, então momentos de observação anteriores ao atual também dispõem da informação sobre a posição de α^* . De fato, no caso SISO, é garantido que $E^T(t)E(t)$ sempre terá posto 1 e não é possível inverter a matriz para obter α^* de qualquer forma. Porém:

$$0 = -E^T(t)E(t)\alpha^* - E^T(t)e_{n+1}(t) \quad (3.66)$$

É válida para todo o t . Portanto, definindo os seguintes somatórios das matrizes durante um período em que o vetor regressor da planta tenha sofrido excitação segundo a definição dada anteriormente:

$$M = \sum_{i=1}^p E^T(t_i)E(t_i) \quad (3.67)$$

$$v = \sum_{i=1}^p E^T(t_i)e_{n+1}(t_i) \quad (3.68)$$

Temos garantia que M é de posto cheio [prova]. Podemos estimar α^* a partir de 3.25 modificada:

$$\dot{\hat{\alpha}} = -P(E^T(t)E(t) + M)\hat{\alpha} - P(E^T(t)e_{n+1}(t) + v) \quad (3.69)$$

Podemos também gerar M e v passando $E^T(t)E(t)$ e $v(t)$ por filtros, tal que sejamos capazes de "capturar" mais informação sobre os parâmetros da planta:

$$\begin{aligned} v(0) &= 0 \\ \dot{v} &= -\sigma v + e_{n+1}(t) \\ M(0) &= 0 \\ \dot{M} &= -\sigma M + E^T(t)E(t) \end{aligned} \quad (3.70)$$

E os mesmos argumentos da Teoria de Lyapunov apresentados se sustentam. Podemos identificar os parâmetros da planta a partir de uma entrada excitante ao longo do transiente da planta, sem necessitarmos de um sinal persistentemente excitante para manter a garantia.

Capítulo 4

Adaptação de Segundo Nível aplicada ao Controle

Neste capítulo, ao tratar da Adaptação de Segundo Nível, usaremos modelos de identificação fixos por motivos de simplicidade. Uma consideração futura na implementação dos algoritmos em ambiente de simulação será a introdução de técnicas de estimação convencionais aos modelos de identificação, de acordo com o que foi tratado em 3.2.1.

4.1 Adaptação de Segundo Nível aplicada ao Controle Adaptativo por Modelo de Referência de Plantas com Polinômio do Numerador conhecido e Variáveis de Estado Acessíveis

4.1.1 Formulação

Como em mostrado em (Gushiken & Araujo 2016), neste caso assumimos que as matrizes A_p da planta e A_m do modelo estão em forma canônica. Seja a planta como descrita em 2.2, com b conhecido e A_p desconhecida, escritas nas formas canônicas:

$$A_p = \begin{bmatrix} 0 & 1 & 0 & \dots & 0 \\ 0 & 0 & 1 & \dots & 0 \\ 0 & 0 & 0 & \dots & 0 \\ \dots & \dots & \dots & \dots & \dots \\ a_1 & a_2 & a_3 & \dots & a_n \end{bmatrix}, b = \begin{bmatrix} 0 \\ 0 \\ 0 \\ \dots \\ 1 \end{bmatrix}$$

Seja o vetor $\theta_p^T = [a_1, a_2, \dots, a_n]$ o vetor de parâmetros desconhecidos da planta e assumimos que o mesmo se localiza em uma região conhecida do R^n .

Seja o modelo de referência descrito por:

$$\Sigma_m : \dot{x}_m(t) = A_m x_m(t) + b r(t) \quad (4.1)$$

com A_m no mesmo formato de A_p , escolhido de forma que o modelo de referência seja

estável. A referência $r(t)$ é escolhida pelo projetista e uniformemente limitada.

Como em 2.2.2, queremos escolher a entrada $u(t)$, na presença de incertezas paramétricas, que garanta a saída da planta seguindo a saída do modelo de forma assintótica. Adicionalmente, queremos que o vetor de estimativas dos parâmetros da planta tenda aos valores corretos e que a referência não seja um sinal rico em frequências para todo o tempo t . A lei de controle neste caso se reduz a:

$$u(t) = r(t) + k^T x_p(t) \quad (4.2)$$

Pois o acesso às variáveis de estado torna desnecessária a geração de filtrados da entrada e da saída. O modelo série-paralelo usado para identificação:

$$\dot{\hat{x}}_p = A_m \hat{x}_p(t) + [A_1(t) - A_m] x_p(t) + b u(t) \quad (4.3)$$

que gera o erro entre os vetores de estado da planta e de sua estimativa como em 2.6. onde A_1 se encontra na forma canônica mostrada anteriormente e sua última linha consiste do vetor θ_1^T adaptado através de 3.5 e k^T da lei de controle é dado por:

$$k^T = \theta_m - \theta_1 \quad (4.4)$$

onde θ_m corresponde à última linha transposta da matriz A_m e θ_1 é uma estimativa de θ_p .

4.1.2 Simulação 1 - Planta Instável de Segunda Ordem

Para demonstrar os resultados obtidos, simulamos uma planta de segunda ordem sem ruído de medição e sem perturbações. O vetor de parâmetros da planta é $\theta_p^T = [2.3 \ -3.6]$, correspondendo à função de transferência $G(s) = \frac{1}{s^2 + 3.6s - 2.3}$. Escolhemos os modelos de identificação $\theta_1^T = [-4 \ -5]$, $\theta_2^T = [-3 \ -2]$, $\theta_3^T = [8 \ -4]$. Queremos que a planta siga o modelo de referência $\theta_m^T = [-4 \ -4]$. Partimos do repouso com a planta e modelos de identificação, e escolhemos $x_m^T(0) = [0.2 \ 0.3]$ e as condições iniciais da estimativa da planta $\hat{x}^T(0) = [0 \ 1]$. Escolhemos $c = 5$, $\gamma = 20$, $q = 10^4$, $v = 10$, $l = 0.2$, $w_1 = 1$, $m = 10^{-2}$. Os resultados se encontram na Figura 1. Em particular, verificamos que os parâmetros convergem para seus valores corretos após deslizar na superfície do fecho durante algum tempo. E também que, dada esta convergência, a parcela PE da referência é desligada pois $\eta \rightarrow 0$.

4.1.3 Simulação 2 - Planta Instável de Terceira Ordem

Simulamos também uma planta de terceira ordem sem ruído de medição e sem perturbações. O vetor de parâmetros da planta é $\theta_p^T = [-6 \ 9 \ 2]$, correspondendo à função de transferência $G(s) = \frac{1}{s^3 - 2s^2 - 9s + 6}$. Escolhemos os modelos de identificação $\theta_1^T = [-8 \ 7 \ -1]$, $\theta_2^T = [-2 \ 13 \ 6]$, $\theta_3^T = [14 \ -6 \ -2]$ e $\theta_4^T = [-15 \ 7 \ 9]$. Queremos que a planta siga o modelo de referência $\theta_m^T = [-9 \ -10 \ -12]$. Partimos com a planta e modelos de identificação com as condições iniciais $x_p^T(0) = x_i^T(0) = [0.1 \ 0.2 \ 0.3]$ e com o modelo de

4.1. ADAPTAÇÃO DE SEGUNDO NÍVEL APLICADA AO CONTROLE ADAPTATIVO POR MODELO




Figura 4.1: a) Trajetória dos parâmetros b) Comportamento da figura de Mérito η c) Norma do vetor de erros entre as variáveis de estado da planta e do modelo de referência d) Sinal de Controle e) Comportamento da Saída da Planta, Referência/Ganho Estático e Saída do Modelo de Referência

referência em repouso, e as condições iniciais da estimativa da planta $\hat{\alpha}^T(0) = [0 \ 0 \ 0]$. Escolhemos $c = 5$, $\gamma = 100$, $q = 10^4$, $v = 10$, $l = 0.2$, $w_1 = 1, w_2 = 2$, $m = 10^{-2}$. Os resultados se encontram na Figura 2. Novamente, os parâmetros convergem e a parcela PE da referência é desligada.




Figura 4.2: *a)* Trajetória dos parâmetros em termos do valor de cada α_i *b)* Comportamento da figura de Mérito η *c)* Norma do vetor de erros entre as variáveis de estado da planta e do modelo de referência *d)* Sinal de Controle *e)* Comportamento da Saída da Planta, Referência/Ganho Estático e Saída do Modelo de Referência

4.1.4 Simulação 3 - Planta Instável de Segunda Ordem com Perturbação na Entrada

Neste caso introduzimos uma perturbação na planta de segunda ordem estudada na simulação 1, no tempo $t_0 = 16s$, com $p(t_0) = -1$, e retiramos a perturbação em $t_1 = 22s$. Observamos que a introdução de uma perturbação na planta se reflete nas estimativas dos parâmetros e que, após a retirada, os valores retornam para uma vizinhança de θ_p . Os resultados se encontram na Figura 3.

4.1. ADAPTAÇÃO DE SEGUNDO NÍVEL APLICADA AO CONTROLE ADAPTATIVO POR MODELO




Figura 4.3: a) Trajetória dos parâmetros onde a linha em verde é o caminho feito após a introdução da perturbação b) Comportamento da figura de Mérito η c) Norma do vetor de erros entre as variáveis de estado da planta e do modelo de referência d) Sinal de Controle e) Comportamento da Saída da Planta, Referência/Ganho Estático e Saída do Modelo de Referência

4.1.5 Simulação 4 - Planta Instável de Segunda Ordem com Ruído de Medição

Também simulamos o que acontece no caso em que as medidas das variáveis de estado da planta não são livres de ruído. Com um ruído distribuído de forma normal no valor de $\pm 7.5\%$ do valor da saída em regime permanente introduzido nas medições das variáveis de estado da planta, se verificou a convergência dos parâmetros e do erro de saída, porém com os seguintes ajustes: $m = 0.2$, $\gamma = 20$. Os resultados se encontram na Figura 4. Nota-se a influência do ruído mais pronunciadamente em η , enquanto que os outros gráficos permanecem praticamente idênticos aos da simulação 1. Todas as simulações foram feitas usando passo de integração fixo $h = 10^{-3}s$




Figura 4.4: *a)* Trajetória dos parâmetros *b)* Comportamento da figura de Mérito η *c)* Norma do vetor de erros entre as variáveis de estado da planta e do modelo de referência *d)* Sinal de Controle *e)* Comportamento da Saída da Planta, Referência/Ganho Estático e Saída do Modelo de Referência

4.2 Adaptação de Segundo Nível aplicada ao Controle Adaptativo por Modelo de Referência de uma Planta com Grau Relativo Unitário com realimentação de Entrada e Saída

4.2.1 Formulação

Consideramos a seguinte planta, cujos parâmetros do numerador e denominador são conhecidos com incertezas:

$$W(s) = \frac{y(s)}{u(s)} = 1 \frac{s^2 + 4s + 3}{s^3 + 4s^2 + 4.5s + 1.875} \quad (4.5)$$

Que deve seguir o modelo de referência:

$$M(s) = \frac{y_m(s)}{r(s)} = 2.5 \frac{s^2 + 8s + 6}{s^3 + 9s^2 + 23s + 15} \quad (4.6)$$

Sabe-se que o vetor de parâmetros da planta:

$$\theta_p^T = [1 \quad 4 \quad 3 \quad 4 \quad 4.5 \quad 1.875] \quad (4.7)$$

Esta contido no fecho convexo delimitado por:

$$\Theta = [\theta_1 \quad \theta_2 \quad \theta_3 \quad \theta_4 \quad \theta_5 \quad \theta_6 \quad \theta_7] \quad (4.8)$$

Tal que:

$$\Theta = \begin{bmatrix} -4.2748 & -2.0727 & 3.1990 & -5.7136 & -0.3390 & 1.6579 & 4.2983 \\ 10.3168 & -2.8507 & 7.4804 & 4.8865 & -0.2454 & 7.8240 & -2.3002 \\ -0.1756 & 3.0194 & 9.5034 & -0.0940 & -0.7587 & 3.6440 & -0.6675 \\ 1.6518 & 7.4110 & 4.0450 & 1.7125 & 10.8438 & 6.8285 & -3.7609 \\ 3.4023 & 3.1134 & 10.9909 & 5.4061 & 5.2530 & 2.8326 & -1.7132 \\ 2.0863 & -0.5700 & -0.4138 & 6.2352 & 3.1425 & 4.9063 & 0.2758 \end{bmatrix} \quad (4.9)$$

Que mapeia θ_p a partir do vetor $\bar{\alpha}^*$ que queremos estimar:

$$\bar{\alpha}^{*T} = [0.1010 \quad 0.0717 \quad 0.2416 \quad 0.0499 \quad 0.1429 \quad 0.2026 \quad 0.1883] \quad (4.10)$$

As estimativas do vetor $\bar{\alpha}^*$ são geradas como em 3.69 e 3.70 com $P = \text{diag}(\gamma_1)$, γ_1 gerado a partir de 3.63. O posto de $M(t)$ é monitorado através de decomposição em valores singulares, quando o valor do autovalor mínimo de $M(t)^T M(t)$ ultrapassa uma certa tolerância α^* é calculado a partir de inversão de matrizes. Para garantir a estabilidade

α_0	[0.1429 0.1429 0.1429 0.1429 0.1429 0.1429]
Tempo de Simulação	16 segundos
Passo de Integração h	10^{-4}
$x_m(0)$	[0 0.03 0]
$x_p(0)$	[0.2 0 0]
γ	1
$P(0)$	100I
Tolerância da Inversão de Matrizes	10^{-4}
k_p mínimo	0.1

Tabela 4.1: Parâmetros de Simulação do MRAC com realimentação de entrada e saída

do esquema a projeção retangular é usada, como em 3.4.1. De posse de uma estimativa $\hat{\alpha}$ para $\tilde{\alpha}^*$ geramos $\theta_p = \Theta \hat{\alpha}$.

Como em 2.2.2, queremos escolher a entrada $u(t)$, na presença das incertezas paramétricas, que garanta a saída da planta seguindo a saída do modelo. No esquema de estimação usado existe garantia de convergência dos parâmetros para seus valores corretos desde que o valor do autovalor mínimo de $M(t)^T M(t)$ ultrapasse uma certa tolerância, escolhida de forma a evitar erros numéricos. Desta forma não é necessária a introdução de um sinal com característica de Persistência de Excitação. Os parâmetros θ_c da lei de controle $u = \theta_c^T w$ são calculados mapeando θ_p para obter as estimativas de $k_p, \alpha_1, \alpha, \beta$ dos parâmetros da planta e então usando estas estimativas em 2.73.

4.2.2 Simulação 1 - Planta Estável de Terceira Ordem

Simulamos o sistema para as seguintes condições e parâmetros:
Obtendo 4.5.

4.2.3 Simulação 2 - Planta Estável de Terceira Ordem com Ruído de Medição na Saída da Planta

Introduzindo um ruído de medição na saída da planta da ordem de 1% do valor medido, obtemos os resultados de 4.6.

4.2.4 Simulação 3 - Planta Estável de Terceira Ordem com Perturbação na Entrada

Introduzindo uma perturbação $d = -1$ na entrada da planta em $t = 2s$ obtemos 4.7.

4.2.5 Simulação 4 - Planta Estável de Terceira Ordem com Ruído de Medição na Saída e Perturbação na Entrada

Introduzindo a perturbação e o ruído simultaneamente na planta, obtemos 4.8.

4.2. ADAPTAÇÃO DE SEGUNDO NÍVEL APLICADA AO CONTROLE ADAPTATIVO POR MODELO




Figura 4.5: Simulação para o MRAC aplicando Adaptação de Segundo Nível: a) Erro de Saída b) Saída da Planta e do Modelo de Referência c) Sinal de Controle d, e, f) Trajetória dos parâmetros α




Figura 4.6: Simulação para o MRAC aplicando Adaptação de Segundo Nível com Ruído de Medição: a) Erro de Saída b) Saída da Planta e do Modelo de Referência c) Sinal de Controle d, e, f) Trajetória dos parâmetros α




Figura 4.7: Simulação para o MRAC aplicando Adaptação de Segundo Nível com Perturbação introduzida na entrada da planta em $t=2s$: a) Erro de Saída b) Saída da Planta e do Modelo de Referência c) Sinal de Controle d, e, f) Trajetória dos parâmetros α




Figura 4.8: Simulação para o MRAC aplicando Adaptação de Segundo Nível com ruído de medição na saída da planta e perturbação na entrada: a) Erro de Saída b) Saída da Planta e do Modelo de Referência c) Sinal de Controle d, e, f) Trajetória dos parâmetros α

4.3 Adaptação de Segundo Nível aplicada ao Controle Adaptativo em Modo Dual Indireto Adaptativo Robusto de uma Planta com Grau Relativo Unitário e Realimentação de Entrada e Saída

Se gerarmos a estimativa de θ_p^* como uma combinação convexa da "estimativa" entregue pelo controle com estrutura variável e da estimativa produzida a partir da adaptação de segundo nível tal que:

$$\mu = -q + (1 + q)e^{\frac{\epsilon_0^2}{L}} \quad (4.11)$$

$$\mu = \begin{cases} -q + (1 + q)e^{\frac{\epsilon_0^2}{L}}, & \text{se } \mu \leq 1 \text{ e } \mu \geq 0 \\ 0 & \text{se } \mu < 0 \\ 1 & \text{se } \mu > 1 \end{cases} \quad (4.12)$$

Introduzimos esta modificação na lei proposta por Cunha tal que seja possível a atuação exclusiva de cada um dos modos. A introdução desta modificação corresponde a um "achatamento" da gaussiana μ usada para gerar a combinação convexa. Assim geramos:

$$\theta_p = \mu \Theta \tilde{\alpha} + (1 - \mu) \theta_{p,vs} \quad (4.13)$$

Calculando os parâmetros do controlador como em 2.73.

4.3.1 Simulação 1 - Planta Estável de Terceira Ordem

Aplicamos os parâmetros das simulações anteriores e introduzimos os parâmetros relacionados ao controle com estrutura variável, de forma que ficamos com a tabela:

Que produz os resultados vistos em 4.9.

4.3.2 Simulação 2 - Planta Estável de Terceira Ordem com Ruído de Medição na Saída da Planta

Novamente, introduzimos um ruído de medição na saída da planta, obtendo os resultados de 4.10

4.3.3 Simulação 3 - Planta Estável de Terceira Ordem com Perturbação na Entrada

Com uma perturbação $d = 0.6$ na entrada da planta introduzida em $t = 2s$ temos 4.11

α_0	[0.1429 0.1429 0.1429 0.1429 0.1429 0.1429]
Tempo de Simulação	16 segundos
Passo de Integração h	10^{-4}
$x_m(0)$	[0 0.03 0]
$x_p(0)$	[0.2 0 0]
γ	1
$P(0)$	100I
Tolerância da Inversão de Matrizes	10^{-4}
k_p mínimo	0.1
q	0.1
L	0.05
$k_{p,nom}$	0.1
$\bar{k}_p$	2
$\bar{\alpha}_{1,p}$	6
$\bar{\alpha}_p$	[6 8]
$\bar{\beta}_p$	[10 8]

Tabela 4.2: Parâmetros de Simulação do IDMARC




Figura 4.9: Simulação para o IDMARC aplicando Adaptação de Segundo Nível: a) Erro de Saída b) Saída da Planta e do Modelo de Referência c) Sinal de Controle d, e, f) Trajetória dos parâmetros α

4.3. ADAPTAÇÃO DE SEGUNDO NÍVEL APLICADA AO CONTROLE ADAPTATIVO EM MODO




Figura 4.10: Simulação para o IDMARC aplicando Adaptação de Segundo Nível com ruído de medição na saída da planta: a) Erro de Saída b) Saída da Planta e do Modelo de Referência c) Sinal de Controle d, e, f) Trajetória dos parâmetros α




Figura 4.11: Simulação para o IDMARC aplicando Adaptação de Segundo Nível com perturbação na entrada da planta: a) Erro de Saída b) Saída da Planta e do Modelo de Referência c) Sinal de Controle d, e, f) Trajetória dos parâmetros α

4.3.4 Simulação 4 - Planta Estável de Terceira Ordem com Ruído de Medição na Saída e Perturbação na Entrada

Finalmente, com a perturbação e o ruído introduzidos na mesma simulação temos 4.12




Figura 4.12: Simulação para o IDMARC aplicando Adaptação de Segundo Nível com ruído de medição na saída e perturbação na entrada da planta: a) Erro de Saída b) Saída da Planta e do Modelo de Referência c) Sinal de Controle d, e, f) Trajetória dos parâmetros α

4.3.5 Simulação 5 - Planta Instável de Terceira Ordem

A partir deste ponto, consideramos a planta instável:

$$W(s) = \frac{y(s)}{u(s)} = 1 \frac{s^2 + 4s + 3}{s^3 - 4s^2 - 4.5s - 1.875} \quad (4.14)$$

Contida no fecho:

$$\Theta = \begin{bmatrix} -4.274 & -2.072 & 3.199 & -5.713 & -0.339 & 1.657 & 4.298 \\ 10.316 & -2.850 & 7.480 & 4.886 & -0.245 & 7.824 & -2.300 \\ -0.175 & 3.019 & 9.503 & -0.094 & -0.758 & 3.644 & -0.667 \\ -1.651 & -7.411 & -4.045 & -1.712 & -10.843 & -6.828 & 3.760 \\ -3.402 & -3.113 & -10.990 & -5.406 & -5.253 & -2.832 & 1.713 \\ -2.086 & 0.570 & 0.413 & -6.235 & -3.142 & -4.906 & -0.275 \end{bmatrix} \quad (4.15)$$

Que é apenas o fecho Θ que vínhamos utilizando anteriormente com suas 3 últimas linhas multiplicadas por -1 , tal que α^* para este conjunto planta+fecho é o mesmo das

4.3. ADAPTAÇÃO DE SEGUNDO NÍVEL APLICADA AO CONTROLE ADAPTATIVO EM MODO

simulações feitas anteriormente. Obtemos os resultados a seguir, no caso sem ruído e sem perturbação na entrada, 4.13.




Figura 4.13: Simulação para o IDMARC aplicando Adaptação de Segundo Nível com ruído de medição na saída e perturbação na entrada da planta instável: a) Erro de Saída b) Saída da Planta e do Modelo de Referência c) Sinal de Controle d, e, f) Trajetória dos parâmetros α

4.3.6 Simulação 6 - Planta Instável de Terceira Ordem com Ruído de Medição na Saída da Planta

Introduzindo um ruído de medição na saída da planta da ordem de 1% do valor medido temos 4.14

4.3.7 Simulação 7 - Planta Instável de Terceira Ordem com Perturbação na Entrada

Colocando uma perturbação $d = 0.6$ na entrada da planta em $t = 2s$ temos 4.15

4.3.8 Simulação 8 - Planta Instável de Terceira Ordem com Ruído de Medição na Saída e Perturbação na Entrada

Finalmente, introduzimos o ruído de medição na saída da planta e uma perturbação $d = 0.6$ em $t = 2s$. Note-se que fomos forçados a diminuir a largura da gaussiana para $L = 0.01$ para obter um resultado com $e_0(t)$ confinado a um domínio residual que consideramos pequeno o suficiente. Os resultados podem ser vistos em 4.16




Figura 4.14: Simulação para o IDMARC aplicando Adaptação de Segundo Nível com ruído de medição na saída e perturbação na entrada da planta instável: a) Erro de Saída b) Saída da Planta e do Modelo de Referência c) Sinal de Controle d, e, f) Trajetória dos parâmetros α




Figura 4.15: Simulação para o IDMARC aplicando Adaptação de Segundo Nível com ruído de medição na saída e perturbação na entrada da planta instável: a) Erro de Saída b) Saída da Planta e do Modelo de Referência c) Sinal de Controle d, e, f) Trajetória dos parâmetros α

4.3. ADAPTAÇÃO DE SEGUNDO NÍVEL APLICADA AO CONTROLE ADAPTATIVO EM MODO




Figura 4.16: Simulação para o IDMARC aplicando Adaptação de Segundo Nível com ruído de medição na saída e perturbação na entrada da planta instável: *a)* Erro de Saída *b)* Saída da Planta e do Modelo de Referência *c)* Sinal de Controle *d, e, f)* Trajetória dos parâmetros α

Capítulo 5

Implementação

5.1 MATLAB

5.1.1 Adaptação de Segundo Nível aplicada ao Controle Adaptativo por Modelo de Referência de uma Planta com Polinômio do Numerador Conhecido e Acesso às Variáveis de Estado da Planta

```
function estrutura = L2AA(args)
tic
%declaração de variáveis:
[t_0,t_final, h, modelos, planta, modelo_de_referencia, cond_iniciais_p, ...
 cond_iniciais_m,cond_iniciais_i, alfa0,Q,gamma,P,~,ref_amp, ...
 ref_freq,tol_eta,tau_ref] = convert_struct(args);
stoptime = t_final-t_0;
%prealocação de memória:
    %número de passos a serem dados na simulação
endk = floor(stoptime/h);
size_modelos = size(modelos);
n_de_linhas = size_modelos(1);

[tempo,r,r_ponto,eta,u, ...
 alfa_ponto,alfa_ponto_n1,alfa_n1,x_i_ponto, ...
 x_m_ponto, x_p_ponto, e_o, norm_2_e_o, ...
 theta_p_estimativa, x_i, x_p, x_m, theta_i, ...
 A_i, theta_i_ponto, k_T, alfa_barra, alfa,E,e_i] ...
 = preallocate_memory(n_de_linhas,endk);

%matrizes na forma canônica (companion form):
A_p = can(planta);
A_m = can(modelo_de_referencia);
for i=1:length(modelos)
A_i(:, :, i, 1) = can(modelos(:, i));
end
```

```

theta_BARRA(:, :, 1) = modelos;
for j=1:length(modelos)
theta_i(:, j, 1) = modelos(:, j);
end
%b é considerado conhecido, os sistemas não contém zeros.
b(n_de_linhas, 1)=1;

%condições iniciais da planta, modelo de referência e modelos de
%identificação
x_p(:, 1) = cond_iniciais_p;
x_m(:, 1) = cond_iniciais_m;

for j=1:length(modelos)
x_i(:, j, 1) = cond_iniciais_i(:, j);
%inicialização dos erros
e_i(:, j, 1) = x_i(:, j, 1) - x_p(:, 1);
end

%inicialização da matriz E
for j=1:(length(modelos)-1)
    E(:, j, 1) = x_i(:, j, 1)-x_i(:, n_de_linhas+1, 1);
end

%condições iniciais do vetor de combinação linear alfa_barra
alfa(:, 1)= alfa0;
alfa_barra(:, 1) = transpose([transpose(alfa(:, 1)) 1-ones(1, n_de_linhas)*alfa(:, 1)]);

%inicialização dos parâmetros do controlador
k_T(:, 1) = transpose(modelo_de_referencia) - theta_BARRA*alfa_barra(:, 1);

%inicialização da entrada da planta
u(1) = ref_amp(1);

%inicialização do tempo de simulação
tempo(1) = 0;
eta(1)=0;

r_ponto(1) = 0;
%início
for k=1:endk
%tempo de simulação
    tempo(k+1) = tempo(k)+h;
%sinal de referência

```

```

r(k+1) = ref_amp*cos(tempo(k)*ref_freq);
if eta(k)<=tol_eta
    r_ponto(k) = tau_ref*(-r(k) + ref_amp(1));
    r(k+1) = r(k) + h*r_ponto(k);
end
%Geração dos erros entre os modelos escolhidos e a planta
for j=1:length(modelos)
    e_i(:,j,k) = x_i(:,j,k) - x_p(:,k);
%geração de uma matriz E, tal que as colunas de E sejam e_i-e_{n+1}
end

for j=1:(n_de_linhas)
    E(:,j,k) = x_i(:,j,k)-x_i(:,n_de_linhas+1,k);
end
%geração do vetor alfa através da inversa de E
    alfa_ponto(:,k) = gamma*(-transpose(E(:, :, k))*E(:, :, k)*alfa(:,k)-(transpose(E
    alfa_n1(k) = 1-ones(1, n_de_linhas)*alfa(:,k);
    alfa_ponto_n1(k) = -ones(1, n_de_linhas)*alfa_ponto(:,k);
    for i=1:n_de_linhas
        if (alfa(i,k)>=1 && alfa_ponto(i,k)>0) || (alfa(i,k)<=0 && alfa_ponto(i,k)<
            alfa_ponto(i,k)=0;
        end
        if (alfa_n1(k)>=1 && alfa_ponto_n1(k)>0) || (alfa_n1(k)<=0 && alfa_ponto_n1
        for j=1:length(alfa_ponto(:,k))
            if sign(alfa_ponto_n1(k)) ~= sign(alfa_ponto(j,k))
                alfa_ponto(j,k)=0;
            end
        end
    end
end
    alfa(:,k+1) = alfa(:,k) + h*alfa_ponto(:,k);
    eta(k+1) = transpose(alfa_ponto(:,k))*Q*alfa_ponto(:,k)/(1 + transpose(alfa_p
%composição de alfa para gerar alfa_barra, que é uma parametrização d
%planta
    alfa_barra(:,k) = transpose([transpose(alfa(:,k)) 1-ones(1, n_de_linhas)*alfa
%geração dos parâmetros do controlador, note-se que
%theta_BARRA*alfa_barra(1:3,k) corresponde a theta_p_chapéu, a estima
%dos parâmetros da planta

    k_T(:,k) =transpose(modelo_de_referencia) - theta_BARRA(:, :, k)*alfa_barra(:,k)
%lei de controle
    u(k) = r(k) + transpose(k_T(:,k))*x_p(:,k);
%dinâmica dos modelos, da planta e do modelo de referência

```

```

for j=1:n_de_linhas+1
    theta_i_ponto(:,j,k) = -transpose(e_i(:,j,k))*P*b*x_p(:,k);
    theta_i(:,j,k+1) = theta_i(:,j,k) + h*theta_i_ponto(:,j,k);
    theta_BARRA(:,j,k+1) = theta_i(:,j,k+1);
    A_i(:, :, j,k+1) = can(theta_BARRA(:,j,k+1));
end

for j=1:n_de_linhas+1
    x_i_ponto(:,j,k) = A_m*x_i(:,j,k) + (A_i(:, :, j,k) - A_m)*x_p(:,k) + b*u(k);
    x_i(:,j,k+1) = x_i(:,j,k) + h*x_i_ponto(:,j,k);
end
    x_m_ponto(:,k) = A_m*x_m(:,k) + b*r(k);
    x_m(:,k+1) = x_m(:,k) + h*x_m_ponto(:,k);
    x_p_ponto(:,k) = A_p*x_p(:,k) + b*u(k);
    x_p(:,k+1) = x_p(:,k) + h*x_p_ponto(:,k);
    %cálculo da norma 2 do erro
    e_o(:,k) = x_m(:,k) - x_p(:,k);
    norm_2_e_o(k) = sqrt(transpose(e_o(:,k))*e_o(:,k));
    theta_p_estimativa(:,k) = theta_BARRA(:, :, k)*alfa_barra(:,k);
    %fim do laço principal

end

estrutura = make_struct(x_p,x_m,eta,theta_p_estimativa,norm_2_e_o, ...
    e_o,u, alfa_barra, r, modelo_de_referencia, ...
    planta, theta_BARRA, modelos,tempo,endk);

toc

end

```

5.1.2 Adaptação de Segundo Nível aplicada ao Controle Adaptativo por Modelo de Referência de uma Planta com Grau Relativo Unitário e Realimentação de Entrada e Saída

```

function L2A_IO_FE(tempo_sim,h,Nps,Dps,kp,...
    xps0,Nms,Dms,km,xms0,theta_chapeu_barra,gamma,alfa0,...
    gain,tol,kp_bar)

vaux(length(Dms)) = 0; vaux(1)=1;
n = (length(theta_chapeu_barra)-1)/2;

```

```

[Az,bz,Cz,Dz]          = tf2ss(vaux,Dms);
[Af,bf,~,~]            = tf2ss(ones(1,n),Dms);
[Ap,bp,hp_transposto,~] = tf2ss(kp*Nps,Dps);
[Am,bm,hm_transposto,~] = tf2ss(km*Nms,Dms);
[Av,~,~,~]             = tf2ss(gamma,Nms);
beta_m(:,1) = Nms(2:1:n);
alfa_m_1     = Dms(2);
alfa_m(:,1) = Dms(3:1:n+1);
g(n-1,1) = 0; g(1,1) = gamma;
%inicializacao das variaveis, forma compacta
    endk = tempo_sim/h;xps(:,1,1) = xps0; xps(:,1,endk) = zeros(n,1);
    saida_planta(1) = hp_transposto*xps0;saida_planta(endk) = 0;
    xms(:,1,1) = xms0;xms(:,1,endk) = zeros(n,1);
    saida_modelo(1) = hm_transposto*xms0;saida_modelo(endk) = 0;
    fi1(:,1,endk) = zeros(n,1);fi2(:,1,endk) = zeros(n,1);
    v1(:,1,endk) = zeros(n-1,1); v2(:,1,endk) = zeros(n-1,1);
    alfa(:,1) = alfa0;
    alfa_barra(:,1) = [alfa(:,1)' 1-ones(1, 2*n)*alfa(:,1)]';
    theta_p_estimativa(:,1) = theta_chapeu_barra*alfa_barra(:,1);
    kp_chapeu(1)          = 1;
    beta_chapeu(:,1,1) = theta_p_estimativa(2:n,1);
    alfa_1_chapeu(1)     = theta_p_estimativa(n+1,1);
    alfa_chapeu(:,1,1) = theta_p_estimativa(n+2:2*n,1);
    theta_2n(1) = km/kp_chapeu(1);
    theta_n(1)  = (alfa_1_chapeu(1)-alfa_m_1)/kp_chapeu(1);
    theta_v1(:,1,1) = (beta_m - beta_chapeu(:,1,1))/gamma;
    theta_v2(:,1,1) = (alfa_chapeu(:,1,1) - alfa_m+(alfa_m_1-alfa_1_chapeu(1))*bet
    theta_controlador(:,1,1) = [theta_v1(:,1,1); theta_n(1); theta_v2(:,1,1); thet
    r(1) = 1;
    w(:,1,1) = [v1(:,1,1); saida_planta(1); v2(:,1,1); r(1)];
    z_vetor_planta(:,1,1) = zeros(n,1);
    M(:, :, 1) = zeros(2*n,2*n);
    vm(:,1)    = zeros(2*n,1);
for k=1:endk
    tempo(k+1) = k*h;
    tempo2(k)  = k*h;
    %r(k+1) = sin(tempo(k));
    r(k+1) = 1;
    %Lei de Controle
        u(k) = (theta_controlador(:,1,k)')*w(:,1,k);
    %planta
    xps_p(:,1,k) = Ap*xps(:,1,k) + bp*u(k);
    xps(:,1,k+1) = xps(:,1,k) + h*xps_p(:,1,k);
    saida_planta(k+1) = hp_transposto(1,:)*xps(:,1,k+1);

```

```
%%FILTROS
```

```
%Geração do Vetor fi, usado na identificação dos parâmetros da planta
```

```
fil_p(:,1,k) = Af*fil(:,1,k) + bf*u(k);
fil(:,1,k+1) = fil(:,1,k) + h*fil_p(:,1,k);
fi2_p(:,1,k) = Af*fi2(:,1,k) + bf*saida_planta(k);
fi2(:,1,k+1) = fi2(:,1,k) + h*fi2_p(:,1,k);
fi(:,1,k) = [fil(:,1,k); -fi2(:,1,k)];
```

```
%fi(t) <-> fi(:,1,k)
```

```
%Geração de w, usado no sinal de controle
```

```
v1_p(:,1,k) = Av*v1(:,1,k) + g*u(k);
v2_p(:,1,k) = Av*v2(:,1,k) + g*saida_planta(k);
v1(:,1,k+1) = v1(:,1,k) + h*v1_p(:,1,k);
v2(:,1,k+1) = v2(:,1,k) + h*v2_p(:,1,k);

w(:,1,k+1) = [v1(:,1,k+1); saida_planta(k+1); v2(:,1,k+1); r(k+1)];

z_vetor_planta_ponto(:,1,k) = Az*z_vetor_planta(:,1,k) + bz*(saida_planta(k));
z_vetor_planta(:,1,k+1) = z_vetor_planta(:,1,k) + h*z_vetor_planta_ponto(:,1,k);
z_planta(k) = Cz*z_vetor_planta(:,1,k) + Dz*saida_planta(k);
z_planta_estimado(k) = theta_p_estimativa(:,k)'*fi(:,1,k);
%z(t) = y filtrado(t) <-> z(k)
```

```
%%
```

```
z_filtrado_n1(k) = theta_chapeu_barra(:,2*n+1)'*fi(:,1,k);
e_n1(k) = z_filtrado_n1(k) - z_planta(k);
for i=1:(2*n) %construcao das saidas z dos modelos e do vetor erro de ident
    %z_vetor_filtrado_modelos_ponto(:,1,i,k) = Aw1*z_vetor_filtrado_modelo
    %z_vetor_filtrado_modelos(:,1,i,k+1) = z_vetor_filtrado_modelos(:,1,i,
    %z_filtrado_modelos(i,k+1) = Cw1*z_vetor_filtrado_modelos(:,1,i,k) + D
    z_filtrado_modelos(i,k) = theta_chapeu_barra(:,i)'*fi(:,1,k); %construcao diret
    E(1,i,k) = z_filtrado_modelos(i,k) - z_filtrado_n1(k); %vetor linha E(t)
end

M_ponto(:, :, k) = -0.02*M(:, :, k) + E(1, :, k)'*E(1, :, k);
M(:, :, k+1) = M(:, :, k) + h*M_ponto(:, :, k);
l = 1 / (h*max(svd(E(1, :, k)'*E(1, :, k))));
    if gain>l
        gain=l/2;
    end
vm_ponto(:, k) = -0.02*vm(:, k) + E(1, :, k)'*e_n1(k);
```

```

vm(:,k+1) = vm(:,k) + h*vm_ponto(:,k);
alfa_ponto(:,k) = gain*(-E(1,:,k)'*E(1,:,k)*alfa(:,k)- E(1,:,k)'*e_n1(k));
alfa_n1(k) = 1-ones(1,2*n)*alfa(:,k);
alfa_ponto_n1(k) = -ones(1, 2*n)*alfa_ponto(:,k);
alfa(:,k+1) = alfa(:,k) + h*alfa_ponto(:,k);

if min(svd(M(:, :,k)+E(1,:,k)'*E(1,:,k)))> tol
    alfa(:,k+1) = ((M(:, :,k)+E(1,:,k)'*E(1,:,k))\-(vm(:,k)+E(1,:,k)'*e_n1(k)))
    % M(:, :,k) = zeros(2*n,2*n);
    % vm(:,k) = zeros(2*n,1);
end
for i=1:2*n
    if alfa(i,k+1)>1
        alfa(i,k+1)=1;
    end
    if alfa(i,k+1)<0
        alfa(i,k+1)=0;
    end
end

alfa_barra(:,k+1) = [alfa(:,k+1)' 1-ones(1, 2*n)*alfa(:,k+1)]';

theta_p_estimativa(:,k+1) = theta_chapeu_barra*alfa_barra(:,k+1);
%modelo de referencia, no entanto, temos acesso aos polinômios por
%definição, e o erro usado para calcular os parametros é o dos mod
%portanto, precisamos do modelo de referência apenas por motivos c
%comparação
xms_p(:,1,k) = Am*xms(:,1,k) + bm*r(k);
xms(:,1,k+1) = xms(:,1,k) + h*xms_p(:,1,k);
saida_modelo(k+1) = hm_transposto*xms(:,1,k+1);

%tradução de theta_p_estimativa em termos dos polinômios e ganho c
%planta estimados

%verificar lei de controle
kp_chapeu(k+1) = theta_p_estimativa(1,k+1);
if kp_chapeu(k+1) <kp_bar
    kp_chapeu(k+1)=kp_bar;
end

beta_chapeu(:,1,k+1) = theta_p_estimativa(2:1:n,k+1)/kp_chapeu(k+1);
alfa_1_chapeu(k+1) = theta_p_estimativa(n+1,k+1);
alfa_chapeu(:,1,k+1) = theta_p_estimativa(n+2:1:2*n,k+1);

```

```

    %Geração dos parâmetros do controlador a partir das estimativas
    theta_2n(k+1) = km/kp_chapeu(k+1); %% OK
    theta_n(k+1) = (alfa_1_chapeu(k+1)-alfa_m_1)/kp_chapeu(k+1);
    theta_v1(:,1,k+1) = (beta_m - beta_chapeu(:,1,k+1))/gamma;
    theta_v2(:,1,k+1) = (alfa_chapeu(:,1,k+1) - alfa_m+(alfa_m_1-alfa_1_chapeu(k+1))*b
    theta_controlador(:,1,k+1) = [theta_v1(:,1,k+1); theta_n(k+1); theta_v2(:,1,k+1);

end

figure('Name','Resultados')

subplot(3,2,1)
plot(tempo,saida_planta-saida_modelo,'Color',[0 0.1 0.5],'LineWidth',2.0)
leg1 = legend('Erro de Saída e_o');
set(leg1,'FontSize', 10);
grid on
subplot(3,2,2)

plot(tempo,saida_modelo,'Color',[1 0.2 0],'LineWidth',2.0)
hold on
plot(tempo,saida_planta,'Color',[0.2 0 1],'LineWidth',2.0)
leg1 = legend('Saída do modelo, y_m', 'Saída da planta, y');
set(leg1,'FontSize', 10);
grid on
subplot(3,2,3)
plot(tempo2,u,'Color',[0.2 0 0.5],'LineWidth',2.0);
leg1 = legend('Sinal de Controle u');
set(leg1,'FontSize', 10);
grid on
for i=1:n
    subplot(3,2,i+3)

    plot(alfa(i,1),alfa(2*n-i,1),'Marker','*','Color',[0 0 0],'LineWidth',2.0)
    line(alfa(i,:),alfa(2*n-i,:), 'Color',[0 0.2 1],'LineWidth',3.0);
    line([0 0 1 1 0],[0 1 1 0 0],'Color',[1 0.2 0],'LineWidth',2.0)
    hold on
    plot(alfa(i,endk),alfa(2*n-i,endk), 'Marker','x','Color',[0.2 0.2 0.2],'LineWidth'
    leg1 = legend('Posição inicial *', 'Trajetória', ' Fecho Convexo','Posição Final x
    set(leg1,'FontSize', 10);
    grid on
end

```

end

5.1.3 Adaptação de Segundo Nível aplicada ao Controle Adaptativo em Modo Dual Indireto Adaptativo Robusto de uma Planta com Grau Relativo Unitário e Realimentação de Entrada e Saída

```
function L2A_IO_FE_IDMARC(tempo_sim,h,Nps,Dps,kp,...
    xps0,Nms,Dms,km,xms0,theta_chapeu_barra,gamma,alfa0,...
    gain,tol,kp_bar,q,L,kp_nom,kp_barra,alfa_1_barra,...
    beta_barra, alfa_nomec_barra)

vaux(length(Dms)) = 0; vaux(1)=1;
n = (length(theta_chapeu_barra)-1)/2;
[Az,bz,Cz,Dz] = tf2ss(vaux,Dms);
[Af,bf,~,~] = tf2ss(ones(1,n),Dms);
[Ap,bp,hp_transposto,~] = tf2ss(kp*Nps,Dps);
[Am,bm,hm_transposto,~] = tf2ss(km*Nms,Dms);
[Av,~,~,~] = tf2ss(gamma,Nms);
beta_m(:,1) = Nms(2:1:n);
alfa_m_1 = Dms(2);
alfa_m(:,1) = Dms(3:1:n+1);
g(n-1,1) = 0; g(1,1) = gamma;
%inicializacao das variaveis, forma compacta
endk = tempo_sim/h;xps(:,1,1) = xps0; xps(:,1,endk) = zeros(n,1);
saida_planta(1) = hp_transposto*xps0;saida_planta(endk) = 0;
xms(:,1,1) = xms0;xms(:,1,endk) = zeros(n,1);
saida_modelo(1) = hm_transposto*xms0;saida_modelo(endk) = 0;
fi1(:,1,endk) = zeros(n,1);fi2(:,1,endk) = zeros(n,1);
v1(:,1,endk) = zeros(n-1,1); v2(:,1,endk) = zeros(n-1,1);
alfa(:,1) = alfa0;
alfa_barra(:,1) = [alfa(:,1)' 1-ones(1, 2*n)*alfa(:,1)]';
theta_p_estimativa(:,1) = theta_chapeu_barra*alfa_barra(:,1);
kp_chapeu(1) = 1;
beta_chapeu(:,1,1) = theta_p_estimativa(2:n,1);
alfa_1_chapeu(1) = theta_p_estimativa(n+1,1);
alfa_chapeu(:,1,1) = theta_p_estimativa(n+2:2*n,1);
theta_2n(1) = km/kp_chapeu(1);
theta_n(1) = (alfa_1_chapeu(1)-alfa_m_1)/kp_chapeu(1);
theta_v1(:,1,1) = (beta_m - beta_chapeu(:,1,1))/gamma;
theta_v2(:,1,1) = (alfa_chapeu(:,1,1) - alfa_m+(alfa_m_1-alfa_1_chapeu(1))*bet
theta_controlador(:,1,1) = [theta_v1(:,1,1); theta_n(1); theta_v2(:,1,1); thet
r(1) = 1;
w(:,1,1) = [v1(:,1,1); saida_planta(1); v2(:,1,1); r(1)];
```

```

    z_vetor_planta(:,1,1) = zeros(n,1);
    M(:, :, 1) = zeros(2*n, 2*n);
    vm(:, 1) = zeros(2*n, 1);
    for k=1:endk
        tempo(k+1) = k*h;
        tempo2(k) = k*h;
        %r(k+1) = sin(tempo(k));
        r(k+1) = 1;
        %Lei de Controle
        u(k) = (theta_controlador(:,1,k)')*w(:,1,k);
        %planta
        d=0;
        if k>20000;
            d=-1;
        end
        xps_p(:,1,k) = Ap*xps(:,1,k) + bp*u(k)+bp*d;
        xps(:,1,k+1) = xps(:,1,k) + h*xps_p(:,1,k);
        saida_planta(k+1) = hp_transposto(1,:) * xps(:,1,k+1) + 0.01*randn(1);

        %%FILTROS
        %Geração do Vetor fi, usado na identificação dos parâmetros da planta
        fil_p(:,1,k) = Af*fil(:,1,k) + bf*u(k);
        fil(:,1,k+1) = fil(:,1,k) + h*fil_p(:,1,k);
        fi2_p(:,1,k) = Af*fi2(:,1,k) + bf*saida_planta(k);
        fi2(:,1,k+1) = fi2(:,1,k) + h*fi2_p(:,1,k);
        fi(:,1,k) = [fil(:,1,k); -fi2(:,1,k)];

        %fi(t) <-> fi(:,1,k)

        %Geração de w, usado no sinal de controle
        v1_p(:,1,k) = Av*v1(:,1,k) + g*u(k);
        v2_p(:,1,k) = Av*v2(:,1,k) + g*saida_planta(k);
        v1(:,1,k+1) = v1(:,1,k) + h*v1_p(:,1,k);
        v2(:,1,k+1) = v2(:,1,k) + h*v2_p(:,1,k);
        w(:,1,k+1) = [v1(:,1,k+1); saida_planta(k+1); v2(:,1,k+1); r(k+1)];

        %sinais relacionados ao VS pela formulacao de Leonardo, Cunha e Araujo
        csip = Nms(2:n)*v1(:,1,k)/gamma -u(k) - theta_p_estimativa(2:n,k)'*v1(:,1,k)/gamma;
        csib = -v1(:,k)/gamma;
        csil = saida_planta(k)-Nms(2:n)*v2(:,1,k)/gamma;
        csia = v2(:,1,k)/gamma;

```

```

z_vetor_planta_ponto(:,1,k) = Az*z_vetor_planta(:,1,k) + bz*(saida_planta(k));
z_vetor_planta(:,1,k+1) = z_vetor_planta(:,1,k) + h*z_vetor_planta_ponto(:,1,k);
z_planta(k) = Cz*z_vetor_planta(:,1,k) + Dz*saida_planta(k);
z_planta_estimado(k) = theta_p_estimativa(:,k)'*fi(:,1,k);
%z(t) = y filtrado(t) <-> z(k)

%%
z_filtrado_n1(k) = theta_chapeu_barra(:,2*n+1)'*fi(:,1,k);
e_n1(k) = z_filtrado_n1(k)-z_planta(k);
for i=1:(2*n) %construcao das saidas z dos modelos e do vetor erro de i
    %z_vetor_filtrado_modelos_ponto(:,1,i,k) = Aw1*z_vetor_filtrado_modelos_ponto(:,1,i,k);
    %z_vetor_filtrado_modelos(:,1,i,k+1) = z_vetor_filtrado_modelos(:,1,i,k);
    %z_filtrado_modelos(i,k+1) = Cw1*z_vetor_filtrado_modelos(:,1,i,k);
    z_filtrado_modelos(i,k) = theta_chapeu_barra(:,i)'*fi(:,1,k); %construcao da linha E(t)
    E(1,i,k) = z_filtrado_modelos(i,k) - z_filtrado_n1(k); %vetor linha E(t)
end

%l = 1/(h*max(svd(E(1, :, k)'*E(1, :, k)))));
% if gain>1
% gain=1/2;
% end

M_ponto(:, :, k) = -0.02*M(:, :, k) + E(1, :, k)'*E(1, :, k);
M(:, :, k+1) = M(:, :, k) + h*M_ponto(:, :, k);
l = 1/(h*max(svd(E(1, :, k)'*E(1, :, k)))));
if gain>1
    gain=1/2;
end

vm_ponto(:, k) = -0.02*vm(:, k) + E(1, :, k)'*e_n1(k);
vm(:, k+1) = vm(:, k) + h*vm_ponto(:, k);
alfa_ponto(:, k) = gain*(-(E(1, :, k)'*E(1, :, k))*alfa(:, k) - E(1, :, k)'*(e_n1(k)));
alfa_n1(k) = 1-ones(1, 2*n)*alfa(:, k);
alfa_ponto_n1(k) = -ones(1, 2*n)*alfa_ponto(:, k);
alfa(:, k+1) = alfa(:, k) + h*alfa_ponto(:, k);
if min(svd(M(:, :, k)+E(1, :, k)'*E(1, :, k)))> tol
    alfa(:, k+1) = ((M(:, :, k)+E(1, :, k)'*E(1, :, k))\-(vm(:, k)+E(1, :, k)'*e_n1(k)))
    % M(:, :, k) = zeros(2*n, 2*n);
    % vm(:, k) = zeros(2*n, 1);
end
for i=1:2*n
    if alfa(i, k+1)>1
        alfa(i, k+1)=1;
    end
    if alfa(i, k+1)<0
        alfa(i, k+1)=0;
    end
end

```

```

    end
end

alfa_barra(:,k+1) = [alfa(:,k+1)' 1-ones(1, 2*n)*alfa(:,k+1)]';

theta_p_estimativa(:,k+1) = theta_chapeu_barra*alfa_barra(:,k+1);
%modelo de referencia, no entanto, temos acesso aos polinômios por
%definição, e o erro usado para calcular os parametros é o dos modelos
%portanto, precisamos do modelo de referência apenas por motivos de
%comparação
xms_p(:,1,k) = Am*xms(:,1,k) + bm*r(k);
xms(:,1,k+1) = xms(:,1,k) + h*xms_p(:,1,k);
saida_modelo(k+1) = hm_transposto*xms(:,1,k+1);
e_0(k+1) = saida_planta(k+1)-saida_modelo(k+1);
%tradução de theta_p_estimativa em termos dos polinômios e ganho da
%planta estimados

mu(k) = -q+(1+q)*exp(-e_0(k)^2/L);
if mu(k)>1
mu(k)=1;
end
if mu(k)<0
mu(k)=0;
end

theta_p_est_barra(1,k+1) = kp_nom - kp_barra*sign(e_0(k)*csip);
theta_p_est_barra(n+1,k+1) = -alfa_1_barra*sign(e_0(k)*csi1);
theta_p_est_barra(2:n,k+1) = -beta_barra.*sign(e_0(k)*csib);
theta_p_est_barra(n+2:2*n,k+1) = -alfa_nomec_barra.*sign(e_0(k)*csia);
theta_p_estimativa(:,k+1) = mu(k)*theta_p_estimativa(:,k+1)+(1-mu(k))*theta_p_est_

%verificar lei de controle
kp_chapeu(k+1) = theta_p_estimativa(1,k+1);
if kp_chapeu(k+1) < kp_bar
    kp_chapeu(k+1)=kp_bar;
end

beta_chapeu(:,1,k+1) = theta_p_estimativa(2:1:n,k+1)/kp_chapeu(k+1);
alfa_1_chapeu(k+1) = theta_p_estimativa(n+1,k+1);
alfa_chapeu(:,1,k+1) = theta_p_estimativa(n+2:1:2*n,k+1);

%Geração dos parâmetros do controlador a partir das estimativas
theta_2n(k+1) = km/kp_chapeu(k+1); %% OK
theta_n(k+1) = (alfa_1_chapeu(k+1)-alfa_m_1)/kp_chapeu(k+1);

```

```

theta_v1(:,1,k+1) = (beta_m - beta_chapeu(:,1,k+1))/gamma;
theta_v2(:,1,k+1) = (alfa_chapeu(:,1,k+1) - alfa_m+(alfa_m_1-alfa_1_chapeu(k+
theta_controlador(:,1,k+1) = [theta_v1(:,1,k+1); theta_n(k+1); theta_v2(:,1,k+1);

end

figure('Name','Resultados')

subplot(4,2,1)
plot(tempo,saida_planta-saida_modelo,'Color',[0 0.1 0.5],'LineWidth',2.0)
leg1 = legend('Erro de Saída e_o');
set(leg1,'FontSize', 10);
grid on
subplot(4,2,2)

plot(tempo,saida_modelo,'Color',[1 0.2 0],'LineWidth',2.0)
hold on
plot(tempo,saida_planta,'Color',[0.2 0 1],'LineWidth',2.0)
leg1 = legend('Saída do modelo, y_m', 'Saída da planta, y');
set(leg1,'FontSize', 10);
grid on
subplot(4,2,3)
plot(tempo2,u,'Color',[0.2 0 0.5],'LineWidth',2.0);
leg1 = legend('Sinal de Controle u');
set(leg1,'FontSize', 10);
grid on
for i=1:n
    subplot(4,2,i+3)

    plot(alfa(i,1),alfa(2*n-i,1),'Marker','*','Color',[0 0 0],'LineWidth',2.0)
    line(alfa(i,:),alfa(2*n-i,:), 'Color',[0 0.2 1],'LineWidth',3.0);
    line([0 0 1 1 0],[0 1 1 0 0], 'Color',[1 0.2 0], 'LineWidth',2.0)
    hold on
    plot(alfa(i,endk),alfa(2*n-i,endk), 'Marker','x','Color',[0.2 0.2 0.2], 'LineW
    leg1 = legend('Posição inicial *', 'Trajetória', ' Fecho Convexo', 'Posição Fi
    set(leg1,'FontSize', 10);
    grid on
end

subplot(4,2,[7 8])
plot(tempo2,mu,'Color',[0.2 0.2 0.2], 'LineWidth',0.7)
leg1 = legend('mu da Logica Fuzzy');
set(leg1,'FontSize', 10);

```

```
%plot(tempo2,z_planta-z_planta_estimado);  
%estimacao entrada-saida funcionando perfeitamente!  
%theta_p_estimativa(:,k)  
  
%figure('Name','w')  
%wacs(:,:) = w(:,1,:);  
%plot(tempo,wacs);  
%alfa(:,endk)  
%figure('Name','thetac')  
%tetracs(:,:) = theta_controlador(:,1,:);  
%plot(tempo,tetracs);  
%figure('Name','kp')  
%plot(tempo,kp_chapeu)  
%theta_p_estimativa(:,k)  
end
```

Capítulo 6

Conclusão

A técnica de estimação de parâmetros conhecida como Adaptação de Segundo Nível tem característica de garantia de convergência dos parâmetros para seus valores corretos na presença de um sinal que cause excitação dos modos da planta num intervalo de tempo finito. Sua aplicação ao Controle Adaptativo por Modelo de Referência, tanto no caso das variáveis de estado da planta acessíveis como no caso em que apenas a entrada e a saída da planta estão disponíveis para medição. Também foi aplicada ao Controle em Modo Dual Indireto Adaptativo Robusto, combinando as características consideradas desejáveis do Controle por Estrutura Variável, tais como convergência do erro para um domínio residual em tempo finito e rapidez no transitório da planta, com aquelas consideradas desejáveis no Controle Adaptativo por Modelo de Referência, como por exemplo o sinal de controle suave e a capacidade de "aprendizado" sobre os parâmetros da planta. Restam uma série de questões a serem respondidas acerca deste método de estimação e do seu emprego no Controle Adaptativo, que tentaremos listar a seguir:

- A Adaptação de Segundo nível atende ao conceito de condição de "matching" apresentado nos livros da literatura de controle adaptativo? Em especial, é possível caracterizar, em termos da distância mínima até a superfície do fecho, a magnitude da perturbação que pode ser introduzida na entrada da planta tal que ainda seja possível para o estimador produzir uma estimativa do vetor de parâmetros da planta tal que o controlador produza um sinal de controle que rejeite a perturbação.
- Existe prova de estabilidade através da teoria de Lyapunov da combinação do estimador por Adaptação de Segundo Nível com o Controle em Modo Dual Indireto Adaptativo Robusto para plantas de grau relativo unitário?
- Como utilizar as vantagens dos modelos de identificação série-paralelo no caso em que apenas a entrada e saída da planta estão disponíveis para medição.
- Como o conceito de Aprendizado Convergente se relaciona com plantas cujos parâmetros variam lentamente ao longo do tempo, como é o caso na maioria das aplicações industriais do Controle Adaptativo com estimação leis integrais?
- Como caracterizar um fecho convexo que contenha a região de incerteza dos parâmetros da planta? Em especial, como, partindo de uma planta intervalar repre-

sentada por 2^{2n} vértices correspondentes aos intervalos de seus parâmetros, calcular um fecho convexo de $2n + 1$ vértices no R^{2n} para que possamos utilizar a Adaptação de Segundo Nível minimizando o esforço computacional empregado.

É também necessário listar as limitações presentes neste documento, que pretendemos tratar ao transformá-lo gradualmente em uma dissertação completa. Pretendemos introduzir:

- Simulações referentes ao Controle Adaptativo Indireto utilizando os estimadores por Método do Gradiente e Método dos Mínimos Quadrados
- Simulações referentes ao Controle Adaptativo por Posicionamento de Polos
- Figuras demonstrando a simetria radial de trajetórias das estimativas dos parâmetros para plantas de ordem 1, no R^2
- Um detalhamento de trabalhos relacionados
- Apêndice contendo as Provas de Estabilidade já detalhadas na literatura
- Um detalhamento rigoroso do Controlador Adaptativo em Modo Dual Indireto por Modelo de Referência.

Finalmente, esperamos que o conteúdo pesquisado se mostre útil.

Referências Bibliográficas

- Boyd, S. & S. S. Sastry (1986), ‘Necessary and sufficient conditions for parameter convergence in adaptive control’, *Automatica* **22**(6), 629–639.
- Chen, Chi-Tsong (1999), *Linear System Theory and Design*, Oxford University Press.
- Chowdhary, Girish, Tansel Yucelen, Maximillian Mühlegg & Eric N. Johnson (2013), ‘Concurrent learning adaptive control of linear systems with exponentially convergent bounds’, *International Journal of Adaptive Control and Signal Processing* **27**(4), 280–301.
URL: <http://dx.doi.org/10.1002/acs.2297>
- Cunha, C. D. (2008), *Controlador em Modo Dual Adaptativo Robusto - DMARC*, Tese de doutorado, Universidade Federal do Rio Grande do Norte, Natal, RN.
- Cunha, C. D., A. D. Araujo & F. C. Mota (2007), ‘Controlador em modo dual adaptativo robusto para plantas com grau relativo unitário: Prova de estabilidade’, *Revista Controle e Automação* **18**(2), 223–232.
- Gushiken, P. Y. & A. D. Araujo (2016), Adaptação de segundo nível usando modelos fixos com desligamento do sinal persistentemente excitante, em X. C. B. de Automática, ed., ‘Vitória - Espírito Santo’, Editora da Sociedade Brasileira de Automática v. v.1. p, Anais do XXI Congresso Brasileiro de Automática. Vitória - Espírito Santo, pp. 1–6.
- Han, Z. & K. S. Narendra (2010a), Multiple adaptive models for control, em ‘Decision and Control (CDC), 2010 49th IEEE Conference on’, pp. 60–65.
- Han, Z. & K. S. Narendra (2010b), Multiple adaptive models for control, em ‘Decision and Control (CDC), 2010 49th IEEE Conference on’, pp. 60–65.
- Han, Z. & K. S. Narendra (2012), ‘New concepts in adaptive control using multiple models’, *IEEE Transactions on Automatic Control* **57**(1), 78–89.
- Hsu, L. (1990), ‘Variable structure model reference adaptive control using only input and output measurements: The general case’, *IEEE Trans. Automatic Control* **AC-35**(11), 1238–1243.
- Hsu, L., A. D. Araujo & R. R. Costa (1994), ‘Analysis and design of i/o based variable structure adaptive control’, *IEEE Trans. Automatic Control* **39**(1), 4–21.

- Hsu, L. & R. R. Costa (1989), 'Variable structure model reference adaptive control using only input and output measurements - part i', *International Journal of Control* **49**(2), 399–416.
- Ioannou, Petros A. & Jing Sun (1996), *Robust Adaptive Control*, Pearson Education, Inc.
- Khalil, Hassan K. (1996), *Nonlinear Systems*, Prentice Hall.
- M. Krstic, I. Kanellakopoulos & P. Kokotovic (1995), *Nonlinear and Adaptive Control Design*, Wiley.
- Mota, F. C. & A. D. Araujo (2002), 'Proposta de um controlador dual adaptativo robusto utilizando o modelo de takagi-sugeno', *Anais do XIV Congresso Brasileiro de Automática pp* pp. 173–177.
- Narendra, K. S. & A. M. Annaswamy (1989), *Stable Adaptive Systems*, Prentice-Hall.
- Narendra, K. S., Y. Wang & W. Chen (2014), Stability, robustness, and performance issues in second level adaptation, *em* 'American Control Conference (ACC), 2014', pp. 2377–2382.
- Narendra, Kumpati S., Yu Wang & Wei Chen (2012), The rationale for second level adaptation, *em* 'The 16th Yale Workshop on Adaptive and Learning Systems', Yale University.
- Ogata, Katsuhiko (2010), *Modern Control Engineering*, Pearson Education, Inc.
- Oliveira, J. B. (2003), *Controle adaptativo indireto por modelo de referência e estrutura variável*, Dissertação de mestrado, Universidade Federal do Rio Grande do Norte, Natal, RN.
- Oliveira, J. B. (2007), *Estabilidade e Robustez de um Controlador Adaptativo Indireto por Modelo de Referência e Estrutura Variável*, Tese de doutorado, Universidade Federal do Rio Grande do Norte, Natal, RN.
- Oliveira, J. B. & A. D. Araujo (2008a), 'Design and stability analysis of an indirect variable structure model reference adaptive control', *International Journal of Control* **81**(12), 1870–1877.
- Oliveira, J. B. & A. D. Araujo (2008b), A modified design for the vs-mrac based on the indirect approach: Stability analysis, *em* 'Proceedings of the 17th IFAC 2008 WC 1', pp. 13121–13126.
- Tahmasebi, S., M. A. Khansar & M. Teshnehlal (2016), Fuzzy reference model for adaptive indirect takagi-sugeno model reference control, *em* 'Proceedings of 2016 IEEE 13th International Conference on Networking', Sensing, and Control, pp. 1–6.
- Tao, G. (2003), *Adaptive Control Design and Analysis*, Wiley.

- Teixeira, L. R. L. (2011), *Uma abordagem indireta para o controlador em modo dual adaptativo robusto*, Dissertação de mestrado, Universidade Federal do Rio Grande do Norte, Natal, RN.
- Teixeira, L. R. L., J. B. Oliveira & A. D. Araujo (2013), An intuitive design for the dual mode adaptive robust controller based on indirect control, *em* 'Proceedings of the European Control Conference 2013 - ECC '13 1', pp. 4526–4531.
- Teixeira, Leonardo Rodrigues de Lima (2016), *Controlador em Modo Dual Adaptativo Robusto Indireto (IDMARC)*. 2016. 93f, Tese (Doutorado em Engenharia Elétrica e de Computação) - Centro de Tecnologia, Universidade Federal do Rio Grande do Norte, Natal.