

ADAPTAÇÃO DE SEGUNDO NÍVEL USANDO MODELOS FIXOS COM FATOR DE ESQUECIMENTO

*

*

Email:

Abstract— Second level adaptation is as a parameter estimation method for linear plants, using multiple identification models, that can be applied to indirect adaptive control. Second level adaptation is based on the idea that the parameter vector for a Linear Time Invariant (LTI) plant can be interpreted as a convex combination of the parameter vectors of a set of identification models. This way, with a second level of adaptation, the coefficients of this combination can be estimated, such that the estimate of the plant parameters is represented by the convex combination of the identification models. Simulation results show that this new method results in faster and smoother convergence than conventional adaptive control. In this paper, we introduce a modification in the adaptive law for second level adaptation, so as to accumulate recent information from the plant's transient response, while at the same time discarding older information. With this modification, we are able to achieve a smaller convergence time for the estimates and also smoother, when compared to the unmodified version of second level adaptation.

Keywords— Adaptive Control, Identification, Second Level Adaptation, Multiple Models

Resumo— A adaptação de segundo nível é um método de estimação dos parâmetros de plantas lineares, usando múltiplos modelos de identificação, que pode ser aplicada ao controle adaptativo indireto destas plantas. A adaptação de segundo nível se baseia na ideia de que o vetor de parâmetros da planta Linear Invariante no Tempo (LIT) pode ser interpretado como uma combinação convexa dos vetores de parâmetros pertencentes a um conjunto de modelos de identificação. Desta forma, com um segundo nível de adaptação, pode-se estimar os coeficientes desta combinação, de forma que a estimativa dos parâmetros da planta passe a ser representada pela combinação convexa dos modelos de identificação. Resultados de simulação demonstram que o novo método resulta em um melhor desempenho em relação ao controle adaptativo com leis integrais convencionais. Neste trabalho, introduzimos uma modificação na lei adaptativa da adaptação de segundo nível, de forma a acumular informações recentes do transitório da planta e dos modelos, ao mesmo tempo em que descartamos informações mais antigas. Com esta modificação, conseguimos um tempo menor de convergência das estimativas para seus valores corretos, e também uma convergência mais suave, em relação à adaptação de segundo nível convencional.

Palavras-chave— Controle Adaptativo, Identificação, Adaptação de Segundo Nível, Múltiplos Modelos.

1 Introdução

O controle adaptativo consiste numa forma de lidar com incertezas e variações paramétricas. No entanto, ao investigar a estabilidade e robustez deste tipo de controle, descobriu-se ao longo dos anos que, em muitos casos, eram necessárias modificações às leis adaptativas, como, por exemplo, a normalização, a projeção e o fator de esquecimento (Ioannou and Sun, 1996; Narendra and Annaswamy, 1989; Tao, 2003), já que para determinados tipos de perturbação e dinâmica não modelada, este tipo de controle poderia apresentar instabilidade (Rohrs et al., 1985). Em geral, estas modificações tendem a tornar o processo de estimação de parâmetros mais lento, o que constitui um problema, pois o desempenho do controle adaptativo durante o transitório depende, em parte, da rapidez e acurácia com que os parâmetros podem ser estimados. De fato, é geralmente aceito que o controle adaptativo é capaz de lidar com pequenas incertezas paramétricas limitadas, principalmente, pela rapidez e precisão com que é capaz de estimar os parâmetros do controlador. Como uma forma de lidar com incertezas maiores e de variação mais rápida, (Han and Narendra, 2012) introduziram

a adaptação de segundo nível, que estima os parâmetros da planta por meio de uma combinação convexa dos parâmetros de múltiplos modelos de identificação. Esta abordagem é pelo menos uma ordem de grandeza mais rápida que as leis integrais convencionais do controle adaptativo.

Neste trabalho, como uma forma de melhorar as características da adaptação de segundo nível, introduzimos uma modificação na lei adaptativa de estimação dos coeficientes da combinação convexa, passando a acumular e considerar informações de instantes do passado recente no processo de estimação, descartando informações que consideramos mais antigas, usando como critério um escalar $\sigma > 0$, que chamamos fator de esquecimento.

2 Formulação do Problema

Discutimos aqui algumas ideias referentes ao controle adaptativo convencional quando o objetivo é fazer com que a planta rastreie a saída de um modelo de referência. Assumimos que o vetor de estado da planta é acessível.

2.1 Controle Adaptativo Convencional com Variáveis de Estado Acessíveis

Seja a planta descrita por:

$$\Sigma_p : \dot{x}_p(t) = A_p x_p(t) + b u(t) \quad (1)$$

onde $x_p(t) \in \mathbb{R}^n$, $u(t) \in \mathbb{R}$ e A_p e b estão na seguinte forma canônica:

$$A_p = \begin{bmatrix} 0 & 1 & 0 & \dots & 0 \\ 0 & 0 & 1 & \dots & 0 \\ 0 & 0 & 0 & \dots & 0 \\ \dots & \dots & \dots & \dots & \dots \\ a_1 & a_2 & a_3 & \dots & a_n \end{bmatrix}, b = \begin{bmatrix} 0 \\ 0 \\ 0 \\ \dots \\ 1 \end{bmatrix}$$

Consideremos o vetor b conhecido e os parâmetros $[a_1, a_2, \dots, a_n]$ como sendo desconhecidos. Seja o vetor $\theta_p^T = [a_1, a_2, \dots, a_n]$ de parâmetros desconhecidos da planta, e assumimos que o mesmo se localiza em uma região conhecida do espaço de parâmetros $\mathbb{R}^n$.

Seja o modelo de referência descrito por:

$$\Sigma_m : \dot{x}_m(t) = A_m x_m(t) + b r(t) \quad (2)$$

onde A_m se encontra no mesmo formato de A_p , e é escolhida de forma que o modelo de referência seja estável. A referência $r(t)$ é definida pelo projetista e deve ser um sinal uniformemente limitado.

Definimos o erro de saída:

$$e_o(t) \triangleq x_m - x_p \quad (3)$$

que deve tender a 0 à medida que $t \rightarrow \infty$.

2.2 Caracterização

Na presença de incertezas paramétricas, o valor exato de θ_p é desconhecido. Não obstante, gostaríamos de escolher uma lei de controle que garanta a saída da planta seguindo a saída do modelo de forma assintótica. Para tanto, é necessário estimar os parâmetros incertos. Adicionalmente, queremos que o vetor de estimativas dos parâmetros da planta tenda ao valor correto e, portanto, usaremos um sinal rico em frequências, e, portanto, persistentemente excitante, de forma a garantir esta condição. Abordaremos este problema do ponto de vista do controle adaptativo indireto, isto é, estimando os parâmetros da planta para calcular os parâmetros do controlador.

No controle adaptativo indireto convencional, neste caso, escolhe-se a entrada:

$$u(t) = r(t) + k^T x_p(t) \quad (4)$$

O modelo usado para identificação é do tipo série-paralelo:

$$\dot{\hat{x}}_p = A_m \hat{x}_p(t) + [A_1(t) - A_m] x_p(t) + b u(t) \quad (5)$$

onde $\hat{x}_p$ é uma estimativa do vetor de estado da planta. Geramos o vetor de erro entre os vetores de estado da planta e de sua estimativa:

$$e_1(t) = \hat{x}_p(t) - x_p(t) \quad (6)$$

onde A_1 se encontra na forma canônica mostrada anteriormente e sua última linha consiste no vetor θ_1^T adaptado através de:

$$\dot{\theta}_1 = -e_1^T P b x_p(t) \quad (7)$$

onde P é uma matriz de ganhos definida positiva escolhida pelo projetista e k^T da lei de controle é dado por:

$$k^T = \theta_m - \theta_1 \quad (8)$$

onde θ_m corresponde à última linha transposta da matriz A_m e θ_1 é uma estimativa de θ_p .

Note-se que, caso θ_p fosse conhecido, a lei de controle poderia ser gerada diretamente:

$$u^*(t) = r(t) + k^{*T} x_p(t) \quad (9)$$

onde o vetor k^{*T} é dado por:

$$k^{*T} = \theta_m - \theta_p \quad (10)$$

Podemos, então, definir um erro de controle, como uma medida da diferença entre a lei de controle ideal $u^*(t)$ e a lei gerada com uma estimativa dos parâmetros da planta:

$$e_u(t) \triangleq u^*(t) - u(t) \quad (11)$$

3 Adaptação de Segundo Nível

3.1 Fecho Convexo

Em (Han and Narendra, 2010), foi provado que, se θ_p se encontra em um fecho convexo de pelo menos N vetores adaptativos $\theta_i(0)$, e as condições iniciais da planta e dos modelos são iguais, então o fecho convexo formado por $\theta_i(0)$ continuará a conter θ_p para todo o tempo. Desta forma, é possível calcular θ_p através de uma combinação convexa dos vetores $\theta_i(t)$.

$$\sum_{i=1}^N \alpha_i^* \theta_i = \theta_p, \quad \sum_{i=1}^N \alpha_i^* = 1 \quad (12)$$

ou seja, o problema da estimação de θ_p pode ser transformado no problema da estimação dos coeficientes α_i^* , com $i = 1, \dots, N$, da combinação convexa dos parâmetros dos múltiplos modelos fixos.

3.2 Múltiplos Modelos

Sejam os modelos de identificação fixos:

$$\Sigma_i : \dot{x}_i = A_m x_i(t) + [A_i(t) - A_m] x_p(t) + b u(t) \quad (13)$$

onde θ_i^T é a última linha de cada matriz A_i .

Sabemos que, se θ_p se encontra no fecho convexo delimitado por N modelos, existem $0 \leq \alpha_i^* \leq 1$, e $\sum_{i=1}^N \alpha_i^* = 1$ tal que:

$$\sum_{i=1}^N \alpha_i^* \theta_i(t_0) = \theta_p \quad (14)$$

Definimos o erro entre os modelos e a planta:

$$e_i(t) = x_i(t) - x_p(t) \quad (15)$$

com $i = 2, \dots, N$, e o erro entre os parâmetros da planta e dos modelos:

$$\phi_i(t) = \theta_i(t) - \theta_p \quad (16)$$

Então, segue que:

$$\sum_{i=1}^N \alpha_i^* \phi_i(t_0) = \sum_{i=1}^N \alpha_i^* \theta_i(t_0) - \left(\sum_{i=1}^N \alpha_i^* \right) \theta_p = 0 \quad (17)$$

Destas equações, temos que:

$$\sum_{i=1}^N \alpha_i^* e_i(t) = 0 \quad (18)$$

E, em forma matricial:

$$\bar{\Theta}(t) \bar{\alpha}^* = \theta_p \quad (19)$$

$$\bar{E}(t) \bar{\alpha}^* = 0 \quad (20)$$

onde $\bar{\alpha}^*$ é um vetor coluna cujos elementos correspondem aos coeficientes α_i^* , $\bar{\Theta}$ e $\bar{E}$ são matrizes $n \times N$, as colunas de $\bar{\Theta}$ correspondem aos vetores θ_i , e as colunas de $\bar{E}$ correspondem aos vetores e_i , com $i = 1, \dots, N$, e, então, podemos expressar:

$$\Theta(t) \alpha^* = \theta_p - \theta_N \quad (21)$$

$$E(t) \alpha^* = -e_N(t) \quad (22)$$

onde $\Theta(t)$ e $E(t)$ são matrizes $n \times (N-1)$, onde cada vetor coluna é $\theta_i(t) - \theta_N(t)$ e $e_i(t) - e_N(t)$, respectivamente, e $\alpha^* = [\alpha_1^*, \dots, \alpha_{N-1}^*]^T$. A partir de (22), podemos obter uma lei adaptativa para estimar α^* :

$$\dot{\hat{\alpha}} = \gamma_{n2} (-E^T(t) E(t) \hat{\alpha} - E^T(t) e_N(t)) \quad (23)$$

onde $\hat{\alpha}$ é uma estimativa de α^* e γ_{n2} é o ganho adaptativo, que deve ser escolhido pelo projetista, cumprindo $\gamma_{n2} > 0$. Note-se que a introdução de γ_{n2} não adiciona ou altera os pontos de equilíbrio da equação (23), e, portanto, pode ser feita sem perda de generalidade.

Alternativamente, α^* poderia ser calculado algebricamente por:

$$\alpha^* = -E^{-1}(t) e_N(t) \quad (24)$$

dependendo das condições numéricas para esta operação, como por exemplo o número de condição da matriz E . Note-se que apesar de $E^{-1}(t)$ e $e_N(t)$ serem funções do tempo, o valor de α^* é invariante.

A partir da estimativa obtida com (23), pode-se obter a estimativa $\hat{\alpha}$ de $\bar{\alpha}^*$:

$$\hat{\alpha} = \left[\hat{\alpha}^T \quad 1 - \sum_{i=1}^{N-1} \hat{\alpha}_i \right] \quad (25)$$

observando-se a restrição de convexidade dos coeficientes $\hat{\alpha}_i$, $i = 1, \dots, N$.

4 Adaptação de Segundo Nível com fator de esquecimento

Com base na ideia de Chowdhary et al. (2013), isto é, a de registrar informações de instantes anteriores e usá-las de forma concomitante com os dados disponíveis no instante atual, de forma a melhorar o comportamento da convergência das estimativas, buscamos introduzir o conceito de acúmulo das informações à adaptação de segundo nível, com base numa integral de convolução. Portanto, consideremos novamente a equação (22) e, a partir dela, podemos escrever:

$$E^T E \alpha^* = -E^T e_N \quad (26)$$

Podemos integrar ambos os lados de (26):

$$\begin{aligned} \int_0^t e^{-\sigma(t-\tau)} E^T(\tau) E(\tau) \alpha^* d\tau &= \\ &= - \int_0^t e^{-\sigma(t-\tau)} E^T(\tau) e_N(\tau) d\tau \end{aligned} \quad (27)$$

onde $\sigma > 0$ é chamado fator de esquecimento e serve como nosso critério de descarte de informações. Como α^* é invariante no tempo, podemos colocá-lo como um fator pós-multiplicando a integral $\int_0^t e^{-\sigma(t-\tau)} E^T(\tau) E(\tau) d\tau$ para obter:

$$\begin{aligned} \int_0^t e^{-\sigma(t-\tau)} E^T(\tau) E(\tau) d\tau \alpha^* &= \\ &= - \int_0^t e^{-\sigma(t-\tau)} E^T(\tau) e_N(\tau) d\tau \end{aligned} \quad (28)$$

Somamos (26) e (28) e, a seguir, colocamos todos os termos no lado direito da equação:

$$\begin{aligned}
0 = & - \int_0^t e^{-\sigma(t-\tau)} E^T(\tau) E(\tau) d\tau \alpha^* \\
& - E^T E \alpha^* - \int_0^t e^{-\sigma(t-\tau)} E^T(\tau) e_N(\tau) d\tau - E^T e_N
\end{aligned} \tag{29}$$

Note-se que esta passagem é a mesma que resultou na equação (23) a partir de (22).

A partir de (29), obtemos uma lei adaptativa para atualizar uma estimativa $\hat{\alpha}$ de α^* , utilizando informações do instante atual concomitantemente às acumuladas em instantes anteriores:

$$\begin{aligned}
\dot{\hat{\alpha}} = & \gamma_{n2} \left(- \int_0^t e^{-\sigma(t-\tau)} E^T(\tau) E(\tau) d\tau \hat{\alpha} \right. \\
& \left. - E^T E \hat{\alpha} - \int_0^t e^{-\sigma(t-\tau)} E^T(\tau) e_N(\tau) d\tau - E^T e_N \right)
\end{aligned} \tag{30}$$

Definimos as seguintes variáveis:

$$\begin{aligned}
M & \triangleq \int_0^t e^{-\sigma(t-\tau)} E^T(\tau) E(\tau) d\tau \\
v & \triangleq \int_0^t e^{-\sigma(t-\tau)} E^T(\tau) e_N(\tau) d\tau \\
X & \triangleq M + E^T E \\
x & \triangleq v + E^T e_N
\end{aligned} \tag{31}$$

que podem ser geradas diretamente, estipulando $M(0) = \mathbf{0}$ e $v(0) = \mathbf{0}$, pelas equações diferenciais:

$$\begin{aligned}
\dot{M} & = -\sigma M + E^T E \\
\dot{v} & = -\sigma v + E^T e_N
\end{aligned} \tag{32}$$

Então, reescrevemos (30) em forma compacta, adicionando o ganho adaptativo $\gamma_{n2} > 0$ como em (23), obtendo:

$$\dot{\hat{\alpha}} = \gamma_{n2} (-X \hat{\alpha} - x) \tag{33}$$

Definimos as seguintes variáveis:

$$\begin{aligned}
\tilde{\alpha} & = \hat{\alpha} - \alpha^* \\
\tilde{\tilde{\alpha}} & = \hat{\alpha} - \bar{\alpha}^*
\end{aligned} \tag{34}$$

Consideremos, então, a seguinte candidata a função de Lyapunov definida positiva:

$$V = \frac{1}{2\gamma_{n2}} \tilde{\alpha}^T \tilde{\alpha} \tag{35}$$

Derivando ao longo de suas trajetórias obtemos:

$$\dot{V} = -N \tilde{\alpha}^T (E^T E + M) \tilde{\alpha} \leq 0 \tag{36}$$

onde frisamos que N é o número de modelos utilizado. A derivada $\dot{V}$ obtida é semi-definida

negativa. Portanto, $\tilde{\tilde{\alpha}}$ não pode crescer e a estabilidade do estimador fica demonstrada. Frisamos que com este resultado a estabilidade da planta em malha fechada fica demonstrada, conforme os teoremas apresentados em (Han and Narendra, 2012). Adicionalmente, com a modificação proposta, a convergência da estimativa $\bar{\alpha}$ para $\bar{\alpha}^*$ passa a depender de informações presentes e passadas.

5 Controle e Identificação

Nesta seção, discutiremos resultados obtidos usando as equações (7), (23) e (33) para adaptar as estimativas. Consideramos a planta:

$$G(s) = \frac{1}{s^2 + a_1(t)s + a_2(t)} \tag{37}$$

onde $a_1(t) = 3 + g_1(t)$ e $a_2(t) = -4 + g_2(t)$, e as funções $g_1(t)$ e $g_2(t)$ são especificadas de acordo com a simulação. Escolhemos os modelos de identificação $\theta_1^T = [3.3 \quad -4.4]$, $\theta_2^T = [-1.2 \quad -4.4]$, $\theta_3^T = [3.3 \quad 0.1]$. Queremos que a planta siga o modelo de referência $\theta_m^T = [4 \quad 4]$. Partimos do repouso com a planta e modelos de identificação, e escolhemos $x_m^T(0) = [0.15 \quad 0.2]$ e as condições iniciais da estimativa da planta $\hat{\alpha}^T(0) = [0 \quad 1]$, ou seja, inicializamos o vetor de estimativas dos parâmetros da planta em θ_2 . No caso da lei adaptativa convencional, a matriz de ganhos adaptativos P é escolhida como $P = 25I$, onde I é a matriz identidade. Adicionalmente, escolhemos o parâmetro $\gamma_{n2} = 20$ para a adaptação de segundo nível e o fator de esquecimento $\sigma = 1$.

Para a simulação 1 temos a planta LIT, ou seja, $g_1(t) = 0$ e $g_2(t) = 0$.

Para a simulação 2, testamos uma variação rápida e suave de parâmetros $g_1(t) = 0.3\sin(t)$ e $g_2(t) = 0.4\cos(t)$.

Para a simulação 3, $g_1(t) = -1 + \text{sign}(\sin(\frac{t}{7}))$ e $g_2(t) = -0.5 + 0.5\text{sign}(\cos(\frac{t}{5}))$ que implica em uma planta com variação abrupta dos parâmetros.

Finalmente, na simulação 4, $g_1(t) = 0.3\sin(t) + \text{sign}(\sin(\frac{t}{7}))$ e $g_2(t) = 0.4\cos(t) + 0.5\text{sign}(\cos(\frac{t}{5}))$, onde há tanto variação abrupta quanto suave. Os resultados se encontram nas Figuras 1-4, numeradas de acordo com suas respectivas simulações.

Podemos ver, na Figura 1, que a lei adaptativa convencional não é capaz de alcançar o objetivo para um tempo de simulação igual a 100 segundos, pois a estimativa $\hat{a}_2$ foi inicializada com um valor muito distante do valor correto. De fato, apesar da presença de um sinal de referência rico em frequências, a velocidade com que esta




Figura 1: a) norma 2 do erro de saída $e_o(t)$, b) erro de controle dado por $e_u(t) = u^*(t) - u(t)$, c) erro paramétrico dado por $\phi_1(t) = \hat{a}_1 - a_1$, d) erro paramétrico dado por $\phi_2(t) = \hat{a}_2 - a_2$. As linhas pontilhadas azuis correspondem à equação (7), as linhas tracejadas amarelas à (23), e as linhas cheias verdes à (33).

lei adaptativa estima os parâmetros da planta se mostra insuficiente.

Em comparação, a adaptação de segundo nível, com ou sem fator de esquecimento, é capaz de fazer com que o erro de saída tenda para 0 mais rapidamente, assim como o erro de controle e erros paramétricos. Em relação à adaptação de segundo nível sem fator de esquecimento, a adaptação de segundo nível com fator de esquecimento se mostra ainda mais rápida e suave e, portanto, nesta situação, houve um benefício tangível em acumular informações de instantes passados.

Já na Figura 2, onde há variação paramétrica rápida e suave, novamente a lei adaptativa (7) se mostra inadequada, o que não é surpreendente, já que no caso da planta invariante no tempo mostrada na Figura 1 este já era o caso.

Por outro lado, para a adaptação de segundo nível, o erro de saída e controle se encontram numa vizinhança mais próxima da origem, assim como os erros paramétricos. Porém, é preciso notar que tanto (23) quanto (33) não são capazes de rastrear os valores de $a_1(t)$ e $a_2(t)$. Além disso, no caso da estimativa $a_2(t)$, notamos que o erro paramétrico diminui mais rapidamente, no caso da adaptação de segundo nível com fator de esquecimento.

A seguir, na Figura 3, para a planta com parâmetros que variam abruptamente, a lei adaptativa convencional apresenta dificuldades mais




Figura 2: a) norma 2 do erro de saída $e_o(t)$, b) erro de controle dado por $e_u(t) = u^*(t) - u(t)$, c) erro paramétrico dado por $\phi_1(t) = \hat{a}_1 - a_1$, d) erro paramétrico dado por $\phi_2(t) = \hat{a}_2 - a_2$. As linhas pontilhadas azuis correspondem à equação (7), as linhas tracejadas amarelas à (23), e as linhas cheias verdes à (33).




Figura 3: a) norma 2 do erro de saída $e_o(t)$, b) erro de controle dado por $e_u(t) = u^*(t) - u(t)$, c) erro paramétrico dado por $\phi_1(t) = \hat{a}_1 - a_1$, d) erro paramétrico dado por $\phi_2(t) = \hat{a}_2 - a_2$. As linhas pontilhadas azuis correspondem à equação (7), as linhas tracejadas amarelas à (23), e as linhas cheias verdes à (33).

uma vez. De fato, podemos observar que os erros, tanto de saída, quanto controle e paramétricos não tendem a 0.

Em contrapartida, ambos os tipos de adaptação de segundo nível lidam satisfatoriamente com este problema, sendo capazes de fazer com que todos os erros tendam a uma vizinhança próxima da origem após cada variação dos parâmetros. Destacamos também que, durante o período anterior à segunda variação dos parâmetros da planta, a adaptação de segundo nível com fator de esquecimento exhibe uma convergência mais rápida de sua estimativa $\hat{a}_2$ em direção ao valor correto.




Figura 4: a) norma 2 do erro de saída $e_o(t)$, b) erro de controle dado por $e_u(t) = u^*(t) - u(t)$, c) erro paramétrico dado por $\phi_1(t) = \hat{a}_1 - a_1$, d) erro paramétrico dado por $\phi_2(t) = \hat{a}_2 - a_2$. As linhas pontilhadas azuis correspondem à equação (7), as linhas tracejadas amarelas à (23), e as linhas cheias verdes à (33).

Finalmente, na Figura 4, a adaptação convencional é visivelmente inadequada para atingir o objetivo de controle, pois seus erros de saída e controle não tendem a 0 de forma suficientemente rápida.

No caso da adaptação de segundo nível, no entanto, apesar de mais uma vez não ser possível rastrear os parâmetros da planta, tanto o erro de saída quanto o erro de controle são mantidos numa vizinhança mais próxima da origem, em comparação com a lei adaptativa convencional.

6 Conclusões

A adaptação de segundo nível se mostra promissora em relação aos métodos convencionais

de identificação e controle de plantas LTI com incertezas, dentro das limitações discutidas, pois demonstra boa rapidez de convergência dos parâmetros para seus valores corretos. As propriedades de robustez e estabilidade são iguais ou melhores que as da adaptação convencional, como mostrado em (Narendra et al., 2014; Gushiken and Araujo, 2016). A modificação proposta resulta numa melhora da velocidade e suavidade de convergência das estimativas para seus valores corretos. Futuramente, continuaremos a comparar esta e outras estratégias de controle adaptativo.

Referências

- Chowdhary, G., Yucelen, T., Mühlegg, M. and Johnson, E. N. (2013). Concurrent learning adaptive control of linear systems with exponentially convergent bounds, *International Journal of Adaptive Control and Signal Processing* **27**(4): 280–301.
- Gushiken, P. Y. and Araujo, A. D. (2016). Adaptação de segundo nível usando modelos fixos com desligamento do sinal persistentemente excitante, *Anais do XXI Congresso Brasileiro de Automática. Vitória - Espírito Santo* pp. 1–6.
- Han, Z. and Narendra, K. S. (2010). Multiple adaptive models for control, *Decision and Control (CDC), 2010 49th IEEE Conference on*, pp. 60–65.
- Han, Z. and Narendra, K. S. (2011). Second level adaptation using multiple models, *Proceedings of the 2011 American Control Conference*, pp. 2350–2355.
- Han, Z. and Narendra, K. S. (2012). New concepts in adaptive control using multiple models, *IEEE Transactions on Automatic Control* **57**(1): 78–89.
- Ioannou, P. A. and Sun, J. (1996). *Robust adaptive control*, Pearson Education, Inc.
- Narendra, K. S. and Annaswamy, A. M. (1989). *Stable adaptive systems*, Prentice-Hall.
- Narendra, K. S., Wang, Y. and Chen, W. (2014). Stability, robustness, and performance issues in second level adaptation, *American Control Conference (ACC), 2014*, pp. 2377–2382.
- Rohrs, C. E., Valavani, L., Athans, M. and Stein, G. (1985). Robustness of continuous-time adaptive control algorithms in the presence of unmodeled dynamics, *IEEE Trans. Automatic Control AC-* **30**(9): 881–889.

Tao, G. (2003). *Adaptive control design and analysis*, Wiley.